


Ricardo Felipe Ferreira

ESTATÍSTICA MULTIVARIADA 1



1	Introdução	1
1.1	Os limites da análise estatística univariada	1
1.2	Expandindo a análise: introdução ao bivariado	7
1.3	Rumo à análise multivariada	14
2	Análise descritiva multivariada	15
2.1	Organização dos dados	15
2.2	Medidas descritivas	16
2.3	Visualização de dados	27
2.4	Exercícios	47
3	Vetores aleatórios	54
3.1	Distribuições multivariadas	54
3.2	Valor esperado de um vetor aleatório	62
3.3	Matriz de variâncias e covariâncias de um vetor aleatório	78
3.4	Matriz de correlações de um vetor aleatório	101
3.5	Particionamento de vetores aleatórios	106
3.6	Exercícios	111
4	Distribuição normal multivariada	120
4.1	A distribuição normal bivariada	120
4.2	Contornos da densidade de uma normal bivariada	128
4.3	Densidade e propriedades da normal multivariada	145
4.4	Exercícios	162
5	Inferência a partir de dados multivariados	167
5.1	Amostras aleatórias e estimadores não-viesados	167
5.2	Amostras aleatórias de uma distribuição normal multivariada	173
5.3	Teste de hipóteses para o vetor de médias de uma população normal	189
5.4	Regiões de confiança para o vetor de médias de uma população normal	201
5.5	Intervalos de confiança simultâneos	218
5.6	Inferência sobre o vetor de médias populacionais a partir de grandes amostras de dados multivariados	240
5.7	Exercícios	244
6	Comparação de vários vetores de médias	254
6.1	Comparações pareadas	254
6.2	Delineamento de experimentos com medidas repetidas para comparar trata- mentos	262
6.3	Análise de variância multivariada com um único fator	269
6.4	Análise de perfis	280
6.5	Exercícios	288
7	Considerações finais	296

1 Introdução

Na maioria dos fenômenos físicos e sociais diversas mensurações e/ou observações são feitas simultaneamente em cada um dos indivíduos ou objetos amostrados. Tipicamente, essas variáveis estão correlacionadas, tornando sua análise individual insuficiente para compreender o fenômeno estudado. A análise estatística multivariada permite examinar essas variáveis de forma conjunta, revelando a estrutura subjacente dos dados, mostrando como as diferentes variáveis se conectam e influenciam umas às outras, o que possibilita identificar padrões e relações não detectáveis em abordagens univariadas.

1.1 Os limites da análise estatística univariada

Para entender as limitações da análise univariada, vamos explorar o conjunto de dados `bdims` do pacote R `openintro`, que contém medidas antropométricas de 507 adultos fisicamente ativos (247 homens e 260 mulheres), incluindo diversas circunferências corporais, diâmetros ósseos, além de idade, peso e gênero. Nesta seção, focaremos exclusivamente na variável *altura*. Essa abordagem nos permitirá caracterizar adequadamente essa variável isoladamente antes de investigarmos, na próxima seção, como ela se relaciona com outras medidas corporais através de um análise bivariada.

Exemplo 1.1

Considere uma pesquisa estatística interessada em estudar a **altura média** de indivíduos fisicamente ativos no estado da Califórnia (EUA). Para isso, os pesquisadores coletaram uma amostra aleatória de 507 indivíduos fisicamente ativos, registrando a altura de cada participante.

- (a) Qual é a população de estudo?
- (b) Qual é a variável de interesse?
- (c) Qual é o parâmetro de interesse?
- (d) Como foi realizada a coleta de dados?
- (e) Quais análises estatísticas iniciais devem ser conduzidas após o registro dos dados?
- (f) Calcule e reporte em uma tabela organizada as seguintes estatísticas descritivas da variável altura: mínimo, primeiro quartil (Q_1), mediana, média, desvio pa

Exemplo 1.1

drão, terceiro quartil (Q_3) e máximo.

- (g) Qual das estatísticas do item (f) representa a melhor estimativa não-viesada para a altura média populacional? Justifique. Interprete essa estimativa no contexto do problema, incluindo sua unidade de medida.
- (h) Construa um *boxplot* das alturas. Inclua todos os elementos essenciais (bigodes, mediana, quartis, possíveis outliers). Há indícios de assimetria na distribuição? Existem possíveis valores atípicos?
- (i) Construa um histograma. A distribuição parece unimodal ou multimodal? Há indícios de normalidade? Qual é o intervalo de valores mais frequentes?
- (j) Construa um gráfico Q-Q (quantil-quantil) para os dados e, em seguida, realize o teste de Shapiro-Wilk assumindo nível de significância $\alpha = 1\%$. Há desvios sistemáticos da reta esperada? Rejeitamos ou não a normalidade? Qual o p-valor obtido? Interprete.
- (k) Podemos assumir que a distribuição da altura na população é normal?
- (l) Como podemos construir intervalos de confiança e conduzir testes de hipóteses?

SOLUÇÃO:

- (a) **População de estudo:** Todos os indivíduos fisicamente ativos no estado da Califórnia (EUA).
- (b) **Variável de interesse:** Altura X dos indivíduos (em centímetros).
- (c) **Parâmetro de interesse:** Altura média populacional (μ).
- (d) **Coleta de dados:** Foi obtida uma amostra aleatória de 507 indivíduos fisicamente ativos (247 homens e 260 mulheres), com medição padronizada da altura.
- (e) **Análises iniciais:**
 - Estatísticas descritivas básicas;
 - Visualização dos dados;
 - Verificação da aderência de alguma distribuição teórica (ex.: normal) aos dados.

Exemplo 1.1

(f) Estatísticas descritivas:

Tabela 1.1. Medidas descritivas das alturas (em cm).

Mínimo	Q1	Mediana	Média	Desv. Padr.	Q3	Máximo
147,2	163,8	170,3	171,1	9,4	177,8	198,1

Código R

```

1 # Estatísticas descritivas da altura
2 summary(hgt) # Mín, Q1, Mediana, Média, Q3, Máx
3 sd(hgt)      # Desvio padrão

```

Resultado no console

```

1   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
2 147.2  163.8   170.3   171.1   177.8   198.1
3
4 [1] 9.4

```

(g) Estimativa não-viesada:

- A média amostral ($\bar{x} = 171,1$ cm) é a melhor estimativa não-viesada para a altura média populacional.
- **Interpretação:** Com base na amostra observada, **estima-se** que a altura média dos indivíduos fisicamente ativos na Califórnia seja de 171,1 cm.

(h) Boxplot:

Código R

```

1 # Criar boxplot básico
2 boxplot(hgt,
3         main = "",
4         ylab = "Altura (cm)",
5         col = "white",
6         border = "black")
7
8 # Adicionar grid para melhor visualização
9 grid(nx = NA, ny = NULL, col = "gray", lty = "dotted")

```

Exemplo 1.1





Figura 1.1. *Boxplot* das alturas (em cm).

O *boxplot* das alturas revela uma distribuição simétrica. A posição central da mediana (170,3 cm) dentro da caixa do *boxplot*, igualmente distante de Q1 (163,8 cm) e Q3 (177,8 cm), juntamente com a proximidade entre mediana e média (171,1 cm), indica uma distribuição equilibrada e aproximadamente normal. Os bigodes se estendem de forma simétrica, abrangendo a faixa de valores típicos desde o mínimo (147,2 cm) até o máximo (198,1 cm), sem a presença de *outliers*. O intervalo interquartil (IQR) de 14 cm mostra que 50% centrais dos dados estão razoavelmente concentrados.

(i) **Histograma:**


Código R

```
1 # Criar histograma
2 hist(hgt,
3       main = "",
4       xlab = "Altura (cm)",
5       ylab = "Frequência",
6       col = "lightgreen",
7       border = "darkgreen",
8       prob = FALSE) # Probabilidades ao invés de
                       frequências
```

Exemplo 1.1**Figura 1.2.** Histograma das alturas (em cm).

O histograma apresenta distribuição unimodal (pico em 170 cm), com forma aproximadamente normal (curva de densidade alinhada à teórica, assimetria de 0.215 e curtose de 2.89), e intervalo predominante entre 165 – 175 cm, indicando simetria e aderência à normalidade, exceto por discretos desvios nas caudas.

(j) **Gráfico Q-Q e teste de normalidade:**

**Figura 1.3.** Gráfico Q-Q das alturas normalizadas.

Exemplo 1.1

Código R

```

1 # Normalizar a variável
2 hgt_normalizado <- (hgt - mean(hgt)) / sd(hgt)
3
4 # Gráfico Q-Q com linha teórica
5 qqnorm(hgt_normalizado,
6         main = "",
7         xlab = "Quantis teóricos",
8         ylab = "Quantis amostrais normalizados")
9
10 qqline(hgt_normalizado, col = "red")
11
12 # Teste de Shapiro-Wilk com alpha = 1%
13 shapiro.test(hgt)

```

Resultados do teste

```

1 Estatística do teste: W = 0.9935
2 p-valor: 0.01045
3 Conclusão (alpha = 0.01): Não rejeitar normalidade

```

- **Interpretação:** O gráfico Q-Q mostra que os pontos seguem aproximadamente a linha teórica (vermelha), com pequenos desvios nas caudas. Ao **nível de significância de 1%, não rejeitamos** a hipótese nula do teste de Shapiro-Wilk. Portanto, **não há evidências estatísticas suficientes** para concluir que a distribuição das alturas difere de uma distribuição normal.

(k) Como **não há evidências contra a normalidade**, podemos **assumir** que a **altura** X dos indivíduos dessa população **segue aproximadamente** uma distribuição normal, i.e.,

$$X \sim \text{Normal}(\mu, \sigma^2),$$

em que

- μ : representa a **altura média populacional**;
- σ^2 : representa a **variância da altura na população**.

Exemplo 1.1

(l) Como $X \sim \text{Normal}(\mu, \sigma^2)$, valem as seguintes implicações

$$X \sim \text{Normal}(\mu, \sigma^2) \Rightarrow \bar{X} \sim \text{Normal}\left(\mu, \frac{\sigma^2}{n}\right) \Rightarrow T := \frac{\bar{X} - \mu}{s/\sqrt{n}} \sim t_{n-1}.$$

Portanto,

- T é uma **quantidade pivotal**, permitindo obter **estimativas intervalares** para μ .
- T é uma **estatística** para **testar**, por exemplo, $H_0 : \mu = 170 \text{ cm}$ vs. $H_1 : \mu \neq 170 \text{ cm}$, possibilitando a realização de **testes de hipóteses**.

A análise univariada da altura revelou sua distribuição (média, variância e normalidade), porém apresenta limitações ao ignorar relações com outras variáveis como peso, idade, gênero e medidas corporais. Questões fundamentais sobre os fatores que influenciam a altura ou padrões entre grupos permanecem sem resposta, evidenciando a necessidade de técnicas multivariadas para explorar simultaneamente múltiplas variáveis e suas interações.

1.2 Expandindo a análise: introdução ao bivariado

Para avançar além das limitações da análise univariada, agora examinaremos conjuntamente a *altura* e a *circunferência do tornozelo* no mesmo conjunto de dados `bdims`, explorando como essas variáveis se relacionam. Enquanto o Exemplo 1.1 nos permitiu caracterizar isoladamente a distribuição das alturas, esta análise bivariada revelará padrões conjuntos e interdependências entre as medidas corporais.

Exemplo 1.2

Considere a mesma pesquisa estatística descrita no Exemplo 1.1.. No entanto, agora estamos interessados em estudar **conjuntamente** a **altura média** (em cm) e o **diâmetro médio do tornozelo** (em cm) de indivíduos fisicamente ativos no estado da Califórnia (EUA). Vamos considerar a mesma amostra aleatória de 507 indivíduos fisicamente ativos.

- Especifique o vetor de variáveis aleatórias de interesse.
- Defina o vetor de parâmetros populacionais.

Exemplo 1.2

- (c) Quais análises estatísticas iniciais devem ser realizadas?
- (d) Apresente as estatísticas descritivas em tabela.
- (e) Estime o vetor de médias populacionais e interprete.
- (f) Calcule e interprete a matriz de covariâncias amostrais.
- (g) Calcule e interprete a matriz de correlações amostrais.
- (h) Construa o gráfico de dispersão das variáveis.
- (i) Verifique a normalidade bivariada através de histogramas marginais, gráficos Q-Q individuais e teste de Shapiro-Wilk.
- (j) Conclua sobre a distribuição conjunta das variáveis.

SOLUÇÃO:

(a) **Vetor de variáveis:** $\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} = \begin{bmatrix} \text{Altura} \\ \text{Diâmetro do tornozelo} \end{bmatrix}.$

(b) **Vetor de médias populacionais:** $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = \begin{bmatrix} \mathbb{E}[X_1] \\ \mathbb{E}[X_2] \end{bmatrix}.$

(c) **Análises iniciais:**

- Estatísticas descritivas marginais;
- Matrizes de covariância e correlação;
- Visualizações bivariadas;
- Verificação de normalidade.

(d) **Estatísticas descritivas:**

Tabela 1.2. Medidas descritivas das alturas e dos diâmetros dos tornozelos (ambos em cm).

Variável	Mínimo	Q1	Mediana	Média	Q3	Máximo
Altura	147,2	163,8	170,3	171,1	177,8	198,1
Tornozelo	9,9	13,0	13,8	13,9	14,8	17,2

Exemplo 1.2

Código R

```

1 # Estatísticas descritivas
2 summary(bdims[,c("hgt", "ankle.di")])

```

(e) **Vetor de médias amostrais:** $\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix} = \begin{bmatrix} 171,1 \\ 13,9 \end{bmatrix}$.

Com base na amostra observada, **estima-se** que a altura média dos indivíduos fisicamente ativos no estado da Califórnia (EUA) seja de 171,1 cm e que o diâmetro médio de seus tornozelos seja de 13,9 cm.

(f) **Matriz de covariâncias:** $\mathbf{S} = \begin{bmatrix} s_1^2 & s_{12} \\ s_{21} & s_2^2 \end{bmatrix} = \begin{bmatrix} 88,50 & 8,05 \\ 8,05 & 1,56 \end{bmatrix}$.

- As variâncias **não são comparáveis**, pois as **escalas** das variáveis são **diferentes**:
 - altura varia 147,2 cm até 198,1 cm (amplitude = 50,9 cm);
 - diâmetro do tornozelo varia de 9,9 cm até 17,2 cm (amplitude = 7,3 cm).
- A covariância amostral é $s_{12} = s_{21} = 8,05 > 0$, o que indica uma relação linear **positiva** entre as variáveis, i.e., as variáveis **tendem** a variar no **mesmo sentido**.

Código R

```

1 #Matriz de variâncias e covariâncias amostral
2 cov(bdims[,c("hgt", "ankle.di")])

```

(g) **Matriz de correlações:** $\mathbf{R} = \begin{bmatrix} r_1^2 & r_{12} \\ r_{21} & r_2^2 \end{bmatrix} = \begin{bmatrix} 1,00 & 0,69 \\ 0,69 & 1,00 \end{bmatrix}$.

Com base na amostra observada de 507 indivíduos fisicamente ativos na Califórnia, **estima-se** que a correlação linear entre a altura e o diâmetro do tornozelo seja de 0,69. Esse resultado sugere uma **relação linear positiva forte** entre as variáveis. Dessa forma, há **indicativos** de que, na população estudada, indivíduos mais altos **tendem** a apresentar tornozelos mais largos.

Exemplo 1.2

Código R

```

1 #Matriz de correlações amostral
2 cor(bdims[,c("hgt", "ankle.di")])

```

(h) Gráfico de dispersão:




Figura 1.4. Gráfico de dispersão da altura vs. diâmetro do tornozelo.

Código R

```

1 #Gráfico de dispersão da altura vs. diâmetro do tornozelo
2 plot(hgt, ank_di,
3       main = "",
4       xlab = "Altura (cm)",
5       ylab = "Diâmetro do tornozelo (cm)",
6       pch = 19,
7       cex = 0.5)

```

(i) Verificação de normalidade:

Ao nível de significância de 1%, não rejeitamos a hipótese nula do teste de Shapiro-Wilk. Portanto, não há evidências estatísticas suficientes para concluir que nem a distribuição das alturas nem a distribuição dos diâmetros dos tornozelos difere de uma distribuição normal.

Exemplo 1.2




Figura 1.5. Histograma das alturas (em cm) e dos diâmetros dos tornozelos (em cm).




Figura 1.6. Gráfico Q-Q das alturas normalizadas e dos diâmetros dos tornozelos normalizados.

Tabela 1.3. Resultado do teste de Shapiro-Wilk para normalidade da distribuição das alturas e dos diâmetros dos tornozelos na população.

Variável	p-valor
Altura	0,01045
Tornozelo	0,09595

Exemplo 1.2

Código R

```

1 # Histograma 1: Altura
2 hist(hgt,
3     breaks = 11,
4     col = "lightgreen",
5     #border = "white",
6     main = "",
7     xlab = "Altura (cm)",
8     ylab = "Frequência")
9
10 # Histograma 2: Diâmetro do Tornozelo
11 hist(ank_di,
12     breaks = 11,
13     col = "salmon",
14     #border = "white",
15     main = "",
16     xlab = "Diâmetro (cm)",
17     ylab = "Frequência")
18
19 altura_normalizada <- (hgt - mean(hgt))/sd(hgt)
20 tornozelo_normalizado <- (ank_di - mean(ank_di))/sd(ank_di)
21
22 # Configurar layout para 2 gráficos lado a lado (1 linha,
23   2 colunas)
24 par(mfrow = c(1, 2)) # 1 linha, 2 colunas
25
26 #QQ-plot da altura normalizada
27 qqnorm(altura_normalizada,
28     main = "",
29     xlab = "Quantis teóricos",
30     ylab = "Quantis amostrais normalizados (altura)")
31 qqline(altura_normalizada,
32     col = "red")

```


Exemplo 1.2

```

1 ##QQ-plot do diâmetro do tornozelo normalizado
2 qqnorm(tornozelo_normalizado,
3       main = "",
4       xlab = "Quantis teóricos",
5       ylab = "Quantis amostrais normalizados (diâmetro do
6             tornozelo)")
7 qqline(tornozelo_normalizado,
8       col = "red")
9
10 shapiro.test(hgt) #Teste de normalidade para a altura
11 shapiro.test(ank_di) #Teste de normalidade para o diâmetro
    do tornozelo

```

- (j) Como **não há evidências contra a normalidade**, podemos **assumir** que tanto a **altura** X_1 quanto o **diâmetro** X_2 dos tornozelos dos indivíduos dessa população **seguem aproximadamente** uma distribuição normal, i.e.,

$$X_1 \sim \text{Normal}(\mu_1, \sigma_1^2) \text{ e } X_2 \sim \text{Normal}(\mu_2, \sigma_2^2)$$

em que

- μ_1 : representa a **altura média populacional**;
- μ_2 : representa o **diâmetro médio do tornozelo populacional**;
- σ_1^2 : representa a **variância da altura na população**;
- σ_2^2 : representa a **variância do diâmetro do tornozelo na população**.

Dessa forma é razoável assumir $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, em que

- $\boldsymbol{\mu} := \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ é o **vetor de médias populacional**;
- $\boldsymbol{\Sigma} := \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{21} & \sigma_2^2 \end{bmatrix}$ é a **matriz de variâncias e covariâncias populacional**.

Logo,

$$\bar{\mathbf{X}} \sim \text{Normal}_2\left(\boldsymbol{\mu}, \frac{1}{n}\boldsymbol{\Sigma}\right) \Rightarrow T^2 := n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \frac{2(n-1)}{n-2} F_{2,n-2},$$

Exemplo 1.2

em que $F_{2,n-2}$ é a distribuição F de Snedecor com p e $n - p$ graus de liberdade. Portanto,

- T^2 é uma **quantidade pivotal**, permitindo obter **regiões de confiança** para μ .
- T^2 é uma **estatística** para **testar**, por exemplo, $H_0 : \mu = \mu_0$ vs. $H_1 : \mu \neq \mu_0$, possibilitando a realização de **testes de hipóteses**.

A análise bivariada entre altura e circunferência do tornozelo revelou uma relação linear significativa, demonstrando como variáveis antropométricas podem variar conjuntamente. No entanto, mesmo essa abordagem ainda é limitada: não captura interações com outras medidas corporais (como peso ou diâmetros ósseos) nem identifica padrões condicionais a grupos específicos (por gênero ou faixa etária, por exemplo). Essas limitações reforçam a necessidade de métodos multivariados mais completos.

1.3 Rumo à análise multivariada

A análise multivariada engloba duas áreas principais: *estatística descritiva* e *inferencial*. No âmbito *descritivo*, buscamos, nesta etapa inicial, combinações lineares ótimas de variáveis, cujo critério de otimalidade varia conforme a técnica e o objetivo específico. Na *inferência multivariada*, muitas técnicas são extensões de procedimentos univariados. Sendo assim, adotamos a abordagem de revisar primeiro o método univariado antes de apresentar sua versão multivariada, como feito neste capítulo.

Iniciaremos com a organização e análise descritiva de dados, introduzindo vetores aleatórios e suas propriedades amostrais, como o vetor de médias e a matriz de covariância. Em seguida, abordaremos as distribuições multivariadas, com ênfase na normal multivariada, que é fundamental para a inferência estatística. Posteriormente, exploraremos técnicas inferenciais, incluindo a construção de regiões de confiança e testes de hipóteses sobre vetores de médias. Por fim, avançaremos para métodos mais complexos, como a ANOVA multivariada (MANOVA) e a regressão linear multivariada, aplicados a problemas reais.

Com este curso, espero que o(a) leitor(a) seja capaz de compreender as técnicas multivariadas – seus propósitos, pressupostos, limitações e particularidades –, selecionar as técnicas mais adequadas para cada conjunto de dados multivariados e interpretar corretamente os resultados de análises computacionais.

Bom estudo!

2 Análise descritiva multivariada

Na análise multivariada, trabalhamos com conjuntos de dados que envolvem múltiplas características medidas simultaneamente - como peso, altura e idade em um estudo antropométrico; ou vendas, custos e satisfação do cliente em uma análise de negócios. Essas informações, quando organizadas em tabelas ou representadas graficamente, revelam padrões e relações entre as variáveis que seriam difíceis de identificar isoladamente. Complementando a organização visual, medidas descritivas (como médias, variações e correlações) quantificam as características essenciais dos dados. Neste capítulo, exploramos os fundamentos para estruturar e descrever dados multivariados de maneira sistemática, abordando técnicas básicas de organização, representação e sumarização que constituem a base para análises mais complexas.

2.1 Organização dos dados

Dados multivariados surgem sempre que um investigador, buscando entender um fenômeno físico ou social, seleciona e observa $p \geq 1$ *variáveis* em n *indivíduos, objetos* ou *unidades experimentais*. Consequentemente, os dados multivariados podem ser exibidos da seguinte forma:

	Variável 1 (X_1)	Variável 2 (X_2)	...	Variável k (X_k)	...	Variável p (X_p)
Item 1:	x_{11}	x_{12}	...	x_{1k}	...	x_{1p}
Item 2:	x_{21}	x_{22}	...	x_{2k}	...	x_{2p}
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
Item j :	x_{j1}	x_{j2}	...	x_{jk}	...	x_{jp}
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
Item n :	x_{n1}	x_{n2}	...	x_{nk}	...	x_{np}

em que x_{jk} representa o valor da k -ésima variável X_k observada no j -ésimo item, para todo $1 \leq j \leq n$ e $1 \leq k \leq p$.

Matematicamente, podemos representar os dados multivariados construindo a matriz de dados $\mathbf{X} \in M_{n \times p}(\mathbb{R})$, que contém todas as observações em todas as variáveis, i.e.,

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}.$$

Exemplo 2.1: (Johnson e Wichern, 2014, p.6, tradução e grifo nosso)

Uma seleção de **quatro** recibos de uma livraria universitária foi obtida para investigar a natureza das vendas de livros. Cada recibo forneceu, entre outras coisas, o número de livros vendidos e o valor total de cada venda. Seja a primeira variável (X_1) o valor total em dólares das vendas e a segunda variável (X_2) o número de livros vendidos. Suponha que os dados, em forma tabular, sejam:

Variável 1 (vendas em dólares): 42 52 48 58
 Variável 2 (número de livros): 4 5 4 3

- (a) Determine o número p de variáveis e a quantidade n de observações neste estudo.
- (b) Construa a matriz de dados $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ correspondente.

SOLUÇÃO:

- (a) Nesse estudo, temos $p = 2$ variáveis (valor total X_1 em dólares das vendas e o número X_2 de livros vendidos) e $n = 4$ observações (cada um dos quatro recibos representa uma observação independente).
- (b) A matriz de dados $\mathbf{X} \in M_{4 \times 2}(\mathbb{R})$ é dada por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \\ x_{41} & x_{42} \end{bmatrix} = \begin{bmatrix} 42 & 4 \\ 52 & 5 \\ 48 & 4 \\ 58 & 3 \end{bmatrix}.$$

2.2 Medidas descritivas

Quando trabalhamos com muitos dados de uma só vez, fica difícil enxergar padrões só olhando para os números brutos (observações). É aí que as estatísticas descritivas entram em ação - elas são como *resumos numéricos* que capturam as informações mais importantes de forma organizada. A média, por exemplo, nos diz qual é o valor central do conjunto, enquanto medidas como a variância mostram o quanto os dados variam em torno dessa média. Nesta seção, vamos focar em três tipos desses resumos: (i) os que mostram onde os dados se concentram (como a média), (ii) os que indicam o espalhamento dos valores (como a variância), e (iii) os que revelam relações lineares entre variáveis (covariâncias e

correlações de Pearson). São ferramentas simples, mas poderosas, para começar a entender qualquer conjunto de dados multivariados.

Sejam $X_1, X_2, \dots, X_p$ as p variáveis de um estudo. Para cada variável X_k (como peso, altura ou notas em uma prova), a média aritmética das observações pode ser calculada de duas formas:

- *média populacional* (μ_k): quando consideramos *todos* os itens da população (situação ideal, porém rara na prática);
- *média amostral* ($\bar{x}_k$): quando trabalhamos com uma amostra de n observações (caso mais frequente em pesquisas).

Nesse sentido, para todo $k = 1, 2, \dots, p$, a *média populacional* μ_k da variável X_k é a *esperança* de X_k , i.e.,

$$\mu_k := \mathbb{E}[X_k].$$

Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k calculamos a *média amostral* $\bar{x}_k$ da seguinte maneira

$$\bar{x}_k := \frac{x_{1k} + x_{2k} + \dots + x_{nk}}{n} = \frac{1}{n} \sum_{j=1}^n x_{jk},$$

qualquer que seja $k = 1, 2, \dots, p$. A média μ_k representa um *valor central* da variável X_k na *população*, enquanto $\bar{x}_k$ representa um *valor central* de X_k na *amostra* coletada. As p médias populacionais e as p médias amostrais podem ser organizadas em vetores.

Definição 2.1: Vetores de médias

Sejam $X_1, X_2, \dots, X_p$ as p variáveis de um estudo.

(a) O *vetor de médias populacionais* é o vetor $\boldsymbol{\mu} \in \mathbb{R}^p$ tal que

$$\boldsymbol{\mu} := \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix}.$$

(b) Considere que n observações $x_{1k}, x_{2k}, \dots, x_{nk}$ foram realizadas em cada uma das variáveis X_k , $k = 1, 2, \dots, p$. O *vetor de médias amostrais* é o vetor $\bar{\mathbf{x}} \in \mathbb{R}^p$ tal que

Definição 2.1

$$\bar{\mathbf{x}} := \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}.$$

Assim como a média, a variabilidade das observações pode ser analisada de duas formas:

- *variância populacional* (σ_k^2): quando calculada para *todos* os itens da população (situação ideal, porém rara na prática);
- *variância amostral* (s_k^2): quando estimada a partir de uma amostra de n observações (caso mais frequente em pesquisas).

Nesse sentido, para todo $k = 1, 2, \dots, p$, a *variância populacional* σ_k^2 da variável X_k é a *variância* de X_k , i.e.,

$$\sigma_k^2 := \text{Var}[X_k].$$

Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k calculamos a *variância amostral* σ_k^2 da seguinte maneira

$$s_k^2 := \frac{(x_{1k} - \bar{x}_k)^2 + \dots + (x_{nk} - \bar{x}_k)^2}{n} = \frac{1}{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2,$$

qualquer que seja $k = 1, 2, \dots, p$. Para cada variável X_k , a *variância populacional* σ_k^2 é o quanto esperamos que a variável X_k desvie da sua média μ_k , enquanto a *variância amostral* mede o quanto, em média, as observações $x_{1k}, x_{2k}, \dots, x_{nk}$ se dispersam em torno da média $\bar{x}_k$.

É importante destacar três pontos sobre o cálculo da variância amostral:

1. **Divisor n vs $n - 1$:** Embora tenhamos usado n no denominador, muitos livros utilizam $n - 1$. Essa diferença é especialmente relevante quando trabalhamos com poucos dados (pequeno n), pois o termo $n - 1$ corrige uma tendência de subestimação da variância real da população. As duas versões da variância amostral serão sempre diferenciada.
2. **Notação s_{kk} :** Quando organizamos as variâncias de múltiplas variáveis em uma matriz (ver Definição 2.2), usamos a notação s_{kk} para a variância da k -ésima variável. Isso ajuda a identificar claramente a posição de cada medida na tabela, mantendo a

equivalência $s_k^2 = s_{kk}$. Por exemplo, numa pesquisa com peso (X_1) e altura (X_2), teríamos s_{11} para a variância dos pesos e s_{22} para a variância das alturas.

3. **Desvio-padrão** $\sqrt{s_{kk}}$: Enquanto a variância (s_{kk}) mede a dispersão nos dados em *unidades ao quadrado* (ex.: cm^2 se medirmos altura), o *desvio padrão* ($\sqrt{s_{kk}}$) traz essa medida de volta para a escala original dos dados (cm, no caso da altura), o permite uma comparação direta com os dados originais.

Quando coletamos dados com múltiplas características, é importante entender como elas se relacionam. A *covariância* é uma medida de associação linear entre duas variáveis, i.e., ela nos diz se duas variáveis tendem a variar linearmente juntas em um mesmo sentido ou não. Nesse sentido, para todo $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$ com $i \neq k$, a *covariância populacional* σ_{ik} entre as variáveis X_i e X_k é *covariância* de X_i com X_k , i.e.,

$$\sigma_{ik} := \text{Cov}[X_i, X_k] := E[(X_i - \mu_i)(X_k - \mu_k)].$$

Quando coletamos n pares de observações para duas variáveis quaisquer X_i e X_k do conjunto de p variáveis (altura e peso, por exemplo), a *covariância amostral* é o produto médio dos desvios de suas respectivas médias, i.e.,

$$s_{ik} := \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k),$$

quaisquer que sejam $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$. Tanto a *covariância populacional* σ_{ik} quanto a *amostral* s_{ik} são número reais, quando esse número é

- **um valor positivo:** tendência de ambas variáveis aumentarem ou diminuïrem juntas;
- **um valor negativo:** quando uma variável aumenta, a outra tende a diminuir e vice-versa;
- **próximo de zero:** ausência de relação linear consistente.

Notamos que a covariância (populacional e amostral) se reduz à variância (populacional e amostral, respc.) quando $i = k$. Além disso, $\sigma_{ik} = \sigma_{ki}$ e $s_{ik} = s_{ki}$ para todos $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$. Nesse sentido, podemos organizar as variâncias e covariâncias (populacionais e amostrais) em matrizes simétricas.

Definição 2.2: Matrizes de variâncias e covariâncias

Sejam $X_1, X_2, \dots, X_p$ as p variáveis de um estudo.

- (a) A *matriz de variâncias e covariâncias populacionais* é a matriz *simétrica* $\Sigma \in M_{p \times p}(\mathbb{R})$ tal que

$$\Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix}.$$

- (b) Considere que n observações $x_{1k}, x_{2k}, \dots, x_{nk}$ foram realizadas em cada uma das variáveis X_k , $k = 1, 2, \dots, p$. A *matriz de variâncias e covariâncias amostrais* é a matriz *simétrica* $S_n \in M_{p \times p}(\mathbb{R})$ tal que

$$S_n = \begin{bmatrix} s_{11} & s_{12} & \cdots & s_{1p} \\ s_{21} & s_{22} & \cdots & s_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ s_{p1} & s_{p2} & \cdots & s_{pp} \end{bmatrix}.$$

O subscrito n utilizado para denotar a matriz de variâncias e covariâncias S_n é usado para lembrar que n é empregado como divisor para os elementos s_{ik} .

O *coeficiente de correlação de Pearson* é a última medida descritiva que vamos considerar nesta seção. Ela é a medida mais usada para avaliar relações lineares entre duas variáveis. Suas principais vantagens são que ela independe das unidades, permitindo, comparar variáveis com escalas diferentes (ex.: peso [kg] e altura [cm]), e varia entre -1 e 1, o que facilita a interpretação da força da relação. Nesse sentido, para todo $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$ com $i \neq k$, a *correlação populacional* ρ_{ik} entre as variáveis X_i e X_k é *correlação* de X_i com X_k , i.e.,

$$\rho_{ik} := \frac{\sigma_{ik}}{\sqrt{\sigma_{ii}}\sqrt{\sigma_{kk}}}.$$

Quando coletamos n pares de observações para duas variáveis quaisquer X_i e X_k do conjunto de p variáveis (altura e peso, por exemplo), a *correlação amostral* é definida da seguinte maneira

$$r_{ik} := \frac{s_{ik}}{\sqrt{s_{ii}}\sqrt{s_{kk}}} = \frac{\sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k)}{\sqrt{\sum_{j=1}^n (x_{ji} - \bar{x}_i)^2} \sqrt{\sum_{j=1}^n (x_{jk} - \bar{x}_k)^2}},$$

quaisquer que sejam $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$. Notamos que a correlação (populacio

nal ou amostral) é igual a 1 quando $i = k$ e que $\rho_{ik} = \rho_{ki}$ e $r_{ik} = r_{ki}$ para todo $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$.

O coeficiente de correlação (populacional ou amostral) é uma versão padronizada da covariância (populacional ou amostral, resp.), onde o produto das raízes quadradas das variâncias (populacionais ou amostrais, resp.) fornece a padronização. Observe que a *correlação amostral* r_{ik} possui o mesmo valor se n ou $n - 1$ é escolhido como o divisor comum para s_{ii} , s_{kk} e s_{ik} .

Embora os sinais da correlação e da covariância sejam os mesmos, a correlação é geralmente mais fácil de interpretar porque sua magnitude é limitada. Para resumir, a correlação r (populacional ou amostral) tem as seguintes propriedades:

- $r = +1$: relação linear perfeita positiva;
- $0 < r < 1$: relação linear positiva;
- $r \approx 0$: ausência de relação linear;
- $-1 < r < 0$: relação linear negativa;
- $r = -1$: relação linear perfeita negativa.

Neste texto, desde que mencionado o contrário, vamos assumir as seguintes interpretações para a correlação r (populacional ou amostral) entre duas variáveis:

Tabela 2.1. Convenção a respeito da interpretação da magnitude da correlação (populacional ou amostral).

Intervalo	Força	Interpretação
$0,9 \leq r \leq 1,0$	Muito forte	Relação linear quase perfeita
$0,7 \leq r < 0,9$	Forte	Relação linear evidente
$0,5 \leq r < 0,7$	Moderada	Relação linear perceptível
$0,3 \leq r < 0,5$	Fraca	Relação linear tênue
$0,0 \leq r < 0,3$	Muito fraca	Relação linear desprezível

É importante ressaltar que em áreas como física, correlações abaixo de 0,9 podem ser consideradas “fracas”, enquanto em ciências sociais, acima de 0,5 já são significativas. Os valores da Tabela 2.1 são apenas referenciais, sempre considere o tamanho da amostra (n), um teste de significância (p -valor) e uma análise gráfica (gráfico de dispersão).

A covariância e correlação são como “óculos para enxergar relações lineares” – elas só detectam padrões retilíneos entre variáveis e podem ser enganadas por dados atípicos. Associações não-lineares podem existir e não serem reveladas por essas estatísticas descritivas. Mesmo com essas limitações, quando usadas no contexto certo (dados sem padrões complexos nem valores extremos), oferecem uma medida numérica valiosa para entender como variáveis se relacionam.

Observação 2.1

Dados que parecem “fora do normal” merecem atenção: primeiro cheque se não foi erro de digitação. Se forem valores reais, calcule a correlação e covariância duas vezes - uma com todos os dados e outra sem esses pontos extremos. Compare os resultados para decidir o que fazer, pois às vezes um único valor diferente pode mudar completamente suas conclusões.

As correlações (populacionais e amostrais) podem ser organizadas em matrizes simétricas cujos elementos da diagonal principal são todos iguais a 1.

Definição 2.3: Matrizes de correlações

Sejam $X_1, X_2, \dots, X_p$ as p variáveis de um estudo.

- (a) A *matriz de correlações populacionais* é a matriz *simétrica* $\mathbf{P} \in M_{p \times p}(\mathbb{R})$, cujos elementos da diagonal principal são todos iguais a 1, i.e.,

$$\mathbf{P} = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}.$$

- (b) Considere que n observações $x_{1k}, x_{2k}, \dots, x_{nk}$ foram realizadas em cada uma das variáveis X_k , $k = 1, 2, \dots, p$. A *matriz de correlações amostrais* é a matriz *simétrica* $\mathbf{R} \in M_{p \times p}(\mathbb{R})$, cujos elementos da diagonal principal são todos iguais a 1, i.e.,

$$\mathbf{R} = \begin{bmatrix} 1 & r_{12} & \cdots & r_{1p} \\ r_{21} & 1 & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & 1 \end{bmatrix}.$$

Exemplo 2.2: (Johson e Wichern, 2014, p. 10, tradução e grifo nosso)

Considere os dados introduzidos no Exemplo 2.1. Cada recibo produz um par de medições: valor total X_1 em dólares das vendas e número X_2 de livros vendidos.

- (a) Determine o vetor de médias amostrais $\bar{\mathbf{x}}$ e interprete.

Exemplo 2.2

- (b) Determine a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$ e interprete.
- (c) Determine a matriz de correlações amostrais $\mathbf{R}$ e interprete.

SOLUÇÃO:

(a) **Vetor de médias amostrais:** $\bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 4 \end{bmatrix}$.

Com base na amostra observada, **estima-se** que o valor médio das vendas seja de 50 dólares e que o número médio de livros vendidos seja igual a 4.

Código R

```
1 # Exemplo 1.1 de Johson e Wichern, 2014, p.6 e p. 10
2 dados <- data.frame(
3   vendas = c(42, 52, 48, 58), # Valores em dólares
4   livros = c(4, 5, 4, 3))     # Quantidade de livros
5
6 # Vetor de médias amostrais
7 medias <- colMeans(dados)
8 medias
```

(b) **Matriz de variâncias e covariâncias:** $\mathbf{S}_n = \begin{bmatrix} 34 & -1,5 \\ -1,5 & 0,5 \end{bmatrix}$.

- As variâncias **não são diretamente comparáveis** devido às **diferentes escalas** e **unidades** das variáveis:
 - a venda total varia de 42 a 58 dólares (amplitude = 16 dólares);
 - o número de livros variam de 3 a 5 unidades (amplitude = 2 livros).
- A covariância amostral é $s_{12} = s_{21} = -1,5 < 0$, o que sugere uma **possível** relação linear **negativa** entre as variáveis, i.e., as variáveis **tendem** a variar em **sentidos opostos**.

Código R

```
1 # Matriz de variâncias e covariâncias amostrais
2 n <- 4
3 ((n-1)/n)*cov(dados)
```

Exemplo 2.2

(c) **Matriz de correlações amostrais:** $R = \begin{bmatrix} 1 & -0.36 \\ -0.36 & 1 \end{bmatrix}$.

Com base na amostra observada, **estima-se** que a correlação linear entre o número de livros vendidos e o valor total da venda seja de $-0,36$. Esse resultado sugere uma **relação linear fraca** entre as variáveis. Dessa forma, há **indicativos** de que, na população estudada, **não há** uma **relação linear** evidente entre o número de livros de vendidos e o valor total da venda. Assim, **não podemos concluir** que vendas com menos livros **tendam** a ter valores maiores.

Código R

```
1 #Matriz de correlações amostrais
2 cor(dados)
```

No Exemplo 2.2, a correlação negativa $(-0,36)$ entre número de livros e valor das vendas pode sugerir que compras com menos livros têm valores maiores, mas é crucial entender que: (i) esta relação é fraca e pode ser não-significativa, (ii) com apenas 4 observações, o resultado pode ser apenas coincidência, e (iii) na prática, esperaríamos que mais livros levassem a vendas maiores. Uma explicação possível é que clientes que compram muitos livros podem estar escolhendo obras mais baratas (como usados), enquanto quem compra poucos livros pode estar levando itens mais caros (como livros técnicos). Porém, com tão poucos dados, essa interpretação é apenas uma hipótese – seriam necessárias mais observações para confirmar qualquer padrão.

Exemplo 2.3

Considere o conjunto de dados do Brasileirão, obtido no R por meio do pacote `worldfootballR`. Por meio desse pacote é possível extrair dados diretamente de *sites* como `FBRef`, `Transfermarkt` e `Understat`, utilizando técnicas de *web scraping* para capturar as informações públicas disponíveis nessas plataformas. O resultado dessa mineração de dados foram estatísticas de desempenho das equipes masculinas na série A do campeonato Brasileiro. A base inclui informações sobre gols, assistências, posse de bola, cartões, idade média dos jogadores e minutos jogados, entre outras métricas. Os dados abrangem todas as equipes da competição em uma temporada específica.

Exemplo 2.3

Neste exemplo, consideramos **todos** os 20 times que competiram a temporada de 2023 e apenas os jogos em que esses times jogaram em casa. Considere as seguintes variáveis:

- total de gols marcados na temporada (X_1);
- total de assistências na temporada (X_2);
- percentual médio de posse de bola durante os jogos na temporada (X_3).

- (a) Determine o vetor de médias amostrais $\bar{\mathbf{x}}$ e interprete.
- (b) Determine a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$ e interprete.
- (c) Determine a matriz de correlações amostrais $\mathbf{R}$ e interprete.

SOLUÇÃO:

Código R

```

1 # Instalar e carregar o pacote
2 install.packages("worldfootballR")
3 library(worldfootballR)
4
5 # Buscar estatísticas da temporada do Brasileirão
6 brasileiro <- fb_season_team_stats(
7   country = "BRA",
8   gender = "M",
9   season_end_year = 2023,
10  tier = "1st",
11  stat_type = "standard")
12
13 #População
14 dados <- brasileiro[1:20,]
15
16 #Acessando os nomes das colunas como nomes de variáveis
17 attach(dados)
18
19 #Selecionando as variáveis a serem analisadas
20 X <- cbind(Gls, Ast, Poss)

```

Exemplo 2.3

(a) Vetor de médias populacionais: $\mu = \begin{bmatrix} 46,15 \\ 31,60 \\ 50,00 \end{bmatrix}$.

Na temporada 2023 do Brasileirão, quando os times jogavam em casa, o número total **médio** de gols feitos por um time na temporada foi de aproximadamente 46 gols, o total **médio** de assistências foi de aproximadamente 32 assistências e, em média, o percentual médio de posse de bolas durante os jogos da temporada foi de 50%.

Código R

```
1 #Vetor de médias populacionais
2 colMeans(X)
```

(b) Matriz de variâncias e covariâncias populacionais:

$$\Sigma = \begin{bmatrix} 65,53 & 49,51 & 13,57 \\ 49,51 & 42,54 & 10,64 \\ 13,57 & 10,64 & 27,82 \end{bmatrix}.$$

Na temporada 2023 do Brasileirão, quando os times jogavam em casa,

- $\sigma_{12} = \sigma_{21} = 49,51$, **sugere** que **pode** haver uma **relação linear positiva** entre o número de gols marcados e o número de assistências;
- $\sigma_{13} = \sigma_{31} = 13,57$, **sugere** que **pode** haver uma **relação linear positiva** entre o número de gols marcados e o percentual médio de posse de bola;
- $\sigma_{23} = \sigma_{32} = 10,64$, **sugere** que **pode** haver uma **relação linear positiva** entre o número de assistências e o percentual médio de posse de bola.

Código R

```
1 #Calcular a matriz de variâncias e covariâncias
  populacionais
2 n <- 20
3 Sigma <- ((n-1)/n)*cov(X)
4 round(Sigma, 2)
```

Exemplo 2.3

(c) **Matriz de correlações populacionais:**

$$\mathbf{P} = \begin{bmatrix} 1,00 & 0,94 & 0,32 \\ 0,94 & 1,00 & 0,31 \\ 0,32 & 0,31 & 1,00 \end{bmatrix}.$$

Na temporada 2023 do Brasileirão, quando os times jogavam em casa,

- $\rho_{12} = \rho_{21} = 0,94$, **indica** que existe uma **relação linear positiva muito forte** entre o número de gols marcados e o número de assistências, o que confirma que times que dão mais assistências **tendem** a marcar mais gols.
- $\rho_{13} = \rho_{31} = 0,32$, **indica** que existe uma **relação linear positiva fraca** entre o número de gols marcados e o percentual médio de posse de bola. Sem uma relação linear evidente entre as variáveis, **não** pode-se afirmar que times com um posse maior de bola, tendam a marcar mais gols.
- $\rho_{23} = \rho_{32} = 0,31$, **indica** que existe uma **relação linear positiva fraca** entre o número de gols marcados e o percentual médio de posse de bola. Sem uma relação linear evidente entre as variáveis, **não** pode-se afirmar que times com um posse maior de bola, tendam a dar mais assistências.

Código R

```
1 #Matriz de correlações populacionais
2 R <- cor(X)
3 round(R,2)
```

2.3 Visualização de dados

Os gráficos são ferramentas poderosas, e muitas vezes negligenciados, na análise de dados. Embora não possamos visualizar todas as variáveis de uma só vez quando trabalhamos com múltiplas variáveis, gráficos simples – como os de variáveis individuais ou de pares de variáveis – podem ainda ser muito informativos. É boa prática estatística plotar esses gráficos e analisar visualmente como as variáveis se relacionam. Vejamos agora exemplos práticos de como diferentes técnicas gráficas podem nos ajudar na visualização de dados multivariados.

Exemplo 2.4: Gráfico de correlações populacionais

Considere os dados introduzidos no Exemplo 2.3, considerando as mesmas três variáveis: total X_1 de gols marcados na temporada, total X_2 de assistências na temporada e percentual médio X_3 de posse da bola na temporada. Construa o gráfico de correlações populacionais.

SOLUÇÃO:




Figura 2.1. Visualização gráfica da matriz de correlações populacionais de três variáveis pré-selecionadas da base de dados do Brasileirão 2023, considerando apenas os jogos em que os times jogam em casa.

Código R

```
1 #Gráfico de correlações populacionais
2
3 #Instalar o pacote corrplot
4 install.packages("corrplot")
5
6 #Acessar a biblioteca corrplot
7 library("corrplot")
8
9 #Construir o gráfico de correlações populacionais
10 corrplot(R, type = "lower")
```


Exemplo 2.5: Gráfico de dispersão

Considere os dados introduzidos no Exemplo 2.3. Todavia, vamos considerar apenas as seguintes variáveis: total X_1 de gols marcados na temporada e o total X_2 de assistências na temporada. Construa um gráfico de dispersão e interprete-o.

SOLUÇÃO:




Figura 2.2. Gráfico de dispersão do número total de assistências na temporada vs. o número de gols marcados na temporada 2023 do Brasileirão, considerando apenas os jogos em que os times jogam em casa.

Código R

```
1 #Gráfico de dispersão do número total de assistências na
   temporada vs. o número de gols marcados
2 plot(Ast, Gls,
3       xlab = "Número total de assistências",
4       ylab = "Número de gols marcados",
5       pch = 19,
6       cex = 0.5)
```

Exemplo 2.6: Gráfico de dispersão multivariado

Considere os dados introduzidos no Exemplo 2.3, considerando as mesmas três variáveis: total X_1 de gols marcados na temporada, total X_2 de assistências na temporada e percentual médio X_3 de posse da bola na temporada. Construa o gráfico

Exemplo 2.6: Gráfico de dispersão multivariado

de dispersão multivariado.

SOLUÇÃO:




Figura 2.3. Gráfico de dispersão multivariado para as variáveis pré-selecionadas da base de dados do Brasileirão 2023, considerando apenas os jogos em que os times jogam em casa.

Código R

```
1 #Gráfico de dispersão multivariado
2 pairs(X)
```

No exemplo anterior, observamos uma relação que faz sentido do ponto de vista causal: quanto maior o número de assistências, maior tende a ser o número de gols marcados. Essa relação é intuitiva e esperada, pois uma jogada bem construída geralmente aumenta as chances de um gol. No entanto, é importante lembrar que nem toda correlação alta entre duas variáveis indica, necessariamente, uma relação de causa e efeito. Às vezes, duas variáveis podem estar altamente correlacionadas por coincidência ou por estarem ambas associadas a uma terceira variável não observada – esses são os chamados casos de correlação espúria. Por isso, devemos ter cautela ao interpretar correlações e evitar con-

clusões precipitadas. A seguir, veremos um exemplo em que uma correlação aparente pode nos enganar.

Exemplo 2.7

Considere o conjunto de dados que analisa a relação entre o consumo per capita de margarina, a taxa de divórcios no estado do Maine e o consumo de leite nos Estados Unidos, entre os anos de 2000 e 2009, a partir de dados históricos. As seguintes variáveis, portanto, são:

- consumo per capita de margarina (libras por pessoa) (X_1);
- taxa de divórcios no Maine (por 1.000 habitantes) (X_2);
- consumo per capita de leite (litros por ano) (X_3).

- Determine o vetor de médias amostrais $\bar{\mathbf{x}}$ e interprete.
- Determine a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$ e interprete.
- Determine a matriz de correlações populacionais $\mathbf{R}$ e construa o gráfico de correlações amostrais. Interprete.
- Construa o gráfico de dispersão multivariado.

SOLUÇÃO:

Código R

```

1 #Dados
2 margarina <- c(8.2, 7.0, 6.5, 5.3, 5.2, 4.0, 4.6, 4.5,
3   4.2, 3.7) # Consumo per capita de margarina (libras
4   por pessoa)
5 divorcios <- c(5.0, 4.7, 4.6, 4.4, 4.3, 4.1, 4.2, 4.2,
6   4.2, 4.1) # Taxa de divórcios no Maine (por 1.000
7   habitantes)
8 leite <- c(200, 195, 190, 185, 180, 175, 170, 165, 160,
9   155) # Consumo per capita de leite (litros por ano)
10
11 #Construindo a matriz de dados
12 X <- cbind(margarina, divorcios, leite)

```

Exemplo 2.7

(a) **Vetor de médias amostrais:** $\bar{x} = \begin{bmatrix} 5,32 \\ 4,38 \\ 177,50 \end{bmatrix}$.

Com base na amostra observada, **estima-se** que o consumo médio de margarina seja de 5,32 libras por pessoa, a taxa média de divórcios seja de aproximadamente 4,38 por 1.000 habitantes e o consumo médio de leite seja de 177,50 litros por ano.

Código R

```
1 #Calcular o vetor de médias amostrais
2 colMeans(X)
```

(b) **Matriz de variâncias e covariâncias amostrais:**

$$S_n = \begin{bmatrix} 1,93 & 0,39 & 18,35 \\ 0,39 & 0,08 & 3,60 \\ 18,35 & 3,60 & 206,25 \end{bmatrix}.$$

Com base na amostra observada,

- $s_{12} = s_{21} = 0,39$, o que **sugere** que **pode** haver uma **relação linear positiva** entre o consumo de margarina e a taxa de divórcios;
- $s_{13} = s_{31} = 18,35$, o que **sugere** que **pode** haver uma **relação linear positiva** entre o consumo de margarina e o consumo de leite;
- $s_{23} = s_{32} = 10,64$, o que **sugere** que **pode** haver uma **relação linear positiva** entre o consumo de leite e a taxa de divórcios.

Código R

```
1 #Calcular a matriz de variâncias e covariâncias amostrais
2 n <- 10
3 Sn <- ((n-1)/n)*cov(X)
4 round(Sn, 2)
```

(c) **Matriz de correlações amostrais:**

Exemplo 2.7

$$\mathbf{R} = \begin{bmatrix} 1,00 & 0,99 & 0,92 \\ 0,99 & 1,00 & 0,89 \\ 0,92 & 0,89 & 1,00 \end{bmatrix}.$$

Com base na amostra observada,

- $r_{12} = r_{21} = 0,99$, o que **indica** que existe uma **relação linear positiva muito forte** entre o consumo de margarina e a taxa de divórcios. No entanto, embora haja uma relação linear evidente, não podemos afirmar que pessoas que consomem mais margarina tendem a se divorciar mais.
- $r_{13} = r_{31} = 0,92$, **indica** que existe uma **relação linear positiva muito forte** entre o consumo de margarina e o consumo de leite. No entanto, embora haja uma relação linear evidente, não podemos afirmar que pessoas que quanto maior o consumo de margarina maior **tende** a ser consumo de leite.
- $r_{23} = r_{32} = 0,89$, **indica** que existe uma **relação linear positiva forte** entre o consumo de leite e a taxa de divórcios. No entanto, embora haja uma relação linear evidente, não podemos afirmar que pessoas que consomem mais leite tendem a se divorciar mais.




Figura 2.4. Gráfico de correlações amostrais para o conjunto de dados com possíveis relações espúrias.

Exemplo 2.7

Código R

```

1 #Calcular a matriz de correlações amostrais
2 R <- cor(X)
3 round(R,2)
4
5 # Rótulos personalizados
6 rownames(R) <- colnames(R) <- c("Margarina", "Divórcios",
7   "Leite")
8
9 #Gráfico de correlações amostrais
10 corrrplot(R,
11   method = "color",
12   addCoef.col = "white",
13   type = "lower")

```

(d)




Figura 2.4. Gráfico de dispersão multivariado para o conjunto de dados com possíveis relações espúrias.

Exemplo 2.7

Código R

```

1 # Rótulos personalizados
2 rownames(X) <- colnames(X) <- c("Margarina", "Divórcios",
  "Leite")
3
4 #Gráfico de dispersão multivariado
5 pairs(X)

```

Imagine que estamos acompanhando o crescimento de crianças ao longo dos anos, medindo suas alturas aos 2, 4, 6, 8 e 10 anos de idade. Para cada criança, teremos uma sequência de medidas feitas em diferentes momentos do tempo. Quando colocamos essas informações em um gráfico, ligando os pontos correspondentes às alturas em cada idade, obtemos uma *curva de crescimento*. Esse tipo de gráfico é muito útil para visualizar como cada unidade evolui ao longo do tempo e para comparar diferentes trajetórias. Em termos estatísticos, estamos trabalhando com *medidas repetidas*, ou seja, várias observações da mesma unidade (por exemplo, a mesma criança) ao longo do tempo. Para construir esse gráfico, colocamos o tempo no eixo horizontal (eixo x) e a variável de interesse – como altura, peso ou rendimento – no eixo vertical (eixo y). Depois, traçamos uma linha para cada unidade. Isso nos permite observar tanto a tendência média quanto as diferenças entre os perfis individuais de crescimento.

Exemplo 2.8: Curvas de crescimento

Considere o conjunto de dados `ChickWeight` do R. Esse conjunto acompanha o crescimento de 50 pintinhos ao longo do tempo sob diferentes dietas. Construa um gráfico com as curvas de crescimento e interprete-o.

SOLUÇÃO:

Código R

```

1 #Carregar pacote dplyr.
2 library(dplyr)
3
4 #Carregar dados ChickWeight
5 data(ChickWeight)
6 head(ChickWeight)

```

Exemplo 2.8

Código R

```

1 # Obter a dieta de cada pintinho (cada Chick tem uma única
  Diet)
2 diet_info <- ChickWeight %>%
3   group_by(Chick) %>%
4   summarise(Diet = first(Diet)) %>%
5   arrange(as.numeric(Chick))
6
7 # Criar uma matriz onde cada linha representa um tempo e cada
  coluna um pintinho
8 library(reshape2)
9 chick_wide <- dcast(ChickWeight,
10                    Time ~ Chick,
11                    value.var = "weight")
12 chick_wide
13
14 # Gerar vetor de cores de acordo com a dieta
15 diet_colors <- c("red", "blue", "green", "purple")
16 curve_colors <- diet_colors[as.numeric(diet_info$Diet)]
17
18 # Criar gráfico com cores por dieta
19 matplot(chick_wide$Time, chick_wide[, -1],
20         type = "l",
21         lty = 1,
22         col = curve_colors,
23         xlab = "Tempo de vida (dias)",
24         ylab = "Peso (g)",
25         main = "")
26
27 # Adicionar legenda
28 legend("topleft",
29       legend = paste("Dieta", 1:4),
30       col = diet_colors,
31       lty = 1,
32       bty = "n")

```



Exemplo 2.8

Figura 2.5. Gráfico de curvas de crescimento para o peso de 50 pintinhos sob 4 dietas diferentes.

De modo geral, todos os pintinhos ganharam peso com o tempo, o que é esperado – as curvas seguem uma tendência de subida. Mesmo dentro de uma mesma dieta, há bastante variação entre os pintinhos – alguns cresceram bem mais do que outros. As linhas verdes (dieta 3) e azuis (dieta 2) parecem, em média, crescer mais rápido e atingir pesos mais altos, enquanto as linhas vermelhas (dieta 1) tendem a ficar mais abaixo, sugerindo que essa dieta pode ter promovido menos crescimento. As linhas roxas (dieta 4) parecem ficar entre as demais, com alguma variação.

Este gráfico não prova que uma dieta é melhor do que a outra. Ele sugere padrões, mas não controla outros fatores (ex.: genética, saúde inicial dos pintinhos). Para concluir qual dieta é “melhor”, precisaríamos de uma análise estatística mais formal, como um modelo de efeitos mistos ou uma ANOVA com medidas repetidas.

Imagine que temos um conjunto de dados com notas de vários alunos em diferentes disciplinas: Matemática, Física, Química e Biologia. Queremos visualizar, ao mesmo tempo, como cada aluno se saiu em todas essas matérias. Para isso, podemos usar um gráfico de coordenadas paralelas: nesse tipo de gráfico, colocamos uma escala vertical para cada variável (ou disciplina, no exemplo), lado a lado. Cada aluno será representado por uma linha que atravessa todas essas escalas, passando pelas notas que ele tirou em cada

matéria. Assim, conseguimos observar rapidamente padrões de desempenho e comparações entre alunos.

Esse tipo de gráfico é muito útil para conjuntos de dados com muitas variáveis quantitativas, pois permite visualizar tendências multivariadas de forma compacta. Além disso, ele se conecta com a ideia de correlação: quando duas variáveis estão positivamente correlacionadas, as linhas entre essas duas escalas tendem a manter a mesma direção (sobem ou descem juntas). Quando estão negativamente correlacionadas, as linhas geralmente se cruzam entre os dois eixos (sobem no primeiro e descem no segundo). E quando a correlação é fraca ou nula, as linhas aparecem mais embaralhadas, sem um padrão claro.

Para construir esse gráfico, basta padronizar ou escalar as variáveis (se estiverem em escalas muito diferentes), alinhar os eixos verticais lado a lado e traçar uma linha para cada unidade (indivíduo, aluno, etc.) ligando seus valores em cada eixo.

Exemplo 2.9: Gráfico de coordenadas paralelas

Considere um conjunto de dados com a nota de 46 estudantes em três provas. Construa um gráfico de coordenadas paralelas e interprete-o.

SOLUÇÃO:




Figura 2.5. Gráfico de coordenadas paralelas para as notas de 46 estudantes em três provas.

Exemplo 2.9

O gráfico mostra que, para muitos alunos, as notas caíram da Prova 1 para a Prova 2 (as linhas descem nesse intervalo) e depois subiram da Prova 2 para a Prova 3 (as linhas sobem). Algumas linhas seguem um padrão quase reto (pouca variação entre provas), indicando alunos com desempenho estável. Outras linhas têm grandes subidas e descidas, indicando flutuação no desempenho. Entre a Prova 1 e a Prova 2, mais linhas se cruzando (algumas sobem, outras descem), do que entre a Prova 2 e a Prova 3, onde observa-se uma tendência mais consistente de subida. Isso sugere que a correlação entre essas duas primeiras provas é menor do que entre as duas últimas. Menos cruzamentos indicam uma correlação mais positiva entre essas provas – os alunos que foram melhor em uma também tendem a ir melhor na outra. De fato, a matriz de correlações amostrais, neste caso, é

$$\mathbf{R} = \begin{bmatrix} 1,00 & 0,48 & 0,66 \\ 0,48 & 1,00 & 0,55 \\ 0,66 & 0,55 & 1,00 \end{bmatrix}.$$

Código R

```
1 # Criando o data frame
2 notas <- data.frame(P1, P2, P3)
3
4 # Gráfico de coordenadas paralelas
5 matplot(t(notas),
6         type = "o",
7         pch = 16,
8         col = rainbow(46),
9         xaxt = "n",
10        xlab = "Provas",
11        ylab = "Notas",
12        main = "")
13
14 axis(1, at = 1:3, labels = c("Prova 1", "Prova 2", "Prova 3"))
15
16 #Verificando correlações
17 round(cor(notas),2)
```

Imagine que você queira comparar o perfil de desempenho de diferentes atletas em

três ou mais habilidades – por exemplo, velocidade, resistência, força e agilidade. Um gráfico de estrelas (ou gráfico radar) coloca cada uma dessas variáveis em um eixo que parte de um ponto central, formando “pétalas” ao redor de um círculo. Para cada atleta, ligamos os valores nesses eixos e formamos uma figura geométrica. Esse tipo de gráfico só é interessante quando temos pelo menos três variáveis ($p \geq 3$), pois com duas ele se reduziria a uma linha comum. Ele é especialmente útil para visualizar perfis multivariados e fazer comparações rápidas entre unidades. Além disso, a área formada pela figura pode dar uma ideia do desempenho geral: em contextos onde todas as variáveis têm a mesma importância e estão na mesma escala, um atleta com área maior pode ser interpretado como tendo um desempenho mais equilibrado ou superior no conjunto das variáveis. Porém, essa comparação deve ser feita com cuidado, pois a área depende tanto dos valores quanto da geometria da figura, o que pode distorcer percepções se as variáveis não forem bem padronizadas.

Exemplo 2.10: Gráfico de estrelas

Considere os dados introduzidos no Exemplo 2.9. Construa um gráfico de coordenadas paralelas e interprete-o.

SOLUÇÃO:




Figura 2.5. Gráfico de estrelas para as notas de 46 estudantes em três provas.

Exemplo 2.10

Ao observar o conjunto, vemos que são poucos os alunos que se saíram muito bem nas três provas (estrelas grandes e equilibradas) e também poucos com desempenho ruim nas três (estrelas bem pequenas). A maioria das figuras se encontra em um tamanho intermediário, sugerindo que a maior parte dos alunos obteve notas próximas da média geral nas três avaliações.

Código R

```
1 #Desempenho dos estudantes em três provas
2 stars(notas, key.loc = c(11,2))
```

Em muitos conjuntos de dados do mundo real, é comum nos depararmos com valores faltantes, ou seja, situações em que uma ou mais informações não foram registradas. Isso pode acontecer por vários motivos: uma pessoa que esqueceu de responder uma pergunta, um equipamento que falhou na medição ou mesmo por erro de digitação. Quando isso ocorre, precisamos decidir como lidar com esses dados ausentes, pois simplesmente ignorá-los pode afetar a análise. Uma opção é remover as observações incompletas, mas isso pode reduzir bastante o número de casos disponíveis, o que prejudica os resultados, especialmente se o número de faltantes for grande. Outra alternativa é preencher (ou imputar) os valores ausentes com alguma estimativa. A forma mais simples é substituir pela média da variável, mas existem métodos mais robustos, como a imputação por regressão (em que o valor faltante é estimado com base nas outras variáveis) ou por k -vizinhos mais próximos (k -NN, do inglês, *k-Nearest Neighbors*), que usa o padrão de unidades semelhantes para prever o valor ausente. Essas técnicas geralmente preservam melhor a estrutura dos dados e reduzem o viés. Em alguns casos, pode-se até optar por remover uma variável inteira, se ela tiver muitos valores faltantes e não for considerada essencial para a análise. Essa também é uma escolha delicada: se a variável estiver correlacionada com as variáveis de interesse, mesmo que isso só seja perceptível nos casos com dados completos, sua exclusão pode levar à perda de informações relevantes e comprometer a interpretação dos resultados. Em resumo, lidar com dados faltantes exige atenção: é preciso entender por que os dados estão faltando e avaliar cuidadosamente o impacto de cada escolha, para garantir que a análise continue sendo confiável e representativa.

Em uma análise de dados, é comum encontrarmos valores atípicos, também chamados de *outliers* ou dados discrepantes. São observações que se destacam por serem muito diferentes das demais, como uma nota muito baixa em uma turma onde quase todos foram bem, ou uma altura muito acima da média em um grupo. Quando estamos lidando com apenas uma variável, identificar *outliers* costuma ser mais simples. Mas em análises multi-

variadas, a situação pode ser mais sutil: uma observação pode parecer estranha em uma variável isolada, mas quando olhamos conjuntamente com outras variáveis, ela pode fazer sentido. Por exemplo, imagine uma pessoa que corre 10 km em 35 minutos – pode parecer um tempo muito rápido e, sozinho, seria considerado um *outlier*. Mas, se soubermos que essa pessoa é um atleta profissional com baixo percentual de gordura, a combinação dos dados justifica o valor. Por isso, é importante analisar os *outliers* no contexto das demais variáveis. Quando detectamos observações atípicas, podemos escolher mantê-las, investigar se são erros de registro ou, em alguns casos, removê-las da análise. Cada atitude tem consequências: excluir *outliers* pode ajudar a evitar distorções nas análises estatísticas, mas também pode nos fazer perder informações importantes sobre casos extremos – como pacientes com reações raras a um medicamento, consumidores que gastam muito mais do que a média em uma loja, ou empresas que apresentam crescimento fora do comum. Para lidar com isso, existem também técnicas estatísticas mais robustas, que são menos sensíveis à presença de *outliers*, como, por exemplo, modelos de regressão robusta. Essas abordagens permitem manter os dados discrepantes na análise sem que eles distorçam indevidamente os resultados. Por isso, é essencial agir com cuidado, explorar bem os dados e justificar qualquer decisão tomada sobre o tratamento dos *outliers*.

Exemplo 2.11: Dados faltantes e atípicos

Considera base de dados *airquality* do R. Essa base contém medições diárias da qualidade do ar em Nova York (EUA) durante os meses de maio a setembro de 1973. Vamos considerar três variáveis:

- concentração de ozônio (X_1);
- temperatura do ar (X_2);
- velocidade do vento (X_3).

A variável X_3 , concentração de ozônio, apresenta alguns dados faltantes, o que sugere que em alguns dias o valor dessa variável não foi registrado.

- (a) Identifique a proporção de dados faltantes. Você acredita ser razoável excluir tais observações?
- (b) Determine a matriz de correlações amostrais excluindo os dados faltantes. Você acredita ser razoável excluir essa variável da análise?
- (c) Determine a matriz de correlações amostrais imputando a média das observações no lugar dos dados faltantes. Avalie o impacto da imputação.

Exemplo 2.11

- (d) Com os dados imputados, construa os *boxplots* das três variáveis e, em seguida, construa o gráfico de dispersão multivariado. Comente sobre possíveis *outliers*.

SOLUÇÃO:

Código R

```

1 # Carregar a base de dados
2 data(airquality)
3
4 # Visualizar os primeiros dados
5 attach(airquality)

```

- (a) A proporção de dados faltantes na variável X_3 , concentração de ozônio, é de, aproximadamente, 24%. Esse valor é relativamente alto, o que nos leva a ter cautela antes de simplesmente excluir essas observações. Excluir 24% dos dados pode reduzir consideravelmente o tamanho da amostra e, com isso, afetar a representatividade e a precisão das análises. Além disso, se os dados não estiverem ausentes completamente ao acaso, a exclusão pode introduzir viés nos resultados. Portanto, não parece razoável remover essas observações sem antes investigar melhor o padrão de ausência e considerar outras estratégias, como a imputação dos valores faltantes por métodos adequados.

Código R

```

1 # Verificar a proporção de dados faltantes
2 sum(is.na(Ozone)) # Contar NAs antes da imputação
3 sum(is.na(Ozone))/length(Ozone)

```

- (b) A matriz de correlações amostrais excluindo os dados faltantes é

$$\mathbf{R} = \begin{bmatrix} 1,00 & 0,70 & -0,60 \\ 0,70 & 1,00 & -0,51 \\ -0,60 & -0,51 & 1,00 \end{bmatrix}.$$

A matriz de correlações amostrais, considerando apenas os casos completos, mostra que a variável ozônio (X_1) possui correlação forte ($r_{12} = 0,70$) com temperatura (X_2) e correlação moderada ($r_{13} = -0,60$) com velocidade do vento (X_3). Esses valores indicam que a concentração de ozônio carrega informação

Exemplo 2.11

relevante para a análise. Portanto, não parece razoável excluir essa variável da análise. Em vez disso, seria mais adequado considerar estratégias de imputação, que permitam preservar as relações observadas sem descartar uma quantidade tão grande de informação.

Código R

```
1 #Matriz de correlações amostrais sem NAs
2 round(cor(X, use = "complete.obs"), 2)
```

- (c) A matriz de correlações amostrais com os dados faltantes substituídos pela média amostral dos dados completos é

$$\mathbf{R} = \begin{bmatrix} 1,00 & 0,61 & -0,53 \\ 0,61 & 1,00 & -0,46 \\ -0,53 & -0,46 & 1,00 \end{bmatrix}.$$

Ao imputar a média das observações nos valores faltantes da variável Ozônio, a matriz de correlações amostrais mudou sensivelmente. Comparando com a matriz obtida com exclusão dos dados faltantes, observamos que as correlações entre Ozônio e Temperatura (de 0,70 para 0,61) e entre Ozônio e Vento (de -0,60 para -0,53) diminuíram de intensidade. Essa redução acontece porque a imputação pela média diminuiu a variabilidade da variável Ozônio, especialmente nos pontos onde os dados estavam ausentes – todos esses valores foram substituídos pelo mesmo número. Como resultado, a associação entre Ozônio e as outras variáveis foi atenuada, o que pode levar a conclusões equivocadas sobre a força das relações. Portanto, embora a imputação pela média seja simples e mantenha o tamanho da amostra, ela pode prejudicar a análise das correlações, especialmente se a proporção de dados faltantes for alta, como é o caso aqui. Isso mostra a importância de considerar métodos de imputação mais sofisticados, que preservem melhor as relações entre variáveis, como, por exemplo, a imputação por regressão, em que os valores faltantes são estimados com base em um modelo que utiliza as outras variáveis disponíveis (como Temperatura e Vento, neste caso). Outra opção é a imputação por k -vizinhos mais próximos (k -NN), que preenche os valores com base em observações semelhantes. Essas abordagens preservam melhor as relações entre as variáveis, resultando em análises mais confiáveis.

Exemplo 2.11

Código R

```

1 # Imputar a média nos valores ausentes
2 airquality$Ozone[is.na(Ozone)] <- mean(Ozone, na.rm = TRUE
  )
3
4 #Matriz de correlação
5 round(cor(X),2)

```

(d)

Código R

```

1 #Ajustando as variáveis
2 Ozone_ajustado <- (Ozone - mean(Ozone))/sd(Ozone)
3 Temp_ajustado <- (Temp - mean(Temp))/sd(Temp)
4 Wind_ajustado <- (Wind - mean(Wind))/sd(Wind)
5
6
7 # Criar três boxplots no mesmo gráfico
8 boxplot(Ozone_ajustado, Temp_ajustado, Wind_ajustado,
9         names = c("Ozônio", "Vento", "Temperatura"),
10        col = c("lightblue", "lightgreen", "lightcoral"),
11        main = "",
12        ylab = "Valores ajustados")
13
14 # Rótulos personalizados
15 rownames(X) <- colnames(X) <- c("Ozônio", "Temperatura", "
  Vento")
16
17 # Criar gráficos de dispersão
18 pairs(X)

```

Os *boxplots* mostram que, individualmente, a variável Ozônio possui vários valores atípicos altos, enquanto Temperatura e Vento têm menos outliers aparentes. No entanto, ao analisarmos o gráfico de dispersão multivariado, percebemos que algumas observações que pareciam discrepantes em apenas uma variável passam a fazer mais sentido quando consideradas em conjunto com as outras.

Exemplo 2.11

Isso mostra como uma observação pode parecer atípica na análise univariada, mas não necessariamente ser um outlier no contexto multivariado. Por isso, é importante sempre considerar as relações entre variáveis antes de decidir remover ou tratar dados extremos.




Figura 2.9. Boxplots das três variáveis consideradas nesse estudo da qualidade do ar em Nova York durante os meses de maio a setembro de 1973.




Figura 2.10. Gráfico de dispersão multivariado considerando três variáveis consideradas nesse estudo da qualidade do ar em Nova York durante os meses de maio a setembro de 1973.

Neste capítulo, buscamos motivar o estudo da análise multivariada destacando a importância de compreender conjuntos de dados com múltiplas variáveis de forma conjunta e integrada. Apresentamos métodos iniciais para organizar, visualizar e explorar os dados – como estatísticas descritivas, gráficos de dispersão e correlações multivariado, curvas de crescimento, gráficos de estrelas e gráfico de coordenadas paralelas –, além de discutirmos desafios comuns, como dados faltantes e valores atípicos, e estratégias para lidar com eles. Esses são apenas os primeiros passos de uma jornada analítica que nos permitirá extrair, de forma mais rica e profunda, as histórias que os dados têm a contar.

2.4 Exercícios

1. (Johnson e Wichern, 2014, p. 38, tradução e grifo nosso) Um jornal lista o preço de 11 carros usados, em que X_1 representa o tempo de uso (em anos) e X_2 representa o preço do carro (em milhares de dólares). Os dados estão sumarizados na seguinte tabela:

X_1	1	2	3	3	4	5	6	8	9	11
X_2	18,95	19,00	17,95	15,54	14,00	12,95	8,94	7,49	6,00	3,99


- (a) Determine o vetor de médias amostrais $\bar{\mathbf{x}}$. Interprete os valores.
 - (b) Construa um gráfico de dispersão dos dados. O gráfico sugere que a covariância amostral s_{12} é positiva ou negativa? Por quê?
 - (c) Determine a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$.
 - (d) As variâncias amostrais s_{11} e s_{22} encontradas no item (c) são comparáveis? Por quê?
 - (e) A covariância amostral s_{12} encontrada no item (c) é consistente com sua resposta para pergunta do item (b)? Interprete esse valor.
 - (f) Determine a matriz de correlações amostrais $\mathbf{R}$. Interprete a correlação amostral r_{12} .
2. O conjunto de dados `iris` do R, introduzido por Ronald Fisher em 1936, contém medições de 150 flores de três espécies de Iris (setosa, versicolor e virginica). Para cada flor, foram registradas quatro variáveis: o comprimento e largura das sépalas e pétalas, em centímetros. Use o seguinte código no R para carregar os dados:

```

1 # Carrega o conjunto de dados iris
2 data(iris)

```

Uma imagem ilustrativa é dada a seguir.



- (a) Determine as matrizes de variâncias e covariâncias amostrais $\mathbf{S}_n$ e as matrizes de correlações amostrais $\mathbf{R}$ para cada uma das espécies em estudo: setosa, versicolor e virginica. Use duas casas decimais.
- (b) A seguinte afirmação é feita: “A covariância entre duas variáveis ser maior do que a covariância de outras duas variáveis, implica que a correlação do primeiro par de variáveis será maior do que o segundo par.” Você concorda com essa afirmação? Sustente suas respostas comparando as matrizes $\mathbf{S}_n$ e $\mathbf{R}$ obtidas no item (a). Para isso, procure, por exemplo, por pares de variáveis com mesma covariância amostral e compare as respectivas correlações amostrais.
- (c) As variâncias amostrais do tamanho da sépala (`Sepal.Length`) obtidas para cada uma das três espécies são comparáveis? Por quê? Em caso afirmativo, compare-as e apresente uma interpretação para essa comparação.
- (d) Construa um gráfico de dispersão multivariado para cada uma das três espécies.
- (e) A partir das matrizes de correlações amostrais obtidas no item (a) e dos gráficos de dispersões obtidos no item (d), responda as seguintes perguntas:
 - (i) Qual espécie possui uma relação linear mais evidente entre o tamanho da sépala e o tamanho da pétala? Por quê?
 - (ii) Avalie a seguinte afirmação: “Com base na amostra observada, temos um indicativo de que existe uma relação linear forte entre a largura da pétala e seu tamanho para as três espécies em estudo (setosa, versicolor e virginica), o que sugere que flores do tipo Iris que possuem pétalas mais largas tendem a ser maiores.” Justifique sua resposta.

3. A base de dados `pressure` do R, apresenta valores experimentais da pressão de vapor da água (em milímetros de mercúrio, mm Hg) medida em diferentes temperaturas (em graus Celsius, °C). Ela contém 19 observações obtidas em um experimento físico que buscava descrever o comportamento da pressão de vapor da água à medida que a temperatura aumenta. Use o seguinte código no R para carregar os dados:

```
1 # Carrega o conjunto de dados pressure
2 data(pressure)
```

- Construa o gráfico de dispersão dos dados e determine a correlação amostral entre a pressão e a temperatura.
 - Com base no item (a), você afirmaria que há uma relação curvilínea (não linear) muito forte entre as variáveis? Sustente sua resposta com base na velocidade com que a nuvem de dispersão cresce ou decresce comparativamente ao esperado de uma relação linear. O valor da correlação amostral corrobora sua resposta? Por quê?
 - Considere a transformação logarítmica natural em ambas as variáveis, isto é, aplique `log(temperature)` e `log(pressure)`. Retire a primeira observação, cujo valor da temperatura é 0 (Por quê?) e construa o gráfico de dispersão dos dados transformados e calcule a correlação amostral entre essas variáveis transformadas. Comente se a transformação foi eficaz para revelar a magnitude esperada da relação entre as variáveis.
4. Sejam $\mathbf{x} \in \mathbb{R}^n$ um vetor com n observações de uma variável X e $\mathbf{y} \in \mathbb{R}^n$ um vetor com n observações de uma variável Y . Considere os vetores $\mathbf{d}_X \in \mathbb{R}^n$ e $\mathbf{d}_Y \in \mathbb{R}^n$ tais que

$$\mathbf{d}_X := \begin{bmatrix} x_1 - \bar{x} \\ x_2 - \bar{x} \\ \vdots \\ x_n - \bar{x} \end{bmatrix} \quad \text{e} \quad \mathbf{d}_Y := \begin{bmatrix} y_1 - \bar{y} \\ y_2 - \bar{y} \\ \vdots \\ y_n - \bar{y} \end{bmatrix}.$$

O vetor $\mathbf{d}_X$ é conhecido como *vetor dos desvios* da variável X e o vetor $\mathbf{d}_Y$ é conhecido como *vetor dos desvios* da variável Y .

- Verifique que as variâncias amostrais são proporcionais ao quadrado das normas Euclidianas dos vetores de desvios, i.e.,

$$s_{XX} = \frac{1}{n} \|\mathbf{d}_X\|^2 \quad \text{e} \quad s_{YY} = \frac{1}{n} \|\mathbf{d}_Y\|^2.$$

- (b) Verifique que a covariância amostral é proporcional à norma Euclidiana do produto interno dos vetores de desvios, i.e.,

$$s_{XY} = \frac{1}{n} \mathbf{d}_X^\top \mathbf{d}_Y.$$

- (c) Verifique a correlação amostral é igual ao cosseno do ângulo θ formado entre os vetores de desvios, i.e.,

$$r_{XY} = \cos(\theta).$$

Lembre que

$$\cos(\theta) := \frac{\mathbf{d}_X^\top \mathbf{d}_Y}{\|\mathbf{d}_X\| \|\mathbf{d}_Y\|}.$$

Conclua que $-1 \leq r_{XY} \leq 1$.

- (d) Mostre que $r_{XY} = \pm 1$ se, e somente se, $Y = aX + b$, quaisquer que sejam $a \in \mathbb{R}^*$ e $b \in \mathbb{R}$.

- (e) Sejam $\mathbf{x}^* \in \mathbb{R}^n$ e $\mathbf{y}^* \in \mathbb{R}^n$ os vetores de observações ajustados, i.e.,

$$\mathbf{x}^* := \frac{1}{\sqrt{s_{XX}}} \mathbf{d}_X \quad \text{e} \quad \mathbf{y}^* := \frac{1}{\sqrt{s_{YY}}} \mathbf{d}_Y.$$

Mostre que a correlação amostral dos vetores ajustados é igual à sua covariância amostral, i.e., $r_{X^*Y^*} = s_{X^*Y^*}$.

5. A base de dados `decathlon`, disponível no pacote `FactoMineR` do R, reúne informações de desempenho de atletas de elite que competiram em eventos de decatlo. Cada linha representa um atleta, e as colunas contêm pontuações ou tempos obtidos nas diferentes modalidades do decatlo. Para esta análise, foram selecionadas apenas três provas de corrida: 400 metros rasos (`400m`), 110 metros com barreiras (`110m.hrdle`) e 1500 metros rasos (`1500m`) – todas expressas em tempo (segundos). Essas variáveis permitem estudar o perfil de velocidade e resistência dos atletas a partir de medidas quantitativas diretamente ligadas ao desempenho físico. Use o seguinte código no R para carregar os dados:

```
1 #Instala o pacote FactoMine no R
2 install.packages("FactoMineR")
3
4 # Carrega a biblioteca FactoMine no R
5 library(FactoMineR)
6 # Carrega o conjunto de dados decathlon
7 data(decathlon)
```

- (a) Construa o gráfico de estrelas e diga três atletas que tiveram um desempenho pior em relação aos demais. Qual a diferença entre eles? Sustente sua resposta levando em consideração as variáveis selecionadas para o estudo.
- (b) Com base no gráfico de estrelas do item (a), é possível afirmar que existiu algum atleta que teve um desempenho superior a todos outros? Sustente sua resposta levando em consideração as variáveis selecionadas para o estudo.
6. A base de dados **BodyWeight**, disponível no pacote **nlme** do R, contém informações sobre o peso de ratos medido ao longo do tempo em um experimento com três grupos:
- **chow**: dieta padrão (controle),
 - **reduced**: dieta com restrição alimentar,
 - **other**: outra dieta alternativa.

Foram observados 16 ratos ao longo de 64 dias, totalizando 176 observações. Cada rato foi identificado por um código e teve seu peso (em gramas) registrado em diferentes tempos (em dias). O objetivo do estudo é analisar o efeito da dieta sobre o peso dos ratos ao longo do tempo. Construa um gráfico de curvas de crescimento e interprete o efeito das dietas sobre os pesos dos ratos. Use o seguinte código no R para carregar os dados:

```
1 #Instala o pacote nlme no R
2 install.packages("nlme")
3
4 # Carrega a biblioteca FactoMine no R
5 library(nlme)
6
7 # Carrega o conjunto de dados BodyWeight
8 data("BodyWeight")
```

7. A base de dados **schooldata**, disponível no pacote **heplots** do R, contém informações acadêmicas e psicossociais de estudantes do ensino médio. Ela foi coletada com o objetivo de analisar o desempenho dos alunos em diferentes áreas do conhecimento, além de investigar aspectos emocionais e sociais relacionados ao contexto escolar. Para esta análise, foram selecionadas três variáveis: **reading** (leitura), **mathematics** (matemática) e **selfesteem** (autoestima). Use o seguinte código R para carregar os dados:

```

1 library(heplots)
2 data(package = "heplots")
3 data("schooldata")

```

- (a) Construa o gráfico de coordenadas paralelas. Interprete-o.
- (b) Construa o gráfico de correlações amostrais. Interprete as correlações amostrais.
- (c) Os achados nos itens (a) e (b) são consistentes.
8. A tabela abaixo mostra a quantidade de minutos semanais dedicados a diferentes tipos de atividade física (caminhada, bicicleta e academia) por um grupo de 10 pessoas. Algumas informações estão ausentes (valores NA), pois nem todos os participantes lembraram exatamente o tempo dedicado a todas as atividades.

Pessoa	Caminhada	Bicicleta	Academia
A	120	45	60
B	90	35	50
C	100	30	45
D	110	NA	55
E	80	25	40
F	105	38	NA
G	95	33	48
H	NA	40	58
I	85	28	42
J	115	50	150

- (a) Determine a matriz de correlações amostrais $\mathbf{R}$ e, em seguida, construa o gráfico de dispersão multivariado, sem considerar os dados faltantes.
- (b) Determine a matriz de correlações amostrais $\mathbf{R}$ e, em seguida, construa o gráfico de dispersão multivariado, considerando imputação de dados, i.e., impute os valores ausentes com a média da respectiva variável.
- (c) Compare os resultados obtidos nos itens (a) e (b) e comente o impacto da imputação de dados nos resultados.
- (d) Cite alternativas mais robustas de imputação de dados.

- (e) A partir do item (a), onde não consideramos os dados faltantes, você diria que há algum ponto discrepante nos dados? Use os *boxplots* das três variáveis como apoio visual. Em caso afirmativo, identifique a(s) observação(ões) discrepante(s) e refaça o item (a) desconsiderando-as. Comente o impacto dessa exclusão nos resultados.
- (f) Cite alternativas mais robustas para tratar dados discrepantes.

3 Vetores aleatórios

Este capítulo marca o início de uma abordagem mais formal da Estatística Multivariada. Introduziremos o conceito de vetores aleatórios, um elemento central na análise estatística multivariada, e estudaremos as propriedades matemáticas do vetor de médias populacionais e da matriz de variâncias e covariâncias populacionais. Esses conceitos são fundamentais para o desenvolvimento das técnicas inferenciais que exploraremos nos capítulos seguintes. Em seguida, abordaremos o caso de amostras multivariadas, discutindo os principais estimadores não-viesados tanto para o vetor de médias quanto para a matriz de variâncias e covariâncias. Tais estimadores desempenham um papel essencial em grande parte das aplicações da Estatística Multivariada.

3.1 Distribuições multivariadas

Definição 3.1: Vetor aleatório

Seja p um número inteiro positivo. Um *vetor aleatório* $\mathbf{X}$ em $\mathbb{R}^p$ é um vetor

$$\mathbf{X} := \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix},$$

em que cada entrada X_j é uma variável aleatória real definida sobre o mesmo espaço amostral, $j = 1, 2, \dots, p$. Assim, uma *observação* do vetor aleatório $\mathbf{X}$ é um vetor $\mathbf{x} \in \mathbb{R}^p$.

Antes de avançarmos para definições mais gerais, vamos começar lembrando os vetores aleatórios bidimensionais, com os quais vocês já tiveram contato em cursos anteriores de Probabilidade. Esses vetores nada mais são do que pares de variáveis aleatórias que podem ser observadas simultaneamente em um experimento aleatório.

Exemplo 3.1: Vetor aleatório bidimensional discreto

Considere um experimento aleatório que consiste em selecionar, ao acaso, duas bolas de uma urna, uma de cada vez, *sem reposição*. A urna contém 2 bolas vermelhas

Exemplo 3.1

e 3 bolas brancas. Defina a variável aleatória

$$X_k = \begin{cases} 1, & \text{se a } k\text{-ésima bola selecionada for branca,} \\ 0, & \text{se a } k\text{-ésima bola selecionada for vermelha,} \end{cases}$$

em que $k = 1, 2$. Defina o vetor aleatório $\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ que representa as cores das bolas selecionadas.

- (a) Determine a *função de distribuição de probabilidades conjunta* do vetor aleatório $\mathbf{X}$.
- (b) Determine as respectivas *distribuições marginais* das variáveis aleatórias X_1 e X_2 .
- (c) Construa o gráfico da função de distribuição de probabilidades conjunta do vetor aleatório $\mathbf{X}$.
- (d) As variáveis X_1 e X_2 são *independentes*? Por quê?

SOLUÇÃO:

- (a) As possíveis observações do vetor aleatório $\mathbf{X}$, ou para ser mais formal, o conjunto imagem de $\mathbf{X}$ é

$$\text{Im}(\mathbf{X}) = \left\{ \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}.$$

Logo, para todo vetor $\mathbf{x} \in \text{Im}(\mathbf{X})$, podemos escrever a **função de distribuição de probabilidade** $p : \mathbb{R}^2 \rightarrow [0, 1]$ do vetor aleatório $\mathbf{X}$ é definido como

$$p(x_1, x_2) := \mathbb{P}(X_1 = x_1, X_2 = x_2),$$

para todo $\mathbf{x} \in \mathbb{R}^2$. Quando $\mathbf{x} \in \text{Im}(\mathbf{X})$, a distribuição conjunta pode ser descrita em forma de tabela da seguinte maneira:

Exemplo 3.1

$x_1 \backslash x_2$	0	1	$\mathbb{P}(X_1 = x_1)$
0	2/20	6/20	8/20
1	6/20	6/20	12/20
$\mathbb{P}(X_2 = x_2)$	8/20	12/20	1

Agora, para todo vetor $\mathbf{x} \notin \text{Im}(\mathbf{X})$, temos $p(x_1, x_2) = 0$.

- (b) As **distribuições marginais** das variáveis aleatórias X_1 e X_2 são dadas pelas funções $p_1 : \mathbb{R} \rightarrow [0, 1]$ e $p_2 : \mathbb{R} \rightarrow [0, 1]$ tais que

$$p_1(x_1) := \mathbb{P}(X_1 = x_1) \quad \text{e} \quad p_2(x_2) := \mathbb{P}(X_2 = x_2),$$

para todo $x_1 \in \mathbb{R}$ e $x_2 \in \mathbb{R}$. Assim, as distribuições marginais de X_1 e X_2 encontram-se, respectivamente, na margem direita e inferior da tabela anterior. Vale destacar que $\mathbb{P}(X_1 = x_1) = 0$ e $\mathbb{P}(X_2 = x_2) = 0$ quando $x_1, x_2 \notin \{0, 1\}$.

- (c)




Figura 3.1. Gráfico da distribuição de probabilidades conjunta do vetor bidimensional $\mathbf{X}$ que modela as retiradas de bolas vermelhas e brancas de uma urna.

Exemplo 3.1

- (d) Neste exemplo, com retirada sem reposição, as variáveis aleatórias X_1 e X_2 não são independentes. Isso acontece porque o resultado da primeira retirada afeta diretamente a composição da urna na segunda retirada. Por exemplo, se a primeira bola for branca, haverá uma bola branca a menos disponível, o que diminui a chance de sair branca na segunda rodada. Da mesma forma, se a primeira for vermelha, a chance de sair vermelha na próxima também muda. Assim, a probabilidade de um resultado na segunda retirada depende do que ocorreu na primeira, caracterizando uma situação de dependência entre as variáveis. De fato,

$$\mathbb{P}(X_1 = 0, X_2 = 0) = \frac{2}{20} \neq \frac{8}{20} \times \frac{8}{20} = \mathbb{P}(X_1 = 0)\mathbb{P}(X_2 = 0),$$

o que confirma a dependência entre X_1 e X_2 .

Exemplo 3.2: Vetor aleatório bidimensional contínuo

Suponha que temos uma mesa de desenho quadrada, com lado de 2 metros. Um experimento consiste em lançar um pequeno marcador aleatoriamente sobre a mesa. Uma amostra suficientemente grande de lançamentos revelou que qualquer ponto da superfície parece possuir a mesma chance de receber o marcador. Assumindo isso como verdade.

- (a) Qual *função de densidade conjunta* parecer ser razoável assumir para o vetor aleatório $\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ que representa a posição do ponto na mesa, em que X_1 é a posição horizontal do ponto e X_2 a posição vertical?
- (b) Quais são as *distribuições marginais* das variáveis aleatórias X_1 e X_2 ?
- (c) Construa o gráfico da função de densidade conjunta do vetor aleatório $\mathbf{X}$.
- (d) As variáveis X_1 e X_2 são *independentes*? Por quê?

SOLUÇÃO:

- (a) É razoável supor que o vetor aleatório $\mathbf{X}$ possui distribuição uniforme no quadrado $[0, 2] \times [0, 2]$. Logo, a **densidade conjunta** do vetor aleatório $\mathbf{X}$ é a

Exemplo 3.2

função $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

$$f(x_1, x_2) := \begin{cases} \frac{1}{4}, & \text{se } 0 \leq x_1 \leq 2 \text{ e } 0 \leq x_2 \leq 2, \\ 0, & \text{caso contrário.} \end{cases}$$

Note que

$$\int_0^2 \int_0^2 f(x_1, x_2) dx_1 dx_2 = \frac{1}{4} \times 2 \times 2 = 1.$$

(b) A **densidade marginal** de X_1 é a função $f_1 : \mathbb{R} \rightarrow [0, +\infty[$ tal que

$$f_1(x_1) := \int_0^2 f(x_1, x_2) dx_2 = \frac{1}{4} \times 2 = \frac{1}{2},$$

se $0 \leq x_1 \leq 2$ e $f_1(x_1) = 0$, caso contrário. Portanto, $X_1 \sim \text{Uniforme}(0, 2)$.

Analogamente, a **densidade marginal** de X_2 é a função $f_2 : \mathbb{R} \rightarrow [0, +\infty[$ tal que

$$f_2(x_2) := \int_0^2 f(x_1, x_2) dx_1 = \frac{1}{4} \times 2 = \frac{1}{2},$$

se $0 \leq x_2 \leq 2$ e $f_2(x_2) = 0$, caso contrário. Portanto, $X_2 \sim \text{Uniforme}(0, 2)$.

(c)




Figura 3.2. Gráfico da densidade conjunta do vetor bidimensional $\mathbf{X}$ que modela a posição de um marcador em uma mesa.

Exemplo 3.2

(d) Como

$$f(x_1, x_2) = f_1(x_1)f_2(x_2),$$

para todo $\mathbf{x} \in \mathbb{R}^2$, concluímos que X_1 e X_2 são variáveis aleatórias independentes.

Após explorarmos dois exemplos envolvendo vetores aleatórios bivariados, estamos prontos para generalizar a ideia para vetores aleatórios com um número arbitrário de componentes. A seguir, apresentamos a definição formal da distribuição conjunta de um vetor aleatório em $\mathbb{R}^p$.

Definição 3.2: Distribuição de um vetor aleatório

Sejam p um número inteiro positivo e $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$.

- (a) Quando o conjunto imagem do vetor $\mathbf{X}$ é enumerável, i.e., as variáveis aleatórias que o compõem são variáveis aleatórias discretas, definimos a *função de distribuição de probabilidade conjunta* do vetor aleatório $\mathbf{X}$ como sendo a função $p : \mathbb{R}^p \rightarrow [0, 1]$ tal que

$$p(\mathbf{x}) = p(x_1, \dots, x_p) := \mathbb{P}(X_1 = x_1, \dots, X_p = x_p) = \mathbb{P}(\mathbf{X} = \mathbf{x})$$

e

$$\sum_{\mathbf{x} \in \text{Im}(\mathbf{X})} p(\mathbf{x}) = 1.$$

- (b) Quando as variáveis aleatórias que o compõem o vetor aleatório $\mathbf{X}$ são contínuas, definimos a *função densidade de probabilidade conjunta* do vetor aleatório $\mathbf{X}$ como sendo a função $f : \mathbb{R}^p \rightarrow [0, \infty)$ tal que

$$f(\mathbf{x}) = f(x_1, \dots, x_p) \geq 0$$

e

$$\int_{\mathbb{R}^p} f(\mathbf{x}) d\mathbf{x} = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, x_2, \dots, x_p) dx_1 dx_2 \cdots dx_p = 1.$$

De modo análogo ao caso bivariado, as *distribuições marginais* das componentes de um vetor aleatório multivariado são obtidas integrando (ou somando, no caso discreto) a função de distribuição conjunta em relação às demais variáveis. Com efeito,

- para cada $k = 1, 2, \dots, p$, segue que a distribuição marginal da variável aleatória X_k , no caso discreto, é a função $p_k : \mathbb{R} \rightarrow [0, 1]$ tal que

$$p_k(x_k) = \sum_{x_1} \cdots \sum_{x_{k-1}} \sum_{x_{k+1}} \cdots \sum_{x_p} p(x_1, \dots, x_p);$$

- para cada $k = 1, 2, \dots, p$, segue que a distribuição marginal da variável aleatória X_k , no caso contínuo, é a função $f_k : \mathbb{R} \rightarrow [0, +\infty[$ tal que

$$f_k(x_k) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, \dots, x_p) dx_1 \dots dx_{k-1} dx_{k+1} \dots dx_p.$$

De maneira semelhante, ao considerarmos apenas um subconjunto das componentes de um vetor aleatório multivariado, obtemos uma nova distribuição conjunta, chamada de *distribuição marginal* desse subconjunto, ao integrar (ou somar, no caso discreto) a função de distribuição conjunta original em relação às demais variáveis que não fazem parte do subconjunto. Por exemplo, digamos que você esteja interessado na distribuição marginal das primeiras k variáveis de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$. Nesse caso,

- qualquer que seja $1 \leq k < p$, segue que a distribuição marginal das variáveis aleatórias $X_1, X_2, \dots, X_k$, no caso discreto, é a função $p : \mathbb{R}^k \rightarrow [0, 1]$ tal que

$$p(x_1, x_2, \dots, x_k) = \sum_{x_{k+1}} \sum_{x_{k+2}} \cdots \sum_{x_p} p(x_1, \dots, x_p);$$

- qualquer que seja $1 \leq k < p$, segue que a distribuição marginal das variáveis aleatórias $X_1, X_2, \dots, X_k$, no caso contínuo, é a função $f : \mathbb{R}^k \rightarrow [0, +\infty[$ tal que

$$f(x_1, x_2, \dots, x_k) = \int_{-\infty}^{+\infty} \cdots \int_{-\infty}^{+\infty} f(x_1, \dots, x_p) dx_{k+1} dx_{k+2} \dots dx_p.$$

Da mesma forma, o conceito de independência entre variáveis aleatórias se generaliza naturalmente para o caso multivariado. Dizemos que as componentes do vetor aleatório são *independentes* se a função de distribuição conjunta puder ser escrita como o produto das funções de distribuição marginais. Em outras palavras,

- $X_1, X_2, \dots, X_p$ são *mutuamente independentes*, no caso discreto, quando

$$p(x_1, x_2, \dots, x_p) = p_1(x_1)p_2(x_2) \cdots p_p(x_p).$$

- $X_1, X_2, \dots, X_p$ são *mutuamente independentes*, no caso contínuo, quando

$$f(x_1, x_2, \dots, x_p) = f_1(x_1)f_2(x_2) \cdots f_p(x_p).$$

Exemplo 3.3

Considere $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$, em que X_1, X_2 e X_3 são variáveis aleatórias mutuamente independentes com $X_k \sim \text{Normal}(0, 1)$ para todo $k = 1, 2, 3$.

- (a) Determine a função densidade de probabilidade conjunta do vetor aleatório $\mathbf{X}$.
- (b) Determine a função densidade de probabilidade conjunta das componentes X_1 e X_3 do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

- (a) Como X_1, X_2 e X_3 são mutuamente independentes e possuem distribuição normal padrão, então a função densidade de $\mathbf{X}$ é $f : \mathbb{R}^3 \rightarrow [0, +\infty[$ tal que

$$\begin{aligned}
 f(\mathbf{x}) &= f(x_1, x_2, x_3) \\
 &= f_1(x_1)f_2(x_2)f_3(x_3) \\
 &= \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_1^2}{2}\right) \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_2^2}{2}\right) \times \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x_3^2}{2}\right) \\
 &= \left(\frac{1}{\sqrt{2\pi}}\right)^3 \exp\left(-\frac{1}{2} \sum_{i=1}^3 x_i^2\right) \\
 &= (2\pi)^{-3/2} \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right).
 \end{aligned}$$

$$\therefore f(\mathbf{x}) = (2\pi)^{-3/2} \exp\left(-\frac{\mathbf{x}^\top \mathbf{x}}{2}\right).$$

- (b) Pela definição, a marginal do vetor $[X_1, X_3]^\top$ é $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ é tal que

$$\begin{aligned}
 f(x_1, x_3) &= \int_{-\infty}^{+\infty} f(x_1, x_2, x_3) dx_2 \\
 &= \int_{-\infty}^{+\infty} f_1(x_1)f_2(x_2)f_3(x_3) dx_2 \\
 &= f_1(x_1)f_3(x_3) \underbrace{\int_{-\infty}^{+\infty} f_2(x_2) dx_2}_{=1} \\
 &= \left(\frac{1}{\sqrt{2\pi}}\right)^2 \exp\left(-\frac{x_1^2 + x_3^2}{2}\right).
 \end{aligned}$$

$$\therefore f(x_1, x_3) = \left(\frac{1}{\sqrt{2\pi}}\right)^2 \exp\left(-\frac{x_1^2 + x_3^2}{2}\right).$$

Vale notar que embora existam situações em que um vetor aleatório seja composto por uma mistura de variáveis discretas e contínuas, não trataremos desse caso neste momento. Isso porque, ao longo desse texto, trabalharemos principalmente com vetores aleatórios contínuos, em especial com a distribuição normal multivariada (veja Capítulo 4). Essa distribuição desempenha um papel central na Estatística Multivariada, uma vez que, sob certas condições, o vetor aleatório de médias amostrais converge em distribuição para uma normal multivariada, cuja validade, como veremos nos próximos capítulos, é garantida pelo Teorema Central do Limite em sua versão multivariada.

3.2 Valor esperado de um vetor aleatório

Nesta seção, estudaremos o valor esperado de um vetor aleatório, uma generalização natural do conceito de esperança matemática univariada. Assim como no caso de uma única variável aleatória, o valor esperado de um vetor aleatório representa uma medida de tendência central, só que agora no contexto multivariado. Vamos ver que o valor esperado de um vetor aleatório é simplesmente o vetor formado pelas esperanças de cada uma de suas componentes. Esse conceito será fundamental para o desenvolvimento de resultados teóricos e práticos ao longo desse texto.

Definição 3.3: Valor esperado de um vetor aleatório

Seja p um número inteiro positivo. O *valor esperado* do vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, denotado por $\mathbb{E}(\mathbf{X})$, é o vetor $\boldsymbol{\mu} \in \mathbb{R}^p$ tal que

$$\mathbb{E}(\mathbf{X}) := \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \vdots \\ \mathbb{E}(X_p) \end{bmatrix} = \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} := \boldsymbol{\mu}.$$

Como vimos no Capítulo 2, $\boldsymbol{\mu}$ é o *vetor de médias populacionais*.

Exemplo 3.4: Vetor aleatório bidimensional discreto

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.1.

- (a) Determine o valor esperado do vetor aleatório $\mathbf{X}$ e interprete o resultado no contexto do problema.

Exemplo 3.4

- (b) Reproduza o gráfico da função de distribuição de probabilidades conjunta do vetor aleatório $\mathbf{X}$, representando os pontos no plano $\mathbb{R}^2$ com tamanhos proporcionais às suas probabilidades. Destaque no gráfico o ponto correspondente ao valor esperado $\mathbb{E}(\mathbf{X})$ e comente sua posição em relação à distribuição dos dados.

SOLUÇÃO:

- (a) Para $x_1 \in \{0, 1\}$, a distribuição marginal da variável aleatória X_1 é

x_1	0	1	Σ
$p_1(x_1)$	8/20	12/20	1

Agora, para $x_1 \notin \{0, 1\}$, $p_1(x_1) = 0$. Logo, o valor esperado de X_1 é

$$\mathbb{E}(X_1) = \sum_{x_1=0}^1 x_1 p_1(x_1) = \left(0 \times \frac{8}{20}\right) + \left(1 \times \frac{12}{20}\right) = \frac{12}{20}.$$

Note que $X_1 \sim \text{Bernoulli}(12/20)$. Como a distribuição marginal de X_2 é igual a distribuição marginal de X_1 , i.e., $X_2 \sim \text{Bernoulli}(12/20)$, segue que

$$\mathbb{E}(X_2) = \mathbb{E}(X_1) = \frac{12}{20}.$$

Portanto, o valor esperado do vetor aleatório $\mathbf{X}$ é

$$\mathbb{E}(\mathbf{X}) = \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \end{bmatrix} = \begin{bmatrix} 12/20 \\ 12/20 \end{bmatrix}.$$

Como o vetor de médias populacionais $\boldsymbol{\mu}$ é, por definição, o próprio $\mathbb{E}(\mathbf{X})$, podemos afirmar que, em média, esperamos obter uma bola vermelha tanto na primeira quanto na segunda retirada em 12 de cada 20 experimentos, sob o mesmo esquema de sorteio.

- (b) O ponto vermelho na Figura 3.3 é o valor esperado do vetor aleatório $\mathbf{X}$, que, como vimos, é o ponto $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu} = \begin{bmatrix} 0,6 \\ 0,6 \end{bmatrix}$. Esse ponto corresponde ao centro de massa da distribuição: é o ponto de equilíbrio do sistema se pensarmos que cada ponto tem um peso proporcional à sua probabilidade. Observe que esse ponto não coincide com nenhuma das observações possíveis do vetor aleatório $\mathbf{X}$, o que é esperado, já que o valor esperado não precisa ser um ponto observado,

Exemplo 3.4

mas sim um resumo do comportamento médio da distribuição. Neste caso, o ponto médio está deslocado na direção dos pontos com maior probabilidade, ou seja, para a região em que as bolhas são maiores, o que mostra como o valor esperado é sensível à concentração de massa de probabilidade.




Figura 3.3. Gráfico da função de distribuição de probabilidades conjunta do vetor aleatório $\mathbf{X}$, representando os pontos no plano $\mathbb{R}^2$ com tamanhos proporcionais às suas probabilidades, com destaque de $\mathbb{E}(\mathbf{X})$.

Código R

```
1 # Pacotes necessários
2 library(ggplot2)
3
4 # Dados da distribuição conjunta
5 df <- data.frame(
6   x1 = c(0, 0, 1, 1),
7   x2 = c(0, 1, 0, 1),
8   prob = c(2/20, 6/20, 6/20, 6/20))
```

Exemplo 3.4

```

1 # Gráfico
2 ggplot(df, aes(x = x1, y = x2))+
3     geom_point(aes(size = prob),
4               color = "steelblue",
5               alpha = 0.6)+ #vetor de dados com
6                               probabilidade
7     geom_point(data = media, aes(x = x1, y = x2),
8               color = "red",
9               size = 4,
10              shape = 4,
11              stroke = 1.5)+ # vetor de médias
12     labs(x = expression(X[1]), y = expression(X[2]),
13          title = "")+
14     scale_size_continuous(range = c(4, 10),
15                           name = "Probabilidade",
16                           limits = c(0.1, 0.4))+
17     theme_minimal()

```

Exemplo 3.5: Vetor aleatório bidimensional contínuo

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.2.

- Determine o valor esperado do vetor aleatório $\mathbf{X}$ e interprete o resultado no contexto do problema.
- Simule observações do vetor aleatório $\mathbf{X}$. Lembre-se que X_1 e X_2 são variáveis aleatórias independentes e uniformemente distribuídas no intervalo $[0, 2]$. Represente os pontos obtidos em um gráfico no plano $\mathbb{R}^2$. No mesmo gráfico, destaque o ponto correspondente ao valor esperado $\mathbb{E}(\mathbf{X})$. Comente a posição desse ponto em relação à distribuição dos dados simulados.

SOLUÇÃO:

- Tanto a distribuição marginal da variável aleatória X_1 quanto a distribuição marginal da variável aleatória X_2 trata-se de uma distribuição uniforme no intervalo $[0, 2]$, i.e., $X_1 \sim \text{Uniforme}(0, 2)$ e $X_2 \sim \text{Uniforme}(0, 2)$. Lembrando que, quaisquer que sejam $a, b \in \mathbb{R}$ com $a < b$, quando $X \sim \text{Uniforme}(a, b)$, o

Exemplo 3.5

valor esperado da variável aleatória X é o ponto médio do intervalo $[a, b]$, i.e.,

$$\mathbb{E}(X) = \frac{a + b}{2},$$

concluimos que

$$\mathbb{E}(X_1) = \mathbb{E}(X_2) = 1.$$

Portanto, o valor esperado do vetor aleatório $\mathbf{X}$ é

$$\mathbb{E}(\mathbf{X}) = \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Como o vetor de médias populacionais $\boldsymbol{\mu}$ é, por definição, o próprio $\mathbb{E}(\mathbf{X})$, podemos afirmar que, ao realizarmos sucessivos experimentos de lançamento do marcador com distribuição uniforme sobre esse quadrado, a média das posições observadas tenderá a se concentrar em torno do ponto $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$.

- (b) A Figura 3.4 mostra uma nuvem de pontos representando observações do vetor aleatório $\mathbf{X}$, cuja distribuição conjunta é uniforme no quadrado $[0, 2] \times [0, 2]$. O ponto vermelho destacado no centro do gráfico representa o valor esperado do vetor $\mathbf{X}$, i.e., $\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$. Assim, a nuvem de pontos representa observações simuladas do vetor aleatório $\mathbf{X}$, e o valor esperado aparece como o *centro de massa* dessa nuvem, ou seja, o ponto de equilíbrio do conjunto. Se imaginássemos o plano como uma mesa e cada bolinha tivesse o mesmo peso, o valor esperado corresponderia ao local onde um apoio poderia ser colocado para equilibrar a mesa. Assim, mesmo que o marcador raramente caia exatamente nesse ponto, ele resume de forma eficaz o comportamento médio do vetor aleatório $\mathbf{X}$.

Código R

```
1 #Simulação
2 set.seed(123)
3 n <- 100000
4 X1 <- runif(n, 0, 2)
5 X2 <- runif(n, 0, 2)
```

Exemplo 3.5

```

1 # Gráfico
2 plot(X1, X2, pch = 21, bg = "skyblue", col = "gray30",
3       xlim = c(0,2), ylim = c(0,2), asp = 1,
4       xlab = expression(X[1]), ylab = expression(X[2]),
5       main = "")
6
7 # Valor esperado
8 points(1, 1, pch = 4, col = "red", lwd = 3, cex = 2)

```




Figura 3.4. Gráfico dos pontos simulados de um vetor aleatório $\mathbf{X}$ com distribuição uniforme no quadrado $[0, 2] \times [0, 2]$, com destaque de $\mathbb{E}(\mathbf{X})$.

Exemplo 3.6

Determine o valor esperado do vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.3.

SOLUÇÃO:

Para todo $k = 1, 2, 3$, temos $X_k \sim \text{Normal}(0, 1)$. Logo, $\mathbb{E}(X_k) = 0$ e, consequentemente,

Exemplo 3.6

$$\mathbb{E}(\mathbf{X}) = \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \mathbb{E}(X_3) \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0}_3.$$

Antes de analisarmos as propriedades do valor esperado de um vetor aleatório, é importante lembrar que muitas das regras que conhecemos do valor esperado escalar (isto é, para variáveis aleatórias unidimensionais) também se estendem de forma natural para o caso vetorial. Essas propriedades são fundamentais para a manipulação de expressões envolvendo vetores aleatórios e aparecem com frequência em aplicações práticas. A seguir, apresentamos um conjunto de propriedades que mostram como o valor esperado se comporta frente a operações lineares com vetores e matrizes. Essas propriedades facilitam muito os cálculos em Estatística Multivariada, especialmente quando lidamos com modelos lineares ou transformações lineares de vetores aleatórios.

Resultado 3.1: Propriedades do valor esperado de um vetor aleatório

Seja p um número inteiro positivo. Considere os vetores aleatórios $\mathbf{X}$ e $\mathbf{Y}$ em $\mathbb{R}^p$. O *valor esperado* de vetores aleatórios possui as seguintes propriedades.

- (a) $\mathbb{E}(a\mathbf{X}) = a\mathbb{E}(\mathbf{X})$, qualquer que seja a constante $a \in \mathbb{R}$.
- (b) $\mathbb{E}(\mathbf{X} + \mathbf{Y}) = \mathbb{E}(\mathbf{X}) + \mathbb{E}(\mathbf{Y})$.
- (c) $\mathbb{E}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mathbb{E}(\mathbf{X})$, qualquer que seja o vetor de constantes $\mathbf{a} \in \mathbb{R}^p$.
- (d) $\mathbb{E}(\mathbf{a}^\top \mathbf{X} + \mathbf{b}^\top \mathbf{Y}) = \mathbf{a}^\top \mathbb{E}(\mathbf{X}) + \mathbf{b}^\top \mathbb{E}(\mathbf{Y})$, quaisquer que sejam os vetores de constantes $\mathbf{a} \in \mathbb{R}^p$ e $\mathbf{b} \in \mathbb{R}^p$.
- (e) $\mathbb{E}(\mathbf{A}\mathbf{X}) = \mathbf{A}\mathbb{E}(\mathbf{X})$, qualquer que seja a matriz de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$, em que q é um número inteiro positivo.
- (f) $\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{B}\mathbb{E}(\mathbf{Y})$, quaisquer que sejam as matrizes de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$ e $\mathbf{B} \in M_{q \times p}(\mathbb{R})$, em que q é um número inteiro positivo.
- (g) $\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}$, quaisquer que sejam a matriz de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$ e o vetor de constantes $\mathbf{b} \in \mathbb{R}^q$, em que q é um número inteiro positivo.

Resultado 3.1DEMONSTRAÇÃO:

- (a) Pela definição do vetor de médias e por propriedades do valor esperado de variáveis aleatórias, segue que

$$\mathbb{E}(a\mathbf{X}) := \begin{bmatrix} \mathbb{E}(aX_1) \\ \vdots \\ \mathbb{E}(aX_p) \end{bmatrix} = \begin{bmatrix} a\mathbb{E}(X_1) \\ \vdots \\ a\mathbb{E}(X_p) \end{bmatrix} = a \begin{bmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{bmatrix} = a\mathbb{E}(\mathbf{X}).$$

- (b) Pela definição do vetor de médias e pela linearidade do valor esperado para variáveis aleatórias, temos

$$\begin{aligned} \mathbb{E}(\mathbf{X} + \mathbf{Y}) &:= \begin{bmatrix} \mathbb{E}(X_1 + Y_1) \\ \vdots \\ \mathbb{E}(X_p + Y_p) \end{bmatrix} \\ &= \begin{bmatrix} \mathbb{E}(X_1) + \mathbb{E}(Y_1) \\ \vdots \\ \mathbb{E}(X_p) + \mathbb{E}(Y_p) \end{bmatrix} \\ &= \begin{bmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{bmatrix} + \begin{bmatrix} \mathbb{E}(Y_1) \\ \vdots \\ \mathbb{E}(Y_p) \end{bmatrix} \\ &= \mathbb{E}(\mathbf{X}) + \mathbb{E}(\mathbf{Y}). \end{aligned}$$

- (c) Note que

$$\mathbf{a}^\top \mathbf{X} = \begin{bmatrix} a_1 & \cdots & a_p \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} = a_1 X_1 + \cdots + a_p X_p.$$

Logo, $\mathbf{a}^\top \mathbf{X}$ é uma variável aleatória. Assim, pela linearidade do valor esperado para variáveis aleatórias, temos

$$\begin{aligned} \mathbb{E}(\mathbf{a}^\top \mathbf{X}) &= \mathbb{E}(a_1 X_1 + \cdots + a_p X_p) \\ &= \mathbb{E}(a_1 X_1) + \cdots + \mathbb{E}(a_p X_p) \\ &= a_1 \mathbb{E}(X_1) + \cdots + a_p \mathbb{E}(X_p) \\ &= a_1 \mathbb{E}(X_1) + \cdots + a_p \mathbb{E}(X_p) \end{aligned}$$

Resultado 3.1

$$\begin{aligned}
 &= \begin{bmatrix} a_1 & \cdots & a_p \end{bmatrix} \begin{bmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{bmatrix} \\
 &= \mathbf{a}^\top \mathbb{E}(\mathbf{X}).
 \end{aligned}$$

(d) Aplicando o resultado do item (b), seguido do resultado do item (c), temos

$$\mathbb{E}(\mathbf{a}^\top \mathbf{X} + \mathbf{b}^\top \mathbf{Y}) \stackrel{(b)}{=} \mathbb{E}(\mathbf{a}^\top \mathbf{X}) + \mathbb{E}(\mathbf{b}^\top \mathbf{Y}) \stackrel{(c)}{=} \mathbf{a}^\top \mathbb{E}(\mathbf{X}) + \mathbf{b}^\top \mathbb{E}(\mathbf{Y}).$$

(e) Note que

$$\mathbf{A}\mathbf{X} = \begin{bmatrix} a_{11} & \cdots & a_{1p} \\ \vdots & \ddots & \vdots \\ a_{q1} & \cdots & a_{qp} \end{bmatrix} \begin{bmatrix} X_1 \\ \vdots \\ X_p \end{bmatrix} = \begin{bmatrix} a_{11}X_1 + \cdots + a_{1p}X_p \\ \vdots \\ a_{q1}X_1 + \cdots + a_{qp}X_p \end{bmatrix}.$$

Logo, pela definição de esperança de vetores e linearidade do operador esperança, temos

$$\begin{aligned}
 \mathbb{E}(\mathbf{A}\mathbf{X}) &= \begin{bmatrix} \mathbb{E}(a_{11}X_1 + \cdots + a_{1p}X_p) \\ \vdots \\ \mathbb{E}(a_{q1}X_1 + \cdots + a_{qp}X_p) \end{bmatrix} \\
 &= \begin{bmatrix} a_{11}\mathbb{E}(X_1) + \cdots + a_{1p}\mathbb{E}(X_p) \\ \vdots \\ a_{q1}\mathbb{E}(X_1) + \cdots + a_{qp}\mathbb{E}(X_p) \end{bmatrix} \\
 &= \begin{bmatrix} a_{11} & \cdots & a_{1p} \\ \vdots & \ddots & \vdots \\ a_{q1} & \cdots & a_{qp} \end{bmatrix} \begin{bmatrix} \mathbb{E}(X_1) \\ \vdots \\ \mathbb{E}(X_p) \end{bmatrix} \\
 &= \mathbf{A}\mathbb{E}(\mathbf{X}).
 \end{aligned}$$

(f) Aplicando o resultado do item (b), seguido do resultado do item (e), temos

$$\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{B}\mathbf{Y}) \stackrel{(b)}{=} \mathbb{E}(\mathbf{A}\mathbf{X}) + \mathbb{E}(\mathbf{B}\mathbf{Y}) \stackrel{(e)}{=} \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{B}\mathbb{E}(\mathbf{Y}).$$

(g) Aplicando o resultado do item (b), seguido do resultado do item (e), temos

Resultado 3.1

$$\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{b}) \stackrel{(b)}{=} \mathbb{E}(\mathbf{A}\mathbf{X}) + \mathbb{E}(\mathbf{b}) \stackrel{(e)}{=} \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b}.$$

Note que usamos $\mathbb{E}(\mathbf{b}) = \mathbf{b}$, pois $\mathbf{b}$ é um vetor de constantes.

**Exemplo 3.7**

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^4$, em que as componentes são mutuamente independentes e $X_k \sim \text{Bernoulli}(\theta)$, em que $0 < \theta < 1$, $k = 1, 2, 3, 4$. Determine os seguintes valores esperados.

- (a) Use as propriedades do Resultado 3.1 para determinar $\mathbb{E}(\mathbf{1}^\top \mathbf{X})$, em que $\mathbf{1} \in \mathbb{R}^4$ é o vetor de uns.
- (b) Qual é a distribuição da variável aleatória $\mathbf{1}^\top \mathbf{X}$? O resultado do item (a) é consistente com valor esperado atrelado a essa distribuição?
- (c) Use as propriedades do Resultado 3.1 para determinar $\mathbb{E}(\mathbf{a}^\top \mathbf{X} + 5)$, em que $\mathbf{a}^\top = [1 \ 2 \ 3 \ 4]$.
- (d) Podemos afirmar que a distribuição de $\mathbf{a}^\top \mathbf{X} + 5$ é Binomial? Por quê?

SOLUÇÃO:

- (a) Pelo item (c) do Resultado 3.1, segue que

$$\mathbb{E}(\mathbf{1}^\top \mathbf{X}) = \mathbf{1}^\top \mathbb{E}(\mathbf{X}) = \begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \mathbb{E}(X_3) \\ \mathbb{E}(X_4) \end{bmatrix} = \mathbb{E}(X_1) + \cdots + \mathbb{E}(X_4) = 4\theta,$$

pois $\mathbb{E}(X_1) = \cdots = \mathbb{E}(X_4) = \theta$.

- (b) Note que $\mathbf{1}^\top \mathbf{X} = X_1 + \cdots + X_4$. Logo, a variável aleatória $\mathbf{1}^\top \mathbf{X}$ trata-se de uma soma de variáveis aleatórias independentes todas com distribuição Bernoulli(θ), $0 < \theta < 1$. Logo,

$$\mathbf{1}^\top \mathbf{X} = X_1 + \cdots + X_4 \sim \text{Binomial}(n = 4, \theta).$$

Exemplo 3.7

Da teoria de distribuições, sabemos que para uma variável aleatória $Y \sim \text{Binomial}(n, \theta)$, temos $\mathbb{E}(Y) = n\theta$. Logo, como esperado e desejado, $\mathbb{E}(\mathbf{1}^\top \mathbf{X}) = n\theta = 4\theta$, o que é consistente com o resultado obtido no item (a).

(c) Como $\mathbf{a}^\top \mathbf{X}$ é uma variável aleatória

$$\mathbb{E}(\mathbf{a}^\top \mathbf{X} + 5) = \mathbb{E}(\mathbf{a}^\top \mathbf{X}) + 5.$$

Logo, pelo item (c) do Resultado 3.1, segue que

$$\begin{aligned} \mathbb{E}(\mathbf{a}^\top \mathbf{X} + 5) &= \mathbf{a}^\top \mathbb{E}(\mathbf{X}) + 5 \\ &= \begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix} \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \mathbb{E}(X_3) \\ \mathbb{E}(X_4) \end{bmatrix} + 5 \\ &= \mathbb{E}(X_1) + 2\mathbb{E}(X_2) + 3\mathbb{E}(X_3) + 4\mathbb{E}(X_4) + 5 \\ &= 10\theta + 5, \end{aligned}$$

pois $\mathbb{E}(X_1) = \dots = \mathbb{E}(X_4) = \theta$.

(d) Não podemos afirmar que a distribuição da variável aleatória $\mathbf{a}^\top \mathbf{X} + 5$ é Binomial, pois, embora as variáveis aleatórias sejam independentes com a mesma distribuição Bernoulli(θ), a distribuição Binomial exige soma de Bernoullis equiponderadas (i.e., com mesmo coeficiente). Com efeito, o termo constante (+5) desloca o suporte para fora do padrão $\{0, 1, \dots, n\}$ das distribuições binomiais.

Exemplo 3.8

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$, com componentes independentes e $X_k \sim \text{Normal}(k, k^2)$, $k = 1, 2, 3$. Considere a matriz $\mathbf{A} \in M_{2 \times 3}(\mathbb{R})$ tal que

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 0 \\ 2 & 4 & -3 \end{bmatrix}.$$

(a) Use as propriedades do Resultado 3.1 para determinar $\mathbb{E}(\mathbf{A}\mathbf{X})$.

Exemplo 3.8

- (b) Qual é a distribuição de probabilidade da variável aleatória $\mathbf{a}_1^\top \mathbf{X} + \mathbf{a}_2^\top \mathbf{X}$, em que $\mathbf{a}_1^\top$ e $\mathbf{a}_2^\top$ são a primeira e a segunda linha da matriz $\mathbf{A}$, respectivamente.

SOLUÇÃO:

- (a) Pelo item (e) do Resultado 3.1, segue que

$$\begin{aligned}\mathbb{E}(\mathbf{AX}) &= \mathbf{A}\mathbb{E}(\mathbf{X}) \\ &= \begin{bmatrix} 1 & -1 & 0 \\ 2 & 4 & -3 \end{bmatrix} \begin{bmatrix} \mathbb{E}(X_1) \\ \mathbb{E}(X_2) \\ \mathbb{E}(X_3) \end{bmatrix} \\ &= \begin{bmatrix} 1 & -1 & 0 \\ 2 & 4 & -3 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \\ &= \begin{bmatrix} -1 \\ 1 \end{bmatrix},\end{aligned}$$

pois $\mathbb{E}(X_k) = k$, para todo $k = 1, 2, 3$.

- (b) Note que $\mathbf{a}_1^\top \mathbf{X} = X_1 - X_2$ e $\mathbf{a}_2^\top \mathbf{X} = 2X_1 + 4X_2 - 3X_3$. Logo, $\mathbf{a}_1^\top \mathbf{X} + \mathbf{a}_2^\top \mathbf{X} = 3X_1 + 3X_2 - 3X_3$. Como a combinação linear de variáveis aleatórias independentes e normalmente distribuídas possui distribuição normal, segue que

$$\mathbf{a}_1^\top \mathbf{X} + \mathbf{a}_2^\top \mathbf{X} = 3X_1 + 3X_2 - 3X_3 \sim \text{Normal}(0, 126),$$

pois

$$\mathbb{E}(\mathbf{a}_1^\top \mathbf{X} + \mathbf{a}_2^\top \mathbf{X}) = 3\mathbb{E}(X_1) + 3\mathbb{E}(X_2) - 3\mathbb{E}(X_3) = 3 \times (1 + 2 - 3) = 0$$

e

$$\text{Var}(\mathbf{a}_1^\top \mathbf{X} + \mathbf{a}_2^\top \mathbf{X}) = 9\text{Var}(X_1) + 9\text{Var}(X_2) + 9\text{Var}(X_3) = 9 \times (1 + 4 + 9) = 126.$$

Em problemas com múltiplas variáveis, é comum considerarmos uma amostra aleatória de tamanho n de um vetor aleatório $\mathbf{X} = [X_1 \ \cdots \ X_p]^\top$ em $\mathbb{R}^p$. Podemos organizar essa amostra em uma *matriz aleatória* $\mathbf{X}$ em $M_{n \times p}(\mathbb{R})$. Por exemplo, cada linha representa uma unidade amostral (ex.: um indivíduo) e cada coluna uma variável (ex.: altura, peso, etc.).

Definição 3.4: Matriz aleatória

Sejam n e p números inteiros positivos. Uma *matriz aleatória* $\mathbf{X}$ em $M_{n \times p}(\mathbb{R})$ é uma matriz cujas entradas são variáveis aleatórias definidas no mesmo espaço de probabilidade, i.e.,

$$\mathbf{X} := \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}.$$

Para descrever o comportamento médio dessa matriz, usamos a matriz de médias populacionais, que contém os valores esperados de cada variável. Essa ideia será fundamental mais adiante, quando estudarmos a matriz de variâncias e covariâncias e também as distribuições multivariadas, como a normal multivariada.

Definição 3.5: Valor esperado de uma matriz aleatória

Sejam n e p números inteiros positivos. O *valor esperado* de uma matriz aleatória $\mathbf{X}$ em $M_{n \times p}(\mathbb{R})$, denotado por $\mathbb{E}(\mathbf{X})$, é uma matriz cujas entradas são os valores esperados das variáveis aleatórias que compõem a matriz $\mathbf{X}$, i.e.,

$$\mathbb{E}(\mathbf{X}) := \begin{bmatrix} \mathbb{E}(X_{11}) & \mathbb{E}(X_{12}) & \cdots & \mathbb{E}(X_{1p}) \\ \mathbb{E}(X_{21}) & \mathbb{E}(X_{22}) & \cdots & \mathbb{E}(X_{2p}) \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}(X_{n1}) & \mathbb{E}(X_{n2}) & \cdots & \mathbb{E}(X_{np}) \end{bmatrix}.$$

Exemplo 3.9

Seja $\mathbf{X}$ uma matriz aleatória em $M_{2 \times 2}(\mathbb{R})$ tal que

$$\mathbb{E}(\mathbf{X}) = \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix}.$$

Considere as matrizes de constantes $\mathbf{A} \in M_{3 \times 2}(\mathbb{R})$ e $\mathbf{B} \in M_{2 \times 3}(\mathbb{R})$ tais que

Exemplo 3.9

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix} \quad \text{e} \quad \mathbf{B} = \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & -1 \end{bmatrix}.$$

Defina $\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{B}$. Verifique que $\mathbf{Y}$ é uma matriz aleatória e determine seu valor esperado.

SOLUÇÃO:

Como $\mathbf{X}$ é um vetor aleatório, $\mathbf{Y} = \mathbf{A}\mathbf{X}\mathbf{B}$ é uma matriz aleatória em $M_{3 \times 3}(\mathbb{R})$ tal que

$$\begin{aligned} \mathbf{Y} &= \mathbf{A}\mathbf{X}\mathbf{B} \\ &= \begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} X_{11} & X_{12} \\ X_{21} & X_{22} \end{bmatrix} \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & -1 \end{bmatrix} \\ &= \begin{bmatrix} X_{11} + X_{21} & X_{12} + X_{22} \\ -X_{11} & -X_{12} \\ -X_{21} & -X_{22} \end{bmatrix} \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & -1 \end{bmatrix} \\ &= \begin{bmatrix} X_{11} + X_{21} & X_{11} + X_{21} & 2X_{11} + 2X_{21} - X_{12} - X_{22} \\ -X_{11} & -X_{11} & -2X_{11} + X_{12} \\ -X_{21} & -X_{21} & -2X_{21} + X_{22} \end{bmatrix}. \end{aligned}$$

Logo, a matriz de médias $\mathbb{E}(\mathbf{Y})$ é dada por

$$\begin{bmatrix} \mathbb{E}(X_{11}) + \mathbb{E}(X_{21}) & \mathbb{E}(X_{11}) + \mathbb{E}(X_{21}) & 2\mathbb{E}(X_{11}) + 2\mathbb{E}(X_{21}) - \mathbb{E}(X_{12}) - \mathbb{E}(X_{22}) \\ -\mathbb{E}(X_{11}) & -\mathbb{E}(X_{11}) & -2\mathbb{E}(X_{11}) + \mathbb{E}(X_{12}) \\ -\mathbb{E}(X_{21}) & -\mathbb{E}(X_{21}) & -2\mathbb{E}(X_{21}) + \mathbb{E}(X_{22}) \end{bmatrix}.$$

Uma vez que conhecemos o vetor de médias $\mathbb{E}(\mathbf{X})$ segue que

$$\mathbb{E}(\mathbf{Y}) = \begin{bmatrix} -2 & -2 & -6 \\ 2 & 2 & 4 \\ 0 & 0 & 2 \end{bmatrix}.$$

As demonstrações das propriedades envolvendo o valor esperado de matrizes aleatórias, que enunciaremos a seguir, seguem ideias muito semelhantes às que já vimos para vetores aleatórios. A chave está em aplicar a linearidade do valor esperado a cada entrada X_{ij}

da matriz. Por isso, deixamos essas demonstrações como exercício para o leitor (ver Exercício 8 da Lista 2).

Resultado 3.2: Propriedades do valor esperado de uma matriz aleatória

Sejam n e p números inteiros positivos. Considere o vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$ e a matriz aleatória $\mathbf{Y}$ em $M_{n \times p}(\mathbb{R})$. As seguintes propriedades são válidas.

- (a) $\mathbb{E}(\mathbf{X}\mathbf{a}^\top) = \mathbb{E}(\mathbf{X})\mathbf{a}^\top$, qualquer que seja o vetor de constantes $\mathbf{a} \in \mathbb{R}^q$.
- (b) $\mathbb{E}(\mathbf{X}\mathbf{a}^\top + \mathbf{B}) = \mathbb{E}(\mathbf{X})\mathbf{a}^\top + \mathbf{B}$, quaisquer que sejam o vetor de constantes $\mathbf{a} \in \mathbb{R}^p$ e a matriz de constantes $\mathbf{B} \in M_{p \times q}(\mathbb{R})$.
- (c) $\mathbb{E}(\mathbf{a}^\top \mathbf{X} \mathbf{a}^\top) = \mathbf{a}^\top \mathbb{E}(\mathbf{X}) \mathbf{a}^\top$, qualquer que seja o vetor de constantes $\mathbf{a} \in \mathbb{R}^p$.
- (d) $\mathbb{E}(\mathbf{A} \mathbf{X} \mathbf{b}^\top) = \mathbf{A} \mathbb{E}(\mathbf{X}) \mathbf{b}^\top$, quaisquer que sejam a matriz de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$ e o vetor de constantes $\mathbf{b} \in \mathbb{R}^p$.
- (e) $\mathbb{E}(\mathbf{a} \mathbf{X}^\top + \mathbf{B}) = \mathbf{a} \mathbb{E}(\mathbf{X})^\top + \mathbf{B}$, quaisquer que sejam o vetor de constantes $\mathbf{a} \in \mathbb{R}^p$ e a matriz de constantes $\mathbf{B} \in M_{p \times p}(\mathbb{R})$.
- (f) $\mathbb{E}(\mathbf{A} \mathbf{Y} \mathbf{B}) = \mathbf{A} \mathbb{E}(\mathbf{Y}) \mathbf{B}$, quaisquer que sejam as matrizes de constantes $\mathbf{A} \in M_{m \times n}(\mathbb{R})$ e $\mathbf{B} \in M_{p \times q}(\mathbb{R})$.

DEMONSTRAÇÃO: Exercício.

Exemplo 3.10

Considere a matriz aleatória $\mathbf{Y}$ introduzida no Exemplo 3.9. Verifique que a matriz de médias $\mathbb{E}(\mathbf{Y})$ também pode ser obtida utilizando o item (f) do Resultado 3.2.

SOLUÇÃO:

De fato, pelo item (f) do Resultado 3.2, segue que

$$\begin{aligned} \mathbb{E}(\mathbf{Y}) &= \mathbb{E}(\mathbf{A} \mathbf{X} \mathbf{B}) \\ &= \mathbf{A} \mathbb{E}(\mathbf{X}) \mathbf{B} \\ &= \begin{bmatrix} 1 & 1 \\ -1 & 0 \\ 0 & -1 \end{bmatrix} \begin{bmatrix} -2 & 0 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & -1 \end{bmatrix} \end{aligned}$$

Exemplo 3.10

$$\begin{aligned}
&= \begin{bmatrix} -2 & 2 \\ 2 & 0 \\ 0 & -2 \end{bmatrix} \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & -1 \end{bmatrix} \\
&= \begin{bmatrix} -2 & -2 & -6 \\ 2 & 2 & 4 \\ 0 & 0 & 2 \end{bmatrix}.
\end{aligned}$$

Portanto,

$$\mathbb{E}(\mathbf{Y}) = \begin{bmatrix} -2 & -2 & -6 \\ 2 & 2 & 4 \\ 0 & 0 & 2 \end{bmatrix},$$

o que é consistente com a matriz de médias encontrada no Exemplo 3.9.

Exemplo 3.11

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ cujo vetor de médias é dado por $\boldsymbol{\mu} = \mathbb{E}(\mathbf{X})$. Considere a matriz aleatória $\mathbf{Y}$ em $M_{p \times p}(\mathbb{R})$ dada por $\mathbf{Y} := (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top$. Utilize as propriedades do Resultado 3.2 para mostrar que

$$\mathbb{E}(\mathbf{Y}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] = \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \boldsymbol{\mu}\boldsymbol{\mu}^\top.$$

SOLUÇÃO: Pelos itens (a), (b) e (e) do Resultado 3.2, segue que

$$\begin{aligned}
\mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] &= \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X}^\top - \boldsymbol{\mu}^\top)] \\
&= \mathbb{E}[\mathbf{X}\mathbf{X}^\top - \mathbf{X}\boldsymbol{\mu}^\top - \boldsymbol{\mu}\mathbf{X}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top] \\
&\stackrel{(b)}{=} \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \mathbb{E}(\mathbf{X}\boldsymbol{\mu}^\top) - \mathbb{E}(\boldsymbol{\mu}\mathbf{X}^\top) + \mathbb{E}(\boldsymbol{\mu}\boldsymbol{\mu}^\top) \\
&\stackrel{(a)}{=} \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \mathbb{E}(\mathbf{X})\boldsymbol{\mu}^\top - \mathbb{E}(\boldsymbol{\mu}\mathbf{X})^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\
&\stackrel{(e)}{=} \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \mathbb{E}(\mathbf{X})\boldsymbol{\mu}^\top - \boldsymbol{\mu}\mathbb{E}(\mathbf{X})^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\
&= \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \boldsymbol{\mu}\boldsymbol{\mu}^\top - \boldsymbol{\mu}\boldsymbol{\mu}^\top + \boldsymbol{\mu}\boldsymbol{\mu}^\top \\
&= \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \boldsymbol{\mu}\boldsymbol{\mu}^\top.
\end{aligned}$$

$$\therefore \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] = \mathbb{E}(\mathbf{X}\mathbf{X}^\top) - \boldsymbol{\mu}\boldsymbol{\mu}^\top.$$

3.3 Matriz de variâncias e covariâncias de um vetor aleatório

Nesta seção, estudaremos a matriz de variâncias e covariâncias de um vetor aleatório, uma generalização natural do conceito de variância no contexto univariado. Assim como a variância mede a dispersão de uma única variável aleatória em torno de sua média, a matriz de covariâncias descreve a variabilidade conjunta entre as componentes de um vetor aleatório – tanto a variabilidade individual de cada componente quanto a relação linear entre elas. Veremos que essa matriz desempenha um papel central na Estatística Multivariada, sendo fundamental para o estudo de distribuições, estimação e análise da estrutura de dependência entre variáveis.

Definição 3.6: Matriz de variâncias e covariâncias de um vetor aleatório

Seja p um número inteiro positivo. A *matriz de variâncias e covariâncias* de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, denotada por $Cov(\mathbf{X})$, é uma matriz $\Sigma \in M_{p \times p}(\mathbb{R})$ tal que

$$\begin{aligned} Cov(\mathbf{X}) &:= \begin{bmatrix} Var(X_1) & Cov(X_1, X_2) & \cdots & Cov(X_1, X_p) \\ Cov(X_2, X_1) & Var(X_2) & \cdots & Cov(X_2, X_p) \\ \vdots & \vdots & \ddots & \vdots \\ Cov(X_p, X_1) & Cov(X_p, X_2) & \cdots & Var(X_p) \end{bmatrix} \\ &= \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \sigma_{p2} & \cdots & \sigma_{pp} \end{bmatrix} := \Sigma. \end{aligned}$$

Como vimos no Capítulo 2, Σ é a *matriz de variâncias e covariâncias populacionais*.

Exemplo 3.12

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.1, em que $p: \mathbb{R}^2 \rightarrow [0, 1]$ é tal que

$x_1 \backslash x_2$	0	1	$\mathbb{P}(X_1 = x_1)$
0	2/20	6/20	8/20
1	6/20	6/20	12/20
$\mathbb{P}(X_2 = x_2)$	8/20	12/20	1

Exemplo 3.12

para $\mathbf{x} \in \{0, 1\}^2$ e $p(\mathbf{x}) = 0$ caso contrário. Determine a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

Como vimos no Exemplo 3.1, as variáveis aleatórias X_1 e X_2 são identicamente distribuídas, i.e., $X_1 \sim \text{Bernoulli}(12/20)$ e $X_2 \sim \text{Bernoulli}(12/20)$. Logo,

$$\sigma_{11} = \text{Var}(X_1) = \frac{12}{20} \times \frac{8}{20} = \frac{6}{25} = \text{Var}(X_2) = \sigma_{22}.$$

No Exemplo 3.1, vimos também que X_1 e X_2 não são independentes. Logo, precisamos determinar a covariância entre essas variáveis. Nesse sentido, primeiramente, fazemos

$$\begin{aligned} \mathbb{E}(X_1 X_2) &= \sum_{x_1=0}^1 \sum_{x_2=0}^1 x_1 x_2 p(x_1, x_2) \\ &= \left(0 \times \frac{2}{20}\right) + \left(0 \times \frac{6}{20}\right) + \left(0 \times \frac{6}{20}\right) + \left(1 \times \frac{6}{20}\right) \\ &= \frac{6}{20}. \end{aligned}$$

Logo,

$$\begin{aligned} \sigma_{12} &= \text{Cov}(X_1, X_2) \\ &= \mathbb{E}(X_1 X_2) - \mathbb{E}(X_1)\mathbb{E}(X_2) \\ &= \frac{6}{20} - \left(\frac{12}{20} \times \frac{12}{20}\right) \\ &= -\frac{3}{50}. \end{aligned}$$

Portanto, a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 6/25 & -3/50 \\ -3/50 & 6/25 \end{bmatrix}.$$

Exemplo 3.13

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.2, em que a função densidade de probabilidade $f: \mathbb{R}^2 \rightarrow [0, +\infty[$ é tal que

Exemplo 3.13

$$f(\mathbf{x}) = \begin{cases} \frac{1}{4} & \text{se } \mathbf{x} \in [0, 2] \times [0, 2], \\ 0 & \text{caso contrário.} \end{cases}$$

Determine a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

Como vimos no Exemplo 3.2, as variáveis aleatórias X_1 e X_2 são identicamente distribuídas, i.e., $X_1 \sim \text{Uniforme}(0, 2)$ e $X_2 \sim \text{Uniforme}(0, 2)$. Da teoria de distribuições, sabemos que para uma variável aleatória $Y \sim \text{Uniforme}(a, b)$, em que a e b são número reais tais que $a < b$, temos $\text{Var}(Y) = \frac{b-a}{12}$. Logo,

$$\sigma_{11} = \text{Var}(X_1) = \frac{2}{12} = \frac{1}{6} = \text{Var}(X_2) = \sigma_{22}.$$

No Exemplo 3.2, vimos também que X_1 e X_2 são independentes. Logo,

$$\sigma_{12} = \text{Cov}(X_1, X_2) = 0 = \text{Cov}(X_2, X_1) = \sigma_{21}.$$

Portanto, a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 1/6 & 0 \\ 0 & 1/6 \end{bmatrix}.$$

Exemplo 3.14

Determine a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.3, em que X_1 , X_2 e X_3 são variáveis aleatórias independentes tais que $X_k \sim \text{Normal}(0, 1)$ para $k = 1, 2, 3$.

SOLUÇÃO:

Como para cada $k = 1, 2, 3$, temos $X_k \sim \text{Normal}(0, 1)$, segue que

$$\sigma_{kk} = \text{Var}(X_k) = 1.$$

Desde que X_1 , X_2 e X_3 são variáveis aleatórias independentes, temos

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = 0$$

Exemplo 3.14

para todo $i, k = 1, 2, 3$ com $i \neq k$. Portanto, a matriz de variâncias e covariâncias Σ do vetor aleatório $\mathbf{X}$ é

$$\Sigma = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} := \mathbf{I}_3,$$

em que $\mathbf{I}_3$ denota a matriz identidade de ordem 3×3 .

Antes de estudarmos algumas propriedades da matriz de variâncias e covariâncias de um vetor aleatório, vale destacar que muitas delas são extensões naturais das regras conhecidas no caso univariado. Assim como o valor esperado, a matriz de variâncias e covariâncias apresenta um comportamento bem estruturado frente a transformações lineares, o que é essencial na Estatística Multivariada. Essas propriedades não apenas facilitam cálculos algébricos, mas também formam a base teórica para o desenvolvimento de técnicas como modelos lineares multivariados, análise de componentes principais, análise de discriminante e outras aplicações. A seguir, apresentamos um conjunto de propriedades que nos mostram como a matriz de variâncias e covariâncias se comporta sob operações lineares com vetores e matrizes.

Resultado 3.3: Propriedades da matriz de variâncias e covariâncias

Seja p um número inteiro positivo. Considere o vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$. A *matriz de variâncias e covariâncias* de vetores aleatórios possui as seguintes propriedades.

- (a) $\text{Cov}(\mathbf{X}) = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top]$, em que $\boldsymbol{\mu} = \mathbb{E}(\mathbf{X})$.
- (b) $\text{Cov}(a\mathbf{X}) = a^2 \text{Cov}(\mathbf{X})$, qualquer que seja a constante $a \in \mathbb{R}$.
- (c) $\text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \text{Cov}(\mathbf{X}) \mathbf{a}$, qualquer que seja o vetor de constantes $\mathbf{a} \in \mathbb{R}^p$.
- (d) $\text{Cov}(\mathbf{A}\mathbf{X}) = \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top$, qualquer que seja a matriz de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$, em que q é um número inteiro positivo.
- (e) $\text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top$, quaisquer que sejam a matriz de constantes $\mathbf{A} \in M_{q \times p}(\mathbb{R})$ e o vetor de constantes $\mathbf{b} \in \mathbb{R}^q$, em que q é um número inteiro positivo.

Resultado 3.3DEMONSTRAÇÃO:

(a) Note que $(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top$ é uma matriz de ordem $p \times p$ que pode ser escrita da seguinte maneira

$$\begin{aligned} (\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top &= \begin{bmatrix} X_1 - \mu_1 \\ \vdots \\ X_p - \mu_p \end{bmatrix} \begin{bmatrix} X_1 - \mu_1 & \cdots & X_p - \mu_p \end{bmatrix} \\ &= \begin{bmatrix} (X_1 - \mu_1)(X_1 - \mu_1) & \cdots & (X_1 - \mu_1)(X_p - \mu_p) \\ \vdots & \ddots & \vdots \\ (X_p - \mu_p)(X_1 - \mu_1) & \cdots & (X_p - \mu_p)(X_p - \mu_p) \end{bmatrix}. \end{aligned}$$

Logo, o valor esperado de $(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top$ é a matriz de médias

$$\mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] = \begin{bmatrix} \mathbb{E}(X_1 - \mu_1)(X_1 - \mu_1) & \cdots & \mathbb{E}[(X_1 - \mu_1)(X_p - \mu_p)] \\ \vdots & \ddots & \vdots \\ \mathbb{E}(X_p - \mu_p)(X_1 - \mu_1) & \cdots & \mathbb{E}(X_p - \mu_p)(X_p - \mu_p) \end{bmatrix}$$

Por um lado, sabemos que para cada $k = 1, 2, \dots, p$, a variância da variável aleatória X_k é definida da seguinte maneira

$$\sigma_{kk} = \text{Var}(X_k) := \mathbb{E}[(X_k - \mu_k)^2] = \mathbb{E}[(X_k - \mu_k)(X_k - \mu_k)].$$

Por outro lado, para cada $i, k = 1, 2, \dots, p$ com $i \neq k$, a covariância entre as variáveis aleatórias X_i e X_k é dada por

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = \mathbb{E}[(X_i - \mu_i)(X_k - \mu_k)] = \text{Cov}(X_k, X_i) = \sigma_{ki}.$$

Portanto, podemos reescrever a matriz de médias $\mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top]$ da seguinte maneira

$$\mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix} = \text{Cov}(\mathbf{X}).$$

(b) Defina $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X})$. Pelo item (a) do Resultado 3.1, sabemos que

Resultado 3.3

$$\mathbb{E}(a\mathbf{X}) = a\mathbb{E}(\mathbf{X}) = a\boldsymbol{\mu}.$$

Logo, pelo resultado do item (a) provado anteriormente, segue que

$$\begin{aligned} \text{Cov}(a\mathbf{X}) &= \mathbb{E}[(a\mathbf{X} - a\boldsymbol{\mu})(a\mathbf{X} - a\boldsymbol{\mu})^\top] \\ &= \mathbb{E}[a(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top a] \\ &= a^2 \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \\ &= a^2 \text{Cov}(\mathbf{X}). \end{aligned}$$

(c) Defina $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X})$. Pelo item (c) do Resultado 3.1, sabemos que

$$\mathbb{E}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \mathbb{E}(\mathbf{X}) = \mathbf{a}^\top \boldsymbol{\mu}.$$

Logo, pelo resultado do item (a) provado anteriormente, segue que

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \mathbf{X}) &= \mathbb{E}[(\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu})(\mathbf{a}^\top \mathbf{X} - \mathbf{a}^\top \boldsymbol{\mu})^\top] \\ &= \mathbb{E}\left\{\mathbf{a}^\top [\mathbf{X} - \boldsymbol{\mu}] \left[(\mathbf{a}^\top \mathbf{X})^\top - (\mathbf{a}^\top \boldsymbol{\mu})^\top\right]\right\} \\ &= \mathbb{E}\left[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X}^\top \mathbf{a} - \boldsymbol{\mu}^\top \mathbf{a})\right] \\ &= \mathbb{E}\left[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X}^\top - \boldsymbol{\mu}^\top) \mathbf{a}\right] \\ &= \mathbb{E}\left[\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{a}\right] \\ &\stackrel{(c)}{=} \mathbf{a}^\top \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] \mathbf{a} \\ &= \mathbf{a}^\top \text{Cov}(\mathbf{X}) \mathbf{a}, \end{aligned}$$

em que (c) refere-se ao item (c) do Resultado 3.2.

(d) Defina $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X})$. Pelo item (e) do Resultado 3.1, sabemos que

$$\mathbb{E}(\mathbf{A}\mathbf{X}) = \mathbf{A}\mathbb{E}(\mathbf{X}) = \mathbf{A}\boldsymbol{\mu}.$$

Logo, pelo resultado do item (a) provado anteriormente, segue que

$$\begin{aligned} \text{Cov}(\mathbf{A}\mathbf{X}) &= \mathbb{E}[(\mathbf{A}\mathbf{X} - \mathbf{A}\boldsymbol{\mu})(\mathbf{A}\mathbf{X} - \mathbf{A}\boldsymbol{\mu})^\top] \\ &= \mathbb{E}\left\{\mathbf{A} [\mathbf{X} - \boldsymbol{\mu}] \left[(\mathbf{A}\mathbf{X})^\top - (\mathbf{A}\boldsymbol{\mu})^\top\right]\right\} \\ &= \mathbb{E}\left[\mathbf{A} (\mathbf{X} - \boldsymbol{\mu}) (\mathbf{X}^\top \mathbf{A}^\top - \boldsymbol{\mu}^\top \mathbf{A}^\top)\right] \end{aligned}$$

Resultado 3.3

$$\begin{aligned}
&= \mathbb{E} \left[\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X}^\top - \boldsymbol{\mu}^\top) \mathbf{A}^\top \right] \\
&= \mathbb{E} \left[\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \mathbf{A}^\top \right] \\
&\stackrel{(f)}{=} \mathbf{A} \mathbb{E} \left[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top \right] \mathbf{A}^\top \\
&= \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top,
\end{aligned}$$

em que (f) refere-se ao item (f) do Resultado 3.2.

(e) Defina $\boldsymbol{\mu} := \mathbb{E}(\mathbf{X})$. Pelo item (g) do Resultado 3.1, sabemos que

$$\mathbb{E}(\mathbf{A}\mathbf{X} + \mathbf{b}) = \mathbf{A}\mathbb{E}(\mathbf{X}) + \mathbf{b} = \mathbf{A}\boldsymbol{\mu} + \mathbf{b}.$$

Logo, pelo resultado do item (a) provado anteriormente, segue que

$$\begin{aligned}
\text{Cov}(\mathbf{A}\mathbf{X} + \mathbf{b}) &= \mathbb{E} \left[(\mathbf{A}\mathbf{X} + \mathbf{b} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b})(\mathbf{A}\mathbf{X} + \mathbf{b} - \mathbf{A}\boldsymbol{\mu} - \mathbf{b})^\top \right] \\
&= \mathbb{E} \left[(\mathbf{A}\mathbf{X} - \mathbf{A}\boldsymbol{\mu})(\mathbf{A}\mathbf{X} - \mathbf{A}\boldsymbol{\mu})^\top \right] \\
&= \text{Cov}(\mathbf{A}\mathbf{X}) \\
&= \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top,
\end{aligned}$$

em que a última desigualdade segue da propriedade (d) provada anteriormente.

Exemplo 3.15

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.7.

- (a) Use as propriedades do Resultado 3.3 para determinar $\text{Var}(\mathbf{1}^\top \mathbf{X})$, em que $\mathbf{1} \in \mathbb{R}^4$ é o vetor de uns.
- (b) Sua resposta para o item (a) é consistente com o esperado da variável aleatória $\mathbf{1}^\top \mathbf{X}$ pela teoria de distribuições?
- (c) Use as propriedades do Resultado 3.3 para determinar $\text{Var}(\mathbf{a}^\top \mathbf{X} + 5)$, em que $\mathbf{a}^\top = [1 \ 2 \ 3 \ 4]$.

Exemplo 3.15SOLUÇÃO:

(a) Como $X_1, \dots, X_4$ são variáveis aleatórias independentes, temos

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = 0,$$

para todo $i, k = 1, 2, 3, 4$ com $i \neq k$. Essas variáveis possuem distribuição Bernoulli com parâmetro θ , $0 < \theta < 1$, então

$$\sigma_{kk} = \text{Var}(X_k) = \theta(1 - \theta),$$

para todo $k = 1, 2, 3, 4$. Logo, a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$ é

$$\text{Cov}(\mathbf{X}) = \begin{bmatrix} \theta(1 - \theta) & 0 & 0 & 0 \\ 0 & \theta(1 - \theta) & 0 & 0 \\ 0 & 0 & \theta(1 - \theta) & 0 \\ 0 & 0 & 0 & \theta(1 - \theta) \end{bmatrix} = \theta(1 - \theta)\mathbf{I}_4,$$

em que $\mathbf{I}_4$ denota a matriz identidade de ordem 4×4 . Pelo item (c) do Resultado 3.3, temos

$$\begin{aligned} \text{Var}(\mathbf{1}^\top \mathbf{X}) &= \mathbf{1}^\top \text{Cov}(\mathbf{X}) \mathbf{1} \\ &= \begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix} \theta(1 - \theta) \mathbf{I}_4 \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \\ &= \theta(1 - \theta) \begin{bmatrix} 1 & 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} \\ &= 4\theta(1 - \theta). \end{aligned}$$

$$\boxed{\therefore \text{Var}(\mathbf{1}^\top \mathbf{X}) = 4\theta(1 - \theta).}$$

(b) A variável aleatória $\mathbf{1}^\top \mathbf{X} = X_1 + \dots + X_4$ é uma soma de variáveis aleatórias independentes com a mesma distribuição Bernoulli com parâmetro θ , $0 < \theta < 1$.

Exemplo 3.15

Logo, $\mathbf{1}^\top \mathbf{X} = X_1 + \cdots + X_4 \sim \text{Binomial}(n = 4, \theta)$. Da teoria de distribuições, sabemos que para uma variável aleatória $Y \sim \text{Binomial}(n, \theta)$, temos $\text{Var}(Y) = n\theta(1 - \theta)$. Portanto, $\text{Var}(\mathbf{a}^\top \mathbf{X}) = n\theta(1 - \theta)$ que, como esperado e desejado, é consistente com o resultado que obtivemos no item (a).

- (c) Usando a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$ obtida no item (a), segue, pelo item (c) do Resultado 3.3, que

$$\begin{aligned} \text{Var}(\mathbf{a}^\top \mathbf{X}) &= \mathbf{a}^\top \text{Cov}(\mathbf{X}) \mathbf{a} \\ &= \begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix} \theta(1 - \theta) \mathbf{I}_4 \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \\ &= \theta(1 - \theta) \begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \end{bmatrix} \\ &= 30\theta(1 - \theta) \end{aligned}$$

$$\therefore \text{Var}(\mathbf{a}^\top \mathbf{X}) = 30\theta(1 - \theta).$$

Exemplo 3.16

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.8.

- (a) Use as propriedades do Resultado 3.3 para determinar a matriz de variâncias e covariâncias $\text{Cov}(\mathbf{A}\mathbf{X})$.
- (b) Qual é a distribuição do vetor aleatório $\mathbf{A}\mathbf{X}$?

SOLUÇÃO:

- (a) Como X_1, X_2 e X_3 são variáveis aleatórias independentes, temos

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = 0,$$

Exemplo 3.16

para todo $i, k = 1, 2, 3$ com $i \neq k$. Para cada $k = 1, 2, 3$, $X_k \sim \text{Normal}(k, k^2)$, então

$$\sigma_{kk} = \text{Var}(X_k) = k^2.$$

Logo, a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$ é

$$\text{Cov}(\mathbf{X}) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 9 \end{bmatrix}.$$

Pelo item (d) do Resultado 3.3, temos

$$\begin{aligned} \text{Cov}(\mathbf{AX}) &= \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top \\ &= \begin{bmatrix} 1 & -1 & 0 \\ 2 & 4 & -3 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 4 & 0 \\ 0 & 0 & 9 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ -1 & 4 \\ 0 & -3 \end{bmatrix} \\ &= \begin{bmatrix} 1 & -4 & 0 \\ 2 & 16 & -27 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ -1 & 4 \\ 0 & -3 \end{bmatrix} \\ &= \begin{bmatrix} 5 & -14 \\ -14 & 149 \end{bmatrix}. \end{aligned}$$

$$\therefore \text{Cov}(\mathbf{AX}) = \begin{bmatrix} 5 & -14 \\ -14 & 149 \end{bmatrix}.$$

(b) Como

$$\mathbf{AX} = \begin{bmatrix} 1 & -1 & 0 \\ 2 & 4 & -3 \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} = \begin{bmatrix} X_1 - X_2 \\ 2X_1 + 4X_2 - 3X_3 \end{bmatrix}$$

e as variáveis X_1 , X_2 e X_3 são normalmente distribuídas e independentes, segue que cada entrada do vetor aleatório é uma variável aleatória normalmente distribuída. Como veremos no próximo capítulo, essa característica faz com que o vetor aleatório $\mathbf{AX}$ tenha distribuição normal bivariada com vetor de médias $\mathbb{E}(\mathbf{AX}) = \begin{bmatrix} -1 \\ 1 \end{bmatrix}$ (ver Exemplo 3.8) e com matriz de variâncias e covariâncias $\text{Cov}(\mathbf{AX})$, como encontrada no item (a).

Exemplo 3.17: Esperança de uma forma quadrática

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ com vetor de médias populacionais $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$. Mostre que

$$\mathbb{E}(\mathbf{X}^\top \mathbf{A} \mathbf{X}) = \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu},$$

em que $\mathbf{A} \in M_{p \times p}(\mathbb{R})$ é uma matriz de constantes.

SOLUÇÃO:

Note que $\mathbf{X}^\top \mathbf{A} \mathbf{X}$ é uma forma quadrática em $\mathbf{X}$. Logo, possui dimensão 1×1 , sendo, portanto, uma variável aleatória. Nesse sentido, temos

$$\mathbf{X}^\top \mathbf{A} \mathbf{X} = \text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X}),$$

já que o traço de um escalar é o próprio escalar. Logo,

$$\begin{aligned} \mathbb{E}(\mathbf{X}^\top \mathbf{A} \mathbf{X}) &= \mathbb{E}[\text{tr}(\mathbf{X}^\top \mathbf{A} \mathbf{X})] \\ &\stackrel{(i)}{=} \mathbb{E}[\text{tr}(\mathbf{X} \mathbf{X}^\top \mathbf{A})] \\ &\stackrel{(i)}{=} \mathbb{E}[\text{tr}(\mathbf{A} \mathbf{X} \mathbf{X}^\top)] \\ &\stackrel{(ii)}{=} \text{tr}[\mathbb{E}(\mathbf{A} \mathbf{X} \mathbf{X}^\top)] \\ &\stackrel{(e)}{=} \text{tr}[\mathbf{A} \mathbb{E}(\mathbf{X} \mathbf{X}^\top)] \\ &\stackrel{(iii)}{=} \text{tr}\left\{\mathbf{A} [\text{Cov}(\mathbf{X}) + \mathbb{E}(\mathbf{X})\mathbb{E}(\mathbf{X})^\top]\right\} \\ &= \text{tr}[\mathbf{A} (\boldsymbol{\Sigma} + \boldsymbol{\mu} \boldsymbol{\mu}^\top)] \\ &= \text{tr}(\mathbf{A} \boldsymbol{\Sigma} + \mathbf{A} \boldsymbol{\mu} \boldsymbol{\mu}^\top) \\ &\stackrel{(iv)}{=} \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \text{tr}(\mathbf{A} \boldsymbol{\mu} \boldsymbol{\mu}^\top) \\ &\stackrel{(i)}{=} \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \text{tr}(\boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}) \\ &\stackrel{(vi)}{=} \text{tr}(\mathbf{A} \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}, \end{aligned}$$

em que (i) deve-se ao fato de que $\text{tr}(\mathbf{BCD}) = \text{tr}(\mathbf{DCB})$ quaisquer que sejam as matrizes $\mathbf{B}$, $\mathbf{C}$ e $\mathbf{D}$ em que o produto esteja bem definido; (ii) segue das definições de traço e valor esperado de uma matriz aleatória; (iii) segue do Exemplo 3.11; (iv) deve-se ao fato de que o traço da soma é a soma dos traços; (vi) deve-se ao fato de $\boldsymbol{\mu}^\top \mathbf{A} \boldsymbol{\mu}$ ser um número e o traço de um escalar, como já discutimos, é o próprio escalar; e (e) deve-se ao item (e) do Resultado 3.1.

Exemplo 3.18

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$ cujas componentes são variáveis aleatórias independentes com distribuição normal padrão.

- (a) Use o Exemplo 3.17, para encontrar $\mathbb{E}(\mathbf{X}^\top \mathbf{X})$.
- (b) Qual é a distribuição da forma quadrática $\mathbf{X}^\top \mathbf{X}$? Sua resposta para o item (a) é consistente com o esperado da variável aleatória $\mathbf{X}^\top \mathbf{X}$ pela teoria de distribuições?

SOLUÇÃO:

- (a) Como X_1, X_2 e X_3 são variáveis aleatórias independentes, temos

$$\sigma_{ik} = \text{Cov}(X_i, X_k) = 0.$$

para todo $i, k = 1, 2, 3$ com $i \neq k$. Todas as três variáveis possuem distribuição normal padrão, então $\mu_k = \mathbb{E}(X_k) = 0$ e

$$\sigma_{kk} = \text{Var}(X_k) = 1,$$

para todo $k = 1, 2, 3$. Logo, o vetor de médias $\boldsymbol{\mu}$ e a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ do vetor aleatório $\mathbf{X}$ são, respectivamente,

$$\boldsymbol{\mu} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} = \mathbf{0}_3 \quad \text{e} \quad \boldsymbol{\Sigma} = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \mathbf{I}_3,$$

em que $\mathbf{0}_3$ é o vetor nulo de $\mathbb{R}^3$ e $\mathbf{I}_3$ é a matriz identidade de ordem 3×3 . Pelo Exemplo 3.17,

$$\begin{aligned} \mathbb{E}(\mathbf{X}^\top \mathbf{X}) &= \mathbb{E}(\mathbf{X}^\top \mathbf{I}_3 \mathbf{X}) \\ &= \text{tr}(\mathbf{I}_3 \boldsymbol{\Sigma}) + \boldsymbol{\mu}^\top \mathbf{I}_3 \boldsymbol{\mu} \\ &= \text{tr}(\boldsymbol{\Sigma}) + \mathbf{0}^\top \mathbf{0} \\ &= 3. \end{aligned}$$

$$\boxed{\therefore \mathbb{E}(\mathbf{X}^\top \mathbf{X}) = 3.}$$

- (b) Note que a forma quadrática $\mathbf{X}^\top \mathbf{X} = X_1^2 + X_2^2 + X_3^2$ é uma soma de quadrados

Exemplo 3.18

de variáveis aleatórias independentes com distribuição normal padrão. Logo, $\mathbf{X}^\top \mathbf{X} = X_1^2 + X_2^2 + X_3^2 \sim \chi_3^2$. Da teoria de distribuições, sabemos que para uma variável aleatória $Y \sim \chi_n^2$, temos $\mathbb{E}(Y) = n$. Portanto, $\mathbb{E}(\mathbf{X}^\top \mathbf{X}) = 3$ que, como esperado e desejado, é consistente com o resultado que obtivemos no item (a).

Quando temos uma única variável, a variância costuma ser usada para medir o quanto esperamos que os dados variem em torno da média. No entanto, quando p variáveis são observadas simultaneamente em uma mesma unidade amostral (ou seja, em um contexto multivariado), usamos a matriz de variâncias e covariâncias para descrever essa variação conjunta. Em certas situações, pode ser útil resumir toda essa variação multivariada em um único número. Duas formas comuns de fazer isso envolvem o uso da *variância total populacional* e da *variância generalizada populacional*.

Definição 3.7: Variância total de um vetor aleatório

Seja p um número inteiro positivo. A *variância total* de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, com matriz de variâncias e covariâncias $\Sigma \in M_{p \times p}(\mathbb{R})$, é a soma dos elementos da diagonal principal de Σ , i.e., o traço de Σ :

$$\text{tr}(\Sigma) = \sigma_{11} + \sigma_{22} + \cdots + \sigma_{pp}.$$

Essa medida de variabilidade também é conhecida como *variância total populacional*.

Vale observar que a variância total populacional não leva em conta a estrutura de correlação linear entre as variáveis – ela considera apenas as variações individuais de cada uma. Apesar dessa limitação, a variância total pode ser bastante útil em contextos nos quais desejamos obter uma medida geral da variabilidade do conjunto de variáveis, sem nos preocuparmos com as inter-relações entre elas. Por exemplo, ao comparar dois grupos de indivíduos em termos de variáveis como altura, peso e pressão arterial, a variância total pode fornecer um resumo simples e informativo da variabilidade conjunta de cada grupo. Assim, ela é uma ferramenta prática quando o objetivo é apenas quantificar o “tamanho” da variabilidade total, e não entender como as variáveis se relacionam entre si.

Exemplo 3.19

Considere dois grupos de pacientes avaliados em relação a duas variáveis: pressão sistólica (X_1 , em $mmHg$) e índice de massa corporal (X_2 , em kg/m^2). Suponha que as matrizes de variâncias e covariâncias populacionais para cada grupo sejam

$$\Sigma_1 = \begin{bmatrix} 100 & 10 \\ 10 & 25 \end{bmatrix} \quad \text{e} \quad \Sigma_2 = \begin{bmatrix} 120 & 5 \\ 5 & 30 \end{bmatrix}.$$

- (a) Determine a variância total populacional de cada grupo.
- (b) Qual grupo apresenta maior variabilidade total nas variáveis analisadas?

SOLUÇÃO:

- (a) A variância total populacional de cada grupo é dada pelo traço da matriz de variâncias e covariâncias, ou seja, pela soma das variâncias individuais:

$$tr(\Sigma_1) = 100 + 25 = 125 \quad \text{e} \quad tr(\Sigma_2) = 120 + 30 = 150.$$

- (b) Como $tr(\Sigma_2) > tr(\Sigma_1)$, o grupo 2 apresenta maior variabilidade total nas variáveis analisadas.

Exemplo 3.20

Considere dois grupos em que avaliamos duas variáveis: renda anual (X_1 , em milhares de reais) e satisfação com a qualidade de vida (X_2 , em uma escala de 1 a 10). Suponha que as matrizes de variâncias e covariâncias populacionais para os dois grupos sejam

$$\Sigma_1 = \begin{bmatrix} 400 & 12 \\ 12 & 4 \end{bmatrix} \quad \text{e} \quad \Sigma_2 = \begin{bmatrix} 1600 & 24 \\ 24 & 4 \end{bmatrix}.$$

- (a) Determine a variância total populacional de cada grupo.
- (b) Com base nos valores obtidos, qual grupo apresenta maior variabilidade total nas variáveis analisadas?
- (c) Há alguma variável que domina a variância total? Comente o impacto disso na interpretação dos resultados.

Exemplo 3.20**SOLUÇÃO:**

- (a) A variância total populacional de cada grupo é dada pelo traço da matriz de variâncias e covariâncias, ou seja, pela soma das variâncias individuais:

$$tr(\Sigma_1) = 400 + 4 = 404 \quad \text{e} \quad tr(\Sigma_2) = 1600 + 4 = 1604.$$

- (b) Como $tr(\Sigma_2) > tr(\Sigma_1)$, o grupo 2 apresenta maior variabilidade total nas variáveis analisadas.
- (c) Observe que a variável X_2 (satisfação) tem a mesma variância nos dois grupos, mas a variável X_1 (renda) apresenta uma escala quatro vezes maior no grupo 2. Isso mostra que a variância total está sendo fortemente influenciada pela escala da renda. Esse domínio de uma variável pode mascarar a contribuição da outra, especialmente quando usamos a variância total para comparar variabilidade entre grupos. A variância total do grupo 2 é muito maior, mas isso ocorre principalmente porque a variável renda está em uma escala muito mais alta. Assim, a variância total é dominada pela variável de maior escala, mesmo que as variações relativas entre os grupos não sejam tão diferentes.

Quando as variáveis estão em escalas muito diferentes, como no exemplo anterior, a variância total populacional pode não representar adequadamente a variabilidade conjunta do sistema. Isso acontece porque essa medida soma as variâncias individuais, sem considerar as unidades de medida, escalas ou as correlações entre as variáveis. Por ser simples de calcular e interpretar, a variância total é útil como uma medida inicial de dispersão. No entanto, ela pode mascarar relações importantes entre os dados. Em situações que exigem uma visão mais completa da variabilidade multivariada, é preferível utilizar medidas alternativas, como a *variância generalizada*, que incorpora toda a estrutura de covariância entre as variáveis.

Definição 3.8: Variância generalizada de um vetor aleatório

Seja p um número inteiro positivo. A *variância generalizada* de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, com matriz de variâncias e covariâncias $\Sigma \in M_{p \times p}(\mathbb{R})$, é o determinante de Σ , i.e., $|\Sigma|$. Essa medida de variabilidade também é conhecida como *variância generalizada populacional*.

Uma interpretação geométrica de $|\Sigma|$ pode nos ajudar a apreciar seus pontos fortes e fracos como um resumo descritivo da variabilidade conjunta do sistema. No entanto, para ganharmos intuição em relação a essa interpretação, vamos considerar a variância generalizada amostral $|\mathbf{S}_n|$, em que $\mathbf{S}_n$, com vimos no Capítulo 2, é a matriz de variâncias e covariâncias amostrais.

Sejam $\mathbf{x}_1 \in \mathbb{R}^n$ um vetor de n observações da variável X_1 e $\mathbf{x}_2 \in \mathbb{R}^n$ um vetor de n observações da variável X_2 . Considere os vetores $\mathbf{d}_1 \in \mathbb{R}^n$ e $\mathbf{d}_2 \in \mathbb{R}^n$ tais que

$$\mathbf{d}_1 := \begin{bmatrix} x_{11} - \bar{x}_1 \\ x_{21} - \bar{x}_1 \\ \vdots \\ x_{n1} - \bar{x}_1 \end{bmatrix} \quad \text{e} \quad \mathbf{d}_2 := \begin{bmatrix} x_{12} - \bar{x}_2 \\ x_{22} - \bar{x}_2 \\ \vdots \\ x_{n2} - \bar{x}_2 \end{bmatrix}.$$

O vetor $\mathbf{d}_1$ é conhecido como *vetor de desvios* da variável X_1 e $\mathbf{d}_2$ é conhecido como *vetor de desvios* da variável X_2 . Da álgebra linear no $\mathbb{R}^n$, sabemos que os tamanhos dos vetores $\mathbf{d}_1$ e $\mathbf{d}_2$ podem ser expressos pelas suas normas Euclidianas, i.e.,

$$\begin{aligned} \|\mathbf{d}_1\| &:= \sqrt{\sum_{j=1}^n d_{j1}^2} = \sqrt{\sum_{j=1}^n (x_{j1} - \bar{x}_1)^2}, \\ \|\mathbf{d}_2\| &:= \sqrt{\sum_{j=1}^n d_{j2}^2} = \sqrt{\sum_{j=1}^n (x_{j2} - \bar{x}_2)^2}. \end{aligned}$$

Nesse sentido, a geometria analítica, nos permite construir o diagrama da Figura 3.5.




Figura 3.5. Paralelogramo formado a partir do ângulo entre os vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$.

Note que a área do paralelogramo é dada por

$$\begin{aligned} \text{área} &= \|\mathbf{d}_2\| h \\ &= \|\mathbf{d}_2\| \|\mathbf{d}_1\| \sin(\theta) \\ &= \|\mathbf{d}_1\| \|\mathbf{d}_2\| \sqrt{1 - \cos^2(\theta)}, \end{aligned}$$

em que a última igualdade deve-se à identidade trigonométrica $\sin^2(\theta) + \cos^2(\theta) = 1$.

A correlação amostral entre X_1 e X_2 pode ser escrita da seguinte maneira

$$\begin{aligned}
 r_{12} &:= \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}} \\
 &= \frac{\sum_{j=1}^n (x_{j1} - \bar{x}_1)(x_{j2} - \bar{x}_2)}{\sqrt{\sum_{j=1}^n (x_{j1} - \bar{x}_1)^2} \sqrt{\sum_{j=1}^n (x_{j2} - \bar{x}_2)^2}} \\
 &= \frac{\sum_{j=1}^n d_{j1}d_{j2}}{\sqrt{\sum_{j=1}^n d_{j1}^2} \sqrt{\sum_{j=1}^n d_{j2}^2}} \\
 &\stackrel{(i)}{=} \frac{\mathbf{d}_1^\top \mathbf{d}_2}{\|\mathbf{d}_1\|^2 \|\mathbf{d}_2\|^2} \\
 &\stackrel{(ii)}{=} \frac{\langle \mathbf{d}_1, \mathbf{d}_2 \rangle}{\|\mathbf{d}_1\|^2 \|\mathbf{d}_2\|^2} \\
 &\stackrel{(iii)}{=} \cos(\theta),
 \end{aligned}$$

em que (i) segue da definição dos tamanhos dos vetores de desvios, (ii) segue da definição do produto interno induzido pela norma Euclidiana e (iii) da definição do cosseno do ângulo entre dois vetores. Dessa forma, podemos reescrever a covariância amostral em termos do produto interno dos desvios e as variâncias amostrais em termos das normas dos desvios (ver Exercício 4 da Lista 1). Com efeito,

$$\begin{aligned}
 s_{12} &:= \frac{1}{n} \sum_{j=1}^n (x_{j1} - \bar{x}_1)(x_{j2} - \bar{x}_2) = \frac{1}{n} \sum_{j=1}^n d_{j1}d_{j2} = \frac{1}{n} \mathbf{d}_1^\top \mathbf{d}_2 = \frac{1}{n} \langle \mathbf{d}_1, \mathbf{d}_2 \rangle, \\
 s_{11} &:= \frac{1}{n} \sum_{j=1}^n (x_{j1} - \bar{x}_1)^2 = \frac{1}{n} \sum_{j=1}^n d_{j1}^2 = \frac{1}{n} \|\mathbf{d}_1\|^2, \\
 s_{22} &:= \frac{1}{n} \sum_{j=1}^n (x_{j2} - \bar{x}_2)^2 = \frac{1}{n} \sum_{j=1}^n d_{j2}^2 = \frac{1}{n} \|\mathbf{d}_2\|^2.
 \end{aligned}$$

Portanto,

$$\text{área} = \sqrt{ns_{11}}\sqrt{ns_{22}}\sqrt{1 - r_{12}^2} = n\sqrt{s_{11}s_{22}(1 - r_{12}^2)}. \quad (3.1)$$

Por outro lado, o determinante $|\mathbf{S}_n|$ da matriz de variâncias e covariâncias pode ser escrito da seguinte maneira

$$\begin{aligned}
 |\mathbf{S}_n| &= \begin{vmatrix} s_{11} & s_{12} \\ s_{21} & s_{22} \end{vmatrix} \\
 &= s_{11}s_{22} - s_{12}s_{21} \\
 &= s_{11}s_{22} - s_{12}^2
 \end{aligned}$$

$$\begin{aligned}
&= s_{11}s_{22} - s_{11}s_{22} \frac{s_{12}^2}{s_{11}s_{22}} \\
&= s_{11}s_{22} - s_{11}s_{22}r_{12}^2 \\
&= s_{11}s_{22}(1 - r_{12}^2).
\end{aligned} \tag{3.2}$$

Da igualdade (3.1) com a igualdade (3.2), concluímos que a variância generalizada $|\mathbf{S}_n|$ pode ser escrita como

$$|\mathbf{S}_n| = \frac{\text{área}^2}{n^2}.$$

Essa interpretação geométrica pode ser generalizada para espaços maiores que levam em consideração p variáveis e, conseqüentemente, p vetores de desvios (ver p. 63 de Johnson e Wichern, 2014). Nesse caso,

$$|\mathbf{S}_n| = \frac{\text{volume}^2}{n^{-(p+1)}}.$$




Figura 3.6. (a) Variância generalizada amostral “grande” para $p = 3$ e (b) Variância generalizada “pequena” para $p = 3$.

Para um tamanho de amostra fixo, fica claro pela geometria que o volume, ou $|\mathbf{S}_n|$, aumentará quando o comprimento de qualquer vetor de desvios $\mathbf{d}_i$ (ou, equivalentemente, variância amostral $\sqrt{s_{ii}}$) for aumentado(a). Além disso, o volume aumentará se os vetores de desvio de comprimento fixo forem movidos até que fiquem ortogonais entre si, como na Figura 3.6 (a). Por outro lado, o volume, ou $|\mathbf{S}_n|$, será pequeno se apenas um dos vetores de desvios $\mathbf{d}_i$ (ou, equivalentemente, variância amostral s_{ii}) for pequeno(a) ou se um dos vetores de desvios estiver quase contido no hiperplano formado pelos outros vetores – ou ambos. Essa é a situação mostrada na Figura 3.6 (b), em que $\mathbf{d}_3$ está quase contido no plano formado por $\mathbf{d}_1$ e $\mathbf{d}_2$.

A variância generalizada é uma medida de variabilidade que considera não só a dispersão individual de cada variável, mas também sua independência (ou falta de correlação) em relação às outras, penalizando a redundância entre variáveis, i.e., quanto mais correlacionadas as variáveis, menor será a variância generalizada. Portanto, ela é especialmente útil para detectar se a variabilidade está de fato “espalhada” em várias direções do espaço multivariado, ou se está concentrada em um subespaço de menor dimensão.

No caso da variância generalizada populacional $|\Sigma|$, as interpretações seguem análogas ao caso amostral.

Exemplo 3.21

Uma escola está avaliando o desempenho dos alunos em duas provas muito parecidas. Ambas medem habilidades similares e foram aplicadas na mesma semana. Após a aplicação, foi calculada a seguinte matriz de variâncias e covariâncias populacional

$$\Sigma = \begin{bmatrix} 9 & 8,9 \\ 8,9 & 9 \end{bmatrix}.$$

- (a) Determine a variância total populacional.
- (b) Determine a variância generalizada populacional.
- (c) Compare os valores obtidos nos itens (a) e (b). O que essa comparação revela sobre as desvantagens do uso da variância total como uma medida para resumir a variabilidade conjunta do sistema e sobre como a variância generalizada supera tais desvantagens?

SOLUÇÃO:

- (a) A variância total populacional é dada pelo traço da matriz de variâncias e covariâncias Σ , ou seja, pela soma das variâncias individuais:

$$tr(\Sigma) = s_{11} + s_{22} = 9 + 9 = 18.$$

- (b) A variância generalizada populacional é dada pelo determinante da matriz de variâncias e covariâncias Σ , ou seja,

$$|\Sigma| = \begin{vmatrix} 9 & 8,9 \\ 8,9 & 9 \end{vmatrix} = (9 \times 9) - (8,9 \times 8,9) = 81 - 79,21 = 1,79.$$

Exemplo 3.21

- (c) A variância total populacional é maior do que a variância generalizada populacional ($tr(\Sigma) = 18 > 1,79 = |\Sigma|$). A variância total sugere que há bastante variação nas notas, mas não diz se essa variação é realmente diversa. A variância generalizada mostra que, apesar disso, as duas variáveis praticamente carregam a mesma informação. De fato, $r_{12} = \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}} = \frac{8,9}{9} \approx 0,99$, correlação quase 1. Os alunos que foram bem na primeira prova também foram bem na segunda prova, quase perfeitamente.

Exemplo 3.22: (Johnson e Wichern, 2014, p. 64, tradução e grifo nosso)

Considere uma população finita particionada em três grupos, nos quais um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^2$ foi observado. Os gráficos de dispersão em cada um dos grupos foram construídos na Figura 3.7.




Figura 3.7. Gráficos de dispersão com três diferentes orientações.

Em todos os grupos o vetor de médias populacionais é $\mu = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$ e as matrizes de variâncias e covariâncias populacionais são

Exemplo 3.22

$$\Sigma_1 = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \quad \text{e} \quad \Sigma_3 = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}.$$

- (a) Determine a correlação populacional r_{12} entre as variáveis X_1 e X_2 em cada uma das subpopulações.
- (b) Determine a variância generalizada populacional em cada uma das subpopulações.
- (c) Compare os valores obtidos nos itens (a) e (b). O que essa comparação revela sobre as desvantagens do uso da variância generalizada como uma medida para resumir a variabilidade conjunta do sistema?

SOLUÇÃO:

- (a) A correlação populacional r_{12} entre as variáveis X_1 e X_2 é definida como

$$r_{12} := \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}}.$$

Assim, usando a matriz de variâncias e covariâncias populacionais de cada um dos grupos, temos

- **Grupo 1:** $r_{12} = \frac{4}{5} = 0,8$.
- **Grupo 2:** $r_{12} = 0$.
- **Grupo 3:** $r_{12} = -\frac{4}{5} = -0,8$.

- (b) A variância generalizada populacional é o determinante da matriz de variâncias e covariâncias populacionais. Logo, para cada grupo, temos

- **Grupo 1:** $|\Sigma| = (5 \times 5) - (4 \times 4) = 25 - 16 = 9$.
- **Grupo 2:** $|\Sigma| = (3 \times 3) - (0 \times 0) = 9 - 0 = 9$.
- **Grupo 3:** $|\Sigma| = (5 \times 5) - [(-4) \times (-4)] = 25 - 16 = 9$.

- (c) Aqui a variância generalizada $|\Sigma|$ fornece o mesmo valor, $|\Sigma|$ para todos os três padrões. No entanto, a variância generalizada não contém nenhuma informação sobre a orientação dos padrões. A variância generalizada é mais fácil de interpretar quando as duas (ou mais) populações (ou padrões) que estão sendo comparadas possuem orientações aproximadamente iguais.

Exemplo 3.23

Imagine duas variáveis X_1 e X_2 , em que todas as observações obedecem exatamente $X_2 = 2X_1$.

- (a) Se desejássemos contruir um gráfico de dispersão, os pontos observacionais estariam espalhados pelo plano $\mathbb{R}^2$ ou haveria um padrão evidente? Comente.
- (b) Determine a variância generalizada populacional.
- (c) O valor obtido no item (b) é compatível com sua resposta no item (a)? Por quê?

SOLUÇÃO:

- (a) Nesse caso, os pontos estariam todos dispostos sobre a reta $y = 2x$ (construa esse gráfico por si só).
- (b) A variância generalizada populacional é o determinante da matriz de variâncias e covariâncias populacionais. Logo, precisamos, primeiramente, determinar a matriz de variâncias e covariâncias populacionais Σ . Como $X_2 = 2X_1$, temos.

$$\sigma_{22} = \text{Var}(X_2) = \text{Var}(2X_1) = 4\text{Var}(X_1) = 4\sigma_{11}.$$

As variáveis X_1 e X_2 possuem uma relação linear perfeita e, dessa forma, $r_{12} = 1$. Logo,

$$r_{12} = 1 \Rightarrow \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} = 1 \Rightarrow \sigma_{12} = \sqrt{\sigma_{11}}\sqrt{4\sigma_{11}} = 2\sigma_{11}.$$

Portanto

$$\Sigma = \begin{bmatrix} \sigma_{11} & 2\sigma_{11} \\ 2\sigma_{11} & 4\sigma_{11} \end{bmatrix},$$

e, conseqüentemente,

$$|\Sigma| = 4\sigma_{11}^2 - 4\sigma_{11}^2 = 0.$$

- (c) Como $|\Sigma| = 0$, o paralelogramo formado pelos vetores de desvio $\mathbf{d}_1$ e $\mathbf{d}_2$, associados respectivamente às variáveis X_1 e X_2 , tem área igual a zero. Isso só é possível quando o ângulo entre os vetores é 0° ou 180° , ou seja, quando estão perfeitamente alinhados. Nesses casos, o cosseno do ângulo – que corresponde à correlação entre as variáveis – é igual a 1 ou -1 . Em outras palavras, X_1 e X_2 apresentam uma relação linear perfeita, exatamente como no item (a), onde foi dado que $X_2 = 2X_1$.

A variância generalizada será zero em certas situações. Uma variância generalizada igual a zero é indicativo de uma degeneração extrema. Em Estatística Multivariada (e em Álgebra Linear), degeneração refere-se a situações em que os dados perdem dimensionalidade efetiva, ou seja, parecem viver em um espaço de dimensão menor do que o esperado. Portanto, quando dizemos que há uma degeneração extrema e que a variância generalizada é zero, isso quer dizer que os vetores de desvios (ou seja, os vetores que representam as diferenças entre as observações e a média) estão todos alinhados em um subespaço de dimensão menor. Na prática, em vez de se espalharem em várias direções no espaço (ex: plano ou espaço tridimensional), todos os vetores ficam contidos, por exemplo, numa linha reta ou num plano. Isso implica que uma ou mais variáveis são combinações lineares das outras, ou seja, há colinearidade perfeita.

A variância generalizada é excessivamente afetada pela variabilidade das medições em uma única variável. Por exemplo, suponha que algum seja muito grande ou muito pequeno. Então, geometricamente, o vetor de desvios correspondente será muito longo ou muito curto e, portanto, será claramente um fator importante na determinação do volume. Consequentemente, às vezes é útil padronizar todos os vetores de desvio para que tenham o mesmo comprimento. Isso nos levará à matriz de correlações populacionais e, consequentemente, à variância generalizada das variáveis padronizadas.

Tabela 3.1. Comparação entre variância total e variância generalizada como medidas de variabilidade conjunta.

Aspecto	Variância Total	Variância Generalizada
Definição curta	Traço da matriz de variâncias e covariâncias	Determinante da matriz de variâncias e covariâncias
Desvantagens	Sensível à escala; não considera relações entre variáveis	Sensível à escala; pode ser zero com variâncias marginais positivas; não capta a orientação (sinal das associações)
Utilidade	Comparar variabilidade marginal média entre grupos	Comparar variabilidade conjunta total entre grupos
Interpretação	Soma das variâncias individuais; mede a variabilidade total marginal	Volume do paralelepípedo (ou paralelogramo em $\mathbb{R}^2$) formado pelos vetores de desvio
Situação ideal de uso	Quando se deseja comparar a variabilidade individual entre variáveis em mesma escala e com fracas associações	Quando se deseja comparar grupos em termos da variabilidade conjunta, levando em conta dependências entre variáveis e assumindo orientação consistente dos desvios

3.4 Matriz de correlações de um vetor aleatório

Ao estudar vetores aleatórios em $\mathbb{R}^p$, a matriz de covariância é amplamente usada para analisar a variabilidade e as relações lineares entre as variáveis, porém ela possui limitações significativas, como sua sensibilidade às unidades de medida, o que dificulta comparações, e o fato de apenas indicar a orientação da relação linear sem medir sua força real. Para contornar esses problemas, utilizamos a matriz de correlação, que padroniza as covariâncias ao dividi-las pelo produto dos desvios padrão das variáveis, resultando em valores adimensionais entre -1 e 1 . Essa padronização elimina o efeito das escalas, permitindo comparações justas entre variáveis de diferentes grandezas, além de fornecer uma interpretação direta da intensidade da relação linear por meio do valor absoluto dos coeficientes.

Definição 3.9: Matriz de correlações de um vetor aleatório

Sejam p um número inteiro positivo e $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$, com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$. A *matriz de correlações* de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, denotada por $Cor(\mathbf{X})$, é uma matriz $\mathbf{P} \in M_{p \times p}(\mathbb{R})$ tal que

$$\mathbf{P} := Cor(\mathbf{X}) = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{pmatrix},$$

em que

$$\rho_{ij} = \frac{\sigma_{ij}}{\sqrt{\sigma_{ii}\sigma_{jj}}} = \frac{Cov(X_i, X_j)}{\sqrt{Var(X_i)Var(X_j)}}.$$

Trata-se de uma matriz simétrica com diagonal principal composta por uns e entradas que medem a força linear entre pares de variáveis do vetor aleatório $\mathbf{X}$. Como vimos no Capítulo 2, $\mathbf{P}$ é a *matriz de correlações populacionais*.

Exemplo 3.24

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.1, cuja matriz de variâncias e covariâncias (ver Exemplo 3.12) é

Exemplo 3.24

$$\Sigma = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 6/25 & -3/50 \\ -3/50 & 6/25 \end{bmatrix}.$$

Determine a matriz de correlações do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

Como a correlação ρ_{12} entre as variáveis X_1 e X_2 é

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} = \frac{-3/50}{6/25} = -\frac{1}{4}.$$

Portanto, a matriz de correlações do vetor aleatório $\mathbf{X}$ é a matriz $\mathbf{P} \in M_{2 \times 2}(\mathbb{R})$ tal que

$$\mathbf{P} = \begin{bmatrix} 1 & -1/4 \\ -1/4 & 1 \end{bmatrix}.$$

Exemplo 3.25

Considere o vetor aleatório $\mathbf{X}$ introduzido no Exemplo 3.2, cuja matriz de variâncias e covariâncias (ver Exemplo 3.13) é

$$\Sigma = \text{Cov}(\mathbf{X}) = \begin{bmatrix} 1/6 & 0 \\ 0 & 1/6 \end{bmatrix}.$$

Determine a matriz de correlações do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

Como a correlação ρ_{12} entre as variáveis X_1 e X_2 é

$$\rho_{12} = \frac{\sigma_{12}}{\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}} = \frac{0}{1/6} = 0.$$

Portanto, a matriz de correlações do vetor aleatório $\mathbf{X}$ é a matriz $\mathbf{P} \in M_{2 \times 2}(\mathbb{R})$ tal que

$$\mathbf{P} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} := \mathbf{I}_2.$$

Exemplo 3.26

Seja $\mathbf{X} = [X_1 \ X_2 \ X_3]^\top$ com $X_k \sim \text{Normal}(0, 1)$ e independentes, o vetor aleatório introduzido no Exemplo 3.3, cuja matriz de variâncias e covariâncias (ver Exemplo 3.14) é $\Sigma = \text{Cov}(\mathbf{X}) = \mathbf{I}_3$. Determine a matriz de correlações do vetor aleatório $\mathbf{X}$.

SOLUÇÃO:

Como as variáveis aleatórias X_1, X_2 e X_3 são independentes, temos $\rho_{12} = \rho_{13} = \rho_{23} = 0$. Portanto, a matriz de correlações do vetor aleatório $\mathbf{X}$ é a matriz $\mathbf{P} \in M_{3 \times 3}(\mathbb{R})$ tal que $\mathbf{P} = \mathbf{I}_3$.

O resultado a seguir mostra como podemos obter a matriz de variâncias e covariâncias a partir da matriz de correlações e vice-versa. A expressão dessas relações em termos de operações matriciais permitem que os cálculos sejam implementados de maneira conveniente em um computador.

Resultado 3.4

Sejam p um número inteiro positivo e $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ com matriz de variâncias e covariâncias $\Sigma \in M_{p \times p}(\mathbb{R})$ e matriz de correlações $\mathbf{P} \in M_{p \times p}(\mathbb{R})$. Defina a matriz $\mathbf{V}^{1/2} \in M_{p \times p}(\mathbb{R})$ como sendo a *matriz diagonal dos desvios-padrão*:

$$\mathbf{V}^{1/2} = \begin{bmatrix} \sqrt{\sigma_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{\sigma_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix}.$$

Então, é verdade que

- (a) $\mathbf{V}^{1/2} \mathbf{P} \mathbf{V}^{1/2} = \Sigma$.
- (b) $(\mathbf{V}^{1/2})^{-1} \Sigma (\mathbf{V}^{1/2})^{-1} = \mathbf{P}$.

DEMONSTRAÇÃO:

- (a) Escrevendo na forma matricial

Resultado 3.4

$$\begin{aligned}
\mathbf{V}^{1/2} \mathbf{P} \mathbf{V}^{1/2} &= \begin{bmatrix} \sqrt{\sigma_{11}} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix} \begin{bmatrix} 1 & \cdots & \rho_{1p} \\ \vdots & \ddots & \vdots \\ \rho_{p1} & \cdots & 1 \end{bmatrix} \begin{bmatrix} \sqrt{\sigma_{11}} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix} = \\
&= \begin{bmatrix} \sqrt{\sigma_{11}} & \cdots & \sqrt{\sigma_{11}} \rho_{1p} \\ \vdots & \ddots & \vdots \\ \sqrt{\sigma_{pp}} \rho_{p1} & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix} \begin{bmatrix} \sqrt{\sigma_{11}} & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \sqrt{\sigma_{pp}} \end{bmatrix} = \begin{bmatrix} \sigma_{11} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pp} \end{bmatrix} = \mathbf{\Sigma}.
\end{aligned}$$

(b) Desde que $\sigma_{ii} \neq 0$ para todo $i = 1, 2, \dots, p$, temos $|\mathbf{V}^{1/2}| = \prod_{i=1}^p \sigma_{ii} \neq 0$. Logo, $\mathbf{V}^{1/2}$ é inversível e, portanto, do item (a), segue que

$$\mathbf{V}^{1/2} \mathbf{P} \mathbf{V}^{1/2} = \mathbf{\Sigma} \Rightarrow \mathbf{P} \mathbf{V}^{1/2} = (\mathbf{V}^{1/2})^{-1} \mathbf{\Sigma} \Rightarrow \mathbf{P} = (\mathbf{V}^{1/2})^{-1} \mathbf{\Sigma} (\mathbf{V}^{1/2})^{-1}.$$

■

Embora a variância generalizada nos forneça uma ideia da variabilidade global do sistema, ela é afetada pelo tamanho dos vetores de desvios, equivalentemente, pelas variâncias da variáveis envolvidas. Além disso, é afetada pelas escalas e unidades dessas variáveis. Uma solução para essas limitações é trabalhar com variáveis padronizadas, ou seja, com média zero e variância um. Nesse sentido, se $\mathbf{X}$ é um vetor aleatório em $\mathbb{R}^p$ com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\mathbf{\Sigma} \in M_{p \times p}(\mathbb{R})$, podemos considerar o vetor aleatório padronizado $\mathbf{X}^*$ de modo que

$$X_k^* = \frac{X_k - \mu_k}{\sqrt{\sigma_{kk}}}, \quad k = 1, \dots, p.$$

Assim, observada uma amostra de tamanho n do vetor aleatório $\mathbf{X}$, cujo vetor de médias amostrais é $\bar{\mathbf{x}} \in \mathbb{R}^p$ e a matriz de variâncias e covariâncias amostrais é $\mathbf{S}_n \in M_{p \times p}(\mathbb{R})$, temos as observações do vetor aleatório padronizado $\mathbf{X}^*$ dadas da seguinte maneira

$$x_{jk}^* = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}, \quad k = 1, \dots, p \text{ e } j = 1, \dots, n.$$

Definição 3.10: Variância generalizada das variáveis padronizadas

Sejam p um número inteiro positivo e $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ com matriz de correlações $\mathbf{P} \in M_{p \times p}(\mathbb{R})$. Sendo $\mathbf{X}^*$ o vetor das versões padronizadas do vetor aleatório $\mathbf{X}$ e Σ^* sua matriz de variâncias e covariâncias, então a *variância generalizada das variáveis padronizadas* é definida como o determinante de $\mathbf{P}$, que é igual ao determinante de Σ^* , i.e., $|\mathbf{P}| = |\Sigma^*|$. Na versão amostral, usa-se o determinante da matriz de correlações amostrais $\mathbf{R}$, ou seja, $|\mathbf{R}|$.

O volume gerado pelos vetores de desvios das variáveis padronizadas é ilustrado na Figura 3.8 para os dois conjuntos de vetores de desvios representados na Figura 3.6. Uma comparação dessas figuras revela que a influência que o vetor de desvios $\mathbf{d}_2$ (alta variabilidade de X_2) possui sobre a variância generalizada $|\mathbf{S}_n|$ é muito maior que sua influência sobre $|\mathbf{R}|$.




Figura 3.8. O volume gerado pelos vetores de desvios de mesmos tamanhos das variáveis padronizadas.

Exemplo 3.27

Considere as seguintes matrizes de variâncias e covariâncias:

$$\Sigma_1 = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad \Sigma_2 = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}, \quad \Sigma_3 = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}.$$

Calcule a variância generalizada das variáveis padronizadas em cada caso e interprete os resultados.

Exemplo 3.27**SOLUÇÃO:**

Sejam $\mathbf{P}_1$, $\mathbf{P}_2$ e $\mathbf{P}_3$ as matrizes de correlações amostrais associadas, respectivamente, às matrizes de variâncias e covariâncias Σ_1 , Σ_2 e Σ_3 . Logo,

$$\mathbf{P}_1 = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix}, \quad \mathbf{P}_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \mathbf{P}_3 = \begin{bmatrix} 1 & -0,8 \\ -0,8 & 1 \end{bmatrix}.$$

Portanto, as variâncias generalizadas das variáveis padronizadas, para cada caso, são, respectivamente, $|\mathbf{P}_1| = 0,36$, $|\mathbf{P}_2| = 0$ e $|\mathbf{P}_3| = 0,36$. Note que, embora tenhamos superado o problema das escalas das variáveis e estejamos considerando desvios unitários, a variância generalizada das variáveis padronizadas também é ineficaz em capturar a orientação das relações entre as variáveis envolvidas, isso fica evidente quando comparamos $|\mathbf{P}_1|$ e $|\mathbf{P}_3|$ que levam ao mesmo volume, porém, $\mathbf{P}_1$ sugere uma relação positiva entre as variáveis envolvidas, enquanto $\mathbf{P}_3$ sugere uma orientação negativa (ver Figura 3.7).

3.5 Particionamento de vetores aleatórios

Frequentemente, as características medidas em ensaios individuais se distribuem naturalmente em dois ou mais grupos. Como exemplos, considere medições de variáveis que representam consumo e renda, ou variáveis que representam traços de personalidade e características físicas. Uma abordagem para lidar com essas situações é considerar que as características que definem os grupos distintos sejam subconjuntos da coleção *total* de características. Se a coleção total for representada por um vetor aleatório em $\mathbb{R}^p$, $\mathbf{X}$, os subconjuntos podem ser considerados como componentes de $\mathbf{X}$ e podem ser organizados por meio do particionamento de $\mathbf{X}$.

Exemplo 3.28

Suponha que estamos estudando o desempenho de jogadores em um jogo online competitivo. Podemos dividir as variáveis em dois grupos:

Desempenho no jogo:

- X_1 : número médio de abates por partida;
- X_2 : número médio de mortes por partida;

Exemplo 3.28

- X_3 : número médio de assistências.

Comportamento do jogador:

- X_4 : tempo médio de jogo por semana (horas);
- X_5 : frequência de denúncias recebidas.

Escreva o vetor $\mathbf{X}$ na forma particionada.

SOLUÇÃO:

Nesse caso,

$$\mathbf{X} := \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \\ X_5 \end{bmatrix} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}.$$

Exemplo 3.29

Considere um estudo sobre estilo de vida de estudantes universitários. As variáveis coletadas podem ser agrupadas como:

Hábitos alimentares e físicos:

- X_1 : consumo médio diário de água (litros);
- X_2 : minutos de atividade física por dia.

Bem-estar psicológico:

- X_3 : qualidade do sono (escala de 1 a 10);
- X_4 : níveis de estresse percebido (escala de 1 a 10).

Escreva o vetor $\mathbf{X}$ na forma particionada.

SOLUÇÃO:

Nesse caso,

$$\mathbf{X} := \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \end{bmatrix} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}.$$

De forma geral, podemos particionar as p características contidas no vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$ em, por exemplo, dois grupos de tamanhos q e $p - q$, respectivamente. Podemos escrever

$$\mathbf{X} := \left[\begin{array}{c} X_1 \\ \vdots \\ X_q \\ \hline X_{q+1} \\ \vdots \\ X_p \end{array} \right] = \left\{ \begin{array}{l} \left. \begin{array}{c} X_1 \\ \vdots \\ X_q \end{array} \right\} q \\ \left. \begin{array}{c} X_{q+1} \\ \vdots \\ X_p \end{array} \right\} p - q \end{array} \right\} := \left[\begin{array}{c} \mathbf{X}^{(1)} \\ \hline \mathbf{X}^{(2)} \end{array} \right]$$

Logo, se o vetor aleatório $\mathbf{X}$ possui vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$, podemos particionar o vetor de médias da seguinte maneira

$$\boldsymbol{\mu} = \mathbb{E}(\mathbf{X}) = \left[\begin{array}{c} \mu_1 \\ \vdots \\ \mu_q \\ \hline \mu_{q+1} \\ \vdots \\ \mu_p \end{array} \right] = \left[\begin{array}{c} \boldsymbol{\mu}^{(1)} \\ \hline \boldsymbol{\mu}^{(2)} \end{array} \right],$$

em que $\boldsymbol{\mu}^{(1)} := \mathbb{E}[\mathbf{X}^{(1)}]$ e $\boldsymbol{\mu}^{(2)} := \mathbb{E}[\mathbf{X}^{(2)}]$.

Analogamente, podemos particionar a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ da seguinte maneira

$$\begin{aligned} \boldsymbol{\Sigma} = \mathbb{E}[(\mathbf{X} - \boldsymbol{\mu})(\mathbf{X} - \boldsymbol{\mu})^\top] &= \left[\begin{array}{ccc|ccc} \sigma_{11} & \cdots & \sigma_{1q} & \sigma_{1,q+1} & \cdots & \sigma_{1p} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ \sigma_{q1} & \cdots & \sigma_{qq} & \sigma_{q,q+1} & \cdots & \sigma_{qp} \\ \hline \sigma_{q+1,1} & \cdots & \sigma_{q+1,q} & \sigma_{q+1,q+1} & \cdots & \sigma_{q+1,p} \\ \vdots & \ddots & \vdots & \vdots & \ddots & \vdots \\ \sigma_{p1} & \cdots & \sigma_{pq} & \sigma_{p,q+1} & \cdots & \sigma_{pp} \end{array} \right] \\ &:= \left[\begin{array}{c|c} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \hline \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{array} \right], \end{aligned}$$

em que

$$\begin{aligned}
\Sigma_{11} &:= \mathbb{E} \left[(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})^\top \right] = \text{Cov} \left[\mathbf{X}^{(1)} \right], \\
\Sigma_{12} &:= \mathbb{E} \left[(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})^\top \right] := \text{Cov} \left(\mathbf{X}^{(1)}, \mathbf{X}^{(2)} \right), \\
\Sigma_{21} &:= \mathbb{E} \left[(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})^\top \right] := \text{Cov} \left(\mathbf{X}^{(1)}, \mathbf{X}^{(2)} \right), \\
\Sigma_{22} &:= \mathbb{E} \left[(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})^\top \right] = \text{Cov} \left[\mathbf{X}^{(2)} \right].
\end{aligned}$$

Note que $\Sigma_{12} = \Sigma_{21}^\top$. Essas matrizes não são necessariamente simétricas e nem mesmo quadradas. Introduzimos a notação $\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$, pois ela será conveniente em muitas situações. Essa é uma matriz contendo as covariâncias entre os componentes de $\mathbf{X}^{(1)}$ e os componentes de $\mathbf{X}^{(2)}$.

Resultado 3.5

Sejam p um número inteiro positivo e $\mathbf{X}$ um vetor aleatório de $\mathbb{R}^p$ particionado em dois blocos $\mathbf{X}^{(1)}$ em $\mathbb{R}^q$ e $\mathbf{X}^{(2)}$ em $\mathbb{R}^{p-q}$, em que q é um número inteiro positivo menor do que p . As seguintes afirmações são verdadeiras:

- (a) $\text{Cov}(\mathbf{A}\mathbf{X}^{(1)}, \mathbf{B}\mathbf{X}^{(2)}) = \mathbf{A}\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})\mathbf{B}^\top$, quaisquer que sejam as matrizes $\mathbf{A} \in M_{m \times p}(\mathbb{R})$ e $\mathbf{B} \in M_{n \times p-q}(\mathbb{R})$, em que m e n são números inteiros positivos quaisquer.
- (b) Se $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes, i.e., as variáveis que compõem o vetor $\mathbf{X}^{(1)}$ são independentes dos vetores que compõem o vetor $\mathbf{X}^{(2)}$, então $\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $p \times (p - q)$. A volta nem sempre vale.

DEMONSTRAÇÃO:

(a) Pela definição,

$$\begin{aligned}
\text{Cov}(\mathbf{A}\mathbf{X}^{(1)}, \mathbf{B}\mathbf{X}^{(2)}) &:= \mathbb{E} \left[(\mathbf{A}\mathbf{X}^{(1)} - \mathbf{A}\boldsymbol{\mu}^{(1)})(\mathbf{B}\mathbf{X}^{(2)} - \mathbf{B}\boldsymbol{\mu}^{(2)})^\top \right] \\
&= \mathbb{E} \left[\mathbf{A}(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})^\top \mathbf{B}^\top \right] \\
&= \mathbf{A}\mathbb{E} \left[(\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)})(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})^\top \right] \mathbf{B}^\top \\
&= \mathbf{A}\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})\mathbf{B}^\top.
\end{aligned}$$

$$\boxed{\therefore \text{Cov}(\mathbf{A}\mathbf{X}^{(1)}, \mathbf{B}\mathbf{X}^{(2)}) = \mathbf{A}\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})\mathbf{B}^\top.}$$

Resultado 3.5

(b) Se $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes, então $Cov(X_k, X_i) = 0$ sempre que X_k é uma componente de $\mathbf{X}^{(1)}$ e X_i é uma componente de $\mathbf{X}^{(2)}$, $k = 1, 2, \dots, q$ e $k = q + 1, q + 2, \dots, p$. Logo, todas as entradas da matriz $Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$ é nula e, portanto,

$$Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) = \mathbf{O}.$$

■

Exemplo 3.30

Considere um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^4$ particionado em blocos de tamanho 2, de modo que

$$\mathbf{X}^{(1)} := \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad \text{e} \quad \mathbf{X}^{(2)} := \begin{bmatrix} X_3 \\ X_4 \end{bmatrix},$$

em que X_1 e X_2 são variáveis aleatórias independentes tais que $X_1 \sim \text{Normal}(1, 1)$, $X_2 \sim \text{Normal}(2, 4)$. Sabe-se também que $X_3 = X_1 + 1$ e $X_4 = -X_2$. Determine

$$Cov(\mathbf{1}^\top \mathbf{X}^{(1)}, \mathbf{1}^\top \mathbf{X}^{(2)}),$$

em que $\mathbf{1} \in \mathbb{R}^2$ é o vetor de uns.

SOLUÇÃO:

Primeiramente, vamos determinar a matriz de covariâncias $Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$. Como X_1 e X_2 são variáveis aleatórias independentes, temos X_1 independente de X_4 e X_2 independente de X_3 , uma vez que $X_3 = X_1 + 1$ e $X_4 = -X_2$. Logo, $Cov(X_1, X_4) = 0$ e $Cov(X_2, X_3) = 0$. Como X_1 e X_3 possuem uma relação linear positiva perfeita, temos $Cor(X_1, X_3) = 1$ e, portanto, $Cov(X_1, X_3) = 1$. Por outro lado, X_2 e X_4 possuem uma relação linear negativa perfeita, então $Cor(X_2, X_4) = -1$ e, consequentemente, $Cov(X_2, X_4) = -4$. Logo,

$$Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) = \begin{bmatrix} 1 & 0 \\ 0 & -4 \end{bmatrix}.$$

Portanto, pelo item (a) do Resultado 3.5, segue que

Exemplo 3.30

$$\begin{aligned}
\text{Cov}(\mathbf{1}^\top \mathbf{X}^{(1)}, \mathbf{1}^\top \mathbf{X}^{(2)}) &= \mathbf{1}^\top \text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) \mathbf{1} \\
&= \begin{bmatrix} 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & -4 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\
&= \begin{bmatrix} 1 & -4 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\
&= -3.
\end{aligned}$$

$$\therefore \text{Cov}(\mathbf{1}^\top \mathbf{X}^{(1)}, \mathbf{1}^\top \mathbf{X}^{(2)}) = -3.$$

3.6 Exercícios

1. Considere o vetor aleatório $\mathbf{X}$ em $\mathbb{R}^2$ cuja função densidade de probabilidade conjunta é $f: \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

$$f(\mathbf{x}) = f(x_1, x_2) = \begin{cases} 1, & \text{se } 0 \leq x_1 \leq 1 \text{ e } 0 \leq x_2 \leq 1, \\ 0, & \text{caso contrário.} \end{cases}$$

- Determine a função densidade de probabilidade marginal da variável aleatória X_1 . Qual é a distribuição da variável aleatória X_1 ?
 - Determine a função densidade de probabilidade marginal da variável aleatória X_2 . Qual é a distribuição da variável aleatória X_2 ?
 - Determine o vetor de médias $\boldsymbol{\mu}$ do vetor aleatório $\mathbf{X}$.
 - As variáveis aleatórias X_1 e X_2 são independentes? Por quê?
 - Determine a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ do vetor aleatório $\mathbf{X}$.
 - Determine a matriz de correlações $\mathbf{P}$ do vetor aleatório $\mathbf{X}$.
2. Dois tetraedros regulares (isto é, dados de quatro faces) são lançados simultaneamente. Cada face é numerada de 1 a 4, e todos os resultados são igualmente prováveis. Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^2$ tal que X_1 é o número mostrado no primeiro dado, e X_2 é o máximo entre os números mostrados pelos dois dados.

- (a) Determine a função de distribuição de probabilidade do vetor aleatório $\mathbf{X}$.
 - (b) Determine a função de distribuição de probabilidade marginal da variável aleatória X_1 .
 - (c) Determine a função de distribuição de probabilidade marginal da variável aleatória X_2 .
 - (d) Determine o vetor de médias $\boldsymbol{\mu}$ do vetor aleatório $\mathbf{X}$.
 - (e) As variáveis aleatórias X_1 e X_2 são independentes? Por quê?
 - (f) Determine a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ do vetor aleatório $\mathbf{X}$.
 - (g) Determine a matriz de correlações $\mathbf{P}$ do vetor aleatório $\mathbf{X}$.
3. Considere o experimento aleatório que consiste em 10 lançamentos independentes de um dado equilibrado. Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^6$ tal que X_i é o número de ocorrências da face i , $i = 1, 2, \dots, 6$.
- (a) Determine a função de distribuição de probabilidade conjunta do vetor aleatório $\mathbf{X}$. Qual distribuição é essa?
 - (b) Determine a função de distribuição de probabilidade marginal da variável aleatória X_1 . As outras variáveis aleatórias X_i são identicamente distribuídas a X_1 , $i = 2, 3, \dots, 6$? Por quê?
 - (c) Considere o vetor aleatório $\mathbf{X}$ dividido em $\mathbf{X}^{(1)} = [X_1, X_3, X_5]^\top$ e $\mathbf{X}^{(2)} = [X_2, X_4, X_6]^\top$. Determine a função de distribuição de probabilidade marginal do vetor aleatório $\mathbf{X}^{(1)}$. O vetor aleatório $\mathbf{X}^{(2)}$ possui a mesma distribuição de $\mathbf{X}^{(1)}$? Por quê?
 - (d) Dê uma interpretação, no contexto do problema, para os vetores aleatórios $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$.
 - (e) Determine $\mathbb{E}(\mathbf{X})$, $\mathbb{E}(\mathbf{X}^{(1)})$ e $\mathbb{E}(\mathbf{X}^{(2)})$.
 - (f) Determine $Cov(\mathbf{X})$, $Cov(\mathbf{X}^{(1)})$ e $Cov(\mathbf{X}^{(2)})$.
4. Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^2$ tal que $X_1 = Y$ e $X_2 = 1 - Y$ com $\mathbb{E}(Y) = \mu$ e $Var(Y) = \sigma^2$.
- (a) Obtenha o vetor de médias do vetor aleatório $\mathbf{X}$.
 - (b) Obtenha a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$.
 - (c) Mostre que $Cov(\mathbf{X})$ é semi-definida positiva.
5. (Johnson e Wichern, 2014, p. 144, tradução e grifo nosso) Determine expressões para o valor esperado e a variância das seguintes combinações linear em

termos das médias μ_1 , μ_2 e μ_3 e das variâncias σ_{11} , σ_{22} e σ_{33} das variáveis aleatórias X_1 , X_2 e X_3 , respectivamente.

- (a) $X_1 - 2X_2$.
- (b) $-X_1 + 3X_2$.
- (c) $X_1 + X_2 + X_3$.
- (d) $X_1 + 2X_2 - X_3$.
- (e) $3X_1 - 4X_2$ com X_1 e X_2 variáveis aleatórias independentes.

6. Em uma central de suporte técnico, os atendimentos são feitos por etapas. Quando uma solicitação chega, ela passa por três fases sucessivas:

- Triagem inicial;
- Diagnóstico do problema;
- Resolução ou encaminhamento final.

Suponha que os tempos necessários para completar cada uma dessas etapas sejam modelados por variáveis aleatórias independentes e identicamente distribuídas segundo uma distribuição exponencial com taxa $\alpha > 0$. Seja $\mathbf{X}$ em $\mathbb{R}^3$ o vetor aleatório em que as componentes X_1 , X_2 e X_3 representam os tempos, respectivamente.

- (a) Determine $\mathbb{E}(\mathbf{1}^\top \mathbf{X})$, em que $\mathbf{1} \in \mathbb{R}^3$ é o vetor de uns.
- (b) Determine $Var(\mathbf{1}^\top \mathbf{X})$, em que $\mathbf{1} \in \mathbb{R}^3$ é o vetor de uns.
- (c) Qual é a distribuição de $\mathbf{1}^\top \mathbf{X}$?
- (e) Defina a matriz $\mathbf{A} \in M_{2 \times 3}(\mathbb{R})$ tal que

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

Determine $\mathbb{E}(\mathbf{A}\mathbf{X})$ e $Cov(\mathbf{A}\mathbf{X})$.

- (f) Defina a matriz $\mathbf{B} \in M_{3 \times 3}(\mathbb{R})$ tal que

$$\mathbf{B} = \begin{bmatrix} 1 & 2 & 3 \\ 3 & 2 & 1 \\ 1 & 0 & 1 \end{bmatrix}.$$

Determine $\mathbb{E}(\mathbf{B}\mathbf{X} + \mathbf{1})$ e $Cov(\mathbf{B}\mathbf{X} + \mathbf{1})$.

7. (Johnson e Wichern, 2014, p. 147, tradução e grifo nosso) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^4$ com vetor de médias $\boldsymbol{\mu} = [3, 2, -2, 0]^\top$ e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} := \begin{bmatrix} 3 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 3 \end{bmatrix}.$$

Seja $\mathbf{A} \in M_{3 \times 4}(\mathbb{R})$ uma matriz de constantes tal que

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 0 & 0 \\ 1 & 1 & -2 & 0 \\ 1 & 1 & 1 & -3 \end{bmatrix}.$$

- (a) Determine $\mathbb{E}(\mathbf{AX})$.
 - (b) Determine $Cov(\mathbf{AX})$.
 - (c) Quais pares de combinações lineares de $\mathbf{AX}$ possui covariância zero?
8. Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$. Mostre que
- (a) $\mathbb{E}(\mathbf{X}\mathbf{a}^\top) = \mathbb{E}(\mathbf{X})\mathbf{a}^\top$, qualquer que seja o vetor $\mathbf{a} \in \mathbb{R}^q$.
 - (b) $\mathbb{E}(\mathbf{X}\mathbf{a}^\top + \mathbf{B}) = \mathbb{E}(\mathbf{X})\mathbf{a}^\top + \mathbf{B}$, quaisquer que sejam o vetor $\mathbf{a} \in \mathbb{R}^p$ e a matriz $\mathbf{B} \in M_{p \times q}(\mathbb{R})$.
 - (c) $\mathbb{E}(\mathbf{a}^\top \mathbf{X} \mathbf{a}^\top) = \mathbf{a}^\top \mathbb{E}(\mathbf{X}) \mathbf{a}^\top$, qualquer que seja o vetor $\mathbf{a} \in \mathbb{R}^p$.
 - (d) $\mathbb{E}(\mathbf{AX}\mathbf{b}^\top) = \mathbf{A}\mathbb{E}(\mathbf{X})\mathbf{b}^\top$, quaisquer que sejam a matriz $\mathbf{A} \in M_{q \times p}(\mathbb{R})$ e o vetor $\mathbf{b} \in \mathbb{R}^p$.
 - (e) $\mathbb{E}(\mathbf{a}\mathbf{X}^\top + \mathbf{B}) = \mathbf{a}\mathbb{E}(\mathbf{X})^\top + \mathbf{B}$, quaisquer que sejam o vetor $\mathbf{a} \in \mathbb{R}^p$ e a matriz $\mathbf{B} \in M_{p \times p}(\mathbb{R})$.
9. (a) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^2$ cujas entradas são variáveis aleatórias independentes com distribuição normal padrão. Use as propriedades de valor esperado de um vetor aleatório e matriz de variâncias e covariâncias de um vetor aleatório para determinar $\mathbb{E}(\mathbf{Z})$ e $Cov(\mathbf{Z})$, em que

$$\mathbf{Z} := \begin{bmatrix} X_1^2 + X_2^2 \\ 5X_1^2 + 3X_2^2 \\ X_2^2 \end{bmatrix}.$$

- (b) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$ cujas entradas são variáveis aleatórias com distribuição Geométrica(1/4) e tal que $\rho_{12} = \rho_{13} = \rho_{23} = -\frac{1}{2}$. Determine o

seguinte valor esperado:

$$\mathbb{E} \left(\sum_{i=1}^3 X_i^2 \right).$$

- (c) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$ cujas entradas são variáveis aleatórias com distribuição Poisson(10) e tal que $\rho_{12} = \rho_{13} = \rho_{23} = 1$. Determine o seguinte valor esperado:

$$\mathbb{E} \left(25X_1^2 - 4X_1X_2 + 8X_1X_3 + 4X_2^2 + 2X_2X_3 + 9X_3^2 \right).$$

10. Dois métodos de treinamento foram aplicados em grupos diferentes de funcionários para melhorar o desempenho em três habilidades, todas avaliadas em uma escala de 0 a 100: Comunicação, Liderança e Gestão de Tempo. As matrizes de variâncias e covariâncias obtidas em cada uma das subpopulações foram:

$$\Sigma_1 = \begin{bmatrix} 12 & 3 & 4 \\ 3 & 10 & 5 \\ 4 & 5 & 11 \end{bmatrix} \quad (\text{Método 1}) \quad \text{e} \quad \Sigma_2 = \begin{bmatrix} 8 & 2 & 1 \\ 2 & 7 & 3 \\ 1 & 3 & 6 \end{bmatrix} \quad (\text{Método 2})$$

- (a) Calcule a variância total populacional para cada método.
- (b) Compare os resultados e interprete: qual grupo apresentou maior dispersão geral nas habilidades avaliadas?
- (c) Que tipo de informação o cálculo da variância generalizada da população agregaria?
11. (**Johnson e Wichern, 2014, p. 83, tradução e grifo nosso**) Considere as seguintes matrizes de variâncias e covariâncias amostrais

$$\mathbf{S}_n^{(1)} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{S}_n^{(2)} = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}, \quad \mathbf{S}_n^{(3)} = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}.$$

- (a) Esboce os paralelogramos associados a cada uma das matrizes de variâncias e covariâncias amostrais. Compare-os.
- (b) Determine as variâncias generalizadas associadas a cada uma das matrizes de variâncias e covariâncias amostrais.
- (c) Suas respostas para os itens (a) e (b) são consistentes?
12. Dois métodos de ensino foram aplicados para treinar operadores de máquinas, avaliados em duas habilidades medidas em uma escala de 0 a 10: Precisão e Velocidade.

As matrizes de variâncias e covariâncias obtidas para os dois grupos de operadores foram:

$$\Sigma_1 = \begin{bmatrix} 2 & 1,8 \\ 1,8 & 2 \end{bmatrix} \quad (\text{Método 1}) \quad \text{e} \quad \Sigma_2 = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \quad (\text{Método 2})$$

- (a) Calcule a variância total da população para cada método.
- (b) Compare os resultados: qual grupo apresentou maior dispersão geral?
- (c) A variância total populacional é uma boa medida de resumo nessa situação? Por quê?
- (d) Comente o que o cálculo da variância generalizada agregaria para a análise.
- (e) A variância generalizada populacional é uma boa medida de resumo nessa situação? Por quê?

13. (**Johnson e Wichern, 2014, p. 83, tradução e grifo nosso**) Considere as seguintes matrizes de variâncias e covariâncias populacionais

$$\Sigma_1 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad \text{e} \quad \Sigma_2 = \begin{bmatrix} 1 & -\frac{1}{2} & -\frac{1}{2} \\ -\frac{1}{2} & 1 & -\frac{1}{2} \\ -\frac{1}{2} & -\frac{1}{2} & 1 \end{bmatrix}$$

- (a) Calcule a variância total populacional para cada matriz de variâncias e covariâncias populacionais. Compare os resultados.
 - (b) Calcule a variância generalizada populacional para cada matriz de variâncias e covariâncias populacionais e compare os resultados.
 - (c) Comente sobre as discrepâncias, se houver, encontradas entre os itens (a) e (b).
14. (**Johnson e Wichern, 2014, p. 144, tradução e grifo nosso**) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^3$ cuja matriz de variâncias e covariâncias é dada por

$$\Sigma = \begin{bmatrix} 25 & -2 & 4 \\ -2 & 4 & 1 \\ 4 & 1 & 9 \end{bmatrix}.$$

- (a) Determine a matriz de desvios-padrões populacionais $\mathbf{V}^{1/2}$.
- (b) Determine a matriz de correlações populacionais $\mathbf{P}$.
- (c) A partir da sua resposta para o item (b), encontre a correlação populacional ρ_{13} entre as variáveis X_1 e X_3 . Interprete esse valor.

(d) Encontre a correlação populacional entre as variáveis aleatórias X_1 e $\frac{1}{2}X_2 + \frac{1}{2}X_3$.

15. (Johnson e Wichern, 2014, p. 84, tradução e grifo nosso) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ com matriz de variâncias e covariâncias Σ e matriz de correlações $\mathbf{P}$. Mostre que

$$|\Sigma| = (\sigma_{11}\sigma_{22} \cdots \sigma_{pp})|\mathbf{P}|.$$

16. (Johnson e Wichern, 2014, p. 83, tradução e grifo nosso) A matriz de dados a seguir contém informações sobre as notas em testes, em que X_1 representa a nota no primeiro teste, X_2 representa a nota no segundo teste e X_3 representa a nota total nos dois testes:

$$\mathbf{X} = \begin{bmatrix} 12 & 17 & 29 \\ 18 & 20 & 38 \\ 14 & 16 & 30 \\ 20 & 18 & 38 \\ 16 & 19 & 35 \end{bmatrix}$$

- (a) Obtenha a matriz de desvios $\mathbf{X}_c \in M_{5 \times 3}(\mathbb{R})$, em que as colunas são os vetores de desvios $\mathbf{d}_1$, $\mathbf{d}_2$ e $\mathbf{d}_3$.
- (b) Use o item (a), para obter a matriz de covariância amostral $\mathbf{S}_n$ (veja Exercício 4 da Lista 1).
- (c) Determine a variância generalizada.
- (d) O que a sua resposta para o item (c), diz sobre o sólido produzido pelos vetores de desvios em $\mathbb{R}^3$?
- (e) Comente a dependência linear das colunas da matriz de dados e a dependência linear dos vetores de desvios.
- (f) Como sua resposta para o item (e) se conecta com suas respostas para os itens (c) e (d)?
- (g) Verifique, e se convença, da veracidade ou não da seguinte afirmação:

“Quando a variância generalizada amostral é zero, são as colunas da matriz de dados centrada nas médias, $\mathbf{X}_c = \mathbf{X} - \mathbf{1}\bar{\mathbf{x}}^\top$, que são linearmente dependentes, e não necessariamente as colunas da matriz de dados original.”

17. (Johnson e Wichern, 2014, p. 145, tradução e grifo nosso) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^4$ com vetor de médias populacionais $\boldsymbol{\mu} = \begin{bmatrix} 4 & 3 & 2 & 1 \end{bmatrix}^\top$ e matriz de

variâncias e covariâncias populacionais

$$\Sigma = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}.$$

Considere a seguinte partição do vetor aleatório $\mathbf{X}$

$$\mathbf{X} := \begin{bmatrix} X_1 \\ X_2 \\ X_3 \\ X_4 \end{bmatrix} := \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}.$$

Considere o vetor de constantes $\mathbf{a} \in \mathbb{R}^2$ e a matriz de constantes $\mathbf{B} \in M_{2 \times 2}(\mathbb{R})$ tais que

$$\mathbf{a}^\top = \begin{bmatrix} 1 & -1 \end{bmatrix} \quad \text{e} \quad \mathbf{B} = \begin{bmatrix} 2 & -1 \\ 0 & 1 \end{bmatrix}.$$

Determine

- | | | |
|--|---|--|
| (a) $\mathbb{E}(\mathbf{X}^{(1)})$. | (e) $\mathbb{E}(\mathbf{X}^{(2)})$. | (i) $\text{Cov}(\mathbf{X}^{(1)}, \mathbf{X}^{(2)})$. |
| (b) $\mathbb{E}(\mathbf{a}^\top \mathbf{X}^{(1)})$. | (f) $\mathbb{E}(\mathbf{B} \mathbf{X}^{(2)})$. | (j) $\text{Cov}(\mathbf{a}^\top \mathbf{X}^{(1)}, \mathbf{B} \mathbf{X}^{(2)})$. |
| (c) $\text{Cov}(\mathbf{X}^{(1)})$. | (g) $\text{Cov}(\mathbf{X}^{(2)})$. | (k) $\mathbb{E} \left[\left(\mathbf{X}^{(1)} \right)^\top \mathbf{B} \mathbf{X}^{(1)} \right]$. |
| (d) $\text{Cov}(\mathbf{a}^\top \mathbf{X}^{(1)})$. | (h) $\text{Cov}(\mathbf{B} \mathbf{X}^{(2)})$. | (l) $\text{Cov}(\mathbf{a}^\top \mathbf{B} \mathbf{X}^{(1)})$. |

18. Considere um vetor aleatório $\mathbf{X} \in \mathbb{R}^4$, particionado em blocos de tamanho 2, de modo que

$$\mathbf{X}^{(1)} := \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \quad \text{e} \quad \mathbf{X}^{(2)} := \begin{bmatrix} X_3 \\ X_4 \end{bmatrix}.$$

Suponha que

$$\mathbb{E}(\mathbf{X}^{(1)}) = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \quad \text{e} \quad \text{Cov}(\mathbf{X}^{(1)}) = \begin{bmatrix} 1 & 2\rho \\ 2\rho & 4 \end{bmatrix},$$

em que $\rho \in [-1, 1]$ representa o coeficiente de correlação entre X_1 e X_2 .

Sabe-se também que

$$X_3 = X_1 + 1 \quad \text{e} \quad X_4 = -X_2.$$

Determine

$$\text{Cov} \left(\mathbf{1}^\top \mathbf{X}^{(1)}, \mathbf{1}^\top \mathbf{X}^{(2)} \right),$$

em que $\mathbf{1} \in \mathbb{R}^2$ é o vetor de uns.

19. (Johnson e Wichern, 2014, p. 144, tradução e grifo nosso) Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$. Mostre que

$$\text{Cov}(a_1X_1 + a_2X_2 + \cdots + a_pX_p, b_1X_1 + b_2X_2 + \cdots + b_pX_p) = \mathbf{a}^\top \mathbf{X} \mathbf{b},$$

em que $\mathbf{a} = [a_1 \ a_2 \ \cdots \ a_p]^\top \in \mathbb{R}^p$ e $\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_p]^\top \in \mathbb{R}^p$.

Observação: Não esqueça de especificar o domínio e o conjunto imagem ao definir as f.d.p's, sejam elas conjuntas ou marginais.

4 Distribuição normal multivariada

A distribuição normal multivariada é uma das mais importantes em Estatística, tanto pela sua base teórica quanto pela sua aplicação prática em diversas áreas. Assim como a distribuição normal univariada descreve o comportamento de uma variável aleatória contínua, a distribuição normal multivariada descreve o comportamento conjunto de várias variáveis aleatórias, levando em conta não apenas as características individuais de cada uma, mas também as relações entre elas. Muitos métodos estatísticos multivariados partem do pressuposto de normalidade multivariada, porque as distribuições amostrais acabam se aproximando da normalidade, mesmo que a população original não seja normal, graças a efeitos semelhantes ao Teorema Central do Limite. Portanto, torna-se essencial compreender suas propriedades, formas de representação e implicações. Neste capítulo, vamos explorar a definição formal dessa distribuição, discutir suas principais propriedades e visualizar como ela se comporta em diferentes situações, preparando o terreno para técnicas mais avançadas de análise.

4.1 A distribuição normal bivariada

Para começar a entender a distribuição normal multivariada, vamos dar um passo de cada vez e focar no caso mais simples: a distribuição normal bivariada. Ela descreve o comportamento conjunto de duas variáveis aleatórias contínuas, permitindo analisar não só como cada variável se comporta individualmente, mas também como elas se relacionam entre si. Estudando primeiro o caso com duas variáveis, conseguimos visualizar melhor os conceitos e entender, de forma mais intuitiva, as características da normal multivariada. Assim, antes de generalizarmos para mais dimensões, vamos explorar com calma a normal bivariada, suas propriedades e sua representação gráfica.

Exemplo 4.1

Seja $\mathbf{X} = \begin{bmatrix} X_1 & X_2 \end{bmatrix}^\top$ um vetor aleatório em $\mathbb{R}^2$ tal que $X_1 \sim \text{Normal}(\mu_1, \sigma_{11})$ e $X_2 \sim \text{Normal}(\mu_2, \sigma_{22})$ são variáveis aleatórias independentes, em que $\mu_1, \mu_2 \in \mathbb{R}$ e $\sigma_{11}, \sigma_{22} \in]0, +\infty[$.

- (a) Determine a função de densidade de probabilidade conjunta (f.d.p.) do vetor aleatório $\mathbf{X}$.
- (b) Qual distribuição é essa?
- (c) Construa o gráfico da f.d.p. conjunta do vetor aleatório $\mathbf{X}$ nos seguintes casos:

Exemplo 4.1

- (i) $\mu_1 = \mu_2 = 0$ e $\sigma_{11} = \sigma_{22} = 1$;
(ii) $\mu_1 = 1, \mu_2 = 2, \sigma_{11} = 2$ e $\sigma_{22} = 1$;
(iii) $\mu_1 = 1, \mu_2 = 2, \sigma_{11} = 1$ e $\sigma_{22} = 2$;

SOLUÇÃO:

- (a) A função de densidade de probabilidade conjunta do vetor aleatório $\mathbf{X}$ é a função $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

$$f(\mathbf{x}) = f(x_1, x_2) = f_1(x_1)f_2(x_2),$$

pois as variáveis aleatórias X_1 e X_2 são independentes. Logo, como X_1 e X_2 são variáveis aleatórias normalmente distribuídas, segue que

$$\begin{aligned} f(\mathbf{x}) &= f(x_1, x_2) \\ &= f_1(x_1)f_2(x_2) \\ &= \frac{1}{\sqrt{2\pi\sigma_{11}}} \exp \left[-\frac{1}{2} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 \right] \times \frac{1}{\sqrt{2\pi\sigma_{22}}} \exp \left[-\frac{1}{2} \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \\ &= \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}}} \exp \left\{ -\frac{1}{2} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 \right] \right\}. \end{aligned}$$

Note que, a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$ é

$$\Sigma = \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix}.$$

Logo, $|\Sigma| = \sigma_{11}\sigma_{22}$. Além disso, como o vetor de médias do vetor aleatório $\mathbf{X}$ é $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$, segue que

$$\begin{aligned} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 &= \begin{bmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{bmatrix} \begin{bmatrix} 1/\sigma_{11} & 0 \\ 0 & 1/\sigma_{22} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}), \end{aligned}$$

pois como Σ é diagonal, temos $\Sigma^{-1} = \begin{bmatrix} 1/\sigma_{11} & 0 \\ 0 & 1/\sigma_{22} \end{bmatrix}$.

Exemplo 4.1

Portanto, podemos reescrever a função de densidade de probabilidade do vetor aleatório $\mathbf{X}$ da seguinte maneira

$$f(\mathbf{x}) = \frac{1}{2\pi|\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right] \times \mathbb{I}_{\mathbb{R}^2}(\mathbf{x}).$$

- (b) Dos cursos de probabilidade, sabemos que o vetor aleatório $\mathbf{X}$ tem distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ e matriz de variâncias e covariâncias $\Sigma = \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix}$.

- (c) (i) Nesse caso, o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$ e matriz de variâncias e covariâncias $\Sigma = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2$. Portanto, o gráfico da f.d.p. conjunta de $\mathbf{X}$ é tal como na Figura 4.1.




Figura 4.1. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right)$.

Exemplo 4.1

- (ii) Nesse caso, o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$. Portanto, o gráfico da f.d.p. conjunta de $\mathbf{X}$ é tal como na Figura 4.2.




Figura 4.2. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \right)$.

- (iii) Nesse caso, o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$. Portanto, o gráfico da f.d.p. conjunta de $\mathbf{X}$ é tal como na Figura 4.3.




Figura 4.3. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \right)$.

Nos títulos das figuras do exemplo anterior, introduzimos a notação $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ para dizer que o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$. Essa notação é análoga àquela que utilizamos para a distribuição normal univariada. Na Figura 4.4, ilustramos o gráfico genérico da função de densidade de probabilidade de um vetor aleatório com distribuição normal bivariada, cujas componentes são não-correlacionadas, i.e., $\rho_{12} = 0$.




Figura 4.4. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2\left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix}\right)$.

Quando $\rho_{12} = 0$, a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ do vetor aleatório $\mathbf{X}$ é diagonal com os elementos da diagonal principal todos positivos. Logo, $|\boldsymbol{\Sigma}| > 0$ e, conseqüentemente, sempre existe $\boldsymbol{\Sigma}^{-1}$. Portanto, a expressão que encontramos, no item (a) do Exemplo 1, para f.d.p. conjunta de $\mathbf{X}$ está bem definida. No entanto, no caso em que as componentes do vetor aleatório são correlacionadas ($\rho_{12} \neq 0$), para garantir que a f.d.p. conjunta de $\mathbf{X}$ está bem definida, precisamos ter $|\boldsymbol{\Sigma}| \neq 0$ e que $\boldsymbol{\Sigma}^{-1}$ exista. Para isso, vamos assumir que a matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ é definida positiva.

Definição 4.1: Distribuição normal bivariada

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^2$ com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^2$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{2 \times 2}(\mathbb{R})$ definida positiva. Dizemos que $\mathbf{X}$ possui *distribuição normal bivariada* quando sua função de densidade de probabilidade é a função $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

Definição 4.1

$$f(\mathbf{x}) = f(x_1, x_2) = \frac{1}{2\pi|\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right] \times \mathbb{I}_{\mathbb{R}^2}(\mathbf{x}).$$

Exemplo 4.2

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \Sigma)$, em que $\boldsymbol{\mu} \in \mathbb{R}^2$ é o vetor de médias e $\Sigma \in M_{2 \times 2}(\mathbb{R})$ é a matriz de variâncias e covariâncias. Assuma que $\rho_{12} \neq 0$ e que Σ é definida positiva.

- (a) Determine a f.d.p. do vetor aleatório $\mathbf{X}$ em função de x_1 e x_2 .
- (b) Construa o gráfico da f.d.p. conjunta do vetor aleatório $\mathbf{X}$ nos seguintes casos:
- (i) $\mu_1 = 1, \mu_2 = 2, \sigma_{11} = \sigma_{22} = 1$ e $\rho_{12} = 0,7$.
 - (ii) $\mu_1 = 1, \mu_2 = 2, \sigma_{11} = \sigma_{22} = 1$ e $\rho_{12} = -0,7$.

SOLUÇÃO:

- (a) Como Σ é definida positiva, sabemos da teoria das matrizes que $|\Sigma| \neq 0$ e que Σ^{-1} existe e é tal que

$$\Sigma^{-1} = \frac{1}{|\Sigma|} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{21} & \sigma_{11} \end{bmatrix} = \frac{1}{\sigma_{11}\sigma_{22} - \sigma_{12}^2} \begin{bmatrix} \sigma_{22} & -\sigma_{12} \\ -\sigma_{12} & \sigma_{11} \end{bmatrix},$$

uma vez que $\sigma_{12} = \sigma_{21}$ devido à simetria de Σ . Introduzindo o coeficiente de correlação ρ_{12} , podemos escrever $\sigma_{12} = \rho_{12}\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}$. Logo,

$$\sigma_{11}\sigma_{22} - \sigma_{12}^2 = \sigma_{11}\sigma_{22} - \sigma_{11}\sigma_{22}\rho_{12}^2 = \sigma_{11}\sigma_{22}(1 - \rho_{12}^2).$$

Consequentemente, $(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})$ pode ser reescrita da seguinte maneira

$$\begin{aligned} & \begin{bmatrix} x_1 - \mu_1 & x_2 - \mu_2 \end{bmatrix} \frac{1}{\sigma_{11}\sigma_{22}(1 - \rho_{12}^2)} \begin{bmatrix} \sigma_{22} & -\rho_{12}\sqrt{\sigma_{11}}\sqrt{\sigma_{22}} \\ -\rho_{12}\sqrt{\sigma_{11}}\sqrt{\sigma_{22}} & \sigma_{11} \end{bmatrix} \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \\ &= \frac{\sigma_{22}(x_1 - \mu_1)^2 + \sigma_{11}(x_2 - \mu_2)^2 - 2\rho_{12}\sqrt{\sigma_{11}}\sqrt{\sigma_{22}}(x_1 - \mu_1)(x_2 - \mu_2)}{\sigma_{11}\sigma_{22}(1 - \rho_{12}^2)} \\ &= \frac{1}{1 - \rho_{12}^2} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right]. \end{aligned}$$

Exemplo 4.2

Portanto, a função de densidade de probabilidade conjunta do vetor aleatório $\mathbf{X}$ é a função $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

$$\begin{aligned} f(\mathbf{x}) = f(x_1, x_2) &= \frac{1}{2\pi|\Sigma|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right] \times \mathbb{I}_{\mathbb{R}^2}(\mathbf{x}) \\ &= \frac{1}{2\pi\sqrt{\sigma_{11}\sigma_{22}(1-\rho_{12}^2)}} \exp \left\{ -\frac{1}{2(1-\rho_{12}^2)} \left[\left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right)^2 \right. \right. \\ &\quad \left. \left. + \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right)^2 - 2\rho_{12} \left(\frac{x_1 - \mu_1}{\sqrt{\sigma_{11}}} \right) \left(\frac{x_2 - \mu_2}{\sqrt{\sigma_{22}}} \right) \right] \right\} \times \mathbb{I}_{\mathbb{R}^2}(\mathbf{x}). \end{aligned}$$

- (b) (i) Nesse caso, o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias $\Sigma = \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix}$. Portanto, o gráfico da f.d.p. conjunta de $\mathbf{X}$ é tal como na Figura 4.5.




Figura 4.5. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix} \right)$.

- (ii) Nesse caso, o vetor aleatório $\mathbf{X}$ possui distribuição normal bivariada

Exemplo 4.2

com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} = \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix}$. Portanto, o gráfico da f.d.p. conjunta de $\mathbf{X}$ é tal como na Figura 4.6.




Figura 4.6. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix} \right)$.

Nas Figuras 4.5 e 4.6, conseguimos observar como a presença de correlação causa uma concentração da probabilidade em torno de uma linha. Nesse contexto, ilustramos, na Figura 4.7, o gráfico genérico da função de densidade de probabilidade de um vetor aleatório com distribuição normal bivariada, cujas componentes são correlacionadas positivamente, i.e., $0 < \rho_{12} < 1$.

A expressão obtida no Exemplo 2 para a função de densidade de probabilidade (f.d.p.) de um vetor aleatório $\mathbf{X}$ com distribuição normal bivariada pode ser considerada um tanto difícil de manipular. Por outro lado, a forma genérica e compacta apresentada na Definição 4.1, escrita em notação matricial, é mais elegante e, em muitos aspectos, mais informativa. Ainda assim, a expressão do Exemplo 2 é bastante útil para explorar certas propriedades da distribuição normal bivariada. Por exemplo, se as componentes X_1 e X_2 do vetor aleatório $\mathbf{X}$ são não correlacionadas, ou seja, se $\rho_{12} = 0$, então a f.d.p. conjunta

pode ser reescrita como o produto das f.d.p.s univariadas: $f(x_1, x_2) = f_1(x_1)f_2(x_2)$. Isso implica que X_1 e X_2 são variáveis aleatórias independentes. Combinando essa observação com o que foi mostrado no Exemplo 4.1, ou seja, que variáveis normais independentes têm correlação nula, obtemos o seguinte resultado.

Resultado 4.1: Independência entre variáveis aleatórias normais

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. As componentes X_1 e X_2 do vetor aleatório $\mathbf{X}$ são independentes se, e somente se, $\sigma_{12} = \text{Cov}(X_1, X_2) = 0$.




Figura 4.7. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2\left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \rho_{12} \\ \rho_{12} & \sigma_{22} \end{bmatrix}\right)$, em que $0 < \rho_{12} < 1$.

4.2 Contornos da densidade de uma normal bivariada

O termo

$$\left(\frac{x - \mu}{\sigma}\right)^2 = (x - \mu)(\sigma^2)^{-1}(x - \mu),$$

no expoente da função de densidade de probabilidade de uma variável aleatória X com distribuição normal (univariada) com média μ e variância σ^2 , mede o quadrado da distância de uma possível observação x de X para sua média μ em unidades de desvios-padrão.

Isso pode ser generalizado para um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^2$ com distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^2$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in$

$M_{2 \times 2}(\mathbb{R})$. Logo, a forma quadrática

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$$

mede o quadrado da *distância estatística* entre o vetor observado $\mathbf{x}$ de $\mathbf{X}$ e o vetor de médias $\boldsymbol{\mu}$, desde que $\boldsymbol{\Sigma}^{-1}$ exista. Para garantir sua existência, vamos exigir que $\boldsymbol{\Sigma}$ seja definida positiva. Dessa forma, evitaremos o caso em a função de densidade de probabilidade é degenerada (por exemplo, quando $\sigma_{11} = 0$, $\sigma_{22} = 0$, $\rho = 1$ ou $\rho = -1$). Há razões geométricas para essa exigência que ficarão claras mais adiante.

Dos cursos de cálculo, sabemos que a curva de nível k da função de densidade de probabilidade de um vetor aleatório $\mathbf{X}$ com distribuição normal bivariada com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$, é o conjunto dos pontos $(x_1, x_2) \in \mathbb{R}^2$ tal que $f(x_1, x_2) = k$, i.e.,

$$\mathcal{N}_k := \{(x_1, x_2) \in \mathbb{R}^2 : f(x_1, x_2) = k\}.$$

Note que

$$\begin{aligned} f(x_1, x_2) = k &\Leftrightarrow \frac{1}{2\pi|\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right] = k \\ &\Leftrightarrow \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) \right] = k2\pi|\boldsymbol{\Sigma}|^{1/2} \\ &\Leftrightarrow -\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = \log(k2\pi|\boldsymbol{\Sigma}|^{1/2}) \\ &\Leftrightarrow (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = -2\log(k2\pi|\boldsymbol{\Sigma}|^{1/2}). \end{aligned}$$

Tomando $c^2 = -2\log(k2\pi|\boldsymbol{\Sigma}|^{1/2})$, concluímos que

$$f(x_1, x_2) = k \Leftrightarrow (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2.$$

Em outras palavras, a densidade da normal multivariada é constante sobre superfícies cujo quadrado da distância estatística $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})$ é constante. Esses caminhos são chamados de *contornos*.

Definição 4.2: Contornos da densidade de uma normal bivariada

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Fixado um número real $c \in \mathbb{R}$, o *contorno* associado é o conjunto das observações $\mathbf{x}$ de $\mathbf{X}$ tal que $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2$, i.e.,

$$\mathcal{C}_c := \{\mathbf{x} \in \mathbb{R}^2 : (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2\}.$$

Exemplo 4.3

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, em que o vetor de médias é $\boldsymbol{\mu} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} = \mathbf{0}_2$ e a matriz de variâncias e covariâncias é

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \mathbf{I}_2.$$

- (a) Para $k = 0,05$, determine a curva $\mathcal{N}_k$ de nível k relativa à f.d.p. do vetor aleatório $\mathbf{X}$.
- (b) Determine $c \in \mathbb{R}$ tal que contorno $\mathcal{C}_c$ da densidade do vetor aleatório $\mathbf{X}$ seja igual à curva de nível $\mathcal{N}_k$ quando $k = 0,05$.
- (c) Que curva os conjuntos dos pares ordenados pertencentes às $\mathcal{N}_k$ e $\mathcal{C}_c$ definem? Represente-a no plano cartesiano.
- (d) Se tivéssemos escolhido um nível k_1 tal que $k_1 > 0,05$, a área delimitada pelo contorno da densidade de $\mathbf{X}$ seria maior ou menor do que àquela delimitada pelo contorno encontrado no item (b)? Por quê?
- (e) Se tivéssemos escolhido um nível k_2 tal que $k_2 < 0,05$, a área delimitada pelo contorno da densidade de $\mathbf{X}$ seria maior ou menor do que àquela delimitada pelo contorno encontrado no item (b)? Por quê?

SOLUÇÃO:

- (a) Para $k = 0,05$, a curva $\mathcal{N}_k$ de nível da k da f.d.p. do vetor aleatório $\mathbf{X}$ é composta pelos vetores $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top \in \mathbb{R}^2$ tais que $f(\mathbf{x}) = f(x_1, x_2) = 0,05$. Logo, desde que $\boldsymbol{\mu} = \mathbf{0}_2$ e $\boldsymbol{\Sigma} = \mathbf{I}_2$, temos

$$\begin{aligned} f(x_1, x_2) = 0,05 &\Leftrightarrow (\mathbf{x} - \mathbf{0}_2)^\top \mathbf{I}_2 (\mathbf{x} - \mathbf{0}_2) = -2 \log(0,05 \times 2\pi |\mathbf{I}_2|^{1/2}) \\ &\Leftrightarrow \mathbf{x}^\top \mathbf{x} = -2 \log(0,05 \times 2\pi) \\ &\Leftrightarrow x_1^2 + x_2^2 = 2,32. \end{aligned}$$

$$\therefore \mathcal{N}_{0,05} = \left\{ \mathbf{x} \in \mathbb{R}^2 : x_1^2 + x_2^2 = 2,32 \right\}.$$

- (b) Para que o contorno $\mathcal{C}_c$ seja igual à curva de nível $\mathcal{N}_k$ devemos ter

$$c^2 = -2 \log(k 2\pi |\boldsymbol{\Sigma}|^{1/2}).$$

Exemplo 4.3

Logo, para $k = 0,05$, temos

$$c^2 = -2 \log(0,05 \times 2\pi) = 2,32 \Leftrightarrow c = 1,52.$$

$$\therefore c = 1,52.$$

- (c) Tanto $\mathcal{N}_k$ quanto $\mathcal{C}_c$ definem uma circunferência centrada na origem do plano cartesiano com raio 1,52. Na Figura 4.8, podemos observar a representação do gráfico dessa curva de nível.




Figura 4.8. Curva de nível $k = 0,05$ da função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2\left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right)$.

- (d) Na Figura 4.9, ilustramos a densidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2(\mathbf{0}_2, \mathbf{I}_2)$. Note que conforme aumentamos o valor de k (no eixo z), menor se torna a área delimitada pela curva de nível resultante. Por outro lado, quanto menor se torna o valor de k (no eixo z), maior se torna essa área. Portanto, para $k < 0,05$, a área delimitada pela circunferência seria maior.


Exemplo 4.3

Figura 4.9. Função de densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \right)$.

- (e) Conforme discutido no item (d), para $k > 0,05$, a área delimitada pela curva de nível resultante (circunferência) seria menor.

Exemplo 4.4

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Em cada uma das situações descritas nos itens seguintes, determine o contorno $\mathcal{C}_c$ e represente-o graficamente.

(a) $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \mathbf{0}_2$, $\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$ e $c \in \{0,94; 1,62; 2,64\}$,

(b) $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \mathbf{0}_2$ e $\boldsymbol{\Sigma} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$ e $c \in \{0,94; 1,62; 2,64\}$,

- (c) A área delimitada pelo contorno nos itens (a) e (b) aumentam ou diminuem conforme o aumento do valor de c ? Esse comportamento é esperado? Por quê?

Exemplo 4.4**SOLUÇÃO:**

(a) Nesse caso, o contorno $\mathcal{C}_c$ da f.d.p. do vetor aleatório $\mathbf{X}$ é composto pelos vetores $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top \in \mathbb{R}^2$ tais que $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2$. Logo, desde que

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}, \text{ temos}$$

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2 &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1/2 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} x_1 - 1 & \frac{x_2 - 2}{2} \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} \\ &\Rightarrow (x_1 - 1)^2 + \frac{(x_2 - 2)^2}{2} = c^2 \\ &\Rightarrow \frac{(x_1 - 1)^2}{c^2} + \frac{(x_2 - 2)^2}{2c^2} = 1. \end{aligned}$$

Portanto, para qualquer valor plausível de c , o contorno $\mathcal{C}_c$ é uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ com as extremidades do eixo maior dada por $\mu_2 \pm c\sqrt{2}$ e com as extremidades do eixo menor em $\mu_1 \pm c$. O eixo menor da elipse é paralelo ao eixo das abscissas Ox e o eixo maior da elipse é paralelo ao eixo das ordenadas Oy . A Figura 4.10 ilustra essa situação para $c \in \{0,94; 1,62; 2,64\}$.

(b) Nesse caso, o contorno $\mathcal{C}_c$ da f.d.p. do vetor aleatório $\mathbf{X}$ é composto pelos vetores $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top \in \mathbb{R}^2$ tais que $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2$. Logo, desde que

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}, \text{ temos}$$

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2 &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} \frac{x_1 - 1}{2} & x_2 - 2 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} \end{aligned}$$

Exemplo 4.4

$$\begin{aligned} \Rightarrow \frac{(x_1 - 1)^2}{2} + (x_2 - 2)^2 &= c^2 \\ \Rightarrow \frac{(x_1 - 1)^2}{2c^2} + \frac{(x_2 - 2)^2}{c^2} &= 1. \end{aligned}$$

- (b) Nesse caso, o contorno $\mathcal{C}_c$ da f.d.p. do vetor aleatório $\mathbf{X}$ é composto pelos vetores $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top \in \mathbb{R}^2$ tais que $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2$. Logo, desde que $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e $\boldsymbol{\Sigma} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$, temos

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}(\mathbf{x} - \boldsymbol{\mu}) = c^2 &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} x_1 - 1 & x_2 - 2 \end{bmatrix} \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} = c^2 \\ &\Rightarrow \begin{bmatrix} \frac{x_1 - 1}{2} & x_2 - 2 \end{bmatrix} \begin{bmatrix} x_1 - 1 \\ x_2 - 2 \end{bmatrix} \\ &\Rightarrow \frac{(x_1 - 1)^2}{2} + (x_2 - 2)^2 = c^2 \\ &\Rightarrow \frac{(x_1 - 1)^2}{2c^2} + \frac{(x_2 - 2)^2}{c^2} = 1. \end{aligned}$$

Portanto, para qualquer valor plausível de c , o contorno $\mathcal{C}_c$ é uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ com as extremidades do eixo menor dada por $\mu_2 \pm c\sqrt{2}$ e com as extremidades do eixo maior em $\mu_1 \pm c$. O eixo maior da elipse é paralelo ao eixo das abscissas Ox e o eixo menor da elipse é paralelo ao eixo das ordenadas Oy . A Figura 4.11 ilustra essa situação para $c \in \{0,94; 1,62; 2,64\}$.

- (c) Nos itens (a) e (b), conforme aumentamos o valor de c , obtemos elipses que delimitam uma área cada vez maior (ver Figuras 4.10 e 4.11). Esse comportamento é esperado, uma vez que

$$c^2 = -2 \log \left(-k2\pi |\boldsymbol{\Sigma}|^{1/2} \right).$$

Portanto, c é tão maior quanto menor for k . Como vimos no Exemplo 4.3, valores pequenos de k levam a curvas de níveis que delimitam uma maior área.




Figura 4.10. Contornos $\mathcal{C}_c$ da densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix} \right)$ para $c \in \{0,94; 1,62; 2,64\}$.



Figura 4.11. Contornos $\mathcal{C}_c$ da densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \right)$ para $c \in \{0,94; 1,62; 2,64\}$.

Os Exemplos 4.3 e 4.4 ilustram três situações envolvendo contornos de funções de densidade de probabilidade de vetores aleatórios com distribuição normal bivariada:

- Se $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix} \right)$ com $\sigma_{11} = \sigma_{22}$, então, para um valor plausível de $c \geq 0$ fixado, o contorno da f.d.p. de $\mathbf{X}$ é o conjunto

$$\mathcal{C}_c := \left\{ \mathbf{x} \in \mathbb{R}^2 : (x_1 - \mu_1)^2 + (x_2 - \mu_2)^2 = \sigma_{11}c^2 \right\},$$

que trata-se de uma circunferência centrada em $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ e raio $c\sqrt{\sigma_{11}}$.

- Se $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix} \right)$ com $\sigma_{11} > \sigma_{22}$, então, para um valor plausível de $c \geq 0$ fixado, o contorno da f.d.p. de $\mathbf{X}$ é o conjunto

$$\mathcal{C}_c := \left\{ \mathbf{x} \in \mathbb{R}^2 : \frac{(x_1 - \mu_1)^2}{\sigma_{11}c^2} + \frac{(x_2 - \mu_2)^2}{\sigma_{22}c^2} = 1 \right\},$$

que trata-se de uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ com eixo maior paralelo ao eixo Ox (abscissas) e extremidades em $\mu_1 \pm c\sqrt{\sigma_{11}}$ e com eixo menor paralelo ao eixo Oy (ordenada) e extremidades em $\mu_2 \pm c\sqrt{\sigma_{22}}$.

- Se $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & 0 \\ 0 & \sigma_{22} \end{bmatrix} \right)$ com $\sigma_{11} < \sigma_{22}$, então, para um valor plausível de $c \geq 0$ fixado, o contorno da f.d.p. de $\mathbf{X}$ é o conjunto

$$\mathcal{C}_c := \left\{ \mathbf{x} \in \mathbb{R}^2 : \frac{(x_1 - \mu_1)^2}{\sigma_{11}c^2} + \frac{(x_2 - \mu_2)^2}{\sigma_{22}c^2} = 1 \right\},$$

que trata-se de uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$ com eixo menor paralelo ao eixo Ox (abscissas) e extremidades em $\mu_1 \pm c\sqrt{\sigma_{11}}$ e com eixo maior paralelo ao eixo Oy (ordenada) e extremidades em $\mu_2 \pm c\sqrt{\sigma_{22}}$.

Nos Exemplos 4.2 e 4.4, o vetor aleatório $\mathbf{X}$ era tal que a correlação entre X_1 e X_2 era igual a zero. No entanto, nem sempre essa será a situação com a qual estaremos lidando. Quando existe uma correlação $\rho_{12} \neq 0$, os contornos da função densidade de probabilidade (f.d.p.) de $\mathbf{X}$ continuam sendo elipses. No entanto, seus eixos deixam de ser paralelos aos eixos do plano cartesiano, passando a estar orientados segundo os autovetores da matriz inversa de variâncias e covariâncias, $\boldsymbol{\Sigma}^{-1}$. Se λ_1 e λ_2 são os autovalores da matriz de variâncias e covariâncias de modo que $\lambda_1 > \lambda_2$, então o eixo maior é proporcional ao λ_1 e

o eixo menor ao λ_2 . No Resultado 4.1, mostramos formalmente esse fato.

Resultado 4.2

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Se a matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{2 \times 2}(\mathbb{R})$ é definida positiva, então

- (a) os autovalores de $\boldsymbol{\Sigma}$ são todos positivos;
- (b) $\boldsymbol{\Sigma}^{-1}$ existe;
- (c) se λ é um autovalor de $\boldsymbol{\Sigma}$ e $\mathbf{e}$ é o autovetor ortonormal associado, então

$$\boldsymbol{\Sigma}\mathbf{e} = \lambda\mathbf{e} \Rightarrow \boldsymbol{\Sigma}^{-1}\mathbf{e} = \frac{1}{\lambda}\mathbf{e};$$

- (d) $\boldsymbol{\Sigma}^{-1}$ é definida positiva;
- (e) os contornos $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2$ de $\mathbf{X}$ são elipses centradas no vetor de médias $\boldsymbol{\mu}$ cujos eixos estão na direção de seus autovetores $\mathbf{e}_1$ e $\mathbf{e}_2$ de tal modo que o tamanho do eixo maior é $2c\sqrt{\lambda_1}$ e o tamanho do eixo menor é $2c\sqrt{\lambda_2}$, em que λ_1 é o maior e λ_2 o menor autovalor, associados, respectivamente, à $\mathbf{e}_1$ e $\mathbf{e}_2$.

DEMONSTRAÇÃO:

- (a) Se $\boldsymbol{\Sigma}$ é definida positiva, então para qualquer vetor não-nulo $\mathbf{x} \in \mathbb{R}^2$, temos

$$\mathbf{x}^\top \boldsymbol{\Sigma} \mathbf{x} > 0.$$

Em particular, se $\mathbf{e}$ é um autovetor ortonormal qualquer de $\boldsymbol{\Sigma}$, podemos tomar $\mathbf{x} = \mathbf{e}$ e, conseqüentemente,

$$\mathbf{e}^\top \boldsymbol{\Sigma} \mathbf{e} > 0.$$

Mas, por definição, $\boldsymbol{\Sigma}\mathbf{e} = \lambda\mathbf{e}$, em que $\lambda \in \mathbb{R}$ é o autovalor associado ao $\mathbf{e}$. Logo,

$$\mathbf{e}^\top \boldsymbol{\Sigma} \mathbf{e} > 0 \Rightarrow \mathbf{e}^\top \lambda \mathbf{e} > 0 \Rightarrow \lambda \mathbf{e}^\top \mathbf{e} > 0 \Rightarrow \lambda > 0,$$

pois $\mathbf{e}$ é ortonormal e, conseqüentemente, $\|\mathbf{e}\| = \mathbf{e}^\top \mathbf{e} = 1$.

- (b) Se $\boldsymbol{\Sigma}$ é definida positiva, então, pelo item (a), seus autovalores são todos positivos. Como $|\boldsymbol{\Sigma}| = \lambda_1 \lambda_2 > 0$, segue que existe a inversa $\boldsymbol{\Sigma}^{-1}$.

Resultado 4.2

(c) Se λ é um autovalor de Σ e $\mathbf{e}$ é o autovetor ortonormal associado, segue que

$$\mathbf{e} = \mathbf{I}_2 \mathbf{e} \Rightarrow \mathbf{e} = \Sigma^{-1} \Sigma \mathbf{e} \Rightarrow \mathbf{e} = \Sigma^{-1} \lambda \mathbf{e} \Rightarrow \frac{1}{\lambda} \mathbf{e} = \Sigma^{-1} \mathbf{e}.$$

Em outras palavras Σ e Σ^{-1} possuem os mesmos autovetores e se λ é um autovalor de Σ , $1/\lambda$ será autovalor de Σ^{-1} .

(d) Como Σ^{-1} é simétrica, ela admite decomposição espectral, i.e.,

$$\Sigma^{-1} = \mathbf{E} \mathbf{\Lambda} \mathbf{E}^T,$$

em que $\mathbf{E}$ é a matriz dos autovetores ortonormais de Σ^{-1} (que, por (c), sabemos que são os mesmos autovetores de Σ) e $\mathbf{\Lambda}$ é uma matriz diagonal com autovalores de Σ^{-1} na diagonal principal. Logo,

$$\Sigma^{-1} = [\mathbf{e}_1 \quad \mathbf{e}_2] \begin{bmatrix} 1/\lambda_1 & 0 \\ 0 & 1/\lambda_2 \end{bmatrix} \begin{bmatrix} \mathbf{e}_1^T \\ \mathbf{e}_2^T \end{bmatrix} \Rightarrow \Sigma^{-1} = \frac{\mathbf{e}_1 \mathbf{e}_1^T}{\lambda_1} + \frac{\mathbf{e}_2 \mathbf{e}_2^T}{\lambda_2}.$$

Portanto, qualquer que seja o vetor não-nulo $\mathbf{x} \in \mathbb{R}^2$, temos

$$\begin{aligned} \mathbf{x}^T \Sigma^{-1} \mathbf{x} &= \mathbf{x}^T \left(\frac{\mathbf{e}_1 \mathbf{e}_1^T}{\lambda_1} + \frac{\mathbf{e}_2 \mathbf{e}_2^T}{\lambda_2} \right) \mathbf{x} \\ &= \frac{(\mathbf{x}^T \mathbf{e}_1)(\mathbf{e}_1^T \mathbf{x})}{\lambda_1} + \frac{(\mathbf{x}^T \mathbf{e}_2)(\mathbf{e}_2^T \mathbf{x})}{\lambda_2} \\ &= \frac{(\mathbf{x}^T \mathbf{e}_1)^2}{\lambda_1} + \frac{(\mathbf{x}^T \mathbf{e}_2)^2}{\lambda_2} \\ &> 0. \end{aligned}$$

Portanto, por definição, Σ^{-1} é definida positiva.

(e) Como Σ é simétrica e definida positiva, ela admite decomposição espectral, i.e.

$$\Sigma = \mathbf{E} \mathbf{\Lambda} \mathbf{E}^T$$

em que $\mathbf{E} = [\mathbf{e}_1 \quad \mathbf{e}_2]$ é a matriz de autovetores ortonormais de Σ e $\mathbf{\Lambda} = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$ é uma matriz diagonal com autovalores positivos de Σ dispostos na diagonal

Resultado 4.2

principal. Logo, a inversa de Σ é dada por:

$$\Sigma^{-1} = \mathbf{E}\mathbf{\Lambda}^{-1}\mathbf{E}^\top.$$

Definimos a mudança de variáveis:

$$\mathbf{z} = \mathbf{E}^\top(\mathbf{x} - \boldsymbol{\mu})$$

Isso corresponde a rotacionar o sistema de coordenadas para alinhar com os autovetores de Σ .

Substituindo na equação do contorno:

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu}) &= (\mathbf{x} - \boldsymbol{\mu})^\top \mathbf{E}\mathbf{\Lambda}^{-1}\mathbf{E}^\top (\mathbf{x} - \boldsymbol{\mu}) \\ &= \mathbf{z}^\top \mathbf{\Lambda}^{-1} \mathbf{z} \end{aligned}$$

Escrevendo $\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \end{bmatrix}$, temos

$$\mathbf{z}^\top \mathbf{\Lambda}^{-1} \mathbf{z} = \frac{z_1^2}{\lambda_1} + \frac{z_2^2}{\lambda_2}.$$

Logo, o contorno é:

$$\frac{z_1^2}{\lambda_1} + \frac{z_2^2}{\lambda_2} = c^2 \quad \Rightarrow \quad \frac{z_1^2}{(c\sqrt{\lambda_1})^2} + \frac{z_2^2}{(c\sqrt{\lambda_2})^2} = 1.$$

Essa é a equação de uma elipse no sistema de coordenadas $\mathbf{z}$, com eixo maior de comprimento $2c\sqrt{\lambda_1}$ e eixo menor de comprimento $2c\sqrt{\lambda_2}$.

No sistema original $\mathbf{x}$, a elipse é centrada em $\boldsymbol{\mu}$ e tem seus eixos principais nas direções dos autovetores $\mathbf{e}_1$ e $\mathbf{e}_2$, com os comprimentos dos eixos proporcionais a $\sqrt{\lambda_1}$ e $\sqrt{\lambda_2}$, respectivamente.

Exemplo 4.5

Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \Sigma)$. Em cada uma das situações descritas nos itens seguintes, determine o contorno $\mathcal{C}_c$ e represente-o graficamente.

Exemplo 4.5

$$(a) \boldsymbol{\mu} = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{0}_2, \boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix} \text{ e } c \in \{0,94; 1,62; 2,64\},$$

$$(b) \boldsymbol{\mu} = \begin{bmatrix} 0 \\ -1 \end{bmatrix} = \mathbf{0}_2 \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix} \text{ e } c \in \{0,94; 1,62; 2,64\}.$$

SOLUÇÃO:

(a) A matriz $\boldsymbol{\Sigma}$ é simétrica, então admite decomposição espectral. Calculando os autovalores:

$$\begin{aligned} |\boldsymbol{\Sigma} - \lambda \mathbf{I}_2| = 0 &\Rightarrow \begin{vmatrix} 1 - \lambda & 0,7 \\ 0,7 & 1 - \lambda \end{vmatrix} = 0 \\ &\Rightarrow (1 - \lambda)^2 - 0,49 = 0 \\ &\Rightarrow (1 - \lambda)^2 = 0,49 \\ &\Rightarrow \lambda_1 = 1,7 \text{ e } \lambda_2 = 0,3. \end{aligned}$$

Logo, o conjunto $V(\lambda_1)$ dos autovetores associados ao autovalor $\lambda_1 = 1,7$ é o conjunto dos vetores $\mathbf{u}_1 = \begin{bmatrix} x & y \end{bmatrix}^\top$ tal que

$$\begin{aligned} \boldsymbol{\Sigma} \mathbf{u}_1 = \lambda_1 \mathbf{u}_1 &\Rightarrow \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 1,7 \begin{bmatrix} x \\ y \end{bmatrix} \\ &\Rightarrow \begin{cases} x + 0,7y = 1,7x, \\ 0,7x + y = 1,7y. \end{cases} \\ &\Rightarrow \begin{cases} 0,7y = 0,7x, \\ 0,7x = 0,7y. \end{cases} \\ &\Rightarrow \begin{cases} y = x, \\ x = y. \end{cases} \end{aligned}$$

$$\therefore V(1,7) = \left\{ \begin{bmatrix} x \\ x \end{bmatrix} : x \in \mathbb{R}^* \right\}.$$

Por outro lado, o conjunto $V(\lambda_2)$ dos autovetores associados ao autovalor $\lambda_2 = 0,3$ é o conjunto dos vetores $\mathbf{u}_2 = \begin{bmatrix} x & y \end{bmatrix}^\top$ tal que

Exemplo 4.5

$$\begin{aligned}
\Sigma \mathbf{u}_2 = \lambda_2 \mathbf{u}_2 &\Rightarrow \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 0,3 \begin{bmatrix} x \\ y \end{bmatrix} \\
&\Rightarrow \begin{cases} x + 0,7y = 0,3x, \\ 0,7x + y = 0,3y. \end{cases} \\
&\Rightarrow \begin{cases} 0,7y = -0,7x, \\ 0,7x = -0,7y. \end{cases} \\
&\Rightarrow \begin{cases} y = -x, \\ x = -y. \end{cases}
\end{aligned}$$

$$\therefore V(0,3) = \left\{ \begin{bmatrix} x \\ -x \end{bmatrix} : x \in \mathbb{R}^* \right\}.$$

Portanto, os autovetores ortonormais $\mathbf{e}_1 \in V(1,7)$ e $\mathbf{e}_2 \in V(0,3)$ são

$$\mathbf{e}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \text{ e } \mathbf{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Pelo item (e) do Resultado 4.2, o contorno $\mathcal{C}_c$ é uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ com o eixo maior na mesma direção e sentido de $\mathbf{e}_1$ e com tamanho $2c\sqrt{\lambda_1}$ e com o eixo menor na mesma direção e sentido de $\mathbf{e}_2$ e com tamanho $2c\sqrt{\lambda_2}$. A Figura 4.12 ilustra essa situação para $c \in \{0,94; 1,62; 2,64\}$.

- (b) A matriz Σ é simétrica, então admite decomposição espectral. Calculando os autovalores:

$$\begin{aligned}
|\Sigma - \lambda \mathbf{I}_2| = 0 &\Rightarrow \begin{vmatrix} 1 - \lambda & -0,7 \\ -0,7 & 1 - \lambda \end{vmatrix} = 0 \\
&\Rightarrow (1 - \lambda)^2 - 0,49 = 0 \\
&\Rightarrow (1 - \lambda)^2 = 0,49 \\
&\Rightarrow \lambda_1 = 1,7 \text{ e } \lambda_2 = 0,3.
\end{aligned}$$

Exemplo 4.5

Logo, o conjunto $V(\lambda_1)$ dos autovetores associados ao autovalor $\lambda_1 = 1,7$ é o conjunto dos vetores $\mathbf{u}_1 = \begin{bmatrix} x & y \end{bmatrix}^\top$ tal que

$$\begin{aligned}\Sigma \mathbf{u}_1 &= \lambda_1 \mathbf{u}_1 \Rightarrow \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 1,7 \begin{bmatrix} x \\ y \end{bmatrix} \\ &\Rightarrow \begin{cases} x - 0,7y = 1,7x, \\ -0,7x + y = 1,7y. \end{cases} \\ &\Rightarrow \begin{cases} -0,7y = 0,7x, \\ -0,7x = 0,7y. \end{cases} \\ &\Rightarrow \begin{cases} y = -x, \\ x = -y. \end{cases}\end{aligned}$$

$$\therefore V(1,7) = \left\{ \begin{bmatrix} x \\ -x \end{bmatrix} : x \in \mathbb{R}^* \right\}.$$

Por outro lado, o conjunto $V(\lambda_2)$ dos autovetores associados ao autovalor $\lambda_2 = 0,3$ é o conjunto dos vetores $\mathbf{u}_2 = \begin{bmatrix} x & y \end{bmatrix}^\top$ tal que

$$\begin{aligned}\Sigma \mathbf{u}_2 &= \lambda_2 \mathbf{u}_2 \Rightarrow \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 0,3 \begin{bmatrix} x \\ y \end{bmatrix} \\ &\Rightarrow \begin{cases} x - 0,7y = 0,3x, \\ -0,7x + y = 0,3y. \end{cases} \\ &\Rightarrow \begin{cases} -0,7y = -0,7x, \\ -0,7x = -0,7y. \end{cases} \\ &\Rightarrow \begin{cases} y = x, \\ x = y. \end{cases}\end{aligned}$$

$$\therefore V(0,3) = \left\{ \begin{bmatrix} x \\ x \end{bmatrix} : x \in \mathbb{R}^* \right\}.$$

Exemplo 4.5

Portanto, os autovetores ortonormais $\mathbf{e}_1 \in V(1, 7)$ e $\mathbf{e}_2 \in V(0, 3)$ são

$$\mathbf{e}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \text{ e } \mathbf{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

Pelo item (e) do Resultado 4.2, o contorno $\mathcal{C}_c$ é uma elipse centrada em $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$ com o eixo maior na mesma direção e sentido de $\mathbf{e}_1$ e com tamanho $2c\sqrt{\lambda_1}$ e com o eixo menor na mesma direção e sentido de $\mathbf{e}_2$ e com tamanho $2c\sqrt{\lambda_2}$. A Figura 4.13 ilustra essa situação para $c \in \{0,94; 1,62; 2,64\}$.




Figura 4.12. Contornos $\mathcal{C}_c$ da densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & 0,7 \\ 0,7 & 1 \end{bmatrix} \right)$ para $c \in \{0,94; 1,62; 2,64\}$.




Figura 4.13. Contornos $\mathcal{C}_c$ da densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 1 & -0,7 \\ -0,7 & 1 \end{bmatrix} \right)$ para $c \in \{0,94; 1,62; 2,64\}$.

O Exemplo 4.5 ilustram duas situações envolvendo contornos de funções de densidade de probabilidade de vetores aleatórios com distribuição normal bivariada:

- Se $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} \right)$ com $\rho_{12} > 0$, então, para um valor plausível de $c \geq 0$ fixado, o contorno da f.d.p. de $\mathbf{X}$ é um elipse centrada em $\boldsymbol{\mu}$ com eixo maior com mesma direção e sentido do autovetor ortonormal $\mathbf{e}_1$ de $\boldsymbol{\Sigma}$ e com tamanho $2c\sqrt{\lambda_1}$, em que λ_1 é o maior autovalor e está associado com $\mathbf{e}_1$, e com eixo menor com mesma direção e sentido do autovetor ortonormal $\mathbf{e}_2$ de $\boldsymbol{\Sigma}$ e com tamanho $2c\sqrt{\lambda_2}$, em que λ_2 é o menor autovalor e está associado com $\mathbf{e}_2$.
- Se $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}, \begin{bmatrix} \sigma_{11} & \sigma_{12} \\ \sigma_{21} & \sigma_{22} \end{bmatrix} \right)$ com $\rho_{12} < 0$, então, para um valor plausível de $c \geq 0$ fixado, o contorno da f.d.p. de $\mathbf{X}$ é um elipse centrada em $\boldsymbol{\mu}$ com eixo maior com mesma direção e sentido do autovetor ortonormal $\mathbf{e}_1$ de $\boldsymbol{\Sigma}$ e com tamanho $2c\sqrt{\lambda_1}$, em que λ_1 é o maior autovalor e está associado com $\mathbf{e}_1$, e com eixo menor com mesma direção e sentido do autovetor ortonormal $\mathbf{e}_2$ de $\boldsymbol{\Sigma}$ e com tamanho $2c\sqrt{\lambda_2}$, em que λ_2 é o menor autovalor e está associado com $\mathbf{e}_2$.

A densidade da distribuição normal bivariada atinge seu valor máximo quando a *distância estatística* é zero, ou seja, quando $\mathbf{x} = \boldsymbol{\mu}$. Portanto, o vetor $\boldsymbol{\mu}$ é o **ponto de maior densidade** da distribuição (isto é, a *moda*) e, ao mesmo tempo, representa o *valor esperado* do vetor aleatório $\mathbf{X}$, ou seja, a *média multivariada*. O fato de $\boldsymbol{\mu}$ ser a média da distribuição Normal multivariada decorre da **simetria** das curvas de nível da função densidade: esses contornos de densidade constante são centrados em $\boldsymbol{\mu}$, o que mostra que $\boldsymbol{\mu}$ está no “equilíbrio” da distribuição.

4.3 Densidade e propriedades da normal multivariada

A função densidade da distribuição normal multivariada é obtida a partir da densidade univariada substituindo o quadrado da distância estatística univariada $\frac{(x-\mu)^2}{\sigma^2}$ pelo quadrado da distância estatística multivariada

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}),$$

que leva em conta tanto a variabilidade de cada componente quanto a covariância entre eles. Ao fazer essa substituição, também é necessário adaptar a constante de normalização. No caso univariado, a constante é $(2\pi)^{-1/2} \sigma^{-1}$, e garante que a área sob a curva da densidade seja 1. No caso multivariado, essa constante deve garantir que o *volume* sob a superfície da densidade seja igual a 1. Para isso, a constante apropriada é

$$(2\pi)^{-p/2} |\boldsymbol{\Sigma}|^{-1/2},$$

Definição 4.3: Distribuição normal multivariada

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$ definida positiva. Dizemos que $\mathbf{X}$ possui *distribuição normal p -variada* quando sua função de densidade de probabilidade é a função $f : \mathbb{R}^p \rightarrow [0, +\infty[$ tal que

$$f(\mathbf{x}) = f(x_1, x_2, \dots, x_p) = \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right] \times \mathbb{I}_{\mathbb{R}^p}(\mathbf{x}).$$

Denotamos essa distribuição como $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, em analogia à notação univariada $\text{Normal}(\mu, \sigma^2)$.

Embora tenhamos desenvolvido toda a intuição geométrica no caso bivariado ($p = 2$), as ideias apresentadas se estendem naturalmente para dimensões maiores, isto é, para

o caso geral da distribuição Normal p -variada. Quando $p \geq 3$, continuamos tendo contornos de densidade constante descritos por elipsoides centrados no vetor de médias $\boldsymbol{\mu}$, cujos eixos principais estão nas direções dos autovetores da matriz de covariâncias $\boldsymbol{\Sigma}$, com comprimentos proporcionais à raiz quadrada dos autovalores. Por exemplo, quando $\mathbf{X}$ é uma normal trivariada ($p = 3$), o contorno é um elipsóide no espaço tridimensional como mostra a Figura 4.14.




Figura 4.14. Contornos $\mathcal{C}_c$ da densidade de probabilidade do vetor aleatório $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

Contudo, em casos de maior dimensão ($p > 3$), perdemos parte do apelo geométrico, pois não conseguimos mais visualizar diretamente essas elipses (ou elipsóides). Ainda assim, as propriedades analíticas e algébricas permanecem válidas e fundamentais para aplicações práticas em Estatística Multivariada.

Ao longo da disciplina, precisaremos usar frequentemente algumas propriedades importantes da distribuição normal. Essas propriedades são úteis porque facilitam a manipulação matemática dessa distribuição, o que contribui bastante para sua popularidade na Estatística.

A seguir, listamos quatro propriedades fundamentais de um vetor aleatório $\mathbf{X}$ com distribuição normal multivariada. Elas nos ajudam a entender o comportamento das combinações lineares, subconjuntos e distribuições condicionais de variáveis normalmente distribuídas:

1. Combinações lineares dos componentes de $\mathbf{X}$ também são normalmente distribuídas.
2. Qualquer subconjunto dos componentes de $\mathbf{X}$ possui distribuição normal (isto é, a normalidade multivariada é preservada em subconjuntos).

3. Se dois componentes de $\mathbf{X}$ têm covariância zero, então eles são independentemente distribuídos (o que, no caso normal, é uma equivalência rara e poderosa).
4. As distribuições condicionais dos componentes de $\mathbf{X}$, dado um subconjunto dos demais, também seguem uma distribuição normal (ou normal multivariada, dependendo do número de variáveis condicionadas).

Algumas dessas propriedades serão demonstradas a seguir. Essas demonstrações não apenas fortalecem a intuição sobre o comportamento da normal multivariada, como também ajudam a praticar manipulações com vetores e matrizes. De maneira prática, a propriedade 1 (sobre combinações lineares) pode ser considerada uma definição operacional da normal multivariada. Por isso vamos assumi-la sem demonstração neste texto. A partir dela, as demais propriedades se tornam mais fáceis de compreender e demonstrar. Ao explorarmos essas propriedades, entenderemos como a forma funcional da densidade normal multivariada está relacionada às combinações lineares dos seus componentes.

Resultado 4.3

Suponha que o vetor aleatório $\mathbf{X}$ segue uma distribuição normal multivariada de dimensão p , isto é, $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Então, qualquer combinação linear dos componentes de $\mathbf{X}$, da forma $\mathbf{a}^\top \mathbf{X} = a_1 X_1 + a_2 X_2 + \cdots + a_p X_p$, tem distribuição normal univariada com média $\mathbf{a}^\top \boldsymbol{\mu}$ e variância $\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}$. Ou seja,

$$\mathbf{a}^\top \mathbf{X} \sim N(\mathbf{a}^\top \boldsymbol{\mu}, \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}), \quad \text{para qualquer vetor } \mathbf{a} \in \mathbb{R}^p.$$

Além disso, a recíproca também é verdadeira: se $\mathbf{a}^\top \mathbf{X}$ tem distribuição normal univariada para todo vetor $\mathbf{a} \in \mathbb{R}^p$, então $\mathbf{X}$ tem distribuição normal multivariada com média $\boldsymbol{\mu}$ e matriz de covariância $\boldsymbol{\Sigma}$, isto é,

$$\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}).$$

SOBRE A DEMONSTRAÇÃO:

A média e a variância de $\mathbf{a}^\top \mathbf{X}$ podem ser obtidas diretamente das propriedades de valor esperado e variância para transformações lineares, i.e.,

$$\mathbb{E}[\mathbf{a}^\top \mathbf{X}] = \mathbf{a}^\top \boldsymbol{\mu}, \quad \text{Var}(\mathbf{a}^\top \mathbf{X}) = \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}.$$

Mostrar que $\mathbf{a}^\top \mathbf{X}$ é normalmente distribuída quando $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ exige um pouco mais de trabalho, mas essa é uma propriedade central da distribuição normal multivariada. Já a parte recíproca – de que a normalidade de todas as combinações

Resultado 4.3

lineares implica a normalidade multivariada – é uma forma alternativa de definir a distribuição normal multivariada. ■

Esse resultado é fundamental porque mostra como a estrutura da normal multivariada pode ser entendida por meio de projeções (combinações lineares) dos seus componentes. É a base para muitas técnicas estatísticas multivariadas.

Exemplo 4.6

Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^p$ e $\mathbf{a} \in \mathbb{R}^p$ um vetor de constantes. Considere a combinação linear $\mathbf{a}^\top \mathbf{X}$ de modo que o vetor aleatório $\mathbf{X}$ tenha distribuição normal multivariada com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$, em que escolhemos o vetor $\mathbf{a}^\top = [1, 0, \dots, 0]$. Determine a distribuição da combinação linear $\mathbf{a}^\top \mathbf{X}$.

SOLUÇÃO:

Neste caso, temos

$$\mathbf{a}^\top \mathbf{X} = [1, 0, \dots, 0] \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = X_1$$

Ou seja, a combinação linear reduz-se a apenas um componente do vetor $\mathbf{X}$. Vamos agora verificar a média e a variância dessa combinação linear:

$$\mathbf{a}^\top \boldsymbol{\mu} = [1, 0, \dots, 0] \begin{bmatrix} \mu_1 \\ \mu_2 \\ \vdots \\ \mu_p \end{bmatrix} = \mu_1$$

e

$$\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a} = [1, 0, \dots, 0] \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1p} \\ \sigma_{12} & \sigma_{22} & \cdots & \sigma_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{1p} & \sigma_{2p} & \cdots & \sigma_{pp} \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \sigma_{11}$$

Exemplo 4.6

Portanto, pelo Resultado 4.3, concluímos que

$$X_1 \sim \text{Normal}(\mu_1, \sigma_{11}).$$

Ou seja, qualquer componente individual X_i de um vetor $\mathbf{X} \sim N_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ segue uma distribuição normal univariada com média μ_i e variância σ_{ii} , i.e.,

$$X_i \sim \text{Normal}(\mu_i, \sigma_{ii}).$$

O Exemplo 4.3 mostra como o Resultado 4.2 pode ser usado para obter diretamente a distribuição marginal de qualquer componente de um vetor normal multivariado.

Resultado 4.4

Se $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, então as q combinações lineares definidas por

$$\mathbf{AX} = \begin{bmatrix} a_{11} & \cdots & a_{1p} \\ a_{21} & \cdots & a_{2p} \\ \vdots & \ddots & \vdots \\ a_{q1} & \cdots & a_{qp} \end{bmatrix} \begin{bmatrix} X_1 \\ X_2 \\ \vdots \\ X_p \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^p a_{1j} X_j \\ \sum_{j=1}^p a_{2j} X_j \\ \vdots \\ \sum_{j=1}^p a_{qj} X_j \end{bmatrix}$$

são distribuídas como

$$\mathbf{AX} \sim \text{Normal}_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

Além disso, se somarmos um vetor de constantes $\mathbf{d} \in \mathbb{R}^p$ ao vetor $\mathbf{X}$, temos

$$\mathbf{X} + \mathbf{d} \sim \text{Normal}_p(\boldsymbol{\mu} + \mathbf{d}, \boldsymbol{\Sigma}).$$

DEMONSTRAÇÃO:

O valor esperado de $\mathbf{AX}$ é

$$\mathbb{E}(\mathbf{AX}) = \mathbf{A} \mathbb{E}(\mathbf{X}) = \mathbf{A}\boldsymbol{\mu},$$

e a matriz de covariância de $\mathbf{AX}$ é

$$\text{Cov}(\mathbf{AX}) = \mathbf{A} \text{Cov}(\mathbf{X}) \mathbf{A}^\top = \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top.$$

Como cada entrada de $\mathbf{AX}$ é uma combinação linear de componentes do

Resultado 4.4

vetor aleatório $\mathbf{X}$, segue, pelo resultado 4.2, que essa entrada é normalmente distribuída. Assim, todas as componentes de $\mathbf{A}\mathbf{X}$ são normalmente distribuídas o que implica, pelo resultado 4.2, que o vetor de combinações lineares $\mathbf{A}\mathbf{X}$ é normalmente distribuído.

Para a segunda parte, observe que

$$\mathbf{X} + \mathbf{d} = \begin{bmatrix} X_1 + d_1 \\ X_2 + d_2 \\ \vdots \\ X_p + d_p \end{bmatrix}.$$

Como $X_i \sim \text{Normal}(\mu_i, \sigma_{ii})$, temos $X_i + d_i \sim \text{Normal}(\mu_i + d_i, \sigma_{ii})$, para todo $i = 1, 2, \dots, p$. Logo, cada componente do vetor $\mathbf{X} + \mathbf{d}$ é normalmente distribuído. Portanto,

$$\mathbf{X} + \mathbf{d} \sim \text{Normal}_p(\boldsymbol{\mu} + \mathbf{d}, \boldsymbol{\Sigma})$$

■

Exemplo 4.7

Seja $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com

$$\boldsymbol{\mu} = \mathbf{0}_3, \quad \boldsymbol{\Sigma} = \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & 0 \\ -1 & 0 & 2 \end{bmatrix}.$$

Encontre a distribuição do vetor aleatório

$$\mathbf{Y} = \begin{bmatrix} X_1 - X_2 \\ X_2 - X_3 \end{bmatrix}.$$

SOLUÇÃO:

Note que $\mathbf{Y}$ é um vetor de combinações linear das componentes de $\mathbf{X}$. Podemos reescrevê-lo como

$$\mathbf{Y} = \mathbf{A}\mathbf{X}, \quad \text{com} \quad \mathbf{A} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix}.$$

Como $\mathbf{X}$ é normal multivariada e $\mathbf{Y}$ é uma transformação linear de $\mathbf{X}$, então $\mathbf{Y}$

Exemplo 4.7

também é normal multivariada. Pela regra de transformação, temos:

$$\mathbf{Y} \sim \text{Normal}_2(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top).$$

Vamos agora determinar o vetor de médias dessa transformação linear:

$$\mathbf{A}\boldsymbol{\mu} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \mathbf{0}_3 = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

Agora, para determinar a matriz de variâncias e covariâncias da transformação linear, vamos calcular primeiro $\mathbf{A}\boldsymbol{\Sigma}$:

$$\begin{aligned} \mathbf{A}\boldsymbol{\Sigma} &= \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \end{bmatrix} \begin{bmatrix} 2 & 1 & -1 \\ 1 & 2 & 0 \\ -1 & 0 & 2 \end{bmatrix} \\ &= \begin{bmatrix} 1 & -1 & -1 \\ 2 & 2 & -2 \end{bmatrix}. \end{aligned}$$

Agora, multiplicamos pelo transposto de $\mathbf{A}$:

$$\begin{aligned} \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top &= \begin{bmatrix} 1 & -1 & -1 \\ 2 & 2 & -2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -1 & 1 \\ 0 & -1 \end{bmatrix} \\ &= \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix}. \end{aligned}$$

Portanto, o vetor aleatório $\mathbf{Y}$ segue distribuição

$$\mathbf{Y} \sim \text{Normal}_2 \left(\begin{bmatrix} 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 4 \end{bmatrix} \right).$$

Já mencionamos no início desta seção que qualquer subconjunto das componentes de um vetor aleatório com distribuição normal multivariada possui também distribuição normal multivariada. No Resultado 4.5, enunciamos e provamos formalmente esta propriedade.

Resultado 4.5

Seja $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}, \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix}$$

então

$$\mathbf{X}^{(1)} \sim \text{Normal}_q(\boldsymbol{\mu}^{(1)}, \boldsymbol{\Sigma}_{11}).$$

Especificamente, o vetor formado pelas q primeiras componentes de $\mathbf{X}$, aqui denotado por $\mathbf{X}^{(1)}$, possui distribuição normal com vetor de médias dado por $\boldsymbol{\mu}^{(1)}$ e matriz de covariâncias $\boldsymbol{\Sigma}_{11}$.

DEMONSTRAÇÃO:

Considere a matriz

$$\mathbf{A} = \begin{bmatrix} \mathbf{I}_{q \times q} & \mathbf{O}_{q \times (p-q)} \end{bmatrix}.$$

Aplicando o Resultado 4.4, que afirma que qualquer transformação linear de um vetor normal multivariado resulta em outro vetor normal multivariado, concluímos que

$$\mathbf{AX} = \mathbf{X}^{(1)} \sim \text{Normal}_q(\mathbf{A}\boldsymbol{\mu}, \mathbf{A}\boldsymbol{\Sigma}\mathbf{A}^\top) = \text{Normal}_q(\boldsymbol{\mu}^{(1)}, \boldsymbol{\Sigma}_{11}).$$

■

O Resultado 4.5 é válido para qualquer subconjunto arbitrário das componentes de $\mathbf{X}$. Se o subconjunto de interesse não corresponder às q primeiras componentes, basta reordenar as variáveis para aplicar o resultado acima.

Exemplo 4.8

Seja $\mathbf{X} \sim \text{Normal}_5(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}, \quad \boldsymbol{\Sigma} = \begin{bmatrix} 2 & 1 & 1 & 1 & 1 \\ 1 & 2 & 1 & 1 & 1 \\ 1 & 1 & 2 & 1 & 1 \\ 1 & 1 & 1 & 2 & 1 \\ 1 & 1 & 1 & 1 & 2 \end{bmatrix}.$$

Exemplo 4.8

Determine a distribuição conjunta das componentes $\mathbf{X}_2$ e $\mathbf{X}_4$, ou seja, do vetor aleatório $\mathbf{X}^{(1)} = \begin{bmatrix} X_2 \\ X_4 \end{bmatrix}$.

SOLUÇÃO:

Para isso, vamos aplicar o resultado de marginalização da normal multivariada. Primeiro, identificamos os elementos correspondentes nas posições 2 e 4 do vetor de médias:

$$\boldsymbol{\mu}^{(1)} = \begin{bmatrix} \mu_2 \\ \mu_4 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Em seguida, selecionamos os elementos da matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$ que correspondem às posições (2,2), (2,4), (4,2) e (4,4). Isso nos fornece a submatriz de covariâncias $\boldsymbol{\Sigma}_{11}$ associada ao vetor $\mathbf{X}^{(1)} = \begin{bmatrix} X_2 \\ X_4 \end{bmatrix}$. Em outras palavras,

$$\boldsymbol{\Sigma}_{11} = \begin{bmatrix} \Sigma_{22} & \Sigma_{24} \\ \Sigma_{42} & \Sigma_{44} \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}.$$

Portanto, pelo Resultado 4.5,

$$\begin{bmatrix} X_2 \\ X_4 \end{bmatrix} \sim \text{Normal}_2 \left(\begin{bmatrix} 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix} \right).$$

Um dos aspectos mais impressionantes da distribuição normal multivariada é a equivalência entre ausência de correlação e independência. Em geral, para distribuições arbitrárias, dizer que duas variáveis aleatórias não são correlacionadas (ou seja, possuem covariância nula) está longe de ser suficiente para garantir que sejam independentes. No entanto, no caso da normal multivariada, essa equivalência de conceitos, que normalmente são distintos, torna-se válida. Essa propriedade não apenas simplifica diversas análises, mas também fornece uma ferramenta extremamente poderosa para identificar independência a partir da matriz de variâncias e covariâncias. A seguir, formalizamos esse resultado.

Resultado 4.6

Sejam $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ dois vetores aleatórios, com dimensões $q_1 \times 1$ e $q_2 \times 1$, respectivamente.

Resultado 4.6

(a) Se $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes, então

$$Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) = \mathbf{O},$$

uma matriz $q_1 \times q_2$ de zeros.

(b) Se

$$\begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \sim \text{Normal}_{q_1+q_2} \left(\begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right),$$

então $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes se, e somente se, $\boldsymbol{\Sigma}_{12} = \mathbf{O}$.

(c) Se $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes e seguem distribuições $\text{Normal}_{q_1}(\boldsymbol{\mu}^{(1)}, \boldsymbol{\Sigma}_{11})$ e $\text{Normal}_{q_2}(\boldsymbol{\mu}^{(2)}, \boldsymbol{\Sigma}_{22})$, respectivamente, então

$$\begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \sim \text{Normal}_{q_1+q_2} \left(\begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \mathbf{O} \\ \mathbf{O} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right).$$

DEMONSTRAÇÃO:

(a) Essa afirmação decorre diretamente da definição de independência. Quando $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes, qualquer função mensurável de $\mathbf{X}^{(1)}$ é independente de qualquer função mensurável de $\mathbf{X}^{(2)}$. Em particular, a covariância entre componentes de $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ é nula, o que implica que $Cov(\mathbf{X}^{(1)}, \mathbf{X}^{(2)}) = \mathbf{O}$.

(b) A ida segue diretamente do item (a). Dessa forma, vamos focar em demonstrar a volta. Para isso, suponha que $\boldsymbol{\Sigma}_{12} = \mathbf{O}$. Como $\boldsymbol{\Sigma}$ é uma matriz de covariâncias, temos

$$\boldsymbol{\Sigma} = \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \mathbf{O} \\ \mathbf{O} & \boldsymbol{\Sigma}_{22} \end{bmatrix}.$$

Assim, a densidade conjunta de $\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix}$ pode ser escrita como

$$f_{\mathbf{X}^{(1)}, \mathbf{X}^{(2)}}(\mathbf{x}_1, \mathbf{x}_2) = \frac{1}{(2\pi)^{(q_1+q_2)/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}) \right\}$$

Resultado 4.6

$$= \frac{1}{(2\pi)^{q_1/2} |\Sigma_{11}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_1 - \boldsymbol{\mu}^{(1)})^\top \Sigma_{11}^{-1} (\mathbf{x}_1 - \boldsymbol{\mu}^{(1)}) \right\} \\ \times \frac{1}{(2\pi)^{q_2/2} |\Sigma_{22}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_2 - \boldsymbol{\mu}^{(2)})^\top \Sigma_{22}^{-1} (\mathbf{x}_2 - \boldsymbol{\mu}^{(2)}) \right\}.$$

Portanto,

$$f_{\mathbf{X}^{(1)}, \mathbf{X}^{(2)}}(\mathbf{x}_1, \mathbf{x}_2) = f_{\mathbf{X}^{(1)}}(\mathbf{x}_1) f_{\mathbf{X}^{(2)}}(\mathbf{x}_2).$$

Como a densidade conjunta fatorou no produto das densidades marginais, concluímos que $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ são independentes.

(c) Segue diretamente do item (b). ■

Exemplo 4.9

Considere o vetor aleatório $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \Sigma)$, com matriz de variâncias e covariâncias dada por

$$\Sigma = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

Verifique se X_1 e X_2 são independentes e se o vetor aleatório $[X_1 \ X_2]^\top$ é independente da variável X_3 ?

SOLUÇÃO:

Observamos que $\text{Cov}(X_1, X_2) = 1 \neq 0$, portanto X_1 e X_2 não são independentes. Agora, vamos analisar a independência entre o vetor aleatório $[X_1 \ X_2]^\top$ e a variável X_3 . Para isso, particionamos o vetor $\mathbf{X}$ e a matriz Σ da seguinte maneira

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} = \begin{bmatrix} 4 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

Exemplo 4.9

Aqui, o vetor

$$\mathbf{X}^{(1)} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}, \quad \mathbf{X}^{(2)} = X_3,$$

e a matriz de covariâncias entre $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ é $\Sigma_{12} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$. Como a distribuição conjunta é normal e a covariância entre os blocos $\mathbf{X}^{(1)}$ e $\mathbf{X}^{(2)}$ é nula, o Resultado 4.6 nos garante que X_3 é independente o vetor aleatório $\begin{bmatrix} X_1 & X_2 \end{bmatrix}^\top$. Consequentemente, X_3 é também independente de X_1 e de X_2 individualmente.

Esse exemplo ilustra a força da distribuição normal multivariada, pois, embora X_1 e X_2 sejam correlacionadas e, portanto, não independentes, a ausência de correlação com X_3 nos permite concluir sua independência com o par.

Iniciamos este capítulo com um exemplo no qual lidamos com um vetor aleatório cuja distribuição era normal bivariada cujas componentes eram independentes (veja novamente o Exemplo 4.1). Note que as conclusões obtidas com o exemplo são um caso particular das afirmações feitas no Resultado 4.6. Tente por si só verificar essa particularidade.

Resultado 4.7

Seja

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \sim \text{Normal}_p \left(\begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix} \right),$$

com $|\Sigma_{22}| > 0$. Então a distribuição condicional de $\mathbf{X}^{(1)}$ dado que $\mathbf{X}^{(2)} = \mathbf{x}^{(2)}$ é normal com vetor de médias dado por $\boldsymbol{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)})$ e matriz de variâncias e covariâncias $\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$.

DEMONSTRAÇÃO:

Vamos utilizar uma prova indireta. Definimos a matriz

$$\mathbf{A} = \begin{bmatrix} \mathbf{I} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{O} & \mathbf{I} \end{bmatrix},$$

e aplicamos a transformação $\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})$. Como

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \quad \text{e} \quad \boldsymbol{\mu} = \begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix},$$

Resultado 4.7

$$A(\mathbf{X} - \boldsymbol{\mu}) = \begin{bmatrix} \mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)}) \\ \mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)} \end{bmatrix}.$$

Como $\mathbf{X}$ tem distribuição normal e a transformação é linear, o vetor transformado continua tendo distribuição normal. A matriz de variâncias e covariâncias do vetor transformado é dada por $A\boldsymbol{\Sigma}A^\top$. Logo,

$$A\boldsymbol{\Sigma}A^\top = \begin{bmatrix} \boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21} & \mathbf{O} \\ \mathbf{O} & \boldsymbol{\Sigma}_{22} \end{bmatrix}.$$

Os blocos fora da diagonal são nulos, o que mostra que os vetores $\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})$ e $\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)}$ são independentes. Como $\mathbf{x}^{(2)}$ é um valor fixo, a expressão $\boldsymbol{\mu}^{(1)} + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)})$ é uma constante. Portanto, a distribuição condicional de $\mathbf{X}^{(1)}$ dado que $\mathbf{X}^{(2)} = \mathbf{x}^{(2)}$ coincide com a distribuição do vetor $\mathbf{X}^{(1)} - \boldsymbol{\mu}^{(1)} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{X}^{(2)} - \boldsymbol{\mu}^{(2)})$, isto é, segue uma distribuição normal com vetor de médias $\boldsymbol{\mu}^{(1)} + \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)})$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12}\boldsymbol{\Sigma}_{22}^{-1}\boldsymbol{\Sigma}_{21}$. ■

Exemplo 4.10

(a) Determine a distribuição condicional de X_1 , dado que $X_2 = x_2$ quando $\mathbf{X} \sim \text{Normal}_2 \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \right)$.

(b) Determine a distribuição condicional de X_2 , dado que $X_3 = x_3$ quando $\mathbf{X} \sim \text{Normal}_3 \left(\begin{bmatrix} -3 \\ 1 \\ 4 \end{bmatrix}, \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix} \right)$.

(c) Determine a distribuição condicional de X_3 , dado que $X_1 = x_1$ e $X_2 = x_2$ quando $\mathbf{X} \sim \text{Normal}_3 \left(\begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 2 \end{bmatrix} \right)$.

SOLUÇÃO:

Exemplo 4.10

(a) Seja

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix} \sim \text{Normal}_2 \left(\begin{bmatrix} 0 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix} \right).$$

Queremos a distribuição condicional de X_1 dado que $X_2 = x_2$. Para isso, usamos o fato de que

$$\boldsymbol{\mu}^{(1)} = 0, \quad \boldsymbol{\mu}^{(2)} = 2, \quad \Sigma_{11} = 2, \quad \Sigma_{12} = 0, \quad \Sigma_{22} = 1.$$

Logo, o vetor de médias condicional é

$$\boldsymbol{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)}) = 0 + 0 \cdot 1^{-1}(x_2 - 2) = 0,$$

e a variância condicional é

$$\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = 2 - 0 \cdot 1^{-1} \cdot 0 = 2.$$

Portanto,

$$X_1 \mid X_2 = x_2 \sim \text{Normal}(0, 2).$$

(b) Seja

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim \text{Normal}_3 \left(\begin{bmatrix} -3 \\ 1 \\ 4 \end{bmatrix}, \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix} \right).$$

Queremos a distribuição condicional de X_2 dado que $X_3 = x_3$. Para isso, definimos

$$\mathbf{X}^{(1)} = X_2, \quad \mathbf{X}^{(2)} = X_3,$$

com

$$\boldsymbol{\mu}^{(1)} = 1, \quad \boldsymbol{\mu}^{(2)} = 4, \quad \Sigma_{11} = 5, \quad \Sigma_{12} = 0, \quad \Sigma_{22} = 2.$$

Logo, o vetor de médias condicional é

$$\boldsymbol{\mu}^{(1)} + \Sigma_{12}\Sigma_{22}^{-1}(\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)}) = 1 + 0 \cdot 2^{-1}(x_3 - 4) = 1,$$

e a variância condicional é

$$\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} = 5 - 0 \cdot 2^{-1} \cdot 0 = 5.$$

Exemplo 4.10

Portanto,

$$X_2 \mid X_3 = x_3 \sim \text{Normal}(1, 5).$$

(c) Seja

$$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \\ X_3 \end{bmatrix} \sim \text{Normal}_3 \left(\begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 2 \end{bmatrix} \right).$$

Queremos a distribuição condicional de X_3 dado que $X_1 = x_1$ e $X_2 = x_2$. Para isso, definimos

$$\mathbf{X}^{(1)} = X_3, \quad \mathbf{X}^{(2)} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix},$$

com

$$\boldsymbol{\mu}^{(1)} = 1, \quad \boldsymbol{\mu}^{(2)} = \begin{bmatrix} 2 \\ -3 \end{bmatrix}, \quad \Sigma_{11} = 2, \quad \Sigma_{12} = \begin{bmatrix} 1 & 2 \end{bmatrix}, \quad \Sigma_{22} = \begin{bmatrix} 1 & 1 \\ 1 & 3 \end{bmatrix}.$$

Calculamos a inversa de Σ_{22} , i.e.,

$$\Sigma_{22}^{-1} = \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix}.$$

O vetor de médias condicional é dado por

$$\begin{aligned} \boldsymbol{\mu}^{(1)} + \Sigma_{12} \Sigma_{22}^{-1} (\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)}) &= 1 + \begin{bmatrix} 1 & 2 \end{bmatrix} \cdot \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} - \begin{bmatrix} 2 \\ -3 \end{bmatrix} \right) \\ &= 1 + \frac{1}{2} \begin{bmatrix} 1 & 2 \end{bmatrix} \left(\begin{bmatrix} 3(x_1 - 2) - (x_2 + 3) \\ -1(x_1 - 2) + (x_2 + 3) \end{bmatrix} \right) \\ &= 1 + \frac{1}{2} \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3x_1 - x_2 - 9 \\ -x_1 + x_2 + 5 \end{bmatrix} \\ &= 1 + \frac{1}{2} (3x_1 - x_2 - 9 - 2x_1 + 2x_2 + 10) \\ &= 1 + \frac{1}{2} (x_1 + x_2 + 1) = \frac{1}{2} (x_1 + x_2 + 3). \end{aligned}$$

A variância condicional é

Exemplo 4.10

$$\begin{aligned}
\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} &= 2 - \begin{bmatrix} 1 & 2 \end{bmatrix} \cdot \frac{1}{2} \begin{bmatrix} 3 & -1 \\ -1 & 1 \end{bmatrix} \cdot \begin{bmatrix} 1 \\ 2 \end{bmatrix} \\
&= 2 - \frac{1}{2} \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 3 \cdot 1 + (-1) \cdot 2 \\ -1 \cdot 1 + 1 \cdot 2 \end{bmatrix} = 2 - \frac{1}{2} \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \end{bmatrix} \\
&= 2 - \frac{1}{2}(1 + 2) = 2 - \frac{3}{2} = \frac{1}{2}.
\end{aligned}$$

Portanto,

$$X_3 \mid X_1 = x_1, X_2 = x_2 \sim \text{Normal}\left(\frac{1}{2}(x_1 + x_2 + 3), \frac{1}{2}\right).$$

O próximo resultado é essencial para analisar a plausibilidade de se supor que uma amostra foi coletada de uma distribuição normal multivariada e também para detectar *outliers* nessa amostra.

Resultado 4.8

Seja $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \Sigma)$, com Σ positiva definida. Então as seguintes afirmações são verdadeiras:

(a)

$$(\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{X} - \boldsymbol{\mu}) \sim \chi_p^2.$$

(b) Para todo $\alpha \in (0, 1)$,

$$P\left((\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{X} - \boldsymbol{\mu}) \leq \chi_p^2(\alpha)\right) = 1 - \alpha,$$

em que $\chi_p^2(\alpha)$ é o percentil superior de ordem $100\alpha\%$ da distribuição qui-quadrado com p graus de liberdade.

DEMONSTRAÇÃO:

(a) Como Σ é simétrica e positiva definida, pela decomposição espectral, existe uma matriz ortogonal $\mathbf{\Gamma}$ e uma matriz diagonal

$$\mathbf{\Lambda} = \text{diag}(\lambda_1, \dots, \lambda_p), \quad \lambda_j > 0,$$

Resultado 4.8

tais que

$$\Sigma = \Gamma \Lambda \Gamma^\top.$$

Logo,

$$\Sigma^{-1} = \Gamma \Lambda^{-1} \Gamma^\top,$$

em que

$$\Lambda^{-1} = \text{diag} \left(\frac{1}{\lambda_1}, \dots, \frac{1}{\lambda_p} \right).$$

Defina

$$\mathbf{Z} = \Lambda^{-1/2} \Gamma^\top (\mathbf{X} - \boldsymbol{\mu}),$$

em que

$$\Lambda^{-1/2} = \text{diag} \left(\frac{1}{\sqrt{\lambda_1}}, \dots, \frac{1}{\sqrt{\lambda_p}} \right).$$

Como $\mathbf{Z}$ é uma transformação linear de $\mathbf{X}$, temos

$$\mathbf{Z} \sim \text{Normal}_p(\mathbf{0}, \Lambda^{-1/2} \Gamma^\top \Sigma \Gamma \Lambda^{-1/2}).$$

Substituindo $\Sigma = \Gamma \Lambda \Gamma^\top$, obtemos

$$\begin{aligned} \text{Cov}(\mathbf{Z}) &= \Lambda^{-1/2} \Gamma^\top \Gamma \Lambda \Gamma^\top \Gamma \Lambda^{-1/2} \\ &= \Lambda^{-1/2} \Lambda \Lambda^{-1/2} \\ &= \mathbf{I}_p. \end{aligned}$$

Portanto,

$$\mathbf{Z} \sim \text{Normal}_p(\mathbf{0}, \mathbf{I}_p).$$

Assim,

$$Z_1, \dots, Z_p$$

são independentes e

$$Z_j \sim N(0, 1), \quad j = 1, \dots, p.$$

Agora,

Resultado 4.8

$$\begin{aligned}
\mathbf{Z}^\top \mathbf{Z} &= \left[\Lambda^{-1/2} \Gamma^\top (\mathbf{X} - \boldsymbol{\mu}) \right]^\top \left[\Lambda^{-1/2} \Gamma^\top (\mathbf{X} - \boldsymbol{\mu}) \right] \\
&= (\mathbf{X} - \boldsymbol{\mu})^\top \Gamma \Lambda^{-1/2} \Lambda^{-1/2} \Gamma^\top (\mathbf{X} - \boldsymbol{\mu}) \\
&= (\mathbf{X} - \boldsymbol{\mu})^\top \Gamma \Lambda^{-1} \Gamma^\top (\mathbf{X} - \boldsymbol{\mu}) \\
&= (\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu}).
\end{aligned}$$

Mas $\mathbf{Z}^\top \mathbf{Z} = \sum_{j=1}^p Z_j^2$.

Como $Z_1, \dots, Z_p$ são normais padrão independentes, segue que $\sum_{j=1}^p Z_j^2 \sim \chi_p^2$.

Portanto, $(\mathbf{X} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{X} - \boldsymbol{\mu}) \sim \chi_p^2$.

(b) Segue direto do item (a).

□

Encerramos este capítulo com uma coleção poderosa de resultados sobre a distribuição normal multivariada. Vimos que, além de sua elegância formal, ela possui propriedades que facilitam enormemente o trabalho analítico: a normalidade de marginais e condicionais, a equivalência entre independência e ausência de correlação, e expressões explícitas para médias e covariâncias condicionais. Esses resultados tornam a distribuição normal multivariada uma peça central não apenas na teoria estatística, mas também em aplicações práticas, onde modelos multivariados precisam ser interpretáveis, computacionalmente viáveis e teoricamente sólidos. A partir daqui, abrimos caminho para ferramentas ainda mais sofisticadas de inferência e redução de dimensionalidade.

4.4 Exercícios

1. Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \Sigma)$, em que

$$\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 3 \end{bmatrix} \quad \text{e} \quad \Sigma = \begin{bmatrix} 4 & 0 \\ 0 & 4 \end{bmatrix}.$$

- Escreva a expressão do quadrado da distância estatística $(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})$ como uma função quadrática de x_1 e x_2 .
- Utilize o Geogebra para plotar a densidade do vetor aleatório $\mathbf{X}$. Analise o gráfico e escolha um valor de $k \in [0, +\infty[$ tal que $f(\mathbf{x}) = f(x_1, x_2) = k$. Em outras palavras, escolha um nível.

(c) A partir do nível k determinado no item (b), determine o valor de c tal que

$$(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2.$$

(d) A partir do valor de c determinado no item anterior, construa, em um papel quadriculado, o respectivo contorno da densidade de $\mathbf{X}$.

(e) Sua resposta para o item (d) é consistente com sua resposta para o item (a).

2. Seja $\mathbf{X} \sim \text{Normal}_2(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Prove que se a matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{2 \times 2}(\mathbb{R})$ é definida positiva, então

(a) $\boldsymbol{\Sigma}^{-1}$ existe;

(b) os autovalores de $\boldsymbol{\Sigma}$ são todos positivos;

(c) se λ é um autovalor de $\boldsymbol{\Sigma}$ e $\mathbf{e}$ é o autovetor ortonormal associado, então

$$\boldsymbol{\Sigma}\mathbf{e} = \lambda\mathbf{e} \Rightarrow \boldsymbol{\Sigma}^{-1}\mathbf{e} = \frac{1}{\lambda}\mathbf{e};$$

(d) $\boldsymbol{\Sigma}^{-1}$ é definida positiva;

(e) os contornos $(\mathbf{x} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu}) = c^2$ de $\mathbf{X}$ são elipses centradas no vetor de médias $\boldsymbol{\mu}$ cujos eixos estão na direção de seus autovetores $\mathbf{e}_1$ e $\mathbf{e}_2$ de tal modo que o tamanho do eixo maior é $2c\sqrt{\lambda_1}$ e o tamanho do eixo menor é $2c\sqrt{\lambda_2}$, em que λ_1 é o maior e λ_2 o menor autovalor, associados, respectivamente, à $\mathbf{e}_1$ e $\mathbf{e}_2$.

3. Repita o Exercício 1 para o caso em que $\mathbf{X}$ possui distribuição normal bivariada com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^2$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{2 \times 2}(\mathbb{R})$ tal que

$$(a) \quad \boldsymbol{\mu} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix};$$

$$(c) \quad \boldsymbol{\mu} = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 4 & 1 \\ 1 & 1 \end{bmatrix};$$

$$(b) \quad \boldsymbol{\mu} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 4 & 0 \\ 0 & 1 \end{bmatrix};$$

$$(d) \quad \boldsymbol{\mu} = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 4 & -1 \\ -1 & 1 \end{bmatrix};$$

$$(c) \quad \boldsymbol{\mu} = \begin{bmatrix} 0 \\ 2 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 4 & 1 \\ 1 & 4 \end{bmatrix};$$

$$(e) \quad \boldsymbol{\mu} = \begin{bmatrix} 2 \\ 0 \end{bmatrix} \text{ e } \boldsymbol{\Sigma} = \begin{bmatrix} 1 & -1 \\ -1 & 4 \end{bmatrix}.$$

4. Para cada uma das densidades bivariadas $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ a seguir apresente o vetor de médias e a matriz de variâncias e covariâncias do vetor aleatório $\mathbf{X}$.

$$(a) \quad f(\mathbf{x}) = f(x_1, x_2) = \frac{1}{2\pi} \exp \left\{ -\frac{1}{2} [(x_1 - 1)^2 + (x_2 - 2)^2] \right\}.$$

$$(b) \quad f(\mathbf{x}) = f(x_1, x_2) = \frac{1}{2\pi} \exp \left[-\frac{1}{2} (x_1^2 + x_2^2 + 4x_1 - 6x_2 + 13) \right].$$

$$(c) f(\mathbf{x}) = f(x_1, x_2) = \frac{1}{2\pi} \exp \left[-\frac{1}{2} (2x_1^2 + x_2^2 + 2x_1x_2 - 22x_1 - 14x_2 + 65) \right].$$

Há itens em que as variáveis são independentes?

5. Seja $\mathbf{X}$ um vetor aleatório em $\mathbb{R}^2$ cuja função de densidade de probabilidade é $f : \mathbb{R}^2 \rightarrow [0, +\infty[$ tal que

$$f(\mathbf{x}) = f(x_1, x_2) = \frac{1}{55\pi} \exp \left[-\frac{1}{1512} (36x_1^2 - 24x_1x_2 + 25x_2^2 - 120x_1 - 2x_2 + 121) \right].$$

Calcule $\mathbb{E}(X_1)$, $\mathbb{E}(X_2)$, $Var(X_1)$, $Var(X_2)$ e $Cov(X_1, X_2)$.

6. (Johnson e Wichern, 2014, p. 201, tradução e grifo nosso) Seja $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ com vetor de médias $\boldsymbol{\mu} = [-3 \ 1 \ 4]^\top$ e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & -2 & 0 \\ -2 & 5 & 0 \\ 0 & 0 & 2 \end{bmatrix}.$$

Quais das seguintes variáveis aleatórias são independentes? Explique.

(a) X_1 e X_2 .

(b) X_2 e X_3 .

(c) $\begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ e X_3 .

(d) $\frac{X_1 + X_2}{2}$ e X_3 .

(e) X_2 e $X_2 - \frac{5}{2}X_1 - X_3$.

7. Seja $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{a} \in \mathbb{R}^p$ um vetor de constantes. Mostre que

$$Z = \frac{\mathbf{a}^\top (\mathbf{X} - \boldsymbol{\mu})}{\sqrt{\mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}}} \sim \text{Normal}(0, 1).$$

8. Seja $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ com matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & a & 0 \\ a & 1 & a \\ 0 & a & 1 \end{bmatrix}.$$

Determine o valor de $a \in \mathbb{R}$ para que $\mathbf{b}^\top \mathbf{X}$ e $\mathbf{c}^\top \mathbf{X}$ sejam independentes, sendo $\mathbf{b} = [1 \ 1 \ 1]^\top$ e $\mathbf{c} = [1 \ -1 \ -1]^\top$.

9. Seja $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ em que o vetor de médias é $\boldsymbol{\mu} = \begin{bmatrix} 2 & -3 & 1 \end{bmatrix}^\top$ e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 2 \\ 1 & 2 & 2 \end{bmatrix}.$$

Determine o vetor $\mathbf{a} \in \mathbb{R}^2$ tal que X_2 e $X_2 - \mathbf{a}^\top \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$ são independentes.

10. Seja $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ com matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} \alpha & \frac{\alpha}{2} & \frac{\alpha}{2} \\ \frac{\alpha}{2} & \alpha & \frac{\alpha}{2} \\ \frac{\alpha}{2} & \frac{\alpha}{2} & \alpha \end{bmatrix}.$$

Determine o valor de $\alpha \in \mathbb{R}$ para que $\mathbf{b}^\top \mathbf{X}$ e $\mathbf{c}^\top \mathbf{X}$ sejam independentes, sendo $\mathbf{b} = \begin{bmatrix} 1 & 0 & -1 \end{bmatrix}^\top$ e $\mathbf{c} = \begin{bmatrix} 1 & 1 & 1 \end{bmatrix}^\top$.

11. Seja

$$\mathbf{X} = \begin{bmatrix} \mathbf{X}^{(1)} \\ \mathbf{X}^{(2)} \end{bmatrix} \sim \text{Normal}_p \left(\begin{bmatrix} \boldsymbol{\mu}^{(1)} \\ \boldsymbol{\mu}^{(2)} \end{bmatrix}, \begin{bmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{bmatrix} \right),$$

com $|\boldsymbol{\Sigma}_{22}| > 0$. Mostre que a distribuição condicional de $\mathbf{X}^{(1)}$ dado que $\mathbf{X}^{(2)} = \mathbf{x}^{(2)}$ é normal com vetor de médias dado por

$$\boldsymbol{\mu}^{(1)} + \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{x}^{(2)} - \boldsymbol{\mu}^{(2)})$$

e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma}_{11} - \boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \boldsymbol{\Sigma}_{21}.$$

Dica: Defina

$$\mathbf{A} = \begin{bmatrix} \mathbf{I} & -\boldsymbol{\Sigma}_{12} \boldsymbol{\Sigma}_{22}^{-1} \\ \mathbf{O} & \mathbf{I} \end{bmatrix},$$

e aplique a transformação $\mathbf{A}(\mathbf{X} - \boldsymbol{\mu})$.

12. Considere o vetor aleatório $\mathbf{X} \sim \text{Normal}_3(\mathbf{0}_3, \boldsymbol{\Sigma})$, em que

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0,8 & -0,4 \\ 0,8 & 1 & -0,56 \\ -0,4 & -0,56 & 1 \end{bmatrix}.$$

(a) Determine a distribuição condicional de X_1 e X_3 , dado que $X_2 = x_2$, em que $x_2 \in \mathbb{R}$ está fixado.

(b) Determine a matriz de variâncias e covariâncias de X_1 , dado que $X_2 = x_2$ e $X_3 = x_3$, em que $x_3 \in \mathbb{R}$ está fixado.

13. (Johnson e Wichern, 2014, p. 202, tradução e grifo nosso) Considere o vetor aleatório $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, em que $\boldsymbol{\mu} = [1 \ -1 \ 2]^\top$ e

$$\boldsymbol{\Sigma} = \begin{bmatrix} 4 & 0 & -1 \\ 0 & 5 & 0 \\ -1 & 0 & 2 \end{bmatrix}.$$

(a) Encontre a distribuição condicional de X_1 , dado que $X_3 = x_3$, em que $x_3 \in \mathbb{R}$.

(b) Encontre a distribuição condicional de X_1 , dado que $X_2 = x_2$ e $X_3 = x_3$, em que $x_2 \in \mathbb{R}$ e $x_3 \in \mathbb{R}$.

14. Considere o vetor aleatório $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ em que

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & \rho & \rho^2 \\ \rho & 1 & 0 \\ \rho^2 & 0 & 1 \end{bmatrix},$$

sendo $-1 \leq \rho \leq 1$. Mostre que a distribuição condicional de $[X_1 \ X_2]^\top$ dado que $X_3 = x_3$, em que $x_3 \in \mathbb{R}$ é uma constante fixa, possui distribuição normal bivariada com

com vetor de médias $[\mu_1 + \rho^2(x_3 - \mu_3) \ \mu_2]^\top$ e matriz de variâncias e covariâncias

$$\begin{bmatrix} 1 - \rho^4 & \rho \\ \rho & 1 \end{bmatrix}.$$

5 Inferência a partir de dados multivariados

Este capítulo marca o início da parte metodológica deste material. A partir de agora, utilizaremos os conceitos desenvolvidos até aqui para tratar de uma das tarefas centrais da Estatística: a inferência. Nosso objetivo será investigar como, a partir de uma amostra aleatória multivariada, podemos tirar conclusões válidas sobre parâmetros populacionais, com foco especial no vetor de médias e na matriz de variâncias e covariâncias.

Concentraremos nossa atenção em três abordagens complementares. Começamos com a estimação pontual dos parâmetros populacionais quando assumimos normalidade multivariada. Em seguida, discutimos testes de hipóteses para o vetor de médias. Por fim, estudamos como construir regiões de confiança simultâneas para esse vetor. Ao longo do capítulo, ficará evidente uma das mensagens fundamentais da análise multivariada: quando as variáveis são correlacionadas, elas devem ser analisadas de forma conjunta. Essa interdependência entre componentes é refletida tanto na estrutura da matriz de variâncias e covariâncias quanto na construção das estatísticas de teste e das regiões de confiança apresentadas a seguir.

5.1 Amostras aleatórias e estimadores não-viesados

Exemplo 5.1: Selecionando uma amostra aleatória

Uma equipe de pesquisadores deseja investigar os hábitos de sono de estudantes universitários. Para isso, decide realizar uma pesquisa com alunos de uma universidade pública. A meta é obter uma amostra que represente bem o comportamento da população estudantil da instituição. Um dos métodos considerados foi sortear, de forma aleatória, estudantes da base de dados da universidade, de modo que todos tivessem a mesma probabilidade de serem incluídos. Nessa situação, as observações da amostra podem ser consideradas independentes e provenientes da mesma população, o que permite aplicar técnicas inferenciais clássicas.

No entanto, imagine que a pesquisa fosse aplicada apenas a estudantes encontrados na biblioteca após as 21h. Nesse caso, mesmo que os entrevistados fossem escolhidos ao acaso entre os presentes, os dados coletados tenderiam a refletir um perfil bastante específico de alunos: possivelmente mais disciplinados ou com maior carga de estudos. As observações deixariam de ser representativas da população geral e poderiam estar correlacionadas, comprometendo a validade inferencial.

Exemplo 5.1

Este exemplo ilustra a importância de garantir que a amostra seja verdadeiramente aleatória e que as observações possam ser tratadas como independentes, o que é fundamental para a construção de estimadores confiáveis.

Para desenvolver técnicas de inferência estatística a partir de dados multivariados, é essencial compreendermos o processo de amostragem e as propriedades dos estimadores que utilizamos.

Suponha que ainda não tenhamos observado os dados, mas planejamos coletar n vetores aleatórios, cada um com p variáveis. Como o resultado da medição ou observação ainda não é conhecido, representamos cada entrada dos vetores como uma variável aleatória. O j -ésimo vetor de observações, que chamaremos de $\mathbf{X}_j$, contém os valores observados para as p variáveis em uma dada unidade observacional (por exemplo, um indivíduo ou objeto). A matriz de dados completa, portanto, é dada por

$$\begin{bmatrix} \mathbf{X}_1^\top \\ \mathbf{X}_2^\top \\ \vdots \\ \mathbf{X}_n^\top \end{bmatrix} = \begin{bmatrix} X_{11} & X_{12} & \cdots & X_{1p} \\ X_{21} & X_{22} & \cdots & X_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ X_{n1} & X_{n2} & \cdots & X_{np} \end{bmatrix}.$$

Dizemos que os vetores $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ formam uma *amostra aleatória* se são vetores aleatórios independentes e identicamente distribuídos segundo uma mesma distribuição conjunta de densidade $f(\mathbf{x})$ em $\mathbb{R}^p$. Isso equivale a dizer que a função densidade conjunta de $\mathbf{X}_1, \dots, \mathbf{X}_n$ pode ser escrita como o produto

$$f(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n) = f(\mathbf{x}_1)f(\mathbf{x}_2) \cdots f(\mathbf{x}_n).$$

É importante destacar dois pontos que frequentemente geram confusões entre os estudantes. Primeiro, embora os vetores de linhas sejam independentes entre si, os componentes de um mesmo vetor, i.e., as p variáveis medidas em uma mesma unidade, podem (e geralmente devem) estar correlacionadas. Essa correlação entre variáveis é justamente o que motiva o uso de métodos multivariados. Segundo, a suposição de independência entre vetores amostrais pode não ser apropriada em todas as situações. Em contextos onde os dados são coletados ao longo do tempo (como séries temporais de preços de ações ou indicadores econômicos), é comum que observações feitas em instantes próximos estejam associadas. Nesse caso, a dependência entre vetores consecutivos precisa ser modelada explicitamente, e os métodos inferenciais desenvolvidos aqui, que assumem

independência entre as linhas da matriz $\mathbf{X}$, deixam de ser aplicáveis.

Nos parágrafos seguintes, vamos deduzir dois estimadores fundamentais: o estimador do vetor de médias populacionais e o estimador da matriz de variâncias e covariâncias populacionais. Mostraremos que ambos são não-viesados sob a hipótese de amostragem aleatória, estabelecendo as bases para os procedimentos inferenciais que virão a seguir.

Resultado 5.1

Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de um vetor aleatório $\mathbf{X}$ com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma}$. Então, os seguintes resultados são válidos:

(a) O vetor de médias amostrais

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$$

é um estimador não-viesado para $\boldsymbol{\mu}$, ou seja,

$$\mathbb{E}(\bar{\mathbf{X}}) = \boldsymbol{\mu}.$$

cuja matriz de variâncias e covariâncias é dada por

$$\text{Cov}(\bar{\mathbf{X}}) = \frac{1}{n} \boldsymbol{\Sigma}.$$

(b) A matriz de variâncias e covariâncias amostral

$$\mathbf{S}_n = \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top$$

é um estimador viesado para $\boldsymbol{\Sigma}$, com

$$\mathbb{E}(\mathbf{S}_n) = \frac{n-1}{n} \boldsymbol{\Sigma}.$$

(c) Um estimador não-viesado de $\boldsymbol{\Sigma}$ é dado por

$$\mathbf{S} := \frac{n}{n-1} \mathbf{S}_n.$$

DEMONSTRAÇÃO:

Resultado 5.1

(a) Note que

$$\mathbb{E}(\bar{\mathbf{X}}) = \mathbb{E}\left(\frac{1}{n} \sum_{j=1}^n \mathbf{X}_j\right) = \frac{1}{n} \sum_{j=1}^n \mathbb{E}(\mathbf{X}_j) = \frac{1}{n} \sum_{j=1}^n \boldsymbol{\mu} = \boldsymbol{\mu}.$$

Logo, $\bar{\mathbf{X}}$ é um estimador não-viesado para $\boldsymbol{\mu}$. A matriz de variâncias e covariâncias de $\bar{\mathbf{X}}$ é dada por

$$\text{Cov}(\bar{\mathbf{X}}) = \text{Cov}\left(\frac{1}{n} \sum_{j=1}^n \mathbf{X}_j\right) = \frac{1}{n^2} \sum_{j=1}^n \text{Cov}(\mathbf{X}_j) = \frac{1}{n^2} \cdot n\boldsymbol{\Sigma} = \frac{1}{n}\boldsymbol{\Sigma}.$$

(b) Observamos que

$$\mathbf{S}_n = \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top.$$

Expandindo o termo $(\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top$ com base em somas e produtos matriciais, obtemos a identidade clássica

$$\sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top = \sum_{j=1}^n \mathbf{X}_j \mathbf{X}_j^\top - n\bar{\mathbf{X}}\bar{\mathbf{X}}^\top.$$

Note que

$$\mathbb{E}\left(\sum_{j=1}^n \mathbf{X}_j \mathbf{X}_j^\top\right) = \sum_{j=1}^n \mathbb{E}(\mathbf{X}_j \mathbf{X}_j^\top) = \sum_{j=1}^n (\boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^\top) = n\boldsymbol{\Sigma} + n\boldsymbol{\mu}\boldsymbol{\mu}^\top,$$

e, pelo item (a),

$$\mathbb{E}(n\bar{\mathbf{X}}\bar{\mathbf{X}}^\top) = n \cdot \mathbb{E}(\bar{\mathbf{X}}\bar{\mathbf{X}}^\top) = n\left(\frac{1}{n}\boldsymbol{\Sigma} + \boldsymbol{\mu}\boldsymbol{\mu}^\top\right) = \boldsymbol{\Sigma} + n\boldsymbol{\mu}\boldsymbol{\mu}^\top.$$

Portanto,

$$\mathbb{E}(\mathbf{S}_n) = \frac{1}{n} (n\boldsymbol{\Sigma} + n\boldsymbol{\mu}\boldsymbol{\mu}^\top - \boldsymbol{\Sigma} - n\boldsymbol{\mu}\boldsymbol{\mu}^\top) = \frac{n-1}{n}\boldsymbol{\Sigma}.$$

Assim, concluímos que o estimador $\mathbf{S}_n$ é viesado.

(c) Pelo item (b),

$$\mathbb{E}(\mathbf{S}) = \mathbb{E}\left(\frac{n}{n-1}\mathbf{S}_n\right) = \frac{n}{n-1}\mathbb{E}(\mathbf{S}_n) = \frac{n}{n-1} \times \frac{n-1}{n} \times \boldsymbol{\Sigma} = \boldsymbol{\Sigma}.$$

Resultado 5.1

Portanto, $\mathbf{S}$ é um estimador não-viesado para Σ .

■

Definição 5.1: Matriz de variâncias e covariâncias (não-viesada)

Sejam $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra do vetor aleatório $\mathbf{X}$. A *matriz de variâncias e covariâncias amostrais (não-viesada)* é a matriz *simétrica* $\mathbf{S} \in M_{p \times p}(\mathbb{R})$ tal que

$$\mathbf{S} := \frac{n}{n-1} \mathbf{S}_n = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top.$$

A partir deste ponto, adotaremos $\mathbf{S}$ como a matriz de variâncias e covariâncias amostral. Essa escolha é justificada pelo fato de que $\mathbf{S}$ é um estimador não-viesado de Σ e aparece naturalmente em testes estatísticos multivariados que discutiremos no restante dessas notas.

Exemplo 5.2

Considere uma pesquisa sobre hábitos alimentares conduzida com estudantes universitários. Os pesquisadores decidem coletar informações sobre três variáveis quantitativas: número médio de refeições por dia (X_1), quantidade média de frutas consumidas semanalmente (X_2) e tempo médio (em minutos) gasto preparando a própria comida (X_3). Inicialmente, a amostra é planejada para ser aleatória simples, sorteando estudantes da base de dados da universidade. No entanto, por limitações logísticas, os dados foram coletados presencialmente em apenas dois lugares do campus: a biblioteca e o restaurante universitário. Suponha que, ao final do processo, a matriz de dados observada seja denotada por

$$\begin{bmatrix} \mathbf{x}_1^\top \\ \mathbf{x}_2^\top \\ \vdots \\ \mathbf{x}_n^\top \end{bmatrix},$$

em que cada vetor linha $\mathbf{x}_j$ contém as três variáveis observadas em um único estudante.

Exemplo 5.2

Sabemos que as estimativas de $\bar{\mathbf{X}}$ e $\mathbf{S}$ são válidas sob a suposição de que os vetores aleatórios $\mathbf{X}_1, \dots, \mathbf{X}_n$ são independentes e identicamente distribuídos (i.i.d.). No entanto, nesse cenário, surgem algumas questões importantes:

- (a) O fato de os dados terem sido coletados em locais diferentes pode introduzir algum tipo de viés?
- (b) É razoável assumir que $\mathbf{X}_1, \dots, \mathbf{X}_n$ são i.i.d., mesmo sabendo que o local de coleta pode estar associado ao comportamento alimentar?
- (c) Como a possível quebra de independência pode afetar a validade dos estimadores $\bar{\mathbf{X}}$ e $\mathbf{S}$?

SOLUÇÃO:

- (a) Sim, pode. Se o local de coleta está relacionado a características específicas dos estudantes (por exemplo, quem frequenta a biblioteca pode ter hábitos alimentares distintos de quem almoça no restaurante universitário), a amostra final pode não representar adequadamente a população total de estudantes. Isso compromete a validade das inferências, uma vez que certos perfis comportamentais podem estar super ou sub-representados.
- (b) Não é razoável. A suposição de que os vetores observados são independentes e identicamente distribuídos exige que cada unidade amostral tenha sido selecionada de maneira independente e segundo a mesma distribuição. Se o processo de amostragem varia com o local, e esse local influencia as variáveis de interesse, então as observações não podem ser consideradas i.i.d., pois diferentes subgrupos da população estão sendo modelados por distribuições distintas.
- (c) Se a independência entre os vetores amostrais for violada, a propriedade de não-viesamento de $\mathbf{S}$ pode deixar de ser garantida, e a variância de $\bar{\mathbf{X}}$ pode não seguir mais a estrutura $Cov(\bar{\mathbf{X}}) = \frac{1}{n}\mathbf{\Sigma}$. Isso impacta diretamente a confiabilidade de testes estatísticos e de regiões de confiança baseados nesses estimadores. Em particular, os erros-padrão podem ser subestimados ou superestimados, levando a decisões inferenciais equivocadas. Ou seja, mesmo com cálculos corretos, as conclusões podem ser inválidas por conta da violação das suposições fundamentais do modelo.

O Exemplo 5.2 nos conduz a uma reflexão fundamental: embora as fórmulas dos estimadores sejam sempre as mesmas, sua interpretação e validade inferencial dependem fortemente do mecanismo de amostragem. Em especial, mesmo que os alunos medidos tenham variáveis correlacionadas entre si (o que é esperado), os vetores $\mathbf{X}_j$ devem ser independentes entre si, o que pode ser ameaçado por práticas de coleta não-aleatória. Este exemplo ilustra a importância de analisar cuidadosamente as suposições por trás dos modelos antes de aplicar fórmulas e tirar conclusões.

5.2 Amostras aleatórias de uma distribuição normal multivariada

Nesta seção, vamos considerar que a amostra foi retirada de uma população normal multivariada e investigar outras propriedades do vetor de médias amostrais $\bar{\mathbf{X}}$ e da matriz de variâncias e covariâncias amostrais $\mathbf{S}$ uma vez que, pelo discutido na seção anterior, sabemos que são estimadores não-viesados para o vetor de médias populacionais $\boldsymbol{\mu}$ e para matriz de variâncias e covariâncias populacionais $\boldsymbol{\Sigma}$, respectivamente.

5.2.1 Estimadores de máxima verossimilhança

Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de um vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, ou seja, cada vetor $\mathbf{X}_j$ tem dimensão $p \times 1$, distribuição normal p -variada com vetor de médias populacionais $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias populacional $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$. Como os vetores aleatórios são mutuamente independentes, a densidade conjunta de $\mathbf{X}_1, \dots, \mathbf{X}_n$ é dada pelo produto das densidades marginais, i.e.,

$$\begin{aligned} f(\mathbf{x}_1, \dots, \mathbf{x}_n) &= f(\mathbf{x}_1)f(\mathbf{x}_2) \cdots f(\mathbf{x}_n) \\ &= \prod_{j=1}^n \frac{1}{(2\pi)^{p/2} |\boldsymbol{\Sigma}|^{1/2}} \exp \left\{ -\frac{1}{2} (\mathbf{x}_j - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\}. \end{aligned}$$

Com alguma manipulação algébrica, essa expressão pode ser reescrita como

$$f(\mathbf{x}_1, \dots, \mathbf{x}_n) = \frac{1}{(2\pi)^{np/2} |\boldsymbol{\Sigma}|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\}.$$

Neste momento, é importante dar um passo conceitual. Quando observamos a amostra $\mathbf{x}_1, \dots, \mathbf{x}_n$, ou seja, após os dados terem sido coletados, os vetores observados passam a ser fixos. A expressão acima, quando vista como função dos parâmetros desconhecidos $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$, recebe o nome de *função de verossimilhança*. Portanto, a função de verossimilhança, para

$\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ é dada por

$$L(\boldsymbol{\mu}, \boldsymbol{\Sigma}) := \frac{1}{(2\pi)^{np/2} |\boldsymbol{\Sigma}|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\}.$$

De modo geral, a função de verossimilhança mede o grau de compatibilidade entre os parâmetros do modelo e os dados observados. Quanto maior o valor da verossimilhança para certos valores de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$, mais plausível é que esses parâmetros tenham gerado a amostra que foi efetivamente observada. Em outras palavras, a função de verossimilhança responde à pergunta: quão bem os parâmetros propostos explicam os dados que coletamos? A técnica de *estimação por máxima verossimilhança* (EMV) busca determinar os valores de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ que maximizam essa função, isto é, encontrar os valores dos parâmetros que tornam a amostra observada mais provável sob o modelo normal multivariado.

Os valores de $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ mais plausíveis de terem gerado a amostra observada são denominados *estimativas de máxima verossimilhança*. Para encontrá-los, vamos reescrever a função de verossimilhança em uma forma mais conveniente.

Para facilitar o processo de maximização, é conveniente trabalhar com o logaritmo da função de verossimilhança. Como o logaritmo é uma função crescente, os valores que maximizam a verossimilhança também maximizam seu logaritmo. A *função log-verossimilhança* $\ell(\boldsymbol{\mu}, \boldsymbol{\Sigma}) := \log L(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ é dada por

$$\begin{aligned} \ell(\boldsymbol{\mu}, \boldsymbol{\Sigma}) &:= \log \left[\frac{1}{(2\pi)^{np/2} |\boldsymbol{\Sigma}|^{n/2}} \exp \left\{ -\frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \right\} \right] \\ &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_j - \boldsymbol{\mu}) \\ &= -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{j=1}^n [\mathbf{x}_j^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}_j - 2\boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \mathbf{x}_j + \boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}]. \end{aligned}$$

Agora estamos em condição de enunciar e provar o seguinte resultado

Resultado 5.2

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de um vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Então,

$$\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}} := \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$$

é o estimador de máxima verossimilhança para $\boldsymbol{\mu}$ e

Resultado 5.2

$$\hat{\Sigma} = S_n := \frac{1}{n} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top = \frac{n-1}{n} \mathbf{S}.$$

é o estimador de máxima verossimilhança estimador para Σ . Os seus valores observados $\bar{\mathbf{x}}$ e $\frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})^\top$ são denominadas as estimativas de máxima verossimilhança para μ e Σ , respectivamente.

DEMONSTRAÇÃO:

Para encontrar o valor de μ que maximiza a log-verossimilhança, derivamos com relação a μ e igualamos ao vetor nulo. Note que Σ é tratada como constante nessa etapa. Logo,

$$\frac{\partial \ell}{\partial \mu} = -\frac{1}{2} \left[-2\Sigma^{-1} \sum_{j=1}^n \mathbf{x}_j + 2n\Sigma^{-1}\mu \right] = \Sigma^{-1} \left(n\mu - \sum_{j=1}^n \mathbf{x}_j \right).$$

Igualando ao vetor nulo de $\mathbb{R}^p$, temos

$$\Sigma^{-1} \left(n\mu - \sum_{j=1}^n \mathbf{x}_j \right) = \mathbf{0} \Rightarrow n\mu = \sum_{j=1}^n \mathbf{x}_j \Rightarrow \hat{\mu} = \bar{\mathbf{x}}.$$

Portanto, $\bar{\mathbf{X}}$ é o estimador de máxima verossimilhança para μ . Agora que já conhecemos $\hat{\mu}$, podemos substituí-la na função log-verossimilhança. Assim,

$$\ell(\bar{\mathbf{x}}, \Sigma) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{j=1}^n \left[\mathbf{x}_j^\top \Sigma^{-1} \mathbf{x}_j - 2\bar{\mathbf{x}}^\top \Sigma^{-1} \mathbf{x}_j + \bar{\mathbf{x}}^\top \Sigma^{-1} \bar{\mathbf{x}} \right].$$

Note que o termo

$$\sum_{j=1}^n \left(\mathbf{x}_j^\top \Sigma^{-1} \mathbf{x}_j - 2\bar{\mathbf{x}}^\top \Sigma^{-1} \mathbf{x}_j + \bar{\mathbf{x}}^\top \Sigma^{-1} \bar{\mathbf{x}} \right)$$

é igual a

$$\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})^\top \Sigma^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}).$$

Logo, temos

$$\ell(\bar{\mathbf{x}}, \Sigma) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\Sigma| - \frac{1}{2} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})^\top \Sigma^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}).$$

Agora, derivamos essa expressão em relação a Σ e igualamos à matriz nula.

Resultado 5.2

Alguns resultados de álgebra matricial serão necessários neste ponto da demonstração.

A saber,

$$\frac{\partial}{\partial \Sigma} \left(\frac{n}{2} |\Sigma| \right) = \frac{n}{2} \Sigma^{-1}$$

e

$$\begin{aligned} \frac{\partial}{\partial \Sigma} \left(\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})^\top \Sigma^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}) \right) &= - \sum_{j=1}^n \left[\Sigma^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top \Sigma^{-1} \right] \\ &= - \Sigma^{-1} \left[\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top \right] \Sigma^{-1}. \end{aligned}$$

Logo,

$$\begin{aligned} \frac{\partial \ell}{\partial \Sigma} = \mathbf{O} &\Rightarrow -\frac{n}{2} \Sigma^{-1} + \frac{1}{2} \Sigma^{-1} \left[\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top \right] \Sigma^{-1} (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top = \mathbf{O} \\ &\Rightarrow \Sigma^{-1} = \frac{1}{n} \Sigma^{-1} \left[\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top \right] \Sigma^{-1} \\ &\Rightarrow \mathbf{I}_p = \frac{1}{n} \Sigma^{-1} \left[\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top \right] \\ &\Rightarrow \hat{\Sigma} = \frac{1}{n} \sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}}) (\mathbf{x}_j - \bar{\mathbf{x}})^\top. \end{aligned}$$

Portanto, $\mathbf{S}_n$ é o estimador de máxima verossimilhança para Σ .

■

Depois de obtermos os estimadores de máxima verossimilhança (EMVs) para os parâmetros $\boldsymbol{\mu}$ e Σ , podemos fazer algumas observações importantes sobre suas propriedades.

Primeiramente, vale notar que $\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}}$ é um vetor aleatório, e $\hat{\Sigma} = \mathbf{S}_n$ é uma matriz aleatória, pois ambos são funções da amostra. Os valores que calculamos para esses estimadores dependem diretamente dos dados observados.

Um fato interessante é que, ao substituírmos os EMVs na expressão da verossimilhança, obtemos

$$L(\hat{\boldsymbol{\mu}}, \hat{\Sigma}) = \frac{1}{(2\pi)^{np/2}} \times \frac{1}{|\hat{\Sigma}|^{n/2}} \times e^{-np/2}.$$

Ou seja, a verossimilhança avaliada nos EMVs é inversamente proporcional à raiz n -ésima do determinante de $\hat{\Sigma}$. Esse determinante é conhecido como *variância generalizada* da amostra, e aparece naturalmente como uma medida de dispersão multivariada.

Quanto maior a variância generalizada, mais “espalhada” é a nuvem de pontos; quanto menor, mais “concentrada” em torno de $\bar{\mathbf{X}}$. Essa relação entre a função de verossimilhança e a variância generalizada nos mostra que a verossimilhança é maximizada quando os dados estão bem concentrados, ou seja, quando a matriz de variâncias e covariâncias amostral tem determinante pequeno. Isso está alinhado com a intuição: quanto mais os dados estão próximos da média, mais “plausível” parece o modelo normal multivariado.

Outra propriedade fundamental dos EMVs é a chamada *propriedade de invariância*. Ela afirma que, se $\hat{\boldsymbol{\theta}}$ é o estimador de máxima verossimilhança de um vetor de parâmetros $\boldsymbol{\theta}$, e se desejamos estimar uma função qualquer desses parâmetros, digamos $h(\boldsymbol{\theta})$, então o EMV de $h(\boldsymbol{\theta})$ é simplesmente $h(\hat{\boldsymbol{\theta}})$. Em outras palavras, para obter o EMV de uma transformação, basta aplicar essa transformação diretamente sobre os EMVs. Isso nos economiza esforço e evita deduções repetitivas, pois não precisamos rederivar toda a função de verossimilhança sempre que quisermos estimar uma nova quantidade derivada dos parâmetros. Essa propriedade é especialmente poderosa quando lidamos com estatísticas mais complexas, como razões de variâncias, projeções, distâncias estatísticas e muito mais. Vamos explorá-la em maior profundidade nas próximas seções e capítulos, quando lidarmos com testes de hipóteses e regiões de confiança.

Exemplo 5.3

Considere que $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória do vetor aleatório $\mathbf{X}$ com distribuição $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Usando a propriedade de invariância dos EMVs, determine os EMVs para as seguintes quantidades:

- (a) A média populacional da i -ésima componente, isto é, μ_i .
- (b) A variância da i -ésima componente, isto é, σ_{ii} .
- (c) A covariância entre as componentes i e j da variável aleatória $\mathbf{X}$, isto é, σ_{ik} .
- (d) O desvio padrão da componente i , isto é, $\sqrt{\sigma_{ii}}$.
- (e) A correlação entre as componentes i e j de $\mathbf{X}$, isto é, $\rho_{ik} = \frac{\sigma_{ik}}{\sqrt{\sigma_{ii}\sigma_{kk}}}$.
- (f) A distância quadrática de $\boldsymbol{\mu}$ à origem, isto é, $\boldsymbol{\mu}^\top \boldsymbol{\mu}$.
- (g) A quantidade $\boldsymbol{\mu}^\top \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}$.

SOLUÇÃO:

- (a) Aqui, $h(\boldsymbol{\mu}) = \mu_i$. Como $h(\hat{\boldsymbol{\mu}})$ é EMV para $h(\boldsymbol{\mu})$ e $h(\hat{\boldsymbol{\mu}}) = h(\bar{\mathbf{X}}) = \bar{X}_i$, segue que $\bar{X}_i$ é EMV para μ_i .

Exemplo 5.4

(b) Aqui, $h(\Sigma) = \sigma_{ii}$. Como $h(\hat{\Sigma})$ é EMV para $h(\Sigma)$ e $h(\hat{\Sigma}) = \hat{\sigma}_{ii}$, emque

$$\hat{\sigma}_{ii} = \frac{1}{n} \sum_{j=1}^n (X_{ji} - \bar{X}_i)^2,$$

segue que $\hat{\sigma}_{ii}$ é EMV para σ_{ii} .

(c) Aqui, $h(\Sigma) = \sigma_{ik}$. Como $h(\hat{\Sigma})$ é EMV para $h(\Sigma)$ e $h(\hat{\Sigma}) = \hat{\sigma}_{ik}$, em que

$$\hat{\sigma}_{ik} = \frac{1}{n} \sum_{j=1}^n (X_{ji} - \bar{X}_i)(X_{jk} - \bar{X}_k),$$

segue que $\hat{\sigma}_{ik}$ é EMV para σ_{ik} .

(d) Aqui, $h(\Sigma) = \sqrt{\sigma_{ii}}$. Como $h(\hat{\Sigma})$ é EMV para $h(\Sigma)$ e $h(\hat{\Sigma}) = \sqrt{\hat{\sigma}_{ii}}$, segue que $\sqrt{\hat{\sigma}_{ii}}$ é EMV para $\sqrt{\sigma_{ii}}$.

(e) Aqui, $h(\Sigma) = \frac{\sigma_{ik}}{\sqrt{\sigma_{ii}\sigma_{kk}}}$. Como $h(\hat{\Sigma})$ é EMV para $h(\Sigma)$ e

$$h(\hat{\Sigma}) = \frac{\hat{\sigma}_{ik}}{\sqrt{\hat{\sigma}_{ii}\hat{\sigma}_{kk}}},$$

segue que $\frac{\hat{\sigma}_{ik}}{\sqrt{\hat{\sigma}_{ii}\hat{\sigma}_{kk}}}$ é EMV para ρ_{ik} .

(f) Aqui, $h(\mu) = \mu^\top \mu$. Como $h(\hat{\mu})$ é EMV para $h(\mu)$ e $h(\hat{\mu}) = \bar{X}^\top \bar{X}$, segue que $\bar{X}^\top \bar{X}$ é EMV para $\mu^\top \mu$.

(g) Aqui, $h(\mu, \Sigma) = \mu^\top \Sigma^{-1} \mu$. Como a invariância também vale para funções de múltiplos parâmetros, temos que

$$h(\hat{\mu}, \hat{\Sigma}) = \bar{X}^\top \hat{\Sigma}^{-1} \bar{X}$$

é EMV para $\mu^\top \Sigma^{-1} \mu$.

Ao observarmos a função de verossimilhança para uma amostra aleatória de uma distribuição $\text{Normal}_p(\mu, \Sigma)$, percebemos que ela depende dos dados $\mathbf{x}_1, \dots, \mathbf{x}_n$ apenas por meio de dois elementos: o vetor de médias amostrais $\bar{\mathbf{x}}$ e a matriz de somas de quadrados e produtos centrados, dada por $\sum_{j=1}^n (\mathbf{x}_j - \bar{\mathbf{x}})(\mathbf{x}_j - \bar{\mathbf{x}})^\top = (n-1)\mathbf{S}$. Esse fato indica que qualquer informação relevante sobre os parâmetros μ e Σ já está contida nesses dois resumos da amostra.

Dizemos, nesse caso, que $\bar{\mathbf{X}}$ e $\mathbf{S}$ são estatísticas suficientes. Isso significa que, ao condicionar a distribuição conjunta da amostra a esses dois objetos, nenhuma informação adicional sobre os parâmetros é extraída. Toda a inferência sobre média e covariância que poderíamos realizar a partir dos dados completos pode ser conduzida apenas com essas duas estatísticas. Essa propriedade é particularmente conveniente no contexto da distribuição normal multivariada. A informação total disponível sobre os parâmetros está contida em $\bar{\mathbf{X}}$ e $\mathbf{S}$, independentemente do tamanho amostral n . Se dois analistas estiverem trabalhando com a mesma base de dados, mas um deles descartar as observações após calcular $\bar{\mathbf{X}}$ e $\mathbf{S}$, enquanto o outro mantiver a base completa, ambos obterão exatamente as mesmas estimativas para $\boldsymbol{\mu}$ e $\boldsymbol{\Sigma}$ por máxima verossimilhança. O segundo analista não terá vantagem alguma, pois os dados adicionais que retém não carregam informação extra sobre os parâmetros.

No entanto, é importante reconhecer que essa suficiência está fundamentada na hipótese de normalidade multivariada. Para outras distribuições, não é garantido que o vetor de médias amostrais e a matriz de variâncias e covariâncias amostrais resumam adequadamente a informação dos dados. Procedimentos baseados apenas nessas quantidades podem ignorar aspectos relevantes, como a assimetria ou a presença de *outliers*. Por essa razão, é prudente verificar, na prática, se o modelo normal multivariado é uma descrição razoável para os dados. Quando essa suposição é adequada, $\bar{\mathbf{X}}$ e $\mathbf{S}$ tornam-se pilares da inferência estatística multivariada, tanto do ponto de vista teórico quanto prático.

5.2.2 A distribuição de $\bar{\mathbf{X}}$ e de $\mathbf{S}$

Assumiremos, a partir de agora, que $\mathbf{X}_1, \dots, \mathbf{X}_n$ formam uma amostra aleatória de uma população com distribuição $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Essa hipótese, embora nem sempre plenamente verificável na prática, é suficiente para determinar completamente as distribuições amostrais de $\bar{\mathbf{X}}$ e $\mathbf{S}$. Assim como no caso univariado, conhecer essas distribuições é essencial para formular testes de hipóteses e construir regiões de confiança adequadas para os parâmetros populacionais. O comportamento de $\bar{\mathbf{X}}$ e $\mathbf{S}$ pode ser descrito de forma analítica, mas também será explorado por meio de simulações computacionais. Essa abordagem empírica nos permitirá visualizar, de maneira mais concreta, como as estatísticas amostrais se distribuem em torno dos parâmetros populacionais à medida que o tamanho da amostra varia. Compararemos essas distribuições com as que já conhecemos do caso univariado, o que ajudará a estabelecer conexões naturais com conceitos já familiares.

No caso univariado ($p = 1$), sabemos que $\bar{X}$ possui distribuição normal com média μ e variância σ^2/n . O resultado para o caso multivariado ($p \geq 2$) é análogo, i.e., $\bar{\mathbf{X}}$ possui distribuição normal p -variada com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias $\frac{1}{n}\boldsymbol{\Sigma}$. No entanto, para demonstrá-lo necessitaremos do seguinte resultado.

Resultado 5.3

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ vetores aleatórios independentes tal que $\mathbf{X}_j \sim \text{Normal}_p(\boldsymbol{\mu}_j, \boldsymbol{\Sigma})$, para todo $j = 1, \dots, n$. Então, a combinação linear desses vetores aleatórios

$$\mathbf{V} = \sum_{i=1}^n c_i \mathbf{X}_i,$$

também segue uma distribuição normal multivariada, i.e.,

$$\mathbf{V} \sim \text{Normal}_p \left(\sum_{i=1}^n c_i \boldsymbol{\mu}_i, \left(\sum_{i=1}^n c_i^2 \right) \boldsymbol{\Sigma} \right).$$

DEMONSTRAÇÃO:

Começamos observando que cada vetor $\mathbf{X}_i$ tem distribuição normal multivariada, portanto qualquer combinação linear de suas componentes também tem distribuição normal univariada. Além disso, como os vetores $\mathbf{X}_i$ são independentes, sua soma ponderada também é normalmente distribuída. Isso garante que $\mathbf{V}$ segue uma distribuição Normal_p .

Para calcular o valor esperado de $\mathbf{V}$, usamos a linearidade da esperança, i.e.,

$$\mathbb{E}(\mathbf{V}) = \mathbb{E} \left(\sum_{i=1}^n c_i \mathbf{X}_i \right) = \sum_{i=1}^n c_i \mathbb{E}(\mathbf{X}_i) = \sum_{i=1}^n c_i \boldsymbol{\mu}_i.$$

Para a matriz de variâncias e covariâncias, usamos o fato de que os vetores são independentes, ou seja, $\text{Cov}(\mathbf{X}_i, \mathbf{X}_j) = \mathbf{0}$ sempre que $i \neq j$. Logo,

$$\text{Cov}(\mathbf{V}) = \text{Cov} \left(\sum_{i=1}^n c_i \mathbf{X}_i \right) = \sum_{i=1}^n c_i^2 \text{Cov}(\mathbf{X}_i) = \sum_{i=1}^n c_i^2 \boldsymbol{\Sigma} = \left(\sum_{i=1}^n c_i^2 \right) \boldsymbol{\Sigma}.$$

Portanto, a distribuição de $\mathbf{V}$ é

$$\mathbf{V} \sim \text{Normal}_p \left(\sum_{i=1}^n c_i \boldsymbol{\mu}_i, \left(\sum_{i=1}^n c_i^2 \right) \boldsymbol{\Sigma} \right),$$

■

Resultado 5.4

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatório do vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Então, $\bar{\mathbf{X}} \sim \text{Normal}_p \left(\boldsymbol{\mu}, \frac{1}{n} \boldsymbol{\Sigma} \right)$.

Resultado 5.4**DEMONSTRAÇÃO:**

No caso da média amostral, estamos lidando com a combinação linear em que todos os coeficientes são iguais $c_i = 1/n$, para todo $i = 1, \dots, n$. Portanto, aplicando o Resultado 5.3, temos

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j \sim \text{Normal}_p \left(\frac{1}{n} \sum_{j=1}^n \boldsymbol{\mu}, \left(\sum_{j=1}^n \left(\frac{1}{n} \right)^2 \right) \boldsymbol{\Sigma} \right).$$

A média da soma é simplesmente $\boldsymbol{\mu}$, já que $\sum_{j=1}^n \boldsymbol{\mu} = n\boldsymbol{\mu}$, e a matriz de variâncias e covariâncias da combinação linear é

$$\left(\sum_{j=1}^n \frac{1}{n^2} \right) \boldsymbol{\Sigma} = \frac{n}{n^2} \boldsymbol{\Sigma} = \frac{1}{n} \boldsymbol{\Sigma}.$$

Portanto, concluímos que

$$\bar{\mathbf{X}} \sim \text{Normal}_p \left(\boldsymbol{\mu}, \frac{1}{n} \boldsymbol{\Sigma} \right).$$

■

Exemplo 5.5

Utilizando o *software* *R*, gere 200 amostras de uma população bivariada normal com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 2 \end{bmatrix}.$$

para diferentes tamanhos amostrais $n \in \{5, 10, 50, 200\}$. Para cada uma das amostras determine o valor de $\bar{X}_1$ e $\bar{X}_2$.

- Construa o gráfico dos pontos formados pelos vetores de médias amostrais $\bar{X}_1$ e $\bar{X}_2$, obtidos a partir de amostras simuladas.
- O que acontece com a nuvem de pontos à medida que o tamanho amostral cresce? Esse resultado é consistente com o esperado pelo Resultado 5.4?

Exemplo 5.5

SOLUÇÃO:

(a)




Figura 5.1. Aproximação da distribuição do vetor de médias amostrais $\bar{\mathbf{X}}$ com o aumento de n .

Código R

```

1 library(MASS)      # Para mvrnorm
2 library(ggplot2)   # Para visualização
3 library(dplyr)     # Para manipulação de dados
4
5 # Parâmetros populacionais
6 mu <- c(1, 2)
7 Sigma <- matrix(c(1, 0.8, 0.8, 2), nrow = 2)
8
9 # Tamanhos amostrais
10 n_values <- c(5, 10, 50, 200)
11 n_sim <- 1000
12
13 # Gerar as médias amostrais
14 resultados <- lapply(n_values, function(n) {
15   medias <- replicate(n_sim, {
16     amostra <- mvrnorm(n, mu = mu, Sigma = Sigma)
17     colMeans(amostra)
18   })
19   df <- as.data.frame(t(medias))
20   df$n <- as.factor(n)
21   names(df)[1:2] <- c("X1", "X2")
22   return(df)
23 }) %>% bind_rows()

```

Exemplo 5.5

```

1 # Gráfico
2 ggplot(resultados, aes(x = X1, y = X2)) +
3   geom_point(alpha = 0.4, size = 0.8) +
4   facet_wrap(~n, nrow = 1, labeller = label_bquote(n == .(
5     n))) +
6   xlab(expression(bar(X)[1])) +
7   ylab(expression(bar(X)[2])) +
8   ggtitle("Aproximação da distribuição de médias amostrais") +
9   theme_minimal(base_size = 12)

```

- (b) À medida que o tamanho amostral n cresce, observa-se que os pontos se concentram em torno do verdadeiro vetor de médias populacionais. Esse comportamento evidencia, de forma empírica, a convergência da distribuição de $\bar{\mathbf{X}}$ para uma distribuição $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma}/n)$, conforme discutido anteriormente.

Além disso, quanto maior o valor de n , menor é a variabilidade das médias amostrais ao redor de $\boldsymbol{\mu}$, refletindo a redução da variância amostral e, consequentemente, o aumento da precisão do estimador. Essa simulação ilustra de maneira clara como o resultado teórico se manifesta na prática.

Exemplo 5.6

Utilizando o *software* R , gere 200 amostras de uma população bivariada normal com vetor de médias $\boldsymbol{\mu} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}$ e matriz de variâncias e covariâncias

$$\boldsymbol{\Sigma} = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 2 \end{bmatrix}.$$

para diferentes tamanhos amostrais $n \in \{5, 10, 50, 200\}$. Para cada uma das amostras determine o valor de $\mathbf{S}$

- (a) Construa histogramas para o valor de cada entrada da matriz de variâncias e covariâncias, obtidos a partir de amostras simuladas.
- (b) Que indicativos os histogramas trazem a respeito da verdadeira distribuição das variâncias e covariâncias amostrais? O que ocorre com essas distribuições à me-

Exemplo 5.6

dida que o tamanho amostral cresce?

SOLUÇÃO:

(a)




Figura 5.2. Aproximação da distribuição das variâncias e covariâncias amostrais com o aumento de n .

Código R

```
1 mu <- c(1, 2)
2 Sigma <- matrix(c(1, 0.8, 0.8, 2), nrow = 2)
3 ns <- c(5, 10, 50, 200)
4 B <- 200
5 resultados <- data.frame()
6 for (n in ns) {
7   for (b in 1:B) {
8     amostra <- mvrnorm(n, mu, Sigma)
9     S <- cov(amostra) * (n - 1) / n # versão não
10      corrigida
11     resultados <- rbind(resultados, data.frame(
12       n = n,
13       var_X1 = S[1, 1],
14       var_X2 = S[2, 2],
15       cov_X1X2 = S[1, 2]))}
```

Exemplo 5.6

Código R

```

1 # Gráfico das variâncias de X1
2 ggplot(resultados, aes(x = factor(n), y = var_X1)) +
3   geom_jitter(width = 0.2, alpha = 0.5) +
4   geom_hline(yintercept = 1, linetype = "dashed", color =
5     "red") +
6   labs(x = "Tamanho amostral (n)", y = "Variância amostral
7     de X1")
8
9 # Gráfico das variâncias de X2
10 ggplot(resultados, aes(x = factor(n), y = var_X2)) +
11   geom_jitter(width = 0.2, alpha = 0.5) +
12   geom_hline(yintercept = 2, linetype = "dashed", color =
13     "red") +
14   labs(x = "Tamanho amostral (n)", y = "Variância amostral
15     de X2")
16
17 # Gráfico da covariância entre X1 e X2
18 ggplot(resultados, aes(x = factor(n), y = cov_X1X2)) +
19   geom_jitter(width = 0.2, alpha = 0.5) +
20   geom_hline(yintercept = 0.8, linetype = "dashed", color =
21     "red") +
22   labs(x = "Tamanho amostral (n)", y = "Covariância
23     amostral entre X1 e X2")

```

- (b) À medida que o tamanho amostral n cresce, observa-se que os valores estimados das variâncias e covariâncias se tornam progressivamente mais concentrados ao redor dos valores populacionais verdadeiros. Esse comportamento evidencia, de forma empírica, a convergência de $\mathbf{S}$ para $\mathbf{\Sigma}$, conforme discutido anteriormente. No caso univariado, sabemos que as variâncias amostrais corrigidas estão relacionadas a distribuições qui-quadrado, o que justifica a assimetria observada nos gráficos para n pequenos. Com o aumento de n , essa assimetria vai sendo suavizada, e as distribuições das estimativas passam a se comportar aproximadamente como normais, com variabilidade decrescendo. Essa evidência empírica reforça a intuição de que os elementos da matriz $\mathbf{S}$ são estimadores consistentes (como veremos na próxima seção).

Antes de introduzirmos a distribuição da matriz de variâncias e covariâncias amostrais no caso multivariado, é importante lembrar um resultado clássico do caso univariado, que já foi discutido em disciplinas anteriores.

Seja $X_1, \dots, X_n$ uma amostra aleatória de uma população normal com média μ e variância σ^2 , ou seja, $X_j \sim \text{Normal}(\mu, \sigma^2)$ para todo j . A variância amostral corrigida, dada por

$$S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2,$$

é um estimador não-viesado de σ^2 . Um resultado importante, que já conhecemos, é que a quantidade

$$\frac{n-1}{\sigma^2} S^2 = \sum_{j=1}^n \left(\frac{X_j - \bar{X}}{\sigma} \right)^2$$

segue uma distribuição qui-quadrado com $n-1$ graus de liberdade.

Esse resultado estabelece um elo entre variabilidade amostral e uma distribuição de probabilidade bem conhecida. Nossa intenção, a partir de agora, é expandir esse raciocínio para o caso multivariado, no qual lidamos com vetores de observações e uma matriz que sintetiza suas variâncias e covariâncias. Essa generalização nos levará à chamada distribuição de Wishart, que desempenha um papel central na inferência estatística multivariada.

Definição 5.2: Distribuição Wishart

Seja $\mathbf{Z}_1, \dots, \mathbf{Z}_n$ vetores aleatórios independentes com distribuição $\text{Normal}_p(\mathbf{0}, \mathbf{\Sigma})$, então a matriz

$$\mathbf{W} = \sum_{j=1}^n \mathbf{Z}_j \mathbf{Z}_j^\top$$

possui *distribuição de Wishart*, com n graus de liberdade e matriz de escala $\mathbf{\Sigma}$:

$$\mathbf{W} \sim \text{Wishart}_p(n, \mathbf{\Sigma}).$$

A distribuição $\text{Wishart}_p(n, \mathbf{\Sigma})$ assume valores em matrizes simétricas definidas positivas de dimensão $p \times p$ e sua densidade depende apenas de $\mathbf{\Sigma}$ e de n , i.e.,

$$f(\mathbf{W}) = \frac{1}{2^{np/2} |\mathbf{\Sigma}|^{n/2} \Gamma_p\left(\frac{n}{2}\right)} |\mathbf{W}|^{(n-p-1)/2} \exp\left(-\frac{1}{2} \text{tr}(\mathbf{\Sigma}^{-1} \mathbf{W})\right),$$

em que $\Gamma_p(\cdot)$ é a função gama multivariada, definida por:

Definição 5.2

$$\Gamma_p(a) = \pi^{p(p-1)/4} \prod_{j=1}^p \Gamma\left(a - \frac{j-1}{2}\right), \quad \text{para } a > \frac{p-1}{2}.$$

A distribuição de Wishart pode ser vista como uma generalização multivariada da distribuição qui-quadrado. Enquanto a distribuição qui-quadrado descreve a variabilidade de amostras provenientes de uma população normal univariada, a distribuição de Wishart descreve a variabilidade das matrizes de variâncias e covariâncias amostrais provenientes de uma população normal multivariada.

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de uma população com distribuição $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com $\boldsymbol{\Sigma}$ definida positiva. A matriz

$$\mathbf{W} = \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^\top$$

segue uma distribuição de Wishart com $n - 1$ graus de liberdade e matriz de escala $\boldsymbol{\Sigma}$, e denotamos essa distribuição por

$$\mathbf{W} \sim \text{Wishart}_p(n - 1, \boldsymbol{\Sigma}).$$

No contexto da estatística multivariada, a distribuição Wishart surge naturalmente como a distribuição da matriz de variâncias e covariâncias amostrais (não dividida por $n - 1$), i.e., $(n - 1)\mathbf{S}$ sendo peça central em procedimentos inferenciais envolvendo $\boldsymbol{\Sigma}$.

Como a matriz de variâncias e covariâncias populacionais $\boldsymbol{\Sigma}$ é, em geral, desconhecida, não podemos utilizar diretamente a distribuição de $\bar{\mathbf{X}}$ para construir procedimentos de inferência sobre $\boldsymbol{\mu}$. No entanto, a matriz amostral $\mathbf{S}$ fornece informação independente sobre $\boldsymbol{\Sigma}$, e sua distribuição não depende de $\boldsymbol{\mu}$. Essa independência entre $\bar{\mathbf{X}}$ e $\mathbf{S}$, válida sob a suposição de normalidade multivariada, nos permite construir estatísticas que combinam ambas as quantidades para realizar inferência sobre o vetor de médias populacionais. Exploraremos essa ideia em maior profundidade adiante.

5.2.3 Comportamento assintótico de $\bar{\mathbf{X}}$ e $\mathbf{S}$

Mesmo fora do contexto normal, os estimadores $\bar{\mathbf{X}}$ e $\mathbf{S}$ mantêm propriedades importantes sob certas condições gerais. A intuição por trás desse comportamento foi explorada nos Exemplos 5.5 e 5.6. No primeiro, observamos que, à medida que o tamanho amostral cresce, a nuvem de pontos formados pelos vetores de médias amostrais se concentra em torno do verdadeiro vetor de médias populacionais $\boldsymbol{\mu}$. No segundo, vimos que as estimati-

vas de variâncias e covariâncias se aproximam de seus valores populacionais, revelando convergência também para a matriz Σ .

Esses comportamentos são formalmente descritos por dois resultados fundamentais da teoria da probabilidade: a Lei dos Grandes Números e o Teorema Central do Limite. Suas versões multivariadas garantem que, mesmo sem assumirmos normalidade, os estimadores $\bar{\mathbf{X}}$ e $\mathbf{S}$ ainda apresentam propriedades desejáveis quando a amostra é suficientemente grande.

Resultado 5.5: Lei dos Grandes Números Multivariada

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias Σ , ambas finitas. Então,

$$\bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \longrightarrow \boldsymbol{\mu} \quad \text{quando } n \rightarrow \infty,$$

no sentido da convergência quase certa (ou seja, com probabilidade 1).

DEMONSTRAÇÃO: Ver Teorema 2.4.6, p. 73, de Leite e Singer (1990).

Resultado 5.6: Teorema Central do Limite Multivariado

Seja $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória de uma população com vetor de médias $\boldsymbol{\mu}$ e matriz de variâncias e covariâncias Σ , ambas finitas. Então,

$$\sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \longrightarrow \text{Normal}_p(\mathbf{0}, \Sigma) \quad \text{quando } n \rightarrow \infty,$$

no sentido da convergência em distribuição.

DEMONSTRAÇÃO: Ver Teorema 3.2.8, p. 90, de Leite e Singer (1990).

Esses dois resultados justificam o uso prático de $\bar{\mathbf{X}}$ e $\mathbf{S}$ mesmo em situações nas quais a suposição de normalidade multivariada não é apropriada. Desde que o tamanho amostral seja suficientemente grande, podemos esperar que a distribuição amostral de $\bar{\mathbf{X}}$ seja aproximadamente normal, com matriz de variâncias e covariâncias se aproximando de Σ . Em aplicações reais, essa robustez é fundamental para garantir validade inferencial em contextos mais gerais.

5.3 Teste de hipóteses para o vetor de médias de uma população normal

Neste ponto de nosso estudo, passamos a tratar de técnicas formais de inferência estatística aplicadas ao vetor de médias populacionais $\boldsymbol{\mu}$ em contextos multivariados. Mais especificamente, nosso foco será o teste de hipóteses sobre $\boldsymbol{\mu}$, assumindo que os dados provêm de uma população com distribuição normal multivariada. Essa abordagem amplia os conceitos univariados já conhecidos, incorporando a estrutura de correlação entre as variáveis e exigindo, portanto, uma análise conjunta dos componentes do vetor de médias.

A motivação central é a seguinte: quando trabalhamos com p variáveis correlacionadas, procedimentos que ignoram essa dependência podem levar a conclusões equivocadas. O teste que introduziremos leva essa dependência em conta de forma adequada, sendo construído a partir de estatísticas que combinam $\bar{\mathbf{X}}$ e $\mathbf{S}$. Essas estatísticas carregam, respectivamente, informação sobre a localização e a dispersão dos dados, e foram discutidas com cuidado em seções anteriores. Agora, faremos uso dessas quantidades para avaliar a plausibilidade de uma hipótese formulada sobre o vetor de médias populacionais.

O teste que desenvolveremos nesta seção pode ser visto como uma generalização natural do teste t de Student, amplamente utilizado no contexto univariado para avaliar hipóteses sobre médias populacionais. Assim como no caso univariado, nosso objetivo será comparar uma média amostral com um valor hipotético, levando em conta a variabilidade dos dados. A principal diferença é que agora lidamos com vetores de médias e matrizes de variâncias e covariâncias, exigindo uma abordagem que considere simultaneamente todas as variáveis envolvidas. A estatística de teste que utilizaremos será baseada na distribuição T^2 de Hotelling, uma distribuição que desempenha, no contexto multivariado, um papel análogo ao da distribuição t no caso univariado. Antes de apresentarmos essa estatística em sua forma geral, faremos uma breve revisão do teste t , retomando seus fundamentos com um exemplo simples. Esse passo nos permitirá estabelecer conexões conceituais importantes e preparar o terreno para o avanço ao caso multivariado.

Exemplo 5.7

A base de dados `rmvm`, disponível no pacote `asbio` do *software R*, contém informações provenientes de um estudo biométrico com 500 indivíduos. Para cada um deles, foram registradas 16 variáveis quantitativas de interesse. Inicialmente, estamos interessados em verificar se a média populacional μ_1 da concentração X_1 de uma determinada proteína no sangue difere de 2,5 mg/dL.

Exemplo 5.7

- (a) Construa um histograma para a variável X_1 e um gráfico de quantis teóricos versus quantis observados (Q-Q plot). Com base nesses gráficos, você acredita que os dados podem ter origem em uma população normalmente distribuída?
- (b) Aplique o teste de Shapiro-Wilk para avaliar a normalidade de X_1 . Ao nível de significância de 5%, qual é a sua conclusão?
- (c) Ainda ao nível de significância de 5%, você consideraria que há evidências suficientes para afirmar que a concentração média da proteína difere de 2,5 mg/dL? Defina as hipóteses, estatística de teste, regra de decisão e conclusão.

SOLUÇÃO:

(a)




Figura 5.3. Histograma para a concentração (em mg/dL) de uma determinada proteína no sangue junto o gráfico de quantis teóricos versus quantis observados (Q-Q plot).

Com base nos gráficos da Figura 5.3, temos um indicativo de que a concentração da proteína no sangue dos indivíduos da população da qual os dados foram coletados segue uma distribuição aproximadamente normal. No histograma, observa-se uma forma simétrica, com maior frequência de valores próximos à média e caudas que decaem suavemente nos dois sentidos. Já no gráfico

Exemplo 5.7

de quantis teóricos versus quantis observados (Q-Q plot), os pontos seguem aproximadamente a linha reta de referência, com pequenas discrepâncias apenas nas extremidades – o que é esperado mesmo em amostras de tamanho moderado. Esses aspectos reforçam a plausibilidade da suposição de normalidade para a variável em questão

Código R

```

1 #Verificando a suposição de normalidade
2
3 par(mfrow = c(1, 2))
4
5 #Histograma
6 hist(rmvm$X1,
7      main = "",
8      xlab = "Concentração da proteína no sangue",
9      ylab = "Frequência",
10     col = "LightGreen",
11     ylim = c(0,120))
12
13 #Gráfico QQ-plot
14 qqnorm(rmvm$X1,
15        main = "",
16        xlab = "Quantis teóricos",
17        ylab = "Quantis observados",
18        col = "Red");
19 qqline(rmvm$X1)

```

- (b) Com base no teste de Shapiro-Wilk, não rejeitamos a hipótese de que a amostra seja proveniente de uma população normalmente distribuída, já que o p -valor obtido (0,8022) é maior que o nível de significância previamente fixado ($\alpha = 5\%$).

Código R

```

1 #Verificando a suposição de normalidade
2
3 # Teste de Shapiro-Wilk
4 shapiro.test(rmvm$X1)

```

Exemplo 5.7(c) • **Hipóteses:**

$H_0: \mu_1 = 2,5$ (a concentração média da proteína no sangue é igual a 2,5 mg/dL),

$H_1: \mu_1 \neq 2,5$ (a concentração média da proteína no sangue é diferente de 2,5 mg/dL).

- **Estatística de teste:** Sob $H_0: \mu_1 = 2,5$, a estatística de teste é dada por

$$T = \frac{\bar{X}_1 - 2,5}{S_1/\sqrt{n}} \sim t_{n-1}, \quad \text{com } n = 500.$$

- **Regra de decisão:** Rejeitamos a hipótese $H_0: \mu_1 = 2,5$ ao nível de significância $\alpha = 5\%$ quando $t < -t_c$ ou $t > t_c$, em que t é o valor observado da estatística de teste T e $t_c \in \mathbb{R}_+$ é o valor crítico, i.e.,

$$\mathbb{P}(|T| > t_c | \mu_1 = 2,5) = 0,05.$$

- **Conclusão:** O valor observado da estatística de teste foi $t = 14,72$ e do ponto crítico foi $t_c = 1,96$. Como $t > t_c$, rejeitamos $H_0: \mu_1 = 2,5$ ao nível de significância de $\alpha = 5\%$. Concluimos, portanto, que há evidências suficientes para afirmar que a concentração média da proteína no sangue difere de 2,5 mg/dL.

Código R

```
1 #Conduzindo o teste t de Student
2 t.test(rmvn$X1, mu = 2.5, alternative = "two.side")
```

No Exemplo 5.7, aplicamos o que já aprendemos com teoria do caso univariado para determinar se um valor específico μ_0 é plausível como média populacional de uma variável aleatória normal. Do ponto de vista da inferência estatística, esse problema é tratado como um teste de hipóteses para o parâmetro μ :

$$H_0: \mu = \mu_0,$$

$$H_1: \mu \neq \mu_0.$$

Considere uma amostra aleatória $X_1, X_2, \dots, X_n$ de uma população normal com média μ e variância σ^2 desconhecida. A estatística de teste adequada é

$$t = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1},$$

em que

$$\bar{X} = \frac{1}{n} \sum_{j=1}^n X_j, \quad S^2 = \frac{1}{n-1} \sum_{j=1}^n (X_j - \bar{X})^2.$$

A estatística t tem distribuição t de Student com $n - 1$ graus de liberdade, sob a hipótese nula. Valores extremos de t (isto é, valores muito grandes em módulo) fornecem evidências contra $H_0 : \mu = \mu_0$. Rejeitamos $H_0 : \mu = \mu_0$ quando

$$|t| > t_c,$$

em que t é o valor observado da estatística de teste T e $t_c \in \mathbb{R}_+$ é o ponto crítico que representa o quantil superior da distribuição t de Student com $n - 1$ graus de liberdade ao nível de significância α , i.e.

$$\mathbb{P}(|T| > t_c | \mu = \mu_0) = \alpha.$$

Note que, elevando ao quadrado a estatística T , temos

$$T^2 = \frac{(\bar{X} - \mu_0)^2}{S^2/n} = n(\bar{X} - \mu_0)(S^2)^{-1}(\bar{X} - \mu_0).$$

Esse resultado sugere uma interpretação geométrica da estatística como uma medida de distância quadrática entre a média amostral $\bar{X}$ e o valor testado μ_0 , expressa em unidades de variância. Essa intuição é útil para o caso multivariado.

Suponha que $\mathbf{X}_1, \dots, \mathbf{X}_n$ seja uma amostra aleatória proveniente de uma população $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, com $\boldsymbol{\Sigma}$ definida positiva. Nosso objetivo é investigar se um vetor específico $\boldsymbol{\mu}_0$ pode ser considerado plausível como média populacional. A formulação do teste é

$$H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0 \quad \text{versus} \quad H_1: \boldsymbol{\mu} \neq \boldsymbol{\mu}_0.$$

Chamamos $\bar{\mathbf{X}} = \frac{1}{n} \sum_{j=1}^n \mathbf{X}_j$ o vetor de médias amostrais e

$$\mathbf{S} = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{X}_j - \bar{\mathbf{X}})(\mathbf{X}_j - \bar{\mathbf{X}})^\top$$

a matriz de variâncias e covariâncias amostral. Nesse sentido, uma extensão natural da estatística T^2 , determinada anteriormente para o caso univariado, é dada pela estatística T^2 de Hotelling, que é definida como

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0).$$

O valor de T^2 representa uma medida de distância quadrática entre o vetor de médias observado e o vetor testado, levando em conta a estrutura de correlação entre as variáveis. A intuição é análoga ao escore T^2 no teste univariado: quanto maior a distância de $\bar{\mathbf{X}}$ até $\boldsymbol{\mu}_0$, medida em unidades da variabilidade conjunta, menos plausível se torna $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$.

Sob a hipótese $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$, vale a representação

$$T^2 = \left(\sqrt{n} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \right)^\top \left[\frac{1}{n-1} \mathbf{W}_{p,n-1}(\boldsymbol{\Sigma}) \right]^{-1} \left(\sqrt{n} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \right),$$

na qual $\sqrt{n} (\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \text{Normal}_p(\mathbf{0}, \boldsymbol{\Sigma})$ e $\mathbf{W}_{p,n-1}(\boldsymbol{\Sigma})$ segue uma distribuição de Wishart com $n-1$ graus de liberdade e matriz de escala $\boldsymbol{\Sigma}$. A independência entre o vetor normal centrado e a matriz Wishart resulta em

$$\frac{n-p}{(n-1)p} T^2 \sim F_{p,n-p},$$

isto é, uma variável F de Snedecor com p e $n-p$ graus de liberdade.

Fixado um nível de significância $\alpha \in (0, 1)$, rejeitamos $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ sempre que

$$T^2 > \frac{(n-1)p}{n-p} f_c,$$

em que $f_c \in \mathbb{R}_+$ denota o quantil superior de ordem $100(1-\alpha)\%$ da distribuição $F_{p,n-p}$, i.e.,

$$\mathbb{P}(F > f_c) = \alpha,$$

em que $F \sim F_{p,n-p}$.

Assim, o procedimento multivariado reproduz a lógica do teste t univariado: comparamos uma medida de distância padronizada entre a média amostral e o valor hipotético a um ponto crítico obtido na distribuição apropriada. A estatística T^2 incorpora, porém, toda a estrutura de correlação da amostra por meio de $\mathbf{S}^{-1}$, garantindo um teste que respeita a dependência entre as variáveis. Nos exemplos seguintes aplicaremos esse resultado, interpretando os valores de T^2 da mesma forma que fizemos com T no contexto univariado.

Exemplo 5.8

Considere a mesma base de dados introduzida no Exemplo 5.7. Suponha que agora estejamos interessados nas seguintes variáveis:

- X_1 : Nível de concentração de uma determinada proteína no sangue de indivíduos saudáveis (em mg/dL);
- X_2 : Medida da pressão arterial sistólica em repouso (em $mmHg$);

Exemplo 5.8

- X_3 : Nível de oxigenação sanguínea medido por oximetria (em %).

Queremos verificar a plausibilidade do vetor de médias $\mu_0 = [4, 15 \quad 11, 1 \quad 94, 4]^\top$ para o vetor de médias populacionais μ do vetor aleatório $\mathbf{X} = [X_1 \quad X_2 \quad X_3]^\top$.

- Construa um histograma e um gráfico de quantis teóricos versus quantis observados (Q-Q plot) para cada uma das componentes do vetor aleatório $\mathbf{X}$ e, em seguida, aplique o teste de Shapiro-Wilk para avaliar a normalidade das marginais. Com base nos gráficos e nos testes, você acredita que os dados podem ter origem em uma população multivariada normalmente distribuída? Por quê? Use um nível de significância de 5% para o teste.
- Construa o gráfico de dispersão multivariado. Com base nesse gráfico, você acredita que os dados podem ter origem em uma população multivariada normalmente distribuída? Por quê?
- Ainda ao nível de significância de 5%, teste a plausibilidade do vetor de médias $\mu_0 = [4, 15 \quad 11, 1 \quad 94, 4]^\top$ para o vetor de médias populacionais μ do vetor aleatório $\mathbf{X}$. Defina as hipóteses, estatística de teste, regra de decisão e conclusão.

SOLUÇÃO:

- Com base nos gráficos apresentados na Figura 5.4, temos indícios favoráveis à suposição de normalidade marginal para as três componentes do vetor aleatório $\mathbf{X}$. Os histogramas revelam distribuições aproximadamente simétricas e unimodais com caudas que decaem suavemente nos dois sentidos, enquanto os gráficos de quantis observados versus quantis teóricos (Q-Q plots) mostram que os pontos se alinham de forma bastante satisfatória à reta de referência, sugerindo compatibilidade com a distribuição normal.

Complementando a análise gráfica com os testes de Shapiro-Wilk, obtemos os seguintes resultados:

- p -valor para X_1 : 0,8022;
- p -valor para X_2 : 0,5083;
- p -valor para X_3 : 0,2126.

Exemplo 5.8

Como todos os p -valores são maiores que o nível de significância $\alpha = 5\%$, não rejeitamos a hipótese de normalidade marginal para nenhuma das variáveis. Portanto, tanto os gráficos quanto os testes indicam que é plausível assumir que os dados provêm de uma população com distribuição aproximadamente normal multivariada. Isso não garante normalidade conjunta, mas a evidência empírica sugere que a suposição é razoável neste contexto.




Figura 5.4. Histogramas para as componentes do vetor aleatório $\mathbf{X}$ junto com os respectivos gráficos de quantis teóricos versus quantis observados (Q-Q plot).

Código R

```
1 #Verificando a suposição de normalidade
2
3 par(mfrow = c(2, 3))
4
5 # Histogramas
6 hist(rmvm$X1, main = "", xlab = "Concentração da proteína",
7      ylab = "Frequência", col = "LightGreen")
8 hist(rmvm$X2, main = "", xlab = "Pressão sistólica", ylab = "
9      Frequência", col = "LightGreen")
```


Exemplo 5.8

Código R

```

1 hist(rmvm$X3, main = "", xlab = "Nível de oxigenação",
  ylab = "Frequência", col = "LightGreen")
2
3 # Gráficos Q-Q
4 qqnorm(rmvm$X1, main = "", xlab = "Quantis teóricos", ylab
  = "Quantis observados", col = "Red");
5 qqline(rmvm$X1)
6 qqnorm(rmvm$X2, main = "", xlab = "Quantis teóricos", ylab
  = "Quantis observados", col = "Red");
7 qqline(rmvm$X2)
8 qqnorm(rmvm$X3, main = "", xlab = "Quantis teóricos", ylab
  = "Quantis observados", col = "Red");
9 qqline(rmvm$X3)
10
11 # Teste de Shapiro-Wilk
12 shapiro.test(rmvm$X1)
13 shapiro.test(rmvm$X2)
14 shapiro.test(rmvm$X3)

```

- (b) Com base no gráfico de dispersão multivariado apresentado, é plausível supor que os dados podem ter origem em uma população normal multivariada. As nuvens de pontos entre os pares de variáveis exibem formas aproximadamente circulares, com distribuição simétrica em torno de um centro e sem indícios evidentes de assimetria, caudas pesadas ou agrupamentos fora do padrão, o que está de acordo com o comportamento esperado sob normalidade multivariada. Embora o gráfico de dispersão não permita uma verificação definitiva da normalidade conjunta, ele fornece uma evidência visual consistente com essa suposição. Esse diagnóstico complementa a análise das marginais e o teste de Shapiro-Wilk aplicados no item (a).

Código R

```

(c)
1 #Teste T2-Hotelling
2 library(ICSNP)
3 dados <- rmvm[, c("X1", "X2", "X3")]
4 HotellingsT2(dados, mu = c(4.15, 11.1, 94.4))

```

Exemplo 5.8

- **Hipóteses:**

$$H_0: \boldsymbol{\mu} = \begin{bmatrix} 4,15 \\ 11,1 \\ 94,4 \end{bmatrix} \quad (\text{as médias populacionais são iguais aos valores de referência})$$

$$H_1: \boldsymbol{\mu} \neq \begin{bmatrix} 4,15 \\ 11,1 \\ 94,4 \end{bmatrix} \quad (\text{ao menos uma média populacional difere do valor de referência})$$

- **Estatística de teste:** Sob $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$, a estatística de teste T^2 de Hotelling é dada por

$$T^2 = n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \frac{(n-1)p}{n-p} F_{p,n-p}, \text{ com } n = 500 \text{ e } p = 3.$$

- **Regra de decisão:** Rejeitamos a hipótese $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$ ao nível de significância $\alpha = 5\%$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística de teste T^2 e $t_c^2 \in \mathbb{R}_+$ é o valor crítico, i.e.,

$$\mathbb{P}(T^2 > t_c^2 \mid \boldsymbol{\mu} = \boldsymbol{\mu}_0) = 0,05.$$

- **Conclusão:** O valor observado da estatística de teste foi $t^2 = 0,82$ e do ponto crítico foi $t_c^2 = 7,9$. Como $t^2 < t_c^2$, não rejeitamos a hipótese nula $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$. Concluimos, portanto, que não há evidências suficientes para afirmar que o vetor de médias populacionais difere de $[4,15 \ 11,1 \ 94,4]^\top$.




Figura 5.5. Gráfico de dispersão multivariado para o vetor aleatório $\mathbf{X}$ que contém a informação da concentração de proteína no sangue, pressão sistólica e nível de oxigenação de 500 indivíduos.

Exemplo 5.9

Considere a mesma base de dados introduzida no Exemplo 5.7 e as mesmas variáveis consideradas no Exemplo 5.8.

- (a) Ao nível de significância de 5%, teste a plausibilidade do vetor de médias $\boldsymbol{\mu}_0 = [2,5 \ 11,1 \ 94,4]^\top$ para o vetor de médias populacionais $\boldsymbol{\mu}$ do vetor aleatório $\mathbf{X}$. Defina as hipóteses, estatística de teste, regra de decisão e conclusão.
- (b) Sua resposta para o item (a) é consistente com aquela obtida no item (c) do Exemplo 5.7. Por quê?

SOLUÇÃO:

Código R

(a)

```
1 #Teste T2-Hotelling
2 library(ICSNP)
3 dados <- rmvm[, c("X1", "X2", "X3")]
4 HotellingsT2(dados, mu = c(2.5, 11.1, 94.4))
```

- **Hipóteses:**

$$H_0: \boldsymbol{\mu} = \begin{bmatrix} 2,5 \\ 11,1 \\ 94,4 \end{bmatrix} \quad (\text{as médias populacionais são iguais aos valores de referência})$$

$$H_1: \boldsymbol{\mu} \neq \begin{bmatrix} 2,5 \\ 11,1 \\ 94,4 \end{bmatrix} \quad (\text{ao menos uma média populacional difere do valor de referência})$$

- **Estatística de teste:** Sob $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$, a estatística de teste T^2 de Hotelling é dada por

$$T^2 = n (\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1} (\bar{\mathbf{X}} - \boldsymbol{\mu}_0) \sim \frac{(n-1)p}{n-p} F_{p,n-p}, \text{ com } n = 500 \text{ e } p = 3.$$

- **Regra de decisão:** Rejeitamos a hipótese $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$ ao nível de significância $\alpha = 5\%$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística de teste T^2 e $t_c^2 \in \mathbb{R}_+$ é o valor crítico, i.e.,

$$\mathbb{P}(T^2 > t_c^2 \mid \boldsymbol{\mu} = \boldsymbol{\mu}_0) = 0,05.$$

Exemplo 5.9

- **Conclusão:** O valor observado da estatística de teste foi $t^2 = 474,72$ e do ponto crítico foi $t_c^2 = 7,9$. Como $t^2 > t_c^2$, rejeitamos a hipótese nula $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$. Concluimos, portanto, que há evidências suficientes para afirmar que o vetor de médias populacionais difere de $[2,5 \ 11,1 \ 94,4]^\top$.
- (b) A resposta obtida no item (a) está em concordância com o resultado do item (c) do Exemplo 5.7. No item (c), ao testarmos se a média populacional da concentração da proteína no sangue era igual a 2,5 mg/dL, rejeitamos a hipótese nula ao nível de significância de 5%, indicando que esse valor de referência não é plausível para a média da população de onde os dados foram extraídos. Já no item (c), testamos simultaneamente as médias populacionais das três variáveis $[\mu_1 \ \mu_2 \ \mu_3]^\top$ e, novamente, rejeitamos a hipótese de que elas são iguais aos valores de referência $[2,5, \ 11,1, \ 94,4]^\top$. A rejeição conjunta inclui, em particular, a rejeição da hipótese de que $\mu_1 = 2,5$, o que reforça a consistência entre os dois testes.

O teste T^2 de Hotelling que desenvolvemos nesta seção é, na verdade, equivalente ao teste da razão de verossimilhanças para a hipótese $H_0 : \boldsymbol{\mu} = \boldsymbol{\mu}_0$ quando a matriz de variâncias e covariâncias populacional $\boldsymbol{\Sigma}$ é desconhecida. Essa equivalência garante que o teste T^2 compartilha das boas propriedades assintóticas dos testes baseados em razão de verossimilhanças. Em particular, quando o tamanho amostral é suficientemente grande, o teste possui o maior poder médio possível entre todos os testes de hipótese com tamanho fixado.

Por fim, é importante destacar que, ao rejeitarmos H_0 , não podemos afirmar qual ou quais componentes do vetor $\boldsymbol{\mu}$ são incompatíveis com os valores hipotetizados em $\boldsymbol{\mu}_0$. A rejeição pode ocorrer devido ao desvio de uma única média ou de uma combinação linear específica entre elas. Em aplicações práticas, raramente estamos interessados em testar se todos os componentes da média populacional são exatamente iguais a valores específicos. Em vez disso, geralmente buscamos identificar regiões de valores plausíveis para o vetor $\boldsymbol{\mu}$ com base nos dados observados e é justamente esse o caminho que seguiremos na próxima seção.

5.4 Regiões de confiança para o vetor de médias de uma população normal

Após estudarmos o teste T^2 de Hotelling para o vetor de médias populacionais, surge naturalmente a questão: quais valores de $\boldsymbol{\mu}$ são plausíveis à luz dos dados observados? Em outras palavras, ao invés de testarmos uma hipótese pontual como $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$, queremos encontrar um conjunto de valores de $\boldsymbol{\mu}$ que não sejam rejeitados pelo teste, ou seja, que estejam de acordo com as informações fornecidas pela amostra. Esse conjunto é conhecido como região de confiança para o vetor de médias populacionais.

Antes de tratarmos a construção de regiões de confiança para o vetor de médias populacionais, começaremos com um caso mais simples e familiar: o intervalo de confiança para a média de uma única variável, assumindo normalidade. Essa abordagem servirá como base para compreendermos a lógica por trás das comparações simultâneas e da construção de regiões de confiança no contexto multivariado. Vamos ilustrar esse procedimento por meio de um exemplo prático.

Exemplo 5.10

A base de dados `mtcars`, disponível no próprio *software R*, contém informações técnicas sobre o desempenho de diferentes modelos de automóveis, a partir de um estudo realizado na década de 1970. Para cada modelo, foram registradas diversas variáveis quantitativas relacionadas ao consumo e características do motor. Neste exemplo, nosso objetivo é construir um intervalo de confiança para a média populacional μ_1 da variável X_1 , que representa o consumo médio de combustível (mpg) medido em milhas por galão.

- (a) Construa um histograma da variável X_1 e um gráfico de quantis teóricos versus quantis observados (Q-Q plot). Com base nos gráficos, avalie a possibilidade dos dados terem se originados de uma população normalmente distribuída.
- (b) Aplique o teste de Shapiro-Wilk para avaliar a normalidade da variável X_1 . Ao nível de significância de 5%, qual é a sua conclusão?
- (c) Supondo que a suposição de normalidade seja plausível, construa uma região de confiança com 95% de confiança para a média populacional μ_1 .

Exemplo 5.10**SOLUÇÃO:**

(a)




Figura 5.6. Histograma para o consumo de combustível (em mpg) junto ao gráfico de quantis teóricos versus quantis observados (Q-Q plot).

Com base nos gráficos da Figura 5.6, observamos que a distribuição da variável X_1 (consumo de combustível, em milhas por galão) apresenta uma assimetria à direita. O histograma mostra uma maior concentração de observações entre 15 e 20 mpg, enquanto valores mais altos de consumo aparecem em menor frequência, estendendo a cauda da distribuição. Já no gráfico de quantis teóricos versus quantis observados (Q-Q plot), as observações associadas aos maiores valores de consumo se afastam da linha de referência, especialmente à direita, indicando a presença de desvios em relação à normalidade.

Esses padrões sugerem que os dados podem não ter origem em uma população perfeitamente normal. No entanto, a maior parte das observações permanece próxima da linha, o que pode indicar que a normalidade não está completamente

Exemplo 5.10

descartada. Para avaliar essa suposição com maior rigor, a aplicação de um teste formal de normalidade se faz necessária.

Código R

```

1 #Verificando a suposição de normalidade
2
3 par(mfrow = c(1, 2))
4
5 #Histograma
6 hist(dados$mpg,
7       main = "",
8       xlab = "Consumo de combustível",
9       ylab = "Frequência",
10      col = "lightgreen")
11
12 #Gráfico QQ-plot
13 qqnorm(dados$mpg,
14        main = "",
15        xlab = "Quantis teóricos",
16        ylab = "Quantis observados",
17        col = "Red");
18 qqline(dados$mpg)

```

- (b) Com base no teste de Shapiro-Wilk, não rejeitamos a hipótese de que a amostra seja proveniente de uma população normalmente distribuída, já que o p -valor obtido (0,1229) é maior do que o nível de significância previamente fixado ($\alpha = 5\%$).

Código R

```

1 #Verificando a suposição de normalidade
2
3 # Testes de normalidade univariada
4 shapiro.test(dados$mpg)

```

- (c) Como a suposição de normalidade foi considerada plausível nos itens anteriores, é possível utilizar a distribuição t de Student para construir o intervalo de confiança para a média populacional μ_1 do consumo de combustível.

Exemplo 5.10

- **Quantidade pivotal:**

$$T := \frac{\bar{X}_1 - \mu_1}{S_{11}/\sqrt{n}} \sim t_{n-1}, \quad \text{com } n = 32.$$

- **Intervalo de confiança:** Fixado um nível de confiança 95%, um intervalo de confiança para μ_1 é dado por

$$IC(\mu_1, 95\%) = \left[\bar{X}_1 - t_c \frac{s_{11}}{\sqrt{n}}; \bar{X}_1 + t_c \frac{s_{11}}{\sqrt{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ é tal que

$$\mathbb{P}(-t_c \leq T \leq t_c) = 95\%.$$

1. **Conclusão:** Observada a amostra uma estimativa intervalar para μ_1 com 95% de confiança é dada por

$$IC(\mu_1, 95\%) = [17,92, 22,26].$$

Isso significa que, com 95% de confiança, o consumo médio de combustível dos veículos dessa população encontra-se dentro desse intervalo.

Código R

```
1 # Intervalo de confiança de 95% para a média de mpg
2 t.test(mtcars$mpg, conf.level = 0.95)
```

No exemplo anterior, utilizamos os dados observados para construir um intervalo de confiança para a média populacional μ_1 do consumo de combustível. Agora, vamos retomar a teoria por trás dessa construção para o caso univariado. Suponha que $X_1, X_2, \dots, X_n$ seja uma amostra aleatória de uma população normal com média μ e variância σ^2 desconhecida. Sabemos que, nesse caso,

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}$$

é uma quantidade pivotal que segue uma distribuição t de Student com $n - 1$ graus de liberdade. A partir disso, podemos construir um intervalo com confiança de $1 - \alpha$, $\alpha \in (0, 1)$, para o parâmetro μ da seguinte forma

$$IC(\mu, 1 - \alpha) := \left[\bar{X} - t_c \cdot \frac{S}{\sqrt{n}}, \quad \bar{X} + t_c(1 - \alpha/2) \cdot \frac{S}{\sqrt{n}} \right]$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \alpha$

Esse intervalo é formado por todos os valores de μ que não seriam rejeitados ao nível α em um teste bilateral de hipóteses:

$$H_0: \mu = \mu_0 \quad \text{versus} \quad H_1: \mu \neq \mu_0.$$

Em outras palavras, para cada valor de μ_0 pertencente ao intervalo de confiança, o valor observado da estatística T não seria suficientemente extremo para rejeitar H_0 em um teste com nível de significância α . Por isso, os limites do intervalo fornecem uma descrição mais completa do conjunto de valores plausíveis para a média populacional, com base nos dados observados.

No caso univariado, aprendemos que é possível construir um intervalo de confiança para a média populacional μ , baseando-se na estatística da distribuição t de Student. De forma semelhante, no caso multivariado, desejamos construir uma *região de confiança* para o vetor de médias populacionais $\boldsymbol{\mu}$, que generaliza a ideia de um intervalo de confiança.

Dada uma amostra aleatória $\mathbf{X}_1, \dots, \mathbf{X}_n$ de um vetor aleatório $\mathbf{X}$ com distribuição $\text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ temos, com probabilidade $1 - \alpha$ (antes de observar a amostra), a seguinte desigualdade é satisfeita:

$$\mathbb{P} \left(n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} f_c \right) = 1 - \alpha,$$

em que $\bar{\mathbf{X}}$ é o vetor de médias amostrais, $\mathbf{S}$ é a matriz de variâncias e covariâncias amostrais e $f_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(F \leq f_c) = 1 - \alpha$, em que $F \sim F_{p, n-p}$.

Observada uma amostra $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, a região de confiança para $\boldsymbol{\mu}$ com nível de confiança $100(1 - \alpha)\%$ é, portanto, o conjunto de todos os vetores $\boldsymbol{\mu}$ que satisfazem

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} f_c,$$

definindo, geometricamente, um elipsóide centrado em $\bar{\mathbf{x}}$. Em outras palavras,

$$RC(\boldsymbol{\mu}, 1 - \alpha) = \left\{ \boldsymbol{\mu} \in \mathbb{R}^p : n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq \frac{(n-1)p}{n-p} f_c \right\}$$

Essa construção generaliza o conceito de intervalo de confiança para o caso multivariado e está intimamente relacionada com o teste T^2 de Hotelling. Assim como o intervalo

de confiança univariado contém todos os valores de μ_0 que não seriam rejeitados em um teste bilateral, o elipsóide de confiança multivariado contém todos os vetores μ_0 que não seriam rejeitados em um teste do tipo $H_0 : \mu = \mu_0$ contra $H_1 : \mu \neq \mu_0$ ao nível α .

Exemplo 5.11

A base de dados `mtcars`, disponível no *software R*, contém informações sobre o desempenho de diferentes modelos de carros. Dentre as variáveis registradas, temos o consumo de combustível em milhas por galão (`mpg`) e a cilindrada do motor (`disp`). Neste exercício, estamos interessados em construir uma região de confiança conjunta para o vetor de médias populacionais associado às variáveis $X_1 = \text{mpg}$ e $X_2 = \text{disp}$.

- Construa histogramas e gráficos de quantis teóricos versus quantis observados para cada uma das variáveis. Em seguida, aplique o teste de Shapiro-Wilk e avalie a normalidade marginal. Use o nível de significância de 5%. Avalie a plausibilidade dos dados terem se originado de uma população bivariada normalmente distribuída.
- Considere a variável $X_2^* = \log(\text{disp})$. Reavalie a plausibilidade dos dados terem se originado de uma população bivariada normalmente distribuída.
- Supondo que a suposição de normalidade bivariada seja plausível para o vetor $\begin{bmatrix} X_1 & X_2^* \end{bmatrix}^\top$, construa uma região de confiança com 95% de confiança para o vetor de médias populacionais $\mu = \begin{bmatrix} \mu_1 & \mu_2^* \end{bmatrix}^\top$. Descreva geometricamente essa região e interprete seu significado prático no contexto da base de dados.

SOLUÇÃO:

- Com base nos gráficos apresentados, observa-se que a variável $X_1 = \text{mpg}$ (consumo de combustível) apresenta uma distribuição assimétrica à direita. O histograma mostra maior concentração de valores entre 15 e 20 mpg, com alguns valores mais altos aparecendo com menor frequência. No gráfico de quantis teóricos versus quantis observados (Q-Q plot), os pontos seguem razoavelmente a linha de referência, com certo afastamento nos quantis superiores. Essa leve discrepância indica que a normalidade marginal pode não ser perfeitamente atendida, mas é plausível assumir que X_1 tenha origem em uma população aproximadamente normal, especialmente considerando o resultado do teste de Shapiro-Wilk ($p\text{-valor} = 0,1229$), que não rejeita a hipótese de normalidade ao nível de 5%.

Exemplo 5.11

A variável $X_2 = \text{disp}$ (cilindrada do motor), por sua vez, apresenta distribuição mais evidentemente assimétrica à direita, com concentração de valores menores e cauda longa à direita. Esse padrão é reforçado pelo Q-Q plot, no qual os pontos se afastam da linha de referência, especialmente nas extremidades. Ademais, o teste de Shapiro-Wilk (p -valor = 0,02081) também rejeita a hipótese de normalidade marginal ao nível de 5%.

Portanto, os padrões gráficos e os testes indicam que a suposição de normalidade conjunta para o vetor bivariado $[X_1 \ X_2]^T$ pode não ser plenamente atendida. A normalidade marginal de X_1 é plausível, mas a violação em X_2 compromete a plausibilidade de uma distribuição normal bivariada. Avaliar transformações para X_2 pode ser uma estratégia interessante antes de prosseguir com métodos que assumem normalidade multivariada.

Código R

```

1 #Verificando a suposição de normalidade
2
3 par(mfrow = c(2, 2))
4
5 # Histogramas
6
7 hist(dados$mpg,
8      main = "",
9      xlab = "Consumo de combustível",
10     ylab = "Frequência",
11     col = "lightgreen")
12
13 hist(dados$disp,
14      main = "",
15      xlab = "Cilindrada do motor",
16      ylab = "Frequência",
17      col = "lightgreen")
18
19 #Gráfico QQ-plot
20 qqnorm(dados$mpg,
21        main = "",
22        xlab = "Quantis teóricos",

```

Exemplo 5.11

Código R

```

1      ylab = "Quantis observados",
2      col = "Red");
3 qqline(dados$mpg)
4
5 qqnorm(dados$disp,
6        main = "",
7        xlab = "Quantis teóricos",
8        ylab = "Quantis observados",
9        col = "Red");
10 qqline(dados$disp)
11
12 # Testes de normalidade univariada
13 shapiro.test(dados$mpg)
14 shapiro.test(dados$disp)

```




Figura 5.7. Histogramas para o consumo de combustível (em mpg) e para as cilindradas do motor junto aos gráficos de quantis teóricos versus quantis observados (Q-Q plot).

Exemplo 5.11

- (b) O histograma de X_2^* sugere uma distribuição mais simétrica em comparação com a variável original X_2 , e o gráfico de quantis teóricos versus quantis observados (Q-Q plot) mostra um melhor alinhamento dos pontos à linha de referência, com apenas pequenas discrepâncias nas extremidades. Além disso, o teste de Shapiro-Wilk aplicado à variável transformada resultou em um p -valor de aproximadamente 0,053, o que indica que, ao nível de significância de 5%, não rejeitamos a hipótese de normalidade marginal para $X_2^* = \log(X_2)$.

Comparando com o item (a), onde já havíamos considerado que $X_1 = \text{mpg}$ apresentava uma distribuição aproximadamente normal, a transformação da segunda variável contribui para que a suposição conjunta de normalidade bivariada se torne mais plausível. Embora os dados ainda possam não se ajustar perfeitamente a uma distribuição normal bivariada, os indícios gráficos e o resultado dos testes estatísticos reforçam a razoabilidade dessa hipótese no contexto da análise proposta.




Figura 5.8. Histograma para o logaritmo das cilindradas do motor junto ao gráfico de quantis teóricos versus quantis observados (Q-Q plot).

Exemplo 5.11

Código R

```

1 # Histograma
2
3 hist(log(dados$disp),
4       main = "",
5       xlab = "log(Cilindrada do motor)",
6       ylab = "Frequência",
7       col = "lightgreen")
8
9 #Gráfico QQ-plot
10
11 qqnorm(log(dados$disp),
12         main = "",
13         xlab = "Quantis teóricos",
14         ylab = "Quantis observados",
15         col = "Red");
16 qqline(log(dados$disp))
17
18 # Testes de normalidade univariada
19 shapiro.test(log(dados$disp))

```

- (c) Como a suposição de normalidade foi considerada plausível nos itens anteriores, é possível utilizar a variável aleatória T^2 de Hotelling para construir a região de confiança para o vetor de médias populacionais μ^* associado às variáveis consumo X_1 de combustível em milhas por galão e o logaritmo da cilindrada $X_2^* = \log(X_2)$ do motor.

- **Quantidade pivotal:**

$$T^2 = n \left(\bar{\mathbf{X}}^* - \mu^* \right)^\top \mathbf{S}^{*,-1} \left(\bar{\mathbf{X}}^* - \mu^* \right) \sim \frac{(n-1)p}{n-p} F_{p,n-p},$$

com $n = 32$ e $p = 2$.

- **Região de confiança:** Fixado um nível de confiança de 95%, a região de confiança para μ^* é dada por

Exemplo 5.11

$$RC(\boldsymbol{\mu}^*, 95\%) = \left\{ \boldsymbol{\mu}^* \in \mathbb{R}^2 : (\bar{\mathbf{x}}^* - \boldsymbol{\mu}^*)^\top \mathbf{S}^{*,-1} (\bar{\mathbf{x}}^* - \boldsymbol{\mu}^*) \leq c^2 \right\},$$

em que $c^2 = \frac{(n-1)p}{n(n-p)} f_c$, $f_c \in \mathbb{R}_+$ é o valor crítico associado à distribuição F com $p = 2$ e $n - p = 30$ graus de liberdade, i.e., $\mathbb{P}(F \leq f_c) = 1 - \alpha$, com $F \sim F_{2,30}$.

- **Conclusão:** Observada a amostra uma estimativa para $\boldsymbol{\mu}^*$ com 95% de confiança é dada pela região $RC(\boldsymbol{\mu}^*, 95\%)$ que trata-se de um elipse centrada no vetor de médias amostrais $\bar{\mathbf{x}}^* = [20,09 \quad 5,29]^\top$, cujo o eixo maior tem tamanho

$$2c\sqrt{\lambda_1} = 2 \times \sqrt{0,21} \times \sqrt{36,61} = 5,55$$

com direção e sentido igual ao do autovetor $\mathbf{e}_1 = [-0,99 \quad 0,08]^\top$, e o eixo menor tem tamanho

$$2c\sqrt{\lambda_2} = 2 \times \sqrt{0,21} \times \sqrt{0,61} = 0,30$$

com direção e sentido igual ao do autovetor $\mathbf{e}_1 = [-0,99 \quad 0,08]^\top$. Isso significa que, com 95% de confiança, o vetor contendo o consumo médio de combustível dos veículos e o logaritmo da cilindrada do motor dessa população encontra-se dentro dessa região.




Figura 5.9. Região de 95% de confiança para o vetor contendo o consumo médio de combustível dos veículos e o logaritmo da cilindrada do motor.

Exemplo 5.11

Código R

```

1 # Instale o pacote se necessário
2 install.packages("ellipse")
3
4 library(ellipse)
5
6 # Dados fornecidos
7 mu <- c(20.090625, 5.284836)
8 S <- matrix(c(36.324103, -3.216173,
9               -3.216173, 0.3460685),
10            nrow = 2, byrow = TRUE)
11 n <- 32
12 p <- 2
13
14 alpha <- 0.05
15
16 # Constante crítica (ajustada)
17 f_crit <- qf(1 - alpha, p, n - p)
18 c2 <- (p * (n - 1) / (n * (n - p))) * f_crit
19
20 # Geração da elipse (agora com matriz S ao invés de S/n)
21 elip <- ellipse(S, centre = mu, level = sqrt(c2), t =
22               TRUE)
23
24 # Gráfico
25 plot(elip, type = "l", lwd = 2, col = "blue",
26       xlab = "Consumo médio de combustível (mpg)",
27       ylab = "log(Cilindrada do motor)",
28       main = "Região de confiança conjunta (95%)")
29
30 # Média amostral
31 points(mu[1], mu[2], pch = 19, col = "red")
32
33 # Autovalores e autovetores
34 eig <- eigen(S)
35 eig_vals <- eig$values
36 eig_vecs <- eig$vectors

```


Embora a inspeção visual por meio de histogramas, gráficos de quantis teóricos versus quantis observados (Q-Q plots) e gráficos de dispersão forneça informações importantes sobre a plausibilidade da normalidade multivariada, testes formais podem complementar essa análise. Um dos testes mais utilizados para verificar essa suposição é o teste de Mardia. Esse teste avalia a normalidade conjunta a partir de dois aspectos fundamentais: a simetria multivariada e o achatamento (ou curtose) da distribuição. Intuitivamente, a estatística de simetria compara as distâncias entre observações com o centro da distribuição, enquanto a estatística de curtose analisa o quanto os dados se concentram ou se dispersam em torno desse centro. Valores extremos dessas estatísticas, quando comparados a distribuições de referência adequadas, indicam desvios relevantes da normalidade. A seguir, aplicaremos esse teste aos vetores aleatórios considerados nos exemplos anteriores.

Exemplo 5.12

Considere os problemas do Exemplo 5.8 (concentração X_1 de proteína, pressão arterial X_2 e nível X_3 de oxigenização) e do Exemplo 5.10 (consumo de combustível e cilindrada do motor).

- Aplique o teste de Mardia para verificar a normalidade trivariada do vetor aleatório $\mathbf{X} = [X_1 \ X_2 \ X_3]^\top$ do Exemplo 5.8. Compare com as análises univariadas feitas anteriormente.
- Aplique o teste de Mardia para verificar a normalidade bivariada do vetor aleatório $\mathbf{X} = [X_1 \ X_2]^\top$ do Exemplo 5.10. Compare com as análises univariadas feitas anteriormente.
- Aplique o teste de Mardia para verificar a normalidade bivariada do vetor aleatório $\mathbf{X} = [X_1 \ X_2^*]^\top$ do Exemplo 5.10, em que $X_2^* = \log(X_2)$. Compare com as análises univariadas feitas anteriormente.

SOLUÇÃO:

- Ao aplicar o teste de Mardia ao vetor aleatório trivariado $\mathbf{X} = [X_1 \ X_2 \ X_3]^\top$, obtemos como resultado uma estatística de assimetria $b_{1p} = 14$, com valor de probabilidade igual a 0,17, e uma estatística de curtose $b_{2p} = -1,82$, com valor de probabilidade igual a 0,068. Segundo o teste, ao nível de significância de 5%, não rejeitamos a hipótese nula de normalidade multivariada.

Esses resultados são coerentes com as análises univariadas previamente realizadas. No gráfico de quantis teóricos versus quantis observados na Figura 5.10, os

Exemplo 5.12

pontos estão razoavelmente alinhados com a linha de referência, o que reforça a plausibilidade da suposição de normalidade conjunta. Portanto, a evidência empírica sugere que o vetor $\mathbf{X}$ pode ter origem em uma população trivariada normalmente distribuída.




Figura 5.10. Gráficos de quantis teóricos vs. quantis observados para a normalidade trivariada do vetor aleatório em estudo no Exemplo 5.8.

- (b) Com base no teste de Mardia aplicado às variáveis $X_1 = \text{mpg}$ (consumo de combustível) e $X_2 = \text{disp}$ (cilindrada do motor), observamos uma estatística de assimetria multivariada de aproximadamente 9,54, com valor-p igual a 0,049, e uma estatística de curtose igual a $-1,14$, com valor-p igual a 0,25. Considerando o nível de significância de 5%, um dos p-valores é superior ao limiar adotado e o outro inferior, portanto há evidências suficientes para rejeitar a hipótese de normalidade bivariada com base nesse teste.

Esses resultados dialogam com as análises marginais realizadas anteriormente. Enquanto a variável X_1 apresentava alguma assimetria à direita, mas sem rejeição significativa no teste de Shapiro-Wilk, a variável X_2 exigiu uma transformação logarítmica para atingir uma distribuição mais próxima da normal, o que é

Exemplo 5.12

reforçado pelo gráfico de quantis teóricos versus quantis observados na Figura 5.10, onde observamos algum afastamento nas caudas da reta de referência.




Figura 5.11. Gráficos de quantis teóricos vs. quantis observados para a normalidade bivariada do vetor aleatório em estudo no Exemplo 5.10, sem transformação logarítmica.

- (c) Após essa transformação, os gráficos de quantis teóricos versus quantis observados indicaram boa aderência à normalidade, o que é reforçado pela não rejeição da hipótese de normalidade bivariada no teste de Mardia, onde observamos uma estatística de assimetria multivariada de aproximadamente 4,72, com valor-p igual a 0,32, e uma estatística de curtose igual a $-1,22$, com valor-p igual a 0,22.

Portanto, os resultados obtidos pelo teste formal estão coerentes com as avaliações gráficas univariadas e bivariadas conduzidas anteriormente, reforçando a plausibilidade da suposição de normalidade bivariada para o vetor aleatório composto pelas variáveis transformadas $X_1 = \text{mpg}$ e $X_2 = \log(\text{disp})$.


Exemplo 5.12

Figura 5.12. Gráficos de quantis teóricos vs. quantis observados para a normalidade bivariada do vetor aleatório em estudo no Exemplo 5.8, com transformação logarítmica.

Código R

```
1 mardia(dados[, c("mpg", "disp")])
2 mardia(dados[, c("mpg", "log_disp")])
3 mardia(rvm[, c("X1", "X2", "X3")])
```

Vale destacar que a região de confiança construída para o vetor de médias fornece, de maneira visual e geométrica, as combinações de valores populacionais para as quais não rejeitaríamos a hipótese nula no teste T^2 de Hotelling. Sendo assim, é esperado que valores localizados fora dessa região levem à rejeição da hipótese nula, enquanto valores no interior sejam suportados pelos dados observados.

Exemplo 5.13

Considere o problema do Exemplo 5.10 (consumo de combustível e cilindrada do motor). Conduza o teste T^2 de Hotelling para alguns valores de referência dentro e fora da região de confiança.

Exemplo 5.13**SOLUÇÃO:**

Com base nos testes T^2 de Hotelling conduzidos, observamos que os seguintes vetores de médias populacionais não foram rejeitados ao nível de significância de 5%: $\mu_0 = \begin{bmatrix} 22 \\ 5,1 \end{bmatrix}$ (p -valor = 0,2153), $\mu_0 = \begin{bmatrix} 20 \\ 5,3 \end{bmatrix}$ (p -valor = 0,9838) e $\mu_0 = \begin{bmatrix} 18 \\ 5,5 \end{bmatrix}$ (p -valor = 0,1412). Esses resultados indicam que tais valores são compatíveis com o vetor de médias populacionais verdadeiro ao nível de confiança adotado, e estão contidos na região elipsoidal de confiança construída no Exemplo 5.11.

Por outro lado, o vetor $\mu_0 = \begin{bmatrix} 18 \\ 5,0 \end{bmatrix}$ resultou em um p -valor extremamente pequeno (p -valor $< 5,3 \times 10^{-11}$), o que leva à rejeição da hipótese nula com elevada evidência. Tal vetor está claramente localizado fora da região de confiança conjunta.

Esses resultados confirmam a coerência entre os testes de hipótese individuais e a interpretação geométrica da região de confiança: vetores não rejeitados nos testes estão situados dentro da elipse, enquanto vetores rejeitados estão fora. A região de confiança pode, portanto, ser compreendida como o conjunto dos vetores de médias populacionais para os quais o teste T^2 de Hotelling não leva à rejeição da hipótese nula.

Código R

```
1 HotellingsT2(dados[, c("mpg", "log_disp")], mu = c(22, 5.1))
2 HotellingsT2(dados[, c("mpg", "log_disp")], mu = c(20, 5.3))
3 HotellingsT2(dados[, c("mpg", "log_disp")], mu = c(18, 5.5))
4 HotellingsT2(dados[, c("mpg", "log_disp")], mu = c(18, 5))
```

Ao aplicar uma transformação não-linear, como a logarítmica, para tornar plausível a suposição de normalidade dos dados, é importante lembrar que o valor de referência utilizado nos testes não deve ser simplesmente a transformação do valor original de interesse. Por exemplo, se estamos interessados em testar se a média de uma variável original X é μ_0 , não é, em geral, correto realizar o teste com a hipótese de que $\mathbb{E}[\log(X)] = \log(\mu_0)$. Isso só seria válido sob condições muito restritas, como no caso em que $\log(X)$ é aproximadamente normal com variância pequena. De forma mais ampla, a decisão estatística tomada com base na variável transformada não pode ser automaticamente transferida para a escala original. Mesmo que a hipótese nula seja rejeitada na escala transformada, isso não implica necessariamente que a hipótese original (em termos da média de X) também seria rejeitada – e o contrário também é verdadeiro. Essa distinção deve ser considerada com cuidado na

interpretação dos resultados. Por outro lado, no caso de transformações lineares, como uma padronização do tipo $Y = aX + b$, a equivalência entre os testes na escala original e transformada é garantida, uma vez que a linearidade preserva as relações de esperança e variância de maneira proporcional.

5.5 Intervalos de confiança simultâneos

A região de confiança definida por

$$n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) \leq c^2$$

já resume o conhecimento conjunto sobre os valores plausíveis de $\boldsymbol{\mu}$. Entretanto, em muitas situações é útil traduzir essa informação para afirmações de confiança a respeito de *cada* componente do vetor de médias. De fato, quando estamos trabalhando com muitas variáveis, as regiões não possuem um apelo geométrico e, portanto, não são ferramentas acessíveis para clientes e pesquisadores sem uma sólida formação estatística. Estimativas intervalares são mais fáceis de interpretar e fazem mais sentido para esse tipo de público. Queremos, portanto, que todas as afirmações individuais sejam verdadeiras *simultaneamente* com alta probabilidade. Esse requisito motiva a construção dos chamados *intervalos de confiança simultâneos*.

É natural que a primeira estratégia para criar intervalos de confiança individuais para cada componente do vetor de médias populacionais seja considerar os intervalos de confiança para as médias de populações normais com variância desconhecida, os quais são baseados na distribuição t de Student e, portanto, também são conhecidos como *t-intervalos*. Iniciamos, portanto, discutindo intervalos dessa natureza. Para tal, vamos construir t -intervalos para quaisquer combinações lineares da forma $\mathbf{a}^\top \boldsymbol{\mu}$ de componentes do vetor de médias populacionais $\boldsymbol{\mu}$. A razão para essa escolha se fará clara mais adiante neste texto.

Seja $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e considere a combinação linear

$$Z := a_1 X_1 + a_2 X_2 + \cdots + a_p X_p = \mathbf{a}^\top \mathbf{X},$$

em que $\mathbf{a} = [a_1 \ \cdots \ a_p]^\top \in \mathbb{R}^p$ é um vetor de constantes qualquer. Pelo resultado de propriedades de combinações lineares de variáveis normais, temos

$$\begin{aligned} \mu_Z &= \mathbb{E}(Z) = \mathbf{a}^\top \boldsymbol{\mu}, \\ \sigma_Z^2 &= \text{Var}(Z) = \mathbf{a}^\top \boldsymbol{\Sigma} \mathbf{a}. \end{aligned}$$

Seja $\mathbf{x}_1, \dots, \mathbf{x}_n$ os vetores observados da amostra aleatória $\mathbf{X}_1, \dots, \mathbf{X}_n$ do vetor aleatório $\mathbf{X}$. Defina

$$z_j := \mathbf{a}^\top \mathbf{x}_j, \quad j = 1, \dots, n.$$

Note que, dessa forma, $\bar{z} = \mathbf{a}^\top \bar{\mathbf{x}}$ e $s_z^2 = \mathbf{a}^\top \mathbf{S} \mathbf{a}$, em que $\bar{\mathbf{x}}$ e $\mathbf{S}$ são, respectivamente, o vetor de médias e a matriz de variâncias e covariâncias amostrais observadas.

Sabemos que quando a variância σ_Z^2 é desconhecida, a variável aleatória

$$T := \frac{\bar{Z} - \mu_Z}{S_z / \sqrt{n}} = \frac{\sqrt{n}(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})}{\sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}}$$

segue distribuição t de Student com $n - 1$ graus de liberdade. Logo, um intervalo para $\mu_Z = \mathbf{a}^\top \boldsymbol{\mu}$ com $100 \times (1 - \alpha) \%$ de confiança é

$$IC(\mu_Z, 1 - \alpha) = \left[\bar{Z} \pm t_c \sqrt{\frac{S_z^2}{n}} \right]$$

ou, equivalentemente,

$$IC(\mathbf{a}^\top \boldsymbol{\mu}, 1 - \alpha) = \left[\mathbf{a}^\top \bar{\mathbf{X}} \pm t_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \alpha$, sendo $T \sim t_{n-1}$. Em outras palavras,

$$\mathbb{P} \left[\mathbf{a}^\top \bar{\mathbf{X}} - t_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \leq \mathbf{a}^\top \boldsymbol{\mu} \leq \mathbf{a}^\top \bar{\mathbf{X}} + t_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \right] = 1 - \alpha.$$

Escolher $\mathbf{a} = [1 \ 0 \ \dots \ 0]^\top$, por exemplo, recupera o intervalo usual para μ_1 , e assim por diante para os demais componentes. Contudo, exigir validade simultânea para *todas* as escolhas de $\mathbf{a}$ não preserva o nível $1 - \alpha$ desejado; é preciso um ajuste.

Exemplo 5.14

Uma amostra aleatória de 36 crianças da 5ª série do ensino fundamental de uma certa escola proporcionou uma altura média $\bar{x}_1 = 150$ cm com desvio-padrão de $\sqrt{s_{11}} = 5$ cm, e uma nota média em Matemática $\bar{x}_2 = 5$ pontos com desvio-padrão de $\sqrt{s_{22}} = 2$ pontos. Suponha que os dados tenham sido analisados e que a hipótese de normalidade bivariada para o vetor aleatório $\mathbf{X} = [X_1 \ X_2]^\top$ de acordo com o teste de Mardia seja plausível. Além disso, suponha ser razoável assumir que X_1 é independente de X_2 .

Exemplo 5.14

- (a) Fixado um nível de confiança de 95%, construa intervalos de confiança individuais (t -intervalos) para a altura média μ_1 e para nota média μ_2 das crianças da 5ª série do ensino fundamental de uma certa escola. Interprete os intervalos em termos do problema.
- (b) Qual é a probabilidade dos t -intervalos incluírem *simultaneamente* o verdadeiro valor de μ_1 e o verdadeiro valor de μ_2 .
- (c) Represente graficamente a região de confiança delimitada pelos t -intervalos obtidos no item (a). Interprete a região em termos do problema.

SOLUÇÃO:

- (a) Observada a amostra, temos $\bar{x}_1 = 150$ cm e $\sqrt{s_{11}} = 5$ cm. Logo, um intervalo para μ_1 com 95% de confiança é dado por

$$\begin{aligned} IC(\mu_1, 95\%) &= \left[\bar{x}_1 \pm t_c \sqrt{\frac{s_{11}}{n}} \right] \\ &= \left[150 \pm 2,03 \times \frac{5}{\sqrt{36}} \right] \\ &= [150 \pm 1,69] \\ &= [148,31; 151,69]. \end{aligned}$$

Portanto, com uma confiança de 95%, o intervalo $[148,31; 151,69]$ inclui a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão.

Por outro lado, observada a amostra, temos $\bar{x}_2 = 5$ cm e $\sqrt{s_{22}} = 2$ cm. Logo, um intervalo para μ_2 com 95% de confiança é dado por

$$\begin{aligned} IC(\mu_2, 95\%) &= \left[\bar{x}_2 \pm t_c \sqrt{\frac{s_{22}}{n}} \right] \\ &= \left[5 \pm 2,03 \times \frac{2}{\sqrt{36}} \right] \\ &= [5 \pm 0,68] \\ &= [4,32; 5,68]. \end{aligned}$$

Portanto, com uma confiança de 95%, o intervalo $[4,32; 5,68]$ inclui a verdadeira nota média das crianças da 5ª série do ensino fundamental da escola em questão.

Exemplo 5.14

(b) Como é plausível assumir que X_1 é independente de X_2 , temos

$$\begin{aligned} & \mathbb{P} \left\{ \bigcap_{i=1}^2 \left[\bar{X}_i - t_c \sqrt{\frac{S_{ii}}{n}} \leq \mu_i \leq \bar{X}_i + t_c \sqrt{\frac{S_{ii}}{n}} \right] \right\} \\ &= \prod_{i=1}^2 \mathbb{P} \left[\bar{X}_i - t_c \sqrt{\frac{S_{ii}}{n}} \leq \mu_i \leq \bar{X}_i + t_c \sqrt{\frac{S_{ii}}{n}} \right] \\ &= 0,95^2 \\ &= 0,9025. \end{aligned}$$

(c) Com 90,25% de confiança, simultaneamente, tanto o intervalo $[148,31; 151,69]$ inclui a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão, quanto o intervalo $[4,32; 5,68]$ inclui a verdadeira nota média dessas crianças.




Figura 5.13. Região de confiança delimitada pelos t -intervalos construídos para a altura média e a nota média de crianças da quinta série do ensino fundamental de uma certa escola.

Para realizar o ajuste supramencionado, primeiramente, observe que fixado um nível de

confiança $1 - \alpha$, temos para cada $\mathbf{a} \in \mathbb{R}^p$

$$\mathbb{P}(-t_c \leq T \leq t_c) = \mathbb{P}(T^2 \leq t_c^2) = 1 - \alpha,$$

em que

$$T = \frac{\sqrt{n}(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})}{\sqrt{\mathbf{a}^\top \mathbf{S} \mathbf{a}}} \sim t_{n-1}.$$

Como

$$T^2 = \frac{n(\mathbf{a}^\top \bar{\mathbf{x}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}},$$

segue que

$$\mathbb{P}\left(\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq t_c^2\right) = 1 - \alpha.$$

Portanto, como vimos no Exemplo 5.14,

$$\mathbb{P}\left(\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq t_c^2, \forall \mathbf{a} \in \mathbb{R}^p\right) \leq 1 - \alpha.$$

Para que *todas* as escolhas plausíveis de $\mathbf{a}$ compartilhem um mesmo coeficiente de confiança global $1 - \alpha$, substitui-se o limite t_c por um valor maior, digamos c^2 . Esse c^2 é selecionado de modo que

$$\mathbb{P}\left(\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq c^2, \forall \mathbf{a} \in \mathbb{R}^p\right) = 1 - \alpha.$$

Note que essa estratégia resulta numa região de confiança que inclui todas as combinações lineares $\mathbf{a}^\top \boldsymbol{\mu}$ com confiança $1 - \alpha$. Consequentemente, os intervalos extraídos dessa região – um para cada escolha de $\mathbf{a}$, i.e., cada combinação linear específica – são mais largos que os obtidos individualmente, refletindo o preço pago por garantir cobertura conjunta.

Para determinar c^2 tal que

$$\mathbb{P}\left(\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq c^2, \forall \mathbf{a} \in \mathbb{R}^p\right) = 1 - \alpha.$$

Observamos que

$$\max_{\mathbf{a} \in \mathbb{R}^p} \frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} = n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu}) := T^2.$$

Dessa forma, temos

$$\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq c^2, \forall \mathbf{a} \in \mathbb{R}^p \Leftrightarrow T^2 \leq c^2.$$

Logo,

$$\mathbb{P}(T^2 \leq c^2) = \mathbb{P}\left(\frac{n(\mathbf{a}^\top \bar{\mathbf{X}} - \mathbf{a}^\top \boldsymbol{\mu})^2}{\mathbf{a}^\top \mathbf{S} \mathbf{a}} \leq c^2, \forall \mathbf{a} \in \mathbb{R}^p\right) = 1 - \alpha.$$

Como já vimos,

$$T^2 \sim \frac{(n-1)p}{n-p} F_{p, n-p}.$$

Portanto,

$$c^2 = \frac{(n-1)p}{n-p} f_c,$$

em que $f_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{p, n-p}$.

Acabamos de mostrar que

$$\mathbb{P}\left[\mathbf{a}^\top \bar{\mathbf{X}} - \sqrt{\frac{(n-1)p}{n-p}} f_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \leq \mathbf{a}^\top \boldsymbol{\mu} \leq \mathbf{a}^\top \bar{\mathbf{X}} + \sqrt{\frac{(n-1)p}{n-p}} f_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}}, \forall \mathbf{a} \in \mathbb{R}^p\right] = 1 - \alpha.$$

Note que, *simultaneamente*, para *toda* $\mathbf{a} \in \mathbb{R}^p$, os intervalos da forma

$$\left[\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{(n-1)p}{n-p}} f_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \leq \mathbf{a}^\top \boldsymbol{\mu}\right]$$

incluem os verdadeiros valores de $\mathbf{a}^\top \boldsymbol{\mu}$ com confiança de *exatamente* $(1 - \alpha) \times 100\%$. Por outro lado, *individualmente*, para *cada* $\mathbf{a} \in \mathbb{R}^p$, cada intervalo da forma

$$\left[\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{(n-1)p}{n-p}} f_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \leq \mathbf{a}^\top \boldsymbol{\mu}\right]$$

inclui o verdadeiro valor de $\mathbf{a}^\top \boldsymbol{\mu}$ com confiança de *pelo menos* $(1 - \alpha) \times 100\%$. É conveniente referir-se a esses intervalos simultâneos como T^2 -intervalos, já que a cobertura é determinada pela distribuição da estatística T^2 .

Sucessivas escolhas de vetores

$$\mathbf{a}^\top = [1, 0, \dots, 0],$$

$$\mathbf{a}^\top = [0, 1, \dots, 0],$$

$$\vdots,$$

$$\mathbf{a}^\top = [0, \dots, 0, 1]$$

nos permitem construir intervalos simultâneos para cada componente de $\boldsymbol{\mu}$, i.e.,

$$IC(\mu_1, \geq 1 - \alpha) := \left[\bar{X}_1 \pm \sqrt{\frac{p(n-1)}{n(n-p)}} f_c \sqrt{\frac{S_{11}}{n}}\right],$$

$$\begin{aligned}
 IC(\mu_2, \geq 1 - \alpha) &:= \left[\bar{X}_2 \pm \sqrt{\frac{p(n-1)}{n(n-p)}} f_c \sqrt{\frac{S_{22}}{n}} \right], \\
 &\vdots \\
 IC(\mu_p, \geq 1 - \alpha) &:= \left[\bar{X}_p \pm \sqrt{\frac{p(n-1)}{n(n-p)}} f_c \sqrt{\frac{S_{pp}}{n}} \right]
 \end{aligned}$$

todos válidos *simultaneamente* com coeficiente de confiança $1 - \alpha$ e *individualmente* com coeficiente de confiança de *pelo menos* $1 - \alpha$.

Note que, sem alterar o coeficiente de confiança global, também é possível construir intervalos para diferenças $\mu_i - \mu_k$ escolhendo vetores $\mathbf{a}$ como

$$\mathbf{a}^\top = [0, \dots, 0, a_i, 0, \dots, 0, a_k, 0, \dots, 0],$$

em que $a_i = 1$ e $a_k = -1$.

Exemplo 5.15

Considere o mesmo problema descrito no Exemplo 5.14.

- Fixado um nível de confiança global de 95%, construa intervalos de confiança simultâneos (T^2 -intervalos) para a altura média e a nota média em Matemática das crianças da quinta série do ensino fundamental da escola em questão. Interprete esses intervalos em termos do problema.
- Compare os intervalos obtidos no item (a) com os t -intervalos obtidos no Exemplo 3.14. Para a comparação leve em consideração a confiança e a precisão (tamanho) dos intervalos.
- Represente no mesmo plano cartesiano a região de confiança delimitada pelos t -intervalos, a região de confiança delimitada pelos T^2 -intervalos e a elipse de confiança. Compare essas regiões.

SOLUÇÃO:

- Observada a amostra, temos $\bar{x}_1 = 150$ cm e $\sqrt{s_{11}} = 5$ cm. Logo, um intervalo para μ_1 com 95% de confiança é dado por

Exemplo 5.15

$$\begin{aligned}
 IC(\mu_1, \geq 95\%) &= \left[\bar{x}_1 \pm \sqrt{\frac{p(n-1)}{n(n-p)}} f_c \sqrt{\frac{s_{11}}{n}} \right] \\
 &= \left[150 \pm 5,93 \times \frac{5}{\sqrt{36}} \right] \\
 &= [150 \pm 4,94] \\
 &= [145,06; 154,94].
 \end{aligned}$$

Portanto, com uma confiança de pelo menos 95%, o intervalo [145,06; 154,94] inclui a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão.

Por outro lado, observada a amostra, temos $\bar{x}_2 = 5$ cm e $\sqrt{s_{22}} = 2$ cm. Logo, um intervalo para μ_2 com 95% de confiança é dado por

$$\begin{aligned}
 IC(\mu_2, \geq 95\%) &= \left[\bar{x}_2 \pm \sqrt{\frac{p(n-1)}{n(n-p)}} f_c \sqrt{\frac{s_{22}}{n}} \right] \\
 &= \left[5 \pm 5,93 \times \frac{2}{\sqrt{36}} \right] \\
 &= [5 \pm 1,98] \\
 &= [3,02; 6,98].
 \end{aligned}$$

Portanto, com uma confiança de 95%, o intervalo [3,02; 6,98] inclui a verdadeira nota média das crianças da 5ª série do ensino fundamental da escola em questão.

- (b) Por um lado, o T^2 -intervalo para μ_1 é [145,06; 154,94], enquanto o respectivo t -intervalo é [148,31; 151,69]. Por outro lado, o T^2 -intervalo para μ_2 é [3,02; 6,98], enquanto o respectivo t -intervalo é [4,32; 5,68]. Podemos notar que os T^2 intervalos são mais largos (menos precisos) do que os respectivos t -intervalos. Isso ocorre, porque, individualmente, os T^2 -intervalos são mais confiáveis (confiança de *pelo menos* 95%) do que os t -intervalos (confiança de *exatamente* 95%).
- (c) • Com *exatamente* 90,25% de confiança, simultaneamente, tanto o intervalo [148,31; 151,69] inclui a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão, quanto o intervalo [4,32; 5,68] inclui a verdadeira nota média dessas crianças.

Exemplo 5.15

- Com *exatamente* 95% de confiança, a elipse inclui, simultaneamente, tanto a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão, quanto a verdadeira nota média dessas crianças.
- Com *pelo menos* 95% de confiança, simultaneamente, tanto o intervalo $[145,06; 154,94]$ inclui a verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão, quanto o intervalo $[3,02; 6,98]$ inclui a verdadeira nota média dessas crianças.




Figura 5.14. Regiões de confiança delimitadas pelos t -intervalos, T^2 -intervalos e elipse de confiança construídas para a altura média e a nota média de crianças da quinta série do ensino fundamental de uma certa escola.

Note que, por um lado, a confiança de que os t -intervalos incluam as verdadeiras médias populacionais decrescem com número p de variáveis em análise, sendo cada vez menores do que o nível de confiança global $1 - \alpha$. Por outro lado, embora a confiança dos T^2 -intervalos sejam maiores do que o nível de confiança global $1 - \alpha$, eles são poucos precisos (muito largos).

Exemplo 5.16

De 50.000 válvulas fabricadas por uma cia., retira-se uma amostra de 61 válvulas e obtém-se a vida média de 800 horas o desvio-padrão de $\sqrt{244}$ horas e o tamanho médio de 120 mm e desvio-padrão de 15,25 mm. Suponha que seja plausível assumir que o tempo de vida e o tamanho das válvulas venham de uma população normal bivariada. Além disso, assuma ser plausível assumir independência entre essas variáveis.

- (a) Construa um intervalo de confiança para o verdadeiro tempo de vida médio das válvulas com 95% de confiança.
- (b) Construa um intervalo de confiança para o tamanho médio das válvulas com 95% de confiança.
- (c) Qual é a probabilidade de ambos os intervalos dos itens (a) e (b) conterem simultaneamente os respectivos parâmetros verdadeiros? Interprete.
- (d) Construa intervalos de confiança simultâneos (T^2 -intervalos) para μ_1 e μ_2 com 95% de confiança.
- (e) Compare os intervalos simultâneos (T^2 -intervalos) obtidos no item (d) com os intervalos individuais (t -intervalos) obtidos nos itens (a) e (b).
- (f) Construa uma região de confiança para o vetor de médias populacionais μ utilizando os intervalos de confiança individuais (t -intervalos). Qual é a confiança dessa região incluir o verdadeiro valor de μ ?
- (g) Construa uma região de confiança para o vetor de médias populacionais μ utilizando os intervalos de confiança simultâneos (T^2 -intervalos). Qual é a confiança dessa região incluir o verdadeiro valor de μ ?
- (h) Construa a elipse de confiança para o vetor de médias populacionais μ . Qual é a confiança dessa região incluir o verdadeiro valor de μ ?
- (i) Construa as regiões de confiança obtidas nos itens (f), (g) e (h) todas em um mesmo plano cartesiano e compare-as.

SOLUÇÃO:

(a) Sejam

X_1 : Tempo de vida da válvula (em horas),

Exemplo 5.16

μ_1 : Tempo de vida médio das válvulas (em horas),

$X_{1,1}, X_{2,1}, \dots, X_{61,1}$ a.a. de X_1 .

- **Quantidade pivotal:**

$$T = \frac{\bar{X}_1 - \mu_1}{\sqrt{S_{11}/n}} \sim t_{n-1}, \quad n = 61.$$

- **Intervalo de confiança:** Observada a amostra, temos $\bar{x}_1 = 800$ h e $s_{11} = 244$ h². Logo, o intervalo para μ_1 com 95% de confiança é dado por:

$$IC(\mu_1, 95\%) = \left[\bar{x}_1 \pm t_c \sqrt{\frac{s_{11}}{n}} \right] = \left[800 \pm 2 \cdot \sqrt{\frac{244}{61}} \right] = [796, 804].$$

- **Interpretação do intervalo:** Com 95% de confiança, o intervalo [796, 804] inclui o verdadeiro valor do tempo de vida médio das válvulas dessa cia.

(b) Sejam

X_2 : Tamanho da válvula (em mm),

μ_2 : Tamanho médio da válvula (em mm),

$X_{1,2}, X_{2,2}, \dots, X_{61,2}$ a.a. de X_2 .

- **Quantidade pivotal:**

$$T = \frac{\bar{X}_2 - \mu_2}{\sqrt{S_{22}/n}} \sim t_{n-1}, \quad n = 61$$

- **Intervalo de confiança:** Observada a amostra, temos $\bar{x}_2 = 120$ mm e $s_{22} = 15,25$ mm². Logo, o intervalo para μ_2 com 95% de confiança é dado por:

$$IC(\mu_2, 95\%) = \left[\bar{x}_2 \pm t_c \sqrt{\frac{s_{22}}{n}} \right] = \left[120 \pm 2 \cdot \sqrt{\frac{15,25}{61}} \right] = [119, 121].$$

- **Interpretação do intervalo:** Com 95% de confiança, o intervalo [119, 121] inclui o verdadeiro tamanho médio das válvulas dessa cia.

Exemplo 5.16

- (c) Defina os intervalos aleatórios $I_1 := [\bar{X}_1 \pm t_c \sqrt{\frac{S_{11}}{n}}]$ e $I_2 := [\bar{X}_2 \pm t_c \sqrt{\frac{S_{22}}{n}}]$, em seguida, defina os eventos

$$(I_1 \ni \mu_1) := \text{o intervalo } I_1 \text{ inclui o verdadeiro valor de } \mu_1,$$

$$(I_2 \ni \mu_2) := \text{o intervalo } I_2 \text{ inclui o verdadeiro valor de } \mu_2.$$

Logo, a probabilidade de cobertura simultânea é dada por

$$\mathbb{P}[(I_1 \ni \mu_1) \cap (I_2 \ni \mu_2)] = \mathbb{P}(I_1 \ni \mu_1) \cdot \mathbb{P}(I_2 \ni \mu_2) = 0,95 \times 0,95 = 0,9025,$$

pois estamos assumindo X_1 e X_2 variáveis aleatórias independentes.

Interpretação: Com 90,25% de confiança, simultaneamente, tanto o intervalo [796, 804] inclui o verdadeiro tempo de vida médio quanto o intervalo [119, 121] inclui o verdadeiro tamanho médio das válvulas dessa cia.

- (d) Sejam

$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$: vetor aleatório, cujas componentes são o tempo X_1 de vida (em horas) e o tamanho X_2 (em mm) das válvulas dessa cia,

$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$: vetor de médias populacionais, cujas componentes são o tempo de vida médio μ_1 (em horas) e o tamanho médio μ_2 (em mm) das válvulas dessa cia,

$\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_{61}$ a.a. de $\mathbf{X}$.

Fixado o nível de confiança de 95%, sabemos que

$$\mathbb{P} \left\{ \left[\mathbf{a}^\top \bar{\mathbf{X}} \pm \sqrt{\frac{(n-1)}{n-p}} f_c \cdot \frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n} \right] \ni \mathbf{a}^\top \boldsymbol{\mu}, \forall \mathbf{a} \in \mathbb{R}^2 \right\} = 0,95,$$

Logo,

$$\mathbb{P} \left\{ \left[\bar{X}_1 \pm \sqrt{\frac{(n-1)}{n-p}} f_c \cdot \frac{S_{11}}{n} \right] \ni \mu_1 \cap \left[\bar{X}_2 \pm \sqrt{\frac{(n-1)}{n-p}} f_c \cdot \frac{S_{22}}{n} \right] \ni \mu_2 \right\} \geq 0,95$$

Exemplo 5.16

- **Intervalos de confiança:** Observada a amostra, temos $\bar{x}_1 = 800$ h , $s_{11} = 244$ h², $\bar{x}_2 = 120$ mm, $s_{22} = 15,25$ mm², $n = 61$, $p = 2$, $f = 3,15$.

Logo, os intervalos que incluem μ_1 e μ_2 simultaneamente com 95% de confiança são, respectivamente:

$$\begin{aligned} \left[800 \pm \sqrt{\frac{60 \cdot 2 \cdot 3,15}{59} \cdot \frac{244}{61}} \right] &\approx [800 \pm 5,06] = [794,94, 805,06], \\ \left[120 \pm \sqrt{\frac{60 \cdot 2 \cdot 3,15}{59} \cdot \frac{15,25}{61}} \right] &\approx [120 \pm 1,27] = [118,73, 121,27]. \end{aligned}$$

- **Interpretação do intervalo:** Com pelo menos 95% de confiança, o intervalo $[794,94, 805,06]$ inclui o verdadeiro tempo de vida médio das válvulas da cia ao mesmo tempo que o intervalo $[118,73, 121,27]$ inclui o verdadeiro tamanho médio.

(e) • **Para μ_1 :**

- IC individual (t -intervalo): $[796, 804]$,
- IC simultâneo (T^2 -intervalo): $[794,94, 805,06]$

• **Para μ_2 :**

- IC individual: $[119, 121]$,
- IC simultâneo: $[118,73, 121,27]$.

- **Discussão:** Os intervalos simultâneos (T^2 -intervalos) para μ_1 e μ_2 são mais largos, pois a confiança de que cada um, individualmente, inclua o verdadeiro valor do parâmetro é maior do que 95%, enquanto a confiança dos intervalos individuais (t -intervalos) é exatamente 95%.

- **Justificativa:** De fato,

$$\mathbb{P} \left\{ \mu_i \in \left[\bar{X}_i \pm \sqrt{\frac{(n-1)}{n-p} f_c \cdot \frac{S_{ii}}{n}} \right] \right\} > 0,95.$$

Quanto maior a confiança exigida em relação a uma estimativa intervalar, menos precisos estaremos sendo e, portanto, mais largos os intervalos de confiança serão.

Exemplo 5.16

- (f) Com 90,25% de confiança, o verdadeiro vetor de médias populacionais μ está contido na região delimitada pelos intervalos de confiança individuais (t -intervalos.)




Figura 5.15. Região de confiança delimitada pelos t -intervalos construídos para o tempo de vida médio e para o tamanho médio das válvulas da cia.

(g)




Figura 5.16. Região de confiança delimitada pelos T^2 -intervalos construídos para o tempo de vida médio e para o tamanho médio das válvulas da cia. Com confiança de pelo menos 95%, a região delimitada pelos T^2 -intervalos incluem o verdadeiro vetor de médias populacionais μ .

Exemplo 5.16

(h) Sabemos que a região com 95% de confiança é definida por

$$RC(\boldsymbol{\mu}, 95\%) = \left\{ \boldsymbol{\mu} \in \mathbb{R}^2 : \frac{(\mu_1 - 800)^2}{244 \cdot c^2} + \frac{(\mu_2 - 120)^2}{15,25 \cdot c^2} \leq 1 \right\},$$

em que

$$c^2 = \frac{60 \cdot 2 \cdot 3,15}{59 \cdot 61} \approx 0,105.$$

Logo, a região de confiança é delimitada por uma elipse centrada em $\bar{\mathbf{x}} = \begin{bmatrix} 800 \\ 120 \end{bmatrix}$, com eixo maior paralelo ao eixo das abscissas, de extremidades $800 \pm 5,06$, e eixo menor paralelo ao eixo das ordenadas, com extremidades $120 \pm 1,27$.

Note que os intervalos simultâneos:

$$[794,94, 805,06] \quad \text{e} \quad [118,73, 121,27]$$

coincidem com os extremos da elipse.




Figura 5.17. Elipse de confiança construída para o tempo de vida médio e para o tamanho médio das válvulas da cia.

- **Conclusão:** Com confiança de 95%, a região elíptica inclui o verdadeiro vetor de médias populacionais $\boldsymbol{\mu}$.

Exemplo 5.16

- (i) A maior região é aquela delimitada pelo intervalos simultâneos (T^2 -intervalos), pois possui maior confiança 95%. A segunda maior região é a elipse que também possui exatamente 95% de confiança, enquanto a menor região é aquela delimitada pelos intervalos individuais (t -intervalos), que possui a menor confiança (90,25%). Todas as regiões incluem, simultaneamente, o verdadeiro tempo de vida médio e o verdadeiro tamanho médio das válvulas da companhia com os respectivos níveis de confiança.




Figura 5.18. Regiões de confiança delimitadas pelos t -intervalos, T^2 -intervalos e elipse de confiança construídas para o tempo de vida médio e para o tamanho médio das válvulas da cia.

Em muitas situações, o interesse está restrito a um número pequeno de afirmações de confiança individuais. Nesses casos, é possível obter regiões de confiança simultâneas menores (mais precisas) do que as fornecidas pelos intervalos T^2 . Um método alternativo para construções simultâneas é chamado de *método de Bonferroni*. Esse método é creditado ao matemático italiano Carlo Emilio Bonferroni, que publicou no início do século XX uma desigualdade fundamental da teoria da probabilidade. Embora sua motivação original tenha surgido no contexto de probabilidade pura, a desigualdade passou a ser amplamente

utilizada em inferência estatística como uma forma conservadora de controlar o erro do tipo I em testes múltiplos. Seu uso em estatística aplicada ganhou força a partir da década de 1950, especialmente em contextos em que se deseja garantir que várias inferências sejam simultaneamente válidas com elevado grau de confiança.

Suponha que, antes da coleta dos dados, deseje-se fazer afirmações de confiança sobre m combinações lineares $\mathbf{a}_1^\top \boldsymbol{\mu}, \mathbf{a}_2^\top \boldsymbol{\mu}, \dots, \mathbf{a}_m^\top \boldsymbol{\mu}$. Denote por C_i a afirmação de confiança sobre o valor de $\mathbf{a}_i^\top \boldsymbol{\mu}$, como, por exemplo, um intervalo aleatório que inclua o verdadeiro valor de $\mathbf{a}_i^\top \boldsymbol{\mu}$. Defina

$$\mathbb{P}[C_i \text{ verdadeira}] = 1 - \alpha_i, \quad i = 1, 2, \dots, m.$$

A probabilidade de todas essas afirmações serem simultaneamente verdadeiras é

$$\begin{aligned} \mathbb{P}[\text{todas as } C_i \text{ verdadeiras}] &= 1 - \mathbb{P}[\text{pelo menos uma } C_i \text{ falsa}] \\ &\geq 1 - \sum_{i=1}^m P(C_i \text{ falsa}) \\ &= 1 - \sum_{i=1}^m (1 - P(C_i \text{ verdadeira})) \\ &= 1 - (\alpha_1 + \alpha_2 + \dots + \alpha_m). \end{aligned}$$

A desigualdade anterior, conhecida como desigualdade de Bonferroni, permite controlar o erro global $\alpha_1 + \alpha_2 + \dots + \alpha_m$, independentemente da estrutura de correlação entre as afirmações de confiança. O método ainda permite atribuir diferentes níveis de importância a algumas afirmações, ajustando os α_i conforme necessário. Quando não temos informação *a priori* sobre qual o grau de importância das afirmações de confiança, podemos assumir $\alpha_i = \frac{\alpha}{m}$ para todo $i = 1, 2, \dots, m$, i.e., todas as afirmações de confiança possuem o mesmo grau de importância.

Desejando construir intervalos simultâneos para os componentes individuais μ_i do vetor de médias $\boldsymbol{\mu}$ de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$ e assumindo $\alpha_i = \alpha/p$, podemos utilizar os intervalos

$$\bar{x}_i \pm t_c \sqrt{\frac{S_{ii}}{n}}, \quad i = 1, 2, \dots, m,$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{m}$. Assim, para cada $i = 1, 2, \dots, p$,

$$\mathbb{P} \left(\left[\bar{X}_i \pm t_c \sqrt{\frac{S_{ii}}{n}} \right] \ni \mu_i \right) = 1 - \frac{\alpha}{p}$$

e, consequentemente, utilizando o método de Bonferroni discutido anteriormente, temos

$$\mathbb{P} \left(\bigcap_{i=1}^p \left\{ \left[\bar{X}_i \pm t_c \sqrt{\frac{S_{ii}}{n}} \right] \ni \mu_i \right\} \right) \geq 1 - \left(\frac{\alpha}{p} + \frac{\alpha}{p} + \cdots + \frac{\alpha}{p} \right) \\ = 1 - \alpha.$$

Portanto, fixado um *nível de confiança global* de $1 - \alpha$ e observada uma amostra $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, podemos escrever as $m = p$ afirmações sobre as componentes do vetor de médias populacionais $\boldsymbol{\mu}$ da seguinte maneira:

$$IC \left(\mu_1, 1 - \frac{\alpha}{p} \right) = \left[\bar{x}_1 - t_c \sqrt{\frac{s_{11}}{n}}; \bar{x}_1 + t_c \sqrt{\frac{s_{11}}{n}} \right], \\ IC \left(\mu_2, 1 - \frac{\alpha}{p} \right) = \left[\bar{x}_2 - t_c \sqrt{\frac{s_{22}}{n}}; \bar{x}_2 + t_c \sqrt{\frac{s_{22}}{n}} \right], \\ \vdots \\ IC \left(\mu_p, 1 - \frac{\alpha}{p} \right) = \left[\bar{x}_p - t_c \sqrt{\frac{s_{pp}}{n}}; \bar{x}_p + t_c \sqrt{\frac{s_{pp}}{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{p}$, sendo $T \sim t_{n-1}$.

Nesse sentido, se ao invés de intervalos simultâneos para os componentes do vetor de médias populacionais $\boldsymbol{\mu}$ de um vetor aleatório $\mathbf{X}$ de $\mathbb{R}^p$, estivéssemos interessados em construir intervalos simultâneos para m combinações lineares $\mathbf{a}^\top \boldsymbol{\mu}$ desse vetor de médias populacionais, poderíamos assumir $\alpha_i = \alpha/m$ para todo $i = 1, 2, \dots, m$ e utilizar o método de Bonferroni discutido anteriormente. Assim, fixado um nível de confiança global de $1 - \alpha$ e observada amostra $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, temos

$$IC \left(\mathbf{a}^\top \boldsymbol{\mu}, 1 - \frac{\alpha}{m} \right) = \left[\mathbf{a}^\top \bar{\mathbf{X}} \pm t_c \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{m}$ sendo $T \sim t_{n-1}$. Análogo ao caso dos componentes do vetor de médias populacionais, a probabilidade desses intervalos incluírem simultaneamente as m transformações lineares de interesse é de pelo menos $1 - \alpha$.

Note que os intervalos de Bonferroni para combinações lineares $\mathbf{a}^\top \boldsymbol{\mu}$ e os intervalos análogos do tipo T^2 possuem a mesma estrutura geral, i.e.,

$$\mathbf{a}^\top \bar{\mathbf{X}} \pm (\text{valor crítico}) \sqrt{\frac{\mathbf{a}^\top \mathbf{S} \mathbf{a}}{n}}.$$

Fixado um nível de confiança global de $1 - \alpha$, quando $\alpha_i = \alpha/m$, para todo $i = 1, 2, \dots, m$, a razão entre o comprimento do intervalo de Bonferroni e o do intervalo do tipo T^2 é dada por

$$\frac{\text{Comprimento do intervalo de Bonferroni}}{\text{Comprimento do intervalo } T^2} = \frac{t_c}{\sqrt{\frac{p(n-1)}{n-p}} f_c},$$

em que $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{p}$, sendo $T \sim t_{n-1}$, e $f_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{p, n-p}$. Note que a razão independe das quantidades aleatórias $\bar{\mathbf{X}}$ e $\mathbf{S}$. Para um número pequeno m de combinações paramétricas do tipo $\mathbf{a}^\top \boldsymbol{\mu}$, os intervalos de Bonferroni tendem a ser mais curtos do que os intervalos simultâneos do tipo T^2 . A Tabela 5.4 mostra o quanto eles são mais curtos para diferentes valores de n e $p = m$, quando $1 - \alpha = 0,95$.

Tabela 5.1 Razão entre o comprimento do intervalo de Bonferroni e o comprimento do intervalo T^2 para $1 - \alpha = 0,95$ e $\alpha_i = 0,05/m$.

n	$m = p = 2$	$m = p = 4$	$m = p = 10$
15	0,88	0,69	0,29
25	0,90	0,75	0,48
50	0,91	0,78	0,58
100	0,91	0,80	0,62
∞	0,91	0,81	0,66

Por outro lado, quando comparamos os intervalos de Bonferroni com os t -intervalos individuais construídos com nível de confiança $1 - \alpha$, temos

$$\frac{\text{Comprimento do intervalo de Bonferroni}}{\text{Comprimento do intervalo } t} = \frac{t_c^B}{t_c},$$

em que $t_c^B \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c^B \leq T \leq t_c^B) = 1 - \frac{\alpha}{p}$, sendo $T \sim t_{n-1}$, e $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \alpha$, sendo $T \sim t_{n-1}$.

Note que os t -intervalos são menores (mais precisos). Isso ocorre porque o valor crítico t_c^B dos intervalos de Bonferroni é associado a um nível de confiança individual maior que $1 - \alpha$, mais precisamente, $1 - \alpha/p$, enquanto o valor crítico t_c dos t -intervalos é associado a uma confiança de exatamente $1 - \alpha$.

Logo, ao passo que os intervalos de Bonferroni encurtam os intervalos simultâneos do tipo T^2 quando p é pequeno, eles necessariamente alargam os t -intervalos construídos individualmente. Esse alargamento é o preço a se pagar para garantir uma confiança simultânea mínima de $1 - \alpha$ sobre todos os parâmetros considerados.

Exemplo 5.17

- (a) Considere o mesmo problema discutido nos Exemplos 5.14 e 5.15. Fixado um nível de confiança global de 95%, construa os intervalos de Bonferroni para a altura média e a nota média em Matemática das crianças da quinta série do ensino fundamental da escola em questão. Compare-os com os t -intervalos e com os T^2 -intervalos. Para a comparação leve em consideração a confiança e a precisão (tamanho) dos intervalos.
- (b) Considere o mesmo problema discutido no Exemplos 5.16. Fixado um nível de confiança global de 95%, construa os intervalos de Bonferroni para o tempo de vida médio e o tamanho médio das válvulas fabricadas pela cia. Compare-os com os t -intervalos e com os T^2 -intervalos. Para a comparação leve em consideração a confiança e a precisão (tamanho) dos intervalos.

SOLUÇÃO:

(a) Sejam

$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$: vetor aleatório, cujas componentes são a altura X_1 (em cm) e a nota X_2 (em pontos) das crianças da quinta série do ensino fundamental da escola participante do estudo;

$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$: vetor de médias populacionais, cujas componentes são a altura média μ_1 (em cm) e a nota média μ_2 (em pontos) as crianças da quinta série do ensino fundamental da escola participante do estudo;

$\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_{36}$ a.a. de $\mathbf{X}$.

Observada a amostra, temos $\bar{x}_1 = 150$ cm e $\sqrt{s_{11}} = 5$ cm. Logo, fixado um nível de confiança global de 95%, um intervalo de Bonferroni para μ_1 com 97,5% de confiança é dado por

$$\begin{aligned} IC(\mu_1, 97,5\%) &= \left[\bar{x}_1 \pm t_c \sqrt{\frac{s_{11}}{n}} \right] \\ &= \left[150 \pm 2,34 \times \frac{5}{\sqrt{36}} \right] \\ &= [150 \pm 1,95] \\ &= [148,05; 151,95]. \end{aligned}$$

Portanto, com uma confiança de 97,5%, o intervalo $[148,05; 151,95]$ inclui a

Exemplo 5.17

verdadeira altura média das crianças da 5ª série do ensino fundamental da escola em questão.

Por outro lado, observada a amostra, temos $\bar{x}_2 = 5$ cm e $\sqrt{s_{22}} = 2$ cm. Logo, fixado um nível de confiança global de 95%, um intervalo de Bonferroni para μ_2 com 97,5% de confiança é dado por

$$\begin{aligned} IC(\mu_2, 97,5\%) &= \left[\bar{x}_2 \pm t_c \sqrt{\frac{s_{22}}{n}} \right] \\ &= \left[5 \pm 2,34 \times \frac{2}{\sqrt{36}} \right] \\ &= [5 \pm 0,78] \\ &= [4,22; 5,78]. \end{aligned}$$

Portanto, com uma confiança de 95%, o intervalo $[4,22; 5,78]$ inclui a verdadeira nota média das crianças da 5ª série do ensino fundamental da escola em questão.

	μ_1		μ_2	
	LI	LS	LI	LS
t -intervalos	148,31	151,69	4,32	5,68
Intervalos de Bonferroni	148,05	151,95	4,22	5,78
T^2 -intervalos	145,06	154,94	3,02	6,98

A partir da tabela anterior, notamos que os t -intervalos são os mais precisos, no sentido de apresentarem menor comprimento, mas também são os menos confiáveis, já que cada um deles possui apenas 95% de confiança individual, com confiança conjunta menor do que o nível de confiança global fixado. Em contraste, os T^2 -intervalos são os mais conservadores, isto é, mais largos, pois asseguram um nível de confiança conjunta de, no mínimo, 95%. Os intervalos de Bonferroni ocupam uma posição intermediária: são mais largos do que os t -intervalos, pois precisam compensar a multiplicidade para manter a confiança simultânea, mas ainda assim tendem a ser mais curtos do que os T^2 -intervalos quando o número de parâmetros p não é muito grande. Assim, oferecem um bom equilíbrio entre precisão e controle da confiança global.

(b) Sejam

Exemplo 5.17

$\mathbf{X} = \begin{bmatrix} X_1 \\ X_2 \end{bmatrix}$: vetor aleatório, cujas componentes são o tempo X_1 de vida (em horas) e o tamanho X_2 (em mm) das válvulas dessa cia,

$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$: vetor de médias populacionais, cujas componentes são o tempo de vida médio μ_1 (em horas) e o tamanho médio μ_2 (em mm) das válvulas dessa cia,

$\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_{61}$ a.a. de $\mathbf{X}$.

Observada a amostra, temos $\bar{x}_1 = 800h$ e $s_{11} = 244 h^2$. Logo, fixado um nível de confiança global de 95%, um intervalo de Bonferroni para μ_1 com 97,5% de confiança é dado por

$$\begin{aligned} IC(\mu_1, 97,5\%) &= \left[\bar{x}_1 \pm t_c \sqrt{\frac{s_{11}}{n}} \right] \\ &= \left[800 \pm 2,34 \cdot \sqrt{\frac{244}{61}} \right] \\ &= [800 \pm 4,68] \\ &= [795,32; 804,68]. \end{aligned}$$

Com 97,5% de confiança, o intervalo $[795,32; 804,68]$ inclui o verdadeiro valor do tempo de vida médio das válvulas dessa cia.

Observada a amostra, temos $\bar{x}_2 = 120 \text{ mm}$ e $s_{22} = 15,25 \text{ mm}^2$. Logo, fixado um nível de confiança global de 95%, um intervalo de Bonferroni para μ_2 com 97,5% de confiança é dado por

$$\begin{aligned} IC(\mu_2, 97,5\%) &= \left[\bar{x}_2 \pm t_c \sqrt{\frac{s_{22}}{n}} \right] \\ &= \left[120 \pm 2 \cdot \sqrt{\frac{15,25}{61}} \right] \\ &= [120 \pm 1,17] \\ &= [118,83; 121,17]. \end{aligned}$$

Com 97,5% de confiança, o intervalo $[118,83; 121,17]$ inclui o verdadeiro tamanho médio das válvulas dessa cia.

Exemplo 5.17

	μ_1		μ_2	
	LI	LS	LI	LS
t -intervalos	796	804	119	121
Intervalos de Bonferroni	795,32	804,68	118,83	121,17
T^2 -intervalos	794,94	805,06	118,73	121,27

A partir da tabela anterior, notamos que os t -intervalos são os mais precisos, no sentido de apresentarem menor comprimento, mas também são os menos confiáveis, já que cada um deles possui apenas 95% de confiança individual, com confiança conjunta menor do que o nível de confiança global fixado. Em contraste, os T^2 -intervalos são os mais conservadores, isto é, mais largos, pois asseguram um nível de confiança conjunta de, no mínimo, 95%. Os intervalos de Bonferroni ocupam uma posição intermediária: são mais largos do que os t -intervalos, pois precisam compensar a multiplicidade para manter a confiança simultânea, mas ainda assim tendem a ser mais curtos do que os T^2 -intervalos quando o número de parâmetros p não é muito grande. Assim, oferecem um bom equilíbrio entre precisão e controle da confiança global.

5.6 Inferência sobre o vetor de médias populacionais a partir de grandes amostras de dados multivariados

Quando o tamanho amostral n é grande, torna-se possível inferir sobre o vetor de médias populacionais $\boldsymbol{\mu}$ do vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$, dispensando a suposição de normalidade para distribuição de $\mathbf{X}$. Sob condições gerais de regularidade, i.e., $\mathbf{X}_1, \dots, \mathbf{X}_n$ uma amostra aleatória (i.i.d.) de $\mathbf{X}$ com $\boldsymbol{\mu}$ finito e matriz de covariância positiva definida $\boldsymbol{\Sigma}$, vale a aproximação assintótica

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \sim \chi_p^2,$$

em que χ_p^2 indica a distribuição qui-quadrado com p graus de liberdade. Consequentemente,

$$\mathbb{P} \left[n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq q_c \right] \approx 1 - \alpha,$$

com $q_c \in \mathbb{R}_+$ sendo o percentil superior de ordem $100 \times \alpha\%$ da distribuição χ_p^2 , i.e., $\mathbb{P}(Q > q_c) = \alpha$ para $Q \sim \chi_p^2$. A partir dessa relação obtêm-se, para amostras grandes, testes de hipóteses e regiões de confiança simultâneas.

Nesse sentido, se $n - p$ é grande, para testar $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$ contra $H_1: \boldsymbol{\mu} \neq \boldsymbol{\mu}_0$, podemos utilizar a seguinte regra de decisão: rejeitamos H_0 ao nível significância $\alpha \in (0, 1)$ quando

$$n(\bar{\mathbf{X}} - \boldsymbol{\mu}_0)^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}_0) > q_c,$$

em que $q_c \in \mathbb{R}_+$ é o ponto crítico tal que $\mathbb{P}(Q > q_c) = \alpha$ para $Q \sim \chi_p^2$. Nesse caso, o elipsóide com $100 \times (1 - \alpha)\%$ de confiança é dado por

$$RC(\boldsymbol{\mu}, 1 - \alpha) = \left\{ \boldsymbol{\mu} \in \mathbb{R}^p : n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}) \leq q_c \right\}.$$

Tais aproximações possuem a seguinte consequência prática: para cada componente μ_i , $i = 1, 2, \dots, p$, forma-se o intervalo

$$IC(\mu_i, \leq 1 - \alpha) := \left[\bar{X}_i \pm \sqrt{q_c} \sqrt{\frac{s_{ii}}{n}} \right]$$

que apresenta confiança simultânea de pelo menos $1 - \alpha$.

É importante observar que em uma ou duas dimensões, amostras entre 30 e 50 observações já costumam ser consideradas grandes. Em dimensões maiores exige-se $n - p$ suficientemente grande: com $p = 2$, $n = 50$ pode ser “grande”, mas com $p = 52$ seria necessário n muito maior do que 100 para manter $n - p$ elevado. Além disso, moderados desvios de normalidade tendem a não afetar drasticamente o nível do teste, mas desvios extremos podem inflá-lo. Sugerem-se as mesmas verificações gráficas (histogramas, Q-Q plots) e eventuais transformações usadas no caso normal-teórico.

Exemplo 5.18: Johnson e Wichern, 2014, p. 236, tradução e grifo nosso

Para estabelecer normas nacionais de desempenho musical na Finlândia, um educador aplicou testes de aptidão musical a milhares de estudantes do 12º ano. A Tabela 5.2 resume parte desse conjunto de dados para uma amostra de $n = 96$ alunos, apresentando a média amostral $\bar{x}_i$ e o desvio-padrão $\sqrt{s_{ii}}$ de cada componente avaliada.

- (a) Fixado um nível de confiança global de 95%, construa os intervalos individuais (t -intervalos), os intervalos simultâneos (T^2 -intervalos) e os intervalos de Bonferroni, para grandes amostras, utilizando a aproximação qui-quadrado.
- (b) Fixado um nível de confiança global de 95%, construa os intervalos individuais (t -intervalos), os intervalos simultâneos (T^2 -intervalos) e os intervalos de Bonferroni sem considerar a aproximação qui-quadrado.

Exemplo 5.18

- (c) Compare os intervalos obtidos no item (a) com aqueles obtidos no item (b).
- (d) Avalie a plausibilidade da hipótese levantada por um dos pesquisadores de que o perfil musical médio do estudante é dado pelo seguinte vetor de médios

$$\boldsymbol{\mu}_0 = [31 \ 27 \ 34 \ 31 \ 23 \ 22 \ 22]^\top$$

Tabela 5.2. Pontuações médias e desvios-padrão de sete componentes de aptidão musical para $n = 96$ estudantes finlandeses

Variável	Média $\bar{x}_i$	Desvio-padrão $\sqrt{s_{ii}}$
$X_1 = \text{melodia}$	28.1	5.76
$X_2 = \text{harmonia}$	26.6	5.85
$X_3 = \text{tempo}$	35.4	3.82
$X_4 = \text{compasso}$	34.2	5.12
$X_5 = \text{fraseado}$	23.6	3.76
$X_6 = \text{balanço}$	22.0	3.93
$X_7 = \text{estilo}$	22.7	4.03

SOLUÇÃO:

(a)

Tabela 5.3. Limites inferiores e superiores para as sete componentes do vetor médio de aptidão musical – comparação entre t -intervalos, T^2 -intervalos e de Bonferroni, fixado um nível de confiança global de 95% e considerando aproximações para grandes amostras. Aqui, utilizamos o quantil da normal $z_c = 1,96$ para os t -intervalos e intervalos de Bonferroni e o quantil da qui-quadrado $q_c = 14,07$ para os T^2 -intervalos.

Componente	t -intervalos		Bonferroni		T^2 -intervalos	
	LI	LS	LI	LS	LI	LS
$\mu_1 = \text{melodia}$	26.95	29.25	26.52	29.68	25.90	30.30
$\mu_2 = \text{harmonia}$	25.43	27.77	24.99	28.21	24.36	28.84
$\mu_3 = \text{tempo}$	34.64	36.16	34.35	36.45	33.94	36.86
$\mu_4 = \text{compasso}$	33.18	35.22	32.79	35.61	32.24	36.16
$\mu_5 = \text{fraseado}$	22.85	24.35	22.57	24.63	22.16	25.04
$\mu_6 = \text{balanço}$	21.21	22.79	20.92	23.08	20.50	23.50
$\mu_7 = \text{estilo}$	21.89	23.51	21.59	23.81	21.16	24.24

Exemplo 5.18

(b)

Tabela 5.4. Limites inferiores e superiores para as sete componentes do vetor médio de aptidão musical – comparação entre t -intervalos, T^2 -intervalos e de Bonferroni, fixado um nível de confiança global de 95% sem considerar aproximações para grandes amostras. Aqui, utilizamos o quantil da t de Student $t_c = 1,99$ para os t -intervalos e intervalos de Bonferroni e o quantil da F $f_c = 2,11$ para os T^2 -intervalos.

Componente	t -intervalos		Bonferroni		T^2 -intervalos	
	LI	LS	LI	LS	LI	LS
$\mu_1 = \text{melodia}$	26.93	29.27	26.48	29.72	25.76	30.44
$\mu_2 = \text{harmonia}$	25.41	27.79	24.96	28.24	24.23	28.97
$\mu_3 = \text{tempo}$	34.63	36.17	34.33	36.47	33.85	36.95
$\mu_4 = \text{compasso}$	33.16	35.24	32.76	35.64	32.12	36.28
$\mu_5 = \text{fraseado}$	22.84	24.36	22.54	24.66	22.07	25.13
$\mu_6 = \text{balanço}$	21.20	22.80	20.90	23.30	20.41	23.59
$\mu_7 = \text{estilo}$	21.88	23.52	21.57	23.83	21.07	24.33

- (c) Os resultados obtidos para a amostra grande de $n = 96$ estudantes mostram que os limites simultâneos baseados na aproximação qui-quadrado (Tabela 5.3) e os que não fazem uso da aproximação (Tabela 5.4) são muito próximos, diferindo apenas na terceira ou, no máximo, na segunda casa decimal. Isso acontece porque, à medida que n cresce e $n - p$ se torna grande, vale a aproximação clássica da T^2 -de Hotelling para qui-quadrado e, de modo análogo, da distribuição t de Student para distribuição normal. Portanto, com n elevado, os três conjuntos de intervalos – t -intervalos, T^2 -intervalos e intervalos de Bonferroni – apresentam praticamente o mesmo comprimento e levam às mesmas conclusões sobre as médias populacionais. Em síntese, para amostras realmente grandes, a escolha entre χ^2 ou F/t afeta pouco a precisão ou a confiança dos intervalos; já para tamanhos moderados, preferir os percentis F/t ainda é uma opção mais conservadora.
- (d) Vemos a partir dos intervalos simultâneos das Tabelas 5.3 e 5.4 que a afirmação feita pelo pesquisador sobre os componentes de μ_0 associado com melodia, tempo e compasso não parecem, ao nível global de 95%, ser valores plausíveis para as correspondentes médias do sistema de pontuação Filandês.

Mesmo quando o tamanho amostral é elevado, muitos estatísticos optam por reter os percentis baseados em F e em t em vez de substituí-los pelos percentis da qui-quadrado ou da normal-padrão. Observe que os pontos críticos da qui-quadrado q_c e da normal padrão z_c podem ser interpretados como os limites, quando $n \rightarrow \infty$, dos valores críticos provenientes das distribuições F e t . Consequentemente, os intervalos obtidos com F e t tendem a ser mais longos e, portanto, mais conservadores, oferecendo ao usuário uma margem de segurança adicional quando julga necessário.

Encerramos este capítulo lembrando que, na prática, raramente somos solicitados a verificar se $\boldsymbol{\mu}$ coincide exatamente com um vetor específico de valores. Ainda assim, o arcabouço desenvolvido aqui é essencial. Os testes para o vetor de médias fornecem a base matemática para situações de interesse aplicado, como comparações pareadas, delineamentos de medidas repetidas sob diferentes tratamentos, análise de variância multivariada (MANOVA, do inglês *Multivariate Analysis of Variance*) e análise de perfis. Esses procedimentos multivariados são ferramentas-chave em áreas como agricultura, biologia, ciências ambientais e psicologia, onde se faz necessário avaliar, simultaneamente, vários desfechos correlacionados. Assim, mesmo que a hipótese $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$ pareça pouco frequente, dominar sua teoria assegura confiança na aplicação de métodos mais sofisticados que dependem, direta ou indiretamente, da inferência aqui apresentada.

5.7 Exercícios

- Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$ com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$. Considere a transformação $\mathbf{Y}_j = \mathbf{A}\mathbf{X}_j + \mathbf{b}$, para todo $j = 1, 2, \dots, n$, em que $\mathbf{A} \in M_{q \times p}$ é uma matriz de constantes e $\mathbf{b} \in \mathbb{R}^q$ é um vetor de constantes.
 - Mostre que $\bar{\mathbf{Y}} = \mathbf{A}\bar{\mathbf{X}} + \mathbf{b}$ e, em seguida, determine $\mathbb{E}(\bar{\mathbf{Y}})$ e $Cov(\bar{\mathbf{Y}})$.
 - Mostre que $\mathbf{S}_n^Y = \mathbf{A}\mathbf{S}_n^X\mathbf{A}^\top$, em que $\mathbf{S}_n^X$ e $\mathbf{S}_n^Y$ são as matrizes de variâncias e covariâncias amostrais e, em seguida, determine $\mathbb{E}(\mathbf{S}_n^Y)$.
- Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma amostra aleatória de um vetor aleatório $\mathbf{X}$ em $\mathbb{R}^p$ com vetor de médias $\boldsymbol{\mu} \in \mathbb{R}^p$ e matriz de variâncias e covariâncias $\boldsymbol{\Sigma} \in M_{p \times p}(\mathbb{R})$. Mostre que $Cov\left(\sum_{j=1}^n a_j \mathbf{X}_j, \sum_{j=1}^n b_j \mathbf{X}_j\right) = 0$ se, e somente se, $\mathbf{a} \in \mathbb{R}^n$ e $\mathbf{b} \in \mathbb{R}^n$ forem ortogonais.
- Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ uma sequência de vetores aleatórios independentes tal que

$\mathbf{X}_j \sim \text{Normal}_p(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$ para qualquer $j = 1, 2, \dots, p$. Mostre que

$$\sum_{j=1}^n a_j \mathbf{X}_j \sim \text{Normal}_p \left(\sum_{j=1}^n a_j \boldsymbol{\mu}_j, \sum_{j=1}^n a_j^2 \boldsymbol{\Sigma}_j \right),$$

em que $\mathbf{a} = [a_1 \ a_2 \ \dots \ a_n]^\top$ é um vetor de constantes reais.

4. (Johnson e Wichern, 2014, p. 204, tradução e grifo nosso) Seja $\mathbf{X}_1, \mathbf{X}_2, \mathbf{X}_3$ e $\mathbf{X}_4$ uma amostra aleatória do vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$.

(a) Encontre as distribuições marginais para cada um dos seguintes vetores aleatórios

$$\mathbf{V}_1 = \frac{1}{4}\mathbf{X}_1 - \frac{1}{4}\mathbf{X}_2 + \frac{1}{4}\mathbf{X}_3 - \frac{1}{4}\mathbf{X}_4$$

e

$$\mathbf{V}_2 = \frac{1}{4}\mathbf{X}_1 + \frac{1}{4}\mathbf{X}_2 - \frac{1}{4}\mathbf{X}_3 - \frac{1}{4}\mathbf{X}_4.$$

(b) Encontre a densidade conjunta do vetor aleatório $\mathbf{V}_1$ e $\mathbf{V}_2$ definido no item (a).

5. (Johnson e Wichern, 2014, p. 204, tradução e grifo nosso) Seja $\mathbf{X}_1, \mathbf{X}_2, \mathbf{X}_3, \mathbf{X}_4$ e $\mathbf{X}_5$ uma amostra aleatória do vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Encontre o vetor de médias e a matriz de variâncias e covariâncias das seguintes combinações lineares de vetores aleatórios

$$\mathbf{V}_1 = \frac{1}{5}\mathbf{X}_1 + \frac{1}{5}\mathbf{X}_2 + \frac{1}{5}\mathbf{X}_3 + \frac{1}{5}\mathbf{X}_4$$

e

$$\mathbf{V}_2 = \mathbf{X}_1 - \mathbf{X}_2 + \mathbf{X}_3 - \mathbf{X}_4 + \mathbf{X}_5.$$

Obtenha também $\text{Cov}(\mathbf{V}_1, \mathbf{V}_2)$.

6. Sejam $\mathbf{X}_1, \mathbf{X}_2$ e $\mathbf{X}_3$ uma amostra aleatória do vetor aleatório $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Considere $\mathbf{Y}_1 = \mathbf{X}_1 + \mathbf{X}_2$, $\mathbf{Y}_2 = \mathbf{X}_2 + \mathbf{X}_3$ e $\mathbf{Y}_3 = \mathbf{X}_1 + \mathbf{X}_3$. Obtenha a distribuição condicional de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2$ e de $\mathbf{Y}_1 | \mathbf{Y}_2 = \mathbf{y}_2, \mathbf{Y}_3 = \mathbf{y}_3$, em que $\mathbf{y}_1, \mathbf{y}_2, \mathbf{y}_3 \in \mathbb{R}^p$ são vetores fixos.
7. (Johnson e Wichern, 2014, p. 205, tradução e grifo nosso) Seja $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_{20}$ uma amostra aleatória de tamanho $n = 20$ de um vetor aleatório $\mathbf{X} \sim \text{Normal}_6(\boldsymbol{\mu}, \boldsymbol{\Sigma})$. Especifique cada uma as distribuições de cada vetor aleatório (ou variável aleatória) definidas a seguir.

$$(a) (\mathbf{X}_1 - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\mathbf{X}_1 - \boldsymbol{\mu}).$$

$$(b) \bar{\mathbf{X}}.$$

$$(c) \sqrt{n}(\bar{\mathbf{X}} - \boldsymbol{\mu}).$$

$$(d) (n-1)\mathbf{S}.$$

$$(e) n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}).$$

$$(f) n(\bar{\mathbf{X}} - \boldsymbol{\mu})^\top \mathbf{S}^{-1}(\bar{\mathbf{X}} - \boldsymbol{\mu}).$$

8. (Johnson e Wichern, 2014, p. 206, tradução e grifo nosso) Uma pesquisa de preços em um jornal local forneceu informações sobre dez carros compactos usados de origem estrangeira. Para cada veículo, foram registrados dois atributos: a idade em anos (X_1) e o preço de venda em milhares de dólares (X_2). Os dados observados são apresentados a seguir:

x_1 (idade)	1	2	3	3	4	5	6	8	9	11
x_2 (preço)	18,95	19,00	17,95	15,54	14,00	12,95	8,94	7,49	6,00	3,99

- (a) Utilize os resultados da matriz de médias amostrais $\bar{\mathbf{X}}$ e da matriz de variâncias e covariâncias amostrais $\mathbf{S}$ para calcular as distâncias estatísticas ao quadrado de cada observação em relação à média:

$$d_j^2 = (\mathbf{x}_j - \bar{\mathbf{x}})^\top \mathbf{S}^{-1}(\mathbf{x}_j - \bar{\mathbf{x}}), \quad j = 1, \dots, 10,$$

$$\text{em que } \mathbf{x}_j = \begin{bmatrix} x_{j1} & x_{j2} \end{bmatrix}^\top.$$

- (b) Ordene as distâncias estatísticas ao quadrado e construa um gráfico de quantis teóricos vs. quantis observados, comparando os quantis teóricos da distribuição qui-quadrado com 2 graus de liberdade. Quais padrões você observa?
- (c) Você considera razoável assumir que os dados foram gerados por uma população aproximadamente normal bivariada? Justifique sua resposta com base nos resultados obtidos.
9. O conjunto de dados `iris`, disponível no *software R*, contém medidas de comprimento e largura das sépalas e pétalas de três espécies de flores. Neste exercício, utilizaremos apenas as 50 observações da espécie `setosa` e três variáveis: tamanho da sépala, largura da sépala e tamanho da pétala. O objetivo é verificar se as suposições de normalidade multivariada são razoáveis, e, em seguida, aplicar o teste T^2 de Hotelling para o vetor de médias.

- (a) Construa histogramas, gráficos de quantis teóricos versus quantis observados (Q-Q plots) e gráficos de dispersão bivariados para todas as combinações das variáveis. Com base nesses gráficos, parece razoável supor que as variáveis seguem conjuntamente uma distribuição normal multivariada?
- (b) Realize testes de Shapiro-Wilk para cada uma das quatro variáveis marginais. Qual é a sua conclusão sobre a normalidade univariada? Use nível de significância de 5%.
- (c) Considere o vetor de valores de referência

$$\boldsymbol{\mu}_0 = \begin{bmatrix} 5,0 \\ 3,4 \\ 1,5 \end{bmatrix}.$$

Você consideraria plausível que o vetor de médias populacionais seja igual a $\boldsymbol{\mu}_0$? Para isso, conduza o teste T^2 de Hotelling com $\alpha = 5\%$. Defina as hipóteses, estatística de teste, regra de decisão e conclusão.

- (d) Determine o vetor de médias amostrais $\bar{\mathbf{x}}$ e compare-o com o vetor de referência $\boldsymbol{\mu}_0$. Sua conclusão para o teste conduzido no item (c) parece compatível com essa comparação? Por quê?
 - (e) Com base nas etapas anteriores, você acredita que a suposição de normalidade multivariada é razoável? A conclusão obtida no teste T^2 de Hotelling parece confiável neste contexto? Por quê?
10. A base de dados `airquality`, disponível no *software R*, contém medidas atmosféricas coletadas na cidade de Nova Iorque durante os meses de maio a setembro de 1973. Para este exercício, foram consideradas duas variáveis quantitativas: velocidade do vento (`Wind`) e temperatura do ar em graus Fahrenheit (`Temp`). Após a exclusão de observações com valores ausentes, restaram n (determine!) observações válidas para análise. O objetivo é verificar a plausibilidade de um modelo multivariado normal e, em seguida, construir uma região de confiança para o vetor de médias populacionais dessas variáveis e testar hipóteses relativas a esse vetor.
- (a) Construa, para cada uma das variáveis, um histograma e um gráfico de quantis teóricos versus quantis observados (Q-Q plot). Com base nesses gráficos, avalie a plausibilidade dos dados terem se originado de uma população normalmente distribuída?
 - (b) Aplique o teste de Shapiro-Wilk para avaliar a normalidade marginal de cada variável. Ao nível de significância de 5%, quais são suas conclusões?

- (c) Construa os gráficos de dispersão bivariados entre as variáveis. A forma das nuvens de pontos observadas sugere plausibilidade da normalidade multivariada?
- (d) Considere como hipótese nula que o vetor de médias populacionais é igual ao vetor de médias amostrais. Conduza o teste T^2 de Hotelling correspondente. Ao nível de significância de 5%, qual é a sua conclusão? Defina as hipóteses, estatística de teste, regra de decisão e conclusão.
- (e) Com relação a sua resposta ao item (d), seria possível chegar a ela sem conduzir o teste T^2 de Hotelling? Por quê?
- (f) Construa uma região de confiança com 95% de confiança para o vetor de médias considerando apenas as variáveis **Wind** e **Temp**. Defina a quantidade pivotal, região de confiança e conclusão. Visualize graficamente a região elipsoidal correspondente.
- (g) De acordo com sua resposta para o item (f), para quais vetores de médias μ_0 , o teste T^2 de Hotelling rejeitaria a hipótese $H_0 : \mu = \mu_0$? Por quê?

11. (Johnson e Wichern, 2014, p. 261, tradução e grifo nosso) Considere a matriz de dados

$$\begin{bmatrix} 2 & 12 \\ 8 & 9 \\ 6 & 9 \\ 8 & 10 \end{bmatrix},$$

em que cada linha representa uma observação bivariada do vetor aleatório $\mathbf{X} = [X_1 \ X_2]^\top$. Suponha que $\mathbf{X} \sim \text{Normal}_2(\mu, \Sigma)$.

- (a) Calcule a estatística de teste T^2 de Hotelling para testar a hipótese

$$H_0: \mu = \begin{bmatrix} 7 \\ 11 \end{bmatrix}.$$

- (b) Especifique a distribuição da estatística T^2 sob H_0 , indicando os graus de liberdade e a forma equivalente da estatística usando a distribuição F .
- (c) Com base nos resultados dos itens anteriores, conduza o teste de hipótese ao nível de significância $\alpha = 5\%$. Apresente sua conclusão com base na comparação entre o valor observado da estatística de teste e o valor crítico adequado.

12. (Johnson e Wichern, 2014, p. 261, tradução e grifo nosso) A transpiração de 20 mulheres saudáveis foi analisada. Três componentes, X_1 = taxa de suor, X_2 = teor de sódio e X_3 = teor de potássio, foram medidos,

e os resultados, que chamaremos de *dados de suor*, estão apresentados na tabela a seguir.

Indivíduo	X_1 (Taxa de suor)	X_2 (Sódio)	X_3 (Potássio)
1	3,7	48,5	9,3
2	5,7	65,1	8,0
3	3,8	47,2	10,9
4	3,2	53,2	12,0
5	3,1	55,5	9,7
6	4,6	36,1	7,9
7	2,4	24,8	14,0
8	7,2	33,1	7,6
9	6,7	47,4	8,5
10	5,4	54,1	11,3
11	3,9	36,9	12,7
12	4,5	58,8	12,3
13	3,5	27,8	9,8
14	4,5	40,2	8,4
15	1,5	13,5	10,1
16	8,5	56,4	7,1
17	4,5	71,6	8,2
18	6,5	52,8	10,9
19	4,1	44,1	11,2
20	5,5	40,9	9,4

Assumindo que $\mathbf{X} \sim \text{Normal}_3(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, faça o que se pede:

- Teste a hipótese $H_0: \boldsymbol{\mu} = \begin{bmatrix} 4 & 50 & 10 \end{bmatrix}^\top$ contra $H_1: \boldsymbol{\mu} \neq \begin{bmatrix} 4 & 50 & 10 \end{bmatrix}^\top$ ao nível de significância $\alpha = 0,10$. Defina as hipóteses, estatística de teste, regra de decisão e conclusão.
 - Determine o conjunto dos valores de $\boldsymbol{\mu}_0 \in \mathbb{R}^3$ para os quais não rejeitaríamos a hipótese $H_0: \boldsymbol{\mu} = \boldsymbol{\mu}_0$ ao nível de significância $\alpha = 0,10$.
 - Esboce o conjunto determinado no item (b).
 - Sua resposta para o item (a) e para o item (b) são consistentes.
13. Sejam $\mathbf{X} \sim \text{Normal}_p(\boldsymbol{\mu}, \boldsymbol{\Sigma})$ e $\mathbf{Y} = \mathbf{C}\mathbf{X} + \mathbf{d}$, em que $\mathbf{C} \in M_{p \times p}$ é uma matriz não-singular e $\mathbf{d} \in \mathbb{R}^p$ é um vetor de constantes. Dadas as observações $\mathbf{x}_1, \dots, \mathbf{x}_n$ de $\mathbf{X}$, mostre que

- (a) $\bar{\mathbf{y}} = \mathbf{C}\bar{\mathbf{x}} + \mathbf{d}$.
- (b) $\mathbf{S}_y = \frac{1}{n-1} \sum_{j=1}^n (\mathbf{y}_j - \bar{\mathbf{y}})(\mathbf{y}_j - \bar{\mathbf{y}})^\top = \mathbf{CSC}^\top$.
- (c) $\boldsymbol{\mu}_y = \mathbb{E}(\mathbf{Y}) = \mathbf{C}\boldsymbol{\mu} + \mathbf{d}$.
- (d) $T^2 = n(\bar{\mathbf{y}} - \boldsymbol{\mu}_y)^\top \mathbf{S}_Y^{-1}(\bar{\mathbf{y}} - \boldsymbol{\mu}_y) = n(\bar{\mathbf{x}} - \boldsymbol{\mu})^\top \mathbf{S}_x^{-1}(\bar{\mathbf{x}} - \boldsymbol{\mu})$.
- (e) Proponha uma matriz $\mathbf{C} \in M_{3 \times 3}(\mathbb{R})$ e um vetor de constantes $\mathbf{d} \in \mathbb{R}^3$ e verifique que a estatística T^2 de Hotelling encontrada no item (a) do Exercício 12 se mantém a mesma se a intenção for testar $H_0 : \mathbf{C}\boldsymbol{\mu} + \mathbf{d} = \mathbf{C} \begin{bmatrix} 4 & 50 & 10 \end{bmatrix}^\top$ vs. $H_0 : \mathbf{C}\boldsymbol{\mu} + \mathbf{d} \neq \mathbf{C} \begin{bmatrix} 4 & 50 & 10 \end{bmatrix}^\top$.

14. (Johnson e Wichern, 2014, p. 263, tradução e grifo nosso) Um antropólogo físico realizou uma análise mineral de nove fios de cabelo de antigos peruanos. Os resultados para os níveis de cromo (X_1) e estrôncio (X_2), em partes por milhão (ppm), foram os seguintes:

x_1 (Cr)	0,48	40,53	2,19	0,55	0,74	0,66	0,93	0,37	0,22
x_2 (St)	12,57	73,68	11,13	20,03	20,29	0,78	4,64	0,43	1,08

Fonte: Benfer et al., “Mineral Analysis of Ancient Peruvian Hair,” *American Journal of Physical Anthropology*, **48**, n.º 3 (1978), pp. 277-282.

Sabe-se que baixos níveis (menores ou iguais a 0,100 ppm) de cromo sugerem a presença de diabetes, enquanto o estrôncio é um indicativo de ingestão de proteína animal.

- (a) Construa a elipse de confiança conjunta de 90% para o vetor de médias populacionais $\boldsymbol{\mu}^\top = [\mu_1 \quad \mu_2]$, assumindo que esses nove fios de cabelo representam uma amostra aleatória de indivíduos pertencentes a uma cultura peruana antiga particular.
- (b) Obtenha os intervalos individuais (t -intervalos) de 90% de confiança para μ_1 e μ_2 .
- (c) Fixado um nível de confiança global de 90%, obtenha os intervalos de confiança simultâneos (T^2 -intervalos) para μ_1 e μ_2 .
- (d) Fixado um nível de confiança global de 90%, obtenha os intervalos de confiança de Bonferroni para μ_1 e μ_2 .
- (e) Compare os intervalos obtidos nos itens (b), (c) e (d) quanto a confiança e precisão.

- (f) Construa em um mesmo plano cartesiano, o retângulo de confiança delimitado pelos intervalos individuais (t -intervalos) encontrados no item (b), o retângulo de confiança delimitado pelos intervalos simultâneos (T^2 -intervalos) encontrados no item (c), o retângulo de confiança delimitado pelos intervalos de Bonferroni encontrados no item (d) e a elipse de confiança obtida no item (a). Compare essas regiões quanto a confiança e precisão.
- (g) Parece que essa cultura peruana tem um nível médio de estrôncio igual a 10? Isto é, algum dos pontos $[\mu_1 \ 10]^\top$ está contido nas regiões de confiança? O vetor $[0,30 \ 10]^\top$ é um valor plausível para μ ? Discuta.
- (h) Os dados parecem seguir uma normal bivariada? Discuta essa hipótese com base no resultado do teste de Mardia. Se os dados não forem normalmente distribuídos, quais são as implicações disso para as conclusões obtidas no item (g)?
- (i) Repita a análise com a observação claramente atípica removida. As inferências mudam? Comente.
15. (Johnson e Wichern, 2014, p. 262, tradução e grifo nosso) Harry Roberts, um naturalista do Departamento de Pesca e Caça do Alasca, estuda ursos pardos com o objetivo de manter uma população saudável. As medições em $n = 61$ ursos forneceram as seguintes estatísticas resumo:

Variável	Médias amostrais $\bar{x}$
Peso (kg)	95,52
Comprimento do corpo (cm)	164,38
Pescoço (cm)	55,69
Circunferência (cm)	93,39
Comprimento da cabeça (cm)	17,98
Largura da cabeça (cm)	31,13

Matriz de variâncias covariância amostrais:

$$S = \begin{bmatrix} 3266,46 & 1343,97 & 731,54 & 1175,50 & 162,68 & 238,37 \\ 1343,97 & 721,91 & 324,25 & 537,35 & 80,17 & 117,73 \\ 731,54 & 324,25 & 179,28 & 281,17 & 39,15 & 56,80 \\ 1175,50 & 537,35 & 281,17 & 474,98 & 63,73 & 94,85 \\ 162,68 & 80,17 & 39,15 & 63,73 & 9,95 & 13,88 \\ 238,37 & 117,73 & 56,80 & 94,85 & 13,88 & 21,26 \end{bmatrix}.$$

- (a) Para as médias populacionais das seis medidas corporais, obtenha os intervalos individuais (t -intervalos) de 95% de confiança (para grandes amostras).
- (b) Fixado um nível de confiança global de 95%, obtenha os intervalos (para grandes amostras) de confiança simultâneos (T^2 -intervalos) para as médias populacionais das seis medidas corporais.
- (c) Obtenha a elipse de confiança de 95% (para grandes amostras) para o vetor de médias populacionais cujas componentes são o peso média e a circunferência média.
- (d) Fixado um nível de confiança global de 95%, obtenha os intervalos de confiança de Bonferroni (para grandes amostras) para as médias populacionais das seis medidas corporais.
- (e) Com base na sua resposta para o item (a), construa o retângulo de confiança delimitado pelos intervalos individuais (t -intervalos) para o peso médio e para circunferência média. Compare esse retângulo com a elipse de confiança obtida no item (c).
- (f) Com base na sua resposta para o item (b), construa o retângulo de confiança delimitado pelos intervalos simultâneos (T^2 -intervalos) para o peso médio e para circunferência média. Compare esse retângulo com a elipse de confiança obtida no item (c).
- (g) Com base na sua resposta para o item (d), construa o retângulo de confiança delimitado pelos intervalos de Bonferroni para o peso médio e para circunferência média, use $\alpha_i = \alpha/6$, $i = 1, 2$. Compare esse retângulo com a elipse de confiança obtida no item (c).
- (h) O que mudaria se ao invés de usar $\alpha_i = \alpha/6$, usássemos $\alpha_i = \alpha/2$? Por quê?
- (i) Fixado um nível de confiança global de 95%, obtenha o intervalo de confiança de Bonferroni (para grandes amostras) para

largura média da cabeça – comprimento médio da cabeça

usando $\alpha/7$.

16. (Johnson e Wichern, 2014, p. 268, tradução e grifo nosso) Um ecólogo de vida selvagem mediu X_1 = comprimento da cauda (em milímetros) e X_2 = comprimento da asa (em milímetros) para uma amostra de $n = 45$ fêmeas de gaviões-de-bico-ganchoso. Os dados estão apresentados na tabela.

x_1 (Cauda)	x_2 (Asa)	x_1 (Cauda)	x_2 (Asa)	x_1 (Cauda)	x_2 (Asa)
191	284	186	266	173	271
197	285	197	285	194	280
208	288	201	295	198	300
180	273	190	282	180	272
180	275	209	305	190	292
188	280	187	285	191	286
210	283	207	297	196	285
196	288	178	268	207	286
191	271	202	271	209	303
179	257	205	285	179	261
208	289	190	280	186	262
202	285	189	277	174	245
200	272	211	310	181	250
192	282	216	305	189	262
199	280	189	274	188	258

Fonte: Dados cedidos por S. Temple.

- (a) Encontre e esboce a elipse de confiança de 95% para as médias populacionais μ_1 e μ_2 . Suponha que se sabe que $\mu_1 = 190$ mm e $\mu_2 = 275$ mm para gaviões machos. Esses são valores plausíveis para o comprimento médio da cauda e comprimento médio da asa das fêmeas? Explique.
- (b) Fixado um nível de confiança global de 95%, construa os intervalos simultâneos de confiança (T^2 -intervalos) de 95% para μ_1 e μ_2 , bem como os intervalos de Bonferroni para μ_1 e μ_2 . Compare os dois conjuntos de intervalos. Qual vantagem, se houver, que os T^2 -intervalos apresentam em relação aos intervalos de Bonferroni?

6 Comparação de vários vetores de médias

Em muitas investigações aplicadas, o interesse recai menos em estimar um único vetor de médias populacionais e mais em comparar simultaneamente vários vetores provenientes de grupos, tratamentos ou momentos distintos de observação. Neste capítulo, estudaremos métodos que estendem de forma natural as ideias de inferência multivariada para cenários comparativos. Iniciaremos com comparações pareadas e delineamentos de medidas repetidas, em que o mesmo conjunto de unidades experimentais é avaliado sob diferentes condições. Em seguida, abordaremos a análise de variância multivariada, permitindo testar, em bloco, se pelo menos um dos grupos difere nos componentes de seu vetor de médias. Finalmente, exploraremos a análise de perfis, ferramenta útil quando o foco é descrever e contrastar o formato (ou tendência) das médias ao longo de uma coleção ordenada de variáveis. Esses procedimentos são amplamente utilizados em áreas como agricultura, biologia, psicologia e ciências da saúde, onde respostas correlacionadas são coletadas para avaliar tratamentos, cultivares, protocolos clínicos ou intervenções comportamentais.

6.1 Comparações pareadas

Nesta seção, o objetivo é planejar experimentos que comparem *mais de uma* medição obtida sob dois tratamentos (ou antes-depois da aplicação de um único tratamento) na *mesma* unidade experimental, ou em unidades muito semelhantes, de modo a controlar a variabilidade intrínseca de cada indivíduo e aumentar o poder do teste. Por exemplo, os resultados de um experimento pareado é descrito na Tabela 6.1. Nesse caso, o experimento é delineado para comparar a pressão sistólica e a frequência cardíaca dos mesmos pacientes antes e depois de um medicamento, cada paciente servindo de “controle” para si mesmo.

Tabela 6.1. Pressão sistólica (em mmHg) e frequência cardíaca (em bpm) medidas em 3 pacientes antes e após a aplicação de um tratamento.

Paciente	Pressão sistólica (mmHg)			Frequência cardíaca (bpm)		
	Antes	Depois	Diferença	Antes	Depois	Diferença
João	140	130	10	82	75	7
Maria	160	150	10	88	80	8
Pedro	150	140	10	79	74	5

Note que todos os pacientes reduziram *exatamente* 10 mmHg na pressão sistólica, revelando inequivocamente o efeito do fármaco. Assim, mesmo que os valores absolutos variem de pessoa para pessoa, a diferença costuma ser muito mais homogênea. Portanto se analisássemos dois grupos independentes, um grupo de que não recebe o tratamento e outro que recebe, essa variabilidade individual poderia obscurecer o efeito de interesse.

No *primeiro* ensaio clínico controlado documentado, James Lind (1747) alojou 12 marinheiros com escorbuto em condições idênticas de bordo, dividindo-os em seis pares que receberam seis tratamentos distintos (sidra, ácido sulfúrico diluído, vinagre, água do mar, laranjas + limões e uma mistura de ervas). Após apenas seis dias, o par que ingeriu frutas cítricas recuperou-se rapidamente, estabelecendo a eficácia da vitamina C, ainda que a falta de randomização e o conhecimento prévio dos tratamentos pelos marinheiros limitem a força inferencial do estudo.

Mais de um século depois, William S. Gosset (Student, 1908) introduziu o teste t ao investigar se diferentes condições de cultivo alteravam o peso médio de grãos de cevada. Seu objetivo declarado era decidir se diferenças de média observadas eram reais ou meramente devidas ao erro amostral (Student, 1908, p. 4).

Exemplo 6.1

Na tabela a seguir, temos o peso de 5 de grãos de cevada que foram expostos a dois métodos de cultivos distintos.

Tabela 6.2. Peso de 5 de grãos de cevada que foram expostos a dois métodos de cultivos distintos.

Grão j	Modo de cultivo		
	x_{j1}	x_{j2}	d_j
1	6,2	6,8	-0,6
2	6,5	7,0	-0,5
3	6,4	7,1	-0,7
4	6,3	6,9	-0,6
5	6,6	7,2	-0,6

Aqui, x_{j1} representa o peso da semente j sob o método de cultivo 1, x_{j2} representa o peso da semente j sob o método de cultivo 2 e $d_j = x_{j1} - x_{j2}$ é a diferença que os métodos de cultivos possuem sobre o peso da semente j , $j = 1, 2, \dots, 5$. Com base na amostra observada, temos a diferença média amostral $\bar{d}$ e variância amostral da diferença s_d^2 :

$$\bar{d} = -0,6 \quad \text{e} \quad s_d^2 = 0,005.$$

Supondo que $D_1, D_2, \dots, D_5$ segue uma distribuição normal com média δ e variância σ^2 , ambas desconhecidas, responda as seguintes perguntas.

- (a) Observando apenas os dados da tabela, o que essa amostra sugere?

Exemplo 6.1

- (b) Fixado um nível de significância $\alpha = 5\%$, verifique se o método de cultivo possui um efeito significativo sob o peso médio das sementes de cevada. Defina as hipóteses (estatística e científica), a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e a conclusão (estatística e em termos do problema).
- (c) Fixado um nível de confiança $1 - \alpha = 95\%$, construa um intervalo para a diferença esperado que o tipo de cultivo causa sobre o peso das sementes. Interprete o intervalo estatisticamente e em termos do problema. Sua resposta é consistente com a sua resposta para o item (b)? Por quê?

SOLUÇÃO:

- (a) Com base na amostra observada, temos *indicativos* de que os grãos que foram expostos o segundo tipo de cultivo são, *em média*, mais pesados.

(b) • Hipóteses:

- $H_0 : \delta = 0$ (em média, não há diferença entre os tipos de cultivos sob o peso dos grãos);
- $H_0 : \delta \neq 0$ (em média, há diferença entre os tipos de cultivos sob o peso dos grãos).

• Estatística de teste: Sob $H_0 : \delta = 0$,

$$T := \frac{\bar{D} - \delta}{S_d / \sqrt{n}} \sim t_{n-1}, \quad \text{com } n = 5.$$

- **Regra de decisão:** Ao nível de significância $\alpha = 5\%$, rejeitamos a hipótese nula $H_0 : \delta = 0$ quando $|t| > t_c$ ($t < -t_c$ ou $t > t_c$), em que t é o valor observado da estatística T e $t_c \in \mathbb{R}_+$ é o valor crítico tal que $\mathbb{P}(|T| > t_c | H_0) = 5\%$.
- **Conclusão:** Observada a amostra, temos $t = -42,86$. Ao nível de significância $\alpha = 5\%$, temos $t_c = 5,598$. Logo, como $t < -t_c$, rejeitamos a hipótese nula $H_0 : \delta = 0$. Em outras palavras, com base na amostra observada, ao nível de significância $\alpha = 5\%$, há evidências de que tipo de cultivo tem impacto no peso médio dos grãos.

Exemplo 6.1

(c) Fixado o nível de confiança de $1 - \alpha = 95\%$,

$$\begin{aligned}
 IC(\delta, 95\%) &= \left[\bar{d} \pm t_c \frac{s_d}{\sqrt{n}} \right] \\
 &= \left[-0,6 \pm 5,598 \sqrt{\frac{0,005}{5}} \right] \\
 &= [-0,6 \pm 0,014] \\
 &= [-0,614; -0,586].
 \end{aligned}$$

Com confiança de 95%, o intervalo $[-0,614; -0,586]$ inclui a verdadeira diferença média entre os pesos dos grãos exposto a primeiro tipo de cultivo com os pesos daqueles expostos ao segundo tipo de cultivo. Como $IC(\delta, 95\%) \not\ni 0$, a amostra traz evidência que o tipo de cultivo afeta a o peso médio das sementes, o que é consistente com nossa resposta para o item (b). Além disso, como o intervalo inclui apenas número negativos, há evidências também que o segundo tipo de cultivo leve a sementes mais pesadas do que aquelas expostas ao primeiro tipo de cultivo.

Agora, se estivermos interessados em realizar mais de duas medições sob dois tratamentos, então denotaremos por X_{1ji} a i -ésima medição feita sobre a unidade experimental j sob o primeiro tratamento e X_{2ji} como sendo a i -ésimo medição feita sobre a unidade experimental j sob o segundo tratamento, sendo $j = 1, 2, \dots, n$ e $i = 1, 2, \dots, p$. Observada a amostra, podemos organizar os dados em tabela da seguinte maneira:

Unidade j	Tratamento 1				Tratamento 2			
	x_{1j1}	x_{1j2}	$\cdots$	x_{1jp}	x_{2j1}	x_{2j2}	$\cdots$	x_{2jp}
1	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$		$\vdots$
2	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$		$\vdots$
$\vdots$	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$		$\vdots$
n	$\vdots$	$\vdots$		$\vdots$	$\vdots$	$\vdots$		$\vdots$

Logo, a diferença das medições entre dois tratamentos pode ser armazenada em um vetor de $\mathbb{R}^p$ da seguinte maneira

$$\mathbf{D}_j := \begin{bmatrix} D_{j1} \\ D_{j2} \\ \vdots \\ D_{jp} \end{bmatrix} := \begin{bmatrix} X_{1j1} - X_{2j1} \\ X_{1j2} - X_{2j2} \\ \vdots \\ X_{1jp} - X_{2jp} \end{bmatrix}.$$

Logo, dadas as observações $\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_n$ dos vetores aleatórios $\mathbf{D}_1, \mathbf{D}_2, \dots, \mathbf{D}_n$ em $\mathbb{R}^p$ tal que $D_j \sim \text{Normal}_p(\boldsymbol{\delta}, \boldsymbol{\Sigma}_d)$, em que $\boldsymbol{\delta} \in \mathbb{R}^p$ é o vetor de diferenças médias e $\boldsymbol{\Sigma}_d \in M_{p \times p}(\mathbb{R})$ é a matriz de variâncias e covariâncias das diferenças, queremos testar hipóteses:

- $H_0 : \boldsymbol{\delta} = \mathbf{0}$ (em média, as medições são as mesmas sob os dois tratamentos),
- $H_1 : \boldsymbol{\delta} \neq \mathbf{0}$ (em médias, pelo menos uma das medições é diferente sob os tratamentos).

Como, sob $H_0 : \boldsymbol{\delta} = \mathbf{0}$,

$$T^2 := n \bar{\mathbf{D}}^\top \mathbf{S}_d^{-1} \bar{\mathbf{D}} \sim \frac{(n-1)p}{n-p} F_{p, n-p},$$

podemos utilizar a estatística T^2 para testar as hipóteses supramencionadas. Logo, ao nível de significância $\alpha = 5\%$, rejeitamos a hipótese nula $H_0 : \boldsymbol{\delta} = \mathbf{0}$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e $t_c^2 \in \mathbb{R}_+$ é o valor crítico tal que

$$t_c^2 = \frac{(n-1)p}{n-p} f_c,$$

sendo $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p, n-p}$.

Fixado o nível de confiança de $100 \times (1 - \alpha)\%$, podemos construir o elipsóide de confiança para o vetor de diferenças médias $\boldsymbol{\delta}$ tal como fazíamos no capítulo anterior, i.e.,

$$RC(\boldsymbol{\delta}, 1 - \alpha) = \left\{ \boldsymbol{\delta} \in \mathbb{R}^p : (\bar{\mathbf{d}} - \boldsymbol{\delta})^\top \mathbf{S}_d^{-1} (\bar{\mathbf{d}} - \boldsymbol{\delta}) \leq c^2 \right\},$$

em que

$$c^2 = \frac{(n-1)p}{n-p} f_c,$$

sendo $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p, n-p}$.

Embora o elipsóide de confiança seja suficiente do ponto de vista teórico, sua utilidade prática diminui rapidamente quando $p > 2$. Em três ou mais dimensões, situação comum quando várias medições são feitas em cada unidade experimental, a visualização direta desse elipsóide torna-se impossível e a interpretação das conclusões passa a ser abstrata para o pesquisador. Por esse motivo, em aplicações com $p \geq 3$ recomenda-se substituir a representação geométrica pelo conjunto de intervalos de confiança *simultâneos* para cada componente $\delta_i = \mu_{1i} - \mu_{2i}$, $i = 1, 2, \dots, p$. Fixado o nível global de confiança $100(1 - \alpha)\%$, esses limites podem ser construídos como fizemos no capítulo anterior: utilizando t -intervalos, T^2 -intervalos e intervalos de Bonferroni:

- **Intervalos individuais (t -intervalos):** Fixado o nível de confiança de $100 \times (1 - \alpha)\%$,

$$IC(\delta_i, 1 - \alpha) = \left[\bar{d}_i \pm t_c \sqrt{\frac{s_{ii}}{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \alpha$, com $T \sim t_{n-1}$.

- **Intervalos simultâneos (T^2 -intervalos):** Fixado o nível de confiança de $100 \times (1 - \alpha)\%$,

$$IC(\delta_i, \geq 1 - \alpha) = \left[\bar{d}_i \pm \sqrt{\frac{(n-1)p}{n-p}} f_c \sqrt{\frac{s_{ii}}{n}} \right],$$

em que $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p, n-p}$.

- **Intervalos de Bonferroni:** Fixado o nível de confiança de $100 \times (1 - \alpha)\%$,

$$IC\left(\delta_i, 1 - \frac{\alpha}{p}\right) = \left[\bar{d}_i \pm t_c \sqrt{\frac{s_{ii}}{n}} \right],$$

em que $t_c \in \mathbb{R}_+$ tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{p}$, com $T \sim t_{n-1}$.

Dessa forma cada componente é reportado em unidades familiares ao usuário, mantendo-se o controle do erro global sem recorrer a figuras de difícil interpretação. Vale lembrar que os intervalos de Bonferroni constituem um equilíbrio prático entre precisão e confiança, pois reduzem-se em relação aos T^2 -intervalos ao mesmo tempo que mantêm o controle do erro global.

Exemplo 6.2: (Johnson e Wichern, 2014, p. 276, tradução e grifo nosso)

Estações municipais de tratamento de esgoto precisam, por lei, monitorar rotineiramente os efluentes lançados em rios e córregos. A confiabilidade dos resultados de um programa de automonitoramento levou a um estudo no qual amostras de efluente foram divididas em duas alíquotas e enviadas a dois laboratórios. Metade de cada amostra foi enviada ao *Wisconsin State Laboratory of Hygiene* e a outra metade a um laboratório comercial usado regularmente no programa de monitoramento. Obtiveram-se, para $n = 11$ amostras fracionadas, medições da demanda bioquímica de oxigênio (BOD) e dos sólidos em suspensão (SS) nos dois laboratórios; os dados estão na Tabela 5.3. Suponha que seja plausível assumir a normalidade multivariada.

Exemplo 6.2

Tabela 6.3. Dados de efluente: BOD e SS medidos por dois laboratórios em $n = 11$ amostras.

Amostra j	Laboratório comercial		Laboratório estadual de higiene	
	x_{1j1} (BOD)	x_{1j2} (SS)	x_{2j1} (BOD)	x_{2j2} (SS)
1	6	27	25	15
2	6	23	28	13
3	18	64	36	22
4	8	44	35	29
5	11	30	15	31
6	34	75	44	64
7	28	26	42	30
8	71	124	54	64
9	43	54	34	56
10	33	30	29	20
11	20	14	39	21

- (a) Fixado um nível de significância $\alpha = 5\%$, verifique se pelo menos uma das medições realizadas nas amostras de água apresenta uma diferença significativa de laboratório para laboratório.
- (b) Construa intervalos de Bonferroni com um nível de confiança global de $1 - \alpha = 95\%$ e verifique se eles são consistentes com sua resposta para o item (a).

SOLUÇÃO:**(a) • Hipóteses:**

- $H_0 : \boldsymbol{\delta} = \mathbf{0}$ (em média, não há diferença entre as medições químicas conduzida pelo laboratório comercial com aquelas conduzidas pelo laboratório estatal);
- $H_1 : \boldsymbol{\delta} \neq \mathbf{0}$ (em média, há diferença entre as medições químicas conduzida pelo laboratório comercial com aquelas conduzidas pelo laboratório estatal)

• Estatística de teste: Sob $H_0 : \boldsymbol{\delta} = \mathbf{0}$,

$$T^2 := n\bar{\mathbf{D}}^\top \mathbf{S}_d^{-1} \bar{\mathbf{D}} \sim \frac{(n-1)p}{n-p} F_{p, n-p}, \quad \text{com } n = 11 \text{ e } p = 2.$$

Exemplo 6.2

- **Regra de decisão:** Ao nível de significância $\alpha = 5\%$, rejeitamos a hipótese nula $H_0 : \delta = 0$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e $t_c^2 \in \mathbb{R}_+$ é o valor crítico tal que

$$t_c^2 = \frac{(n-1)p}{n-p} f_c,$$

sendo $n = 11$, $p = 2$ e $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p, n-p}$.

- **Conclusão:** Observada a amostra, temos $t^2 = 13,6$. Ao nível de significância $\alpha = 5\%$, temos $t_c^2 = 9,47$. Logo, como $t^2 > t_c^2$, rejeitamos a hipótese nula $H_0 : \delta = 0$. Em outras palavras, com base na amostra observada, ao nível de significância $\alpha = 5\%$, há evidências de que *pelo menos* uma das análises químicas realizadas pelo laboratório comercial são diferentes daquelas conduzidas pelo laboratório estatal.
- (b) • **Intervalo de Bonferroni para δ_1 :** Fixado um nível de confiança global de 95%, o intervalo de Bonferroni para diferença média entre o nível de CO₂ na água medido pelo laboratório comercial e o nível medido pelo laboratório estatal é

$$\begin{aligned} IC(\delta_1, 97, 5\%) &= \left[\bar{d}_1 \pm t_c \sqrt{\frac{s_{11}}{n}} \right] \\ &= \left[-9,36 \pm 2,63 \sqrt{\frac{199,26}{11}} \right] \\ &= [-9,36 \pm 11,19] \\ &= [1,83; 20,55]. \end{aligned}$$

Com 97,5% confiança, o intervalo $[1,83; 20,55]$ inclui a verdadeira diferença média entre o nível de CO₂ na água medido pelo laboratório comercial e o nível medido pelo laboratório estatal. Como $[1,83; 20,55] \not\subset 0$, concluímos que há evidências de diferenças significativas entre as medições conduzidas pelos laboratórios.

- **Intervalo de Bonferroni para δ_2 :** Fixado um nível de confiança global de 95%, o intervalo de Bonferroni para diferença média entre a quantidade de sólidos suspensos na água medido pelo laboratório comercial e a quantidade

Exemplo 6.2

medida pelo laboratório estatal é

$$\begin{aligned} IC(\delta_2, 97,5\%) &= \left[\bar{d}_2 \pm t_c \sqrt{\frac{s_{22}}{n}} \right] \\ &= \left[13,27 \pm 2,63 \sqrt{\frac{418,61}{11}} \right] \\ &= [13,27 \pm 6,17] \\ &= [7,10; 19,44]. \end{aligned}$$

Com 97,5% confiança, o intervalo $[7,10; 19,44]$ inclui a verdadeira diferença média entre a quantidade de sólidos suspensos na água medido pelo laboratório comercial e a quantidade medida pelo laboratório estatal. Como $[7,10; 19,44] \not\ni 0$, concluímos que há evidências de diferenças significativas entre as medições conduzidas pelos laboratórios.

6.2 Delineamento de experimentos com medidas repetidas para comparar tratamentos

Em muitos contextos experimentais, especialmente nas áreas da medicina, psicologia, farmacologia, veterinária e ciências biológicas, é comum que a mesma unidade experimental seja submetida a diferentes tratamentos ao longo do tempo. Essa estrutura, conhecida como delineamento com medidas repetidas, permite que cada unidade sirva de seu próprio controle, reduzindo a variabilidade e aumentando o poder do teste estatístico. Do ponto de vista estatístico, esse tipo de delineamento gera dados multivariados correlacionados, nos quais queremos investigar se há evidências de que as médias dos tratamentos diferem significativamente. Ao longo desta seção, desenvolveremos ferramentas para tratar esse tipo de problema e aplicaremos os testes desenvolvidos à comparação de quatro diferentes combinações de tratamentos em cães, com base nas suas respostas fisiológicas.

Considere um experimento com q tratamentos e n unidades experimentais. Suponha que cada unidade experimental receba todos os tratamentos ao longo do tempo, resultando em uma observação vetorial por unidade. Especificamente, denotamos por $\mathbf{X}_j \in \mathbb{R}^q$ a observação da j -ésima unidade experimental, para $j = 1, 2, \dots, n$, em que

$$\mathbf{X}_j = \begin{bmatrix} X_{j1} \\ X_{j2} \\ \vdots \\ X_{jq} \end{bmatrix},$$

com X_{ji} sendo a resposta da j -ésima unidade ao i -ésimo tratamento. Nosso objetivo é testar se os tratamentos produzem respostas diferentes, ou seja, se as componentes do vetor de médias $\boldsymbol{\mu} = \mathbb{E}(\mathbf{X}_j)$ são todas iguais.

Para formalizarmos melhor a hipótese estatística de interesse, vale destacar que um tratamento é definido como a combinação específica dos níveis de dois ou mais fatores, isto é, variáveis categóricas que se acredita influenciarem a variável resposta. Cada fator pode assumir diferentes níveis, e os tratamentos representam todas as possíveis combinações entre esses níveis.

Por exemplo, considere um experimento agrícola em que estamos interessados no efeito da adubação e da irrigação sobre a produtividade de uma lavoura. Suponha que o fator adubação tenha dois níveis (orgânica e química) e o fator irrigação também tenha dois níveis (baixa e alta). Os tratamentos possíveis são então:

- Adubação orgânica com irrigação baixa (tratamento 1);
- Adubação orgânica com irrigação alta (tratamento 2);
- Adubação química com irrigação baixa (tratamento 3);
- Adubação química com irrigação alta (tratamento 4).

Cada uma dessas combinações constitui um tratamento distinto. O objetivo da análise estatística é verificar se há diferenças significativas na resposta (neste caso, a produtividade da lavoura) entre os diferentes tratamentos. Essa estrutura nos permite formular hipóteses como: “Existe efeito da adubação sobre a produtividade?”, “Existe efeito da irrigação?”, e “Há interação entre os fatores adubação e irrigação?”. Nesse caso, podemos testar conjuntamente essas hipóteses definindo uma matriz $\mathbf{C}$, denominada *matriz de contraste*, da seguinte maneira

$$\mathbf{C} = \begin{bmatrix} -1 & -1 & 1 & 1 \\ 1 & 1 & -1 & -1 \\ 1 & -1 & -1 & 1 \end{bmatrix}$$

e escrevendo a hipótese nula do teste como

$$H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_4,$$

em que $\boldsymbol{\mu} = [\mu_1 \ \mu_2 \ \mu_3 \ \mu_4]^\top$, sendo μ_i a produtividade média das lavouras quando

expostas ao tratamento i , $i = 1, 2, 3, 4$. Todavia, o(a) pesquisador(a) poderia estar interessado apenas em verificar o efeito da adubação e da irrigação sobre a produtividade. Nesse caso, a matriz de contraste seria

$$\mathbf{C} = \begin{bmatrix} -1 & -1 & 1 & 1 \\ 1 & 1 & -1 & -1 \end{bmatrix}.$$

Em outras, palavras as matrizes que contrastam combinações lineares entre as médias dos tratamentos dependem das respostas que estamos interessados em responder conjuntamente. Portanto, em geral, a hipótese nula genérica que envolve diferentes combinações dos efeitos dos tratamentos postulado pode ser escrita da seguinte maneira

$$H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_k,$$

para uma matriz de contraste $\mathbf{C}$ de ordem $k \times q$, em que k é o número de contrastes sendo testados conjuntamente. Com base nos vetores transformados $\mathbf{C}\mathbf{X}_j$, é possível calcular a média $\mathbf{C}\bar{\mathbf{X}}$ e a matriz de covariância amostral $\mathbf{CSC}^\top$. O teste é então conduzido utilizando a estatística

$$T^2 = n(\mathbf{C}\bar{\mathbf{X}})^\top (\mathbf{CSC}^\top)^{-1} (\mathbf{C}\bar{\mathbf{X}}),$$

que segue, sob $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_k$, uma distribuição T^2 de Hotelling, i.e.,

$$T^2 \sim \frac{(n-1)k}{n-k} F_{k, n-k}.$$

Portanto, fixando um nível de significância $\alpha \in (0, 1)$, rejeitamos a hipótese nula $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_k$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e t_c^2 é o valor crítico tal que

$$t_c^2 = \frac{(n-1)k}{n-k} f_c,$$

em que $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{k, n-k}$.

Uma outra forma de avaliar a plausibilidade da hipótese $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_k$ é verificar se o elipsóide de $(1 - \alpha) \times 100\%$ de confiança inclui o vetor nulo $\mathbf{0}_k$, i.e., devemos verificar se $RC(\mathbf{C}\boldsymbol{\mu}, 1 - \alpha) \ni \mathbf{0}_k$, em que

$$RC(\mathbf{C}\boldsymbol{\mu}, 1 - \alpha) := \left\{ \mathbf{C}\boldsymbol{\mu} \in \mathbb{R}^k : n(\mathbf{C}\bar{\mathbf{X}} - \mathbf{C}\boldsymbol{\mu})^\top (\mathbf{CSC}^\top)^{-1} (\mathbf{C}\bar{\mathbf{X}} - \mathbf{C}\boldsymbol{\mu}) \leq c^2 \right\},$$

em que

$$c^2 = \frac{(n-1)k}{n-k} f_c,$$

em que $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{k, n-k}$.

Caso a hipótese nula conjunta seja rejeitada, isto é, caso o teste baseado na matriz

de contrastes aponte evidência de que pelo menos um dos efeitos (adubação, irrigação ou interação, no caso do exemplo anterior) tem influência significativa sobre a produtividade, o próximo passo natural é investigar quais contrastes são responsáveis por essa rejeição. Para isso, uma abordagem adequada consiste na construção de intervalos de confiança simultâneos com correção de Bonferroni. Essa técnica permite avaliar individualmente cada contraste da matriz $\mathbf{C}$ controlando o erro do tipo I de forma conservadora, mas menos rígida do que abordagens globais. No contexto do nosso experimento, isso permite responder perguntas práticas como: “A adubação química aumenta significativamente a produtividade em relação à orgânica?”, “Aumentar a irrigação tem efeito significativo?” ou “O efeito da adubação depende do nível de irrigação?”. O método de Bonferroni é especialmente razoável nesse cenário por oferecer um bom equilíbrio entre precisão (ao manter intervalos relativamente estreitos) e confiabilidade (ao garantir um nível global de confiança pré-estabelecido). Assim, além de detectar a presença de algum efeito, conseguimos indicar com clareza quais fatores estão de fato influenciando a variável resposta.

Fixado um nível de confiança global de $1 - \alpha$, $\alpha \in (0, 1)$, o intervalo de Bonferroni para o i -ésimo contraste $\mathbf{c}_i^\top \boldsymbol{\mu}$ é dado por

$$IC\left(\mathbf{c}_i^\top \boldsymbol{\mu}, 1 - \frac{\alpha}{k}\right) = \left[\mathbf{c}_i^\top \bar{\mathbf{x}} \pm t_c \sqrt{\frac{\mathbf{c}_i^\top \mathbf{S} \mathbf{c}_i}{n}}\right],$$

em que $\mathbf{c}_i^\top$ denota a i -ésima linha da matriz de contrastes $\mathbf{C}$ e $t_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c \leq T \leq t_c) = 1 - \frac{\alpha}{p}$, sendo $T \sim t_{n-1}$. Os t -intervalos e os T^2 -intervalos são construídos de maneira análoga, apenas trocando o ponto crítico, respectivamente, por t_c^* e $\sqrt{\frac{(n-1)k}{n-k}} f_c$, em que $t_c^* \in \mathbb{R}_+$ é tal que $\mathbb{P}(-t_c^* \leq T \leq t_c^*) = 1 - \alpha$, sendo $T \sim t_{n-1}$, e $f_c \in \mathbb{R}_+$ é tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{k, n-k}$.

Exemplo 6.3: (Johnson e Wichern, 2014, p. 279, tradução e grifo nosso)

Melhorias em anestésicos frequentemente começam a ser estudadas por meio de experimentos em animais. Em um estudo, 19 cães foram inicialmente tratados com o fármaco pentobarbital. Em seguida, administrou-se dióxido de carbono (CO_2) em dois níveis de pressão para cada cão. Posteriormente, administrou-se halotano (H), e os mesmos dois níveis de pressão de CO_2 foram reaplicados. A variável resposta registrada foi o tempo (em milissegundos) entre batimentos cardíacos. Esse tempo foi medido para os **quatro tratamentos** originados das **combinações** dos níveis de pressão com os níveis da variável que indica a administração ou não de halotano. Esses tratamentos são representados a seguir e a Tabela 6.4 apresenta as quatro

Exemplo 6.3


medições para cada um dos 19 cães, em que

- Tratamento 1 = pressão alta de CO_2 sem halotano;
- Tratamento 2 = pressão baixa de CO_2 sem halotano;
- Tratamento 3 = pressão alta de CO_2 com halotano;
- Tratamento 4 = pressão baixa de CO_2 com halotano

Analisaremos os efeitos anestésicos da pressão de CO_2 e do halotano a partir desse delineamento com medidas repetidas.

Tabela 6.4. Tempo entre batimentos cardíacos (em milissegundos) para os 19 cães sob os quatro tratamentos.

Cão	Tratamento 1	Tratamento 2	Tratamento 3	Tratamento 4
1	426	609	556	600
2	253	236	392	395
3	359	433	349	357
4	432	431	522	600
5	405	426	513	513
6	324	438	507	539
7	310	312	410	456
8	326	326	350	504
9	375	447	547	548
10	286	286	403	422
11	349	382	473	497
12	429	410	488	547
13	348	377	447	514
14	412	473	472	446
15	347	326	455	468
16	434	458	637	524
17	364	367	432	469
18	420	395	508	531
19	397	556	645	625

Exemplo 6.3

- (a) Fixado um nível de significância $\alpha = 5\%$, um pesquisador está interessado em avaliar se pelo menos um dentre três contrastes a seguir possuem um efeito significativo sobre o tempo entre batimentos cardíacos: (i) a administração de halotano, (ii) o nível de pressão ou a interação entre halotano e pressão. Defina as hipóteses estatísticas e científica, a estatística de teste, a distribuição da estatística sob a hipótese nula, a regra de decisão e as conclusões estatística e científica.
- (b) Fixado um de confiança global de $1 - \alpha = 95\%$, construa intervalos de Bonferroni para avaliar qual(is) dentre os três contrastes mencionados no item (a) possui um efeito significativo sobre o tempo entre batimentos cardíacos.

SOLUÇÃO:

(a) Nesse caso, os contrastes são:

- **Contraste 1:** avalia o efeito do halotano sobre o tempo médio entre batimentos cardíacos, sem se importar com o nível de pressão, o que estatisticamente traduzimos como,

$$\mu_1 + \mu_2 = \mu_3 + \mu_4 \Rightarrow \mu_1 + \mu_2 - \mu_3 - \mu_4 = 0.$$

- **Contraste 2:** avalia o efeito do nível de pressão sobre o tempo médio entre batimentos cardíacos, sem se importar com a administração de halotano, o que estatisticamente traduzimos como,

$$\mu_1 + \mu_3 = \mu_2 + \mu_4 \Rightarrow \mu_1 - \mu_2 + \mu_3 - \mu_4 = 0.$$

- **Contraste 3:** avalia o efeito do nível de pressão sobre o tempo médio

Exemplo 6.3

entre batimentos cardíacos, se importando com a administração de halotano, equivalente, a avaliar o efeito do halotano sobre o tempo médio entre batimentos cardíacos, se importando com o nível de pressão. Em outras palavras, estamos avaliando a *interação* entre o nível de pressão e administração de halotano, o que estatisticamente traduzimos como,

$$\mu_1 - \mu_2 = \mu_3 - \mu_4 \Rightarrow \mu_1 - \mu_2 - \mu_3 + \mu_4 = 0.$$

- **Hipóteses:**

- $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_3$ (os contrastes considerados não possuem efeito sobre o tempo médio entre batimentos cardíacos dos cães),
- $H_1 : \mathbf{C}\boldsymbol{\mu} \neq \mathbf{0}_3$ (pelo menos um dos contrastes considerados possuem efeito sobre o tempo médio entre batimentos cardíacos dos cães).

- **Estatística de teste:** Sob $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_3$,

$$T^2 = n(\mathbf{C}\bar{\mathbf{X}})^\top (\mathbf{CSC}^\top)^{-1} (\mathbf{C}\bar{\mathbf{X}}) \sim \frac{(n-1)k}{n-k} F_{k,n-k} \text{ com } n = 19 \text{ e } k = 3.$$

- **Regra de decisão:** Fixado o nível de significância $\alpha = 5\%$, rejeitamos $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_3$ quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e t_c^2 é o ponto crítico tal que

$$t_c^2 = \frac{(n-1)k}{n-k} f_c, \quad \text{com } n = 19 \text{ e } k = 3,$$

em que $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c)$ sendo $F \sim F_{k,n-k}$.

- **Conclusão:** Observada a amostra, temos $t^2 = 116$, e ao nível de significância $\alpha = 5\%$, temos $t_c^2 = 10,94$. Como $t^2 > t_c^2$, rejeitamos a hipótese $H_0 : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_3$ ao nível de significância de 5%. Em outras palavras, a amostra traz evidências de que pelo menos um dos contrastes possui um efeito significativo sobre o tempo médio entre batimentos cardíacos dos cães.

(b) Fixado o nível de confiança global de 95%, temos

$$IC(\mathbf{c}_1\boldsymbol{\mu}, 98, 3\%) = \left[\mathbf{c}_1^\top \bar{\mathbf{x}} \pm t_c \sqrt{\frac{\mathbf{c}_1^\top \mathbf{S} \mathbf{c}_1}{n}} \right] = [209, 31 \pm 73, 70] = [135, 61; 283, 01].$$

Exemplo 6.3

$$IC(\mathbf{c}_2^\top \boldsymbol{\mu}, 98,3\%) = \left[\mathbf{c}_2^\top \bar{\mathbf{x}} \pm t_c \sqrt{\frac{\mathbf{c}_2^\top \mathbf{S} \mathbf{c}_2}{n}} \right] = [-60,05 \pm 54,70] = [-114,75; -5,35],$$

$$IC(\mathbf{c}_3^\top \boldsymbol{\mu}, 98,3\%) = \left[\mathbf{c}_3^\top \bar{\mathbf{x}} \pm t_c \sqrt{\frac{\mathbf{c}_3^\top \mathbf{S} \mathbf{c}_3}{n}} \right] = [12,79 \pm 65,97] = [-53,18; 78,76].$$

O primeiro intervalo de confiança indica que há um efeito do halotano. A presença de halotano aumenta o tempo entre batimentos cardíacos. Isso ocorre em ambos os níveis de pressão de CO_2 , uma vez que o contraste de interação entre halotano e pressão de CO_2 ,

$$(\mu_1 + \mu_4) - (\mu_2 + \mu_3),$$

não é significativamente diferente de zero (ver o terceiro intervalo de confiança). O segundo intervalo de confiança indica que há um efeito devido à pressão de CO_2 : a *menor* pressão de CO_2 produz maiores intervalos entre batimentos cardíacos.

Alguma cautela deve ser adotada na interpretação desses resultados, pois os testes com halotano foram conduzidos após os testes sem halotano. O aparente efeito do halotano pode ser consequência de uma tendência temporal. (Idealmente, a ordem dos tratamentos deveria ser completamente aleatória.)

6.3 Análise de variância multivariada com um único fator

Em diversas situações práticas, estamos interessados em estudar o efeito de um fator qualitativo sobre mais de uma variável resposta quantitativa. Embora a análise de variância (ANOVA, do inglês *Variance Analysis*) permita avaliar esse efeito quando há apenas uma variável resposta, sua aplicação isolada pode ser limitada diante da natureza multivariada de muitos problemas. Nesses casos, a análise de variância multivariada (MANOVA, do inglês *Multivariate Variance Analysis*) surge como uma extensão natural, possibilitando a consideração simultânea de múltiplas respostas e permitindo explorar não apenas as diferenças médias entre grupos, mas também as possíveis correlações entre as variáveis. Iniciamos esta seção revisando como conduzir uma ANOVA univariada.

No caso univariado, assumimos que $X_{\ell 1}, X_{\ell 2}, \dots, X_{\ell n_\ell}$ é uma amostra aleatória proveniente de uma população $Normal(\mu_\ell, \sigma^2)$, com $\ell = 1, 2, \dots, g$, e que as amostras aleatórias são independentes entre si. Embora a hipótese nula de igualdade entre as médias pudesse ser formulada como $H_0 : \mu_1 = \mu_2 = \dots = \mu_g$, é comum expressarmos μ_ℓ como a soma de um componente médio geral, como μ , e de um componente associado à população específica. Por exemplo, podemos escrever $\mu_\ell = \mu + (\mu_\ell - \mu)$ ou $\mu_\ell = \mu + \tau_\ell$, em que $\tau_\ell = \mu_\ell - \mu$.

Populações geralmente correspondem a diferentes conjuntos de condições experimentais. Assim, é conveniente investigar os desvios τ_ℓ associados à ℓ -ésima população (ou tratamento, ou grupo). A reparametrização

$$\underbrace{\mu_\ell}_{\text{média da população } \ell} = \underbrace{\mu}_{\text{média geral}} + \underbrace{\tau_\ell}_{\text{efeito do tratamento } \ell}$$

leva a uma reformulação da hipótese de igualdade entre as médias. A hipótese nula torna-se

$$H_0 : \tau_1 = \tau_2 = \dots = \tau_g = 0.$$

A variável resposta $X_{\ell j}$, com distribuição $Normal(\mu + \tau_\ell, \sigma^2)$, pode, portanto, ser expressa na forma

$$\underbrace{X_{\ell j}}_{\text{resposta}} = \underbrace{\mu}_{\text{média geral}} + \underbrace{\tau_\ell}_{\text{efeito do tratamento}} + \underbrace{\epsilon_{\ell j}}_{\text{erro aleatório}}$$

em que os $\epsilon_{\ell j}$ são variáveis aleatórias independentes com distribuição $Normal(0, \sigma^2)$. Para definir de forma única os parâmetros do modelo e suas estimativas de mínimos quadrados (modelo identificável), é comum impor a restrição

$$\sum_{\ell=1}^g \tau_\ell = 0.$$

Motivada pela decomposição anterior, a análise de variância se baseia em uma decomposição análoga das observações:

$$\underbrace{x_{\ell j}}_{\text{observação}} = \underbrace{\bar{x}}_{\text{média geral da amostra}} + \underbrace{(\bar{x}_\ell - \bar{x})}_{\text{efeito estimado do tratamento}} + \underbrace{(x_{\ell j} - \bar{x}_\ell)}_{\text{resíduo}},$$

em que $\bar{x}$ é uma estimativa de μ , $\hat{\tau}_\ell = (\bar{x}_\ell - \bar{x})$ é uma estimativa de τ_ℓ , e $(x_{\ell j} - \bar{x}_\ell)$ é uma estimativa do erro $\epsilon_{\ell j}$.

Exemplo 6.4

No ano de 2022, na cidade de Violeta do Sul foi conduzida uma pesquisa, cujo objetivo era investigar se o tipo de exercício físico (sedentário, leve, pesado) possuía efeito significativo sobre a pressão arterial sistólica (PAS) nos adultos dessa cidade. O cadastro da cidade continha os dados pessoais de 1.000 adultos, dos quais foi coletada uma amostra de 30 adultos para participar da pesquisa. A amostra observada é dada na Tabela 6.5.

Tabela 6.5. Pressão arterial sistólica (PAS) de acordo com o tipo de exercício físico (sedentário, leve e pesado) aferida em 30 adultos da cidade de Violeta do Sul.


Grupo	PAS (mmHg)
Sedentário	135, 138, 132, 140, 137, 136, 133, 139, 134, 138
Exercício leve	130, 128, 129, 132, 131, 127, 130, 129, 131, 128
Exercício pesado	122, 120, 118, 121, 123, 119, 117, 120, 118, 122

- Construa *boxplots* da pressão arterial sistólica (PAS) em cada um dos grupos definidos pelos tipos de exercício físico (sedentário, leve e pesado). Interprete-os.
- Construa uma tabela ANOVA.
- Fixado um nível de significância $\alpha = 1\%$, verifique se há uma diferença significativa da pressão média entre os grupos. Defina as hipóteses estatísticas e científicas, a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e as conclusões estatísticas e em termos do problema.
- Sua conclusão para o item (c) é compatível com os indícios obtidos no item (a)? Por quê?

SOLUÇÃO:

- Com base nos *boxplots*, temos um indicativo de que a pressão arterial sistólica média em cada um dos grupos é diferente, sendo maior no grupo dos sedentários e menor no grupo dos indivíduos que praticam exercícios pesados. A amostra sugere, portanto, que o tipo de exercício influencia a pressão arterial sistólica.

Exemplo 6.4



(b) A tabela de análise de variância (ANOVA) é dada por

FV	g.l	SQ	QM	Estatística F
Entre os grupos	$g - 1$	SQ_E	QM_E	$F = \frac{QM_E}{QM_D}$
Dentro dos grupos	$n - g$	SQ_D	QM_D	
Total	$n - 1$			

Figura 6.1. *Boxplots* da pressão arterial sistólica (PAS) de acordo com o tipo de exercício físico (sedentário, leve e pesado) aferida em 30 adultos da cidade de Violeta do Sul.

em que FV é uma abreviação para fonte de variação, $g.l$ é uma abreviação para graus de liberdade, SQ é uma abreviação para soma dos quadrados e QM é uma abreviação para a média da soma dos quadrados. São duas as somas dos quadrados:

Exemplo 6.4

- Soma dos quadrados entre os grupos:

$$SQ_E := \sum_{\ell=1}^g n_{\ell} (\bar{x}_{\ell} - \bar{x})^2;$$

- Soma dos quadrados dentro dos grupos:

$$SQ_D := \sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (x_{\ell j} - \bar{x}_{\ell})^2,$$

consequentemente, temos dois QMs:

- Média da soma dos quadrados entre os grupos:

$$QM_E := \frac{1}{g-1} \sum_{\ell=1}^g n_{\ell} (\bar{x}_{\ell} - \bar{x})^2 = \frac{SQ_E}{g-1};$$

- Média da soma dos quadrados dentro dos grupos:

$$QM_D := \frac{1}{n-g} \sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (x_{\ell j} - \bar{x}_{\ell})^2 = \frac{SQ_D}{n-g}.$$

Observada a amostra, a tabela é ANOVA é dada por

FV	g.l	SQ	QM	Estatística F
Entre os grupos	2	1.325,3	662,6	$f = 3,18 \times 10^{-15}$
Dentro dos grupos	27	122,1	4,5	
Total	29			

- (c) • **Hipóteses:**

- $H_0 : \mu_1 = \mu_2 = \mu_3$ (a pressão arterial sistólica média é a mesma para os três grupos considerados na análise: indivíduos sedentários, indivíduos que praticam exercícios leves e indivíduos que praticam exercícios pesados);
- $H_1 : \text{algum } \mu_i \text{ é diferente dos demais (a pressão arterial sistólica média de pelo menos um dos três grupos considerados na análise é diferente das demais).}$

Como discutido, essas hipóteses são equivalentes às seguintes hipóteses:

Exemplo 6.4

- $H_0 : \tau_1 = \tau_2 = \tau_3 = 0$ (os tipos de exercícios (sedentário, leve ou pesado) não possuem efeito sobre a pressão arterial sistólica esperada);
- $H_1 : \text{algum } \tau_i \text{ é diferente dos demais (pelo menos um dos tipos de exercícios (sedentário, leve ou pesado) possui efeito sobre a pressão arterial sistólica esperada)}.$

- **Estatística de teste:** Sob a hipótese nula $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = 0$), temos

$$T^2 = \frac{QM_E}{QM_D} \sim F_{g-1, n-g}, \text{ com } n = 30 \text{ e } g = 3.$$

- **Regra de decisão:** Ao nível de significância $\alpha = 1\%$, rejeitamos a hipótese nula $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = 0$) quando $f > f_c$, em que f é o valor observado da estatística F e $f_c \in \mathbb{R}_+$ é o valor crítico tal que $\mathbb{P}(F > f_c) = 0,01$, sendo $F \sim F_{2,27}$.
- **Conclusão:** Observada a amostra, $f = 3,18 \times 10^{-15}$. Fixado o nível de significância $\alpha = 1\%$, temos $f_c = 5,48$. Como $f > f_c$, ao nível de significância de 1% , rejeitamos a hipótese $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = 0$). Em outras palavras, ao nível de significância de 1% , a amostra observada traz evidências de que **ao menos** um dos grupos possui pressão sistólica arterial média diferente dos demais, i.e., **ao menos** um dos tipos de exercício físico exerce efeito significativo sobre a pressão média.

(d) As conclusões obtidas no item (c) são consistentes com os indícios fornecidos pelos *boxplots* do item (a). No primeiro caso, concluímos que há evidências de que pelo menos um dos grupos possui uma pressão sistólica arterial (PAS) média diferente dos demais e a análise descritiva sugere que indivíduos sedentários possuem a maior PAS média, enquanto o grupo de indivíduos que pratica exercícios pesados possui a menor PAS média. Em suma, os métodos estatísticos utilizados corroboram para o fato de que o tipo de exercício afeta a pressão sistólica arterial.

Na MANOVA, podemos realizar uma reparametrização análoga à feita na ANOVA, mas agora considerando simultaneamente mais de uma variável resposta, o que permite estudar o efeito do fator sobre o vetor e médias populacionais.

Frequentemente, é necessário comparar mais do que duas populações. Amostras aleatórias, coletadas de cada uma das g populações, são organizadas da seguinte forma:

$$\begin{aligned} \text{População 1: } & \mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1}, \\ \text{População 2: } & \mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2}, \\ & \vdots \\ \text{População } g: & \mathbf{X}_{g1}, \mathbf{X}_{g2}, \dots, \mathbf{X}_{gn_g}, \end{aligned}$$

em que $\mathbf{X}_{\ell j}$ é um vetor aleatório de $\mathbb{R}^p$ que representa p respostas da unidade experimental j ao tratamento ℓ , $\ell = 1, 2, \dots, g$ e $j = 1, 2, \dots, n_\ell$.

A MANOVA é utilizada inicialmente para investigar se os vetores de médias populacionais são iguais e, caso não sejam, quais componentes dessas médias diferem significativamente. As suposições sobre a estrutura dos dados para MANOVA de um fator são análogas ao caso univariado:

1. $\mathbf{X}_{\ell 1}, \mathbf{X}_{\ell 2}, \dots, \mathbf{X}_{\ell n_\ell}$ é uma amostra aleatória de tamanho n_ℓ de uma população com média $\boldsymbol{\mu}_\ell$, para $\ell = 1, 2, \dots, g$. As amostras aleatórias provenientes de populações diferentes são independentes entre si;
2. Todas as populações possuem uma mesma matriz de covariância $\boldsymbol{\Sigma}$;
3. Cada população é normalmente distribuída de forma multivariada (p -variada).

A condição 3 pode ser relaxada com base no teorema central do limite multivariado, quando os tamanhos amostrais n_ℓ forem grandes.

Generalizando o modelo desenvolvido para ANOVA univariada, no caso da MANOVA, temos

$$\mathbf{X}_{\ell j} = \boldsymbol{\mu} + \boldsymbol{\tau}_\ell + \boldsymbol{\epsilon}_{\ell j}, \quad j = 1, 2, \dots, n_\ell \quad \text{e} \quad \ell = 1, 2, \dots, g$$

em que os termos $\boldsymbol{\epsilon}_{\ell j}$ são variáveis aleatórias independentes com distribuição $\text{Normal}_p(\mathbf{0}_p, \boldsymbol{\Sigma})$. Aqui, o vetor de parâmetros $\boldsymbol{\mu}$ representa o nível médio geral e $\boldsymbol{\tau}_\ell$ representa o efeito do ℓ -ésimo tratamento sobre a resposta esperada, com a restrição

$$\sum_{\ell=1}^g \boldsymbol{\tau}_\ell = \mathbf{0}_p,$$

para tornar o modelo identificável. De acordo com esse modelo, cada componente do vetor observado $\mathbf{X}_{\ell j}$ satisfaz o modelo univariado correspondente. Os erros associados aos componentes de $\mathbf{X}_{\ell j}$ são correlacionados, mas a matriz de covariância $\boldsymbol{\Sigma}$ é a mesma para todas as populações.

Um vetor de observações pode ser decomposto conforme sugerido pelo modelo. Assim,

$$\underbrace{\mathbf{x}_{\ell j}}_{\text{observação}} = \underbrace{\bar{\mathbf{x}}}_{\text{média geral da amostra}} + \underbrace{(\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})}_{\text{efeito estimado do tratamento } \hat{\tau}_{\ell}} + \underbrace{(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})}_{\text{resíduo } \hat{\epsilon}_{\ell j}}$$

A decomposição acima leva ao análogo multivariado da decomposição da soma dos quadrados observada no caso univariado. Primeiramente, notamos que o produto

$$(\mathbf{x}_{\ell j} - \bar{\mathbf{x}})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}})^{\top}$$

pode ser reescrito como

$$\begin{aligned} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}})^{\top} &= [(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell}) + (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})][(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell}) + (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})]^{\top} \\ &= (\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})^{\top} + (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})(\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})^{\top} \\ &\quad + (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})^{\top} + (\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})(\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})^{\top} \end{aligned}$$

A soma sobre j das duas expressões intermediárias resulta na matriz nula, pois

$$\sum_{j=1}^{n_{\ell}} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell}) = \mathbf{0}.$$

Assim, somando os produtos cruzados sobre os índices ℓ e j , obtemos:

$$\sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}})^{\top} = \sum_{\ell=1}^g n_{\ell} (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})(\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})^{\top} + \sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})^{\top}$$

Agora, as somas de quadrados são matrizes de ordem $p \times p$. Denotamos por $\mathbf{T}$ a matriz da soma de quadrados e termos cruzados totais, $\mathbf{E}$ a matriz da soma de quadrados e termos cruzados entre tratamentos e por $\mathbf{D}$ a matriz da soma de quadrados e termos cruzados dentro dos tratamentos, i.e.,

$$\begin{aligned} \mathbf{T} &= \sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}})^{\top}, \\ \mathbf{E} &= \sum_{\ell=1}^g n_{\ell} (\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})(\bar{\mathbf{x}}_{\ell} - \bar{\mathbf{x}})^{\top}, \\ \mathbf{D} &= \sum_{\ell=1}^g \sum_{j=1}^{n_{\ell}} (\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})(\mathbf{x}_{\ell j} - \bar{\mathbf{x}}_{\ell})^{\top}. \end{aligned}$$

Assim, $\mathbf{T} = \mathbf{E} + \mathbf{D}$.

De forma análoga ao caso univariado, a hipótese de ausência de efeitos de tratamento

$$H_0: \tau_1 = \tau_2 = \cdots = \tau_g = \mathbf{0}_p$$

é testada a partir da comparação entre os tamanhos relativos das somas (e produtos cruzados) entre e dentro dos grupos. Alternativamente, pode-se considerar o tamanho relativo das somas total e dentro de quadrados e produtos cruzados. Para motivar essa maneira alternativa. Lembremos que na ANOVA univariada, rejeitamos H_0 para valores *grandes* de QM_E/QM_D , o que é equivalente a rejeitar H_0 para valores *grandes* de SQ_E/SQ_D ou valores *grandes* de $1 + SQ_E/SQ_D$. Alternativamente, rejeitamos H_0 para valores *pequenos* de

$$\frac{1}{1 + SQ_E/SQ_D} = \frac{SQ_D}{SQ_D + SQ_E} = \frac{SQ_D}{SQ_T}.$$

No caso da análise de variância multivariada, precisamos resumir as informações contidas nas matrizes $\mathbf{T}$, $\mathbf{D}$ e $\mathbf{E}$ para construir a estatística de teste. Para isso, vamos considerar a variabilidade generalizada de cada uma dessas matrizes, i.e., seus determinantes. Portanto, rejeitamos a hipótese $H_0: \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2 = \dots = \boldsymbol{\mu}_g$ (equivalentemente, $H_0: \boldsymbol{\tau}_1 = \boldsymbol{\tau}_2 = \dots = \boldsymbol{\tau}_g = \mathbf{0}_p$) quando

$$\Lambda^* = \frac{|\mathbf{D}|}{|\mathbf{T}|} = \frac{|\mathbf{D}|}{|\mathbf{D} + \mathbf{E}|}$$

for *pequeno*. Essa estatística é denominada *estatística de Wilks* e sua distribuição pode ser derivada a partir dos casos especiais listados na tabela a seguir.

Tabela 6.6. Distribuição da estatística de Wilks Λ^* .

p	g	Distribuição
$p = 1$	$g \geq 2$	$\left(\frac{n-g}{g-1}\right) \left(\frac{1-\Lambda^*}{\Lambda^*}\right) \sim F_{g-1, n-g}$
$p = 2$	$g \geq 2$	$\left(\frac{n-g-1}{g-1}\right) \left(\frac{1-\sqrt{\Lambda^*}}{\sqrt{\Lambda^*}}\right) \sim F_{2(g-1), 2(n-g-1)}$
$p \geq 1$	$g = 2$	$\left(\frac{n-p-1}{p}\right) \left(\frac{1-\Lambda^*}{\Lambda^*}\right) \sim F_{p, n-p-1}$
$p \geq 1$	$g = 3$	$\left(\frac{n-p-2}{p}\right) \left(\frac{1-\sqrt{\Lambda^*}}{\sqrt{\Lambda^*}}\right) \sim F_{2p, 2(n-p-2)}$

Em todo caso, para os fins dessas notas de aulas, vamos contar com o auxílio do *software R* em problemas que envolvem MANOVA de um fator, a função que descrevemos no código a seguir faz uso de uma modificação da estatística de Wilks Λ^* que deve-se a Bartlett (ver slides).

Listing 6.1: Código

```
1 # Ajuste do modelo MANOVA
2 modelo <- manova(cbind(Y1, Y2) ~ grupo, data = dados)
3 # Resultado utilizando a modificação de Barlett para estatística
  de Wilks
4 summary(modelo, test = "Wilks")
```

Exemplo 6.5

Considere o mesmo problema do Exemplo 6.4, mas considere além da pressão arterial sistólica (PAS), a variável resposta frequência cardíaca em repouso (FRC). A amostra observada nos 30 adultos de Violeta do Sul é dada na tabela a seguir.

Tabela 6.7. Pressão arterial sistólica (PAS) e frequência cardíaca em repouso (FR) de acordo com o tipo de exercício físico (sedentário, leve e pesado) aferida em 30 adultos da cidade de Violeta do Sul.

Grupo	PAS (mmHg)	FRC (bpm)
Sedentário	135, 138, 132, 140, 137, 136, 133, 139, 134, 138	91, 88, 90, 92, 87, 89, 86, 93, 88, 90
Exercício leve	130, 128, 129, 132, 131, 127, 130, 129, 131, 128	78, 76, 75, 74, 77, 79, 76, 75, 78, 76
Exercício pesado	122, 120, 118, 121, 123, 119, 117, 120, 118, 122	64, 62, 60, 63, 61, 59, 62, 60, 61, 63

- Construa *boxplots* da pressão arterial sistólica (PAS) e frequência cardíaca em repouso (FRC) em cada um dos grupos definidos pelos tipos de exercício físico (sedentário, leve e pesado). Interprete-os.
- Fixado um nível de significância $\alpha = 1\%$, verifique se há uma diferença significativa do vetor de médias entre os grupos. Defina as hipóteses estatísticas e científicas, a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e as conclusões estatísticas e em termos do problema.
- Sua conclusão para o item (b) é compatível com os indícios obtidos no item (a)? Por quê?

SOLUÇÃO:

- Com base nos *boxplots*, temos um indicativo de que a pressão arterial sistólica média e a frequência cardíaca em repouso em cada um dos grupos é diferente, sendo maior no grupo dos sedentários e menor no grupo dos indivíduos que praticam exercícios pesados. A amostra sugere, portanto, que o tipo de exercício influencia a pressão arterial sistólica e a frequência cardíaca em repouso.

Exemplo 6.5




Figura 6.2. *Boxplots* da pressão arterial sistólica (PAS) de acordo com o tipo de exercício físico (sedentário, leve e pesado) aferida em 30 adultos da cidade de Violeta do Sul.

(b) • **Hipóteses:**

- $H_0 : \mu_1 = \mu_2 = \mu_3$ (o vetor das médias das medidas fisiológicas em pauta (PAS e FRC) é a mesma para os três grupos considerados na análise: indivíduos sedentários, indivíduos que praticam exercícios leves e indivíduos que praticam exercícios pesados);
- $H_1 : \text{algum } \mu_i \text{ é diferente dos demais (o vetor de médias de pelo menos um dos três grupos considerados na análise é diferente dos demais).}$

Como discutido, essas hipóteses são equivalentes às seguintes hipóteses:

- $H_0 : \tau_1 = \tau_2 = \tau_3 = 0$ (os tipos de exercícios (sedentário, leve ou pesado) não possuem efeito sobre o vetor de medidas fisiológicas esperado);
- $H_1 : \text{algum } \tau_i \text{ é diferente dos demais (pelo menos um dos tipos de exercícios (sedentário, leve ou pesado) possui efeito sobre o vetor de medidas fisiológicas esperado).}$

Exemplo 6.5

- **Estatística de teste:** Sob a hipótese nula $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = \mathbf{0}$), temos

$$\Lambda^* = \frac{|D|}{|T|} = \frac{|D|}{|D + E|}$$

tem distribuição de Wilkis tal como dada na Tabela 6.6.

- **Regra de decisão:** Utilizando a modificação de Barlett, para ficar consistente com os resultados do R, ao nível de significância $\alpha = 1\%$, rejeitamos a hipótese nula $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = \mathbf{0}$) quando $f_{approx.} > f_c$, em que $f_{\approx}$ é o valor observado da estatística $F_{\approx}$ (ver slides para detalhes) e $f_c \in \mathbb{R}_+$ é o valor crítico tal que $\mathbb{P}(F_{approx.} > f_c) = 0,01$, sendo $F_{approx.} \sim F_{4,52}$.
- **Conclusão:** Observada a amostra, $f = 77.226$. Fixado o nível de significância $\alpha = 1\%$, temos $f_c = 3,7$. Como $f > f_c$, ao nível de significância de 1% , rejeitamos a hipótese $H_0 : \mu_1 = \mu_2 = \mu_3$ (equivalentemente, $H_0 : \tau_1 = \tau_2 = \tau_3 = \mathbf{0}$). Em outras palavras, ao nível de significância de 1% , a amostra observada traz evidências de que **ao menos** um dos grupos possui vetor de medidas fisiológicas (FCR e PAS) diferente dos demais, i.e., **ao menos** um dos tipos de exercício físico exerce efeito significativo sobre as medidas fisiológicas esperadas.

Embora tenhamos abordado nestas notas apenas a situação com um único fator, é possível conduzir a MANOVA com dois ou mais fatores. Essa extensão permite investigar efeitos principais e possíveis interações entre fatores sobre múltiplas variáveis respostas. Por exemplo, seria possível estudar, simultaneamente, o impacto do tipo de exercício físico e da dieta alimentar sobre indicadores fisiológicos como pressão arterial e frequência cardíaca. No entanto, análises com mais de um fator exigem estruturas matriciais e interpretações adicionais, que não serão tratadas neste material.

6.4 Análise de perfis

A análise de perfis é adequada para situações em que um conjunto de p tratamentos (testes, questionários etc.) é aplicado a dois ou mais grupos de indivíduos, sendo que todas as respostas devem ser expressas na mesma unidade. Além disso, assume-se que as respostas entre os grupos são independentes. Normalmente, deseja-se saber se os vetores

de médias populacionais são iguais. Na análise de perfis, essa questão é dividida em possibilidades mais específicas.

Considere, por exemplo, as médias populacionais $\boldsymbol{\mu}_1^\top = [\mu_{11}, \mu_{12}, \mu_{13}, \mu_{14}]$ representando as médias das respostas para quatro tratamentos no grupo 1. A conexão dessas médias por segmentos de reta define o perfil da população 1.




Figura 6.3. O perfil de uma população exposta a 4 tratamentos.

Perfis podem ser construídos para cada grupo populacional. Suponha dois grupos, com:

$$\boldsymbol{\mu}_1^\top = [\mu_{11}, \mu_{12}, \dots, \mu_{1p}] \quad \text{e} \quad \boldsymbol{\mu}_2^\top = [\mu_{21}, \mu_{22}, \dots, \mu_{2p}]$$

sendo os vetores médios de respostas para os p tratamentos nos grupos 1 e 2. A hipótese $H_0: \boldsymbol{\mu}_1 = \boldsymbol{\mu}_2$ implica que os tratamentos têm o mesmo efeito (médio) nos dois grupos.

Essa igualdade pode ser verificada de forma sequencial:

1. Os perfis são *paralelos*? O que é equivalente a testar a hipótese

$$H_{01}: \mu_{1i} - \mu_{1,i-1} = \mu_{2i} - \mu_{2,i-1}, \quad i = 2, 3, \dots, p.$$

A palavra *paralelo* vem do fato que dois perfis são paralelos quando os coeficientes angulares das retas que conectam os tratamentos são iguais, i.e., $\frac{\mu_{1i} - \mu_{1,i-1}}{1} = \frac{\mu_{2i} - \mu_{2,i-1}}{1}$, para todo $i = 1, 2, 3, \dots, p$.

2. Supondo perfis paralelos, eles *coincidem*? O que é equivalente a testar a hipótese Equivalentemente:

$$H_{02}: \mu_{1i} = \mu_{2i}, \quad i = 1, 2, \dots, p.$$

3. Supondo perfis coincidentes, eles são planos? Ou seja, todas as médias são iguais a uma mesma constante? O que é equivalente a testar a hipótese

$$H_{03}: \mu_{11} = \mu_{12} = \dots = \mu_{1p} = \mu_{21} = \dots = \mu_{2p}.$$

Para encontrarmos a distribuição das estatísticas de testes para cada um dos três problemas definidos anteriormente, precisamos de um resultado, o qual enunciamos e provamos a seguir.

Resultado 6.1

Seja $\mathbf{X}_{11}, \mathbf{X}_{12}, \dots, \mathbf{X}_{1n_1}$ uma amostra aleatória de tamanho n_1 proveniente de uma distribuição $\text{Normal}_p(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$, e seja $\mathbf{X}_{21}, \mathbf{X}_{22}, \dots, \mathbf{X}_{2n_2}$ uma amostra aleatória independente de tamanho n_2 proveniente de uma distribuição $\text{Normal}_p(\boldsymbol{\mu}_2, \boldsymbol{\Sigma})$. Então a estatística

$$T^2 = [\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)]^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{S}_{\text{comb.}} \right]^{-1} [\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)]$$

possui distribuição

$$\frac{(n_1 + n_2 - 2)p}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1},$$

em que

$$\mathbf{S}_{\text{comb.}} = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2}$$

é uma estimativa da matriz de variâncias e covariâncias de $\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2$.

DEMONSTRAÇÃO: Note que

$$\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 = \frac{1}{n_1} \sum_{j=1}^{n_1} \mathbf{X}_{1j} - \frac{1}{n_2} \sum_{j=1}^{n_2} \mathbf{X}_{2j}$$

segue a distribuição

$$\text{Normal}_p \left(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2, \left(\frac{1}{n_1} + \frac{1}{n_2} \right) \boldsymbol{\Sigma} \right)$$

Além disso, sabemos que

$$(n_1 - 1)\mathbf{S}_1 \sim W_p(n_1 - 1, \boldsymbol{\Sigma}) \quad \text{e} \quad (n_2 - 1)\mathbf{S}_2 \sim W_p(n_2 - 1, \boldsymbol{\Sigma}),$$

e como as amostras são independentes, as matrizes $\mathbf{S}_1$ e $\mathbf{S}_2$ também são independentes.

Assim, temos

$$\mathbf{S}_{\text{comb.}} = \frac{(n_1 - 1)\mathbf{S}_1 + (n_2 - 1)\mathbf{S}_2}{n_1 + n_2 - 2} \sim \frac{1}{n_1 + n_2 - 2} W_p(n_1 + n_2 - 2, \boldsymbol{\Sigma})$$

Portanto,

Resultado 6.1

$$T^2 = \left(\frac{1}{n_1} + \frac{1}{n_2} \right)^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \right)^\top \mathbf{S}_{\text{comb.}}^{-1} \left(\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2 - (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \right)$$

segue uma distribuição T^2 de Hotelling tal que

$$\frac{p(n_1 + n_2 - 2)}{n_1 + n_2 - p - 1} F_{p, n_1 + n_2 - p - 1}.$$

Isso é verdade, pois escrevemos T^2 da seguinte maneira

$$T^2 = \text{Normal}_p(\mathbf{0}_p, \boldsymbol{\Sigma})^\top \left(\frac{\text{Wishart}_p(n_1 + n_2 - 2), \boldsymbol{\Sigma}}{n_1 + n_2 - 2} \right)^{-1} \text{Normal}_p(\mathbf{0}_p, \boldsymbol{\Sigma})$$

■

Para testar a hipótese de *paralelismo*, podemos reescrever a hipótese nula postulada anteriormente,

$$H_{01} : \mu_{1,i} - \mu_{1,i-1} = \mu_{2,i} - \mu_{2,i-1}, \quad i = 1, 2, \dots, p,$$

da seguinte maneira

$$H_{01} : \mathbf{C}\boldsymbol{\mu}_1 = \mathbf{C}\boldsymbol{\mu}_2 \Leftrightarrow H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p,$$

em que $\mathbf{C} \in M_{p \times p}(\mathbb{R})$ é tal que

$$\mathbf{C} = \begin{bmatrix} -1 & 1 & 0 & \cdots & 0 & 0 \\ 0 & -1 & 1 & \cdots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -1 & 1 \end{bmatrix}.$$

Sob $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p$, sabemos pelo Resultado 6.1 que

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)^\top \mathbf{C}^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{C} \mathbf{S}_{\text{comb.}} \mathbf{C}^\top \right]^{-1} \mathbf{C} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)$$

possui distribuição $\frac{(n_1+n_2-2)(p-1)}{n_1+n_2-p} F_{p-1, n_1+n_2-p}$.

Logo, fixado um nível de significância $\alpha \in (0, 1)$, rejeitamos $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p$ (isto é, perfis paralelos) quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e t_c^2 é o valor crítico tal que

$$t_c^2 = \frac{(n_1 + n_2 - 2)(p - 1)}{n_1 + n_2 - p} f_c$$

sendo $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p-1, n_1+n_2-p}$.

Quando os perfis são paralelos, podemos ter $\mu_{1i} > \mu_{2i}$ ou $\mu_{1i} < \mu_{2i}$ qualquer que seja o tratamento i . Dessa forma, uma vez paralelos, os perfis serão *coincidentes* quando $\mu_{1i} - \mu_{2i} = 0$ para todo i . Logo, podemos reescrever a hipótese de *coincidência* postulada outrora, $H_{02} : \mu_{1i} = \mu_{2i}$, $i = 1, 2, \dots, p$, da seguinte maneira

$$H_{02} : (\mu_{11} - \mu_{21}) + \dots + (\mu_{1p} - \mu_{2p}) = 0 \Leftrightarrow H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p.$$

Sob $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p$, sabemos do Resultado 6.1, que

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)^\top \mathbf{1} \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{1}^\top \mathbf{S}_{\text{pooled}} \mathbf{1} \right]^{-1} \mathbf{1}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2) \sim F_{1, n_1+n_2-2}$$

Logo, fixado um nível de significância $\alpha \in (0, 1)$, rejeitamos $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_p$ (isto é, perfis coincidentes) quando $t^2 > f_c$, em que t^2 é o valor observado da estatística T^2 e f_c é o valor crítico tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{1, n_1+n_2-2}$.

Para grupos com perfis coincidentes, podemos nos perguntar se $\mathbf{x}_{11}, \mathbf{x}_{12}, \dots, \mathbf{x}_{1n_1}$ e $\mathbf{x}_{21}, \mathbf{x}_{22}, \dots, \mathbf{x}_{2n_2}$ foram coletados de uma população normal p -variada com o mesmo vetor de médias (nesse caso, a população seria a mesma em termos de distribuição, já que ambos os grupos possuem, por hipótese, a mesma matriz de variâncias e covariâncias), i.e., se os dois grupos possuem perfis que coincidem em um mesmo *nível*.

Quando H_{01} e H_{02} são plausíveis, a hipótese $H_{03} : \mu_{11} = \mu_{12} = \dots = \mu_{1p} = \mu_{21} = \dots = \mu_{2p}$ pode ser reescrita da seguinte maneira

$$H_{03} : \mu_1 = \mu_2 = \dots = \mu_p \Leftrightarrow H_{03} : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_p,$$

em que $\boldsymbol{\mu} = [\mu_1 \ \dots \ \mu_p]^\top$ e $\mathbf{C} \in M_{p \times p}(\mathbb{R})$ tal que

$$\mathbf{C} = \begin{bmatrix} -1 & 1 & 0 & \dots & 0 & 0 \\ 0 & -1 & 1 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & \dots & -1 & 1 \end{bmatrix}.$$

Sob $H_{03} : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_p$,

$$T^2 = (n_1 + n_2) \bar{\mathbf{X}} \mathbf{C}^\top [\mathbf{C} \mathbf{S} \mathbf{C}^\top]^{-1} \mathbf{C} \bar{\mathbf{X}} \sim \frac{(n_1 + n_2 - 1)(p - 1)}{n_1 + n_2 - p + 1} F_{p-1, n_1+n_2-p+1}$$

Logo, fixado um nível de significância $\alpha \in (0, 1)$, rejeitamos $H_{03} : \mathbf{C}\boldsymbol{\mu} = \mathbf{0}_p$ (isto é, perfis coincidentes com mesmo nível) quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e t_c^2 é o valor crítico tal que

$$t_c^2 = \frac{(n_1 + n_2 - 1)(p - 1)}{n_1 + n_2 - p + 1} f_c$$

sendo $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{p-1, n_1+n_2-p+1}$.

Exemplo 6.6: Johnson e Wichern, 2014, p. 325, tradução e grifo nosso

Como parte de um estudo mais amplo sobre amor e casamento, a socióloga E. Hatfield entrevistou adultos a respeito de suas “contribuições” e “resultados” no casamento, bem como de seus níveis de amor “passional” e “companheiro”. Homens e mulheres recém-casados foram convidados a responder às seguintes questões, utilizando a escala de 8 pontos ilustrada a seguir:

Extremamente negativa	1
Muito negativa	2
Moderadamente negativa	3
Ligeiramente negativa	4
Ligeiramente positiva	4
Moderadamente positiva	6
Muito positiva	7
Extremamente positiva	8

1. Considerando tudo, como você descreveria *suas contribuições* para o casamento?
2. Considerando tudo, como você descreveria *seus resultados* obtidos do casamento?

Os participantes também responderam às seguintes questões, utilizando a escala de 5 pontos exibida abaixo:

3. Qual é o nível de amor *passional* que você sente pelo(a) seu(ua) parceiro(a)?
4. Qual é o nível de amor *companheiro* que você sente pelo(a) seu(ua) parceiro(a)?

Nenhum	Muito pouco	Algum	Considerável	Enorme
1	2	3	4	5

Exemplo 6.6

- (a) Construa o gráfico de perfis e interprete-o.
- (b) Fixado um nível de significância $\alpha = 5\%$, conduza uma análise de perfis.

SOLUÇÃO:

- (a) Com base no gráfico de perfis, temos um indicativo de que os perfis são coincidentes. Observamos ligeiras diferenças entre as respostas médias às questões. O quão significativa são esses desvios é o que testamos no próximo item.




Figura 6.4. Perfis das repostas dos homens e das mulheres recém-casados.

- (b) (i) *Paralelismo.*

- **Hipóteses:**

- $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_4$ (os perfis são paralelos);
- $H_{11} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \neq \mathbf{0}_4$ (os perfis não são paralelos).

- **Estatística de teste:** Sob $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_4$,

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)^\top \mathbf{C}^\top \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{C} \mathbf{S}_{\text{comb.}} \mathbf{C}^\top \right]^{-1} \mathbf{C} (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)$$

possui distribuição $\frac{(n_1+n_2-2)(p-1)}{n_1+n_2-p} F_{p-1, n_1+n_2-p}$, com $n_1 = n_2 = 30$ e $p = 4$.

Exemplo 6.6

- **Regra de decisão:** Fixado um nível de significância $\alpha = 5\%$, rejeitamos $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_4$ (isto é, perfis paralelos) quando $t^2 > t_c^2$, em que t^2 é o valor observado da estatística T^2 e t_c^2 é o valor crítico tal que

$$t_c^2 = \frac{58 \times 3}{56} f_c$$

sendo $f_c \in \mathbb{R}_+$ tal que $\mathbb{P}(F > f_c) = \alpha$, com $F \sim F_{3,56}$.

- **Conclusão:** Observada a amostra, temos $t^2 = 1,005$. Fixado o nível de significância $\alpha = 5\%$, temos $t_c^2 = 8,7$. Como $t^2 < t_c^2$, não rejeitamos a hipótese $H_{01} : \mathbf{C}(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = \mathbf{0}_4$. Em outras palavras, os dados amostrais não fornecem evidências suficientes para rejeitarmos a hipótese de que os perfis médios de resposta de homens e mulheres sejam paralelos. Essa conclusão é consistente com a análise que fizemos da Figura 6.4.

(ii) *Coincidência.*

- **Hipóteses:**
 - $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 0$ (os perfis são coincidentes);
 - $H_{12} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) \neq 0$ (os perfis não são coincidentes).
- **Estatística de teste:** Sob $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 0_p$,

$$T^2 = (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)^\top \mathbf{1} \left[\left(\frac{1}{n_1} + \frac{1}{n_2} \right) \mathbf{1}^\top \mathbf{S}_{\text{pooled}} \mathbf{1} \right]^{-1} \mathbf{1}^\top (\bar{\mathbf{X}}_1 - \bar{\mathbf{X}}_2)$$

possui distribuição F_{1,n_1+n_2-2} , em que $n_1 = n_2 = 30$ e $p = 4$.

- **Regra de decisão:** Fixado um nível de significância $\alpha = 5\%$, rejeitamos $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 0_p$ (isto é, perfis coincidentes) quando $t^2 > f_c$, em que t^2 é o valor observado da estatística T^2 e f_c é o valor crítico tal que $\mathbb{P}(F > f_c) = \alpha$, sendo $F \sim F_{1,58}$.
- **Conclusão:** Observada a amostra, temos $t^2 = 0,501$. Fixado o nível de significância $\alpha = 5\%$, temos $t_c^2 = 4$. Como $t^2 < t_c^2$, não rejeitamos a hipótese $H_{02} : \mathbf{1}^\top (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2) = 0$. Em outras palavras, os dados amostrais não fornecem evidências suficientes para rejeitarmos a hipótese de que os perfis médios de resposta de homens e mulheres sejam coincidentes. Essa conclusão também é consistente com a análise que fizemos da Figura 6.4.

Exemplo 6.6

Poderíamos agora testar se os perfis são nivelados; no entanto, este teste não faz sentido no nosso exemplo, uma vez que as Questões 1 e 2 foram medidas em uma escala de 1 a 8, enquanto as Questões 3 e 4 foram medidas em uma escala de 1 a 5. A incompatibilidade dessas escalas torna o teste para perfis nivelados sem significado e ilustra a necessidade de medições semelhantes para que uma análise completa de perfis possa ser realizada.

Quando os tamanhos amostrais são pequenos, a análise de perfis dependerá da suposição de normalidade. Essa suposição pode ser verificada usando os métodos discutidos no Capítulo 5, com as observações originais $\mathbf{x}_{\ell j}$ ou com as observações transformadas por contraste $\mathbf{C}\mathbf{x}_{\ell j}$. A análise de perfis para várias populações segue, em grande parte, o mesmo raciocínio que no caso de duas populações.

6.5 Exercícios

1. Um laboratório de fisiologia deseja comparar a eficácia de *duas técnicas de relaxamento* na recuperação cardiovascular. Os mesmos $n = 10$ voluntários saudáveis aplicaram, em dias distintos e ordem randomizada cada uma das técnicas:

- *Meditação guiada* (Tratamento A);
- *Exercícios de respiração diafragmática* (Tratamento B).

Em cada dia o participante executou *o mesmo protocolo de esforço submáximo em bicicleta ergométrica*. Logo após o exercício, aplicou-se a técnica correspondente e registraram-se três medidas fisiológicas:

- frequência cardíaca (FC, batimentos/min);
- pressão arterial sistólica (PAS, mmHg);
- nível de estresse percebido (Escala 0-100).

No dia do tratamento A , para o j -ésimo voluntário, obtiveram-se as seguintes medidas x_{Aj1} (FC), x_{Aj2} (PAS) e x_{Aj3} (escala). No dia do tratamento B , para o j -ésimo voluntário, obtiveram-se x_{Bj1} (FC), x_{Bj2} (PAS) e x_{Bj3} (escala). As mesmas variáveis foram medidas no mesmo paciente, na mesma ordem.

Participante	x_{Aj1}	x_{Aj2}	x_{Aj3}	x_{Bj1}	x_{Bj2}	x_{Bj3}
j	Meditação guiada (A)			Respiração diafragmática (B)		
1	78	122	55	76	118	45
2	82	125	57	78	120	47
3	76	118	53	73	115	44
4	75	117	52	72	114	43
5	80	124	56	77	119	46
6	77	120	54	75	117	45
7	83	128	58	80	124	48
8	79	123	55	76	118	46
9	81	126	57	78	121	47
10	78	121	54	75	116	45

- (a) Fixado um nível de significância $\alpha = 10\%$, verifique se os tratamentos apresentam, em média, uma diferença significativa para pelo menos uma das medidas fisiológicas consideradas. Defina as hipóteses (estatísticas e científicas), a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e a conclusão (estatística e em termos do problema).
- (b) Construa os t -intervalos, T^2 -intervalos e intervalos de Bonferroni com nível de confiança global de 90%. Esses intervalos são consistentes para sua resposta do item (a). Por quê?
- (c) Explicar, de modo acessível, por que a abordagem de medidas repetidas (mesmos indivíduos sob A e B) tende a oferecer maior potência estatística que comparar dois grupos independentes.
- (d) Quais as consequências dos resultados obtidos nos itens (a) e (b)? Como eles impactam a pesquisa do laboratório? Que decisões o laboratório pode tomar com base nesses resultados?
- (e) Para cada participante calcule o vetor de diferenças $\mathbf{d}_j = [d_{1j} \ d_{2j} \ d_{3j}]^T$ com $d_{1j} = x_{Aj1} - x_{Bj1}$, $d_{2j} = x_{Aj2} - x_{Bj2}$, $d_{3j} = x_{Aj3} - x_{Bj3}$. Avalie a plausibilidade da normalidade multivariada para $\mathbf{d}_j$ usando inspeção gráfica e o teste de Mardia. Comente as consequências caso a suposição não seja atendida.
2. Pesquisadores em psicologia cognitiva desejam comparar duas *estratégias de estudo* quanto à recuperação de informações. Os **mesmos** $n = 10$ estudantes realizaram *duas sessões* de estudo-teste, com uma semana de intervalo. Na primeira sessão, usaram *flashcards* (Tratamento A) e, na segunda, *spaced repetition* (Tratamento B). Em cada sessão registraram-se **duas variáveis** imediatamente após o teste de 40 termos técnicos:

- proporção de termos corretamente lembrados (em porcentagem);
- tempo médio de recordação por termo (em segundos).

No sessão do tratamento A , para o j -ésimo estudante, obtiveram-se as seguintes medidas x_{Aj1} (%) e x_{Aj2} (tempo). Na sessão do tratamento B , para o j -ésimo estudante, obtiveram-se x_{Bj1} (%) e x_{Bj2} (tempo). As mesmas variáveis foram medidas no mesmo estudante, na mesma ordem. Suponha que a hipótese de normalidade multivariada seja plausível.

- Fixado um nível de significância $\alpha = 5\%$, verifique se os tratamentos apresentam, em média, uma diferença significativa para pelo menos uma das variáveis consideradas. Defina as hipóteses (estatísticas e científicas), a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e a conclusão (estatística e em termos do problema).
- Construa os t -intervalos, T^2 -intervalos e intervalos de Bonferroni com nível de confiança global de 95%. Esses intervalos são consistentes para sua resposta do item (a). Por quê?
- Quais as consequências dos resultados obtidos nos itens (a) e (b)? Como eles impactam a pesquisa dos psicólogos?

Participante	x_{Aj1}	x_{Aj2}	x_{Bj1}	x_{Bj2}
j	Flashcards (A)		Spaced repetition (B)	
1	91	6.2	96	4.8
2	88	6.5	94	5.0
3	90	6.3	95	4.9
4	92	6.1	97	4.7
5	89	6.6	94	4.9
6	87	6.7	93	5.1
7	93	6.0	97	4.7
8	90	6.4	95	4.8
9	91	6.2	96	4.8
10	88	6.5	94	5.0

- (Johnson e Wichern, 2014, p. 280, tradução e grifo nosso) Um pesquisador analisou três índices que mensuram a severidade de ataques cardíacos. Os valores desses índices, obtidos para $n = 40$ pacientes que chegaram ao pronto-socorro de um hospital, geraram o seguinte resumo estatístico

$$\bar{\mathbf{x}} = \begin{bmatrix} 46.1 \\ 57.3 \\ 50.4 \end{bmatrix}, \quad \mathbf{S} = \begin{bmatrix} 101.3 & 63.0 & 71.0 \\ 63.0 & 80.2 & 55.6 \\ 71.0 & 55.6 & 97.4 \end{bmatrix}.$$

Suponha que a hipótese de normalidade seja plausível.

- (a) Os três índices foram avaliados para cada paciente. Verificar a igualdade das médias populacionais dos índices com nível de significância $\alpha = 5\%$. Defina as hipóteses (estatísticas e científicas), a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e a conclusão (estatística e em termos do problema).
- (b) Avaliar as diferenças, par a par, entre as médias dos índices utilizando intervalos de confiança simultâneos (T^2 -intervalos) com nível de confiança global de 95%.
4. **(Johnson e Wichern, 2014, p. 342, tradução e grifo nosso)** Os dados da tabela anterior foram coletados para investigar dois modelos psicológicos de cognição numérica. A questão central é saber se o processamento de números depende da forma de apresentação dos estímulos (palavras ou dígitos arábicos). Trinta e dois voluntários fizeram julgamentos numéricos rápidos envolvendo dois números exibidos como palavras (“dois”, “quatro”) ou como dígitos (“2”, “4”). Devia-se responder “*mesmo*” quando os dois números tinham a mesma paridade (ambos pares ou ambos ímpares) e “*diferente*” quando possuíam paridades distintas. Metade dos participantes realizou primeiro um bloco de tentativas com dígitos, seguido por um bloco com palavras, e a outra metade fez a ordem inversa. Dentro de cada bloco, a sequência de tentativas “*mesmo*” e “*diferente*” foi aleatorizada para cada sujeito. Para cada uma das quatro combinações de *formato* e *paridade*, registrou-se o *tempo de reação mediano* (em milissegundos) das respostas corretas.

X_1 = tempo de reação mediano para *palavra* – paridades diferentes

X_2 = tempo de reação mediano para *palavra* – paridades iguais

X_3 = tempo de reação mediano para *dígito arábico* – paridades diferentes

X_4 = tempo de reação mediano para *dígito arábico* – paridades iguais

WordDiff (x_1)	WordSame (x_2)	ArabicDiff (x_3)	ArabicSame (x_4)
869.0	860.5	691.0	601.0
995.0	875.0	678.0	659.0
1056.0	930.5	833.0	826.0
1126.0	954.0	888.0	728.0
1044.0	909.0	865.0	839.0
925.0	856.5	1059.5	797.0
1172.5	896.5	926.0	766.0
1408.5	1311.0	854.0	986.0
1028.0	887.0	915.0	735.0
1011.0	863.0	761.0	657.0
726.0	674.0	663.0	583.0
982.0	894.0	831.0	640.0
1225.0	1179.0	1037.0	905.5
731.0	662.0	662.5	624.0
975.5	872.5	814.0	735.0
1130.5	811.0	843.0	657.0
945.0	909.0	867.5	754.0
747.0	752.5	777.0	687.5
656.5	659.5	572.0	539.0
919.0	833.0	752.0	611.0
751.0	744.0	683.0	553.0
774.0	735.0	671.0	612.0
941.0	931.0	901.5	700.0
751.0	785.0	789.0	735.0
767.0	737.5	724.0	639.0
813.5	750.5	711.0	625.0
1289.5	1140.0	904.5	784.5
1096.5	1009.0	1076.0	983.0
1083.0	958.0	918.0	746.5
1114.0	1046.0	1081.0	796.0
708.0	669.0	657.0	572.5
1201.0	925.0	1004.5	673.5

- (a) Fixado um nível de significância $\alpha = 10\%$, verifique se pelo menos um dos tratamentos (formato numérico e paridade) ou a interação entre eles apresentaram um efeito significativo sobre o tempo de reação mediano esperado. Defina as hipóteses (estatísticas e científicas), a estatística de teste, a distribuição da estatística de teste sob a hipótese nula, a regra de decisão e a conclusão (estatística e em termos do problema).
- (b) Construir intervalos com nível de confiança global de 90% para os contrastes que representam (i) o efeito do formato numérico, (ii) o efeito do tipo de paridade e (iii) a interação formato x paridade. Interpretar cada intervalo obtido.
- (c) Qual tipo de intervalo você escolheu para o item (b)? t -intervalos, T^2 -intervalos ou intervalos de Bonferroni? Por quê?
- (d) A ausência de interação sustenta o modelo M de cognição numérica, enquanto a presença de interação sustenta o modelo $C \& C$. Qual desses modelos é apoiado pelos resultados deste experimento?
- (e) Avalie a plausibilidade da normalidade multivariada para $\mathbf{X}_j = [X_{j1} \ \cdots \ X_{j4}]^T$ usando inspeção gráfica e o teste de Mardia. Comente as consequências caso a suposição não seja atendida.
5. Um pesquisador deseja investigar se diferentes programas de treinamento físico produzem efeitos distintos sobre variáveis fisiológicas de atletas universitários. Quarenta e cinco estudantes foram divididos aleatoriamente em três grupos:
- Grupo A: Treinamento de resistência ($n_A = 15$);
 - Grupo B: Treinamento de força ($n_B = 15$);
 - Grupo C: Treinamento funcional ($n_C = 15$).

Ao final de 8 semanas, foram coletadas as seguintes medidas em cada atleta:

- X_1 : VO2 máximo (ml/kg/min);
- X_2 : Frequência cardíaca em repouso (bpm);
- X_3 : Percentual de gordura corporal (%).

Os dados estão em anexo no arquivo `dadosEx5.csv`.

- (a) Fixado um nível de significância $\alpha = 10\%$, realize uma análise de variância multivariada (MANOVA) para avaliar se há evidências de que os programas de treinamento produzem efeitos diferentes sobre as três variáveis conjuntamente.

- (b) Caso a MANOVA aponte efeito significativo, conduza análises univariadas (gráficos e testes) e interprete os resultados. Diga quais suposições sobre o erro α do tipo *I* foram realizadas para conduzir as análises univariadas de maneira consistente.
 - (c) Discuta se os resultados univariados são coerentes com o resultado multivariado.
6. Três métodos de ensino foram testados em 60 alunos do terceiro ano do Ensino Médio, com o objetivo de melhorar o desempenho em três áreas cognitivas:
- Método 1: Ensino tradicional ($n = 20$);
 - Método 2: Sala de aula invertida ($n = 20$);
 - Método 3: Ensino baseado em projetos ($n = 20$).

Ao final do semestre, os alunos realizaram três provas padronizadas:

- X_1 : Raciocínio lógico (nota de 0 a 100);
- X_2 : Leitura crítica (nota de 0 a 100);
- X_3 : Resolução de problemas (nota de 0 a 100).

Os dados estão em anexo no arquivo `dadosEx6.csv`.

- (a) Verifique, por meio da MANOVA, se o método de ensino influencia simultaneamente as três dimensões avaliadas.
 - (b) Caso a MANOVA aponte efeito significativo, conduza análises univariadas (gráficos e testes) e interprete os resultados. Diga quais suposições sobre o erro α do tipo *I* foram realizadas para conduzir as análises univariadas de maneira consistente.
 - (c) Discuta se os resultados univariados são coerentes com o resultado multivariado.
7. Uma equipe de nutricionistas quer comparar o efeito de duas dietas populares – Dieta A (low carb) e Dieta B (mediterrânea) – sobre o perfil nutricional diário de seus praticantes. Após quatro semanas de adesão, foi medida a ingestão média (em gramas) de três macronutrientes por dia para cada indivíduo:
- X_1 : Proteínas;
 - X_2 : Carboidratos;
 - X_3 : Lipídios.

Cada dieta foi adotada por 10 participantes distintos (grupos independentes). Os dados estão em anexo no arquivo `dadosEx7.csv`.

(a) Realize a análise de perfil comparando os dois grupos. Para isso, você deve testar

- se os perfis são paralelos;
- se os perfis coincidem;
- se os perfis estão no mesmo nível.

(b) Interprete graficamente os perfis e discuta.

Dica: perfis paralelos sugerem que a proporção entre os macronutrientes é semelhante entre as dietas, enquanto perfis coincidentes implicam perfis nutricionais idênticos. Perfis no mesmo nível exigem cuidado conceitual neste caso – faz sentido perguntar se o consumo total é igual se os formatos forem diferentes?

8. Um instituto de ensino superior deseja investigar se os perfis de desempenho são semelhantes entre estudantes de dois cursos: Engenharia e Administração. Foram selecionados 12 estudantes de cada curso (grupos independentes), e os seguintes escores padronizados (média 100, desvio 15) foram coletados em três dimensões cognitivas:

- X_1 : Raciocínio lógico;
- X_2 : Capacidade verbal;
- X_3 : Tomada de decisão.

Os dados estão em anexo no arquivo `dadosEx8.csv`.

(a) Realize a análise de perfil comparando os dois grupos. Para isso, você deve testar

- se os perfis são paralelos;
- se os perfis coincidem;
- se os perfis estão no mesmo nível.

(b) Interprete graficamente os perfis e discuta.

Dica: um perfil no mesmo nível pode indicar que, mesmo com habilidades distintas, os dois cursos têm desempenho global semelhante.

7 Considerações finais

Este curso de Estatística Multivariada 1 teve como foco principal os fundamentos da inferência estatística multivariada. Ao longo da disciplina, estudamos procedimentos de estimação, construção de intervalos de confiança, testes de hipóteses e regiões de confiança para vetores de médias e outras quantidades de interesse em contextos com múltiplas variáveis.

As técnicas abordadas são essencialmente fundamentadas na hipótese de que os dados seguem uma distribuição normal multivariada. Essa suposição é central para a validade das distribuições utilizadas nos testes (como a estatística T^2 de Hotelling) e nas regiões de confiança elípticas. No entanto, discutimos que, assim como ocorre em outras áreas da inferência estatística, essa hipótese pode ser relaxada quando trabalhamos com grandes amostras, em virtude de resultados assintóticos. No contexto multivariado, considera-se uma amostra grande aquela em que o tamanho amostral n é substancialmente maior que o número de variáveis p , idealmente $n \geq 5p$ ou $n \geq 10p$, dependendo da robustez dos métodos aplicados. No entanto, quando não tivermos disponível uma amostra suficientemente grande que nos permita utilizar o teorema central do limite multivariado, podemos considerar métodos não-paramétricos multivariados. Outra suposição adotada implicitamente ao longo do curso foi a independência entre as unidades amostrais ou experimentais. Essa suposição é bastante razoável na maioria dos estudos observacionais ou experimentais, mas pode falhar em situações em que os dados são coletados ao longo do tempo, ou seja, em presença de fenômenos dinâmicos. Nesses casos, dependências temporais entre observações invalidam muitos dos testes e regiões clássicas. Para contornar tais dificuldades, o pesquisador pode recorrer aos métodos de séries temporais multivariadas, que não exigem independência entre as observações e são apropriados para modelar dependência temporal ou espacial. Por isso, é fundamental destacar a sensibilidade que o pesquisador deve ter ao interpretar o problema em estudo, a fim de selecionar uma metodologia que respeite as características do fenômeno observado. A escolha de técnicas estatísticas não deve ser mecânica, mas orientada por um bom entendimento do contexto e das premissas envolvidas.

Adicionalmente, um ponto-chave do curso foi mostrar que, ao analisarmos simultaneamente várias variáveis, não devemos simplesmente aplicar testes ou construir intervalos de confiança univariados de forma independente. Esse tipo de abordagem ignora as dependências entre as variáveis e compromete o controle do nível de significância global, resultando em um aumento da probabilidade de cometer erros do tipo I. Em outras palavras, o uso de múltiplos testes univariados distorce a confiança conjunta desejada. Além disso, quando realizamos vários testes ou intervalos univariados sem correção, não apenas inflamos a taxa de erro tipo I, como também podemos afetar adversamente o poder

dos testes, especialmente ao tentarmos ajustar excessivamente para manter o nível global sob controle. Em outras palavras, quanto mais testes realizamos, maior a chance de não detectar efeitos reais (erro tipo II), a menos que medidas apropriadas sejam adotadas. No entanto, é importante reconhecer que, em contextos práticos, o pesquisador ou cliente geralmente está interessado em identificar quais componentes específicos contribuíram para a rejeição da hipótese conjunta. Nesse cenário, testes e intervalos de confiança univariados são bem-vindos e necessários, desde que sejam construídos de maneira que respeitem a confiança global desejada. Para isso, métodos de correção múltipla, como o ajuste de Bonferroni, oferecem uma solução prática. Esse método ajusta o nível de significância de cada teste individual de forma que a probabilidade conjunta de erro seja controlada, mantendo assim um equilíbrio entre precisão e confiança. Dessa forma, conseguimos interpretar individualmente os componentes do vetor de médias, sem comprometer a validade da inferência multivariada.

Portanto, acredito que este curso tenha oferecido uma boa introdução à inferência multivariada clássica, buscando equilibrar a apresentação das técnicas com a valorização de uma postura crítica diante de suas hipóteses e limitações. Espero que estas notas de aula tenham sido úteis em sua trajetória de aprendizado e que o conteúdo aqui discutido possa servir de ponto de partida para estudos mais aprofundados e aplicações práticas em diferentes áreas da Estatística.

Referência Bibliográfica

Johnson, Richard Arnold, and Dean W. Wichern “Applied multivariate statistical analysis.”, 2014.

