


Ricardo Felipe Ferreira

TEORIA DE MATRIZES PARA ESTATÍSTICA



1	Vetores	1
1.1	O espaço Euclidiano	1
1.2	O espaço dos vetores	8
1.3	O espaço das coordenadas	13
1.4	Algumas propriedades básicas de vetores	16
1.4.1	O espaço vetorial $\mathbb{R}^n$	17
1.4.2	Produto interno, norma e ângulo entre vetores	24
1.4.3	Distância e projeção ortogonal entre vetores	35
1.5	Aspectos geométricos de uma amostra por meio de conceitos de vetores	42
1.5.1	O vetor de médias amostrais e a projeção ortogonal	43
1.5.2	O vetor de desvios	49
1.5.3	Variância amostral e a norma dos vetores de desvios	55
1.5.4	Covariância amostral e o produto interno entre vetores de desvios	61
1.5.5	Correlação amostral e o cosseno do ângulo entre vetores de desvios	67
1.6	Distâncias entre vetores e a Estatística	73
1.6.1	O método do vizinho mais próximo	73
1.6.2	Detecção de <i>outliers</i>	85
1.7	Dependência e independência linear	94
1.8	Projeção ortogonal, o métodos dos mínimos quadrados e a regressão linear simples	106
1.9	Exercícios	114
2	Matrizes	127
2.1	A história por trás da Álgebra Matricial	127
2.2	Matrizes como um objeto para organizar dados	128
2.3	Formalização matemática da noção de matriz	133
2.4	Matriz como fruto de uma transformação linear	139
2.5	Matrizes especiais	148
2.6	Igualdade de matrizes e igualdade de transformações lineares	154
2.7	$M_{n \times p}(\mathbb{R})$ e $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ como espaços vetoriais isomorfos	156
2.8	Produto de matrizes e a composição de transformações lineares	170
2.9	A transposta e a decomposição de uma matriz em sua parte simétrica e anti-simétrica	181
2.10	Matrizes invisíveis e a bijetividade de transformações lineares	189
2.10.1	Transformações lineares injetivas	189
2.10.2	Núcleo de uma transformação linear	191
2.10.3	Transformações lineares sobrejetivas	195
2.10.4	Transformações lineares bijetivas	196
2.10.5	Posto de uma matriz	198
2.10.6	Matrizes inversíveis	199
2.11	Determinantes	205
2.12	Traço	217
2.13	Aspectos geométricos de uma amostra por meio do conceito de matrizes	220
2.14	Exercícios	235



3	Formas lineares e quadráticas	251
3.1	Definições e primeiros exemplos	251
3.2	Matrizes definidas positivas, definidas negativas, semidefinidas positivas e semidefinidas negativas	258
3.3	Derivadas de formas lineares e quadráticas	264
3.4	Aplicação das derivadas de formas lineares e quadráticas em regressão linear múltipla	267
3.5	Exercícios	270
4	Decomposição de matrizes	273
4.1	Autovalores e autovetores	273
4.2	Decomposição espectral	285
4.3	Decomposição em valores singulares	292
4.4	Exercícios	300
5	Considerações finais	303

“Costuma-se dizer que o tempo tem apenas uma dimensão e o espaço, três. Mas também se diz que o espaço é infinito e o tempo, eterno. Por que não imaginar, então, que o espaço também seja eterno e o tempo, infinito?”

William Rowan Hamilton (1805 – 1865)

Na Estatística, muitos conceitos, como a saúde de uma pessoa, suas habilidades intelectuais ou mesmo sua personalidade, não podem ser adequadamente descritos por um único número. Em situações como essas, é necessário recorrer a diversas medidas simultaneamente, organizadas de forma a capturar diferentes dimensões do fenômeno em estudo. Essa necessidade de reunir diversas medidas em um único objeto matemático nos conduz à noção de vetor. Neste capítulo, retomaremos o conceito de vetores sob a ótica geométrica, inicialmente compreendidos como segmentos orientados, independentes de qualquer sistema de coordenadas. Em seguida, veremos como a introdução de um sistema de referência nos permite representá-los por coordenadas em $\mathbb{R}^n$, facilitando o estudo de suas propriedades algébricas e geométricas.

1.1 O espaço Euclidiano

Há mais de dois mil anos, Euclides sistematizou o conhecimento geométrico de sua época na obra *Os Elementos*, onde figuras, linhas e segmentos eram os principais objetos de estudo. Naquela geometria clássica, os segmentos serviam para representar distâncias e relações de proporção, ainda sem a linguagem de coordenadas. Nesta seção, retomaremos esse espírito inicial para construir a primeira noção de vetor, tal como ensinaria a escola Euclidiana: como segmentos orientados, independentes de qualquer sistema de referência. Caro e gentil leitor, prepare-se para caminhar ao lado de Euclides nessa aventura.

Para iniciar nossa jornada ao lado de Euclides, o leitor deve se recordar de que sua geometria tratava apenas do espaço tridimensional, aquele em que vivemos e percebemos diretamente. A noção de espaços com mais de três dimensões, bem como a ideia de infinito, surgiria somente séculos depois, com matemáticos como René Descartes e Bernhard Riemann. Assim, neste primeiro momento, seguiremos a filosofia clássica de Euclides, apresentando os espaços E^3 , E^2 e E^1 . Para aceitá-los plenamente, é necessário estar de acordo com os postulados que Euclides estabeleceu em sua obra *Os Elementos*, os quais serviram de alicerce para toda a geometria por mais de dois milênios.

O espaço Euclidiano E^3 é o espaço tridimensional que segue as regras estabelecidas por Euclides. Nele podem ser definidos sólidos (tais como o cubo e a esfera), figuras planas (tais como o quadrado e o triângulo), além de pontos e retas. Por outro lado, o espaço Euclidiano E^2 corresponde ao plano bidimensional, onde se encontram as figuras geométricas planas, como quadrados, retângulos e círculos, bem como pontos e retas que neles se apoiam. Já o espaço Euclidiano E^1 é unidimensional, representado por uma única reta, na qual podem ser definidos apenas pontos e segmentos de reta.

Antes de prosseguirmos, vamos estabelecer algumas notações que utilizaremos ao longo do texto. Os pontos de um espaço Euclidiano serão representados por letras latinas maiúsculas, como A , B , P ou Q , as retas serão indicadas por letras latinas minúsculas, como r , s ou t e, por fim, os planos serão designados por letras gregas minúsculas, como π , α ou β . Essas convenções serão mantidas para garantir clareza e uniformidade na apresentação dos conceitos.

Grandezas *escalares* são aquelas que podem ser descritas apenas por um número real, eventualmente acompanhado de uma unidade de medida, como ocorre com a área, o comprimento ou a massa. No entanto, muitas situações físicas e geométricas não podem ser caracterizadas por um único valor numérico. A intensidade de uma força ou de uma velocidade, por exemplo, só faz sentido quando conhecemos também sua direção e seu sentido. Grandezas desse tipo são chamadas de *vetoriais* e, para representá-las, recorreremos a segmentos orientados, que oferecem uma forma intuitiva de reunir intensidade, direção e sentido em um único objeto geométrico.

Definição 1.1: Segmento orientado

Um segmento AB é dito *orientado* quando distinguimos os pontos que o determinam, atribuindo a A o papel de *origem* e a B o de *extremidade*. Nesse caso, a notação utilizada é $\overrightarrow{AB}$.

Geometricamente, um segmento orientado $\overrightarrow{AB}$ é representado por uma *seta* que parte do ponto A , denominado origem, e aponta para o ponto B , denominado extremidade. O comprimento da seta indica o tamanho do segmento orientado, a reta suporte determina sua direção e a ponta da seta define o seu sentido. Assim, cada segmento orientado pode ser visto como um objeto geométrico que reúne, de forma intuitiva, as noções de intensidade, direção e sentido. Na Figura 1.1, apresentamos a representação geométrica de dois segmentos orientados com mesma direção e mesma intensidade, porém com sentidos opostos: $\overrightarrow{AB}$ e $\overrightarrow{BA}$.



Figura 1.1. Representação geométrica dos segmentos orientados.

Os segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem a *mesma direção* quando a reta suporte de $\overrightarrow{AB}$ (digamos a reta r) e a reta suporte de $\overrightarrow{CD}$ (digamos a reta s) são coincidentes ($r = s$) ou paralelas ($r // s$).




Figura 1.2. Segmentos orientados com mesma direção.

Os segmentos orientados $\overrightarrow{AB}$ (com reta suporte r) e $\overrightarrow{CD}$ (com reta suporte s) possuem o *mesmo sentido* quando $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem a mesma direção e

- se r e s são distintas, devemos ter os segmentos AC e BD com intersecção vazia;




Figura 1.3. Segmentos orientados com o mesmo sentido.

- se $r = s$ (as retas suportes coincidem), ao tomarmos o segmento orientado $\overrightarrow{A'B'}$ com reta suporte t paralela a r (porém distintas) e com o mesmo sentido de $\overrightarrow{AB}$, devemos ter $\overrightarrow{A'B'}$ com o mesmo sentido de $\overrightarrow{CD}$.




Figura 1.4. Segmentos orientados com sentidos opostos.

Dados dois pontos A e B , o *comprimento* do segmento orientado $\overrightarrow{AB}$ é a *distância* entre os pontos A e B , i.e., um número real, o qual denotamos por $d(A, B)$, tal que

- (i) $d(A, B) = 0$ quando $A = B$;
- (ii) $d(A, B) > 0$ quando $A \neq B$;
- (iii) $d(A, B) = d(B, A)$;
- (iv) $d(A, C) + d(C, B) = d(A, B)$ se, e somente se, C é um ponto que pertence ao segmento AB .

Assim, dizemos que os segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem o *mesmo comprimento* quando $d(A, B) = d(C, D)$.

As grandezas vetoriais serão representadas por segmentos orientados (veja Figura 1.5). Para que duas dessas grandezas sejam consideradas iguais, será necessário que os segmentos que as representam tenham a mesma direção, o mesmo sentido e o mesmo comprimento. Surge então uma questão natural: se duas grandezas vetoriais são iguais, será que os segmentos orientados que as representam também precisam ser idênticos? A resposta é não. Dois segmentos orientados distintos podem representar a mesma grandeza vetorial, desde que possuam a mesma direção, o mesmo sentido e o mesmo comprimento. Nessa situação, dizemos que esses segmentos são *equivalentes*. Assim, uma grandeza vetorial pode ser representada por qualquer segmento orientado de uma *classe* de segmentos equivalentes, e é exatamente essa classe que chamaremos de *vetor*.




Figura 1.5. Grandezas vetoriais representadas por segmentos orientados.

Definição 1.2: Segmentos orientados equivalentes

Dados os segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$, dizemos que $\overrightarrow{AB}$ é *equivalente* a $\overrightarrow{CD}$ quando

- $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem o mesmo comprimento;
- $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem a mesma direção;
- $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem o mesmo sentido.

Definição 1.3: Vetor

Seja $\overrightarrow{AB}$ um segmento orientado. O conjunto de todos os segmentos orientados equivalentes a $\overrightarrow{AB}$ é denominado *vetor* representado por $\overrightarrow{AB}$.

Se $\overrightarrow{AB}$ é o segmento orientado escolhido como representante do vetor $\vec{u}$ e $\overrightarrow{CD}$ é o segmento orientado escolhido como representante do vetor $\vec{v}$, então podemos estabelecer as seguintes definições:

- Quando $\overrightarrow{AB}$ e $\overrightarrow{CD}$ são *equivalentes*, dizemos que $\vec{u}$ e $\vec{v}$ são *iguais*.
- Quando $\overrightarrow{AB}$ e $\overrightarrow{CD}$ são *paralelos* (isto é, suas retas suporte são coincidentes ou paralelas), dizemos que $\vec{u}$ e $\vec{v}$ são ditos *paralelos*.
- Quando $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem o *mesmo sentido*, dizemos que $\vec{u}$ e $\vec{v}$ são ditos ter o *mesmo sentido*.


- Quando $\overrightarrow{AB}$ e $\overrightarrow{CD}$ possuem o *mesmo comprimento*, isto é, $d(A, B) = d(C, D)$, dizemos que $\vec{u}$ e $\vec{v}$ são ditos ter a *mesma norma (ou módulo)*. Vamos escrever $\|\vec{u}\|$ e $\|\vec{v}\|$ para denotar, respectivamente, a norma do vetor $\vec{u}$ e a norma do vetor $\vec{v}$. No caso em que $\vec{u}$ e $\vec{v}$ possuem a mesma norma (ou módulo), temos $\|\vec{u}\| = d(A, B) = d(C, D) = \|\vec{v}\|$.
- Quando $A = B$, o segmento orientado $\overrightarrow{AB} = \overrightarrow{AA} = \overrightarrow{BB}$ trata-se de um único ponto. Ao conjunto de todos os segmentos orientados dessa natureza, vamos denominar *vetor nulo*, que denotaremos por $\vec{0}$.

Caro leitor, creio que esteja se deleitando com a teoria desenvolvida até aqui. No entanto, é chegado o momento de fazermos uma breve pausa para treinar os conceitos apresentados até o momento.


Exemplo 1.1

Em cada item, grandezas vetoriais físicas são representadas por dois segmentos orientados no espaço Euclidiano E^3 . Os segmentos podem ter diferentes módulos, direções e sentidos. Com base na descrição de cada caso, diga em quais casos as *grandezas físicas são iguais*.

- (a) *Força*: Duas forças são aplicadas sobre um mesmo objeto. As forças são representadas pelos segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$:




- (b) *Velocidade*: Duas velocidades são aplicadas sobre um mesmo objeto. As forças são representadas pelos segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$:




Exemplo 1.1


- (c) *Aceleração*: Duas acelerações são aplicadas sobre um mesmo objeto. As acelerações são representadas pelos segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$:



- (d) *Momento linear*: Dois momentos lineares são aplicados sobre um mesmo objeto. Os momentos lineares são representados pelos segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$:



- (e) *Deslocamento*: Dois deslocamentos são aplicados sobre um mesmo objeto. Os deslocamentos são representados pelos segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{BC}$:

**SOLUÇÃO:**

- (a) Nesse caso, as forças são *iguais*, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ são *segmentos orientados equivalentes* (mesma direção, mesmo sentido e mesmo comprimento).
- (b) Nesse caso, as velocidades são *diferentes*, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ *não* são segmentos orientados equivalentes, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ *não* possuem mesmo sentido.

Exemplo 1.1

- (c) Nesse caso, as acelerações são *diferentes*, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ não são segmentos orientados equivalentes, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ não possuem a mesma direção.
- (d) Nesse caso, os momentos lineares são *diferentes*, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ não são segmentos orientados equivalentes, pois $\overrightarrow{AB}$ e $\overrightarrow{CD}$ não possuem o mesmo comprimento.
- (e) Nesse caso, os deslocamentos são *iguais*, pois $\overrightarrow{AB}$ e $\overrightarrow{BC}$ são *segmentos orientados equivalentes* (mesma direção, mesmo sentido e mesmo comprimento).

1.2 O espaço dos vetores

Todo objeto matemático, uma vez definido, precisa de um lugar (um espaço) para performar sua existência. Esse lugar é o conjunto formado por todos os elementos de sua natureza, um espaço que reúne apenas os seus semelhantes. Dessa forma, vamos definir V^1 como o conjunto de todos os vetores que podem ser representados por segmentos orientados situados numa única reta, i.e., que pertencem ao espaço Euclidiano E^1 . De modo análogo, V^2 é formado por todos os vetores representados por segmentos orientados em um mesmo plano, ou seja, que são elementos do espaço Euclidiano E^2 . Por fim, V^3 é constituído por todos os vetores representados por segmentos orientados no espaço Euclidiano tridimensional E^3 . Os conjuntos V^1 , V^2 e V^3 são, respectivamente, os *espaços dos vetores* de E^1 , E^2 e E^3 .

Para compreender melhor os vetores que habitam os espaços V^1 , V^2 e V^3 , precisamos atribuir a eles um *endereço*. Esse endereço, que chamaremos de *coordenadas*, permite identificar de forma numérica a posição de um vetor dentro de seu espaço. Entretanto, como os vetores foram definidos a partir de segmentos orientados em E^1 , E^2 e E^3 , é natural que o conceito de coordenada surja primeiro para os pontos que determinam tais segmentos. Assim como um ponto em E^i pode ser localizado por meio de suas coordenadas em um sistema de referência, também poderemos localizar o vetor em V^i por meio das coordenadas do segmento orientado que o representa.

Para estabelecer coordenadas em E^1 , fixamos um ponto O (a origem) e escolhemos um eixo orientado. Esse eixo pode ser posto em correspondência biunívoca com o conjunto dos números reais $\mathbb{R}$ da seguinte maneira:

- à origem O fazemos corresponder o número 0;
- a cada ponto X situado à *direita* de O corresponde o número real $x = d(O, X)$

(*positivo*), em que $d(O, X)$ representa a distância entre O e X ;

- a cada ponto X situado à *esquerda* de O corresponde o número real $x = -d(O, X)$ (*negativo*).

Dessa forma, cada ponto P em E^1 é identificado de modo único por um número real x , que chamamos de sua *coordenada*. No plano E^2 , ao fixarmos dois eixos perpendiculares orientados com origem comum O (duas retas reais perpendiculares), cada ponto Q é identificado por um par ordenado de números reais (x, y) , as *coordenadas* de Q . Por fim, no espaço E^3 , ao fixarmos três eixos orientados (retas reais) mutuamente perpendiculares, cada ponto R é identificado por uma tripla ordenada (x, y, z) , as *coordenadas* de R . Tais sistemas de coordenadas são denominados *sistemas cartesianos de coordenadas*.

Chamamos de sistema *cartesiano* de coordenadas em homenagem ao filósofo e matemático francês René Descartes (1596 – 1650), que no século XVII propôs uma maneira inovadora de relacionar a Geometria com a Álgebra. A ideia central de Descartes foi atribuir a cada ponto do espaço uma sequência ordenada de números, obtida a partir de distâncias medidas em relação a eixos perpendiculares entre si. Essa correspondência entre pontos e números permitiu traduzir problemas geométricos em equações algébricas e, de forma recíproca, interpretar soluções algébricas como figuras geométricas. Assim nasceu a chamada Geometria Analítica, e em reconhecimento a essa contribuição fundamental, o sistema de coordenadas recebeu o nome de *cartesiano*.


Exemplo 1.2

Em cada situação descrita a seguir, diga como podemos localizar os pontos mencionados nos eixos de coordenadas estabelecidos. Represente geometricamente cada situação.


- Em E^1 , considere os pontos $P = (-3)$, $Q = (0)$ e $R = (2)$ sobre uma reta orientada com origem em O .
- Em E^2 , considere os pontos $A = (3, 2)$, $B = (-2, 1)$ e $C = (0, -2)$ sobre o plano cartesiano com origem em $O = (0, 0)$.
- Em E^3 , considere o ponto $D = (-2, 0, 3)$ sobre o espaço cartesiano tridimensional com origem em $O = (0, 0, 0)$.

Exemplo 1.2SOLUÇÃO:

- (a)
- Se $P = (-3)$, isso significa que, a partir da origem O , devemos *andar* 3 unidades no sentido negativo do eixo para chegar a P .
 - Se $Q = (0)$, isso significa que, ao *ficar parado* na origem O já chegamos em Q .
 - Se $R = (2)$, isso significa que, a partir da origem O , devemos *andar* 2 unidades no sentido positivo do eixo para chegar a R .




- (b)
- Se $A = (3, 2)$, partindo da origem O , devemos *andar* 3 unidades no sentido positivo do eixo x e, em seguida, 2 unidades no sentido positivo do eixo y para alcançar A .
 - Se $B = (-2, 1)$, partindo da origem O , devemos *andar* 2 unidades no sentido negativo do eixo x e, em seguida, 1 unidades no sentido positivo do eixo y para alcançar B .
 - Se $C = (0, 2)$, partindo da origem O , devemos *andar* 2 unidades no sentido positivo do eixo y para alcançar C .



- (c) Para chegar a $D = (-2, 1, 3)$, partindo da origem O , caminhamos 2 no sentido negativo do eixo x , depois 1 unidade no sentido positivo do eixo y e, finalmente,

Exemplo 1.2

3 unidades no sentido positivo do eixo z .



Com o exemplo anterior, o leitor deve ter percebido – ainda que de forma repetitiva e talvez um pouco cansativa, mas necessária – que cada coordenada de um ponto indica *quanto devemos avançar na direção de cada eixo* para localizar esse ponto no espaço. Uma vez estabelecidas as coordenadas dos pontos nos espaços euclidianos, podemos agora atribuir também um endereço aos vetores, a partir das coordenadas dos segmentos orientados que os representam.

Definição 1.4: Coordenadas de um vetor

Seja $\vec{v}$ um vetor cujo representante é o segmento orientado $\overrightarrow{AB}$, em que as coordenadas de A são (x, y, z) e as coordenadas de B são (x', y', z') . As *coordenadas do vetor* $\vec{v}$ são estabelecidas pela terna ordenada $(x' - x, y' - y, z' - z)$ de números reais.

A definição de coordenadas de um vetor pode soar um tanto estranha em um primeiro momento, pois estamos atribuindo sequências ordenadas de números a um objeto que é, essencialmente, uma classe de segmentos orientados equivalentes. No entanto, o exemplo a seguir tornará clara a razão pela qual essa é uma boa definição. Como todo segmento orientado pertencente a um mesmo vetor é equivalente aos demais, o cálculo de suas coordenadas leva sempre ao mesmo resultado. Assim, não importa qual representante do vetor seja escolhido: as coordenadas obtidas serão invariantes. Por essa razão, falar de um

vetor ou de suas coordenadas é, em última análise, a mesma coisa.


Exemplo 1.3

Seja $\vec{v}$ um vetor de V^3 .

- (a) Se escolhermos o segmento orientado $\overrightarrow{AB}$ como representante de $\vec{v}$, tal que as *coordenadas* do ponto A são $(0, 1, 0)$ e as *coordenadas* do ponto B são $(1, 2, 0)$, quais serão as coordenadas do vetor $\vec{v}$ de acordo com a definição?
- (b) Agora, se escolhêssemos o segmento orientado $\overrightarrow{CD}$ como representante de $\vec{v}$, tal que as *coordenadas* do ponto C são $(1, 2, 0)$ e as *coordenadas* do ponto D são $(2, 3, 0)$, quais seriam as coordenadas do vetor $\vec{v}$?
- (c) E se escolhêssemos o segmento orientado $\overrightarrow{OP}$, tal que as *coordenadas* do ponto O são $(0, 0, 0)$ e as *coordenadas* do ponto P são $(1, 1, 0)$?

SOLUÇÃO:

- (a) Nesse caso, as coordenadas de $\vec{v}$ são $(1, 1, 0)$, pois $(1 - 0, 2 - 1, 0 - 0) = (1, 1, 0)$.
- (b) Nesse caso, as coordenadas de $\vec{v}$ são $(1, 1, 0)$, pois $(2 - 1, 3 - 2, 0 - 0) = (1, 1, 0)$.
- (c) Nesse caso, as coordenadas de $\vec{v}$ são $(1, 1, 0)$, pois $(1 - 0, 1 - 0, 0 - 0) = (1, 1, 0)$.



Note que para segmentos orientados equivalentes (mesma direção, sentido e comprimento) pertencentes a um mesmo vetor, o cálculo de suas coordenadas leva sempre ao mesmo resultado.

Espero que o leitor tenha apreciado o exemplo anterior sem qualquer tipo de moderação,

de modo que, neste momento, já lhe seja evidente que, sempre que houver a liberdade de escolher qual representante utilizar para um dado vetor, a opção mais natural é tomar aquele cujo segmento orientado tem origem na própria origem do sistema de coordenadas. Assim, as coordenadas do ponto extremo desse segmento coincidem exatamente com as coordenadas do vetor, o que simplifica tanto a notação quanto a interpretação geométrica.

1.3 O espaço das coordenadas

Como já mencionamos, todo objeto matemático, uma vez definido, precisa de um lugar (um espaço) para performar sua existência. Por se tratarem de sequências ordenadas de números reais, as coordenadas de um vetor pertencem a produtos cartesianos de conjuntos de números reais. Assim, para vetores em V^1 temos coordenadas em $\mathbb{R}$, para vetores em V^2 as coordenadas estão em $\mathbb{R}^2$ e, para vetores em V^3 , as coordenadas pertencem a $\mathbb{R}^3$.

A cada vetor de V^i conseguimos associar uma e apenas uma coordenada em $\mathbb{R}^i$; de forma equivalente, a cada coordenada em $\mathbb{R}^i$ corresponde um e apenas um vetor em V^i . Em outras palavras, existe uma bijeção entre esses dois espaços e, portanto, falar de V^i ou falar de suas coordenadas é exatamente a mesma coisa. Se você me dá um vetor, eu te dou a sua coordenada; se você me dá a coordenada, eu te devolvo o vetor correspondente, e não há ambiguidade nesse processo.

Na Estatística, quando estudamos um fenômeno, não é comum que apenas uma ou duas medidas sejam suficientes para descrevê-lo. Pense, por exemplo, em uma pesquisa de saúde: para cada paciente podemos registrar altura, peso, pressão arterial, frequência cardíaca e diversos outros indicadores. Limitar essa descrição a apenas três dimensões seria claramente insuficiente. Da mesma forma, em uma análise econômica, não basta observar apenas renda, gasto e poupança; muitas outras variáveis podem ser necessárias para compreender adequadamente a realidade em estudo. Isso põe fim à nossa caminhada com Euclides pelo mundo da geometria tridimensional, pois, para os nossos propósitos, devemos passar a enxergar cada vetor como um elemento de $\mathbb{R}^n$, em que n indica a dimensão do espaço em que ele está inserido.

Isso mesmo: usamos sequências ordenadas de números para modelar fenômenos reais, e essas sequências são justamente as coordenadas de vetores, que por sua vez correspondem a conjuntos de segmentos orientados. Dessa forma, Geometria, Álgebra e Estatística caminham lado a lado, colaborando entre si na tentativa de compreender, descrever e analisar o mundo que nos cerca. Desse modo, a partir de agora, a definição de vetor que nos interessa é a de uma sequência ordenada de números reais e as notações que utilizaremos são estabelecidas na definição a seguir.

Definição 1.5: Vetor

Sejam n um número inteiro positivo. Uma sequência ordenada $x_1, x_2, \dots, x_n$ de números reais é denominada *vetor*. Essa sequência pode ser escrita como

$$\mathbf{x} := \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \quad \text{ou} \quad \mathbf{x}^\top := \begin{bmatrix} x_1 & x_2 & \cdots & x_n \end{bmatrix},$$

onde em $\mathbf{x}$ dispomos os números em *coluna* e em $\mathbf{x}^\top$ dispomos os números em *linha*. Lê-se $\top$ como *transposto*.

Dessa forma, passamos a enxergar cada vetor como um elemento de $\mathbb{R}^n$, em que n indica a dimensão do espaço em que ele está inserido. Quando nos referirmos a um vetor como um conjunto de segmentos orientados, isto é, um elemento de V^n , utilizaremos a notação com uma seta sobre a letra, como em $\vec{x}$. Por outro lado, quando estivermos tratando das suas coordenadas, ou seja, do vetor como elemento de $\mathbb{R}^n$, adotaremos a notação em **negrito**, como em $\mathbf{x}$. Como já comentamos, geometricamente, um vetor $\mathbf{x}$ pode ser representado como um segmento orientado em n dimensões, com componente x_1 ao longo do primeiro eixo, x_2 ao longo do segundo eixo, e assim por diante, até x_n no n -ésimo eixo. Para ilustrar, a Figura 1.6 apresenta esse caso para $n = 3$.




Figura 1.6. Representação geométrica do vetor $\mathbf{x}^\top = \begin{bmatrix} 1 & 3 & 2 \end{bmatrix}$.

Se $\mathbf{x} \in \mathbb{R}^n$, então vamos dizer que o vetor $\mathbf{x}$ possui **ordem** ou **dimensão** n . Por exemplo, na Figura 1.6, o vetor $\mathbf{x} \in \mathbb{R}^3$, portanto, dizemos que ele possui ordem 3.

Definição 1.6: Vetores bastante utilizados na Estatística

Seja n é um número inteiro positivo.

- (a) O vetor $\mathbf{0} \in \mathbb{R}^n$ cujas entradas são todas iguais a 0, i.e.,

$$\mathbf{0} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

é dito **vetor nulo** de ordem n .

- (b) O vetor $\mathbf{1} \in \mathbb{R}^n$ cujas entradas são todas iguais a 1, i.e.,

$$\mathbf{1} = \begin{bmatrix} 1 \\ 1 \\ \vdots \\ 1 \end{bmatrix}$$

é dito **vetor de uns** de ordem n .

- (c) O **vetor oposto** ao vetor $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$ de $\mathbb{R}^n$ é o vetor $-\mathbf{x} = \begin{bmatrix} -x_1 \\ -x_2 \\ \vdots \\ -x_n \end{bmatrix}$.

Na Estatística, os vetores desempenham um papel fundamental como forma de organizar e armazenar dados. Sempre que coletamos informações sobre indivíduos ou unidades experimentais, podemos reunir essas medidas em uma única estrutura ordenada, o que facilita tanto a representação como os cálculos subsequentes. Em alguns casos, um vetor reúne diferentes variáveis observadas em um mesmo indivíduo; em outros, contém várias observações de uma mesma variável em indivíduos distintos. Essa flexibilidade torna os vetores uma das principais ferramentas matemáticas para lidar com dados estatísticos.

Exemplo 1.4

- (a) Dê um exemplo de um vetor de medidas de um mesmo indivíduo.

Exemplo 1.4

- (b) Dê um exemplo de um vetor de observações da mesma variável em diferentes indivíduos.

SOLUÇÃO:

- (a) Suponha que um pesquisador esteja interessado no *estado de saúde de um paciente*. Para isso, ele coleta quatro variáveis: altura (em cm), peso (em kg), pressão arterial sistólica (em mmHg) e frequência cardíaca de repouso (em bpm). Para um paciente específico, digamos João, esses valores foram: altura = 175 cm, peso = 72 kg, pressão = 118 mmHg e frequência = 70 bpm. Assim, podemos organizar as informações de João no vetor

$$\mathbf{x}^\top = [175 \quad 72 \quad 118 \quad 70],$$

em que cada coordenada representa uma variável diferente, mas todas associadas ao mesmo indivíduo.

- (b) Agora considere que o pesquisador deseja analisar a *pressão arterial sistólica* em um grupo de quatro pacientes (João, Maria, Ana e Pedro). As observações foram: 118 mmHg, 124 mmHg, 110 mmHg e 135 mmHg, respectivamente. Essas medidas podem ser reunidas no vetor

$$\mathbf{y} = \begin{bmatrix} 118 \\ 124 \\ 110 \\ 135 \end{bmatrix},$$

no qual cada coordenada corresponde a um indivíduo diferente, mas todas associadas à mesma variável.

1.4 Algumas propriedades básicas de vetores

Ao estudar vetores, percebemos que o espaço das coordenadas $\mathbb{R}^n$, no qual representamos os vetores por meio de sequências ordenadas de números, e o espaço geométrico V^n , em que os visualizamos como segmentos orientados, compartilham uma mesma estrutura de operações. Em ambos os contextos, somar vetores ou multiplicá-los por escalares (números reais) leva a resultados consistentes que obedecem a certas regras fundamentais. Essa

coincidência não é mero acaso: trata-se da manifestação de propriedades gerais que definem o que chamamos de *espaço vetorial*. Assim, ainda que nossa intuição inicial esteja apoiada em representações geométricas ou em coleções de coordenadas, o conceito de espaço vetorial é muito mais amplo: qualquer conjunto que satisfaça tais propriedades pode ser tratado como um espaço vetorial. Sem querer adiantar demais a conversa, retomaremos esse ponto mais adiante, quando estudarmos o espaço das matrizes (ver Capítulo 2).

1.4.1 O espaço vetorial $\mathbb{R}^n$

Começemos por estabelecer quando dois vetores são *iguais*.


Exemplo 1.5

Considere os pontos $A = (-1, -1)$ e $B = (2, 2)$. O segmento orientado $\overrightarrow{AB}$ é um representante do vetor $\vec{u}$. De forma análoga, tomando $O = (0, 0)$ e $P = (3, 3)$, o segmento orientado $\overrightarrow{OP}$ é um representante do vetor $\vec{v}$.

- Podemos afirmar que os vetores $\vec{u}$ e $\vec{v}$ são *iguais*, i.e., são o mesmo conjunto de segmentos orientados equivalentes?
- Determine as coordenadas dos vetores $\vec{u}$ e $\vec{v}$. O que você observa?

SOLUÇÃO:

- Geometricamente, temos



Como $\overrightarrow{AB}$ e $\overrightarrow{OP}$ são segmentos orientados equivalentes (mesma direção, sentido e comprimento), temos $\vec{u}$ igual a $\vec{v}$, i.e., $\vec{u} = \vec{v}$

Exemplo 1.5

(b) Em coordenadas,

$$\mathbf{u} = \begin{bmatrix} 3 \\ 3 \end{bmatrix} \quad \text{e} \quad \mathbf{v} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}.$$

Portanto, as coordenadas são *iguais*, i.e., $\mathbf{u} = \mathbf{v}$.

Definição 1.7: Vetores iguais

- Dois vetores $\vec{u}, \vec{v} \in V^n$ são ditos *iguais* quando correspondem a segmentos orientados equivalentes, isto é, que possuem o mesmo comprimento, direção e sentido.
- De maneira equivalente, em coordenadas, dados $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, temos $\mathbf{u} = \mathbf{v}$ quando $u_i = v_i$ para todo $i = 1, 2, \dots, n$.

Ao pensar em vetores como deslocamentos, é natural imaginar o movimento de uma partícula no plano. Se ela percorre primeiro um vetor e depois outro, o resultado é um único deslocamento equivalente, que corresponde à *soma* desses vetores.


Exemplo 1.6

Considere os pontos $O = (0, 0)$, $P = (1, 2)$ e $Q = (2, 1)$. O segmento orientado $\overrightarrow{OP}$ é um representante do vetor $\vec{u}$, enquanto $\overrightarrow{OQ}$ é um representante do vetor $\vec{v}$.

- Construa o paralelogramo $OPRQ$, em que $R = (3, 3)$.
- Qual segmento orientado você acredita representar a soma $\vec{u} + \vec{v}$?
- Determine as coordenadas de $\vec{u}$, $\vec{v}$ e $\vec{u} + \vec{v}$. O que você observa?

SOLUÇÃO:

- Geometricamente, temos:

Exemplo 1.6

- (b) Note que o segmento orientado $\overrightarrow{PR}$ é equivalente ao segmento orientado $\overrightarrow{OQ}$. Assim, se uma partícula parte de O , desloca-se até P e depois segue por $\overrightarrow{PR}$, alcançará o ponto R . De maneira análoga, como $\overrightarrow{QR}$ é equivalente a $\overrightarrow{OP}$, uma partícula que vá de O até Q e em seguida percorra $\overrightarrow{QR}$ também chegará a R . Portanto, o segmento orientado $\overrightarrow{OR}$ representa o vetor $\vec{u} + \vec{v}$, pois descreve o deslocamento resultante de seguir consecutivamente os caminhos que representam $\vec{u}$ e $\vec{v}$.
- (c) Em coordenadas,

$$\mathbf{u} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}, \quad \mathbf{u} + \mathbf{v} = \begin{bmatrix} 3 \\ 3 \end{bmatrix}.$$

Portanto, a soma de vetores em $\mathbb{R}^n$ corresponde à soma coordenada a coordenada.

Definição 1.8: Soma de vetores

- Dados $\vec{u}, \vec{v} \in V^n$, a soma $\vec{u} + \vec{v}$ é definida como o vetor representado pela diagonal do paralelogramo construído a partir de $\vec{u}$ e $\vec{v}$.
- De maneira equivalente, em coordenadas, a soma $\mathbf{u} + \mathbf{v}$ dos vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ é definida como

$$\mathbf{u} + \mathbf{v} := \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} + \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} u_1 + v_1 \\ u_2 + v_2 \\ \vdots \\ u_n + v_n \end{bmatrix}.$$

Ao pensar em vetores como deslocamentos, é natural imaginar o que acontece quando repetimos o mesmo deslocamento várias vezes. Se uma partícula percorre duas vezes o vetor $\vec{u}$, o resultado é um deslocamento equivalente a percorrer um único vetor que tem o mesmo sentido, mas comprimento dobrado. Essa ideia nos conduz à noção de *multiplicação* de um vetor por um escalar.


Exemplo 1.7

Considere os pontos $O = (0, 0)$, $P = (1, 2)$ e $Q = (2, 4)$. O segmento orientado $\overrightarrow{OP}$ é um representante do vetor $\vec{u}$. O segmento orientado $\overrightarrow{OQ}$, por sua vez, é um representante do vetor $2\vec{u}$.

- (a) Represente geometricamente $\vec{u}$ e $2\vec{u}$.
- (b) O que você observa quanto à direção, sentido e comprimento desses vetores?
- (c) Determine as coordenadas de $\vec{u}$ e $2\vec{u}$.

SOLUÇÃO:

- (a) Geometricamente, temos:



- (b) Observamos que $2\vec{u}$ tem a *mesma direção e sentido* que $\vec{u}$, mas o comprimento é o dobro.
- (c) Em coordenadas,

$$\mathbf{u} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad 2\mathbf{u} = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Portanto, multiplicar um vetor por um escalar corresponde a multiplicar cada coordenada do vetor por esse escalar.

Definição 1.9: Multiplicação de um vetor por um escalar

- Dado $\vec{u} \in V^n$ e $\alpha \in \mathbb{R}$, definimos $\alpha\vec{u}$ como o vetor que possui a mesma direção de $\vec{u}$, sentido igual ao de $\vec{u}$ se $\alpha > 0$ (oposto se $\alpha < 0$), e comprimento $|\alpha|$ vezes o comprimento de $\vec{u}$.
- Em coordenadas, se $\mathbf{u} \in \mathbb{R}^n$, definimos

$$\alpha\mathbf{u} := \alpha \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} = \begin{bmatrix} \alpha u_1 \\ \alpha u_2 \\ \vdots \\ \alpha u_n \end{bmatrix}.$$

A operação de *subtração* de vetores nada mais é do que uma combinação das operações já definidas de soma e multiplicação por escalar. De fato,

$$\mathbf{u} - \mathbf{v} = \mathbf{u} + (-1)\mathbf{v},$$

i.e., a soma de um vetor multiplicada por um escalar (-1) .

Definição 1.10: Subtração de vetores

- Dados $\vec{u}, \vec{v} \in V^n$, a subtração $\vec{u} - \vec{v}$ é o vetor obtido ao somarmos $\vec{u}$ com o oposto de $\vec{v}$, isto é, $\vec{u} - \vec{v} := \vec{u} + (-1)\vec{v}$.
- De maneira equivalente, em coordenadas, dados $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, definimos

$$\mathbf{u} - \mathbf{v} := \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix} - \begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} u_1 - v_1 \\ u_2 - v_2 \\ \vdots \\ u_n - v_n \end{bmatrix}.$$

As operações de soma de vetores e multiplicação por escalar obedecem a um conjunto de propriedades fundamentais, que enunciaremos a seguir sem demonstração.

Resultado 1.1: Propriedades em V^n

Sejam $\vec{u}, \vec{v}, \vec{w} \in V^n$ e $\alpha, \beta \in \mathbb{R}$. A soma de vetores e a multiplicação por escalar em V^n satisfazem as seguintes propriedades:

A. Propriedades da soma de vetores

1. **Comutatividade:** $\vec{u} + \vec{v} = \vec{v} + \vec{u}$.
2. **Associatividade:** $(\vec{u} + \vec{v}) + \vec{w} = \vec{u} + (\vec{v} + \vec{w})$.
3. **Elemento neutro:** $\vec{u} + \vec{0} = \vec{u}$.
4. **Elemento oposto:** $\vec{u} + (-\vec{u}) = \vec{0}$.

B. Propriedades da multiplicação por escalar

1. **Associatividade:** $\alpha(\beta\vec{u}) = (\alpha\beta)\vec{u}$.
2. **Distributividade em relação ao escalar:** $(\alpha + \beta)\vec{u} = \alpha\vec{u} + \beta\vec{u}$.
3. **Distributividade em relação ao vetor:** $\alpha(\vec{u} + \vec{v}) = \alpha\vec{u} + \alpha\vec{v}$.
4. **Elemento unidade:** $1\vec{u} = \vec{u}$.

Resultado 1.2: Propriedades da soma e da multiplicação por escalar

Sejam $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ e $\alpha, \beta \in \mathbb{R}$. Valem as seguintes propriedades:

A. Propriedades da soma de vetores

1. **Comutatividade:** $\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}$.
2. **Associatividade:** $(\mathbf{u} + \mathbf{v}) + \mathbf{w} = \mathbf{u} + (\mathbf{v} + \mathbf{w})$.
3. **Elemento neutro:** $\mathbf{u} + \mathbf{0} = \mathbf{u}$.
4. **Elemento oposto:** $\mathbf{u} + (-\mathbf{u}) = \mathbf{0}$.

B. Propriedades da multiplicação por escalar

1. **Associatividade:** $\alpha(\beta\mathbf{u}) = (\alpha\beta)\mathbf{u}$.
2. **Distributividade em relação ao escalar:** $(\alpha + \beta)\mathbf{u} = \alpha\mathbf{u} + \beta\mathbf{u}$.

Resultado 1.2

3. **Distributividade em relação ao vetor:** $\alpha(\mathbf{u} + \mathbf{v}) = \alpha\mathbf{u} + \alpha\mathbf{v}$.
4. **Elemento unidade:** $1\mathbf{u} = \mathbf{u}$.

O espaço dos vetores V^n e o espaço das coordenadas $\mathbb{R}^n$ munidos com a soma e o produto por escalar definidos como anteriormente, por possuírem as propriedades enunciadas nos Resultados 1.1 e 1.2, são denominados *espaços vetoriais*. Qualquer conjunto munido com uma soma e um produto por escalar que possua tais propriedades será denominado *espaço vetorial*.

Exemplo 1.8

Considere os seguintes vetores de $\mathbb{R}^3$:

$$\mathbf{u} = \begin{bmatrix} 3 \\ -1 \\ 0 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 4 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{w} = \begin{bmatrix} -1 \\ 1 \\ 5 \end{bmatrix}.$$

Determine o vetor $\mathbf{x} \in \mathbb{R}^3$ tal que

$$3(2\mathbf{u} + \mathbf{x}) = 2\mathbf{x} - \mathbf{v}.$$

SOLUÇÃO:

$$\begin{aligned} 3(2\mathbf{u} + \mathbf{x}) = 2\mathbf{x} - \mathbf{v} &\Leftrightarrow 6\mathbf{u} + 3\mathbf{x} = 2\mathbf{x} - \mathbf{v} \\ &\Leftrightarrow 6\mathbf{u} + 3\mathbf{x} - 2\mathbf{x} = -\mathbf{v} \\ &\Leftrightarrow 6\mathbf{u} + \mathbf{x} = -\mathbf{v} \\ &\Leftrightarrow \mathbf{x} = -\mathbf{v} - 6\mathbf{u}. \end{aligned}$$

Substituindo os vetores dados:

$$\mathbf{x} = -\begin{bmatrix} 4 \\ 0 \\ 1 \end{bmatrix} - 6\begin{bmatrix} 3 \\ -1 \\ 0 \end{bmatrix} = \begin{bmatrix} -4 \\ 0 \\ -1 \end{bmatrix} + \begin{bmatrix} -18 \\ 6 \\ 0 \end{bmatrix} = \begin{bmatrix} -22 \\ 6 \\ -1 \end{bmatrix}.$$

1.4.2 Produto interno, norma e ângulo entre vetores

Querido e gentil leitor, até aqui exploramos operações fundamentais como a soma de vetores e a multiplicação por escalares, que garantem a estrutura de espaço vetorial. No entanto, muitas vezes desejamos ir além dessas operações básicas e comparar vetores em termos de direção, ângulo ou comprimento. Para isso, introduzimos uma nova operação, chamada *produto interno*, que associa a cada par de vetores um número real. Esse número nos permitirá quantificar noções geométricas como ortogonalidade, projeção e magnitude, estabelecendo uma ponte entre a álgebra vetorial e a geometria.

Embora continuemos a recorrer, quando conveniente, à noção geométrica de vetores em V^n para reforçar a intuição, a partir deste ponto as definições e propriedades que nos interessam serão sempre formuladas em termos dos vetores de $\mathbb{R}^n$. Sempre que este autor julgar necessário, retomaremos a perspectiva geométrica para esclarecer interpretações e conexões visuais.

Definição 1.11: Produto interno canônico do $\mathbb{R}^n$

O *produto interno* de dois vetores $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$ é definido como a soma do produto de suas entradas, isto é,

$$\mathbf{u}^\top \mathbf{v} = \begin{bmatrix} u_1 & \cdots & u_n \end{bmatrix} \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix} = u_1 v_1 + u_2 v_2 + \cdots + u_n v_n = \sum_{i=1}^n u_i v_i.$$

Observação: Note que $\mathbf{u}^\top \mathbf{v} = \mathbf{v}^\top \mathbf{u}$.

As relações abaixo decorrem diretamente da definição do produto interno e serão enunciadas sem demonstração.

Resultado 1.3: Propriedades do produto interno

Sejam $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ e $\alpha \in \mathbb{R}$. Valem as seguintes propriedades:

1. $(\mathbf{u} + \mathbf{v})^\top \mathbf{w} = \mathbf{u}^\top \mathbf{w} + \mathbf{v}^\top \mathbf{w}$.
2. $(\alpha \mathbf{u})^\top \mathbf{v} = \alpha(\mathbf{u}^\top \mathbf{v})$.
3. $\mathbf{u}^\top \mathbf{v} = \mathbf{v}^\top \mathbf{u}$.

Resultado 1.3

4. $\mathbf{u}^\top \mathbf{u} > 0$ para todo $\mathbf{u} \neq \mathbf{0}$.

Exemplo 1.9

Sejam os vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^2$ tais que

$$\mathbf{u} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} -1 \\ 1 \end{bmatrix}.$$

Determine o vetor $\mathbf{w} \in \mathbb{R}^2$ tal que

$$\mathbf{u}^\top \mathbf{w} = -1 \quad \text{e} \quad \mathbf{v}^\top \mathbf{w} = 3.$$

SOLUÇÃO:

Tomando $\mathbf{w} = \begin{bmatrix} x \\ y \end{bmatrix}$, temos

$$\mathbf{u}^\top \mathbf{w} = -1 \Rightarrow \begin{bmatrix} 1 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = -1 \Rightarrow x + 2y = -1.$$

e

$$\mathbf{v}^\top \mathbf{w} = 3 \Rightarrow \begin{bmatrix} -1 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = 3 \Rightarrow -x + y = 3.$$

O sistema a resolver é

$$\begin{cases} x + 2y = -1, \\ -x + y = 3. \end{cases}$$

Somando as equações, temos

$$(x - x) + (2y + y) = -1 + 3 \Rightarrow 3y = 2 \Rightarrow y = \frac{2}{3}.$$

Substituindo em $-x + y = 3$, segue que

$$-x + \frac{2}{3} = 3 \Rightarrow -x = \frac{7}{3} \Rightarrow x = -\frac{7}{3}.$$

Exemplo 1.9

Portanto,

$$\mathbf{w} = \begin{bmatrix} -\frac{7}{3} \\ \frac{2}{3} \end{bmatrix}.$$

O produto interno é uma operação que enriquece o espaço vetorial: com ele, podemos falar de comprimento de vetores, de ângulos entre vetores e de ortogonalidade.

Definição 1.12: Norma de um vetor

A *norma* de um vetor $\mathbf{u} \in \mathbb{R}^n$ é o número real não-negativo dado por

$$\|\mathbf{u}\| = \sqrt{u_1^2 + u_2^2 + \cdots + u_n^2} = \sqrt{\sum_{i=1}^n u_i^2} = \sqrt{\mathbf{u}^\top \mathbf{u}}.$$

Exemplo 1.10

Considere em V^2 o vetor $\vec{u}$ representado pelo segmento orientado que tem origem em $O = (0, 0)$ e extremidade em $P = (3, 4)$.

- (a) Qual é a norma de $\vec{u}$ ou, equivalentemente, a norma de $\mathbf{u}$?
- (b) Como essa norma se relaciona com o comprimento do segmento $\overrightarrow{OP}$?

SOLUÇÃO:

(a)

$$\begin{aligned} \|\mathbf{u}\| &= \sqrt{3^2 + 4^2} \\ &= \sqrt{9 + 16} \\ &= \sqrt{25} \\ &= 5. \end{aligned}$$

- (b) Portanto, a norma do vetor $\vec{u}$ é igual a 5, que corresponde exatamente ao comprimento do segmento $\overrightarrow{OP}$ no plano cartesiano (verifique, basta utilizar o teorema de Pitágoras).




Figura 1.7. Representação geométrica da norma (ou comprimento) do vetor $\mathbf{x}$.

Exemplo 1.11

Seja $\mathbf{u} \in \mathbb{R}^n$ um vetor e $\alpha \in \mathbb{R}$ um escalar.

- (a) Determine o vetor $\mathbf{u} \in \mathbb{R}^n$ tal que $\|\mathbf{u}\| = 0$.
- (b) Determine a norma do vetor $\alpha\mathbf{u}$.
- (c) Responda às seguintes perguntas:
 - (i) O que ocorre com o *sentido* do vetor $\mathbf{u}$ quando o multiplicamos por um escalar $\alpha > 0$?
 - (ii) O que ocorre com o *sentido* do vetor $\mathbf{u}$ quando o multiplicamos por um escalar $\alpha < 0$?
 - (iii) O que ocorre com o *tamanho* do vetor $\mathbf{u}$ quando o multiplicamos por um escalar $\alpha > 1$?
 - (iv) O que ocorre com o *tamanho* do vetor $\mathbf{u}$ quando o multiplicamos por um escalar $0 < \alpha < 1$?
 - (v) O que ocorre com o tamanho e com o sentido do vetor $\mathbf{u}$ quando o multiplicamos pelo escalar $\alpha = \frac{1}{\|\mathbf{u}\|}$?

SOLUÇÃO:

(a)

$$\|\mathbf{u}\| = 0 \Leftrightarrow \sqrt{\sum_{i=1}^n u_i^2} = 0 \Leftrightarrow \sum_{i=1}^n u_i^2 = 0 \Leftrightarrow u_i^2 = 0 \text{ para todo } i = 1, \dots, n$$

Exemplo 1.11

$$\Leftrightarrow u_i = 0 \text{ para todo } i = 1, \dots, n \Leftrightarrow \mathbf{u} = \mathbf{0}.$$

(b)

$$\|\alpha \mathbf{u}\| = \sqrt{\sum_{i=1}^n (\alpha u_i)^2} = \sqrt{\sum_{i=1}^n \alpha^2 u_i^2} = \sqrt{\alpha^2} \sqrt{\sum_{i=1}^n u_i^2} = |\alpha| \|\mathbf{u}\|.$$

- (c) (i) Se $\alpha > 0$, cria-se um novo vetor $\alpha \mathbf{u}$ com o **mesmo sentido** de $\mathbf{u}$.
(ii) Se $\alpha < 0$, cria-se um novo vetor $\alpha \mathbf{u}$ com o **sentido oposto** ao de $\mathbf{u}$.
(iii) Se $\alpha > 1$, cria-se um novo vetor $\alpha \mathbf{u}$ com **tamanho maior** que o de $\mathbf{u}$.
(iv) Se $0 < \alpha < 1$, cria-se um novo vetor $\alpha \mathbf{u}$ com **tamanho menor** que o de $\mathbf{u}$.
(v) Se $\alpha = \frac{1}{\|\mathbf{u}\|}$, cria-se um novo vetor $\alpha \mathbf{u}$ com o **mesmo sentido** de $\mathbf{u}$ e cujo tamanho é

$$\|\alpha \mathbf{u}\| = |\alpha| \|\mathbf{u}\| = \frac{1}{\|\mathbf{u}\|} \|\mathbf{u}\| = 1.$$

Definição 1.13: Vetor unitário e normalização

- Todo vetor $\mathbf{u} \in \mathbb{R}^n$ tal que $\|\mathbf{u}\| = 1$ é dito *vetor unitário*.
- Todo vetor $\mathbf{u} \in \mathbb{R}^n$ pode ser *normalizado*, i.e., transformado em um novo vetor cuja norma é igual a 1.

A normalização do vetor $\mathbf{u}$ é feita multiplicando-o pelo escalar $\frac{1}{\|\mathbf{u}\|}$, isto é,

$$\frac{\mathbf{u}}{\|\mathbf{u}\|},$$

que tem norma 1 (ver Exemplo 1.11).

Um vetor unitário nada mais é do que um vetor com comprimento igual a 1, isto é, $\|\mathbf{u}\| = 1$. Sua utilidade aparece especialmente quando nos interessa a direção de um vetor e não o seu tamanho. Pense, por exemplo, em duas setas: uma pequena e outra grande, ambas apontando exatamente para o mesmo lado. Apesar de terem comprimentos diferentes, elas “mostram o mesmo caminho”. Ao normalizarmos os vetores, i. e., transformá-los em vetores unitários, eliminamos essa diferença de escala e passamos a trabalhar apenas com

a orientação. Isso é muito útil quando queremos comparar direções, já que o tamanho deixa de influenciar na análise, como se estivéssemos apenas observando para onde cada seta aponta, sem nos preocuparmos com o quanto ela se estende.

O próximo conceito geométrico é o de *ângulo* entre vetores. Para introduzir o conceito, considere dois vetores genéricos do plano

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \text{ e } \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \end{bmatrix}.$$

Sejam $\overrightarrow{OP}$ e $\overrightarrow{OQ}$ segmentos orientados representantes do vetor $\mathbf{u}$ e do vetor $\mathbf{v}$, ambos com origem na origem $O = (0, 0)$ e com extremidades $P = (x_1, x_2)$ e $Q = (y_1, y_2)$, respectivamente, tais como representados na Figura 1.8.




Figura 1.8. Representação geométrica do ângulo θ entre dois vetores $\mathbf{x}$ e $\mathbf{y}$ de $\mathbb{R}^2$.

A partir da figura, θ é o ângulo entre os segmentos orientados $\overrightarrow{OP}$ e $\overrightarrow{OQ}$, θ_1 é o ângulo entre o segmento orientado $\overrightarrow{OP}$ e o eixo das abscissas e θ_2 é o ângulo entre o segmento orientado $\overrightarrow{OQ}$ e o eixo das abscissas. O ângulo θ pode, portanto, ser representado como a diferença entre os ângulos θ_1 e θ_2 . Considerando os triângulos retângulos OPR e OQS , temos, pela definição de cosseno e seno,

$$\begin{aligned} \cos(\theta_1) &= \frac{x_1}{\sqrt{x_1^2 + x_2^2}} = \frac{x_1}{\|\mathbf{x}\|}, & \sin(\theta_1) &= \frac{x_2}{\|\mathbf{x}\|}, \\ \cos(\theta_2) &= \frac{y_1}{\sqrt{y_1^2 + y_2^2}} = \frac{y_1}{\|\mathbf{y}\|}, & \sin(\theta_2) &= \frac{y_2}{\|\mathbf{y}\|}. \end{aligned}$$

Como $\theta = \theta_2 - \theta_1$,

$$\cos(\theta) = \cos(\theta_2 - \theta_1) = \cos(\theta_2) \cos(\theta_1) + \sin(\theta_2) \sin(\theta_1).$$

Substituindo as expressões acima

$$\cos(\theta) = \frac{x_1 y_1}{\|\mathbf{x}\| \|\mathbf{y}\|} + \frac{x_2 y_2}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{x_1 y_1 + x_2 y_2}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

ou seja,

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|}.$$

Portanto, o ângulo entre dois vetores pode ser determinado a partir do produto interno entre eles, normalizado pelos seus comprimentos.

Definição 1.14: Ângulo entre vetores em $\mathbb{R}^n$

O *ângulo* entre os vetores $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$ é o ângulo $\theta \in \mathbb{R}$ tal que

$$\cos(\theta) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

Exemplo 1.12

(a) Determine o ângulo $\theta \in \mathbb{R}$ entre os vetores $\mathbf{u} \in \mathbb{R}^n$ e $-\mathbf{u} \in \mathbb{R}^n$.

(b) Seja

$$\mathbf{x} = \begin{bmatrix} -1 \\ 5 \\ 2 \\ -2 \end{bmatrix}, \quad \mathbf{y} = \begin{bmatrix} 4 \\ -3 \\ 0 \\ 1 \end{bmatrix}.$$

Determine o ângulo $\theta \in \mathbb{R}$ entre os vetores $\mathbf{x}$ e $\mathbf{y}$.

(c) Determine o ângulo $\theta \in \mathbb{R}$ entre os vetores $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$ tais que $\mathbf{u}^\top \mathbf{v} = 0$.

SOLUÇÃO:

(a)

$$\cos(\theta) = \frac{\mathbf{u}^\top (-\mathbf{u})}{\|\mathbf{u}\| \|\mathbf{-u}\|} = -\frac{1}{\|\mathbf{u}\|^2} \sum_{i=1}^n u_i^2 = -1.$$

Portanto,

$$\theta = (2k + 1)\pi, \quad \forall k \in \mathbb{Z}.$$

(b) O comprimento dos vetores é

Exemplo 1.12SOLUÇÃO:

(b)

$$\|\mathbf{x}\| = \sqrt{(-1)^2 + 5^2 + 2^2 + (-2)^2} = \sqrt{34} \approx 5,83,$$

$$\|\mathbf{y}\| = \sqrt{4^2 + (-3)^2 + 0^2 + 1^2} = \sqrt{26} \approx 5,10.$$

O produto interno é

$$\mathbf{x}^\top \mathbf{y} = (-1)(4) + 5(-3) + 2(0) + (-2)(1) = -21.$$

Assim,

$$\cos(\theta) = \frac{\mathbf{x}^\top \mathbf{y}}{\|\mathbf{x}\| \|\mathbf{y}\|} = \frac{-21}{\sqrt{34} \sqrt{26}} = \frac{-21}{5,83 \cdot 5,10} \approx -0,706.$$

Portanto,

$$\theta \approx 135^\circ.$$

(c)

$$\cos(\theta) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{0}{\|\mathbf{u}\| \|\mathbf{v}\|} = 0.$$

Logo,

$$\theta = (2k + 1) \frac{\pi}{2}, \quad \forall k \in \mathbb{Z}.$$

Nesse caso, os segmentos orientados que representam $\vec{u}$ e $\vec{v}$ são **perpendiculares** (basta pensar no caso $n = 2$ para criar intuição).

Definição 1.15: Vetores ortogonais

Os vetores $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$ são ditos *ortogonais* quando

$$\mathbf{u}^\top \mathbf{v} = 0.$$




Figura 1.9. Representação geométrica de dois vetores ortogonais $\mathbf{u}$ e $\mathbf{v}$ em $\mathbb{R}^2$.

A ortogonalidade entre dois vetores não significa apenas que eles apontam para direções distintas, mas sim que a diferença entre suas direções é máxima no sentido de independência geométrica: ao formar um ângulo reto, um vetor não tem nenhum componente projetado sobre o outro. É diferente do caso em que dois vetores formam 180° , pois ali eles continuam sobre a mesma linha, só que em sentidos opostos. A intuição é a de que vetores ortogonais “abrem um novo eixo de variação”, i.e., se um vetor descreve deslocamentos horizontais, o outro descreve deslocamentos verticais, e nenhum pode ser construído a partir do outro. É como caminhar em uma cidade planejada, onde uma rua vai do norte ao sul e a outra do leste ao oeste; cada uma delas conduz a destinos diferentes sem interferência. Essa propriedade é fundamental porque garante que a informação carregada por cada vetor é completamente independente. Na prática, isso significa decompor fenômenos complexos em partes mais simples, facilitando tanto os cálculos quanto a interpretação geométrica dos problemas.

O conceito de ângulo entre vetores é central na Estatística, pois está diretamente ligado a ideias de correlação, independência geométrica e projeção de variáveis em diferentes direções. Por isso, enunciaremos e demonstraremos a seguir alguns resultados fundamentais, que servirão de base para a compreensão de importantes resultados das disciplinas Estatísticas que vocês verão nos próximos anos.

Resultado 1.4: Desigualdade de Cauchy–Schwarz em $\mathbb{R}^n$

Para quaisquer vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, vale a desigualdade

$$|\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|.$$

Resultado 1.4DEMONSTRAÇÃO:

Seja $\theta \in \mathbb{R}$ o ângulo entre os vetores $\mathbf{u}$ e $\mathbf{v}$. Por definição,

$$\cos(\theta) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

Sabemos que, qualquer que seja $\theta \in \mathbb{R}$,

$$-1 \leq \cos(\theta) \leq 1.$$

Logo,

$$-1 \leq \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} \leq 1 \quad \Leftrightarrow \quad -\|\mathbf{u}\| \|\mathbf{v}\| \leq \mathbf{u}^\top \mathbf{v} \leq \|\mathbf{u}\| \|\mathbf{v}\|.$$

Portanto,

$$|\mathbf{u}^\top \mathbf{v}| \leq \|\mathbf{u}\| \|\mathbf{v}\|,$$

como queríamos demonstrar. □

Resultado 1.5: Desigualdade triangular em $\mathbb{R}^n$

Para quaisquer vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$, vale

$$\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|.$$

DEMONSTRAÇÃO:

Pela definição da norma induzida pelo produto interno, temos

$$\|\mathbf{u} + \mathbf{v}\|^2 = (\mathbf{u} + \mathbf{v})^\top (\mathbf{u} + \mathbf{v}) = \|\mathbf{u}\|^2 + 2\mathbf{u}^\top \mathbf{v} + \|\mathbf{v}\|^2.$$

Pela desigualdade de Cauchy-Schwarz,

$$\mathbf{u}^\top \mathbf{v} \leq \|\mathbf{u}\| \|\mathbf{v}\|.$$

Portanto,

Resultado 1.5

$$\|\mathbf{u} + \mathbf{v}\|^2 \leq \|\mathbf{u}\|^2 + 2\|\mathbf{u}\| \|\mathbf{v}\| + \|\mathbf{v}\|^2 = (\|\mathbf{u}\| + \|\mathbf{v}\|)^2.$$

Extraindo raízes quadradas positivas em ambos os lados, obtemos

$$\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|,$$

como queríamos demonstrar. □

A desigualdade triangular recebe esse nome porque pode ser interpretada geometricamente: em qualquer triângulo, o comprimento de um dos lados nunca excede a soma dos comprimentos dos outros dois. Trata-se de um resultado clássico da Geometria Euclidiana, agora expresso em linguagem algébrica.




Figura 1.10 Representação geométrica da desigualdade triangular.

É fundamental que o leitor e a leitora desenvolvam a habilidade de demonstrar resultados matemáticos, pois esse exercício estimula o raciocínio lógico, a clareza de pensamento e a capacidade de estruturar argumentos de forma rigorosa. Essas competências não se restringem ao campo da Matemática: elas se refletem em diversas esferas da vida acadêmica e profissional, ajudando na tomada de decisões, na resolução de problemas complexos e na comunicação de ideias com precisão. Nesse espírito, o próximo exemplo será apresentado como um exercício de demonstração.

Exemplo 1.13

Seja $\mathbf{z} \in \mathbb{R}^n$. Mostre que $\mathbf{z}$ é ortogonal a todo vetor $\mathbf{v} \in \mathbb{R}^n$ se, e somente se, $\mathbf{z} = \mathbf{0}$.

Exemplo 1.14**DEMONSTRAÇÃO:**

Se $\mathbf{z}$ é ortogonal a todo vetor $\mathbf{v}$ do $\mathbb{R}^n$, então, em particular, isso vale para quando $\mathbf{v} = \mathbf{z}$, logo

$$\mathbf{z}^\top \mathbf{v} = 0 \Rightarrow \mathbf{z}^\top \mathbf{z} = 0 \Rightarrow \mathbf{z} = \mathbf{0}.$$

Por outro lado, quando $\mathbf{z} = \mathbf{0}$, temos, para todo $\mathbf{v} \in \mathbb{R}^n$,

$$\mathbf{z}^\top \mathbf{v} = \mathbf{0}^\top \mathbf{v} = 0.$$

1.4.3 Distância e projeção ortogonal entre vetores

Depois de compreendermos as ideias de ângulo e ortogonalidade entre vetores, é natural avançarmos para a noção de distância. Afinal, medir quão “longe” dois pontos ou vetores estão um do outro é tão fundamental quanto entender a direção ou a independência entre eles. Nesse contexto, uma norma em $\mathbb{R}^n$ dá origem a uma noção de distância em $\mathbb{R}^n$, permitindo quantificar de forma rigorosa a separação entre elementos. Essa noção será central em Estatística, pois fundamenta conceitos como proximidade entre observações, agrupamento de dados e análise de similaridade em espaços de alta dimensão.




Figura 1.11 Representação da geometria do vetor $\mathbf{u} - \mathbf{v}$, em que $\mathbf{u}$ e $\mathbf{v}$ são vetores de $\mathbb{R}^2$.

A intuição geométrica da distância Euclidiana é bastante clara: ela mede o comprimento do segmento de reta que liga dois pontos ou, equivalentemente, a norma do vetor diferença entre eles. Se pensarmos em $\mathbb{R}^2$, dados dois pontos representados pelos vetores $\mathbf{u}$ e $\mathbf{v}$, podemos formar um triângulo em que o lado correspondente ao vetor $\mathbf{u} - \mathbf{v}$ conecta diretamente as duas posições. Assim, a distância Euclidiana nada mais é do que o tamanho desse lado, ou seja, a menor distância possível entre $\mathbf{u}$ e $\mathbf{v}$. Em $\mathbb{R}^n$, a ideia é a mesma: mesmo que não possamos “desenhar” o espaço em dimensões maiores, a distância Euclidiana continua sendo a medida mais natural para quantificar o quão separados dois pontos estão no espaço.

Definição 1.16: Distância Euclidiana em $\mathbb{R}^n$

Sejam $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$. A *distância Euclidiana* entre $\mathbf{u}$ e $\mathbf{v}$ é um número real $d(\mathbf{u}, \mathbf{v})$ maior do que 0 tal que

$$d(\mathbf{u}, \mathbf{v}) := \|\mathbf{u} - \mathbf{v}\| = \sqrt{\sum_{i=1}^n (u_i - v_i)^2}.$$

A função distância $d : \mathbb{R}^n \times \mathbb{R}^n \rightarrow [0, +\infty[$ tal que

$$d(\mathbf{u}, \mathbf{v}) := \|\mathbf{u} - \mathbf{v}\| = \sqrt{\sum_{i=1}^n (u_i - v_i)^2}$$

obedece a algumas propriedades fundamentais, que enunciamos a seguir sem demonstração. Portanto é um excelente momento para o leitor e a leitora testar suas habilidades de demonstração, tentando por si só provar as propriedades do Resultado 1.6.

Resultado 1.6: Propriedades da distância em $\mathbb{R}^n$

Sejam $\mathbf{u}, \mathbf{v}, \mathbf{w} \in \mathbb{R}^n$. A distância Euclidiana $d(\cdot, \cdot)$ satisfaz:

1. $d(\mathbf{u}, \mathbf{v}) \geq 0$.
2. **Comutatividade:** $d(\mathbf{u}, \mathbf{v}) = d(\mathbf{v}, \mathbf{u})$.
3. **Desigualdade triangular:**


$$d(\mathbf{u}, \mathbf{v}) \leq d(\mathbf{u}, \mathbf{w}) + d(\mathbf{w}, \mathbf{v}).$$

Exemplo 1.15

Considere os vetores do $\mathbb{R}^2$

$$\mathbf{u} = \begin{bmatrix} 3 \\ 0 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 0 \\ 4 \end{bmatrix}.$$

- (a) Calcule a norma de $\mathbf{u}$.
- (b) Calcule a norma de $\mathbf{v}$.
- (c) Determine o produto interno $\mathbf{u}^\top \mathbf{v}$.
- (d) Determine o ângulo θ entre os vetores $\mathbf{u}$ e $\mathbf{v}$.
- (e) Calcule a distância Euclidiana entre $\mathbf{u}$ e $\mathbf{v}$.

**SOLUÇÃO:**

- (a) Pela definição de norma,

$$\|\mathbf{u}\| = \sqrt{3^2 + 0^2} = \sqrt{9} = 3.$$

- (b) De modo análogo,

$$\|\mathbf{v}\| = \sqrt{0^2 + 4^2} = \sqrt{16} = 4.$$

Exemplo 1.15

(c) O produto interno é

$$\mathbf{u}^\top \mathbf{v} = 3 \cdot 0 + 0 \cdot 4 = 0,$$

i.e., $\mathbf{u}$ e $\mathbf{v}$ são vetores ortogonais.

(d) Pelo fato de $\cos(\theta) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}$, temos

$$\cos(\theta) = \frac{0}{3 \cdot 4} = 0 \quad \Rightarrow \quad \theta = \frac{\pi}{2}.$$

(e) A distância Euclidiana entre $\mathbf{u}$ e $\mathbf{v}$ é

$$d(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\| = \sqrt{(3-0)^2 + (0-4)^2} = \sqrt{9+16} = \sqrt{25} = 5.$$

O Exemplo 1.15 é um caso particular de uma situação mais geral, a qual exemplificamos a seguir.

Exemplo 1.16: Teorema de Pitágoras em $\mathbb{R}^n$

Sejam $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$. Mostre que

$$\mathbf{u} \perp \mathbf{v} \iff d(\mathbf{u}, \mathbf{v}) = \sqrt{\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2}.$$

Aqui utilizamos $\perp$ para indicar que os vetores $\mathbf{u}$ e $\mathbf{v}$ são ortogonais.

SOLUÇÃO:

($\Rightarrow$) Suponha que $\mathbf{u} \perp \mathbf{v}$. Então $\mathbf{u}^\top \mathbf{v} = 0$. Logo,

$$d^2(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2\mathbf{u}^\top \mathbf{v} = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2.$$

Portanto,

$$d(\mathbf{u}, \mathbf{v}) = \sqrt{\|\mathbf{u}\|^2 + \|\mathbf{v}\|^2}.$$

($\Leftarrow$) Reciprocamente, suponha que

$$d^2(\mathbf{u}, \mathbf{v}) = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2.$$

Exemplo 1.16

Mas, em geral,

$$d^2(\mathbf{u}, \mathbf{v}) = \|\mathbf{u} - \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 - 2\mathbf{u}^\top \mathbf{v}.$$

Comparando as duas expressões, obtemos $-2\mathbf{u}^\top \mathbf{v} = 0$, isto é,

$$\mathbf{u}^\top \mathbf{v} = 0.$$

Portanto, $\mathbf{u} \perp \mathbf{v}$.

□

O resultado relatado no Exemplo 1.16 é precisamente o Teorema de Pitágoras expresso em linguagem vetorial. Ele nos diz que, quando dois vetores são ortogonais, a distância entre eles corresponde ao comprimento da hipotenusa do triângulo retângulo formado, cujo quadrado é a soma dos quadrados dos comprimentos dos catetos. Em outras palavras, a clássica relação pitagórica da Geometria Euclidiana surge aqui de maneira natural a partir do conceito de produto interno em $\mathbb{R}^n$.

Caro e gentil leitor, agora vamos conectar a ideia distância a outra noção importante dentro da Álgebra Linear: a de *projeção ortogonal*. Para isso, comecemos por analisar a Figura 1.12 a seguir.




Figura 1.12. Representação geométrica da projeção ortogonal do vetor $\mathbf{u}$ sobre o vetor $\mathbf{v}$ e do complemento ortogonal $\mathbf{w}$ fruto dessa projeção.

Note que se uma partícula está no ponto O para que ela possa se deslocar até o ponto P , ela pode percorrer o segmento orientado $\overrightarrow{OP}$ que representa o vetor $\mathbf{u}$ ou, equivalentemente, ela pode se deslocar até o ponto P' por meio do segmento orientado $\overrightarrow{OP'}$ e, em seguida, percorrer o segmento orientado $\overrightarrow{P'P}$ para chegar ao ponto P . Dessa forma, se o segmento orientado $\overrightarrow{OP'}$ é o representante do vetor $\text{proj}_{\mathbf{v}}(\mathbf{u})$, o qual chamaremos *projeção ortogonal de $\mathbf{u}$ sobre $\mathbf{v}$* , e $\overrightarrow{P'P}$ é o segmento orientado representante do vetor $\text{rej}_{\mathbf{v}}(\mathbf{u})$, que denominaremos *complemento ortogonal da projeção de $\mathbf{u}$ sobre $\mathbf{v}$* , então pe-

la regra do paralelogramo (que usamos para definir soma de vetores), temos

$$\mathbf{u} = \text{proj}_{\mathbf{v}}(\mathbf{u}) + \text{rej}_{\mathbf{v}}(\mathbf{u}).$$

Agora, vamos determinar a projeção do vetor $\mathbf{u}$ sobre o vetor $\mathbf{v}$ analisando a triângulo retângulo $OP'P$ da Figura 1.12. Seja $\theta \in \mathbb{R}$ o ângulo formado entre os segmentos orientados $\overrightarrow{OP}$ e $\overrightarrow{OP'}$. Logo, pela definição de cosseno em triângulos retângulos, temos

$$\cos(\theta) = \frac{\|\text{proj}_{\mathbf{v}}(\mathbf{u})\|}{\|\mathbf{u}\|}.$$

Por outro lado, o cosseno do ângulo formado entre o vetor $\mathbf{u}$ e o vetor $\mathbf{v}$ é

$$\cos(\theta) = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|}.$$

Logo,

$$\frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{u}\| \|\mathbf{v}\|} = \frac{\|\text{proj}_{\mathbf{v}}(\mathbf{u})\|}{\|\mathbf{u}\|} \Leftrightarrow \|\text{proj}_{\mathbf{v}}(\mathbf{u})\| = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{v}\|}.$$

Note que o vetor $\text{proj}_{\mathbf{v}}(\mathbf{u})$, que projeta o vetor $\mathbf{u}$ sobre o vetor $\mathbf{v}$, está sobre a mesma reta suporte do vetor $\mathbf{v}$, i.e., possui a mesma direção de $\mathbf{v}$ e, nesse caso, o mesmo sentido também. Logo, $\text{proj}_{\mathbf{v}}(\mathbf{u}) = \alpha \mathbf{v}$, para alguma $\alpha > 0$, i.e., o vetor projeção $\text{proj}_{\mathbf{v}}(\mathbf{u})$ só possui um tamanho diferente do vetor $\mathbf{v}$. Para determinar α , fazemos

$$\|\text{proj}_{\mathbf{v}}(\mathbf{u})\| = \|\alpha \mathbf{v}\| \Leftrightarrow \|\text{proj}_{\mathbf{v}}(\mathbf{u})\| = |\alpha| \|\mathbf{v}\| \Leftrightarrow \alpha = \frac{\text{proj}_{\mathbf{v}}(\mathbf{u})}{\|\mathbf{v}\|}.$$

Logo, o vetor $\text{proj}_{\mathbf{v}}(\mathbf{u})$ que projeta o vetor $\mathbf{u}$ sobre o vetor $\mathbf{v}$ é dado por

$$\text{proj}_{\mathbf{v}}(\mathbf{u}) = \frac{\text{proj}_{\mathbf{v}}(\mathbf{u})}{\|\mathbf{v}\|} \mathbf{v} = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{v}\|} \frac{\mathbf{v}}{\|\mathbf{v}\|}.$$

Antes de formalizarmos as definições, vale a pena interpretar geometricamente a ideia de projeção. A *projeção ortogonal* de $\mathbf{u}$ sobre $\mathbf{v}$ pode ser pensada como a “sombra” de $\mathbf{u}$ lançada sobre a reta que contém $\mathbf{v}$. É como se disséssemos que, se $\mathbf{u}$ vivesse na mesma reta suporte de $\mathbf{v}$, então a sua versão nessa reta seria exatamente a projeção. Por outro lado, o *complemento ortogonal* (ou vetor rejeição) representa a parte que “faltou” para que $\mathbf{u}$ fosse idêntico à sua projeção: é o resíduo que permanece perpendicular a $\mathbf{v}$. Uma boa analogia é imaginar uma luz que incide sobre $\mathbf{u}$ na direção perpendicular a $\mathbf{v}$: a projeção é a sombra sobre a reta, enquanto o complemento ortogonal é a *distância* que separa $\mathbf{u}$ dessa sombra.

Definição 1.17: Projeção ortogonal de um vetor do $\mathbb{R}^n$ sobre outro

Sejam $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$.

- O *tamanho do vetor projeção* de $\mathbf{u}$ sobre $\mathbf{v}$ é definido como

$$\|\text{proj}_{\mathbf{v}} \mathbf{u}\| = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{v}\|}.$$

- O *vetor projeção* de $\mathbf{u}$ sobre $\mathbf{v}$ é definido como

$$\text{proj}_{\mathbf{v}} \mathbf{u} = \frac{\mathbf{u}^\top \mathbf{v}}{\|\mathbf{v}\|^2} \mathbf{v}.$$

Definição 1.18: Complemento ortogonal de uma projeção ortogonal

Sejam $\mathbf{u} \in \mathbb{R}^n$ e $\mathbf{v} \in \mathbb{R}^n$. O *complemento ortogonal* (ou *vetor rejeição*) de $\mathbf{u}$ sobre $\mathbf{v}$ é definido como

$$\text{rej}_{\mathbf{v}} \mathbf{u} = \mathbf{u} - \text{proj}_{\mathbf{v}} \mathbf{u}.$$

Exemplo 1.17

- (a) Determine a projeção ortogonal do vetor

$$\mathbf{x} = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{4} \end{bmatrix} \quad \text{sobre o vetor de uns} \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e, em seguida, o complemento ortogonal dessa projeção.

- (b) Determine a projeção ortogonal do vetor

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \quad \text{sobre o vetor de uns} \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e, em seguida o complemento ortogonal dessa projeção.

- (c) Qual é o tamanho da projeção ortogonal entre dois vetores $\mathbf{u}$ e $\mathbf{v}$ do $\mathbb{R}^n$ que são ortogonais? E o tamanho do complemento ortogonal?

1.5 Aspectos geométricos de uma amostra por meio de conceitos de vetores

Dados multivariados surgem sempre que um investigador, buscando entender um fenômeno físico ou social, seleciona e observa $p \geq 1$ *variáveis* em n *indivíduos*, *objetos* ou *unidades experimentais*. Consequentemente, os dados multivariados podem ser exibidos da seguinte forma:

	Variável 1 (X_1)	Variável 2 (X_2)	...	Variável k (X_k)	...	Variável p (X_p)
Item 1:	x_{11}	x_{12}	...	x_{1k}	...	x_{1p}
Item 2:	x_{21}	x_{22}	...	x_{2k}	...	x_{2p}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
Item j :	x_{j1}	x_{j2}	...	x_{jk}	...	x_{jp}
$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$	$\ddots$	$\vdots$
Item n :	x_{n1}	x_{n2}	...	x_{nk}	...	x_{np}

em que x_{jk} representa o valor da k -ésima variável X_k observada no j -ésimo item, para todo $1 \leq j \leq n$ e $1 \leq k \leq p$.

Assim, cada item da amostra pode ser representado por um vetor cujas entradas correspondem aos valores observados das variáveis em estudo. Esse ponto de vista geométrico é fundamental, pois permite explorar propriedades algébricas e espaciais dos vetores, facilitando a interpretação de distâncias, ângulos e projeções entre observações, bem como a estrutura global do conjunto de dados.

Antes de prosseguirmos com a análise geométrica, é importante fixarmos algumas notações que serão utilizadas ao longo do texto. Denotaremos por $\mathbf{x}_k \in \mathbb{R}^n$ o vetor de observações x_{jk} da k -ésima variável X_k , $j = 1, 2, \dots, n$, isto é, o conjunto de todas as respostas registradas para aquela variável em cada uma das n unidades amostrais. De forma complementar, representaremos por $\mathbf{x}^{(j)} \in \mathbb{R}^p$ o vetor de observações x_{jk} correspondente ao j -ésimo indivíduo, $k = 1, 2, \dots, p$, ou seja, o conjunto de valores que esse indivíduo apresenta para cada uma das p variáveis observadas. Essas duas perspectivas, por variáveis e por indivíduos, serão fundamentais para compreendermos tanto a estrutura dos dados quanto as interpretações geométricas que delas decorrem.

Quando trabalhamos com muitos dados de uma só vez, fica difícil enxergar padrões só olhando para os números brutos (observações). É aí que as estatísticas descritivas entram em ação - elas são como *resumos numéricos* que capturam as informações mais importantes de forma organizada. A média, por exemplo, nos diz qual é o valor central do

conjunto, enquanto medidas como a variância mostram o quanto os dados variam em torno dessa média. Nesta seção, vamos focar em três tipos desses resumos: (i) os que mostram onde os dados se concentram (como a média), (ii) os que indicam o espalhamento dos valores (como a variância), e (iii) os que revelam relações lineares entre variáveis (covariâncias e correlações de Pearson). São ferramentas simples, mas poderosas, para começar a entender qualquer conjunto de dados.

1.5.1 O vetor de médias amostrais e a projeção ortogonal

Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k calculamos a *média amostral* $\bar{x}_k$ da seguinte maneira

$$\bar{x}_k := \frac{x_{1k} + x_{2k} + \dots + x_{nk}}{n} = \frac{1}{n} \sum_{j=1}^n x_{jk},$$

qualquer que seja $k = 1, 2, \dots, p$. A média $\bar{x}_k$ representa um *valor central* de X_k na *amostra* coletada. As p médias amostrais podem ser organizadas em vetores.

Definição 1.19: Vetor de médias amostrais em $\mathbb{R}^p$

Considere que n observações $x_{1k}, x_{2k}, \dots, x_{nk}$ foram realizadas em cada uma das variáveis X_k , $k = 1, 2, \dots, p$. O *vetor de médias amostrais* é o vetor $\bar{\mathbf{x}} \in \mathbb{R}^p$ tal que

$$\bar{\mathbf{x}} := \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \\ \vdots \\ \bar{x}_p \end{bmatrix}.$$

Exemplo 1.18

Considere uma pesquisa interessada em estudar duas variáveis de interesse: saldo da conta bancária (X_1) e valor da fatura do cartão de crédito (X_2). Considere ambas as variáveis medidas em milhares de reais. Os vetor de observações referentes às variáveis são dados a seguir:

$$\mathbf{x}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

Exemplo 1.18

- (a) Determine os vetores de observações $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$ e $\mathbf{x}^{(3)}$ referentes às unidades amostrais.
- (b) Determine o vetor de médias $\bar{\mathbf{x}}$.
- (c) Represente, em um sistema cartesiano de coordenadas em E^2 , os vetores de observações referentes às unidades amostrais juntamente com o vetor de médias.
- (d) Represente, em um sistema cartesiano de coordenadas em E^3 , os vetores de observações referentes às variáveis.

SOLUÇÃO:


- (a) Os vetores de observações referentes às unidades amostrais são:

$$\mathbf{x}^{(1)} = \begin{bmatrix} 4 \\ 1 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} -1 \\ 3 \end{bmatrix}, \quad \text{e} \quad \mathbf{x}^{(3)} = \begin{bmatrix} 3 \\ 5 \end{bmatrix}.$$

- (b) O vetor de médias é:


$$\bar{\mathbf{x}} = \begin{bmatrix} \frac{4 + (-1) + 3}{3} \\ \frac{1 + 3 + 5}{3} \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

- (c) Os vetores de observações referentes às unidades amostrais juntamente com o vetor de médias podem ser representados em E^2 da seguinte maneira



Exemplo 1.18

- (d) Os vetores de observações referentes às variáveis podem ser representados em E^3 da seguinte maneira

**Exemplo 1.19**

Considere uma pesquisa interessada em estudar duas variáveis de interesse: valor de mercado atual de uma casa (X_1) e tamanho de uma casa (X_2). Considere a variável X_1 medida em milhares de reais e a variável X_2 em m^2 .

$$x_1 = \begin{bmatrix} 400 \\ 100 \\ 700 \\ 900 \end{bmatrix} \quad \text{e} \quad x_2 = \begin{bmatrix} 100 \\ 50 \\ 200 \\ 150 \end{bmatrix}.$$

Exemplo 1.19

- (a) Determine os vetores de observações $\mathbf{x}^{(1)}$, $\mathbf{x}^{(2)}$, $\mathbf{x}^{(3)}$ e $\mathbf{x}^{(4)}$ referentes às unidades amostrais.
- (b) Determine o vetor de médias $\bar{\mathbf{x}}$.
- (c) Represente, em um sistema cartesiano de coordenadas em E^2 , os vetores de observações referentes às unidades amostrais juntamente com o vetor de médias.
- (d) Represente, em um sistema cartesiano de coordenadas em E^4 , os vetores de observações referentes às variáveis.

SOLUÇÃO:


- (a) Os vetores de observações referentes às unidades amostrais são:

$$\mathbf{x}^{(1)} = \begin{bmatrix} 400 \\ 100 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 100 \\ 50 \end{bmatrix}, \quad \mathbf{x}^{(3)} = \begin{bmatrix} 700 \\ 200 \end{bmatrix}, \quad \text{e} \quad \mathbf{x}^{(4)} = \begin{bmatrix} 900 \\ 150 \end{bmatrix}.$$

- (b) O vetor de médias é:

$$\bar{\mathbf{x}} = \begin{bmatrix} 525 \\ 125 \end{bmatrix}.$$

- (c) Os vetores de observações referentes às unidades amostrais juntamente com o vetor de médias podem ser representados em E^2 da seguinte maneira:



Exemplo 1.19

(d) Aí é pedir demais! Não conseguimos representar os vetores de observações referentes às variáveis, pois em E^4 perdemos o apelo geométrico.

Após termos definido o vetor de médias e explorado alguns exemplos, podemos agora interpretar esse conceito de forma geométrica. Considere o vetor de observações associado à variável X_k , dado por

$$\mathbf{x}_k = \begin{bmatrix} x_{1k} \\ x_{2k} \\ \vdots \\ x_{nk} \end{bmatrix}.$$

Quando projetamos $\mathbf{x}_k$ sobre o vetor de uns $\mathbf{1}$, estamos essencialmente calculando quanto do “conteúdo” de $\mathbf{x}_k$ está alinhado com a direção de $\mathbf{1}$. Em outras palavras, se os valores observados $\mathbf{x}_k$ da variável X_k pertencessem à mesma reta suporte do vetor de uns $\mathbf{1}$, então ele seria o vetor projeção de $\mathbf{x}_k$ sobre o vetor de uns $\mathbf{1}$. O tamanho dessa projeção é proporcional à média amostral. De fato,

$$\|\text{proj}_{\mathbf{1}} \mathbf{x}_k\| = \frac{\mathbf{x}_k^\top \mathbf{1}}{\|\mathbf{1}\|} = \frac{1}{\sqrt{n}} \sum_{j=1}^n x_{jk} = \sqrt{n} \bar{x}_k,$$

em que $\bar{x}_k$ é a média das observações de X_k . Já o vetor projeção é dado por

$$\text{proj}_{\mathbf{1}} \mathbf{x}_k = \frac{\mathbf{x}_k^\top \mathbf{1}}{\|\mathbf{1}\|^2} \mathbf{1} = \bar{x}_k \mathbf{1}.$$

Portanto, a média amostral $\bar{x}_k$ pode ser entendida como o múltiplo do vetor de uns necessário para que $\mathbf{x}_k$ seja projetado na direção de $\mathbf{1}$. Em outras palavras, a média é o fator de escala que transforma o vetor de uns no ponto que melhor representa $\mathbf{x}_k$ sobre essa reta de referência.

Exemplo 1.20

(a) Determine a projeção ortogonal do vetor

$$\mathbf{x} = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{4} \end{bmatrix} \quad \text{sobre o vetor de uns} \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e, em seguida, o complemento ortogonal dessa projeção.

Exemplo 1.20

(b) Determine a projeção ortogonal do vetor

$$\mathbf{x} = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \quad \text{sobre o vetor de uns} \quad \mathbf{1} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e, em seguida, o complemento ortogonal dessa projeção.

SOLUÇÃO:

(a) A projeção ortogonal de $\mathbf{x}$ sobre $\mathbf{1}$ é dada por

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \frac{\mathbf{x}^{\top} \mathbf{1}}{\|\mathbf{1}\|^2} \mathbf{1}.$$

Temos


$$\mathbf{x}^{\top} \mathbf{1} = \frac{1}{2} + \frac{1}{4} = \frac{3}{4}, \quad \|\mathbf{1}\|^2 = 1^2 + 1^2 = 2.$$

Portanto,

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \frac{\frac{3}{4}}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{3}{8} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{3}{8} \\ \frac{3}{8} \end{bmatrix}.$$

O complemento ortogonal é

$$\mathbf{x} - \text{proj}_{\mathbf{1}}(\mathbf{x}) = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{4} \end{bmatrix} - \begin{bmatrix} \frac{3}{8} \\ \frac{3}{8} \end{bmatrix} = \begin{bmatrix} \frac{1}{8} \\ -\frac{1}{8} \end{bmatrix}.$$



Note que

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \bar{x} \mathbf{1} = \frac{3}{8} \mathbf{1}.$$

Exemplo 1.20

(b) A projeção ortogonal de $\mathbf{x}$ sobre $\mathbf{1}$ é dada por

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \frac{\mathbf{x}^{\top} \mathbf{1}}{\|\mathbf{1}\|^2} \mathbf{1}.$$

Temos


$$\mathbf{x}^{\top} \mathbf{1} = 3 + 4 = 7, \quad \|\mathbf{1}\|^2 = 1^2 + 1^2 = 2.$$

Portanto,

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \frac{7}{2} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \begin{bmatrix} \frac{7}{2} \\ \frac{7}{2} \end{bmatrix}.$$

O complemento ortogonal é

$$\mathbf{x} - \text{proj}_{\mathbf{1}}(\mathbf{x}) = \begin{bmatrix} 3 \\ 4 \end{bmatrix} - \begin{bmatrix} \frac{7}{2} \\ \frac{7}{2} \end{bmatrix} = \begin{bmatrix} -\frac{1}{2} \\ \frac{1}{2} \end{bmatrix}.$$



Note que

$$\text{proj}_{\mathbf{1}}(\mathbf{x}) = \bar{x} \mathbf{1} = \frac{7}{2} \mathbf{1}.$$

1.5.2 O vetor de desvios

Ao estudarmos a média amostral, vimos que ela pode ser interpretada como a projeção dos dados sobre o vetor de uns. A média fornece, em certo sentido, uma “posição central” dos dados. Agora vamos dar um passo além: em vez de olhar apenas para essa posição central, queremos analisar como cada observação se afasta da média. Para isso, introduzi-

introduzimos o *vetor de desvios*, que nada mais é do que o vetor que contém as diferenças entre cada observação e a média da variável correspondente. Em termos geométricos, isso equivale a *centralizar* os dados. Quando temos duas variáveis ($\mathbb{R}^2$) envolvidas no estudo, centralizar os dados significa deslocar a nuvem de pontos de forma que a média fique posicionada exatamente na origem do sistema de coordenadas. Isso significa transladar o gráfico de dispersão para que o “centro” dos dados coincida com o ponto $(0, 0)$.

Essa ideia de centralização é fundamental em Estatística. Ao trabalhar com os dados centralizados, eliminamos o efeito do deslocamento absoluto e passamos a enxergar apenas as variações em torno da média. Isso será essencial, por exemplo, quando estudarmos medidas de dispersão, correlação entre variáveis e, futuramente, a padronização, em que além de centralizar dividimos os desvios pelo desvio-padrão para obter variáveis comparáveis em diferentes escalas. Nas próximas definições, formalizamos o conceito de vetor de desvios e mostramos como ele se organiza tanto para cada variável quanto para cada unidade amostral.

Definição 1.20: Vetor de desvios

Considere uma pesquisa interessada em estudar as variáveis $X_1, X_2, \dots, X_p$. Para todo $k = 1, 2, \dots, p$, o vetor $\mathbf{d}_k \in \mathbb{R}^n$ tal que

$$\mathbf{d}_k = \begin{bmatrix} x_{1k} - \bar{x}_k \\ x_{2k} - \bar{x}_k \\ \vdots \\ x_{nk} - \bar{x}_k \end{bmatrix}$$

é o *vetor dos desvios* das observações da variável X_k em relação à sua média $\bar{x}_k$.

Assim, $\mathbf{d}_k$ nos mostra como cada valor da variável X_k se afasta da média. Outra maneira de enxergar a centralização é olhar não variável por variável, mas sim *unidade por unidade*, isto é, observar como as p variáveis de um mesmo indivíduo se ajustam em relação às suas respectivas médias.

Definição 1.21: Vetor de observações ajustado pela média

Considere uma pesquisa interessada em estudar as variáveis $X_1, X_2, \dots, X_p$. O *vetor de observações ajustado pela média* $\mathbf{x}'^{(j)} \in \mathbb{R}^p$ para a unidade amostral j é

Definição 1.21

$$\mathbf{x}'^{(j)} = \begin{bmatrix} d_{j1} \\ d_{j2} \\ \vdots \\ d_{jp} \end{bmatrix}, \quad j = 1, 2, \dots, n.$$

Em outras palavras, $\mathbf{x}'^{(j)}$ corresponde ao vetor de características do indivíduo j , mas centralizado em relação às médias de cada variável. Geometricamente, isso significa que o ponto $\mathbf{x}'^{(j)}$ representa a posição ajustada do indivíduo j em um sistema de coordenadas cujo centro é a média das variáveis.

Exemplo 1.21

Considere uma pesquisa interessada em estudar duas variáveis de interesse: saldo da conta bancária (X_1) e valor da fatura do cartão de crédito (X_2), ambas medidas em milhares de reais. Os vetores de observações referentes às variáveis são:

$$\mathbf{x}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

- Determine os vetores de desvios da média para cada uma das variáveis.
- Represente no sistema cartesiano de coordenadas o gráfico de pontos localizando $\mathbf{x}^{(1)}, \mathbf{x}^{(2)}, \mathbf{x}^{(3)}$ e $\bar{\mathbf{x}}$.
- Represente no sistema cartesiano de coordenadas o gráfico de pontos localizando $\mathbf{x}'^{(1)}, \mathbf{x}'^{(2)}, \mathbf{x}'^{(3)}$ e $\bar{\mathbf{x}}'$.

SOLUÇÃO:

- Como $\bar{x}_1 = 2$ e $\bar{x}_2 = 3$, temos:


$$\mathbf{d}_1 = \begin{bmatrix} 4 - 2 \\ -1 - 2 \\ 3 - 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{d}_2 = \begin{bmatrix} 1 - 3 \\ 3 - 3 \\ 5 - 3 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}.$$

Exemplo 1.21


Portanto, os vetores de observações ajustados pela média são:

$$\mathbf{x}'^{(1)} = \begin{bmatrix} 2 \\ -2 \end{bmatrix}, \quad \mathbf{x}'^{(2)} = \begin{bmatrix} -3 \\ 0 \end{bmatrix}, \quad \mathbf{x}'^{(3)} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \bar{\mathbf{x}}' = \begin{bmatrix} 0 \\ 0 \end{bmatrix}.$$

(b)



(c)



Podemos agora fazer uma conexão direta com a seção anterior, em que discutimos a projeção ortogonal de um vetor de dados sobre o vetor de uns. Recorde que, para a variá-

vel X_k , o vetor de observações é

$$\mathbf{x}_k = \begin{bmatrix} x_{1k} \\ x_{2k} \\ \vdots \\ x_{nk} \end{bmatrix}.$$

Sua projeção sobre o vetor de uns é dada por

$$\text{proj}_{\mathbf{1}}(\mathbf{x}_k) = \bar{x}_k \mathbf{1},$$

em que $\bar{x}_k$ é a média amostral da variável X_k .

O que acontece se retirarmos de $\mathbf{x}_k$ exatamente essa projeção? O vetor resultante é

$$\mathbf{x}_k - \bar{x}_k \mathbf{1},$$

que, por definição, é o vetor de desvios

$$\mathbf{d}_k = \begin{bmatrix} x_{1k} - \bar{x}_k \\ x_{2k} - \bar{x}_k \\ \vdots \\ x_{nk} - \bar{x}_k \end{bmatrix}.$$

Portanto, o vetor de desvios $\mathbf{d}_k$ pode ser interpretado como o *complemento ortogonal* da projeção de $\mathbf{x}_k$ sobre o vetor de uns $\mathbf{1}$. Em outras palavras, decompomos o vetor de observações em duas partes: uma componente alinhada à direção de $\mathbf{1}$ (a média multiplicada pelo vetor de uns) e uma componente ortogonal a essa direção (os desvios em relação à média). Essa decomposição é ilustrada geometricamente na Figura 1.13.




Figura 1.13. A decomposição do vetor de observações $\mathbf{x}_k$ da variável X_k em duas componentes: o vetor $\bar{x}_k \mathbf{1}$, que a projeção ortogonal de $\mathbf{x}_k$ sobre $\mathbf{1}$, e $\mathbf{d}_k$, que é o vetor de desvios.

Assim, cada vetor de dados pode ser decomposto em

$$\mathbf{x}_k = \bar{x}_k \mathbf{1} + \mathbf{d}_k,$$

mostrando claramente a relação entre média e desvios: a média concentra a informação sobre a posição central, enquanto o vetor de desvios concentra a informação sobre a variabilidade em torno dessa posição.

Exemplo 1.22

Considere o mesmo problema do Exemplo 1.21. Decomponha os vetores de observações relativos às variáveis $\mathbf{x}_1$ e $\mathbf{x}_2$ em suas componentes de médias e de desvios.

SOLUÇÃO:

Para a variável X_1 , temos

$$\mathbf{x}_1 = \bar{x}_1 \mathbf{1} + \mathbf{d}_1,$$

com

$$\bar{x}_1 \mathbf{1} = 2 \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix}, \quad \mathbf{d}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix} - \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}.$$

Para a variável X_2 , temos

$$\mathbf{x}_2 = \bar{x}_2 \mathbf{1} + \mathbf{d}_2,$$

com

$$\bar{x}_2 \mathbf{1} = 3 \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 3 \\ 3 \\ 3 \end{bmatrix}, \quad \mathbf{d}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} - \begin{bmatrix} 3 \\ 3 \\ 3 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}.$$

Portanto, a decomposição final fica:

$$\mathbf{x}_1 = \begin{bmatrix} 2 \\ 2 \\ 2 \end{bmatrix} + \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 3 \\ 3 \\ 3 \end{bmatrix} + \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

Essa decomposição mostra a ideia discutida de que cada vetor de dados pode ser escrito como a soma de uma parte totalmente alinhada com o vetor de uns (a média) e uma parte ortogonal a ele (os desvios).

1.5.3 Variância amostral e a norma do vetores de desvios

Na seção anterior, introduzimos o vetor de desvios como a parte do vetor de dados que representa o quanto cada observação se afasta da média. Cada entrada de $\mathbf{d}_k$ mede, portanto, essa distância individual em relação à média $\bar{x}_k$. Naturalmente, surge a seguinte questão: como podemos resumir em um único número o “tamanho global” dessas variações em torno da média? A resposta está na **variância amostral**. Ela nada mais é do que uma medida associada ao comprimento (norma) do vetor de desvios. Quanto maior for a norma de $\mathbf{d}_k$, maior será a variabilidade dos dados da variável X_k em torno da sua média. Essa é justamente a ideia central por trás da variância, i.e., transformar a informação de todos os desvios em uma medida única de dispersão.

Definição 1.22: Variância amostral

Considere uma pesquisa interessada em estudar as variáveis $X_1, X_2, \dots, X_p$. Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k calculamos a *variância amostral* σ_{kk} da seguinte maneira

$$s_{kk} := \frac{1}{n} \|\mathbf{d}_k\|^2 = \frac{1}{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2, \quad k = 1, 2, \dots, p.$$

Em outras palavras, a variância amostral da variável X_k é proporcional ao quadrado da norma do seu vetor de desvios em relação à média.

É importante destacar três pontos sobre o cálculo da variância amostral:

1. **Divisor n vs $n - 1$:** Embora tenhamos usado n no denominador, muitos livros utilizam $n - 1$. Essa diferença é especialmente relevante quando trabalhamos com poucos dados (pequeno n), pois o termo $n - 1$ corrige uma tendência de subestimação da variância real da população. As duas versões da variância amostral serão sempre diferenciada.
2. **Notação s_{kk} :** Quando organizamos as variâncias de múltiplas variáveis em uma matriz (ver próximo capítulo), usamos a notação s_{kk} para a variância da k -ésima variável. Isso ajuda a identificar claramente a posição de cada medida na tabela, mantendo a equivalência $s_k^2 = s_{kk}$. Por exemplo, numa pesquisa com peso (X_1) e altura (X_2), teríamos s_{11} para a variância dos pesos e s_{22} para a variância das alturas.
3. **Desvio-padrão $\sqrt{s_{kk}}$:** Enquanto a variância (s_{kk}) mede a dispersão nos dados em

unidades ao quadrado (ex.: cm^2 se medirmos altura), o *desvio padrão* ($\sqrt{s_{kk}}$) traz essa medida de volta para a escala original dos dados (cm, no caso da altura), o permite uma comparação direta com os dados originais.

Assim, pensar a variância como proporcional ao tamanho do vetor de desvios ajuda a enxergar a interpretação geométrica: vetores de desvios mais longos representam variabilidade maior, enquanto vetores mais curtos representam dados mais concentrados em torno da média.

Exemplo 1.23

Considere o mesmo problema do Exemplo 1.21, no qual observamos as variáveis X_1 (saldo da conta bancária, em milhares de reais) e X_2 (valor da fatura do cartão de crédito, em milhares de reais) em $n = 3$ indivíduos. Os vetores de observações relativos às variáveis são, respectivamente,

$$\mathbf{x}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

- (a) Para cada uma das variáveis, determine o tamanho do vetor de desvios.
- (b) Utilize o item (a), para encontrar a variância amostral e o desvio-padrão amostral de cada variável.
- (c) Qual variável apresenta maior variabilidade? Essa comparação da variabilidade das duas variáveis é justa? Por quê?

SOLUÇÃO:

- (a) Os vetores de desvios são dados por

$$\mathbf{d}_k = \mathbf{x}_k - \bar{x}_k \mathbf{1}, \quad k = 1, 2.$$

Para a variável X_1 , temos

$$\bar{x}_1 = \frac{4 + (-1) + 3}{3} = 2.$$

Logo,

Exemplo 1.23

$$\mathbf{d}_1 = \begin{bmatrix} 4 - 2 \\ -1 - 2 \\ 3 - 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}.$$

Assim, o tamanho do vetor de desvios é

$$\|\mathbf{d}_1\| = \sqrt{2^2 + (-3)^2 + 1^2} = \sqrt{14}.$$

Para a variável X_2 temos

$$\bar{x}_2 = \frac{1 + 3 + 5}{3} = 3.$$

Logo,

$$\mathbf{d}_2 = \begin{bmatrix} 1 - 3 \\ 3 - 3 \\ 5 - 3 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}.$$

Assim, o tamanho do vetor de desvios é

$$\|\mathbf{d}_2\| = \sqrt{(-2)^2 + 0^2 + 2^2} = \sqrt{8}.$$

(b) A variância amostral é dada por

$$s_{kk} = \frac{1}{n} \|\mathbf{d}_k\|^2, \quad k = 1, 2,$$

e o desvio-padrão amostral por

$$\sqrt{s_{kk}} = \frac{1}{\sqrt{n}} \|\mathbf{d}_k\|.$$

Para X_1 :


$$s_{11} = \frac{1}{3}(14) = \frac{14}{3} \approx 4,67, \quad \sqrt{s_{11}} = \frac{1}{\sqrt{3}}\sqrt{14} \approx 2,16.$$

Para X_2 :

$$s_{22} = \frac{1}{3}(8) = \frac{8}{3} \approx 2,67, \quad \sqrt{s_{22}} = \frac{1}{\sqrt{3}}\sqrt{8} \approx 1,63.$$

Exemplo 1.23

- (c) Comparando as variâncias e desvios-padrão, concluímos que a variável X_1 (saldo da conta bancária) apresenta maior variabilidade do que X_2 (valor da fatura do cartão). No entanto, essa comparação não é inteiramente justa porque as duas variáveis estão medidas na *mesma unidade* (milhares de reais), mas poderiam estar em escalas diferentes. Por isso, em situações gerais, é comum utilizar medidas relativas como o *coeficiente de variação*.

Comparação dos comprimentos dos vetores de desvios**Exemplo 1.24**

Considere o mesmo problema do Exemplo 1.19, no qual observamos as variáveis X_1 (valor de mercado atual da casa, em milhares de reais) e X_2 (tamanho da casa, em m^2) em $n = 3$ diferentes indivíduos. Para esses indivíduos, os vetores de observações relativos às variáveis são, respectivamente,

$$\mathbf{x}_1 = \begin{bmatrix} 400 \\ 100 \\ 700 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 200 \\ 100 \\ 300 \end{bmatrix}.$$

- (a) Para cada uma das variáveis, determine o tamanho do vetor de desvios.

Exemplo 1.24

- (b) Utilize o item (a), para encontrar a variância amostral e o desvio-padrão amostral de cada variável.
- (c) Qual variável apresenta maior variabilidade? Essa comparação da variabilidade das duas variáveis é justa? Por quê?

SOLUÇÃO:

- (a) Os vetores de desvios são dados por

$$\mathbf{d}_k = \mathbf{x}_k - \bar{x}_k \mathbf{1}, \quad k = 1, 2.$$

Para a variável X_1 (valor de mercado da casa), temos

$$\bar{x}_1 = \frac{400 + 100 + 700}{3} = \frac{1200}{3} = 400.$$

Logo,

$$\mathbf{d}_1 = \begin{bmatrix} 400 - 400 \\ 100 - 400 \\ 700 - 400 \end{bmatrix} = \begin{bmatrix} 0 \\ -300 \\ 300 \end{bmatrix}.$$

Assim, o tamanho do vetor de desvios é

$$\|\mathbf{d}_1\| = \sqrt{0^2 + (-300)^2 + 300^2} = \sqrt{180.000} \approx 424,26.$$

Para a variável X_2 (tamanho da casa), temos

$$\bar{x}_2 = \frac{200 + 100 + 300}{3} = \frac{600}{3} = 200.$$

Logo,

$$\mathbf{d}_2 = \begin{bmatrix} 200 - 200 \\ 100 - 200 \\ 300 - 200 \end{bmatrix} = \begin{bmatrix} 0 \\ -100 \\ 100 \end{bmatrix}.$$

Assim, o tamanho do vetor de desvios é

$$\|\mathbf{d}_2\| = \sqrt{0^2 + (-100)^2 + 100^2} = \sqrt{20.000} \approx 141,42.$$

Exemplo 1.24

(b) A variância amostral é dada por

$$s_{kk} = \frac{1}{n} \|d_k\|^2, \quad k = 1, 2,$$

e o desvio-padrão amostral por

$$\sqrt{s_{kk}} = \frac{1}{\sqrt{n}} \|d_k\|.$$

Para X_1 :


$$s_{11} = \frac{1}{3}(180.000) = 60.000, \quad \sqrt{s_{11}} = \frac{1}{\sqrt{3}}(424.26) \approx 244,95.$$

Para X_2 :

$$s_{22} = \frac{1}{3}(20.000) = 6.666,67, \quad \sqrt{s_{22}} = \frac{1}{\sqrt{3}}(141.42) \approx 81,65.$$

(c)

Comparação dos comprimentos dos vetores de desvios de X_1 e X_2



Comparando as duas variáveis, observamos que X_1 (valor de mercado da casa) apresenta maior variabilidade, tanto pela variância quanto pelo desvio-padrão.

Exemplo 1.24

No entanto, essa comparação direta não é justa, pois as duas variáveis estão em *unidades e escalas diferentes*: X_1 está em milhares de reais, enquanto X_2 está em metros quadrados. Variâncias maiores podem simplesmente refletir a unidade de medida utilizada e não necessariamente maior dispersão relativa. Para uma comparação justa, é necessário recorrer a medidas adimensionais, como o *coeficiente de variação*.

1.5.4 Covariância amostral e o produto interno entre vetores de desvios

Na seção anterior, vimos que a variância amostral de uma variável X_k pode ser entendida como uma medida da intensidade dos desvios em relação à média, isto é, estava diretamente associada à norma do vetor de desvios $\mathbf{d}_k$. Essa interpretação geométrica mostra que quanto maior for o comprimento de $\mathbf{d}_k$, maior será a variabilidade da variável.

Um passo natural agora é estudar a relação entre duas variáveis, digamos X_i e X_k . Para isso, em vez de considerar apenas o tamanho de um vetor de desvios, analisamos o *produto interno* entre dois vetores de desvios, $\mathbf{d}_i$ e $\mathbf{d}_k$. Do ponto de vista geométrico, o produto interno está ligado ao *ângulo* entre os vetores: se eles apontam em direções semelhantes, o produto interno será positivo; se apontam em direções opostas, será negativo; e se forem ortogonais, o produto interno será nulo. Do ponto de vista estatístico, essa ideia se conecta diretamente à noção de *covariância*, que mede a tendência da nuvem de pontos em um diagrama de dispersão: valores positivos indicam que as variáveis tendem a crescer juntas, valores negativos indicam que uma cresce enquanto a outra diminui, e valores próximos de zero sugerem ausência de relação linear.

Definição 1.23: Covariância amostral

Considere uma pesquisa interessada em estudar as variáveis $X_1, X_2, \dots, X_p$. Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k , calculamos a *covariância amostral* entre duas dessas variáveis, digamos X_i e X_k , da seguinte maneira

$$s_{ik} := \frac{1}{n} \mathbf{d}_i^\top \mathbf{d}_k = \frac{1}{n} \sum_{j=1}^n (x_{ji} - \bar{x}_i)(x_{jk} - \bar{x}_k),$$

em que $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$. Em outras palavras, a covariância amostral

Definição 1.23

entre as variáveis X_i e X_k é proporcional ao produto interno dos seus vetores de desvios d_i e d_k .




Figura 1.14. A covariância amostral e o ângulo entre os vetores de desvios. O ângulo agudo entre os vetores de desvios implica que o produto interno entre eles será positivo e a nuvem de dispersão terá tendência crescente. O ângulo reto entre os vetores de desvios implica que o produto interno será zero e a nuvem de dispersão não terá um padrão linear evidente. O ângulo obtuso entre os vetores de desvios implica que o produto interno entre eles será negativo e a nuvem de dispersão terá tendência decrescente.

Exemplo 1.25

Considere o mesmo problema do Exemplo 1.21, no qual observamos as variáveis X_1 (saldo da conta bancária, em milhares de reais) e X_2 (valor da fatura do cartão de crédito, em milhares de reais) em $n = 3$ indivíduos. Os vetores de observações relativos às variáveis são, respectivamente,

$$\mathbf{x}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

- (a) Determine o produto interno entre os vetores de desvios associados às variáveis X_1 e X_2 . Apresente a interpretação geométrica do valor obtido.

Exemplo 1.25

- (b) Utilize o item (a), para encontrar a covariância amostral entre X_1 e X_2 . Apresente a interpretação estatística do valor obtido.
- (c) Represente em um plano cartesiano dos vetores desvios associados às variáveis X_1 e X_2 .
- (d) Faça o diagrama de dispersão relativo às variáveis X_1 e X_2 , i.e., represente, em um sistema de coordenadas de E^2 , os vetores de observações referentes às unidades amostrais.

SOLUÇÃO:

- (a) Primeiramente, calculamos os vetores de desvios de cada variável.

Para X_1 (saldo da conta bancária), temos

$$\bar{x}_1 = \frac{4 + (-1) + 3}{3} = \frac{6}{3} = 2.$$

Logo,

$$\mathbf{d}_1 = \begin{bmatrix} 4 - 2 \\ -1 - 2 \\ 3 - 2 \end{bmatrix} = \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}.$$

Para X_2 (valor da fatura do cartão de crédito), temos

$$\bar{x}_2 = \frac{1 + 3 + 5}{3} = \frac{9}{3} = 3.$$

Logo,

$$\mathbf{d}_2 = \begin{bmatrix} 1 - 3 \\ 3 - 3 \\ 5 - 3 \end{bmatrix} = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}.$$

O produto interno entre os vetores de desvios é

$$\mathbf{d}_1^\top \mathbf{d}_2 = (2)(-2) + (-3)(0) + (1)(2) = -4 + 0 + 2 = -2.$$

Interpretação: O produto interno negativo indica que os vetores de desvios formam um ângulo *obtusos*.


Exemplo 1.25

(b) A covariância amostral é dada por

$$s_{12} = \frac{1}{n} \mathbf{d}_1^\top \mathbf{d}_2 = \frac{1}{3}(-2) = -\frac{2}{3}.$$

Interpretação: O valor negativo da covariância amostral sugere que se existir uma relação linear entre as variáveis X_1 e X_2 a nuvem de dispersão terá uma tendência decrescente.


(c)



Observação: A figura ilustra a ideia de ângulo obtuso entre os vetores, consistente com o produto interno negativo.

(d)

Fatura do cartão de crédito



Observação: O diagrama de dispersão que outras medidas devem ser calculadas para estar mais certos da tendência linear da nuvem de dispersão.

Exemplo 1.26

Considere o mesmo problema do Exemplo 1.19, no qual observamos as variáveis X_1 (valor de mercado atual da casa, em milhares de reais) e X_2 (tamanho da casa, em m^2) em $n = 3$ diferentes indivíduos. Para esses indivíduos, os vetores de observações relativos às variáveis são, respectivamente,

$$\mathbf{x}_1 = \begin{bmatrix} 400 \\ 100 \\ 700 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 200 \\ 100 \\ 300 \end{bmatrix}.$$

- Determine o produto interno entre os vetores de desvios associados às variáveis X_1 e X_2 . Apresente a interpretação geométrica do valor obtido.
- Utilize o item (a), para encontrar a covariância amostral entre X_1 e X_2 . Apresente a interpretação estatística do valor obtido.
- Represente em um plano cartesiano dos vetores desvios associados às variáveis X_1 e X_2 .
- Faça o diagrama de dispersão relativo às variáveis X_1 e X_2 , i.e., represente, em um sistema de coordenadas de E^2 , os vetores de observações referentes às unidades amostrais.

SOLUÇÃO:

- (a) Primeiro, determinamos as médias amostrais:

$$\bar{x}_1 = \frac{400 + 100 + 700}{3} = 400, \quad \bar{x}_2 = \frac{200 + 100 + 300}{3} = 200.$$

Os vetores de desvios em relação às médias são

$$\mathbf{d}_1 = \begin{bmatrix} 400 - 400 \\ 100 - 400 \\ 700 - 400 \end{bmatrix} = \begin{bmatrix} 0 \\ -300 \\ 300 \end{bmatrix}, \quad \mathbf{d}_2 = \begin{bmatrix} 200 - 200 \\ 100 - 200 \\ 300 - 200 \end{bmatrix} = \begin{bmatrix} 0 \\ -100 \\ 100 \end{bmatrix}.$$

O produto interno entre eles é

$$\mathbf{d}_1^\top \mathbf{d}_2 = 0 \cdot 0 + (-300)(-100) + (300)(100) = 60.000.$$

Exemplo 1.26


Interpretação: O produto interno positivo indica que os vetores de desvios formam um ângulo *agudo*.

(b) A covariância amostral é proporcional a esse produto interno, i.e.,

$$s_{12} = \frac{1}{n} \mathbf{d}_1^\top \mathbf{d}_2 = \frac{1}{3} \cdot 60.000 = 20.000.$$

Interpretação: O valor positivo da covariância amostral sugere que se existir uma relação linear entre as variáveis X_1 e X_2 a nuvem de dispersão terá uma tendência crescente.


(c)



Observação: A figura ilustra a ideia de ângulo agudo entre os vetores, consistente com o produto interno positivo.

(d)

Valor de mercado (R\$ mil/100)



1.5.5 Correlação amostral e o cosseno do ângulo entre vetores de desvios

Na seção anterior, vimos que a covariância entre duas variáveis pode ser interpretada como o produto interno entre os respectivos vetores de desvios em relação às suas médias. Agora, vamos um passo além: ao normalizar esse produto interno pelos comprimentos (normas) dos vetores envolvidos, obtemos uma medida adimensional que indica o grau de alinhamento entre esses vetores. Essa medida é a *correlação amostral*, que pode ser interpretada geometricamente como o *cosseno do ângulo* θ_{ik} formado entre os vetores de desvios $\mathbf{d}_i$ e $\mathbf{d}_k$.

Definição 1.24: Correlação amostral

Considere uma pesquisa interessada em estudar as variáveis $X_1, X_2, \dots, X_p$. Quando coletamos n medições $x_{1k}, x_{2k}, \dots, x_{nk}$ da variável X_k , calculamos a **correlação amostral** entre duas dessas variáveis, digamos X_i e X_k , da seguinte maneira

$$r_{ik} := \cos(\theta_{ik}) = \frac{\mathbf{d}_i^\top \mathbf{d}_k}{\|\mathbf{d}_i\| \|\mathbf{d}_k\|} = \frac{s_{ik}}{\sqrt{s_{ii}} \sqrt{s_{kk}}},$$

em que $i = 1, 2, \dots, p$ e $k = 1, 2, \dots, p$. Em outras palavras, a correlação amostral entre as variáveis X_i e X_k é o cosseno do ângulo θ_{ik} entre os respectivos **vetores de desvios** $\mathbf{d}_i$ e $\mathbf{d}_k$.

O coeficiente de correlação é uma versão padronizada da covariância onde o produto das raízes quadradas das variâncias fornece a padronização. Observe que a *correlação amostral* r_{ik} possui o mesmo valor se n ou $n - 1$ é escolhido como o divisor comum para s_{ii} , s_{kk} e s_{ik} .

Do ponto de vista geométrico, a correlação mede o grau de alinhamento dos vetores $\mathbf{d}_i$ e $\mathbf{d}_k$ sobre uma mesma reta suporte:

- valores próximos de 1 indicam que os vetores são quase colineares (quase possuem a mesma reta suporte) e apontam para o mesmo sentido;
- valores próximos de -1 indicam que os vetores são quase colineares (quase possuem a mesma reta suporte), mas apontam para sentidos opostos;
- valores próximos de 0 sugerem que os vetores são quase ortogonais, ou seja, não apresentam alinhamento evidente.

Do ponto de vista estatístico, a correlação mede a tendência linear da nuvem de dispersão formada pelas observações das variáveis X_i e X_k :

- valores próximos de 1 indicam concentração dos pontos em torno de uma reta *crescente*;
- valores próximos de -1 indicam concentração dos pontos em torno de uma reta *decrecente*;
- valores próximos de 0 indicam ausência de tendência linear evidente, com os pontos dispersos sem padrão direcional claro.

Embora os sinais da correlação e da covariância sejam os mesmos, a correlação é geralmente mais fácil de interpretar porque sua magnitude é limitada. Para resumir, a correlação r_{ik} entre duas variáveis X_i e X_k tem as seguintes propriedades:

- $r_{ik} = +1$: relação linear perfeita positiva;
- $0 < r_{ik} < 1$: relação linear positiva;
- $r_{ik} \approx 0$: ausência de relação linear;
- $-1 < r_{ik} < 0$: relação linear negativa;
- $r_{ik} = -1$: relação linear perfeita negativa.

Neste texto, desde que mencionado o contrário, vamos assumir as seguintes interpretações para a correlação r (populacional ou amostral) entre duas variáveis:

Tabela 1.1. Convenção a respeito da interpretação da magnitude da correlação amostral.

Intervalo	Força	Interpretação
$0,9 \leq r \leq 1,0$	Muito forte	Relação linear quase perfeita
$0,7 \leq r < 0,9$	Forte	Relação linear evidente
$0,5 \leq r < 0,7$	Moderada	Relação linear perceptível
$0,3 \leq r < 0,5$	Fraca	Relação linear tênue
$0,0 \leq r < 0,3$	Muito fraca	Relação linear desprezível

É importante ressaltar que em áreas como física, correlações abaixo de 0,9 podem ser consideradas “fracas”, enquanto em ciências sociais, acima de 0,5 já são significativas. Os valores da Tabela 1.1 são apenas referenciais, sempre considere o tamanho da amostra (n), um teste de significância (p -valor) e uma análise gráfica (gráfico de dispersão).

A covariância e correlação são como “óculos para enxergar relações lineares” – elas só detectam padrões retilíneos entre variáveis e podem ser enganadas por dados atípicos.

Associações não-lineares podem existir e não serem reveladas por essas estatísticas descritivas. Mesmo com essas limitações, quando usadas no contexto certo (dados sem padrões complexos nem valores extremos), oferecem uma medida numérica valiosa para entender como variáveis se relacionam.

Exemplo 1.27

Considere o mesmo problema do Exemplo 1.21, no qual observamos as variáveis X_1 (saldo da conta bancária, em milhares de reais) e X_2 (valor da fatura do cartão de crédito, em milhares de reais) em $n = 3$ indivíduos. Os vetores de observações relativos às variáveis são, respectivamente,

$$\mathbf{x}_1 = \begin{bmatrix} 4 \\ -1 \\ 3 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix}.$$

- Determine o cosseno do ângulo θ_{12} entre os vetores de desvios associados às variáveis X_1 e X_2 . Apresente a interpretação geométrica do valor obtido.
- Utilize o item (a), para encontrar a correlação amostral entre as variáveis X_1 e X_2 . Interprete o valor obtido. Apresente a interpretação estatística do valor obtido.
- Comente o gráfico com os vetores de desvios e o diagrama de dispersão construídos no Exemplo 1.25.

SOLUÇÃO:

- Do Exemplo 1.21, segue que os vetores de desvios em relação às médias são

$$\mathbf{d}_1 = \begin{bmatrix} 2 \\ -3 \\ 1 \end{bmatrix}, \quad \mathbf{d}_2 = \begin{bmatrix} -2 \\ 0 \\ 2 \end{bmatrix}.$$

O cosseno do ângulo θ_{12} entre esses vetores é dado por

$$\cos(\theta_{12}) = \frac{\mathbf{d}_1^\top \mathbf{d}_2}{\|\mathbf{d}_1\| \|\mathbf{d}_2\|}.$$

Exemplo 1.27

Calculamos

$$\mathbf{d}_1^\top \mathbf{d}_2 = (2)(-2) + (-3)(0) + (1)(2) = -2,$$

$$\|\mathbf{d}_1\| = \sqrt{2^2 + (-3)^2 + 1^2} = \sqrt{14},$$

$$\|\mathbf{d}_2\| = \sqrt{(-2)^2 + 0^2 + 2^2} = \sqrt{8}.$$

Portanto,

$$\cos(\theta_{12}) = \frac{-2}{\sqrt{14} \cdot \sqrt{8}} = \frac{-2}{\sqrt{112}} \approx -0,189.$$

Geometricamente, isso indica que os vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$ formam um ângulo obtuso, ou seja, possuem tendência de apontar em direções opostas.

(b) A correlação amostral entre X_1 e X_2 é dada exatamente por

$$r_{12} = \cos(\theta_{12}) \approx -0,189.$$

Do ponto de vista estatístico, esse valor sugere que a nuvem de dispersão formada pelas observações de X_1 e X_2 possui uma *tendência linear decrescente desprezível (muito fraca)*.

(c) No gráfico dos vetores de desvios (Exemplo 1.25), observamos que $\mathbf{d}_1$ e $\mathbf{d}_2$ não estão ortogonais, mas formam um ângulo ligeiramente obtuso, confirmando o valor negativo da correlação. Já no diagrama de dispersão das variáveis X_1 e X_2 , a disposição dos pontos sugere uma relação levemente decrescente, mas sem padrão linear evidente, o que é coerente com a interpretação estatística obtida no item anterior.

Exemplo 1.28

Considere o mesmo problema do Exemplo 1.19, no qual observamos as variáveis X_1 (valor de mercado atual da casa, em milhares de reais) e X_2 (tamanho da casa, em m^2) em $n = 3$ diferentes indivíduos. Para esses indivíduos, os vetores de observações relativos às variáveis são, respectivamente,

Exemplo 1.28

$$\mathbf{x}_1 = \begin{bmatrix} 400 \\ 100 \\ 700 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 200 \\ 100 \\ 300 \end{bmatrix}.$$

- (a) Determine o cosseno do ângulo θ_{12} entre os vetores de desvios associados às variáveis X_1 e X_2 . Apresente a interpretação geométrica do valor obtido.
- (b) Utilize o item (a), para encontrar a correlação amostral entre as variáveis X_1 e X_2 . Interprete o valor obtido. Apresente a interpretação estatística do valor obtido.
- (c) Comente o gráfico com os vetores de desvios e o diagrama de dispersão construídos no Exemplo 1.26.

SOLUÇÃO:

- (a) Primeiro, calculamos as médias amostrais:

$$\bar{x}_1 = \frac{400 + 100 + 700}{3} = 400, \quad \bar{x}_2 = \frac{200 + 100 + 300}{3} = 200.$$

Os vetores de desvios em relação às médias são

$$\mathbf{d}_1 = \begin{bmatrix} 400 - 400 \\ 100 - 400 \\ 700 - 400 \end{bmatrix} = \begin{bmatrix} 0 \\ -300 \\ 300 \end{bmatrix}, \quad \mathbf{d}_2 = \begin{bmatrix} 200 - 200 \\ 100 - 200 \\ 300 - 200 \end{bmatrix} = \begin{bmatrix} 0 \\ -100 \\ 100 \end{bmatrix}.$$

O cosseno do ângulo θ_{12} entre esses vetores é dado por

$$\cos(\theta_{12}) = \frac{\mathbf{d}_1^\top \mathbf{d}_2}{\|\mathbf{d}_1\| \|\mathbf{d}_2\|}.$$

Temos

$$\begin{aligned} \mathbf{d}_1^\top \mathbf{d}_2 &= (0)(0) + (-300)(-100) + (300)(100) = 60.000, \\ \|\mathbf{d}_1\| &= \sqrt{0^2 + (-300)^2 + 300^2} = \sqrt{180.000}, \\ \|\mathbf{d}_2\| &= \sqrt{0^2 + (-100)^2 + 100^2} = \sqrt{20.000}. \end{aligned}$$

Logo,

Exemplo 1.28

$$\cos(\theta_{12}) = \frac{60.000}{\sqrt{180.000} \cdot \sqrt{20.000}} = \frac{60.000}{60.000} = 1.$$

Geometricamente, isso significa que os vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$ são colineares e apontam para o mesmo sentido.

(b) A correlação amostral entre X_1 e X_2 é dada por


$$r_{12} = \cos(\theta_{12}) = 1.$$

Do ponto de vista estatístico, isso indica que as variáveis X_1 e X_2 apresentam uma associação linear perfeita e positiva: a nuvem de dispersão se concentra exatamente em uma reta de inclinação positiva.


(c) No gráfico dos vetores de desvios (Exemplo 1.26), observamos que $\mathbf{d}_1$ e $\mathbf{d}_2$ são múltiplos exatos um do outro, confirmando a colinearidade e o valor $\cos(\theta_{12}) = 1$. Já no diagrama de dispersão, os pontos estão perfeitamente alinhados sobre uma reta crescente, ilustrando de maneira clara a correlação linear perfeita entre as duas variáveis, i.e., $r_{12} = 1$.

Querido leitor, finalizo esta seção com um alerta sobre algumas possibilidades de diagramas de dispersão quando $r_{12} \approx 0$. Como já mencionamos, quando a correlação amostral é próxima de zero, a nuvem de dispersão não possui uma tendência linear perceptível. Isso pode significar:


- (i) os pontos apresentarem um padrão não-linear;
- (ii) os pontos não apresentarem nenhum padrão evidente; ou
- (iii) os pontos se concentrarem em torno de uma reta constante.



(i) Padrão não-linear



(ii) Sem padrão



(iii) Reta constante

1.6 Distâncias entre vetores e a Estatística

Caro e gentil leitor, nesta seção, exploraremos como a noção geométrica de *distância entre vetores* se conecta de forma natural com problemas estatísticos práticos. Ao considerar uma amostra de observações de variáveis quantitativas, cada indivíduo pode ser representado por um vetor em $\mathbb{R}^p$, como, por exemplo, $\mathbf{x}^{(j)} = [x_{j1} \ x_{j2} \ \cdots \ x_{jp}]^\top$. A partir dessa representação, medidas de proximidade entre vetores permitem desenvolver métodos importantes em Estatística. Dois exemplos fundamentais são: (i) o *método do vizinho mais próximo*, no qual a classe de um novo indivíduo é prevista a partir da comparação de sua posição com os vetores de uma amostra conhecida, e (ii) a *detecção de outliers*, que pode ser feita avaliando a distância de um vetor de observações em relação ao vetor de médias amostrais $\bar{\mathbf{x}}$. A compreensão dessas ideias reforça a ponte entre conceitos algébricos de vetores e aplicações estatísticas, mostrando como noções geométricas podem fundamentar técnicas de análise de dados.

Não é objetivo deste autor apresentar tais métodos em todos os seus detalhes, mas sim em suas versões mais simples, de modo a exemplificar a relação entre a Álgebra Linear e a Estatística. Em cursos mais avançados, o leitor poderá se aprofundar e apreciar os aspectos mais refinados de cada método.

1.6.1 O método do vizinho mais próximo

O método do vizinho mais próximo é uma das formas mais simples e intuitivas de realizar *classificação estatística*. A ideia central é representar cada indivíduo da amostra como um vetor de observações em $\mathbb{R}^p$, isto é,

$$\mathbf{x}^{(j)} = \begin{bmatrix} x_{j1} \\ x_{j2} \\ \vdots \\ x_{jp} \end{bmatrix}, \quad j = 1, 2, \dots, n,$$

em que n é o número de indivíduos e p é o número de variáveis medidas. Cada vetor $\mathbf{x}^{(j)}$ está associado a uma classe conhecida, denotada por $y^{(j)} \in \{1, 2, \dots, C\}$, em que C é o número de classes possíveis.

Quando surge uma nova unidade, representado pelo vetor $\mathbf{x}^* \in \mathbb{R}^p$, cuja classe y^* é desconhecida, o procedimento consiste em calcular as distâncias entre $\mathbf{x}^*$ e cada vetor da amostra $\mathbf{x}^{(j)}$. A nova unidade será classificada na mesma classe de seu vizinho mais pró-

ximo, isto é, o vetor $\mathbf{x}^{(j)}$ que estiver mais próximo de $\mathbf{x}^*$ segundo uma métrica de distância, comumente a *distância Euclidiana*:

$$d(\mathbf{x}^*, \mathbf{x}^{(j)}) = \|\mathbf{x}^* - \mathbf{x}^{(j)}\| = \sqrt{\sum_{k=1}^p (x_k^* - x_{jk})^2}.$$




Figura 1.15. Ilustração do método do vizinho mais próximo em $\mathbb{R}^2$. Nesse caso, $\mathbf{x}^*$ é a mais próximo de $\mathbf{x}^{(2)}$.

Esse raciocínio pode ser estendido para considerar não apenas um, mas os k vizinhos mais próximos de $\mathbf{x}^*$, atribuindo sua classe por meio de uma votação majoritária. Entretanto, neste curso, apresentaremos o caso mais simples, em que $k = 1$, suficiente para ilustrar a relação entre noções geométricas de vetores e procedimentos estatísticos.

Exemplo 1.29

Considere o problema de classificação de clientes do iFood em duas categorias:

$$Y = \begin{cases} 1, & \text{se o cliente é Premium,} \\ 0, & \text{se o cliente é Econômico.} \end{cases}$$

Para cada cliente, foram medidas três variáveis descritivas:

- X_1 : número de refeições pedidas por semana;
- X_2 : valor gasto mensalmente no iFood (em reais);
- X_3 : número de pedidos realizados no mês.

A base amostral disponível contém $n = 8$ clientes, cujas informações estão sumariadas na tabela a seguir.

Exemplo 1.29

ID	Refeições/sem	Gasto mensal (R\$)	Pedidos/mês	Classe
1	4	850	85	1
2	5	900	90	1
3	6	700	70	1
4	4	750	75	1
5	8	250	25	0
6	9	300	30	0
7	7	200	20	0
8	8	400	40	0

O objetivo é prever se novos clientes são Premium ou Econômicos, a partir de seu perfil de consumo. Para isso, será utilizado o método do vizinho mais próximo, classificando cada novo cliente de acordo com a classe do cliente mais próximo da amostra em termos de distância Euclidiana.

Suponha que acompanhamos o perfil de compra de três novos clientes (próxima tabela), e desejamos classificá-los segundo essa regra de que clientes similares compartilham da mesma classe.

ID	Refeições/sem	Gasto mensal (R\$)	Pedidos/mês	Classe verdadeira
9	5	820	82	?
10	9	280	28	?
11	6	650	65	?

- Utilizando apenas a variável X_2 , classifique os três novos clientes de acordo com o método do vizinho mais próximo.
- Utilizando as variáveis X_1 e X_2 , classifique os três novos clientes de acordo com o método do vizinho mais próximo.
- Compare as distâncias obtidos no item (a) com aquelas obtidas no item (b) e comente sobre o poder de decisão de cada variável no processo de classificação.

SOLUÇÃO:

- Utilizando apenas a variável X_2 (gasto mensal no iFood), a distância Euclidiana entre dois clientes i e j é

Exemplo 1.29

$$d(x_2^{(i)}, x_2^{(j)}) = |x_2^{(i)} - x_2^{(j)}|.$$

Cliente 9: $x_2^{(9)} = 820$. Calculamos

$$d(x_2^{(j)}, x_2^{(9)}) = |x_{j2} - 820|, \quad j = 1, 2, \dots, 8.$$

Cliente	$d(x_2^{(j)}, x_2^{(9)})$	Classe
$x^{(1)}$	30	1
$x^{(2)}$	80	1
$x^{(3)}$	120	1
$x^{(4)}$	70	1
$x^{(5)}$	570	0
$x^{(6)}$	520	0
$x^{(7)}$	620	0
$x^{(8)}$	420	0

O cliente 9 está mais próximo do cliente 1, logo classificamos o cliente 9 como **Premium** (classe 1).

Cliente 10: $x_2^{(10)} = 280$. Calculamos

$$d(x_2^{(j)}, x_2^{(10)}) = |x_{j2} - 280|, \quad j = 1, 2, \dots, 8.$$

Cliente	$d(x_2^{(j)}, x_2^{(10)})$	Classe
$x^{(1)}$	570	1
$x^{(2)}$	620	1
$x^{(3)}$	420	1
$x^{(4)}$	470	1
$x^{(5)}$	30	0
$x^{(6)}$	20	0
$x^{(7)}$	80	0
$x^{(8)}$	120	0

O cliente 10 está mais próximo do cliente 6, logo classificamos o cliente 10 como

Exemplo 1.29

Econômico (classe 0).

Cliente 11: $x_2^{(11)} = 650$. Calculamos

$$d(x_2^{(j)}, x_2^{(11)}) = |x_{j2} - 650|, \quad j = 1, 2, \dots, 8.$$

Cliente	$d(x_2^{(j)}, x_2^{(11)})$	Classe
$x^{(1)}$	200	1
$x^{(2)}$	250	1
$x^{(3)}$	50	1
$x^{(4)}$	100	1
$x^{(5)}$	400	0
$x^{(6)}$	350	0
$x^{(7)}$	450	0
$x^{(8)}$	250	0

O cliente 11 está mais próximo do cliente 3, logo classificamos o cliente 11 como **Premium** (classe 1).

Assim, as classificações previstas com base apenas em X_2 são:

Cliente	Classe prevista
9	1
10	0
11	1

- (b) Utilizando as variáveis X_1 (refeições por semana) e X_2 (gasto mensal), representamos cada cliente pelo vetor bidimensional

$$\mathbf{x}^{(j)} = \begin{bmatrix} x_{j1} \\ x_{j2} \end{bmatrix}.$$

A distância Euclidiana entre $\mathbf{x}^{(j)}$ e um novo cliente $\mathbf{x}^{(*)}$ é

$$d(\mathbf{x}^{(j)}, \mathbf{x}^{(*)}) = \sqrt{(x_{j1} - x_1^*)^2 + (x_{j2} - x_2^*)^2}.$$

Exemplo 1.29

Cliente 9: $\mathbf{x}^{(9)} = \begin{bmatrix} 5 \\ 820 \end{bmatrix}$.

$$d(\mathbf{x}^{(j)}, \mathbf{x}^{(9)}) = \sqrt{(x_{j1} - 5)^2 + (x_{j2} - 820)^2}.$$

Cliente	$d(x_2^{(j)}, x_2^{(9)})$	$d(\mathbf{x}^{(j)}, \mathbf{x}^{(9)})$	Classe
$x^{(1)}$	30	30,02	1
$x^{(2)}$	80	80,00	1
$x^{(3)}$	120	120,00	1
$x^{(4)}$	70	70,01	1
$x^{(5)}$	570	570,01	0
$x^{(6)}$	520	520,03	0
$x^{(7)}$	620	620,01	0
$x^{(8)}$	420	420,01	0

O cliente 9 está mais próximo do cliente 1, logo classificamos o cliente 9 como **Premium** (classe 1).

Cliente 10: $\mathbf{x}^{(10)} = \begin{bmatrix} 9 \\ 280 \end{bmatrix}$.

$$d(\mathbf{x}^{(j)}, \mathbf{x}^{(10)}) = \sqrt{(x_{j1} - 9)^2 + (x_{j2} - 280)^2}.$$

Cliente	$d(x_2^{(j)}, x_2^{(10)})$	$d(\mathbf{x}^{(j)}, \mathbf{x}^{(10)})$	Classe
$x^{(1)}$	570	570,02	1
$x^{(2)}$	620	620,01	1
$x^{(3)}$	420	420,01	1
$x^{(4)}$	470	470,03	1
$x^{(5)}$	30	30,02	0
$x^{(6)}$	20	20,00	0
$x^{(7)}$	80	80,02	0
$x^{(8)}$	120	120,00	0

Exemplo 1.29

O cliente 10 está mais próximo do cliente 6, logo classificamos o cliente 10 como **Econômico** (classe 0).

Cliente 11: $\mathbf{x}^{(11)} = \begin{bmatrix} 6 \\ 650 \end{bmatrix}$.

$$d(\mathbf{x}^{(j)}, \mathbf{x}^{(11)}) = \sqrt{(x_{j1} - 6)^2 + (x_{j2} - 650)^2}.$$

Cliente	$d(x_2^{(j)}, x_2^{(11)})$	$d(\mathbf{x}^{(j)}, \mathbf{x}^{(11)})$	Classe
$x^{(1)}$	200	200,01	1
$x^{(2)}$	250	250,00	1
$x^{(3)}$	50	50,00	1
$x^{(4)}$	100	100,02	1
$x^{(5)}$	400	400,00	0
$x^{(6)}$	350	350,01	0
$x^{(7)}$	450	450,00	0
$x^{(8)}$	250	250,00	0

O cliente 11 está mais próximo do cliente 3, logo classificamos o cliente 11 como **Premium** (classe 1).

Assim, as classificações previstas com base em X_1 e X_2 são:

Cliente	Classe prevista
9	1
10	0
11	1

(c) Comparando os resultados obtidos:

- Utilizando apenas X_2 (gasto mensal), os três novos clientes foram classificados corretamente: cliente 9 como Premium, cliente 10 como Econômico e cliente 11 como Premium.
- Utilizando X_1 e X_2 em conjunto, as classificações permaneceram as mesmas, mas os valores das distâncias mudaram apenas ligeiramente.

Exemplo 1.29

A razão para isso está na diferença de escala entre as variáveis. Enquanto X_1 varia em valores pequenos (número de refeições por semana), X_2 assume valores muito maiores (gasto mensal em reais). Assim, a contribuição de X_2 domina o cálculo da distância Euclidiana, fazendo com que ele tenha maior poder de decisão no processo de classificação. Em resumo, neste exemplo, a variável X_2 exerce mais influência não porque seja necessariamente mais informativa, mas porque sua escala é maior. Isso ilustra a importância da *padronização das variáveis* em métodos baseados em distância, para evitar que variáveis em maior escala predominem artificialmente na classificação.

Considere que observamos uma amostra de tamanho n da variável X_k , cujas observações são $x_{1k}, x_{2k}, \dots, x_{nk}$. Definimos a versão *padronizada* dessa variável como

$$z_{jk} = \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}}, \quad j = 1, 2, \dots, n,$$

em que $\bar{x}_k$ é a média amostral de X_k e s_{kk} é a variância amostral de X_k .

Nesse caso, a média amostral da variável padronizada é $\bar{z}_k = 0$ e a variância amostral é $s_{kk}(z) = 1$. De fato, por um lado

$$\bar{z}_k = \frac{1}{n} \sum_{j=1}^n z_{jk} = \frac{1}{n} \sum_{j=1}^n \frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}} = \frac{1}{\sqrt{s_{kk}}} \cdot \frac{1}{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k).$$

Como $\sum_{j=1}^n (x_{jk} - \bar{x}_k) = 0$, concluímos que

$$\bar{z}_k = 0.$$

Por outro lado, a variância amostral da variável padronizada é

$$s_{kk}(z) = \frac{1}{n} \sum_{j=1}^n (z_{jk} - \bar{z}_k)^2.$$

Como $\bar{z}_k = 0$, temos

$$s_{kk}(z) = \frac{1}{n} \sum_{j=1}^n z_{jk}^2.$$

Substituindo a definição de z_{jk} , temos

$$s_{kk}(z) = \frac{1}{n} \sum_{j=1}^n \left(\frac{x_{jk} - \bar{x}_k}{\sqrt{s_{kk}}} \right)^2 = \frac{1}{s_{kk}} \cdot \frac{1}{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2.$$

Mas, pela definição de s_{kk} , temos $\frac{1}{n} \sum_{j=1}^n (x_{jk} - \bar{x}_k)^2 = s_{kk}$. Logo, $s_{kk}(z) = \frac{s_{kk}}{s_{kk}} = 1$.

Exemplo 1.30

Considere o mesmo problema do Exemplo 1.29. Classifique os novos clientes utilizando o método do vizinho mais próximos e as variáveis X_1 e X_2 padronizadas. É possível observar uma contribuição mais significativa da variável X_1 no processo de classificação após a padronização?

SOLUÇÃO:

Considere os três novos clientes do Exemplo 1.29, agora representados pelas variáveis padronizadas Z_1 e Z_2 . O vetor do cliente i será denotado por

$$\mathbf{z}^{(i)} = \begin{bmatrix} z_{i1} \\ z_{i2} \end{bmatrix}.$$

A distância Euclidiana entre dois clientes j e i é dada por

$$d(\mathbf{z}^{(j)}, \mathbf{z}^{(i)}) = \sqrt{(z_{j1} - z_{i1})^2 + (z_{j2} - z_{i2})^2}.$$

Cliente 9: $\mathbf{z}^{(9)} = \begin{bmatrix} -0,72 \\ 0,97 \end{bmatrix}.$

Cliente	$d(z_2^{(j)}, z_2^{(9)})$	$d(\mathbf{z}^{(j)}, \mathbf{z}^{(9)})$	Classe
$z^{(1)}$	0,10	0,53	1
$z^{(2)}$	0,28	0,28	1
$z^{(3)}$	0,42	0,67	1
$z^{(4)}$	0,24	0,57	1
$z^{(5)}$	1,99	2,53	0
$z^{(6)}$	1,82	2,76	0
$z^{(7)}$	2,17	2,41	0
$z^{(8)}$	1,47	2,14	0

Mais próximo de $z^{(2)}$, logo o cliente 9 é classificado como **Premium**.

Exemplo 1.30

Cliente 10: $z^{(10)} = \begin{bmatrix} 1, 89 \\ -0, 92 \end{bmatrix}$.

Cliente	$d(z_2^{(j)}, z_2^{(10)})$	$d(z^{(j)}, z^{(10)})$	Classe
$z^{(1)}$	1,99	3,70	1
$z^{(2)}$	2,17	3,39	1
$z^{(3)}$	1,47	2,55	1
$z^{(4)}$	1,64	3,53	1
$z^{(5)}$	0,10	1,05	0
$z^{(6)}$	0,07	0,52	0
$z^{(7)}$	0,28	1,59	0
$z^{(8)}$	0,42	1,12	0

Mais próximo de $z^{(6)}$, logo o cliente 10 é classificado como **Econômico**.

Cliente 11: $z^{(11)} = \begin{bmatrix} -0, 20 \\ 1, 14 \end{bmatrix}$.

Cliente	$d(z_2^{(j)}, z_2^{(11)})$	$d(z^{(j)}, z^{(11)})$	Classe
$z^{(1)}$	0,07	1,04	1
$z^{(2)}$	0,10	0,53	1
$z^{(3)}$	0,59	0,59	1
$z^{(4)}$	0,42	1,12	1
$z^{(5)}$	2,17	2,41	0
$z^{(6)}$	1,99	2,53	0
$z^{(7)}$	2,34	2,40	0
$z^{(8)}$	1,64	1,95	0

Mais próximo de $z^{(2)}$, logo o cliente 11 é classificado como **Premium**.

Resumo das classificações:

Cliente	Classe prevista
9	1
10	0
11	1

Exemplo 1.30

Conclusão: Embora a acurácia tenha se mantido (todos foram corretamente classificados), agora observamos uma *contribuição mais equilibrada da variável X_1* no cálculo das distâncias. Isso ocorre porque, após a padronização, ambas as variáveis passaram a ter média zero e variância um, de modo que a diferença de escalas deixou de influenciar o processo. Assim, X_1 participa de forma mais significativa na definição das similaridades entre os clientes.

Exemplo 1.31

Considere o mesmo problema do Exemplo 1.29. Classifique os novos clientes utilizando o método do vizinho mais próximos e as variáveis X_2 e X_3 padronizadas. Discuta sobre a contribuição de ambas as variáveis no processo de classificação.

SOLUÇÃO:

Cliente 9:

$$\mathbf{z}^{(9)} = \begin{bmatrix} 0,97 \\ 0,97 \end{bmatrix}.$$

Calculando a **distância Euclidiana** nos dados padronizados:

$$d(\mathbf{z}^{(j)}, \mathbf{z}^{(9)}) = \sqrt{(z_{j2} - 0,97)^2 + (z_{j3} - 0,97)^2},$$

para todos os clientes $j = 1, 2, \dots, 8$.

Cliente	$d(z_2^{(j)}, z_2^{(9)})$	$d(\mathbf{z}^{(j)}, \mathbf{z}^{(9)})$	Classe
$\mathbf{z}^{(1)}$	0,10	$\sqrt{2} \times 0,10$	1
$\mathbf{z}^{(2)}$	0,28	$\sqrt{2} \times 0,28$	1
$\mathbf{z}^{(3)}$	0,42	$\sqrt{2} \times 0,42$	1
$\mathbf{z}^{(4)}$	0,24	$\sqrt{2} \times 0,24$	1
$\mathbf{z}^{(5)}$	1,99	$\sqrt{2} \times 1,99$	0
$\mathbf{z}^{(6)}$	1,82	$\sqrt{2} \times 1,82$	0
$\mathbf{z}^{(7)}$	2,17	$\sqrt{2} \times 2,17$	0
$\mathbf{z}^{(8)}$	1,47	$\sqrt{2} \times 1,47$	0

O cliente 9 está mais próximo do cliente 1, portanto classificamos 9 como **Premium** (mesma classe do cliente 1).

Exemplo 1.31**Cliente 10:**

$$\mathbf{z}^{(10)} = \begin{bmatrix} -0,92 \\ -0,92 \end{bmatrix}.$$

De modo análogo, obtemos que o cliente 10 está mais próximo do cliente 6, portanto classificamos 10 como **Econômico** (mesma classe do cliente 6).

Cliente 11:

$$\mathbf{z}^{(11)} = \begin{bmatrix} 1,14 \\ 1,14 \end{bmatrix}.$$

Nesse caso, o cliente 11 está mais próximo do cliente 2, portanto classificamos 11 como **Premium** (mesma classe do cliente 2).

Resumo das predições:

Cliente	Classe prevista
9	1
10	0
11	1

Discussão: Embora tenhamos incluído as duas variáveis X_2 (gasto mensal) e X_3 (número de pedidos/mês), é importante notar que elas são *múltiplas uma da outra*. Isso implica que a distância considerando (X_2, X_3) nada mais é do que a distância em X_2 , multiplicada por uma constante. Assim, a classificação obtida é exatamente a mesma de quando utilizamos apenas X_2 . Portanto, neste exemplo, a variável X_3 não adiciona nova informação ao processo de classificação: o poder discriminatório continua vindo exclusivamente de X_2 .

No exemplo analisado, observamos um caso de *colinearidade perfeita*, em que $X_i = \alpha X_k$ para algum escalar $\alpha \neq 0$. Nesse caso, os vetores de desvios $\mathbf{d}_i$ e $\mathbf{d}_k$ são múltiplos um do outro, o que significa que ambos estão sobre a mesma reta suporte no espaço vetorial. Em termos geométricos, o cosseno do ângulo entre eles é ± 1 , implicando que X_i e X_k são perfeitamente correlacionadas (colineares). Como consequência, essas variáveis fornecem exatamente o mesmo tipo de informação no processo de classificação, não sendo necessário utilizá-las simultaneamente.

Vale destacar que em métodos como a *regressão linear* (veremos em breve), a presença de variáveis colineares pode ser particularmente problemática, pois gera instabilidade nas estimativas dos coeficientes. Na prática, dificilmente temos variáveis *perfeitamente* cor-

relacionadas, mas é comum encontrarmos pares de variáveis com *alta correlação*. Detectar e tratar esse tipo de relação é essencial para a aplicação adequada de métodos estatísticos multivariados.

1.6.2 Detecção de *outliers*

Além de nos auxiliar em problemas de classificação, as medidas de distância também podem ser utilizadas para a *detecção de outliers*. De forma intuitiva, um *outlier* é uma observação que se afasta do padrão geral dos dados, ou seja, um ponto que está muito distante da região em que se concentram a maioria das observações. No contexto multivariado, diremos que uma observação é um *outlier* quando o seu vetor de observações $\mathbf{x}^*$ está muito distante do *vetor de médias* $\bar{\mathbf{x}}$ da amostra.

No caso bidimensional ($\mathbb{R}^2$), quando analisamos duas variáveis, um *outlier* corresponde a um ponto na nuvem de dispersão que se encontra muito longe do centro (média amostral). Para formalizar essa ideia, utilizaremos duas métricas: a *distância Euclidiana* e a *distância de Mahalanobis*. A distância Euclidiana mede a separação geométrica padrão entre dois pontos, enquanto a distância de Mahalanobis leva em conta a *variabilidade dos dados* em cada direção. Por hora, não vamos considerar a covariância no cálculo da distância de Mahalanobis. No próximo capítulo, veremos a versão mais geral dessa medida utilizando a matriz de variâncias e covariâncias amostrais.

Em alguns casos, pontos que parecem ser *outliers* pela distância Euclidiana podem não ser considerados discrepantes pela distância de Mahalanobis, justamente porque esta última pondera as distâncias de acordo com a variabilidade de cada variável. Ao longo desta seção, exploraremos essas duas medidas e veremos como elas ajudam a identificar, de maneira mais ou menos refinada, possíveis pontos discrepantes em um conjunto de dados.

Começemos pela situação mais simples, em que observamos apenas uma variável X . Seja uma amostra de tamanho n , com média amostral $\bar{x}$. Intuitivamente, diremos que um ponto x^* é um *outlier* quando estiver muito distante do centro dos dados, isto é, da média amostral.

Uma forma de quantificar essa ideia é por meio da *distância Euclidiana* entre a observação x^* e a média $\bar{x}$, i.e.,

$$d(x^*, \bar{x}) = |x^* - \bar{x}|.$$

Dessa forma, estabelecemos um critério prático: classificamos x^* como um *outlier* quando

$$d(x^*, \bar{x}) = |x^* - \bar{x}| > c,$$

em que $c > 0$ é um *limiar* previamente fixado. Equivalentemente, podemos definir a seguinte região de decisão:

$$\mathcal{B}_c(\bar{x}) = \{x \in \mathbb{R} : |x - \bar{x}| \leq c\} = (\bar{x} - c, \bar{x} + c).$$

Quando $x^* \in \mathcal{B}_c(\bar{x})$, então x^* é dito ser um *ponto típico*, caso contrário é dito um *outlier*. Nesse caso, $\mathcal{B}_c(\bar{x})$ trata-se de um *intervalo*. O limiar c pode ser escolhido de acordo com o contexto, por exemplo, em termos de quantidades de desvios-padrão ou de faixas consideradas aceitáveis para a variável em estudo.

Embora seja um critério simples, ele traduz bem a ideia geométrica de *outlier* no caso univariado: pontos que se afastam muito da média devem ser analisados com cuidado, pois podem representar erros de medição, registros atípicos ou informações relevantes que destoam do padrão principal dos dados.

Exemplo 1.31

Considere as notas (em uma escala de 0 a 10) de cinco estudantes em uma prova de Estatística:

$$x_1 = 7, \quad x_2 = 6, \quad x_3 = 8, \quad x_4 = 7, \quad x_5 = 2.$$

Para $c = 3$, existe alguma nota atípica (*outlier*)? Em caso afirmativo, represente graficamente a região de decisão $\mathcal{B}_c(\bar{x})$ e marque esse ponto em vermelho.

SOLUÇÃO:

A média amostral é

$$\bar{x} = \frac{7 + 6 + 8 + 7 + 2}{5} = 6.$$

A distância Euclidiana de cada observação em relação à média é dada por


$$|x_j - \bar{x}|, \quad j = 1, 2, \dots, 5.$$

A tabela a seguir sumariza tais distâncias.

Estudante	Nota	Distância $ x_j - \bar{x} $
1	7	1
2	6	0
3	8	2
4	7	1
5	2	4

Exemplo 1.31

Para $c = 3$, x^* é considerado um *outlier* quando $|x^* - \bar{x}| > 3$. Como apenas a nota do estudante 5 ($x_5 = 2$) apresenta distância maior do que 3, concluímos que esse ponto é um ponto atípico.



No caso em que temos duas variáveis, isto é, $\mathbf{x} \in \mathbb{R}^2$, a detecção de outliers pode ser feita a partir da distância Euclidiana entre cada ponto e o vetor de médias amostral $\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix}$. Fixando um valor $c > 0$, um ponto $\mathbf{x}^*$ é dito ser um *outlier* quando

$$d(\mathbf{x}^*, \bar{\mathbf{x}}) = \sqrt{(x_1^* - \bar{x}_1)^2 + (x_2^* - \bar{x}_2)^2} > c,$$

ou, equivalentemente, quando

$$(x_1^* - \bar{x}_1)^2 + (x_2^* - \bar{x}_2)^2 > c^2.$$




Figura 1.16. Detecção de *outlier* em $\mathbb{R}^2$ por meio da distância Euclidiana.

Assim, a região de decisão, nesse caso, é dada pelo conjunto

$$\mathcal{B}_c(\bar{\mathbf{x}}) := \left\{ \mathbf{x} \in \mathbb{R}^2 : (x_1 - \bar{x}_1)^2 + (x_2 - \bar{x}_2)^2 \leq c^2 \right\}.$$

Esse conjunto $\mathcal{B}_c(\bar{\mathbf{x}}) \subset \mathbb{R}^2$ corresponde a um *círculo* centrado em $\bar{\mathbf{x}}$, com raio c . Assim, classificamos como *outliers* todos os pontos que estiverem fora desse círculo, ou seja, para os quais $\|\mathbf{x} - \bar{\mathbf{x}}\| > c$.

De forma mais geral, em $\mathbb{R}^p$, vale o mesmo raciocínio, i.e., a região de decisão trata-se do conjunto dos pontos que estão até distância c do vetor de médias é dado por

$$\mathcal{B}_c(\bar{\mathbf{x}}) := \left\{ \mathbf{x} \in \mathbb{R}^p : \|\mathbf{x} - \bar{\mathbf{x}}\|^2 \leq c^2 \right\},$$

o que corresponde a uma *hiperesfera* centrada em $\bar{\mathbf{x}} \in \mathbb{R}^p$ com raio c .

Exemplo 1.32

Considere a amostra bidimensional formada pelas observações

$$\mathbf{x}^{(1)} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \quad \mathbf{x}^{(3)} = \begin{bmatrix} 4 \\ 3 \end{bmatrix}, \quad \mathbf{x}^{(4)} = \begin{bmatrix} 5 \\ 4 \end{bmatrix}, \quad \mathbf{x}^{(5)} = \begin{bmatrix} 10 \\ 10 \end{bmatrix}.$$

Para $c = 3$, existe algum ponto atípico (*outlier*) em $\mathbb{R}^2$? Em caso afirmativo, represente graficamente a região de decisão $\mathcal{B}_c(\bar{\mathbf{x}})$ e marque esse ponto em vermelho.

SOLUÇÃO:

O vetor de médias amostral é

$$\bar{\mathbf{x}} = \begin{bmatrix} \frac{2+3+4+5+10}{5} \\ \frac{2+1+3+4+10}{5} \end{bmatrix} = \begin{bmatrix} 4, 8 \\ 4, 0 \end{bmatrix}.$$


A distância Euclidiana de cada observação em relação à média é dada por

$$d(\mathbf{x}^{(j)}, \bar{\mathbf{x}}) = \sqrt{(x_{j1} - \bar{x}_1)^2 + (x_{j2} - \bar{x}_2)^2}, \quad j = 1, 2, \dots, 5.$$

Como pode ser observado na tabela a seguir apenas a observação $\mathbf{x}^{(5)} = \begin{bmatrix} 10 \\ 10 \end{bmatrix}$ apresenta distância maior do que $c = 3$, concluímos que esse ponto é um *outlier*.

Exemplo 1.32

Indivíduo	x_{j1}	x_{j2}	Distância $d(x_j, \bar{x})$
1	2	2	3,61
2	3	1	3,25
3	4	3	1,08
4	5	4	0,20
5	10	10	8,38



A distância Euclidiana é bastante intuitiva, porém apresenta uma limitação importante: ela é sensível à *escala das variáveis*. Se uma variável apresenta valores em uma ordem de grandeza maior do que outra, a contribuição dessa variável será dominante no cálculo da distância. Na Figura 1.17, ilustramos esse problema. O eixo X apresenta uma escala muito maior do que o eixo Y . Como consequência, pontos que estão longe apenas na direção de X (mas que são típicos na direção de Y) acabam caindo fora do círculo de decisão (região verde), sendo erroneamente considerados *outliers* apenas devido à diferença de escala.

Uma forma de contornar esse problema é *padronizar as variáveis*, ou seja, transformá-las de modo que passem a ter média zero e variância um. Em seguida, calculamos a distância Euclidiana entre as variáveis padronizadas, o que garante que cada variável contribua proporcionalmente no processo de detecção de *outliers*. Essa ideia está diretamente relacionada ao conceito de *distância de Mahalanobis*, que veremos a seguir.




Figura 1.17. O efeito da escala das variáveis no processo de detecção de *outliers* com a distância Euclidiana.

No caso em que temos duas variáveis, isto é, $\mathbf{x} \in \mathbb{R}^2$, podemos considerar a sua versão *padronizada* como sendo o vetor $\mathbf{z} \in \mathbb{R}^2$ tal que $z_j := (x_j - \bar{x})/\sqrt{s_{jj}}$. Nesse contexto, a detecção de *outliers* pode ser feita a partir da distância Euclidiana entre cada ponto e o vetor de médias amostral $\bar{\mathbf{z}} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$. Fixando um valor $c > 0$, um ponto $\mathbf{z}^*$ é dito ser um *outlier* quando

$$d(\mathbf{z}^*, \bar{\mathbf{z}}) = \sqrt{(z_1^* - 0)^2 + (z_2^* - 0)^2} > c,$$

ou, equivalentemente, quando

$$(z_1^*)^2 + (z_2^*)^2 > c^2 \Leftrightarrow \left(\frac{x_1^* - \bar{x}_1}{\sqrt{s_{11}}} \right)^2 + \left(\frac{x_2^* - \bar{x}_2}{\sqrt{s_{22}}} \right)^2 > c^2.$$

Assim, a região de decisão, nesse caso, é dada pelo conjunto


$$\mathcal{B}_c(\bar{\mathbf{x}}) := \left\{ \mathbf{x} \in \mathbb{R}^2 : \left(\frac{x_1^* - \bar{x}_1}{\sqrt{s_{11}}} \right)^2 + \left(\frac{x_2^* - \bar{x}_2}{\sqrt{s_{22}}} \right)^2 \leq c^2 \right\}.$$

Esse conjunto $\mathcal{B}_c(\bar{\mathbf{x}}) \subset \mathbb{R}^2$ corresponde a uma *ellipse* centrada em $\bar{\mathbf{x}}$, com eixos $\pm c\sqrt{s_{11}}$ e $\pm c\sqrt{s_{22}}$. Assim, classificamos como *outliers* todos os pontos que estiverem fora dessa elipse, ou seja, para os quais $\|\mathbf{z}\| > c$.

De forma mais geral, em $\mathbb{R}^p$, vale o mesmo raciocínio. A região de decisão é o conjunto dos pontos que estão até distância c do vetor de médias padronizado, i.e.,

$$\mathcal{B}_c(\bar{\mathbf{x}}) := \left\{ \mathbf{x} \in \mathbb{R}^p : \|\mathbf{z} - \bar{\mathbf{z}}\|^2 \leq c^2 \right\},$$

o que corresponde a um *elipsóide* centrado em $\bar{\mathbf{x}} \in \mathbb{R}^p$ com raio eixos da forma $\pm c\sqrt{s_{ii}}$.



Definição 1.25: Distância de Mahalanobis

Considere uma amostra $\mathbf{x}^{(1)}, \dots, \mathbf{x}^{(n)} \in \mathbb{R}^2$, cuja média amostral é

$$\bar{\mathbf{x}} = \begin{bmatrix} \bar{x}_1 \\ \bar{x}_2 \end{bmatrix} \in \mathbb{R}^2,$$

com $s_{11} > 0$ representando a variância amostral relativa à variável X_1 , $s_{22} > 0$ a variância amostral relativa à variável X_2 e $s_{12} = 0$ a covariância amostral entre X_1 e X_2 . A *distância de Mahalanobis* de uma nova observação $\mathbf{x}^* \in \mathbb{R}^2$ em relação ao vetor de médias $\bar{\mathbf{x}} \in \mathbb{R}^2$ é definida por

$$d_M(\mathbf{x}^*, \bar{\mathbf{x}}) = \sqrt{\left(\frac{x_1^* - \bar{x}_1}{\sqrt{s_{11}}}\right)^2 + \left(\frac{x_2^* - \bar{x}_2}{\sqrt{s_{22}}}\right)^2}.$$

Note que, nesse caso particular em que $s_{12} = 0$, a distância de Mahalanobis coincide com a distância Euclidiana calculada nas *variáveis padronizadas* Z_1 e Z_2 , isto é, após cada variável ser centralizada por sua média amostral e dividida pelo seu desvio-padrão amostral. No caso que a amostra é observada em $\mathbb{R}^p$, temos

$$d_M(\mathbf{x}^*, \bar{\mathbf{x}}) = \|\mathbf{z}^* - \bar{\mathbf{z}}\|.$$

Exemplo 1.33

Considere o mesmo problema do Exemplo 1.32, no qual temos uma amostra

Exemplo 1.33

bidimensional formada pelas observações

$$\mathbf{x}^{(1)} = \begin{bmatrix} 2 \\ 2 \end{bmatrix}, \quad \mathbf{x}^{(2)} = \begin{bmatrix} 3 \\ 1 \end{bmatrix}, \quad \mathbf{x}^{(3)} = \begin{bmatrix} 4 \\ 3 \end{bmatrix}, \quad \mathbf{x}^{(4)} = \begin{bmatrix} 5 \\ 4 \end{bmatrix}, \quad \mathbf{x}^{(5)} = \begin{bmatrix} 10 \\ 10 \end{bmatrix}.$$

Para $c = 3$, existe algum ponto atípico (*outlier*) em $\mathbb{R}^2$? Use a distância de Mahalanobis para tomar sua decisão. Em caso afirmativo, represente graficamente a região de decisão $\mathcal{B}_c(\bar{\mathbf{x}})$ e marque esse ponto em vermelho.

SOLUÇÃO: O vetor de médias amostral é

$$\bar{\mathbf{x}} = \begin{bmatrix} 4,8 \\ 4,0 \end{bmatrix}.$$

As variâncias individuais são

$$s_{11} = \frac{1}{4} \sum_{i=1}^5 (x_{i1} - \bar{x}_1)^2 = \frac{31,2}{4} = 7,8, \quad s_{22} = \frac{1}{4} \sum_{i=1}^5 (x_{i2} - \bar{x}_2)^2 = \frac{54}{4} = 13,5.$$

Padronizando cada observação,

$$z_{ij} = \frac{x_{ij} - \bar{x}_j}{\sqrt{s_{jj}}},$$

temos

$$\mathbf{z}^{(1)} \approx \begin{bmatrix} -1,00 \\ -0,54 \end{bmatrix}, \quad \mathbf{z}^{(2)} \approx \begin{bmatrix} -0,64 \\ -0,82 \end{bmatrix}, \quad \mathbf{z}^{(3)} \approx \begin{bmatrix} -0,29 \\ -0,27 \end{bmatrix}, \quad \mathbf{z}^{(4)} \approx \begin{bmatrix} 0,07 \\ 0,00 \end{bmatrix}, \quad \mathbf{z}^{(5)} \approx \begin{bmatrix} 1,86 \\ 1,63 \end{bmatrix}.$$

Como não estamos considerando a covariância no cálculo da distância de Mahalanobis, ela se reduz à norma Euclidiana no espaço padronizado. Logo,

$$d_M(\mathbf{x}^{(1)}, \bar{\mathbf{x}}) = \|\mathbf{z}^{(1)}\| \approx 1,14,$$

$$d_M(\mathbf{x}^{(2)}, \bar{\mathbf{x}}) = \|\mathbf{z}^{(2)}\| \approx 1,03,$$

$$d_M(\mathbf{x}^{(3)}, \bar{\mathbf{x}}) = \|\mathbf{z}^{(3)}\| \approx 0,40,$$


$$d_M(\mathbf{x}^{(4)}, \bar{\mathbf{x}}) = \|\mathbf{z}^{(4)}\| \approx 0,07,$$

$$d_M(\mathbf{x}^{(5)}, \bar{\mathbf{x}}) = \|\mathbf{z}^{(5)}\| \approx 2,48.$$

Como $d_M(\mathbf{x}^{(i)}, \bar{\mathbf{x}}) < c = 3$ para todos os pontos, concluímos que nenhum deles é

Exemplo 1.33

atípico. A região de decisão $\mathcal{B}_c(\bar{\mathbf{x}})$ corresponde a uma elipse centrada em $\bar{\mathbf{x}} = \begin{bmatrix} 4, 8 \\ 4, 0 \end{bmatrix}$ com eixo menor sendo $\pm 3\sqrt{7,8}$ e eixo maior sendo $\pm 3\sqrt{13,5}$.



No Exemplo 1.32, quando utilizamos a distância Euclidiana no processo de detecção de *outliers*, o ponto $\mathbf{x}^{(5)}$ foi considerado atípico. Entretanto, no Exemplo 1.33, ao utilizarmos a distância de Mahalanobis, esse mesmo ponto não foi classificado como *outlier*. A razão está no fato de que a distância de Mahalanobis leva em consideração a variabilidade de cada variável: como X_2 apresenta variabilidade maior do que X_1 , o maior eixo da elipse de decisão é orientado na direção de X_2 , enquanto o menor eixo está na direção de X_1 . Dessa forma, $\mathbf{x}^{(5)}$ permanece dentro da região de decisão $\mathcal{B}_c(\bar{\mathbf{x}})$.

Outro ponto importante é que a utilização da distância de Mahalanobis também resolve o problema de *escala* entre as variáveis, já mencionado anteriormente. Enquanto a distância Euclidiana trata todas as variáveis na mesma unidade de medida, a distância de Mahalanobis leva em consideração as variâncias individuais, ajustando adequadamente o impacto de cada componente no cálculo da distância. A Figura 1.18 ilustra essa diferença. Na abordagem Euclidiana, a região de decisão é uma circunferência, enquanto na abordagem de Mahalanobis ela se transforma em uma elipse, adaptada à dispersão e escala dos dados em cada direção.




Figura 1.18. O efeito da escala das variáveis no processo de detecção de *outliers* com a distância de Mahalanobis sem considerar a covariância das variáveis.

1.7 Dependência e independência linear

Nesta seção, estudaremos os conceitos de *dependência* e *independência linear* entre vetores, fundamentais para compreender a estrutura de espaços vetoriais como $\mathbb{R}^n$. A partir dessas definições, será possível discutir a noção de *base* e de *conjunto gerador*, elementos que permitem caracterizar completamente o espaço vetorial. Além da interpretação geométrica, essas ideias possuem conexões diretas com a Estatística, em especial na análise de *multicolinearidade*, quando algumas variáveis explicativas podem ser expressas como combinações lineares de outras, afetando de forma significativa a estimação de modelos de regressão e a interpretação dos resultados.

Definição 1.26: Dois vetores linearmente dependentes em $\mathbb{R}^n$

Os vetores $\mathbf{x}_1 \in \mathbb{R}^n$ e $\mathbf{x}_2 \in \mathbb{R}^n$ são ditos *linearmente dependentes* quando existem duas constantes reais c_1 e c_2 , ambas diferentes de zero, tais que

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 = \mathbf{0}.$$

Em outras palavras, $\mathbf{x}_1$ e $\mathbf{x}_2$ estão sobre a *mesma reta suporte* (mesma direção), uma vez que são múltiplos um do outro

$$\mathbf{x}_2 = -\frac{c_1}{c_2} \mathbf{x}_1.$$

Definição 1.27: Dois vetores independentes em $\mathbb{R}^n$

Os vetores $\mathbf{x}_1 \in \mathbb{R}^n$ e $\mathbf{x}_2 \in \mathbb{R}^n$ são ditos *linearmente independentes* quando *não estão sobre a mesma reta suporte*, isto é, *não possuem a mesma direção*. Nesse caso, não é possível escrever

$$\mathbf{x}_2 = c \mathbf{x}_1,$$

com c uma constante real não nula e, portanto, o sistema linear

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 = \mathbf{0}$$

só possui a *solução trivial*, i.e., $c_1 = c_2 = 0$.




Figura 1.19. Dois vetores dependentes e dois vetores independentes em $\mathbb{R}^2$.

Como vimos, geometricamente, vetores linearmente dependentes possuem a mesma direção, isto é, estão sobre a mesma reta suporte ou em retas paralelas. Portanto, o ângulo θ entre dois vetores linearmente dependentes só pode assumir dois valores: $\theta = 0$, quando os vetores apontam no mesmo sentido, ou $\theta = \pi$, quando apontam em sentidos opostos. Consequentemente, o cosseno do ângulo entre dois vetores linearmente dependentes é $\cos(\theta) = 1$, no caso de mesmo sentido, ou $\cos(\theta) = -1$, no caso de sentidos contrários.

Por outro lado, quando os vetores são linearmente independentes, o ângulo θ entre eles pode assumir qualquer valor entre 0 e π , de modo que o cosseno associado satisfaz $-1 < \cos(\theta) < 1$, diferente de ± 1 . Nesse contexto, destaca-se a noção de ortogonalidade: se dois vetores $\mathbf{x}_1$ e $\mathbf{x}_2$ em $\mathbb{R}^n$ são ortogonais, então $\mathbf{x}_1^\top \mathbf{x}_2 = 0$, o que implica $\cos(\theta) = 0$, de forma que o ângulo entre eles é reto. Assim, vetores ortogonais são necessariamente linearmente independentes. No entanto, a recíproca não é verdadeira, pois vetores linearmente independentes não precisam ser ortogonais (veja Figura 1.19)




Figura 1.20. Casos de dependência linear: mesmo sentido, sentidos opostos e independência ortogonal.

Exemplo 1.34

(a) Considere os seguintes pares de vetores do $\mathbb{R}^2$:

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

São $\mathbf{x}_1$ e $\mathbf{x}_2$ **L.D.** ou **L.I.**? Represente-os graficamente.

(b) Considere os seguintes pares de vetores do $\mathbb{R}^2$:

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$

São $\mathbf{x}_1$ e $\mathbf{x}_2$ **L.D.** ou **L.I.**? Represente-os graficamente.

(c) Considere os seguintes pares de vetores do $\mathbb{R}^2$:

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$

São $\mathbf{x}_1$ e $\mathbf{x}_2$ **L.D.** ou **L.I.**? Represente-os graficamente.

(d) Considere os seguintes pares de vetores do $\mathbb{R}^2$:

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

Exemplo 1.34


Os vetores canônicos $\mathbf{e}_1$ e $\mathbf{e}_2$ do $\mathbb{R}^2$ são **L.D.** ou **L.I.**? Represente-os graficamente.

SOLUÇÃO:

(a) Temos

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 4 \end{bmatrix}.$$

Observa-se que $\mathbf{x}_2 = 2\mathbf{x}_1$, logo os vetores são *linearmente dependentes*. O ângulo entre eles é $\theta = 0$, de modo que $\cos(\theta) = 1$.



(b) Temos

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}.$$


Se fossem dependentes, existiriam c_1, c_2 não nulos tais que $c_1\mathbf{x}_1 + c_2\mathbf{x}_2 = 0$. O sistema

$$\begin{cases} c_1 + 2c_2 = 0 \\ c_1 + 3c_2 = 0 \end{cases}$$

tem solução única $c_1 = c_2 = 0$, logo os vetores são *linearmente independentes*.

O cosseno do ângulo é

$$\cos(\theta) = \frac{\mathbf{x}_1^\top \mathbf{x}_2}{\|\mathbf{x}_1\| \|\mathbf{x}_2\|} = \frac{1 \cdot 2 + 1 \cdot 3}{\sqrt{1^2 + 1^2} \sqrt{2^2 + 3^2}} = \frac{5}{\sqrt{2} \sqrt{13}} \approx 0,98.$$



Exemplo 1.34

(c) Temos

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} -2 \\ 1 \end{bmatrix}.$$


Verificamos se existe relação linear: o sistema

$$\begin{cases} c_1 - 2c_2 = 0 \\ 2c_1 + c_2 = 0 \end{cases}$$

tem única solução $c_1 = c_2 = 0$, logo são *linearmente independentes*. O cosseno do ângulo é

$$\cos(\theta) = \frac{1 \cdot (-2) + 2 \cdot 1}{\sqrt{1^2 + 2^2} \sqrt{(-2)^2 + 1^2}} = \frac{0}{\sqrt{5} \sqrt{5}} = 0.$$

Assim, $\theta = \pi/2$, e os vetores são ortogonais.




(d) Os vetores canônicos

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

são *linearmente independentes*. Além disso,

$$\cos(\theta) = \frac{1 \cdot 0 + 0 \cdot 1}{\sqrt{1} \sqrt{1}} = 0,$$

o que implica $\theta = \pi/2$. Portanto, são *ortogonais*.



A ideia discutida até aqui para dois vetores pode ser naturalmente estendida para um conjunto de k vetores em $\mathbb{R}^n$. Quando analisamos se esses vetores são linearmente dependentes ou independentes, o problema pode ser visto como a busca de soluções para um sistema linear formado por n equações e k incógnitas, correspondentes aos coeficientes das combinações lineares dos vetores em questão. Assim, a verificação de dependência linear passa a ser equivalente à análise da existência de soluções não triviais para esse sistema, generalizando o raciocínio adotado no caso de apenas dois vetores.

Definição 1.28: Dependência linear de um conjunto de k vetores em $\mathbb{R}^n$

Um conjunto de vetores $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k\}$ do $\mathbb{R}^n$ é dito ser *linearmente dependente* (*L.D.*) quando existem k números reais $c_1, c_2, \dots, c_k$, não todos iguais a zero, tal que

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + \dots + c_k\mathbf{x}_k = \mathbf{0}.$$

Em outras palavras, ao menos um dos vetores pode ser escrito como *combinação linear* dos outros vetores. Se apenas a *solução trivial*

$$c_1 = c_2 = \dots = c_k = 0$$

satisfaz a equação, então o conjunto de vetores é dito ser *linearmente independente* (*L.I.*).

Vale notar que, em $\mathbb{R}^n$, com $n \geq 2$, dois vetores $\mathbf{x}_1$ e $\mathbf{x}_2$ são linearmente dependentes quando estão sobre a mesma reta suporte. De forma análoga, em $\mathbb{R}^n$, com $n \geq 3$, três vetores $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3$ são linearmente dependentes quando pertencem à mesma reta suporte (caso em que todos são múltiplos entre si) ou quando pertencem ao mesmo plano suporte, ainda que não estejam sobre a mesma reta. Já em $\mathbb{R}^n$, com $n \geq 4$, quatro vetores $\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3, \mathbf{x}_4$ são linearmente dependentes quando pertencem à mesma reta suporte, ou ao mesmo plano suporte, ou ainda a um hiperplano de dimensão 3, isto é, um subespaço de dimensão menor que 4, mas maior que 2. De modo mais geral, em $\mathbb{R}^n$, um conjunto de $k \leq n$ vetores é dito linearmente dependente quando eles pertencem a um subespaço de dimensão estritamente menor que k (e, portanto, menor que n). Por outro lado, qualquer conjunto de $k > n$ vetores em $\mathbb{R}^n$ é sempre linearmente dependente.

A razão pela qual esses fatos são verdadeiros está diretamente conectada à ideia de solução de sistemas lineares. Quando verificamos se um conjunto de vetores $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_k \in \mathbb{R}^n$ é linearmente dependente, estamos na prática resolvendo o sistema

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 + \cdots + c_k \mathbf{x}_k = \mathbf{0}.$$

Esse sistema é formado por n equações (uma para cada coordenada dos vetores) e k incógnitas (os coeficientes $c_1, c_2, \dots, c_k$). Se $k > n$, o número de incógnitas é maior que o número de equações, e portanto o sistema sempre admite soluções não triviais, o que implica que o conjunto é necessariamente linearmente dependente. Já quando $k \leq n$, a questão passa a ser se as equações fornecem ou não restrições suficientes para forçar a solução trivial $c_1 = c_2 = \cdots = c_k = 0$. Nesse caso, a dependência linear significa que as linhas do sistema não são todas independentes, ou seja, o conjunto de vetores pertence a um subespaço de dimensão estritamente menor que k . Dessa forma, a análise de dependência ou independência linear nada mais é do que a análise da existência de soluções não triviais em sistemas lineares.

Exemplo 1.35

(a) Mostre que os vetores do $\mathbb{R}^3$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$$

são *linearmente independentes*. Represente-os graficamente.

(b) Os vetores do $\mathbb{R}^3$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 5 \\ -1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}$$

são *linearmente dependentes*. Represente-os graficamente.

SOLUÇÃO:

(a) Para verificar se os vetores

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}$$

Exemplo 1.36


são linearmente dependentes, resolvemos o sistema

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 + c_3 \mathbf{x}_3 = \mathbf{0}.$$

Escrevendo as equações coordenada a coordenada:

$$\begin{cases} c_1 + c_2 + c_3 = 0, \\ 2c_1 - 2c_3 = 0, \\ c_1 - c_2 + c_3 = 0. \end{cases}$$

Da segunda equação, temos $c_1 = c_3$. Substituindo na primeira equação, segue que $c_1 + c_2 + c_1 = 0 \Rightarrow 2c_1 + c_2 = 0$. Da terceira equação, temos $c_1 - c_2 + c_1 = 0 \Rightarrow 2c_1 - c_2 = 0$. Somando as duas, vem que $4c_1 = 0 \Rightarrow c_1 = 0$. Logo $c_2 = 0$ e $c_3 = 0$. Assim, apenas a solução trivial existe, e os vetores são *linearmente independentes*.



(b) Agora consideremos os vetores

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 2 \\ 5 \\ -1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}.$$

Novamente resolvemos

$$c_1 \mathbf{x}_1 + c_2 \mathbf{x}_2 + c_3 \mathbf{x}_3 = \mathbf{0}.$$

Exemplo 1.37


Escrevendo

$$\begin{cases} c_1 + 2c_2 + 0c_3 = 0, \\ c_1 + 5c_2 + c_3 = 0, \\ c_1 - c_2 - c_3 = 0. \end{cases}$$

Da primeira equação, temos $c_1 = -2c_2$. Substituindo na segunda equação, segue que $-2c_2 + 5c_2 + c_3 = 0 \Rightarrow 3c_2 + c_3 = 0 \Rightarrow c_3 = -3c_2$. Na terceira equação, temos $-2c_2 - c_2 - (-3c_2) = 0$, que é satisfeita para qualquer c_2 . Logo, existe solução não trivial, por exemplo

$$c_1 = -2, \quad c_2 = 1, \quad c_3 = -3,$$

o que mostra que os vetores são *linearmente dependentes*.




Note que os vetores moram em um mesmo plano suporte que passa pela origem.

Em $\mathbb{R}^n$, os vetores canônicos são definidos por

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \quad \dots \quad \mathbf{e}_n = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}.$$

Cada vetor canônico possui um 1 em uma posição e zeros nas demais, representando as

direções dos eixos coordenados. Esses vetores são sempre *linearmente independentes*, uma vez que são ortogonais dois a dois.



Uma propriedade fundamental dos vetores canônicos é que eles *geram* todo o espaço $\mathbb{R}^n$. De fato, qualquer vetor $\mathbf{x} \in \mathbb{R}^n$ pode ser escrito como uma combinação linear dos vetores canônicos. Por exemplo, no caso $n = 2$,

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = x_1 \mathbf{e}_1 + x_2 \mathbf{e}_2.$$

qualquer que seja $x_1, x_2 \in \mathbb{R}$. Essa ideia se estende para qualquer dimensão, de forma que os vetores canônicos funcionam como “pilare” sobre os quais todo o espaço $\mathbb{R}^n$ é construído.

Definição 1.29: Base do $\mathbb{R}^n$

Um conjunto de vetores $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\} \in \mathbb{R}^n$ é chamado de *base* de $\mathbb{R}^n$ quando esses vetores são linearmente independentes.

Resultado 1.7

Se $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ é uma base do $\mathbb{R}^n$, então esse conjunto de vetores *gera* o $\mathbb{R}^n$, i.e.,

$$\text{span}(\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n) = \left\{ \sum_{i=1}^n \alpha_i \mathbf{x}_i : \alpha_i \in \mathbb{R} \right\} = \mathbb{R}^n.$$

Em outras palavras, qualquer vetor $\mathbf{x} \in \mathbb{R}^n$ pode ser escrito como uma *combinação linear* dos elementos da base, i.e., existe $\boldsymbol{\alpha} \in \mathbb{R}^n$ tal que

$$\mathbf{x} = \sum_{i=1}^n \alpha_i \mathbf{x}_i.$$

Resultado 1.7**DEMONSTRAÇÃO:**

Seja $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ uma base de $\mathbb{R}^n$. Por definição, isso significa que esses vetores são *linearmente independentes* e que o conjunto contém exatamente n vetores em $\mathbb{R}^n$. Como o espaço $\mathbb{R}^n$ tem dimensão n , qualquer que seja o conjunto $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n, \mathbf{x}\}$ terá $n + 1$ vetores. Como $n + 1 > n$ esse conjunto é *linearmente dependente*. Temos $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ L.I., portanto, para que $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n, \mathbf{x}\}$ seja L.D., só pode que $\mathbf{x}$ seja uma combinação linear de $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$. Como esse argumento vale para qualquer $\mathbf{x} \in \mathbb{R}^n$, o conjunto de n vetores linearmente independentes necessariamente *gera* o espaço. Assim, para todo vetor $\mathbf{x} \in \mathbb{R}^n$, existem escalares $\alpha_1, \alpha_2, \dots, \alpha_n \in \mathbb{R}$ tais que

$$\mathbf{x} = \alpha_1 \mathbf{x}_1 + \alpha_2 \mathbf{x}_2 + \dots + \alpha_n \mathbf{x}_n.$$

Resta mostrar a *unicidade* dessa representação. Suponha que existam dois conjuntos de coeficientes, $\alpha_1, \dots, \alpha_n$ e $\beta_1, \dots, \beta_n$, tais que

$$\mathbf{x} = \sum_{i=1}^n \alpha_i \mathbf{x}_i = \sum_{i=1}^n \beta_i \mathbf{x}_i.$$

Subtraindo as duas expressões, obtemos

$$\sum_{i=1}^n (\alpha_i - \beta_i) \mathbf{x}_i = \mathbf{0}.$$

Como os vetores $\mathbf{x}_1, \dots, \mathbf{x}_n$ são linearmente independentes, a única solução é

$$\alpha_i - \beta_i = 0 \quad \text{para todo } i,$$

isto é, $\alpha_i = \beta_i$ para todo $i = 1, \dots, n$.

Portanto, a decomposição de $\mathbf{x}$ como combinação linear da base é única, o que conclui a prova. ■

Exemplo 1.36

- (a) Os vetores canônicos $\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_n$ do $\mathbb{R}^n$ formam uma *base* do $\mathbb{R}^n$, denominada *base canônica* do $\mathbb{R}^n$.

Exemplo 1.36

(b) Os vetores do $\mathbb{R}^3$

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

formam uma base de $\mathbb{R}^3$?

SOLUÇÃO:

(a) É fácil ver que é verdade. Tente por si só!

(b) Para verificar se os vetores

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{x}_3 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}$$

formam uma base de $\mathbb{R}^3$, analisamos o sistema

$$c_1\mathbf{x}_1 + c_2\mathbf{x}_2 + c_3\mathbf{x}_3 = \mathbf{0}.$$

Escrevendo coordenada a coordenada:

$$c_1 \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} + c_3 \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}.$$

O que equivale ao sistema

$$\begin{cases} c_1 + c_3 = 0, \\ c_1 + c_2 = 0, \\ c_2 + c_3 = 0. \end{cases}$$

Da primeira equação temos $c_3 = -c_1$. Substituímos na segunda: $c_1 + c_2 = 0 \Rightarrow c_2 = -c_1$. Substituímos na terceira: $(-c_1) + (-c_1) = -2c_1 = 0 \Rightarrow c_1 = 0$.

Assim, $c_2 = c_3 = 0$ também. Logo, a única solução é a trivial

Exemplo 1.36

$$c_1 = c_2 = c_3 = 0.$$

Portanto, os vetores são *linearmente independentes*. Como temos três vetores L.I. em $\mathbb{R}^3$, eles formam uma *base* de $\mathbb{R}^3$.

A noção de *colinearidade* entre duas variáveis pode ser estendida para o caso de um conjunto maior de variáveis explicativas. Quando mais de duas variáveis estão fortemente associadas, de forma que uma delas pode ser aproximada como combinação linear das demais, dizemos que há *multicolinearidade*. Nesse contexto, o conjunto de vetores de desvios dessas variáveis se torna linearmente dependente, o que compromete a identificação única dos coeficientes em modelos de regressão múltipla. Em outras palavras, a multicolinearidade reflete a presença de redundância de informação entre variáveis explicativas, levando a instabilidade nas estimativas e dificuldades de interpretação dos modelos. No futuro, veremos em mais detalhes o efeito da multicolinearidade sobre a modelagem estatística.

1.8 Projeção ortogonal, o métodos dos mínimos quadrados e a regressão linear simples

O estudo da regressão linear simples pode ser entendido não apenas como um problema de ajuste de uma reta aos dados, mas também como um problema geométrico em espaços vetoriais. Nesse contexto, o chamado método dos mínimos quadrados surge naturalmente a partir da ideia de projeção ortogonal. Dado um vetor de respostas observado, buscamos sua projeção sobre o subespaço gerado pela variável explicativa, de modo que o vetor projetado seja o mais próximo possível do vetor original. Essa aproximação mínima, medida pela distância euclidiana, garante que os resíduos (diferenças entre os valores observados e os ajustados) sejam ortogonais ao espaço de explicação. Ao longo desta seção, vamos explorar essa conexão entre álgebra linear e estatística, mostrando como as ferramentas de vetores e projeções ajudam a compreender de maneira mais profunda a construção e a interpretação da regressão linear simples.

Para tornar o raciocínio mais claro, vamos começar com uma simplificação: consideraremos apenas o caso em que ajustamos uma reta que passa pela origem, ou seja, sem termo de intercepto. Essa escolha está em sintonia com o que já aprendemos até aqui, pois sabemos projetar um vetor sobre outro em $\mathbb{R}^n$, mas ainda não exploramos projeções em

subespaços de dimensão maior. No próximo capítulo, quando introduzirmos o papel das matrizes, ampliaremos essa ideia para o caso geral, incluindo o intercepto e a possibilidade de trabalhar com mais de uma variável explicativa.

Exemplo 1.37


Considere uma pesquisa estatística na qual estamos interessados em estudar a relação da altura X (em centímetros) com o peso Y (em quilos) de uma certa população. Para isso, uma amostra de $n = 5$ indivíduos é coletada aleatoriamente dessa população e as variáveis X e Y foram observadas. Os dados observados estão sumarizados na tabela a seguir.

i	1	2	3	4	5
x_i	150	160	170	180	190
y_i	50	50	70	70	80

- Construa o diagrama de dispersão e interprete-o.
- Determine a correlação amostral r_{XY} entre as variáveis X e Y e interprete-a.
- Com base nas suas respostas para os itens anteriores, você acredita ser razoável modelar a relação entre X e Y por uma reta que passa através da nuvem de dispersão?

SOLUÇÃO.

(a)



O gráfico de dispersão sugere que a nuvem de dispersão possui uma tendência linear crescente.

Exemplo 1.37

(b)

$$r_{XY} = \frac{s_{XY}}{\sqrt{s_{XX}}\sqrt{s_{YY}}} = \frac{200}{15,81 \times 13,42} \approx 0,94.$$

Portanto, com base na amostra observada, há indicativos de uma relação linear positiva muito forte entre a altura X e o peso Y dos indivíduos dessa população.

(c) Como o gráfico de dispersão apresenta uma tendência linear crescente evidente e a correlação amostral é um valor próximo de 1 que confirma essa tendência, parece ser razoável modelar a relação entre as variáveis X e Y por uma reta que passa através da nuvem de dispersão.

A partir do diagrama de dispersão, concluímos que é razoável supor uma relação linear entre as variáveis, ou seja, podemos buscar uma reta que descreva a tendência central dos pontos observados. No entanto, surge naturalmente a questão: dentre todas as retas que passam pela origem, qual é a mais plausível de ser utilizada para representar essa relação? Em outras palavras, estamos interessados em determinar a equação da reta $y = \beta x$, $\beta \in \mathbb{R}$, que melhor descreve a nuvem de pontos. A resposta depende do critério adotado para medir o quão bem uma reta se ajusta aos dados, e é justamente esse critério que será explicitado a seguir.

Cada valor de $\beta \in \mathbb{R}$ define uma reta distinta, pois corresponde a uma equação diferente do tipo $y = \beta x$. Para cada unidade amostral i , o valor observado da variável X , denotado por x_i , possui uma imagem na reta ajustada que, em geral, não coincide com o valor observado de Y , denotado por y_i . Essa imagem de x_i pela reta ajustada será chamada de valor predito e denotada por $\hat{y}_i$. Assim, vamos preferir escrever a equação da reta ajustada na forma $\hat{y}_i = \beta x_i$. Independentemente da reta escolhida para modelar a relação entre X e Y , sempre existirá um erro associado, resultante da diferença entre o valor observado e o valor predito. A seguir, ajustaremos duas retas diferentes aos dados e calcularemos os erros correspondentes.


Exemplo 1.38

Considere o mesmo problema do Exemplo 1.37. Suponha que as seguintes retas tenham sido ajustadas aos dados: $\hat{y} = 0,2x$ e $\hat{y} = 0,4x$. Para cada indivíduo da amostra e para cada uma das retas ajustadas, determine a diferença entre o valor observado de Y para o indivíduo i e o valor predito pela reta ajustada, isto é, calcule


Exemplo 1.38 $y_i - \hat{y}_i$.SOLUÇÃO.

i	x_i	y_i	$y_i - \hat{y}_i (\hat{\beta} = 0,2)$	$y_i - \hat{y}_i (\hat{\beta} = 0,4)$
1	150	50	20	-10
2	160	50	18	-14
3	170	70	36	2
4	180	70	34	-2
5	190	80	42	4

$$\hat{y} = 0.2x$$



$$\hat{y} = 0.4x$$



A diferença entre o valor observado e o valor predito para cada indivíduo, $y_i - \hat{y}_i$, será denominada *resíduo* e representada por $\epsilon_i := y_i - \hat{y}_i$. Esse resíduo expressa a quantidade que faltou para que o valor predito da reta ajustada coincidissem exatamente com o valor observado do indivíduo i . É importante notar que diferentes escolhas de reta levam a diferentes magnitudes de resíduos. No exemplo, observamos que, quando utilizamos $\hat{y} = 0,4x$, os resíduos tendem a ser menores em comparação com a reta $\hat{y} = 0,2x$, indicando que a primeira reta se ajusta melhor aos dados.

Para n unidades amostrais, isto é, em $\mathbb{R}^n$, podemos organizar os valores observados da variável resposta Y em um vetor $\mathbf{y}$, os valores observados da variável explicativa X em um vetor $\mathbf{x}$, os valores preditos pela reta ajustada em um vetor $\hat{\mathbf{y}}$ e, finalmente, os resíduos correspondentes em um vetor $\boldsymbol{\epsilon}$. Assim, a reta que melhor se ajusta aos dados será aquela que gera um vetor de resíduos com o menor tamanho possível, ou seja, com menor norma Euclidiana $\|\boldsymbol{\epsilon}\|$. É justamente nesse sentido que se estabelece o critério para definir qual reta é mais plausível para a nuvem de dispersão se concentrar ao redor: escolhemos a reta que minimiza os erros cometidos no processo de estimação. Em termos formais, queremos encontrar o valor de $\hat{\beta}$ que minimiza a norma do vetor de resíduos ou, equivalentemente, o quadrado dessa norma, i.e., que minimiza a soma dos quadrados dos resíduos

$$\|\boldsymbol{\epsilon}\|^2 := \sum_{i=1}^n \epsilon_i^2.$$

Definimos a função $L : \mathbb{R} \rightarrow [0, +\infty[$ tal que

$$L(\hat{\beta}) := \|\boldsymbol{\epsilon}\|^2.$$

Podemos reescrevê-la da seguinte maneira

$$\begin{aligned} L(\hat{\beta}) &= \sum_{i=1}^n \epsilon_i^2 \\ &= \sum_{i=1}^n (y_i - \hat{y}_i)^2 \\ &= \sum_{i=1}^n (y_i - \hat{\beta}x_i)^2. \end{aligned}$$

Assim, encontrar $\hat{\beta}$ que minimiza $\|\boldsymbol{\epsilon}\|$ é equivalente a encontrar $\hat{\beta}$ que minimiza $L(\hat{\beta})$. Como L é uma função diferenciável para todo $\hat{\beta} \in \mathbb{R}$, podemos determinar seus pontos críticos derivando em relação a $\hat{\beta}$ e resolvendo

$$\begin{aligned} \frac{dL}{d\hat{\beta}} = 0 &\Rightarrow -2 \sum_{i=1}^n (y_i - \hat{\beta}x_i)x_i = 0 \\ &\Rightarrow \hat{\beta} \sum_{i=1}^n x_i^2 = \sum_{i=1}^n y_i x_i \\ &\Rightarrow \hat{\beta} = \frac{\sum_{i=1}^n y_i x_i}{\sum_{i=1}^n x_i^2} \\ &\Rightarrow \hat{\beta} = \frac{\mathbf{y}^\top \mathbf{x}}{\|\mathbf{x}\|^2}. \end{aligned}$$

Note que $\frac{dL}{d\hat{\beta}^2} = 2 \sum_{i=1}^n x_i^2 > 0$ para todo $\hat{\beta} \in \mathbb{R}$. Logo, $\hat{\beta} = \frac{\mathbf{y}^\top \mathbf{x}}{\|\mathbf{x}\|^2}$ minimiza L . Nesse sentido, temos

$$\hat{\mathbf{y}} = \hat{\beta} \mathbf{x} \Rightarrow \hat{\mathbf{y}} = \frac{\mathbf{y}^\top \mathbf{x}}{\|\mathbf{x}\|^2} \mathbf{x} \Rightarrow \hat{\mathbf{y}} = \text{proj}_{\mathbf{x}} \mathbf{y}.$$

Nesse caso, a reta ajustada aos dados tem equação $\hat{\mathbf{y}} = \hat{\beta} \mathbf{x}$ com $\hat{\beta}$ como encontrado anteriormente. Essa reta é denominada *reta dos mínimos quadrados sem intercepto*, uma vez que foi obtida a partir da minimização da soma dos quadrados dos resíduos.

Uma vez que podemos escrever qualquer vetor como a soma da sua projeção ortogonal com o seu complemento ortogonal, segue que

$$\mathbf{y} = \text{proj}_{\mathbf{x}} \mathbf{y} + \text{rej}_{\mathbf{x}} \mathbf{y} = \hat{\mathbf{y}} + \text{rej}_{\mathbf{x}} \mathbf{y}.$$

Portanto, o complemento ortogonal de $\mathbf{y}$ sobre $\mathbf{x}$ é o vetor de resíduos, i.e.,

$$\text{rej}_{\mathbf{x}} \mathbf{y} = \mathbf{y} - \hat{\mathbf{y}} = \boldsymbol{\epsilon}.$$

Exemplo 1.39

Considere o mesmo problema do Exemplo 1.37. Determine a reta de mínimos quadrados sem intercepto e o vetor de resíduos gerado por ela. Verifique que ele é o de menor tamanho quando comparado às retas ajustadas no Exemplo 38.

SOLUÇÃO.

No modelo sem intercepto, o estimador de mínimos quadrados é dado por

$$\hat{\beta} = \frac{\mathbf{y}^\top \mathbf{x}}{\|\mathbf{x}\|^2}.$$

Uma vez que

$$\mathbf{x} = \begin{bmatrix} 150 \\ 160 \\ 170 \\ 180 \\ 190 \end{bmatrix} \quad \text{e} \quad \mathbf{y} = \begin{bmatrix} 50 \\ 50 \\ 70 \\ 70 \\ 80 \end{bmatrix},$$

temos

$$\mathbf{y}^\top \mathbf{x} = (150 \times 50) + (160 \times 50) + (170 \times 70) + (180 \times 70) + (190 \times 80) = 51.000,$$

Exemplo 1.39

e

$$\|\mathbf{x}\|^2 = 150^2 + 160^2 + 170^2 + 180^2 + 190^2 = 145,500.$$

Assim,

$$\hat{\beta} = \frac{51.000}{145.500} \approx 0,35.$$

Logo, a reta ajustada é $\hat{y} = 0,35x$.

Assim, as estimativas individuais, são

$$\hat{\mathbf{y}} = \begin{bmatrix} (0,35 \times 150) \\ (0,35 \times 160) \\ (0,35 \times 170) \\ (0,35 \times 180) \\ (0,35 \times 190) \end{bmatrix} = \begin{bmatrix} 52,6 \\ 56,2 \\ 59,7 \\ 63,1 \\ 66,6 \end{bmatrix}.$$

O vetor de resíduos é então

$$\boldsymbol{\epsilon} = \mathbf{y} - \hat{\mathbf{y}} = \begin{bmatrix} 50 - 52,6 \\ 50 - 56,2 \\ 70 - 59,7 \\ 70 - 63,1 \\ 80 - 66,6 \end{bmatrix} = \begin{bmatrix} -2,6 \\ -6,2 \\ 10,3 \\ 6,9 \\ 13,4 \end{bmatrix},$$

cujo tamanho é $\|\boldsymbol{\epsilon}\| = 19,45$. Por construção, o vetor $\hat{\mathbf{y}}$ é a projeção ortogonal de $\mathbf{y}$ sobre o subespaço gerado por $\mathbf{x}$, e o vetor de resíduos $\boldsymbol{\epsilon}$ é ortogonal a $\mathbf{x}$, ou seja,


$$\mathbf{x}^\top \boldsymbol{\epsilon} = 0.$$

Finalmente, o vetor $\boldsymbol{\epsilon}$ obtido acima possui o menor comprimento possível dentre todos os vetores de resíduos associados a retas do tipo $y = \beta x$. Em outras palavras, o método dos mínimos quadrados garante que

$$\|\boldsymbol{\epsilon}\| = \min_{\beta \in \mathbb{R}} \|\mathbf{y} - \beta \mathbf{x}\|.$$

Assim, a reta encontrada é aquela que melhor aproxima os dados, no sentido da menor soma dos quadrados dos resíduos.

Exemplo 1.39



Concluimos, portanto, que o problema de ajustar uma reta aos dados observados por meio do método dos mínimos quadrados pode ser interpretado geometricamente como a projeção ortogonal do vetor de observações $\mathbf{y}$ sobre o subespaço gerado pelo vetor de preditores $\mathbf{x}$. Em outras palavras, a reta ajustada representa o ponto de $\mathbb{R}^n$ mais próximo de $\mathbf{y}$ dentro desse subespaço, e o vetor de resíduos corresponde à componente de $\mathbf{y}$ que é ortogonal a $\mathbf{x}$. Essa visão geométrica é fundamental na Estatística, pois revela que o processo de estimação por mínimos quadrados é, essencialmente, um problema de projeção em espaços vetoriais.

Após estudarmos alguns conceitos da teoria de matrizes, como projeções em subespaços de dimensão maior, posto, imagem e núcleo, revisitaremos essa ideia em um contexto mais geral, no qual consideraremos várias variáveis explicativas e a presença de um intercepto no modelo. Nesse caso, a projeção será feita sobre o subespaço gerado por todas as colunas da matriz de planejamento $\mathbf{X}$, e veremos que o raciocínio geométrico desenvolvido aqui continuará sendo a base intuitiva do método dos mínimos quadrados.

1.9 Exercícios

1. Represente geometricamente em um sistema cartesiano de coordenadas os segmentos orientados descritos nos itens a seguir. Se for necessário, use o *software* Geogebra para te auxiliar. Em seguida, determine o comprimento dos segmentos orientados.

- (a) $\overrightarrow{AB}$ um segmento orientado em E^2 com $A = (2, 3)$ e $B = (5, 7)$.
- (b) $\overrightarrow{CD}$ um segmento orientado em E^2 com $C = (1, 1)$ e $D = (4, 5)$.
- (c) $\overrightarrow{EF}$ um segmento orientado em E^3 com $E = (1, 2, 3)$ e $F = (4, 5, 6)$.
- (d) $\overrightarrow{OP}$ um segmento orientado em E^3 com $O = (0, 0, 0)$ e $D = (3, 4, 5)$.
- (e) $\overrightarrow{GH}$ um segmento orientado em E^1 com $G = -2$ e $H = 3$.
- (f) $\overrightarrow{IJ}$ um segmento orientado em E^1 com $I = 1$ e $J = 6$.

Pergunta-se:

- (g) Os segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{CD}$ são equivalentes? Por quê?
 - (h) Os segmentos orientados $\overrightarrow{EF}$ e $\overrightarrow{OP}$ são equivalentes? Por quê?
 - (i) Os segmentos orientados $\overrightarrow{GH}$ e $\overrightarrow{IJ}$ são equivalentes? Por quê?
 - (j) Os segmentos orientados $\overrightarrow{AB}$ e $\overrightarrow{EF}$ são equivalentes? Por quê?
2. Em cada um dos itens abaixo, são especificados dois segmentos orientados. Identifique se os dois segmentos pertencem ao mesmo vetor. Justifique.

- (a) $\overrightarrow{AB}$ e $\overrightarrow{CD}$ são segmentos orientados em E^1 com $A = 1$, $B = 3$, $C = 2$ e $D = 4$.
- (b) $\overrightarrow{EF}$ e $\overrightarrow{GH}$ são segmentos orientados em E^2 com $E = (1, 1)$, $F = (3, 4)$, $G = (2, 2)$ e $H = (4, 5)$.
- (c) $\overrightarrow{OP}$ e $\overrightarrow{IJ}$ são segmentos orientados em E^3 com $O = (0, 0, 0)$, $P = (2, 2, 2)$, $I = (1, 1, 1)$ e $J = (3, 3, 3)$.

Pergunta-se:

- (d) Quais segmentos orientados definem uma mesma grandeza vetorial? Por quê?
- (e) Cada segmento orientado especificado anteriormente pode ser escolhido como representante de um vetor. Quais são as normas desses vetores?
- (f) Como dito no item (e), Cada segmento orientado especificado anteriormente pode ser escolhido como representante de um vetor. Existem vetores iguais? Justifique.

3. Sejam $\mathbf{u}$ e $\mathbf{v}$ vetores de $\mathbb{R}^3$ tais que

$$\mathbf{u} = \begin{bmatrix} 2 \\ 0 \\ -4 \end{bmatrix} \quad \text{e} \quad \mathbf{v} = \begin{bmatrix} 2 \\ 1 \\ -2 \end{bmatrix},$$

em que $\mathbf{1} \in \mathbb{R}^3$. Determine em cada um dos itens a seguir o vetor $\mathbf{x} \in \mathbb{R}^3$.

(a) $2\mathbf{u} - \|\mathbf{v}\|\mathbf{1} = \frac{3}{2}(\mathbf{u} - 2\mathbf{x}).$

(b) $3\mathbf{u} + 7\mathbf{v} = \|\mathbf{u}\|^2(2\mathbf{x} - \mathbf{v}).$

4. Em cada um dos itens a seguir, são definidos os vetores $\mathbf{u}$ e $\mathbf{v}$ de $\mathbb{R}^3$. Em cada item, determine o produto interno $\mathbf{u}^\top \mathbf{v}$, o ângulo θ entre os vetores $\mathbf{u}$ e $\mathbf{v}$ e represente graficamente, em um sistema de coordenadas cartesiana, os vetores $\mathbf{u}'$ e $\mathbf{v}'$ tais que $u'_i = u_i - \bar{u}$ e $v'_i = v_i - \bar{v}$, em que $\bar{u}$ é a média aritmética das entradas do vetor $\mathbf{u}$, $\bar{v}$ é a média aritmética das entradas do vetor $\mathbf{v}$ e $i = 1, 2, 3$. Represente graficamente também os vetores $\mathbf{u}$ e $\mathbf{v}$.

(a)

$$\mathbf{u} = \begin{bmatrix} 1/2 \\ 2 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v} = \begin{bmatrix} 4 \\ 1 \\ -3 \end{bmatrix}.$$

(b)

$$\mathbf{u} = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} \quad \text{e} \quad \mathbf{v} = \begin{bmatrix} 4 \\ 0 \\ 2 \end{bmatrix}.$$

(c)

$$\mathbf{u} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{v} = \begin{bmatrix} 2 \\ -1 \\ 5 \end{bmatrix}.$$

5. Sejam os vetores $\mathbf{u} \in \mathbb{R}^n$, $\mathbf{v} \in \mathbb{R}^n$ e $\mathbf{w} \in \mathbb{R}^2$. Prove que

(a) $\|\mathbf{u}\| = \|\mathbf{v}\| \iff (\mathbf{u} + \mathbf{v})^\top (\mathbf{u} - \mathbf{v}) = 0.$

(b) $\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2 \iff \mathbf{u}^\top \mathbf{v} = 0.$

(c) $\frac{1}{4}\|\mathbf{u} + \mathbf{v}\|^2 - \frac{1}{4}\|\mathbf{u} - \mathbf{v}\|^2 = \mathbf{u}^\top \mathbf{v}.$

(d) $\|\mathbf{u} + \mathbf{v}\|^2 + \|\mathbf{u} - \mathbf{v}\|^2 = 2\|\mathbf{u}\|^2 + 2\|\mathbf{v}\|^2.$

(e) $\|\mathbf{u} + \mathbf{v}\| \leq \|\mathbf{u}\| + \|\mathbf{v}\|.$

(f) $\|\mathbf{u} + \mathbf{v}\| = \|\mathbf{u} - \mathbf{v}\|$, então $\mathbf{u}$ e $\mathbf{v}$ são ortogonais.

(g) **Teorema de Pitágoras:** $\|\mathbf{u} + \mathbf{v}\|^2 = \|\mathbf{u}\|^2 + \|\mathbf{v}\|^2$ quando $\mathbf{u}$ e $\mathbf{v}$ são ortogonais.

(g) **Ortogonalidade não é transitiva:** Se $\mathbf{u}$ é ortogonal a $\mathbf{v}$ e $\mathbf{v}$ é ortogonal a $\mathbf{w}$, então não necessariamente $\mathbf{u}$ é ortogonal a $\mathbf{w}$.

(h) **Normalização:** Os vetores obtidos da normalização de $\mathbf{u}$ e $\alpha\mathbf{u}$ são iguais para todo $\alpha > 0$. O que ocorre se $\alpha < 0$?

6. O vetor de uns do $\mathbb{R}^n$

$$\mathbf{1} = \begin{bmatrix} 1 & 1 & \cdots & 1 \end{bmatrix}^\top$$

também é conhecido pela literatura como **vetor soma**.

(a) Determine $\mathbf{1}^\top \mathbf{x}$ para um vetor genérico $\mathbf{x} \in \mathbb{R}^n$.

(b) Utilize o item (a) para explicar o porquê do vetor $\mathbf{1}$ também ser conhecido como **vetor soma**.

(c) Normalize o vetor $\mathbf{1}$ e, em seguida, determine a norma do vetor normalizado.

7. Em cada um dos itens a seguir, determine o vetor projeção do vetor $\mathbf{u}$ sobre $\mathbf{v}$ e, em seguida, determine o tamanho da projeção.

(a)

$$\mathbf{u} = \begin{bmatrix} 5 \\ 7 \\ 1 \end{bmatrix} \text{ e } \mathbf{v} = \begin{bmatrix} 2 \\ -1 \\ 3 \end{bmatrix}.$$

(b)

$$\mathbf{u} = \begin{bmatrix} 1 \\ -1 \\ 2 \end{bmatrix} \text{ e } \mathbf{v} = \begin{bmatrix} 3 \\ -1 \\ 1 \end{bmatrix}.$$

Utilize o *software* Geogebra para plotar os representantes dos vetores $\mathbf{u}$, $\mathbf{v}$ e $\text{proj}_{\mathbf{v}}\mathbf{u}$ num sistema de coordenadas cartesianas. Verifique que $\text{proj}_{\mathbf{v}}\mathbf{u}$ é a “sombra” de $\mathbf{u}$ sobre $\mathbf{v}$.

8. Dados os vetores do $\mathbb{R}^3$:

$$\mathbf{v} = \begin{bmatrix} x \\ y \\ z \end{bmatrix}, \mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \text{ e } \mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Mostre que $\text{proj}_{e_1} \mathbf{v} = x\mathbf{e}_1$, $\text{proj}_{e_2} \mathbf{v} = y\mathbf{e}_2$ e $\text{proj}_{e_3} \mathbf{v} = z\mathbf{e}_3$. Quais são os tamanhos dessas projeções? Utilize o *software* Geogebra para fazer uma verificação análoga aquela indicada no exercício anterior.

9. Considere uma amostra de 5 indivíduos nos quais foram observadas 5 características: altura (X_1), peso (X_2) e sexo (X_3) de modo que

$$X_3 = \begin{cases} 1, & \text{se o indivíduo for do sexo feminino,} \\ 0, & \text{se o indivíduo for do sexo masculino.} \end{cases}$$

Os dados foram organizados conforme a tabela a seguir.

	Altura (cm)	Peso (kg)	Sexo
Indivíduo 1	168	70	1
Indivíduo 2	173	92	0
Indivíduo 3	167	82	0
Indivíduo 4	164	60	1
Indivíduo 5	176	105	0

- Escreva os vetores de dados relativos às variáveis.
- Escreva os vetores de dados relativos aos indivíduos.
- Determine o vetor de médias $\bar{\mathbf{x}}$.
- Quais são os indivíduos mais similares e os menos similares de acordo com essas variáveis? Para responder a essa pergunta, calcule a distância entre os vetores de dados de cada indivíduo. Você pode utilizar o *software* R para te ajudar nessa tarefa. Existem duas maneiras de calcular as distâncias Euclidianas no R:

- Usando a função `dist()`:

```
r
# Definindo dois vetores
vetor1 <- c(1, 2, 3)
vetor2 <- c(4, 5, 6)

# Calculando a distância euclidiana
dist(rbind(vetor1, vetor2))
```

 Copiar código

- **Cálculo manual:**

```
r
# Definindo os vetores
vetor1 <- c(1, 2, 3)
vetor2 <- c(4, 5, 6)

# Cálculo manual da distância euclidiana
distancia <- sqrt(sum((vetor1 - vetor2)^2))
distancia
```

 Copiar código

- (e) Classifique os indivíduos em ordem crescente de modo que o primeiro indivíduo é aquele mais próximo de $\bar{x}$ e o último indivíduo é aquele mais longe.
10. Considere uma pesquisa interessada em estudar os efeitos do tempo de estudo (X_1) na nota final (X_2) de estudantes em uma certa disciplina. Para isso, uma amostra de 3 estudantes foi coletada e as variáveis X_1 e X_2 foram observadas. Os dados obtidos estão sumarizados na tabela a seguir.

Aluno	Tempo de Estudo (horas/semana)	Nota Final (%)
1	10	64
2	15	63
3	20	84

- (a) Determine os vetores de observações referentes às variáveis.
- (b) Determine os vetores de observações referentes às observações.
- (c) Determine o vetor de médias.
- (d) Determine os vetores de desvios em relação à média para cada uma das variáveis.
- (e) Determine os vetores de observações ajustados pela média referentes às unidades amostrais.
- (f) Determine o vetor de médias ajustado.
- (g) Represente no sistema cartesiano de coordenadas o gráfico de pontos localizando x_1 , x_2 , x_3 e $\bar{x}$ no diagrama resultante.
- (h) Represente no sistema cartesiano de coordenadas o gráfico de pontos localizando x'_1 , x'_2 , x'_3 e $\bar{x}'$ no diagrama resultante.

- (i) Comparando os diagramas obtidos nos itens (g) e (h) o que se pode afirmar a respeito da dispersão dos dados em torno da média? Pontue a principal diferença entre eles.
 - (j) Represente no sistema cartesiano de coordenadas os vetores de desvios obtidos no item (d).
 - (k) Determine o tamanho dos vetores de desvios obtidos no item (d). Qual variável leva ao maior vetor de desvios?
 - (l) Represente no sistema cartesiano de coordenadas os vetores de desvios obtidos no item (d). Você pode utilizar o *software* Geogebra para te auxiliar.
 - (m) Determine as variâncias amostrais e os respectivos desvios-padrões amostrais. Para qual variável as observações amostrais são mais dispersas em relação à média?
 - (n) As conclusões dos itens (k) e (m) são coerentes? Por quê?
 - (o) Determine o produto interno entre os vetores de desvios. Interprete.
 - (p) Determine a covariância amostral entre as variáveis X_1 e X_2 . Interprete.
 - (q) As interpretações dos itens (o) e (p) são coerente? Por quê?
 - (r) Determine o cosseno do ângulo θ entre os vetores de desvios. Represente-o no gráfico do item (m). Interprete.
 - (s) Determine a correlação amostral entre as variáveis X_1 e X_2 . Interprete.
 - (t) As interpretações dos itens (r) e (s) são coerentes? Por quê?
11. O diretor de admissões de uma pequena faculdade selecionou aleatoriamente 120 estudantes da nova turma de calouros em um estudo para determinar se a média de notas dos estudantes (GPA) ao final do primeiro ano (X_2) pode ser prevista a partir da pontuação no vestibular (X_1). A nota média X_1 varia de 0 a 5 pontos e a nota X_1 obtida no vestibular varia de 0 a 50 pontos. O conjunto de dados pode ser encontrado em <http://www.cnachtsheim-text.csom.umn.edu/Kutner/Chapter%20%201%20Data%20Sets/CH01PR19.txt>.
- Sem usar funções prontas do *software* R tais como `var(dados)`, `sd(dados)`, `cor(dados1, dados2)`, faça o que se pede nos itens a seguir.
- (a) Faça um código em R para calcular a norma dos vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$ relativos, respectivamente, às variáveis X_1 e X_2 .
 - (b) Faça um código em R para calcular o produto interno entre os vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$ relativos, respectivamente, às variáveis X_1 e X_2 .

- (c) Faça um código em *R* para calcular o cosseno do ângulo entre os vetores de desvios d_1 e d_2 relativos, respectivamente, às variáveis X_1 e X_2 .
- (d) Faça um código em *R* para plotar o gráfico de dispersão relativo às variáveis X_1 e X_2 . Use a biblioteca *ggplot* do *R*. Veja um exemplo:

```
r
# Instale o pacote ggplot2, se ainda não estiver instalado
# install.packages("ggplot2")

# Carregue o pacote
library(ggplot2)

# Criando um conjunto de dados de exemplo
dados <- data.frame(
  x = c(10, 20, 30, 40, 50),
  y = c(15, 25, 35, 45, 55)
)

# Criando o gráfico de dispersão
ggplot(dados, aes(x = x, y = y)) +
  geom_point(color = "blue", size = 3) + # Adiciona os pontos
  labs(title = "Gráfico de Dispersão", x = "Variável X", y = "Variável Y") +
  theme_minimal() # Estilo do gráfico
```

- (e) Com base na amostra observada, há indicativos de que a relação entre as variáveis é fracamente ou fortemente linear? Por quê? Qual é orientação dessa relação (crescente ou decrescente)? Por quê?
- (f) Utilize o código desenvolvido nos itens (a), (b) e (c) para escrever um código em *R* para calcular a correlação amostral entre X_1 e X_2 . Confira se o código está correto comparando o resultado obtido com aquele obtido por meio da função `cor(dados1, dados2)` do *R*.
- (g) O valor obtido no item (f) é coerente com suas respostas para o item (e). Por quê?
12. Considere uma pesquisa que esteja interessada em estudar a área X_1 de lotes residenciais (em centenas de metros quadrados) e o preço X_2 desses lotes (em centenas de milhares de reais). Para isso, uma amostra de 60 lotes foi coletada e as variáveis X_1 e X_2 foram observadas. O conjunto de dados se encontra anexado no Google Classroom.

- (a) Utilize o *software R* para escrever um código no qual três grupos G_1 , G_2 e G_3 são criados com base nas variáveis X_1 e X_2 de modo que indivíduos de um mesmo grupo sejam similares entre si, i.e., se os indivíduos i e j pertencem ao mesmo grupo, então a distância Euclidiana entre os vetores de dados $\mathbf{x}_i$ e $\mathbf{x}_j$ deve ser pequena, enquanto se esses indivíduos são de grupos distintos, então a distância Euclidiana entre os vetores de dados $\mathbf{x}_i$ e $\mathbf{x}_j$ deve ser grande. Esses grupos **não necessariamente precisam** ter a mesma quantidade de indivíduos. Não use funções prontas do *R*, tente fazer por si só.
- (b) Faça um gráfico de dispersão utilizando o *software R* de modo que indivíduos de um mesmo grupo sejam coloridos com a mesma cor e indivíduos de grupos distintos tenham cores diferentes. Use a biblioteca *ggplot*. Veja um exemplo:

```
r
# Criar gráfico de dispersão colorindo por grupo
ggplot(dados, aes(x = x1, y = x2, color = as.factor(grupo))) +
  geom_point(size = 3) +
  labs(title = "Gráfico de Dispersão por Grupos",
       x = "Variável X1", y = "Variável X2") +
  scale_color_manual(values = c("red", "green", "blue")) +
  theme_minimal()
```

- (c) Apresente uma interpretação para os grupos G_1 , G_2 e G_3 criados a partir das variáveis X_1 e X_2 .
13. Uma pesquisa está interessada em prever qual é o tipo de residência de indivíduos da cidade de São Carlos. Essa previsão será feita com base na idade X_1 dos indivíduos (em anos) e na renda X_2 (em reais). Uma amostra de 6 indivíduos foi coletada e as variáveis X_1 e X_2 foram observadas. Os dados observados estão sumarizados na tabela a seguir.

Indivíduo	X_1 (Idade)	X_2 (Renda)	Tipo de moradia
1	25	2000	Apartamento
2	40	6000	Casa
3	30	3500	Apartamento
4	35	5000	Casa
5	28	3000	Apartamento
6	38	4500	Casa

Dois novos indivíduos, João e José, foram entrevistados. Apenas informações da idade e da renda desses indivíduos estão disponíveis. João possui 26 anos e tem um renda de 2.300 reais. José possui 40 anos e possui uma renda de 6.000 reais. Utilize a amostra observada para prever qual é o tipo de moradia desses novos indivíduos com base nos seguintes critérios de decisão.

- (a) **Critério 1 (O vizinho mais próximo):** O novo indivíduo possui a mesma classe do indivíduo da amostra mais próximo a ele.
- (b) **Critério 2 (Os três vizinhos mais próximos):** A classe do novo indivíduo é igual a classe mais frequente dentre os três indivíduos da amostra mais próximo ele.

14. Considere os vetores do $\mathbb{R}^2$

$$\mathbf{u} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

- (a) Determine a projeção ortogonal de $\mathbf{u}$ sobre $\mathbf{v}$.
- (b) Encontre o vetor complemento ortogonal de $\mathbf{u}$ em relação a $\mathbf{v}$, isto é,

$$\text{rej}_{\mathbf{v}}(\mathbf{u}) = \mathbf{u} - \text{proj}_{\mathbf{v}}(\mathbf{u}).$$

- (c) Verifique que o vetor rejeição encontrado em (b) é ortogonal a $\mathbf{v}$.
- (d) Interprete geometricamente os vetores obtidos em (a) e (b), destacando a ideia de decomposição de $\mathbf{u}$ em duas componentes ortogonais.

15. Sejam X_1 , X_2 e X_3 variável das quais foram coletadas amostras de tamanho n . Pergunta-se: se $r_{12} = 0$ e $r_{23} = 0$, então $r_{23} = 0$? Em caso afirmativo, prove. Em caso negativo, dê um contra-exemplo. Você deve utilizar a definição da correlação via vetores de desvios para justificar.

16. Mostre que quaisquer que sejam as sequências de números reais $\{x_i\}_{i=1}^n$ e $\{y_i\}_{i=1}^n$, se $\bar{x}$ e $\bar{y}$ são, respectivamente, as médias aritméticas dessas sequências, então

- (a) $\sum_{i=1}^n (x_i - \bar{x}) = 0$.
- (b) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n (x_i - \bar{x})x_i$.
- (c) $\sum_{i=1}^n (x_i - \bar{x})^2 = \sum_{i=1}^n x_i^2 - n\bar{x}^2$.
- (d) $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n (x_i - \bar{x})y_i$.
- (e) $\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}) = \sum_{i=1}^n x_i y_i - n\bar{x}\bar{y}$.

17. Verifique quais conjuntos de vetores do espaço vetorial $\mathbb{R}^3$ são linearmente independentes. No caso de formarem uma base, determine $\text{span}\{\mathbf{x}_1, \mathbf{x}_2, \mathbf{x}_3\}$.

$$(a) \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 2 \\ 3 \\ 5 \end{bmatrix} \right\}.$$

$$(b) \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 0 \\ -2 \end{bmatrix} \right\}.$$

$$(c) \left\{ \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \begin{bmatrix} 4 \\ 1 \\ -2 \end{bmatrix} \right\}.$$

$$(d) \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \begin{bmatrix} 3 \\ 3 \\ -1 \end{bmatrix} \right\}.$$

18. Você está analisando o desempenho de diferentes modelos de veículos em testes de eficiência energética. As variáveis representam aspectos mecânicos e de consumo, conforme descrito abaixo:

- X_1 (**Velocidade média, em km/h**): mede a velocidade média dos veículos durante o teste.
- X_2 (**Torque do motor, em $N \cdot m$**): representa a força rotacional média exercida pelo motor.
- X_3 (**Consumo de combustível, em litros**): mede o total de combustível consumido pelo veículo.

Os dados registrados para quatro veículos diferentes são apresentados na tabela a seguir:

Veículo	Velocidade Média (km/h)	Torque do Motor (N·m)	Consumo de Combustível (litros)
1	1	2	3
2	2	4	6
3	3	6	9
4	4	8	12

Suponha que as variáveis X_1 , X_2 e X_3 sejam selecionadas para tentar prever a variável Y que representa o tempo necessário para completar um percurso. Dentre as variáveis preditoras selecionadas observa-se redundância de informação, i.e., variáveis que contribuem com a mesma informação no processo de previsão (**variáveis colineares**)? Justifique com cálculos matemáticos.

19. Você está analisando o desempenho de diferentes modelos de veículos em testes de emissões de poluentes. As variáveis representam características mecânicas e ambientais dos veículos, conforme descrito abaixo:

- X_1 (**Temperatura do motor, em graus Celsius**): mede a temperatura média do motor durante o teste.
- X_2 (**Pressão do combustível, em atm**): representa a pressão média do combustível no sistema do veículo.
- X_3 (**Emissão de CO_2 , em gramas por km**): mede a quantidade de CO_2 emitida pelo veículo durante o teste.

Os dados registrados para quatro veículos diferentes são apresentados na tabela a seguir:

Veículo	Temperatura do Motor ($^{\circ}\text{C}$)	Pressão do Combustível (atm)	Emissão de CO_2 (g/km)
1	80	1.5	120
2	85	1.7	150
3	90	1.4	170
4	95	1.8	190

Suponha que as variáveis X_1 , X_2 e X_3 sejam selecionadas para tentar prever a variável Y , que representa a quantidade de poluentes totais emitidos no teste (em gramas por km). Dentre as variáveis preditoras selecionadas observa-se redundância de informação, i.e., variáveis que contribuem com a mesma informação no processo de previsão (**variáveis colineares**)? Justifique com cálculos matemáticos.

20. Considere a detecção de outliers com base em distâncias em um espaço bidimensional. Para cada item, determine se o ponto dado é um **outlier** calculando
- a **distância Euclidiana** em relação ao vetor de médias;
 - a **distância de Mahalanobis** em relação ao vetor de médias.

Em ambos os casos, compare a distância com o limiar c que foi fornecido. Se a distância for maior que c , o ponto é considerado um *outlier*; caso contrário, não é.

- (a) Seja o vetor de médias $\bar{\mathbf{x}} = \begin{bmatrix} 10 \\ 15 \end{bmatrix}$, com variâncias $s_{11} = 4$ e $s_{22} = 9$. Determine as regiões de decisões $\mathcal{C}_c$ determinadas tanto pela distância Euclidiana quanto pela distância de Mahalanobis e, em seguida, verifique se o ponto $\mathbf{x}^* = \begin{bmatrix} 14 \\ 18 \end{bmatrix}$ é um *outlier* para $c = 5$.
- (b) Seja o vetor de médias $\bar{\mathbf{x}} = \begin{bmatrix} 20 \\ 30 \end{bmatrix}$, com variâncias $s_{11} = 25$ e $s_{22} = 16$. Determine as regiões de decisões $\mathcal{C}_c$ determinadas tanto pela distância Euclidiana quanto pela distância de Mahalanobis e, em seguida, verifique se o ponto $\mathbf{x}^* = \begin{bmatrix} 28 \\ 26 \end{bmatrix}$ é um *outlier* para $c = 3$.
- (c) Seja o vetor de médias $\bar{\mathbf{x}} = \begin{bmatrix} 50 \\ 40 \end{bmatrix}$, com variâncias $s_{11} = 100$ e $s_{22} = 25$. Determine as regiões de decisões $\mathcal{C}_c$ determinadas tanto pela distância Euclidiana quanto pela distância de Mahalanobis e, em seguida, verifique se o ponto $\mathbf{x}^* = \begin{bmatrix} 65 \\ 55 \end{bmatrix}$ é um *outlier* para $c = 4$.

21. Em cada um dos itens a seguir, faça o que se pede:

- (i) Determine a projeção ortogonal do vetor $\mathbf{y} \in \mathbb{R}^5$ com as observações da variável resposta Y sobre o vetor $\mathbf{x} \in \mathbb{R}^5$ com as observações da variável preditora X .
- (ii) Utilize o item (i) para encontrar a equação da reta dos mínimos quadrados que se ajusta aos dados.
- (iii) A partir do item (i) determine o vetor de preditos $\hat{\mathbf{y}} \in \mathbb{R}^5$ seguido do vetor de resíduos $\boldsymbol{\epsilon} \in \mathbb{R}^5$.
- (iv) Utilize o item (iii) para encontrar o complemento ortogonal $\text{rej}_{\mathbf{x}}\mathbf{y}$.
- (v) Construa o gráfico de dispersão e calcule a correlação amostral e, em seguida, comente sobre a plausibilidade de se ajustar uma reta aos dados para fins de predição.
- (a) Situação: X = horas de estudo por semana; Y = nota em uma prova de Estatística.

X	Y
5	60
8	72
10	80
12	85
15	95

- (b) Situação: X = número de treinos semanais de corrida; Y = tempo (em minutos) para completar 5 km.

X	Y
1	26
2	29
3	27
4	30
5	32

- (c) Situação: X = número de cafés tomados por dia; Y = produtividade (tarefas concluídas).

X	Y
1	12
2	14
3	11
4	13
5	12

“Como em qualquer outra coisa, também para uma teoria matemática, a beleza pode ser percebida mas não explicada.”

Arthur Cayley (1821 – 1895)

Matrizes são tabelas retangulares com elementos dispostos em linhas e colunas. Com o advento da computação, cresceu a necessidade de armazenar grandes quantidades de informação; as matrizes, então, adquiriram grande importância, pois passaram a ser amplamente utilizadas com essa finalidade. Nesse sentido, ter um conhecimento sólido de álgebra matricial tornou-se essencial para uma boa formação em Estatística. O papel da teoria das matrizes vai desde ser uma ferramenta por meio da qual problemas estatísticos podem ser expressos de maneira mais conveniente até constituir uma parte fundamental do desenvolvimento e da compreensão dos resultados teóricos em Estatística. É o que ocorre, por exemplo, no estudo dos modelos de regressão e das técnicas de análise multivariada. Nessas áreas, o domínio da álgebra matricial é indispensável para compreender e aplicar os conceitos da teoria estatística subjacente. Portanto, querido(a) e gentil leitor(a), encare este capítulo como um preparativo para os cursos mais avançados de Estatística.

2.1 A história por trás da Álgebra Matricial


A ideia de organizar números em tabelas retangulares é muito antiga. Registros históricos mostram que matemáticos chineses já utilizavam arranjos de números semelhantes a matrizes há mais de dois mil anos para resolver sistemas de equações lineares. O livro *Chiu-chang Suan-shu (Nove Capítulos sobre a Arte da Matemática)*, escrito por volta do século II a.C., apresenta métodos práticos de cálculo baseados em operações sobre essas tabelas numéricas.

Mais de mil anos depois, essas técnicas foram aprimoradas no Japão pelo matemático Seki Kōwa (1642–1708), considerado um dos maiores de seu país. Ele formulou princípios que hoje reconhecemos como etapas de eliminação de variáveis e até antecipou o conceito de determinante, embora ainda não tivesse desenvolvido uma teoria formal de matrizes. O passo decisivo veio séculos mais tarde, com o britânico Arthur Cayley (1821–1895). Em 1855, Cayley apresentou pela primeira vez suas ideias sobre operações entre matrizes, e em 1857 publicou o famoso *A Memoir on the Theory of Matrices*. Esse trabalho marcou o nascimento oficial da teoria das matrizes como uma área independente da matemática.

Cayley via na álgebra matricial não apenas uma ferramenta, mas uma nova linguagem para expressar relações matemáticas. Ele publicou cerca de 300 artigos, muitos em parceria com James Joseph Sylvester (1814–1897), com quem formou uma das duplas mais influentes na história da álgebra moderna. Graças a Cayley e Sylvester, a teoria das matrizes passou de simples manipulação de números em tabelas a um campo estruturado, essencial para a compreensão de fenômenos em diversas áreas, especialmente, na Estatística, onde as matrizes se tornaram instrumentos fundamentais para expressar e resolver problemas de forma elegante e eficiente.



(a) Seki-Kōwa



(b) Arthur Cayley



(c) James Joseph Sylvester

Figura 2.1. Grandes nomes por trás da álgebra matricial. Fonte: Wikipedia.

2.2 Matrizes como um objeto para organizar dados

As matrizes são utilizadas em quase todos os ramos da ciência e da engenharia. Para termos uma ideia da sua importância vamos considerar quatro exemplos de onde elas podem ser aplicadas.

Exemplo 2.1: Adaptado de Dante (2006)

O que vemos na tela do computador é uma grande matriz, sendo que cada valor guardado nas linhas e colunas da matriz representa um ponto colorido mostrado na tela (pixel). A seguir mostramos a mesma imagem em três diferentes resoluções. A imagem mais à esquerda é uma matriz que possui apenas 27 linhas e 33 colunas, en-

Exemplo 2.1

quanto a imagem mais à direita é uma matriz que possui 1.645 linhas e 2.008 colunas.



Esse é um exemplo de como as matrizes podem ser utilizadas em computação gráfica.

Exemplo 2.2: Adaptado de Dante (2006)

Quando você preenche um cadastro em uma página da internet, seus dados vão imediatamente para um banco de dados, que é uma matriz que relaciona suas informações e a de todos os outros cadastrados às respectivas pessoas, de forma recuperável.

	A	B	C	D	E	F
1	Nome	Nascimento	Cidade Natal	Grau de instrução	Profissão	
2	Ana Silvério	02/02/1978	São Paulo	Ensino Médio	Secretária	
3	Bernando Lima	30/07/1973	Rio de Janeiro	Ensino Médio	Técnico	
4	Caio Cruz	01/03/1988	Salvador	Ensino Superior	Médico	
5	Daniela Luiz Paula	13/09/1980	Manaus	Ensino Superior	Advogada	
6	Éder Duarte	29/09/1976	Rio Branco	Ensino Médio	Empresário	
7	Fernanda Barcelos	13/04/1984	Cuiabá	Ensino Superior	Engenheira	
8						
9						
10						
11						
12						

Esse é um exemplo de como as matrizes podem ser utilizadas em computação e/ou estatística.

Exemplo 2.3: Adaptado de Giovani *et al.* (1994)

Considere a tabela abaixo, que indica o número de vendas efetuadas por uma agência de automóveis durante o primeiro trimestre.

	Janeiro	Fevereiro	Março
Monza	20	18	25
Fiat	12	10	15
Gol	15	9	20
Voyage	18	15	21

- (a) Quantos carros Voyage foram vendidos em janeiro? Em qual linha e coluna se encontra essa informação?
- (b) Quantos carros Gol foram vendidos em fevereiro? Em qual linha e coluna se encontra essa informação?
- (c) Quantos carros Monza foram vendidos em março? Em qual linha e coluna se encontra essa informação?

SOLUÇÃO.

- (a) Em janeiro, foram vendidos 18 carros Voyage. Essa informação é o número que está na **quarta linha** e na **primeira coluna** da tabela.
- (b) Em fevereiro, foram vendidos 9 carros Gol. Essa informação é o número que está na **terceira linha** e na **segunda coluna** da tabela.
- (c) Em março, foram vendidos 25 carros Monza. Essa informação é o número que está na **primeira linha** e na **terceira coluna** da tabela.

Exemplo 2.4: Adaptado de Dante (2006)

Considere a tabela abaixo, que indica a nota de quatro estudantes de Teoria das Matrizes nas três provas aplicadas ao longo do curso.

- (a) Qual foi a nota de Lucas na Prova 1? Em qual linha e coluna se encontra essa informação?
- (b) Qual foi a nota de Luiza na Prova 2? Em qual linha e coluna se encontra essa

Exemplo 2.4

informação?

- (c) Qual foi a nota de Nicole na Prova 3? Em qual linha e coluna se encontra essa informação?

	Prova 1	Prova 2	Prova 3
Lucas	10	10	7
Luiza	8	9	9
Matheus	10	9	7
Nicole	10	10	6

SOLUÇÃO.

- (a) Na Prova 1, a nota de Lucas foi 10. Essa informação é o número que está na **primeira linha** e na **primeira coluna** da tabela.
- (b) Na Prova 2, a nota de Luiza foi 9. Essa informação é o número que está na **segunda linha** e na **segunda coluna** da tabela.
- (c) Na Prova 3, a nota de Nicole foi 6. Essa informação é o número que está na **quarta linha** e na **terceira coluna** da tabela.

Nos Exemplos 2.3 e 2.4, os dados estão dispostos em 4 linhas e 3 colunas. Os números colocados nas disposições horizontais formam o que denominamos **linha** e os colocados nas disposições verticais chamamos de **coluna**. O conjunto ordenado dos números que formam a tabela é denominado **matriz** e cada número é chamado **elemento ou entrada** da matriz. Dizemos, portanto, que as matrizes dos Exemplos 2.3 e 2.4 são **matrizes** 4×3 (lê-se: quatro por três), uma vez que são compostas por 4 linhas e 3 colunas.

Podemos representar uma matriz colocando seus elementos **entre parênteses** ou **entre colchetes**. Assim, a matriz do Exemplo 2.3 pode ser representada das seguintes maneiras:

$$\begin{pmatrix} 20 & 18 & 25 \\ 12 & 10 & 15 \\ 15 & 9 & 20 \\ 18 & 15 & 21 \end{pmatrix} \quad \text{ou} \quad \begin{bmatrix} 20 & 18 & 25 \\ 12 & 10 & 15 \\ 15 & 9 & 20 \\ 18 & 15 & 21 \end{bmatrix};$$

enquanto a matriz do Exemplo 2.4 pode ser representada das seguintes maneiras:

$$\begin{pmatrix} 10 & 10 & 7 \\ 8 & 9 & 9 \\ 10 & 9 & 7 \\ 10 & 10 & 6 \end{pmatrix} \quad \text{ou} \quad \begin{bmatrix} 10 & 10 & 7 \\ 8 & 9 & 9 \\ 10 & 9 & 7 \\ 10 & 10 & 6 \end{bmatrix}.$$

As matrizes fornecem, portanto, uma forma muito prática de **organizar dados**. Além disso, o fato de **padronizarmos** a maneira de expressar esses dados facilita a interpretação dos mesmos. Na Estatística, os dados surgem sempre que um investigador, buscando entender um fenômeno físico ou social, seleciona e observa $p \geq 1$ *variáveis* em n *indivíduos*, *objetos* ou *unidades experimentais*. Consequentemente, os dados multivariados podem ser exibidos da seguinte forma:

	Variável 1 (X_1)	Variável 2 (X_2)	...	Variável k (X_k)	...	Variável p (X_p)
Item 1:	x_{11}	x_{12}	...	x_{1k}	...	x_{1p}
Item 2:	x_{21}	x_{22}	...	x_{2k}	...	x_{2p}
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
Item j :	x_{j1}	x_{j2}	...	x_{jk}	...	x_{jp}
$\vdots$	$\vdots$	$\vdots$	...	$\vdots$	...	$\vdots$
Item n :	x_{n1}	x_{n2}	...	x_{nk}	...	x_{np}

em que x_{jk} representa o valor da k -ésima variável X_k observada no j -ésimo item, para todo $1 \leq j \leq n$ e $1 \leq k \leq p$.

Matematicamente, podemos representar os dados multivariados construindo a matriz de dados $\mathbf{X}$, que contém todas as observações em todas as variáveis, i.e.,

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}.$$

Exemplo 2.5: (Johnson e Wichern, 2014, p.6, tradução e grifo nosso)

Uma seleção de quatro recibos de uma livraria universitária foi obtida para investigar a natureza das vendas de livros. Cada recibo forneceu, entre outras coisas, o número de livros vendidos e o valor total de cada venda. Seja a primeira variável (X_1) o valor total em dólares das vendas e a segunda variável (X_2) o número de livros vendidos. Suponha que os dados, em forma tabular, sejam

Exemplo 2.5

Variável 1 (vendas em dólares): 42 52 48 58

Variável 2 (número de livros): 4 5 4 3

- (a) Determine o número p de variáveis e a quantidade n de observações neste estudo.
- (b) Construa a matriz de dados $\mathbf{X}$ correspondente.

SOLUÇÃO:

- (a) Nesse estudo, temos $p = 2$ variáveis (valor total X_1 em dólares das vendas e o número X_2 de livros vendidos) e $n = 4$ observações (cada um dos quatro recibos representa uma observação independente).
- (b) A matriz de dados $\mathbf{X}$ é dada por

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \\ x_{41} & x_{42} \end{bmatrix} = \begin{bmatrix} 42 & 4 \\ 52 & 5 \\ 48 & 4 \\ 58 & 3 \end{bmatrix}.$$

Podemos ainda definir operações (por exemplo, de soma e multiplicação) entre matrizes, e essas operações são definidas de forma que matrizes possuem inúmeras aplicações. Uma delas é na resolução de sistemas de equações lineares com várias equações e variáveis. Nas próximas seções, estudaremos as matrizes e suas operações básicas, aprendendo utilizá-las como um instrumento. É muito importante que denominemos este instrumento matemático antes de utilizá-lo como ferramenta nas diversas aplicações possíveis.

2.3 Formalização matemática da noção de matriz

Tal como no caso das matrizes de dados, a notação que utilizamos para matrizes são letras latinas ou gregas maiúsculas em negrito. Por exemplo, $\mathbf{A}$, $\mathbf{B}$, $\mathbf{C}$, $\mathbf{X}$, $\mathbf{\Lambda}$, $\mathbf{\Sigma}$. A noção de matrizes como tabela, introduzida na Seção 1.1, pode ser formalizada matematicamente da seguinte maneira.

Definição 2.1: Matriz

Sejam n e p dois números naturais não nulos. Uma *matriz* $n \times p$ (lê-se: n por p) é uma tabela retangular formada por np números reais dispostos em n linhas e p colunas. Assim, uma matriz A pode ser representada por

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix}.$$

Observação 2.1

1. Sempre informamos primeiro o número de linhas e depois o número de colunas de uma matriz.
2. Se A é uma matriz $n \times p$, então dizemos que a matriz A é **do tipo** $n \times p$ ou **de ordem** $n \times p$.
3. Uma matriz é, essencialmente, uma tabela cujos elementos são escolhidos a partir de um **corpo** base. (Um **corpo** é um conjunto, cujos elementos podem ser somados e multiplicados de acordo com regras que possuem certas propriedades.) Nestas notas, a menos que façamos alguma advertência, esse corpo será o conjunto dos números reais. O conjunto dos números reais será denotado por $\mathbb{R}$.

Exemplo 2.6

- (a) $\begin{bmatrix} 2 & 3 \\ -4 & 1 \end{bmatrix}$ é uma matriz de **ordem** 2×2 (lê-se: dois por dois), pois possui 2 linhas e 2 colunas.
- (b) $\begin{bmatrix} \sqrt{2} & 0 & \frac{1}{2} \\ -2 & 1 & \pi \end{bmatrix}$ é uma matriz de **ordem** 2×3 (lê-se: dois por três), pois possui 2 linhas e 3 colunas.

Exemplo 2.6

- (c) $\begin{bmatrix} 1 & 0 \\ 0 & -1 \\ 1 & 0 \end{bmatrix}$ é uma matriz de **ordem** 3×2 (lê-se: três por dois), pois possui 3 linhas e 2 colunas.
- (d) $\begin{bmatrix} 1 & 2 & 3 & 4 \end{bmatrix}$ é uma matriz de **ordem** 1×4 (lê-se: um por quatro), pois possui 1 linha e 4 colunas.
- (e) $\begin{bmatrix} -\sqrt{3} \\ -\sqrt{2} \\ 0 \end{bmatrix}$ é uma matriz de **ordem** 3×1 (lê-se: três por um), pois possui 3 linhas e 1 coluna.
- (f) $\begin{bmatrix} 5 \end{bmatrix}$ é uma matriz de **ordem** 1×1 (lê-se: um por um), pois possui 1 linha e 1 coluna.

Seja $\mathbf{A}$ uma matriz qualquer de ordem $n \times p$. O **elemento genérico** dessa matriz que está na (interseção da) linha i e coluna j é indicado por a_{ij} de forma que i e j são números naturais tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Com a convenção de que as linhas sejam numeradas de cima para baixo (de 1 até n) e as colunas da esquerda para direita (de 1 até p), a matriz $\mathbf{A}$ pode ser representada por:

$$\begin{pmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{np} \end{pmatrix} \quad \text{ou} \quad \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{np} \end{bmatrix}.$$

Observação 2.2

Utilizamos letras latinas maiúsculas para indicar matrizes genéricas e letras latinas minúsculas correspondentes para os elementos genéricos.

Exemplo 2.7

Considere as seguintes matrizes

Exemplo 2.7

$$\mathbf{B} = \begin{bmatrix} 1 & \pi & -3 \\ 0 & 1 & 4 \end{bmatrix} \text{ e } \mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 2 & 5 \end{bmatrix}.$$

(a) Identifique os elementos b_{11} , b_{22} , b_{13} da matriz $\mathbf{B}$.

(b) Identifique os elementos c_{31} , c_{32} e c_{12} da matriz $\mathbf{C}$.

SOLUÇÃO:

(a) Na matriz $\mathbf{B}$, temos

- $b_{11} = 1$, pois é o elemento localizado na 1ª linha e 1ª coluna da matriz $\mathbf{B}$;
- $b_{22} = 1$, pois é o elemento localizado na 2ª linha e 2ª coluna da matriz $\mathbf{B}$;
- $b_{13} = -3$, pois é o elemento localizado na 1ª linha e 3ª coluna da matriz $\mathbf{B}$.

(b) Na matriz $\mathbf{C}$, temos

- $c_{31} = 2$, pois é o elemento localizado na 3ª linha e 1ª coluna da matriz $\mathbf{C}$;
- $c_{32} = 5$, pois é o elemento localizado na 3ª linha e 2ª coluna da matriz $\mathbf{C}$;
- $c_{12} = 0$, pois é o elemento localizado na 1ª linha e 2ª coluna da matriz $\mathbf{C}$.

De maneira abreviada, podemos denotar uma matriz genérica $\mathbf{A}$ de ordem $n \times p$ por

$$\mathbf{A}_{n \times p} = [a_{ij}]_{n \times p}.$$

Fica subentendido com essa notação que os índices i e j são números naturais tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Dependendo do contexto, caso não haja possibilidade de confusão quanto à variação dos índices, podemos omiti-los da notação escrevendo apenas $\mathbf{A}$ ou $[a_{ij}]$.

Exemplo 2.8

Escreva a matriz $\mathbf{X} = [x_{ij}]_{3 \times 2}$, em que o elemento x_{ij} que está na linha i e coluna j da matriz $\mathbf{X}$ é dado por $x_{ij} = 3i - j$.

Exemplo 2.8SOLUÇÃO:

Pelos dados do problema, a matriz $\mathbf{X}$ é de ordem 3×2 , logo deve ter 3 linhas e 2 colunas. A representação genérica dessa matriz é

$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ x_{31} & x_{32} \end{bmatrix}.$$

Portanto, a matriz solicitada é

$$\mathbf{X} = \begin{bmatrix} 2 & 1 \\ 5 & 4 \\ 8 & 7 \end{bmatrix}.$$

Exemplo 2.9

Escreva a matriz $\mathbf{Y} = [y_{ij}]_{3 \times 3}$, em que o elemento y_{ij} que está na linha i e coluna j da matriz $\mathbf{Y}$ é dado por

$$y_{ij} = \begin{cases} 1, & \text{se } i = j, \\ 0, & \text{caso contrário.} \end{cases}$$

SOLUÇÃO:

Pelos dados do problema, a matriz $\mathbf{Y}$ é de ordem 3×3 , logo deve ter 3 linhas e 3 colunas. A representação genérica dessa matriz é

$$\mathbf{Y} = \begin{bmatrix} y_{11} & y_{12} & y_{13} \\ y_{21} & y_{22} & y_{23} \\ y_{31} & y_{32} & y_{33} \end{bmatrix}.$$

Portanto, a matriz solicitada é

$$\mathbf{Y} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

Exemplo 2.10: Adaptado do Portal OBMEP

Cada prova do Exame Nacional do Ensino Médio (ENEM) possui uma matriz padrão de respostas, onde cada linha corresponde a um indivíduo inscrito na prova e cada coluna representa uma questão da prova. As entradas dessa matriz são iguais a 0 ou 1, em que 0 indica um erro e 1 indica um acerto. Assim, em 2016 a matriz padrão de respostas do ENEM possuía mais de 7 milhões e 700 mil linhas. Por outro lado, a matriz correspondente à prova de Matemática possui 45 colunas. Assim, se denotarmos a matriz padrão da prova de Matemática por $\mathbf{M} = [m_{ij}]$, ao escrevermos $m_{52} = 1$ estaremos dizendo que o(a) candidato(a) de número 5 acertou a questão 2 da prova de Matemática; da mesma forma, $m_{97} = 0$ significa que o(a) candidato(a) de número 9 errou a questão 7 da prova de Matemática.

Indicaremos por $M_{n \times p}(\mathbb{R})$ o conjunto de todas as matrizes de ordem $n \times p$ cujos elementos são números reais. Se $n = p$, ao invés de $M_{n \times p}(\mathbb{R})$, vamos usar a notação $M_n(\mathbb{R})$. Cada matriz de $M_n(\mathbb{R})$ chama-se **matriz quadrada de ordem n** . Por outro lado, quando $n \neq p$, uma matriz de ordem $n \times p$ se diz uma **matriz retangular**. Uma matriz de ordem 1×1 $[a_{11}]$ se identifica com o número real a_{11} .

Exemplo 2.11

$$(a) \mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix} \text{ é uma matriz quadrada de ordem } 3 \times 3. \text{ Em outras palavras, } \mathbf{A} \in M_3(\mathbb{R}).$$

$$(b) \mathbf{B} = \begin{bmatrix} -1 & 0 & 0 \\ 1 & -1 & 0 \end{bmatrix} \text{ é uma matriz retangular de ordem } 2 \times 3. \text{ Em outras palavras, } \mathbf{B} \in M_{2 \times 3}(\mathbb{R}).$$

$$(c) \mathbf{C} = \begin{bmatrix} \sqrt{2} & -\sqrt{2} \\ -\sqrt{2} & \sqrt{2} \end{bmatrix} \text{ é uma matriz quadrada de ordem } 2 \times 2. \text{ Em outras palavras, } \mathbf{C} \in M_2(\mathbb{R}).$$

$$(d) \mathbf{D} = \begin{bmatrix} 5 \\ \frac{1}{2} \end{bmatrix} \text{ é uma matriz retangular de ordem } 2 \times 1. \text{ Em outras palavras, } \mathbf{D} \in M_{2 \times 1}(\mathbb{R}).$$

Exemplo 2.12

- (e) $\mathbf{E} = [\pi]$ é uma matriz de ordem 1×1 , a qual pode ser identificada como o número real π .

2.4 Matriz como fruto de uma transformação linear

Na seção anterior, apresentamos a definição formal de matriz e a interpretamos como uma tabela retangular composta por elementos dispostos em linhas e colunas. Nesta seção, daremos um passo adiante e mostraremos como as matrizes surgem naturalmente a partir das transformações lineares entre espaços vetoriais. Em outras palavras, veremos que toda transformação linear pode ser representada por uma matriz, e que as operações matriciais nada mais são do que expressões algébricas dessas transformações. Essa perspectiva nos permitirá compreender o papel geométrico das matrizes e sua relevância na formulação de problemas estatísticos.

O conceito de *linearidade* está presente em praticamente toda a Estatística. Na matemática elementar, o termo “função linear” costuma estar associado a retas no plano cartesiano. No entanto, em níveis mais avançados, a ideia de linearidade é muito mais ampla. Lembre-se de que uma função é simplesmente uma regra que associa cada elemento de um conjunto, chamado de *domínio*, a um elemento de outro conjunto, chamado de *imagem*. As funções lineares formam um tipo especial de função, caracterizado por preservar certas propriedades que estudaremos a seguir — e é justamente essa preservação que dá origem ao papel central das matrizes na representação dessas funções.

Definição 2.2: Transformação linear

Seja n um número inteiro positivo. Uma aplicação $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é denominada *transformação linear* de $\mathbb{R}^p$ em $\mathbb{R}^n$ quando

- (a) $F(\mathbf{u} + \mathbf{v}) = F(\mathbf{u}) + F(\mathbf{v})$, quaisquer que sejam os vetores $\mathbf{u} \in \mathbb{R}^p$ e $\mathbf{v} \in \mathbb{R}^p$ e
- (b) $F(\alpha \mathbf{u}) = \alpha F(\mathbf{u})$, qualquer que seja o número real α e o vetor $\mathbf{u} \in \mathbb{R}^p$.

Quando $n = p$, uma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^p$ é chamada também de *operador linear*.

Exemplo 2.13

(a) Seja a aplicação linear $F : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ tal que

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = \begin{bmatrix} x \\ 2x - z \end{bmatrix}.$$

Mostre que F é uma transformação linear.

(b) Verifique que a aplicação $F : \mathbb{R} \rightarrow \mathbb{R}^2$, dada por

$$F(x) = \begin{bmatrix} x \\ 2 \end{bmatrix},$$

não é uma transformação linear.

SOLUÇÃO:

(a) Sejam $\mathbf{u}, \mathbf{v} \in \mathbb{R}^3$ e $\alpha \in \mathbb{R}$. Pela definição da F , temos

$$F(\mathbf{u} + \mathbf{v}) = F\left(\begin{bmatrix} u_1 \\ u_2 \\ u_3 \end{bmatrix} + \begin{bmatrix} v_1 \\ v_2 \\ v_3 \end{bmatrix}\right) = F\left(\begin{bmatrix} u_1 + v_1 \\ u_2 + v_2 \\ u_3 + v_3 \end{bmatrix}\right) = \begin{bmatrix} u_1 + v_1 \\ 2(u_1 + v_1) - (u_3 + v_3) \end{bmatrix}.$$

Como

$$\begin{bmatrix} u_1 + v_1 \\ 2(u_1 + v_1) - (u_3 + v_3) \end{bmatrix} = \begin{bmatrix} u_1 \\ 2u_1 - u_3 \end{bmatrix} + \begin{bmatrix} v_1 \\ 2v_1 - v_3 \end{bmatrix} = F(\mathbf{u}) + F(\mathbf{v}),$$

segue que $F(\mathbf{u} + \mathbf{v}) = F(\mathbf{u}) + F(\mathbf{v})$.

Além disso,

$$F(\alpha \mathbf{u}) = F\left(\begin{bmatrix} \alpha u_1 \\ \alpha u_2 \\ \alpha u_3 \end{bmatrix}\right) = \begin{bmatrix} \alpha u_1 \\ 2\alpha u_1 - \alpha u_3 \end{bmatrix} = \alpha \begin{bmatrix} u_1 \\ 2u_1 - u_3 \end{bmatrix} = \alpha F(\mathbf{u}).$$

Portanto, F satisfaz as propriedades de aditividade e homogeneidade, logo é uma transformação linear.

Exemplo 2.13

(b) Para todo $x, y \in \mathbb{R}$, temos

$$F(x + y) = \begin{bmatrix} x + y \\ 2 \end{bmatrix} \neq \begin{bmatrix} x \\ 2 \end{bmatrix} + \begin{bmatrix} y \\ 2 \end{bmatrix} = F(x) + F(y).$$

Portanto, F não satisfaz a propriedade de aditividade e, conseqüentemente, **não** é uma transformação linear.

Um dos exemplos mais simples de função linear é $f(x) = \alpha x$, cujo gráfico em $\mathbb{R}^2$ é uma reta que passa pela origem. Já a função $f(x) = \alpha x + \beta$ não é considerada linear, pois seu gráfico é uma reta que foi deslocada da origem pelo valor constante β . Esse tipo de função é chamado de **função afim**, ou seja, uma versão “transladada” de uma função linear.

Em $\mathbb{R}^3$, uma função da forma

$$f(x_1, x_2) = \alpha_1 x_1 + \alpha_2 x_2$$

define um plano que passa pela origem, portanto é linear. Se adicionarmos um termo constante β , o gráfico de

$$f(x_1, x_2) = \alpha_1 x_1 + \alpha_2 x_2 + \beta$$

representa um plano que não passa pela origem, caracterizando novamente uma **função afim**.

De forma mais geral, uma função linear de $\mathbb{R}^2$ em $\mathbb{R}^3$ transforma vetores do plano em vetores do espaço tridimensional, de modo que cada coordenada da imagem em $\mathbb{R}^3$ é uma combinação linear das variáveis x_1 e x_2 , isto é,

$$F(x_1, x_2) = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 \\ a_{21}x_1 + a_{22}x_2 \\ a_{31}x_1 + a_{32}x_2 \end{bmatrix}.$$

De maneira análoga, uma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ associa a cada vetor $\mathbf{x} = [x_1, \dots, x_p]^\top$ um vetor $\mathbf{y} = F(\mathbf{x})$ em $\mathbb{R}^n$, em que cada coordenada y_i é uma combinação linear das componentes de $\mathbf{x}$, i.e.,

$$y_i = a_{i1}x_1 + a_{i2}x_2 + \dots + a_{ip}x_p, \quad \text{para } i = 1, 2, \dots, n.$$

Assim, a transformação linear preserva a estrutura linear do espaço vetorial, sendo completamente descrita pela matriz dos coeficientes $\mathbf{A} = [a_{ij}]_{n \times p}$. Nesse sentido, uma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ pode ser escrita de forma geral como

$$F(x_1, x_2, \dots, x_p) = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \dots + a_{1p}x_p \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2p}x_p \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{np}x_p \end{bmatrix}.$$

Cada coordenada de $F(\mathbf{x})$ em $\mathbb{R}^n$ é uma combinação linear das variáveis $x_1, x_2, \dots, x_p$. Uma maneira conveniente de organizar esses coeficientes é armazená-los em uma tabela de n linhas e p colunas, que chamamos de *matriz da transformação linear*. Assim, podemos representar F de maneira compacta por meio da igualdade vetorial

$$F \left(\begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \right) = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{np} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix},$$

ou, de forma mais compacta,

$$F(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

A expressão acima mostra que toda transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^n$ pode ser descrita completamente por uma matriz $\mathbf{A}$, cujas colunas determinam como cada vetor da base canônica de $\mathbb{R}^p$ é transformado em $\mathbb{R}^n$.

Exemplo 2.14

Determine as matrizes das transformações lineares F definidas a seguir:

(a) $F : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ tal que

$$F \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} x + y \\ x \end{bmatrix}.$$

(b) $F : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ tal que

$$F \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} x + y \\ y + z \end{bmatrix}.$$

Exemplo 2.14

(c) $F : \mathbb{R}^3 \rightarrow \mathbb{R}^3$ tal que

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = \begin{bmatrix} x + 2y + 3z \\ x + y - z \\ 2x + 4y \end{bmatrix}.$$

SOLUÇÃO:

(a) Cada coordenada de $F\left(\begin{bmatrix} x \\ y \end{bmatrix}\right)$ pode ser escrita como combinação linear de x e y :

$$F\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 1 \times x + 1 \times y \\ 1 \times x + 0 \times y \end{bmatrix}.$$

Logo, a matriz associada à transformação linear é

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}.$$

(b) De modo semelhante,

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = \begin{bmatrix} 1 \times x + 1 \times y + 0 \times z \\ 0 \times x + 1 \times y + 1 \times z \end{bmatrix},$$

e portanto,

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}.$$

(c) Escrevendo cada coordenada de $F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right)$,

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = \begin{bmatrix} 1 \times x + 2 \times y + 3 \times z \\ 1 \times x + 1 \times y - 1 \times z \\ 2 \times x + 4 \times y + 0 \times z \end{bmatrix},$$

Exemplo 2.14

a matriz associada à transformação linear é

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 1 & -1 \\ 2 & 4 & 0 \end{bmatrix}.$$

Exemplo 2.15

Determine as transformações lineares F associadas às seguintes matrizes:

(a)

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 0 \end{bmatrix}.$$

(b)

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & -1 \end{bmatrix}.$$

SOLUÇÃO:

(a) A matriz $\mathbf{A}$ possui 2 linhas e 3 colunas, logo a transformação linear associada é

$$F : \mathbb{R}^3 \rightarrow \mathbb{R}^2.$$

Para um vetor genérico $\mathbf{x} = \begin{bmatrix} x \\ y \\ z \end{bmatrix}$, temos

$$F(\mathbf{x}) = \mathbf{A}\mathbf{x} = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x + 2y + 3z \\ y \end{bmatrix}.$$

Portanto,

$$F(\mathbf{x}) = \begin{bmatrix} x + 2y + 3z \\ y \end{bmatrix}.$$

Exemplo 2.15

(b) Agora, como $\mathbf{A}$ possui 2 linhas e 2 colunas, segue que

$$F : \mathbb{R}^2 \rightarrow \mathbb{R}^2.$$

Assim, para $\mathbf{x} = \begin{bmatrix} x \\ y \end{bmatrix}$,

$$F(\mathbf{x}) = \mathbf{A}\mathbf{x} = \begin{bmatrix} 2 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 2x + y \\ x - y \end{bmatrix}.$$

Portanto,

$$F(\mathbf{x}) = \begin{bmatrix} 2x + y \\ x - y \end{bmatrix}.$$

Resultado 2.1

Seja $F : \mathbb{R}^n \rightarrow \mathbb{R}^p$ uma transformação linear. Então, são verdadeiras as seguintes propriedades:

- (a) $F(\mathbf{0}_n) = \mathbf{0}_p$, em que $\mathbf{0}_n$ é o vetor nulo de $\mathbb{R}^n$ e $\mathbf{0}_p$ é o vetor nulo de $\mathbb{R}^p$.
- (b) $F(-\mathbf{u}) = -F(\mathbf{u})$, para todo $\mathbf{u} \in \mathbb{R}^n$.
- (c) $F(\mathbf{u} - \mathbf{v}) = F(\mathbf{u}) - F(\mathbf{v})$, para todo $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$.
- (d) $F(\alpha_1 \mathbf{u}_1 + \cdots + \alpha_n \mathbf{u}_n) = \alpha_1 F(\mathbf{u}_1) + \cdots + \alpha_n F(\mathbf{u}_n)$, para todo $\mathbf{u}_i \in \mathbb{R}^n$ e $\alpha_i \in \mathbb{R}$, com $i = 1, 2, \dots, n$.

DEMONSTRAÇÃO:

- (a) Como F é linear, temos $F(\mathbf{0}_n) = F(\mathbf{0}_n + \mathbf{0}_n)$. Pela propriedade da aditividade, isso implica

$$F(\mathbf{0}_n) = F(\mathbf{0}_n) + F(\mathbf{0}_n).$$

Subtraindo $F(\mathbf{0}_n)$ dos dois lados da igualdade, obtemos

$$\mathbf{0}_p = F(\mathbf{0}_n),$$

Resultado 2.1

ou seja, a imagem do vetor nulo de $\mathbb{R}^n$ é o vetor nulo de $\mathbb{R}^p$.

(b) Note que $\mathbf{0}_n = \mathbf{u} + (-\mathbf{u})$. Aplicando F e usando a linearidade, temos:

$$F(\mathbf{0}_n) = F(\mathbf{u} + (-\mathbf{u})) = F(\mathbf{u}) + F(-\mathbf{u}).$$

Pela propriedade anterior, $F(\mathbf{0}_n) = \mathbf{0}_p$, logo

$$\mathbf{0}_p = F(\mathbf{u}) + F(-\mathbf{u}),$$

e portanto

$$F(-\mathbf{u}) = -F(\mathbf{u}).$$

(c) Temos $\mathbf{u} - \mathbf{v} = \mathbf{u} + (-\mathbf{v})$. Aplicando F e usando a aditividade e o resultado anterior:

$$F(\mathbf{u} - \mathbf{v}) = F(\mathbf{u} + (-\mathbf{v})) = F(\mathbf{u}) + F(-\mathbf{v}) = F(\mathbf{u}) - F(\mathbf{v}).$$

(d) A linearidade de F garante que, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ e escalares $\alpha, \beta \in \mathbb{R}$, vale:

$$F(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha F(\mathbf{u}) + \beta F(\mathbf{v}).$$

Aplicando esse raciocínio de forma iterativa a n vetores, obtemos:

$$F(\alpha_1\mathbf{u}_1 + \cdots + \alpha_n\mathbf{u}_n) = \alpha_1 F(\mathbf{u}_1) + \cdots + \alpha_n F(\mathbf{u}_n).$$

■

Exemplo 2.16

Seja $F : \mathbb{R}^3 \rightarrow \mathbb{R}^3$ um operador linear tal que

$$F\left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix}, \quad F\left(\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 5 \\ 2 \\ 7 \end{bmatrix}, \quad F\left(\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}\right) = \begin{bmatrix} -2 \\ 0 \\ 7 \end{bmatrix}.$$

Exemplo 2.16

Determinar $F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right)$, em que $\begin{bmatrix} x \\ y \\ z \end{bmatrix}$ é um vetor genérico de $\mathbb{R}^3$.

SOLUÇÃO:

Como F é linear, o vetor $\begin{bmatrix} x \\ y \\ z \end{bmatrix}$ pode ser escrito como

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = x \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} + y \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} + z \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Logo,

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = xF\left(\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}\right) + yF\left(\begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}\right) + zF\left(\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}\right).$$

Substituindo as imagens conhecidas, obtemos

$$F\left(\begin{bmatrix} x \\ y \\ z \end{bmatrix}\right) = x \begin{bmatrix} 2 \\ 3 \\ 1 \end{bmatrix} + y \begin{bmatrix} 5 \\ 2 \\ 7 \end{bmatrix} + z \begin{bmatrix} -2 \\ 0 \\ 7 \end{bmatrix} = \begin{bmatrix} 2x + 5y - 2z \\ 3x + 2y \\ x + 7y + 7z \end{bmatrix}.$$

Assim, a transformação linear F pode ser expressa matricialmente como

$$F(\mathbf{x}) = \mathbf{A}\mathbf{x}, \quad \text{de modo que} \quad \mathbf{A} = \begin{bmatrix} 2 & 5 & -2 \\ 3 & 2 & 0 \\ 1 & 7 & 7 \end{bmatrix}.$$

Indicaremos por $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ o conjunto de todas as transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$. Assim, cada elemento de $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ associa a cada vetor $\mathbf{x} \in \mathbb{R}^p$ um vetor $\mathbf{y} \in \mathbb{R}^n$ por meio de uma relação linear, isto é, $F(\alpha\mathbf{u} + \beta\mathbf{v}) = \alpha F(\mathbf{u}) + \beta F(\mathbf{v})$ para todos $\mathbf{u}, \mathbf{v} \in \mathbb{R}^p$ e $\alpha, \beta \in \mathbb{R}$.

Existe uma correspondência natural entre transformações lineares e matrizes. De fato,

podemos construir uma função *bijetora*

$$\Phi : M_{n \times p}(\mathbb{R}) \longrightarrow \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$$

tal que, para cada matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$, associamos a transformação linear $F_{\mathbf{A}} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ definida por

$$F_{\mathbf{A}}(\mathbf{x}) = \mathbf{A}\mathbf{x}.$$

Reciprocamente, dada uma transformação linear $F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$, existe uma única matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ tal que $F(\mathbf{x}) = \mathbf{A}\mathbf{x}$ para todo $\mathbf{x} \in \mathbb{R}^p$.

Portanto, existe uma correspondência biunívoca entre matrizes reais de ordem $n \times p$ e transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$, em outras palavras dizemos que $M_{n \times p}(\mathbb{R})$ e $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ são *isomorfos* e denotamos da seguinte maneira

$$M_{n \times p}(\mathbb{R}) \cong \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n).$$

Assim, dado uma matriz, temos uma transformação linear associada, e dada uma transformação linear, podemos determinar a matriz que a representa em relação às bases canônicas.

2.5 Matrizes especiais

Há matrizes que, por apresentarem uma utilidade maior na teoria, recebem nomes especiais dependendo de certas características. A seguir, veremos algumas dessas matrizes.

Definição 2.3: Matriz linha

Seja p um número inteiro positivo. Uma matriz de ordem $1 \times p$ é dita ser uma *matriz linha*. Em outras palavras, uma matriz linha é aquela que possui uma única linha.

Definição 2.4: Matriz coluna

Seja n um número inteiro positivo. Uma matriz de ordem $n \times 1$ é dita ser uma *matriz coluna*. Em outras palavras, uma matriz coluna é aquela que possui uma única coluna.

Exemplo 2.17

(a) $\begin{bmatrix} 1 & \sqrt{5} & \frac{1}{3} \end{bmatrix}$ é uma **matriz linha** de ordem 1×3 .

(b) $\begin{bmatrix} -1 \\ 10 \\ \frac{1}{4} \end{bmatrix}$ é uma **matriz coluna** de ordem 3×1 .

(c) $\begin{bmatrix} 0 & 5 & -7 & 2 \end{bmatrix}$ é uma **matriz linha** de ordem 1×4 .

(d) $\begin{bmatrix} 9 \\ 9 \end{bmatrix}$ é uma **matriz coluna** de ordem 2×1 .

Definição 2.5: Matriz nula

Sejam n e p dois números inteiros positivos. Uma matriz de ordem $n \times p$ cujos elementos são todos iguais a zero é dita ser uma *matriz nula*. Notação: $\mathbf{O}_{n \times p}$.

Exemplo 2.18

(a) $\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ é uma **matriz nula** de ordem 2×3 .

(b) $\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$ é uma **matriz nula** de ordem 2×2 .

(c) $\begin{bmatrix} 0 & 0 & 0 \end{bmatrix}$ é uma **matriz linha nula** de ordem 1×3 .

(d) $\begin{bmatrix} 0 \\ 0 \end{bmatrix}$ é uma **matriz coluna nula** de ordem 2×1 .

Definição 2.6: Matriz quadrada

Seja n um número inteiro positivo. Uma matriz de ordem $n \times n$ é dita ser uma *matriz quadrada*. Em outras palavras, uma matriz quadrada é aquela cujo número de linhas é igual ao número de colunas.

Exemplo 2.19

(a) $\begin{bmatrix} 3 & 5 \\ 2 & 6 \end{bmatrix}$ é uma **matriz quadrada** de ordem 2×2 .

(b) $\begin{bmatrix} 5 & 3 & 10 \\ -1 & -4 & 6 \\ \sqrt{2} & 0 & -\frac{1}{2} \end{bmatrix}$ é uma **matriz quadrada** de ordem 3×3 .

(c) $\begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$ é uma **matriz quadrada nula** de ordem 4×4 .

Definição 2.7: Diagonais de uma matriz quadrada

Sejam n um número natural não-nulo e A uma matriz quadrada de ordem $n \times n$. Em outras palavras,

$$A = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}.$$

(a) A *diagonal principal* da matriz A é o conjunto dos elementos a_{ij} tais que $i = j$, i.e., que possuem os índices iguais. Dessa forma, a diagonal principal de A é o conjunto

$$\{a_{ij} : i = j\} = \{a_{11}, a_{22}, \dots, a_{nn}\}.$$

(b) A *diagonal secundária* da matriz A é o conjunto dos elementos a_{ij} tais que $i + j = n + 1$, i.e., que possuem a soma dos índices igual a $n + 1$. Dessa forma, a diagonal secundária de A é o conjunto

$$\{a_{ij} : i + j = n + 1\} = \{a_{1n}, a_{2,n-1}, \dots, a_{n1}\}.$$

Na matriz a seguir, a diagonal principal está em azul e a diagonal secundária em vermelho.

$$\begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}$$

Exemplo 2.20

(a) $\begin{bmatrix} 9 & 4 \\ -4 & -9 \end{bmatrix}$ é uma matriz quadrada de ordem 2×2 . Sua **diagonal principal** é $\{9, -9\}$ e sua **diagonal secundária** é $\{4, -4\}$.

(b) $\begin{bmatrix} 8 & 9 & -7 \\ 6 & 4 & -5 \\ -1 & 2 & 3 \end{bmatrix}$ é uma matriz quadrada de ordem 3×3 . Sua **diagonal principal** é $\{8, 4, 3\}$ e sua **diagonal secundária** é $\{-7, 4, 1\}$.

(c) $\begin{bmatrix} 0 & 1 & 2 & 3 \\ 4 & 5 & 6 & 7 \\ 8 & 9 & -1 & -2 \\ -3 & -4 & -5 & -6 \end{bmatrix}$ é uma matriz quadrada de ordem 4×4 . Sua **diagonal principal** é $\{0, 5, -1, -6\}$ e sua **diagonal secundária** é $\{3, 6, 9, -3\}$.

Definição 2.8: Matriz triangular

Seja n um número inteiro positivo. Uma matriz quadrada de ordem $n \times n$ cujos elementos acima **ou** abaixo da diagonal principal são todos nulos é dita ser uma *matriz triangular*.

A matriz triangular cujos elementos abaixo da diagonal principal são todos zeros é chamada de *matriz triangular superior*. Na matriz triangular superior a seguir, os elementos iguais a zero estão em verde.

$$\begin{pmatrix} c_{11} & c_{12} & c_{13} \\ 0 & c_{22} & c_{23} \\ 0 & 0 & c_{33} \end{pmatrix}$$

Por outro lado, a matriz triangular cujos elementos acima da diagonal principal são todos zeros é chamada de *matriz triangular inferior*. Na matriz triangular inferior a seguir, os elementos iguais a zero estão em verde.

$$\begin{pmatrix} c_{11} & 0 & 0 \\ c_{12} & c_{22} & 0 \\ c_{31} & c_{32} & c_{33} \end{pmatrix}$$

Exemplo 2.21

(a) $\begin{bmatrix} 2 & 0 & 0 \\ 8 & 5 & 0 \\ 7 & 9 & -5 \end{bmatrix}$ é uma **matriz triangular inferior** de ordem 3×3 .

(b) $\begin{bmatrix} 3 & 5 \\ 0 & 2 \end{bmatrix}$ é uma **matriz triangular superior** de ordem 2×2 .

(c) $\begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 4 \end{bmatrix}$ é uma **matriz triangular** (inferior e superior) de ordem 4×4 .

(d) $\begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$ é uma **matriz triangular nula** de ordem 4×4 .

Observação 2.3

Toda matriz triangular é quadrada, mas nem toda matriz quadrada é triangular.

Definição 2.9: Matriz diagonal

Seja n um número inteiro positivo. Uma matriz quadrada de ordem $n \times n$ cujos elementos acima e abaixo da diagonal principal são nulos é dita ser uma *matriz diagonal*.

Exemplo 2.22

(a) $\begin{bmatrix} 3 & 0 \\ 0 & -2 \end{bmatrix}$ é uma **matriz diagonal** de ordem 2×2 .

(b) $\begin{bmatrix} 4 & 0 & 0 \\ 0 & -2 & 0 \\ 0 & 0 & -3 \end{bmatrix}$ é uma **matriz diagonal** de ordem 3×3 .

(c) $\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ é uma **matriz diagonal nula** de ordem 3×3 .

(d) $\begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ é uma **matriz diagonal** de ordem 3×3 .

Observação 2.4

1. Toda matriz nula é também uma matriz diagonal.
2. Toda matriz diagonal é uma matriz triangular, mas nem toda matriz triangular é diagonal.

Definição 2.10: Matriz identidade

Seja n um número inteiro positivo. Uma matriz diagonal de ordem $n \times n$ cujos elementos da diagonal principal são todos iguais a 1 é dita ser uma *matriz identidade*. Denotaremos a matriz identidade de ordem $n \times n$ por $\mathbf{I}_n$.

2.6 Igualdade de matrizes e igualdade de transformações lineares

Definição 2.11: Transformações lineares iguais

Sejam n e p números inteiros positivos. Considere duas transformações lineares F e G de $\mathbb{R}^p$ em $\mathbb{R}^n$, isto é, $F, G \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$. Dizemos que F e G são *iguais* quando

$$F(\mathbf{x}) = G(\mathbf{x}), \quad \text{para todo } \mathbf{x} \in \mathbb{R}^p.$$

Em outras palavras, duas transformações lineares são iguais quando produzem o mesmo vetor imagem em $\mathbb{R}^n$ para todo vetor $\mathbf{x}$ do domínio $\mathbb{R}^p$.

Como cada transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ pode ser representada por uma matriz $\mathbf{A}_F \in M_{n \times p}(\mathbb{R})$ tal que $F(\mathbf{x}) = \mathbf{A}_F \mathbf{x}$, segue que

$$F = G \iff \mathbf{A}_F = \mathbf{A}_G.$$

Assim, duas transformações lineares são iguais se, e somente se, as suas matrizes associadas são iguais.

Definição 2.12: Matrizes iguais

Sejam n e p números inteiros positivos. Duas matrizes $\mathbf{A} = [a_{ij}]_{n \times p}$ e $\mathbf{B} = [b_{ij}]_{n \times p}$ são ditas *iguais* quando $a_{ij} = b_{ij}$ para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Em outras palavras, as matrizes $\mathbf{A}$ e $\mathbf{B}$ são iguais quando cada elemento da matriz $\mathbf{A}$ é igual ao *elemento correspondente* (elemento que possui o mesmo índice) da matriz $\mathbf{B}$.

Exemplo 2.23

$$(a) \quad \begin{bmatrix} 1 & -3 \\ 7 & -4 \end{bmatrix} = \begin{bmatrix} 1 & -3 \\ 7 & -4 \end{bmatrix}, \text{ pois os elementos correspondentes (com mesmos índices) são todos iguais.}$$

Exemplo 2.23

(b) $\begin{bmatrix} 1 & -3 \\ 7 & -4 \end{bmatrix} \neq \begin{bmatrix} 1 & 7 \\ -3 & 4 \end{bmatrix}$, pois os elementos correspondentes (com mesmo índice) não são todos iguais. Por exemplo, os elementos situados na 2ª linha e 1ª coluna são distintos ($7 \neq -3$).

(c) $\begin{bmatrix} 1 & 0 & 1 \\ 2 & 1 & 4 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 1 & 4 \end{bmatrix}$, pois as ordens das matrizes são diferentes.

(d) $\begin{bmatrix} 1 & 2 & 4 \\ 1 & 3 & 3 \end{bmatrix} \neq \begin{bmatrix} 1 & 2 & 4 \\ 1 & 3 & 3 \\ 0 & 0 & 0 \end{bmatrix}$, pois as ordens das matrizes são diferentes.

Observação 2.5

Só é possível falar da igualdade de duas matrizes quando elas possuem a mesma ordem. Assim, quando duas matrizes possuem ordens distintas elas são diferentes.

Exemplo 2.24

Sejam $\mathbf{A}$ e $\mathbf{B}$ duas matrizes quadradas de ordem 2×2 definidas da seguinte maneira

$$\mathbf{A} = \begin{bmatrix} 2 & 5 \\ 10 & 1 \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} x+y & 5 \\ 3x-y & 1 \end{bmatrix}.$$

Determine os números reais x e y para os quais $\mathbf{A} = \mathbf{B}$.

SOLUÇÃO:

Para satisfazer a definição de igualdade de matrizes, devemos ter

$$\begin{cases} x+y &= 2, \\ 5 &= 5, \\ 3x-y &= 10, \\ 1 &= 1. \end{cases}$$

Exemplo 2.24

Note que da primeira e da terceira equação concluímos que $x = 3$ e $y = -1$. As demais equações também são satisfeitas. Portanto, os números reais x e y para os quais $A = B$ são $x = 3$ e $y = -1$.

Exemplo 2.25

Encontre, se houver, todos os números reais x e y tais que

$$\begin{bmatrix} 8x & 7 \\ 3 & 3y \end{bmatrix} = \begin{bmatrix} 16 & 0 \\ 3 & 9 \end{bmatrix}.$$

SOLUÇÃO:

Não existem x e y que satisfazem a igualdade uma vez que, nas matrizes dadas, os elementos situados na linha 1 e coluna 2 são distintos ($7 \neq 0$).

Observação 2.6

Na solução do problema anterior, devemos tomar cuidado, pois somos tentados a resolver a equação $8x = 16$ e $3y = 9$, o que nos daria $x = 2$ e $y = 3$. Estas condições são necessárias para a igualdade das matrizes, mas não são suficientes. De fato, mesmo com $x = 2$ e $y = 3$ temos

$$\begin{bmatrix} 16 & 7 \\ 3 & 9 \end{bmatrix} \neq \begin{bmatrix} 16 & 0 \\ 3 & 9 \end{bmatrix}.$$

2.7 $M_{n \times p}(\mathbb{R})$ e $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ como espaços vetoriais isomorfos

Primeiro, querido(a) leitor(a), este autor relembra que, para definir um *espaço vetorial*, é necessário estabelecer duas operações fundamentais: a *soma* entre elementos do conjunto e a *multiplicação* desses elementos por um escalar (que, em nosso caso, pertence ao conjunto dos números reais). Somente após a definição clara dessas operações e a verificação de que elas satisfazem os axiomas correspondentes é que podemos afirmar que determinado con-

junto constitui de fato um espaço vetorial real. Portanto, esta será nossa missão ao longo desta seção.

Definição 2.13: Adição de transformações lineares

Sejam F e G duas transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$, isto é, $F, G \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$. A soma de F com G , denotada por $(F + G)$, é a transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^n$ definida por

$$(F + G)(\mathbf{x}) = F(\mathbf{x}) + G(\mathbf{x}), \quad \text{para todo } \mathbf{x} \in \mathbb{R}^p.$$

Em outras palavras, a soma de duas transformações lineares consiste em somar, para cada vetor $\mathbf{x}$ do domínio, as imagens correspondentes $F(\mathbf{x})$ e $G(\mathbf{x})$ em $\mathbb{R}^n$.

Suponha que F e G sejam transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$ tais que

$$F(\mathbf{x}) = \mathbf{A}_F \mathbf{x} \quad \text{e} \quad G(\mathbf{x}) = \mathbf{A}_G \mathbf{x},$$

em que

$$\mathbf{A}_F = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1p} \\ a_{21} & a_{22} & \cdots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{np} \end{bmatrix}, \quad \mathbf{A}_G = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix}.$$

Para todo vetor $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p$, tem-se

$$F(\mathbf{x}) = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p \end{bmatrix}, \quad G(\mathbf{x}) = \begin{bmatrix} b_{11}x_1 + b_{12}x_2 + \cdots + b_{1p}x_p \\ b_{21}x_1 + b_{22}x_2 + \cdots + b_{2p}x_p \\ \vdots \\ b_{n1}x_1 + b_{n2}x_2 + \cdots + b_{np}x_p \end{bmatrix}.$$

Logo, pelo modo como foi definido a soma de vetores,

$$(F + G)(\mathbf{x}) = F(\mathbf{x}) + G(\mathbf{x}) = \begin{bmatrix} (a_{11} + b_{11})x_1 + (a_{12} + b_{12})x_2 + \cdots + (a_{1p} + b_{1p})x_p \\ (a_{21} + b_{21})x_1 + (a_{22} + b_{22})x_2 + \cdots + (a_{2p} + b_{2p})x_p \\ \vdots \\ (a_{n1} + b_{n1})x_1 + (a_{n2} + b_{n2})x_2 + \cdots + (a_{np} + b_{np})x_p \end{bmatrix}.$$

Portanto, a transformação linear $(F + G)$ pode ser escrita como

$$(F + G)(\mathbf{x}) = \mathbf{A}_{F+G}\mathbf{x},$$

em que

$$\mathbf{A}_{F+G} = \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \dots & a_{1p} + b_{1p} \\ a_{21} + b_{21} & a_{22} + b_{22} & \dots & a_{2p} + b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} + b_{n1} & a_{n2} + b_{n2} & \dots & a_{np} + b_{np} \end{bmatrix}.$$

Assim, verificamos que cada elemento da matriz associada a $(F + G)$ é obtido pela soma dos elementos correspondentes das matrizes $\mathbf{A}_F$ e $\mathbf{A}_G$. Essa observação motiva a definição da *soma de matrizes*, que será apresentada a seguir.

Definição 2.14: Adição de matrizes

Sejam n e p números inteiros positivo. A *soma* da matriz $\mathbf{A} = [a_{ij}]_{n \times p}$ com a matriz $\mathbf{B} = [b_{ij}]_{n \times p}$, que indicamos por $\mathbf{A} + \mathbf{B}$, é a matriz $\mathbf{C} = [c_{ij}]_{n \times p}$ tal que

$$c_{ij} = a_{ij} + b_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Em outras palavras, a adição entre duas matrizes de mesma ordem é efetuada somando-se os seus elementos correspondentes (com mesmos índices). Assim,

$$\mathbf{C} = \mathbf{A} + \mathbf{B} = \begin{bmatrix} a_{11} + b_{11} & a_{12} + b_{12} & \dots & a_{1p} + b_{1p} \\ a_{21} + b_{21} & a_{22} + b_{22} & \dots & a_{2p} + b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} + b_{n1} & a_{n2} + b_{n2} & \dots & a_{np} + b_{np} \end{bmatrix}.$$

Exemplo 2.26

Sejam $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ matrizes quadradas de ordem 2×2 definidas da seguinte maneira

$$\mathbf{A} = \begin{bmatrix} -2 & 4 \\ 0 & -1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} \quad \text{e} \quad \mathbf{C} = \begin{bmatrix} 3 & 0 \\ -5 & 2 \end{bmatrix}.$$

Calcule:

Exemplo 2.26

(a) $A + B$.

(b) $B + C$.

SOLUÇÃO:

(a)

$$A + B = \begin{bmatrix} -2 & 4 \\ 0 & -1 \end{bmatrix} + \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} = \begin{bmatrix} -2+4 & 4+2 \\ 0-6 & -1+0 \end{bmatrix} = \begin{bmatrix} 2 & 6 \\ -6 & -1 \end{bmatrix}.$$

(b)

$$B + C = \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} + \begin{bmatrix} 3 & 0 \\ -5 & 2 \end{bmatrix} = \begin{bmatrix} 4+3 & 2+0 \\ -6-5 & 0+2 \end{bmatrix} = \begin{bmatrix} 7 & 2 \\ -11 & 2 \end{bmatrix}.$$

Observação 2.7

1. Para que seja possível somar duas matrizes, é necessário que ambas tenham a mesma ordem.
2. A operação que transforma cada par A e B de matrizes da mesma ordem $n \times p$ na matriz $A + B$ chama-se *adição de matrizes*. Essa é uma operação definida no conjunto $M_{n \times p}(\mathbb{R})$ de todas as matrizes de ordem $n \times p$ com elementos reais.

O resultado seguinte é consequência das propriedades da adição entre números reais.

Resultado 2.2: Propriedades da adição de matrizes

A adição de matrizes no conjunto $M_{n \times p}(\mathbb{R})$ de todas as matrizes de ordem $n \times p$ apresenta as seguintes propriedades:

- (a) (*Associativa*) $(A + B) + C = A + (B + C)$ quaisquer que sejam as matrizes $A, B, C \in M_{n \times p}(\mathbb{R})$.
- (b) (*Comutativa*) $A + B = B + A$ quaisquer que sejam as matrizes $A, B \in M_{n \times p}(\mathbb{R})$.
- (c) (*Elemento neutro aditivo*) A matriz nula O de ordem $n \times p$ é tal que $A + O = A$ para todo $A \in M_{n \times p}(\mathbb{R})$. Portanto, a matriz nula é o elemento neutro aditivo.

Resultado 2.2

- (d) (*Elemento oposto*) Para toda matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$, existe uma única matriz $-\mathbf{A}$, também de ordem $n \times p$, tal que $\mathbf{A} + (-\mathbf{A}) = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times p$.

DEMONSTRAÇÃO:

- (a) Fazendo $\mathbf{X} = (\mathbf{A} + \mathbf{B}) + \mathbf{C}$ e $\mathbf{Y} = \mathbf{A} + (\mathbf{B} + \mathbf{C})$, segue que o elemento genérico x_{ij} da matriz $\mathbf{X}$, que está na linha i e coluna j , é tal que

$$x_{ij} = (a_{ij} + b_{ij}) + c_{ij} = a_{ij} + (b_{ij} + c_{ij}) = y_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Portanto, $\mathbf{X} = \mathbf{Y}$ e, conseqüentemente, $(\mathbf{A} + \mathbf{B}) + \mathbf{C} = \mathbf{A} + (\mathbf{B} + \mathbf{C})$.

- (b) Fazendo $\mathbf{X} = \mathbf{A} + \mathbf{B}$ e $\mathbf{Y} = \mathbf{B} + \mathbf{A}$, segue que o elemento genérico x_{ij} da matriz $\mathbf{X}$ que está na linha i e coluna j é tal que

$$x_{ij} = a_{ij} + b_{ij} = b_{ij} + a_{ij} = y_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Portanto, $\mathbf{X} = \mathbf{Y}$ e, conseqüentemente, $\mathbf{A} + \mathbf{B} = \mathbf{B} + \mathbf{A}$.

- (c) De fato,

$$a_{ij} + 0 = a_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Portanto, $\mathbf{A} + \mathbf{O} = \mathbf{A}$, sempre que $\mathbf{O}$ for a matriz nula de ordem $n \times p$.

- (d) Fazendo $\mathbf{X} = -\mathbf{A}$, temos

$$a_{ij} + x_{ij} = 0 \iff x_{ij} = -a_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Portanto, existe a matriz $-\mathbf{A}$ tal que $\mathbf{A} + (-\mathbf{A}) = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times p$.

■

Uma consequência direta do resultado anterior são as seguintes propriedades da soma de transformações lineares. Fica para o(a) leitor(a) o prazer de se convencer do trivialismo dessas afirmações, que decorrem diretamente das propriedades da soma de matrizes.

Resultado 2.3: Propriedades da soma de transformações lineares

Sejam n e p números inteiros positivos e $F, G, H \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$. Valem as seguintes propriedades:

(a) (*Associativa*)

$$(F + G) + H = F + (G + H).$$

(b) (*Comutativa*)

$$F + G = G + F.$$

(c) (*Elemento neutro aditivo*) A transformação nula $\mathbf{O} \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ é tal que

$$F + \mathbf{O} = F, \quad \text{para todo } F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n).$$

(d) (*Elemento oposto*) Para toda transformação linear $F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$, existe uma única transformação $-F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ tal que

$$F + (-F) = \mathbf{O},$$

em que $\mathbf{O}$ é a transformação nula de $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$.

Da existência do elemento oposto, derivamos a seguinte definição.

Definição 2.15: Matriz oposta

Sejam n e p número inteiros positivos e $\mathbf{A}$ uma matriz de ordem $n \times p$. A **matriz oposta** da matriz $\mathbf{A}$ é a matriz $-\mathbf{A}$ tal que $\mathbf{A} + (-\mathbf{A}) = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times p$. Em outras palavras, a matriz oposta é aquela cujos elementos são os simétricos dos elementos correspondentes (de mesmo índices) da matriz $\mathbf{A}$, i.e.,

$$-\mathbf{A} = \begin{bmatrix} -a_{11} & -a_{12} & \dots & -a_{1p} \\ -a_{21} & -a_{22} & \dots & -a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ -a_{n1} & -a_{n2} & \dots & -a_{np} \end{bmatrix}.$$

Exemplo 2.27

Determine a matriz oposta das seguintes matrizes definidas a seguir.

$$(a) \mathbf{A} = \begin{bmatrix} 2 & -5 \\ -6 & 7 \end{bmatrix}.$$

$$(b) \mathbf{B} = \begin{bmatrix} 1 & 2 & -2 \\ -2 & 1 & 0 \end{bmatrix}.$$

$$(c) \mathbf{C} = \begin{bmatrix} 9 & 8 & -7 \\ -\sqrt{2} & 0 & 1 \end{bmatrix}.$$

SOLUÇÃO:

$$(a) -\mathbf{A} = \begin{bmatrix} -2 & 5 \\ 6 & -7 \end{bmatrix}.$$

$$(b) -\mathbf{B} = \begin{bmatrix} -1 & -2 & 2 \\ 2 & -1 & 0 \end{bmatrix}.$$

$$(c) -\mathbf{C} = \begin{bmatrix} -9 & -8 & 7 \\ \sqrt{2} & 0 & -1 \end{bmatrix}.$$

Definição 2.16: Diferença de matrizes

Sejam n e p números inteiros positivos. A *diferença* da matriz $\mathbf{A} = [a_{ij}]_{n \times p}$ com a matriz $\mathbf{B} = [b_{ij}]_{n \times p}$, que indicamos por $\mathbf{A} - \mathbf{B}$, é a matriz $\mathbf{C} = [c_{ij}]_{n \times p}$ tal que $\mathbf{C} = \mathbf{A} + (-\mathbf{B})$, isto é,

$$c_{ij} = a_{ij} - b_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Em outras palavras, a diferença da matriz $\mathbf{A}$ com a matriz $\mathbf{B}$ é a soma da matriz $\mathbf{A}$ com a matriz oposta de $\mathbf{B}$.

Exemplo 2.28

Sejam $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ matrizes quadradas de ordem 2×2 definidas da seguinte maneira:

Exemplo 2.28

$$\mathbf{A} = \begin{bmatrix} -2 & 4 \\ 0 & -1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} \text{ e } \mathbf{C} = \begin{bmatrix} 3 & 0 \\ -5 & 2 \end{bmatrix}.$$

Calcule:

(a) $\mathbf{A} - \mathbf{B}$.

(b) $\mathbf{B} - \mathbf{C}$.

SOLUÇÃO:

(a)

$$\mathbf{A} - \mathbf{B} = \begin{bmatrix} -2 & 4 \\ 0 & -1 \end{bmatrix} - \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} = \begin{bmatrix} -2-4 & 4-2 \\ 0+6 & -1-0 \end{bmatrix} = \begin{bmatrix} -6 & 2 \\ 6 & -1 \end{bmatrix}.$$

(b)

$$\mathbf{B} - \mathbf{C} = \begin{bmatrix} 4 & 2 \\ -6 & 0 \end{bmatrix} - \begin{bmatrix} 3 & 0 \\ -5 & 2 \end{bmatrix} = \begin{bmatrix} 4-3 & 2-0 \\ -6+5 & 0-2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ -1 & -2 \end{bmatrix}.$$

Exemplo 2.29

Determine os números reais x , y e z tais que

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} + \begin{bmatrix} 3 \\ -5 \\ 8 \end{bmatrix} = \begin{bmatrix} 10 \\ -4 \\ 6 \end{bmatrix}.$$

SOLUÇÃO:

Temos,

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} + \begin{bmatrix} 3 \\ -5 \\ 8 \end{bmatrix} = \begin{bmatrix} 10 \\ -4 \\ 6 \end{bmatrix} \Leftrightarrow \begin{bmatrix} x+3 \\ y-5 \\ z+8 \end{bmatrix} = \begin{bmatrix} 10 \\ -4 \\ 6 \end{bmatrix} \Leftrightarrow \begin{cases} x+3 = 10, \\ y-5 = -4, \\ z+8 = 6. \end{cases} \Leftrightarrow \begin{cases} x = 7, \\ y = 1, \\ z = -14. \end{cases}$$

Exemplo 2.30

Dadas as matrizes $\mathbf{A} = \begin{bmatrix} 3 & -2 & 5 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} -1 & 4 & 2 \end{bmatrix}$, calcule a matrix $\mathbf{X}$ de ordem 1×3 tal que $\mathbf{X} - \mathbf{A} + \mathbf{B} = \mathbf{O}$, em que $\mathbf{O}$ é matriz nula de ordem 1×3 .

SOLUÇÃO:

Se $\mathbf{X} - \mathbf{A} + \mathbf{B} = \mathbf{O}$, então $\mathbf{X} = \mathbf{A} - \mathbf{B}$. Portanto

$$\mathbf{X} = \begin{bmatrix} 2 & -6 & 3 \end{bmatrix}.$$

Definição 2.17: Produto de um escalar por uma transformação linear

Sejam n e p números inteiros positivos e considere $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ o conjunto de todas as transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$. Dada uma transformação linear $F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ e um número real α , define-se o *produto* de α por F , indicado por αF , como a transformação linear

$$(\alpha F)(\mathbf{x}) = \alpha F(\mathbf{x}), \quad \text{para todo } \mathbf{x} \in \mathbb{R}^p.$$

Em outras palavras, multiplicar uma transformação linear F por um escalar α consiste em multiplicar o vetor imagem $F(\mathbf{x})$ pelo mesmo escalar α , para cada $\mathbf{x} \in \mathbb{R}^p$.

Suponha que F seja uma transformação linear de $\mathbb{R}^p$ em $\mathbb{R}^n$ tal que

$$F(\mathbf{x}) = \mathbf{A}_F \mathbf{x},$$

em que

$$\mathbf{A}_F = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1p} \\ a_{21} & a_{22} & \dots & a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{np} \end{bmatrix}.$$

Para todo vetor $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_p \end{bmatrix} \in \mathbb{R}^p$, tem-se

$$F(\mathbf{x}) = \begin{bmatrix} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p \end{bmatrix}.$$

Agora, seja $\alpha \in \mathbb{R}$. Pelo modo como foi definido o produto de escalar por vetor,

$$(\alpha F)(\mathbf{x}) = \alpha F(\mathbf{x}) = \begin{bmatrix} \alpha(a_{11}x_1 + a_{12}x_2 + \cdots + a_{1p}x_p) \\ \alpha(a_{21}x_1 + a_{22}x_2 + \cdots + a_{2p}x_p) \\ \vdots \\ \alpha(a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{np}x_p) \end{bmatrix}.$$

Portanto, a transformação linear (αF) pode ser escrita como

$$(\alpha F)(\mathbf{x}) = \mathbf{A}_{\alpha F} \mathbf{x},$$

em que

$$\mathbf{A}_{\alpha F} = \begin{bmatrix} \alpha a_{11} & \alpha a_{12} & \cdots & \alpha a_{1p} \\ \alpha a_{21} & \alpha a_{22} & \cdots & \alpha a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha a_{n1} & \alpha a_{n2} & \cdots & \alpha a_{np} \end{bmatrix}.$$

Assim, verificamos que cada elemento da matriz associada a (αF) é obtido multiplicando-se por α os elementos correspondentes da matriz $\mathbf{A}_F$. Essa observação motiva a definição do *produto de um escalar por uma matriz*, que será apresentada a seguir.

Definição 2.18: Multiplicação de um número real por uma matriz

Sejam n e p números inteiros positivos. O *produto* de um número real α por uma matriz $\mathbf{A} = [a_{ij}]_{n \times p}$, que indicamos por $\alpha \mathbf{A}$, é a matriz $\mathbf{B} = [b_{ij}]_{n \times p}$ tal que

$$b_{ij} = \alpha a_{ij},$$

para todos os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Em outras palavras, a multiplicação de uma matriz $\mathbf{A}$ por um número real α é uma matriz $\mathbf{B}$ formada pelos elementos da matriz $\mathbf{A}$ todos multiplicados por α . Assim,

Definição 2.18

$$\mathbf{B} = \alpha \mathbf{A} = \begin{bmatrix} \alpha a_{11} & \alpha a_{12} & \dots & \alpha a_{1p} \\ \alpha a_{21} & \alpha a_{22} & \dots & \alpha a_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \alpha a_{n1} & \alpha a_{n2} & \dots & \alpha a_{np} \end{bmatrix}.$$

Exemplo 2.31

$$(a) \quad 3 \begin{bmatrix} 1 & 7 & 2 \\ 5 & -1 & -2 \end{bmatrix} = \begin{bmatrix} 3 \times 1 & 3 \times 7 & 3 \times 2 \\ 3 \times 5 & 3 \times (-1) & 3 \times (-2) \end{bmatrix} = \begin{bmatrix} 3 & 21 & 6 \\ 15 & -3 & -6 \end{bmatrix}.$$

$$(b) \quad \frac{1}{2} \begin{bmatrix} 0 & 2 & 4 \\ 8 & 6 & 4 \\ 10 & 12 & -6 \end{bmatrix} = \begin{bmatrix} (1/2) \times 0 & (1/2) \times 2 & (1/2) \times 4 \\ (1/2) \times 8 & (1/2) \times 6 & (1/2) \times 4 \\ (1/2) \times 10 & (1/2) \times 12 & (1/2) \times (-6) \end{bmatrix} = \begin{bmatrix} 0 & 1 & 2 \\ 4 & 3 & 2 \\ 5 & 6 & -3 \end{bmatrix}.$$

$$(c) \quad 2 \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 \times 1 & 2 \times 1 & 2 \times 1 \\ 2 \times 0 & 2 \times 1 & 2 \times 1 \end{bmatrix} = \begin{bmatrix} 2 & 2 & 2 \\ 0 & 2 & 2 \end{bmatrix}$$

Observação 2.8

A operação que transforma cada par (α, A) , formado por um número real α e uma matriz A de ordem $n \times p$, na matriz αA também de ordem $n \times p$ chama-se *produto de um número real por uma matriz*.

Resultado 2.4: Propriedades do produto de matrizes por números reais

O produto de um número real por uma matriz apresenta as seguintes propriedades:

- (a) (*Associativa*) $\alpha(\beta \mathbf{A}) = (\alpha\beta) \mathbf{A}$, quaisquer que sejam os números reais α e β e qualquer que seja a matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$.
- (b) (*Distributiva em relação à soma de matrizes*) $\alpha(\mathbf{A} + \mathbf{B}) = \alpha \mathbf{A} + \alpha \mathbf{B}$, qualquer que seja o número real α e quaisquer que sejam as matrizes $\mathbf{A}, \mathbf{B} \in M_{n \times p}(\mathbb{R})$.

Resultado 2.4

- (c) (*Distributiva em relação à soma de escalares*) $(\alpha + \beta)\mathbf{A} = \alpha\mathbf{A} + \beta\mathbf{A}$, quaisquer que sejam os números reais α e β e qualquer que seja a matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$.
- (d) $1\mathbf{A} = \mathbf{A}$, qualquer que seja a matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$.

DEMONSTRAÇÃO:

- (a) Seja $\mathbf{A} = [a_{ij}]_{n \times p}$. Temos

$$\alpha(\beta\mathbf{A}) = \alpha[\beta a_{ij}]_{n \times p} = [\alpha(\beta a_{ij})]_{n \times p} = [(\alpha\beta)a_{ij}]_{n \times p} = (\alpha\beta)\mathbf{A}.$$

Logo, a propriedade associativa é satisfeita.

- (b) Sejam $\mathbf{A} = [a_{ij}]_{n \times p}$ e $\mathbf{B} = [b_{ij}]_{n \times p}$. Então,

$$\alpha(\mathbf{A} + \mathbf{B}) = \alpha[a_{ij} + b_{ij}]_{n \times p} = [\alpha(a_{ij} + b_{ij})]_{n \times p} = [\alpha a_{ij} + \alpha b_{ij}]_{n \times p} = \alpha\mathbf{A} + \alpha\mathbf{B}.$$

Assim, a distributividade em relação à soma de matrizes é verificada.

- (c) Seja $\mathbf{A} = [a_{ij}]_{n \times p}$. Temos

$$(\alpha + \beta)\mathbf{A} = [(\alpha + \beta)a_{ij}]_{n \times p} = [\alpha a_{ij} + \beta a_{ij}]_{n \times p} = [\alpha a_{ij}]_{n \times p} + [\beta a_{ij}]_{n \times p} = \alpha\mathbf{A} + \beta\mathbf{A}.$$

Logo, a propriedade distributiva em relação à soma de escalares também é válida.

- (d) Finalmente, para $\mathbf{A} = [a_{ij}]_{n \times p}$, segue que

$$1\mathbf{A} = [1 \cdot a_{ij}]_{n \times p} = [a_{ij}]_{n \times p} = \mathbf{A}.$$

Portanto, o número real 1 atua como elemento neutro multiplicativo. ■

Uma consequência direta do resultado anterior são as seguintes propriedades do produto de um número real por uma transformação linear. Novamente, fica para o(a) leitor(a) o divertido exercício de se convencer do trivialismo dessas afirmações, que decorrem diretamente das propriedades do produto de um número real por uma matriz.

Resultado 2.5: Propriedades para o caso de transformações lineares

Sejam n e p números inteiros positivos, $\alpha, \beta \in \mathbb{R}$ e $F, G \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$. Valem as seguintes propriedades:

- (a) (*Associativa*) $\alpha(\beta F) = (\alpha\beta)F$.
- (b) (*Distributiva em relação à soma de transformações*) $\alpha(F + G) = \alpha F + \alpha G$.
- (c) (*Distributiva em relação à soma de escalares*) $(\alpha + \beta)F = \alpha F + \beta F$.
- (d) (*Elemento neutro multiplicativo*) $1F = F$.

Exemplo 2.32

Considere as matrizes $\mathbf{A} = [a_{ij}]_{2 \times 3}$ e $\mathbf{B} = [b_{ij}]_{2 \times 3}$ tais que o elemento a_{ij} da linha i e coluna j da matriz $\mathbf{A}$ é dado por $a_{ij} = i^2 + j^2$ e o elemento b_{ij} da linha i e coluna j da matriz $\mathbf{B}$ é dado por $b_{ij} = ij$, quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq 2$ e $1 \leq j \leq 3$. Determine a matriz $\mathbf{A} + 2\mathbf{B}$.

SOLUÇÃO:

Seja $\mathbf{C} = \mathbf{A} + 2\mathbf{B}$ e vamos denotar $\mathbf{C} = [c_{ij}]_{2 \times 3}$. Usando as definições de produto de números reais e de soma de matrizes, segue que o elemento c_{ij} da linha i e coluna j da matriz $\mathbf{C}$ é dado por

$$c_{ij} = a_{ij} + 2b_{ij},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq 2$ e $1 \leq j \leq 3$.

Logo,

$$c_{ij} = i^2 + j^2 + 2ij = (i + j)^2.$$

Portanto,

$$\mathbf{C} = \begin{bmatrix} 4 & 9 & 16 \\ 9 & 16 & 25 \end{bmatrix}.$$

Exemplo 2.33

Determine as matrizes $\mathbf{X} \in M_2(\mathbb{R})$ e $\mathbf{Y} \in M_2(\mathbb{R})$ tais que

Exemplo 2.33

$$\begin{cases} \mathbf{X} + \mathbf{Y} = 3\mathbf{I}_2 \\ \mathbf{X} - \mathbf{Y} = 2\mathbf{O} \end{cases},$$

em que $\mathbf{I}_2$ é a matriz identidade de ordem 2×2 e $\mathbf{O}$ é a matriz nula de ordem 2×2 .

SOLUÇÃO:

Somando membro a membro as duas equações, resulta

$$\mathbf{X} + \mathbf{Y} + \mathbf{X} - \mathbf{Y} = 3\mathbf{I}_2 + 2\mathbf{O} \Leftrightarrow 2\mathbf{X} = 3\mathbf{I}_2 \Leftrightarrow \mathbf{X} = \frac{3}{2}\mathbf{I}_2.$$

Subtraindo membro a membro as duas equações, resulta

$$\mathbf{X} + \mathbf{Y} - \mathbf{X} + \mathbf{Y} = 3\mathbf{I}_2 - 2\mathbf{O} \Leftrightarrow 2\mathbf{Y} = 3\mathbf{I}_2 \Leftrightarrow \mathbf{Y} = \frac{3}{2}\mathbf{I}_2.$$

Portanto,

$$\mathbf{X} = \mathbf{Y} = \begin{bmatrix} \frac{3}{2} & 0 \\ 0 & \frac{3}{2} \end{bmatrix}.$$

Encerrando esta seção, observamos que os Resultados 2.2 e 2.4 estabelecem as propriedades de soma e multiplicação por escalar para o conjunto das matrizes reais $M_{n \times p}(\mathbb{R})$. Essas propriedades garantem que o conjunto das matrizes de ordem $n \times p$, munido dessas duas operações, forma um espaço vetorial sobre $\mathbb{R}$, isto é,

$$(M_{n \times p}(\mathbb{R}), +, \cdot) \text{ é um espaço vetorial sobre } \mathbb{R}.$$

De maneira análoga, os Resultados 2.3 e 2.5 mostram que o conjunto das transformações lineares de $\mathbb{R}^p$ em $\mathbb{R}^n$, com as operações de soma e multiplicação por escalar definidas anteriormente, também constitui um espaço vetorial sobre $\mathbb{R}$, ou seja,

$$(\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n), +, \cdot) \text{ é um espaço vetorial sobre } \mathbb{R}.$$

Por fim, como já comentado, existe uma relação biunívoca entre cada transformação linear $F \in \mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$ e uma matriz $\mathbf{A}_F \in M_{n \times p}(\mathbb{R})$. Essa correspondência, além de preservar as operações de adição e multiplicação por escalar, caracteriza um *isomorfismo de espaços vetoriais* entre $M_{n \times p}(\mathbb{R})$ e $\mathcal{L}(\mathbb{R}^p, \mathbb{R}^n)$.

2.8 Produto de matrizes e a composição de transformações lineares

Ao contrário da soma de matrizes, o produto entre duas matrizes não está necessariamente definido para matrizes de mesma ordem e tampouco é realizado entrada a entrada. Trata-se de uma operação definida de maneira bastante peculiar, que à primeira vista pode parecer pouco natural. Dessa forma, vamos começar discutindo um exemplo prático para motivar a definição dessa operação.

Exemplo 2.34: Adaptado do Portal OBMEP

Um doceira produz três tipos de doces, vendidos em duas lojas. A tabela abaixo possui uma linha para cada loja, uma coluna para cada tipo de doce e indica quantos doces de cada tipo foram vendidos por cada loja em uma dada semana.

	Doce 1	Doce 2	Doce 3
Loja A	5	4	3
Loja B	3	2	4

Temos também uma tabela, em que cada linha corresponde a um dos doces, cada coluna corresponde a um ingrediente utilizada na confecção do doce e as entradas indicam as quantidades de cada ingrediente necessário para fabricar cada doce.

	Farinha	Açúcar	Leite	Manteiga	Ovos
Doce 1	500g	200g	500mL	150g	4
Doce 2	400g	100g	300mL	250g	5
Doce 3	300g	150g	600mL	0g	6

Qual é a quantidade de ingredientes que cada loja precisou para produzir os doces desta semana?

SOLUÇÃO:

Sejam A a matriz correspondente a primeira tabela e B a matriz correspondente a segunda tabela. Queremos montar uma matriz C em que cada linha corresponde a uma loja e cada coluna corresponde a um ingrediente, de forma que cada entrada indica a quantidade de cada ingrediente usado por cada loja na fabricação dos doces. Dessa forma, C é uma matriz de ordem 2×5 em que, por exemplo, c_{11} indica a quan-

Exemplo 2.34

tidade de farinha usada pela Loja A. Essa loja produziu 5 doces do tipo 1, gastando 500g de farinha em cada um, ou seja, 2.500g de farinha; produziu 4 doces do tipo 2, gastando 400g de farinha em cada um, ou seja, 1.600g; e produziu 3 doces do tipo 3, gastando 300g de farinha, ou seja, 900g. Assim, ao todo, a Loja A gastou $2.500 + 1.600 + 900 = 5.000$ gramas de farinha. Portanto, $c_{11} = 5.000$ g. Em resumo, para calcular c_{11} tomamos os elementos da primeira linha da matriz A e multiplicamos um a um pelos elementos da primeira coluna da matriz B e, em seguida, somamos os resultados.

Um outro exemplo, seria encontrar c_{23} que indica a quantidade de leite usada pela Loja B. Essa loja produziu 3 doces do tipo 1, gastando 500mL de leite em cada um, ou seja, 1.500mL; produziu 2 doces tipo 2, gastando 300mL em cada um, ou seja, 600mL; e produziu 4 doces do tipo 3, gastando 600mL em cada um, ou seja, 2.400mL. Assim, ao todo, a Loja B gastou $1.500 + 600 + 2.400 = 4.500$ mL de leite. Portanto, $c_{23} = 4.500$ mL. Em resumo, para calcular c_{21} tomamos os elementos da segunda linha da matriz A e multiplicamos um a um pelos elementos da terceira coluna da matriz B e, em seguida, somamos os resultados.

Portanto, calculando cada um dos elementos da matriz C da forma como sugerida, concluímos que

$$C = \begin{bmatrix} 500 & 1.850 & 5.500 & 1.750 & 58 \\ 3.500 & 1.400 & 4.500 & 950 & 46 \end{bmatrix}.$$

No entanto, essa definição revela-se extremamente útil, pois está intimamente relacionada à composição de transformações lineares e ao modo como essas transformações atuam sobre vetores em espaços vetoriais.

Definição 2.19: Composição de transformações lineares

Sejam $F : \mathbb{R}^m \rightarrow \mathbb{R}^n$ e $G : \mathbb{R}^p \rightarrow \mathbb{R}^m$ transformações lineares. Define-se a **composição** de F com G como a transformação linear

$$(F \circ G)(\mathbf{x}) = F(G(\mathbf{x})), \quad \text{para todo } \mathbf{x} \in \mathbb{R}^p.$$

O domínio de $F \circ G$ é o mesmo que o de G , e o contradomínio é o mesmo que o de F , ou seja,

$$F \circ G : \mathbb{R}^p \longrightarrow \mathbb{R}^n.$$

Observação 2.9:

Se $F : \mathbb{R}^p \rightarrow \mathbb{R}^m$ e $G : \mathbb{R}^m \rightarrow \mathbb{R}^n$ com p, m e n números naturais distintos, então $F \circ G$ **não está bem definido**, pois para todo $\mathbf{x} \in \mathbb{R}^m$ temos $G(\mathbf{x}) \in \mathbb{R}^n$, mas para que $F(G(\mathbf{x}))$ faça sentido, deveríamos ter $G(\mathbf{x}) \in \mathbb{R}^p$.

A definição do produto de matrizes surge de maneira natural a partir da composição de transformações lineares. Vejamos um exemplo.

Exemplo 2.35

Considere os operadores lineares $F \in \mathcal{L}(\mathbb{R}^3, \mathbb{R}^3)$ e $G \in \mathcal{L}(\mathbb{R}^3, \mathbb{R}^3)$ tais que

$$F \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{bmatrix} 3x + 4y + 2z \\ 5x + 2y - z \\ 2x + 5y + 3z \end{bmatrix}, \quad G \begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{bmatrix} 2x + 3y + 3z \\ 3x + 5y - 7z \\ -2x + y + 3z \end{bmatrix}.$$

- A transformação composta $F \circ G$ está bem definida? Se sim, determine o seu domínio e o seu contradomínio.
- Determine a matriz do operador linear F em relação às bases canônicas.
- Determine a matriz do operador linear G em relação às bases canônicas.
- Determine a matriz da transformação composta $F \circ G$ em relação às bases canônicas.

SOLUÇÃO:

- A transformação composta $F \circ G$ está bem definida, pois tanto F quanto G têm domínio e contradomínio em $\mathbb{R}^3$. Assim,

$$F \circ G : \mathbb{R}^3 \longrightarrow \mathbb{R}^3.$$

- A matriz do operador linear F em relação às bases canônicas é

$$\mathbf{A} = \begin{bmatrix} 3 & 4 & 2 \\ 5 & 2 & -1 \\ 2 & 5 & 3 \end{bmatrix}.$$

Exemplo 2.36

(c) A matriz do operador linear G em relação às bases canônicas é

$$B = \begin{bmatrix} 2 & 3 & 3 \\ 3 & 5 & -7 \\ -2 & 1 & 3 \end{bmatrix}.$$

(d) Para determinar $F \circ G$, aplicamos primeiro G e depois F :

$$G(\mathbf{x}) = \begin{bmatrix} 2x + 3y + 3z \\ 3x + 5y - 7z \\ -2x + y + 3z \end{bmatrix}.$$

Substituindo as três expressões acima na lei de F , temos

$$(F \circ G)(\mathbf{x}) = \begin{bmatrix} 3(2x + 3y + 3z) + 4(3x + 5y - 7z) + 2(-2x + y + 3z) \\ 5(2x + 3y + 3z) + 2(3x + 5y - 7z) - 1(-2x + y + 3z) \\ 2(2x + 3y + 3z) + 5(3x + 5y - 7z) + 3(-2x + y + 3z) \end{bmatrix}.$$

Efetuando as operações em cada linha:

1ª linha:

$$\begin{aligned} & (3 \cdot 2 + 4 \cdot 3 + 2 \cdot (-2))x + (3 \cdot 3 + 4 \cdot 5 + 2 \cdot 1)y + (3 \cdot 3 + 4 \cdot (-7) + 2 \cdot 3)z \\ & = 14x + 35y - 13z, \end{aligned}$$

2ª linha:

$$\begin{aligned} & (5 \cdot 2 + 2 \cdot 3 + (-1) \cdot (-2))x + (5 \cdot 3 + 2 \cdot 5 + (-1) \cdot 1)y + (5 \cdot 3 + 2 \cdot (-7) + (-1) \cdot 3)z \\ & = 20x + 26y - 5z, \end{aligned}$$

3ª linha:

$$\begin{aligned} & (2 \cdot 2 + 5 \cdot 3 + 3 \cdot (-2))x + (2 \cdot 3 + 5 \cdot 5 + 3 \cdot 1)y + (2 \cdot 3 + 5 \cdot (-7) + 3 \cdot 3)z \\ & = 17x + 40y - 20z. \end{aligned}$$

Exemplo 2.35

Logo,

$$(F \circ G)(\mathbf{x}) = \begin{bmatrix} 14x + 35y - 13z \\ 20x + 26y - 5z \\ 17x + 40y - 20z \end{bmatrix},$$

o que mostra que a matriz associada a $F \circ G$ em relação às bases canônicas é

$$\mathbf{C} = \begin{bmatrix} 14 & 35 & -13 \\ 20 & 26 & -5 \\ 17 & 40 & -20 \end{bmatrix}.$$

Note que o elemento c_{ij} da matriz $\mathbf{C}$ é produto dos elementos da linha i da matriz $\mathbf{A}$ pelos elementos da coluna j da matriz $\mathbf{B}$, i.e.,

$$c_{ij} = a_{i1}b_{1j} + a_{i2}b_{2j} + a_{i3}b_{3j}.$$

A operação realizada no exemplo anterior para obter a matriz $\mathbf{C}$ é justamente o que chamamos de produto matricial da matriz $\mathbf{A}$ pela matriz $\mathbf{B}$. Vejamos a definição formal.

Definição 2.20: Multiplicação de matrizes

Sejam m , n e p números naturais não-nulos. Considere a matriz $\mathbf{A} = [a_{ij}]_{m \times n}$ de ordem $m \times n$ e a matriz $\mathbf{B} = [b_{jk}]_{n \times p}$ de ordem $n \times p$. O **produto** da matriz $\mathbf{A}$ pela matriz $\mathbf{B}$, indicado por $\mathbf{AB}$, é a matriz $\mathbf{C} = [c_{ik}]_{m \times p}$ de ordem $m \times p$ tal que o elemento c_{ik} da linha i e coluna k da matriz $\mathbf{C}$ é dado por

$$c_{ik} = \sum_{j=1}^n a_{ij}b_{jk} = a_{i1}b_{1k} + a_{i2}b_{2k} + \dots + a_{in}b_{nk},$$

quaisquer que sejam os números naturais $1 \leq i \leq m$ e $1 \leq k \leq p$. Em outras palavras, a multiplicação de uma matriz $\mathbf{A}$ por uma matriz $\mathbf{B}$ é uma matriz $\mathbf{C}$ em cada elemento c_{ik} é formado multiplicando-se ordenadamente os elementos da linha i da matriz $\mathbf{A}$, pelos elementos da coluna j da matriz $\mathbf{B}$ e, em seguida, somado-se os produtos

Definição 2.20

obtidos. Assim,

$$\mathbf{C} = \mathbf{AB} = \begin{bmatrix} \sum_{j=1}^n a_{1j}b_{j1} & \sum_{j=1}^n a_{1j}b_{j2} & \cdots & \sum_{j=1}^n a_{1j}b_{jk} \\ \sum_{j=1}^n a_{2j}b_{j1} & \sum_{j=1}^n a_{2j}b_{j2} & \cdots & \sum_{j=1}^n a_{2j}b_{jk} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{j=1}^n a_{mj}b_{j1} & \sum_{j=1}^n a_{mj}b_{j2} & \cdots & \sum_{j=1}^n a_{mj}b_{jp} \end{bmatrix}.$$

Se $G : \mathbb{R}^p \rightarrow \mathbb{R}^m$ e $F : \mathbb{R}^m \rightarrow \mathbb{R}^n$ são transformações lineares representadas, respectivamente, pelas matrizes $\mathbf{B} \in M_{m \times p}(\mathbb{R})$ e $\mathbf{A} \in M_{n \times m}(\mathbb{R})$, então a composição $F \circ G$ também é linear. Assim, existe uma matriz $\mathbf{C} \in M_{n \times p}(\mathbb{R})$ tal que

$$(F \circ G)(\mathbf{x}) = \mathbf{Cx}, \quad \text{para todo } \mathbf{x} \in \mathbb{R}^p.$$

Observa-se que

$$(F \circ G)(\mathbf{x}) = F(G(\mathbf{x})) = \mathbf{A}(\mathbf{Bx}),$$

o que nos leva a definir $\mathbf{C} = \mathbf{AB}$. Portanto, o produto de duas matrizes é definido precisamente de modo a garantir que a matriz associada à composição de duas transformações lineares seja o produto, nessa ordem, das matrizes que as representam.

Exemplo 2.36

Dadas as matrizes

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} 7 \\ 8 \\ 9 \end{bmatrix}.$$

Calcule $\mathbf{AB}$.

SOLUÇÃO:

Temos

$$\mathbf{AB} = \begin{bmatrix} (1 \times 7) + (2 \times 8) + (3 \times 9) \\ (4 \times 7) + (5 \times 8) + (6 \times 9) \end{bmatrix} = \begin{bmatrix} 50 \\ 122 \end{bmatrix}.$$

Exemplo 2.37

Dadas as matrizes

$$A = \begin{bmatrix} 2 & 1 \\ 0 & 1 \end{bmatrix} \text{ e } B = \begin{bmatrix} 3 & 4 \\ 0 & 0 \end{bmatrix}.$$

Calcule AB e BA .

SOLUÇÃO:

Temos,

$$AB = \begin{bmatrix} (2 \times 3) + (1 \times 0) & (2 \times 4) + (1 \times 0) \\ (0 \times 3) + (1 \times 0) & (0 \times 4) + (1 \times 0) \end{bmatrix} = \begin{bmatrix} 6 & 8 \\ 0 & 0 \end{bmatrix} \text{ e}$$

$$BA = \begin{bmatrix} (3 \times 2) + (4 \times 0) & (3 \times 1) + (4 \times 1) \\ (0 \times 2) + (0 \times 0) & (0 \times 1) + (0 \times 1) \end{bmatrix} = \begin{bmatrix} 6 & 7 \\ 0 & 0 \end{bmatrix}.$$

Portanto $AB \neq BA$, isto é, a multiplicação de matrizes não é uma operação comutativa.

Exemplo 2.38

Dada a matriz

$$A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}.$$

Calcule AI_2 , em que I_2 é a matriz identidade de ordem 2×2 .

Solução.

Temos,

$$AI_2 = \begin{bmatrix} (1 \times 1) + (2 \times 0) & (1 \times 0) + (2 \times 1) \\ (3 \times 1) + (4 \times 0) & (3 \times 0) + (4 \times 1) \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = A.$$

Observação 2.10

1. A operação que transforma cada par A e B de matrizes, em que A é da ordem $m \times n$ e B é da ordem $n \times p$, na matriz AB chama-se **multiplicação de matrizes**.

Observação 2.10

2. Para que seja possível realizar a multiplicação de uma matriz A por uma matriz B é necessário que o número de colunas da matriz A seja igual ao número de colunas da matriz B . Observe que na definição a matriz A é da ordem $m \times n$ e a matriz B é da ordem $n \times p$.
3. Pela definição, o produto da matriz A de ordem $m \times n$ pela matriz B de ordem $n \times p$ é a matriz C que possui o mesmo número de linhas que a matriz A e o mesmo número de colunas que a matriz B , ou seja, a matriz C é de ordem $m \times p$.

Resultado 2.6: Propriedades da multiplicação de matrizes

O produto de matrizes apresenta as seguintes propriedades:

- (a) (*Associativa*) $(AB)C = A(BC)$, quaisquer que sejam as matrizes $A \in M_{m \times n}(\mathbb{R})$, $B \in M_{n \times p}(\mathbb{R})$ e $C \in M_{p \times r}(\mathbb{R})$.
- (b) (*Distributiva à direita em relação à adição de matrizes*) $(A + B)C = AC + BC$, quaisquer que sejam as matrizes $A \in M_{m \times n}(\mathbb{R})$, $B \in M_{m \times n}(\mathbb{R})$ e $C \in M_{n \times p}(\mathbb{R})$.
- (c) (*Distributiva à esquerda em relação à adição de matrizes*) $C(A + B) = CA + CB$, quaisquer que sejam as matrizes $A \in M_{m \times n}(\mathbb{R})$, $B \in M_{m \times n}(\mathbb{R})$ e $C \in M_{p \times m}(\mathbb{R})$.
- (d) $(\alpha A)B = A(\alpha B) = \alpha(AB)$, quais que sejam as matrizes $A \in M_{m \times n}(\mathbb{R})$ e $B \in M_{n \times p}(\mathbb{R})$ e o número real α .
- (e) (*Elemento neutro multiplicativo*) $AI_n = A$ e $I_m A = A$, qualquer que seja a matriz $A \in M_{m \times n}(\mathbb{R})$, em que I_n e I_m são matrizes identidade de ordem $n \times n$ e $m \times m$, respectivamente.

DEMONSTRAÇÃO:

- (a) Tome $D = (AB)C$ e $E = A(BC)$. O elemento $d_{i\ell}$ que está na linha i e na coluna ℓ da matriz D é dado por

$$d_{i\ell} = \sum_{k=1}^n \left(\sum_{j=1}^n a_{ij} b_{jk} \right) c_{k\ell},$$

Resultado 2.6

quaisquer que sejam os números naturais i e r tais que $1 \leq i \leq n$ e $1 \leq \ell \leq r$. Por outro lado, o elemento $e_{i\ell}$ que está na linha i e na coluna ℓ da matriz E é dado por

$$e_{i\ell} = \sum_{j=1}^n a_{ij} \left(\sum_{k=1}^p b_{jk} c_{k\ell} \right),$$

quaisquer que sejam os números naturais i e r tais que $1 \leq i \leq n$ e $1 \leq \ell \leq r$. Portanto, pelas propriedades de soma e multiplicação de números reais, concluímos que $d_{i\ell} = e_{i\ell}$, quaisquer que sejam os números naturais i e r tais que $1 \leq i \leq n$ e $1 \leq \ell \leq r$.

- (b) Tome $D = (A + B)C$. Assim, o elemento d_{ik} que está na linha i e na coluna k da matriz D é dado por

$$\begin{aligned} d_{ik} &= \sum_{j=1}^n (a_{ij} + b_{ij}) c_{jk} \\ &= \sum_{j=1}^n (a_{ij} c_{jk} + b_{ij} c_{jk}) \\ &= \sum_{j=1}^n a_{ij} c_{jk} + \sum_{j=1}^n b_{ij} c_{jk}. \end{aligned}$$

Logo, $D = AC + BC$ e, portanto, $(A + B)C = AC + BC$.

- (c) Usa-se o mesmo tipo de raciocínio da demonstração anterior. Fica como exercício.
 (d) O elemento genérico da matriz $(\alpha A)B$ é dado por

$$\sum_{j=1}^n \alpha a_{ij} b_{jk} = \sum_{j=1}^n a_{ij} (\alpha b_{jk}) = \alpha \sum_{j=1}^n a_{ij} b_{jk},$$

quaisquer que sejam os números naturais i e k tais que $1 \leq i \leq m$ e $1 \leq k \leq p$. Como

$$\sum_{j=1}^n a_{ij} (\alpha b_{jk}) \text{ e } \alpha \sum_{j=1}^n a_{ij} b_{jk}$$

são os elementos genéricos de $A(\alpha B)$ e de $\alpha(AB)$, respectivamente, concluímos que

$$(\alpha A)B = A(\alpha B) = \alpha(AB).$$

Resultado 2.6

- (e) Tome $B = AI_n$. O elemento b_{ik} que está na linha i e coluna k da matriz B é dado por

$$b_{ij} = (a_{i1} \times 0) + (a_{i2} \times 0) + \dots + (a_{ii} \times 1) + \dots + (a_{in} \times 0) = a_{ii},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq m$ e $1 \leq j \leq n$. Portanto $AI_n = A$. Usa-se o mesmo raciocínio para mostrar que $I_m A = A$. Fica como exercício.



Uma consequência direta do resultado anterior são as seguintes propriedades da composição de transformações lineares. Fica para o(a) leitor(a) o prazer de se convencer do trivialismo dessas afirmações, que decorrem diretamente das propriedades da soma de matrizes.

Resultado 2.7

O conjunto das transformações lineares também apresenta propriedades análogas às do produto de matrizes:

- (a) (*Associativa*) $(F \circ G) \circ H = F \circ (G \circ H)$,
para quaisquer transformações lineares $F : \mathbb{R}^p \rightarrow \mathbb{R}^r$, $G : \mathbb{R}^n \rightarrow \mathbb{R}^p$ e $H : \mathbb{R}^m \rightarrow \mathbb{R}^n$.
- (b) (*Distributiva à direita em relação à adição*) $(F + G) \circ H = F \circ H + G \circ H$,
para quaisquer transformações lineares $F, G : \mathbb{R}^n \rightarrow \mathbb{R}^p$ e $H : \mathbb{R}^m \rightarrow \mathbb{R}^n$.
- (c) (*Distributiva à esquerda em relação à adição*) $F \circ (G + H) = F \circ G + F \circ H$,
para quaisquer transformações lineares $F : \mathbb{R}^p \rightarrow \mathbb{R}^r$ e $G, H : \mathbb{R}^n \rightarrow \mathbb{R}^p$.
- (d) (*Compatibilidade com escalar*) $(\alpha F) \circ G = \alpha(F \circ G) = F \circ (\alpha G)$,
para quaisquer transformações lineares $F : \mathbb{R}^p \rightarrow \mathbb{R}^r$, $G : \mathbb{R}^n \rightarrow \mathbb{R}^p$ e número real α .
- (e) (*Elemento neutro multiplicativo*) $F \circ I_n = F$ e $I_m \circ F = F$,
para qualquer transformação linear $F : \mathbb{R}^n \rightarrow \mathbb{R}^m$, sendo I_n e I_m as transformações identidade de $\mathbb{R}^n$ e $\mathbb{R}^m$, respectivamente.

Observação 2.11

1. A multiplicação de matrizes não é comutativa, isto é, para duas matrizes quaisquer A e B é falso que $AB = BA$ sempre. Por exemplo,

- (a) Há casos em que existe AB e não existe BA . Isso ocorre quando A é uma matriz de ordem $m \times n$ e B é uma matriz de ordem $n \times p$ e $m \neq p$.
- (b) Há casos em que existem AB e BA , porém são matrizes de ordens diferentes e, portanto, $AB \neq BA$. Isso ocorre quando A é uma matriz de ordem $m \times n$ e B é uma matriz de ordem $n \times m$ e $n \neq m$.
- (c) Mesmo nos casos em que AB e BA são de mesma ordem, temos quase sempre $AB \neq BA$. Veja o caso do Exemplo 37, em que A e B são matrizes quadradas de mesma ordem.
- (d) Quanto A e B são matrizes tais que $AB = BA$, dizemos que as matrizes A e B comutam. Notemos que uma condição necessária para que A e B comutem é que elas sejam matrizes quadradas de mesma ordem. Por exemplo,

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \text{ comuta com } \begin{bmatrix} 4 & -2 \\ -3 & 1 \end{bmatrix},$$

pois

$$\begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} \begin{bmatrix} 4 & -2 \\ -3 & 1 \end{bmatrix} = \begin{bmatrix} 4 & -2 \\ -3 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} -2 & 0 \\ 0 & -2 \end{bmatrix}.$$

2. É importante observar que se A e B são matrizes de ordem $m \times n$ e $n \times p$, respectivamente, tais que $AB = O_{m \times p}$, em que $O_{m \times p}$ é matriz nula de ordem $m \times p$; é falso que $A = O_{m \times n}$ ou $B = O_{n \times p}$ sempre, em que $O_{m \times n}$ e $O_{n \times p}$ são as matrizes nulas de ordem $m \times n$ e $n \times p$, respectivamente. Em outras palavras, é possível encontrar duas matrizes não-nulas cujo produto é a matriz nula. Por exemplo,

$$\begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}.$$

2.9 A transposta e a decomposição de uma matriz em sua parte simétrica e anti-simétrica

Nesta seção, estudaremos a operação de transposição de matrizes e veremos que qualquer matriz quadrada $\mathbf{A}$ pode ser decomposta, de forma única, como soma de duas matrizes especiais: uma parte simétrica e uma parte anti-simétrica. Essa decomposição não é apenas um truque algébrico, ela será especialmente importante no próximo capítulo, quando estudarmos formas quadráticas.

Definição 2.21: Matriz transposta

Sejam n e p números naturais não-nulos. A **matriz transposta** da matriz $\mathbf{A} = [a_{ij}]_{n \times p}$, indicada por $\mathbf{A}^\top$, é uma matriz de ordem $p \times n$ tal que o elemento a'_{ij} da linha i e coluna j da matriz $\mathbf{A}^\top$ é tal que $a'_{ij} = a_{ji}$, em que a_{ji} é o elemento da linha j e coluna i da matriz $\mathbf{A}$, quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$. Em outras palavras, as linhas da matriz $\mathbf{A}^\top$ são ordenadamente iguais às colunas da matriz $\mathbf{A}$.

Exemplo 2.39

$$(a) \text{ Se } \mathbf{A} = \begin{bmatrix} 1 & 3 & 5 & 7 \end{bmatrix}, \text{ então } \mathbf{A}^\top = \begin{bmatrix} 1 \\ 3 \\ 5 \\ 7 \end{bmatrix}.$$

$$(b) \text{ Se } \mathbf{B} = \begin{bmatrix} 3 & 10 & -1 \\ 0 & -2 & 6 \end{bmatrix}, \text{ então } \mathbf{B}^\top = \begin{bmatrix} 3 & 0 \\ 10 & -2 \\ -1 & 6 \end{bmatrix}.$$

$$(c) \text{ Se } \mathbf{C} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \text{ então } \mathbf{C}^\top = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}.$$

$$(d) \text{ Se } \mathbf{D} = [\sqrt{2}], \text{ então } \mathbf{D}^\top = [\sqrt{2}].$$

Resultado 2.8: Propriedades da transposição de matrizes

A transposição de matrizes apresenta as seguintes propriedades:

- (a) $(\mathbf{A}^\top)^\top = \mathbf{A}$ qualquer que seja a matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$.
- (b) $(\mathbf{A} + \mathbf{B})^\top = \mathbf{A}^\top + \mathbf{B}^\top$ quaisquer que sejam as matrizes $\mathbf{A}, \mathbf{B} \in M_{n \times p}(\mathbb{R})$.
- (c) $(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top$ quaisquer que sejam o número real α e a matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$.
- (d) $(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top$ quaisquer que sejam as matrizes $\mathbf{A} \in M_{m \times n}(\mathbb{R})$ e $\mathbf{B} \in M_{n \times p}(\mathbb{R})$.

DEMONSTRAÇÃO:

- (a) Fazendo $\mathbf{B} = \mathbf{A}^\top$ segue que o elemento genérico b_{ji} da linha j e da coluna i da matriz $\mathbf{B}$ é tal que

$$b_{ji} = a_{ij},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$.
Como o elemento genérico b'_{ij} da linha i e coluna j da matriz $\mathbf{B}^\top$ é tal que

$$b'_{ij} = b_{ji} = a_{ij},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$.
Portanto,

$$(\mathbf{A}^\top)^\top = \mathbf{A}.$$

- (b) Fazendo $\mathbf{C} = \mathbf{A} + \mathbf{B}$ segue que o elemento genérico c_{ij} da linha i e da coluna j da matriz $\mathbf{C}$ é tal que

$$c_{ij} = a_{ij} + b_{ij},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$.
Como o elemento genérico c'_{ji} da linha j e coluna i da matriz $\mathbf{C}^\top$ é tal que

$$c'_{ji} = c_{ij} = a_{ij} + b_{ij} = a'_{ji} + b'_{ji},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$,
de forma que a'_{ji} e b'_{ji} são, respectivamente, os elementos genéricos da linha j e coluna i das matrizes $\mathbf{A}^\top$ e $\mathbf{B}^\top$.

Resultado 2.8

- (c) Fazendo $\mathbf{B} = \alpha \mathbf{A}$ segue que o elemento genérico b_{ij} da linha i e coluna j da matriz $\mathbf{B}$ é tal que

$$b_{ij} = \alpha a_{ij} = \alpha a'_{ji},$$

quaisquer que sejam os números naturais i e j tais que $1 \leq i \leq n$ e $1 \leq j \leq p$, de forma que a'_{ji} é o elemento genérico da linha j e coluna i da matriz $\mathbf{A}^\top$. Portanto,

$$(\alpha \mathbf{A})^\top = \alpha \mathbf{A}^\top.$$

- (d) Fazendo $\mathbf{C} = \mathbf{AB}$ segue que o elemento genérico c'_{ki} da linha k e da coluna i da matriz $\mathbf{C}^\top$ é tal que

$$c'_{ki} = c_{ik} = \sum_{j=1}^n a_{ij} b_{jk} = \sum_{j=1}^n b_{jk} a_{ij} = \sum_{j=1}^n b'_{kj} a'_{ji},$$

quaisquer que sejam os números naturais i e k tais que $1 \leq i \leq n$ e $1 \leq k \leq p$, de forma que b'_{kj} é o elemento genérico da linha k e coluna j da matriz $\mathbf{B}^\top$ e a'_{ji} é o elemento genérico da linha j e coluna i da matriz $\mathbf{A}^\top$. Portanto,

$$(\mathbf{AB})^\top = \mathbf{B}^\top \mathbf{A}^\top.$$

□

Exemplo 2.40

Mostre que

$$(\alpha \mathbf{A} \mathbf{I}_n + \mathbf{B} \mathbf{O})^\top = \alpha \mathbf{A}^\top + \mathbf{O},$$

em que $\alpha \in \mathbb{R}$, $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$, $\mathbf{O}$ é a matriz nula de ordem $n \times n$, $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas pertencentes a $M_n(\mathbb{R})$.

SOLUÇÃO:

Utilizando as propriedades do Teorema 1.8 segue que

$$(\alpha \mathbf{A} \mathbf{I}_n + \mathbf{B} \mathbf{O})^\top = (\alpha \mathbf{A} + \mathbf{O})^\top = (\alpha \mathbf{A}^\top) + \mathbf{O}^\top = \alpha \mathbf{A}^\top + \mathbf{O}.$$

O conceito de matriz transposta conecta-se diretamente com as ideias de matriz simétrica e anti-simétrica. Esses dois tipos de matrizes são importantes em Estatística e em outras áreas, pois diversas quantidades de interesse, como matrizes de variâncias e covariâncias (ver Seção 2.11), são naturalmente simétricas e, no próximo capítulo, veremos que ao estudar formas quadráticas podemos concentrar nossa análise apenas na parte simétrica de uma matriz, o que simplifica tanto a teoria quanto os cálculos.

Definição 2.22: Matriz simétrica

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. Dizemos que $\mathbf{A}$ é uma **matriz simétrica** quando $\mathbf{A}^\top = \mathbf{A}$. Em outras palavras, os elementos simetricamente dispostos em relação à diagonal principal são iguais.

Exemplo 2.41

(a) A matriz $\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ é uma matriz simétrica, pois $\mathbf{A}^\top = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}$ e, portanto, $\mathbf{A}^\top = \mathbf{A}$.

(b) A matriz $\mathbf{B} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 3 & 5 & 6 \end{bmatrix}$ é uma matriz simétrica, pois $\mathbf{B}^\top = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 3 & 5 & 6 \end{bmatrix}$ e, portanto, $\mathbf{B} = \mathbf{B}^\top$.

(c) A matriz identidade de ordem $n \times n$, $\mathbf{I}_n = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix}$, é uma matriz simétrica pois $\mathbf{I}_n^\top = \mathbf{I}_n$.

Definição 2.23: Matriz anti-simétrica

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. Dizemos que $\mathbf{A}$ é uma **matriz anti-simétrica** quando $\mathbf{A}^\top = -\mathbf{A}$. Em outras palavras, os elementos simetricamente dispostos em relação à diagonal principal são opostos.

Exemplo 2.42

(a) A matriz $\mathbf{C} = \begin{bmatrix} 0 & 5 \\ -5 & 0 \end{bmatrix}$ é uma matriz anti-simétrica, pois $\mathbf{C}^\top = \begin{bmatrix} 0 & -5 \\ 5 & 0 \end{bmatrix}$ e, portanto, $\mathbf{C}^\top = -\mathbf{C}$.

(b) A matriz $\mathbf{D} = \begin{bmatrix} 0 & 1 & 2 \\ -1 & 0 & 3 \\ -2 & -3 & 0 \end{bmatrix}$ é uma matriz anti-simétrica pois $\mathbf{D}^\top = \begin{bmatrix} 0 & -1 & -2 \\ 1 & 0 & -3 \\ 2 & 3 & 0 \end{bmatrix}$ e, portanto, $\mathbf{D}^\top = -\mathbf{D}$.

(c) A matriz nula $\mathbf{O}$ de ordem $n \times n$ é anti-simétrica, pois $\mathbf{O}^\top = -\mathbf{O}$.

Resultado 2.9: Propriedades das matrizes simétricas e anti-simétricas

As matrizes simétricas e as matrizes anti-simétricas apresentam as seguintes propriedades:

- (a) Se $\mathbf{A} \in M_n(\mathbb{R})$ e $\mathbf{B} \in M_n(\mathbb{R})$ são matrizes simétricas, então $\mathbf{A} + \mathbf{B}$ é uma matriz simétrica de ordem $n \times n$.
- (b) Se $\mathbf{A} \in M_n(\mathbb{R})$ e $\mathbf{B} \in M_n(\mathbb{R})$ são matrizes anti-simétricas, então $\mathbf{A} + \mathbf{B}$ é uma matriz anti-simétrica de ordem $n \times n$.
- (c) Se $\mathbf{A} \in M_n(\mathbb{R})$ é uma matriz anti-simétrica, então $\mathbf{A} + \mathbf{A}^\top = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times n$.

DEMONSTRAÇÃO:

- (a) Como as matrizes $\mathbf{A}$ e $\mathbf{B}$ são simétricas, segue que $\mathbf{A} = \mathbf{A}^\top$ e $\mathbf{B} = \mathbf{B}^\top$. Logo,

$$\mathbf{A} + \mathbf{B} = \mathbf{A}^\top + \mathbf{B}^\top = (\mathbf{A} + \mathbf{B})^\top.$$

Portanto, $\mathbf{A} + \mathbf{B}$ é uma matriz simétrica.

- (b) Como as matrizes $\mathbf{A}$ e $\mathbf{B}$ são anti-simétricas, segue que $\mathbf{A}^\top = -\mathbf{A}$ e $\mathbf{B}^\top = -\mathbf{B}$. Logo,

$$\mathbf{A} + \mathbf{B} = -\mathbf{A}^\top - \mathbf{B}^\top = -(\mathbf{A}^\top + \mathbf{B}^\top) = -(\mathbf{A} + \mathbf{B})^\top.$$

Portanto, $\mathbf{A} + \mathbf{B}$ é uma matriz anti-simétrica.

Resultado 2.9

(c) Como $\mathbf{A}$ é uma matriz anti-simétrica, segue que $\mathbf{A}^\top = -\mathbf{A}$. Logo,

$$\mathbf{A} + \mathbf{A}^\top = \mathbf{A} - \mathbf{A} = \mathbf{O}.$$

□

Observação 2.12

Em uma matriz anti-simétrica todos os elementos da diagonal principal são iguais a zero.

Veremos agora que, dada qualquer matriz quadrada, podemos separar sua “parte simétrica” e sua “parte anti-simétrica” de forma sistemática. Essa ideia será fundamental para a decomposição que mencionamos no início da seção e, mais adiante, para o estudo de formas quadráticas.

Definição 2.24: Parte simétrica e parte anti-simétrica de uma matriz

Seja $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. Definimos:

- a **parte simétrica** de $\mathbf{A}$ como a matriz

$$\mathbf{A}_{\text{sim}} = \frac{\mathbf{A} + \mathbf{A}^\top}{2};$$

- a **parte anti-simétrica** de $\mathbf{A}$ como a matriz

$$\mathbf{A}_{\text{asim}} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}.$$

Como veremos a seguir, $\mathbf{A}_{\text{sim}}$ é sempre uma matriz simétrica e $\mathbf{A}_{\text{asim}}$ é sempre uma matriz anti-simétrica.

Exemplo 2.43

Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 4 \\ 2 & 3 \end{bmatrix}.$$

Então,

$$\mathbf{A}^\top = \begin{bmatrix} 1 & 2 \\ 4 & 3 \end{bmatrix},$$

de modo que

$$\mathbf{A}_{\text{sim}} = \frac{\mathbf{A} + \mathbf{A}^\top}{2} = \frac{1}{2} \begin{bmatrix} 1+1 & 4+2 \\ 2+4 & 3+3 \end{bmatrix} = \begin{bmatrix} 1 & 3 \\ 3 & 3 \end{bmatrix}$$

e

$$\mathbf{A}_{\text{asim}} = \frac{\mathbf{A} - \mathbf{A}^\top}{2} = \frac{1}{2} \begin{bmatrix} 1-1 & 4-2 \\ 2-4 & 3-3 \end{bmatrix} = \begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}.$$

Note que $\mathbf{A}_{\text{sim}}$ é simétrica e $\mathbf{A}_{\text{asim}}$ é anti-simétrica.

Resultado 2.10

Seja $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. As seguintes afirmações são verdadeiras.

(a) $\mathbf{A}_{\text{sim}} = \frac{\mathbf{A} + \mathbf{A}^\top}{2}$ é uma matriz simétrica;

(b) $\mathbf{A}_{\text{asim}} = \frac{\mathbf{A} - \mathbf{A}^\top}{2}$ é uma matriz anti-simétrica;

(c) vale a decomposição

$$\mathbf{A} = \mathbf{A}_{\text{sim}} + \mathbf{A}_{\text{asim}};$$

(d) essa decomposição é única: se $\mathbf{A} = \mathbf{S} + \mathbf{K}$, com $\mathbf{S}$ simétrica e $\mathbf{K}$ anti-simétrica, então necessariamente $\mathbf{S} = \mathbf{A}_{\text{sim}}$ e $\mathbf{K} = \mathbf{A}_{\text{asim}}$.

DEMONSTRAÇÃO:

(a) Temos

$$\mathbf{A}_{\text{sim}}^\top = \left(\frac{\mathbf{A} + \mathbf{A}^\top}{2} \right)^\top = \frac{\mathbf{A}^\top + (\mathbf{A}^\top)^\top}{2} = \frac{\mathbf{A}^\top + \mathbf{A}}{2} = \mathbf{A}_{\text{sim}},$$

Resultado 2.10

logo $\mathbf{A}_{\text{sim}}$ é simétrica.

(b) De forma análoga,

$$\mathbf{A}_{\text{asim}}^{\top} = \left(\frac{\mathbf{A} - \mathbf{A}^{\top}}{2} \right)^{\top} = \frac{\mathbf{A}^{\top} - (\mathbf{A}^{\top})^{\top}}{2} = \frac{\mathbf{A}^{\top} - \mathbf{A}}{2} = -\frac{\mathbf{A} - \mathbf{A}^{\top}}{2} = -\mathbf{A}_{\text{asim}},$$

logo $\mathbf{A}_{\text{asim}}$ é anti-simétrica.

(c) Somando as duas partes, obtemos

$$\mathbf{A}_{\text{sim}} + \mathbf{A}_{\text{asim}} = \frac{\mathbf{A} + \mathbf{A}^{\top}}{2} + \frac{\mathbf{A} - \mathbf{A}^{\top}}{2} = \frac{2\mathbf{A}}{2} = \mathbf{A}.$$

(d) Suponha que $\mathbf{A} = \mathbf{S} + \mathbf{K}$, com $\mathbf{S}$ simétrica e $\mathbf{K}$ anti-simétrica. Tomando transpostas em ambos os lados,

$$\mathbf{A}^{\top} = \mathbf{S}^{\top} + \mathbf{K}^{\top} = \mathbf{S} - \mathbf{K},$$

pois $\mathbf{S}^{\top} = \mathbf{S}$ e $\mathbf{K}^{\top} = -\mathbf{K}$. Somando as duas igualdades, obtemos

$$\mathbf{A} + \mathbf{A}^{\top} = (\mathbf{S} + \mathbf{K}) + (\mathbf{S} - \mathbf{K}) = 2\mathbf{S},$$

isto é,

$$\mathbf{S} = \frac{\mathbf{A} + \mathbf{A}^{\top}}{2} = \mathbf{A}_{\text{sim}}.$$

Subtraindo as duas igualdades, obtemos

$$\mathbf{A} - \mathbf{A}^{\top} = (\mathbf{S} + \mathbf{K}) - (\mathbf{S} - \mathbf{K}) = 2\mathbf{K},$$

isto é,

$$\mathbf{K} = \frac{\mathbf{A} - \mathbf{A}^{\top}}{2} = \mathbf{A}_{\text{asim}}.$$

Portanto, a decomposição é única.

□

2.10 Matrizes invisíveis e a bijetividade de transformações lineares

Ao longo do curso, vimos que toda transformação linear $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ pode ser representada por uma matriz $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ tal que $\mathbf{F}(\mathbf{x}) = \mathbf{A}\mathbf{x}$ quando trabalhamos com as bases canônicas. Muitas vezes, porém, pensamos primeiro na transformação (o que ela faz com os vetores) e apenas depois, se for conveniente, escrevemos a matriz associada, é como se a matriz estivesse “invisível” por trás da transformação. Nesta seção, vamos estudar com cuidado como propriedades importantes de $\mathbf{F}$, como injetividade, sobrejetividade e bijetividade, podem ser descritas em termos de seu núcleo e de sua imagem, bem como das dimensões desses conjuntos. Em seguida, conectaremos essas ideias à teoria de matrizes por meio do espaço coluna e do posto da matriz associada $\mathbf{A}$, mostrando como essas duas linguagens, transformações lineares e matrizes, dizem as mesmas coisas, mas com roupagens diferentes.

2.10.1 Transformações lineares injetivas

Definição 2.25: Transformação linear injetiva

Seja $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ uma transformação linear. Dizemos que $\mathbf{F}$ é **injetiva** quando, para quaisquer vetores $\mathbf{u}, \mathbf{v} \in \mathbb{R}^p$,

$$\mathbf{F}(\mathbf{u}) = \mathbf{F}(\mathbf{v}) \Rightarrow \mathbf{u} = \mathbf{v}.$$

Em outras palavras, vetores distintos em $\mathbb{R}^p$ nunca são “colapsados” para a mesma imagem em $\mathbb{R}^n$.

Exemplo 2.44

Considere a transformação linear $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ definida por

$$\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 2x \\ -3y \end{bmatrix}.$$

Verifique se $\mathbf{F}$ é injetiva.

Exemplo 2.44SOLUÇÃO:

A matriz associada a $\mathbf{F}$ em relação às bases canônicas é

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & -3 \end{bmatrix}.$$

Se $\mathbf{F}(\mathbf{u}) = \mathbf{F}(\mathbf{v})$, então

$$\begin{bmatrix} 2u_1 \\ -3u_2 \end{bmatrix} = \begin{bmatrix} 2v_1 \\ -3v_2 \end{bmatrix} \Rightarrow 2u_1 = 2v_1 \text{ e } -3u_2 = -3v_2,$$

o que implica $u_1 = v_1$ e $u_2 = v_2$. Logo, $\mathbf{u} = \mathbf{v}$ e $\mathbf{F}$ é injetiva. Note que as colunas de $\mathbf{A}$,

$$\mathbf{c}_1 = \begin{bmatrix} 2 \\ 0 \end{bmatrix} \text{ e } \mathbf{c}_2 = \begin{bmatrix} 0 \\ -3 \end{bmatrix},$$

são linearmente independentes.

Exemplo 2.45

Considere agora $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ dada por

$$\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} x + y \\ x - y \\ y \end{bmatrix}.$$

Verifique se $\mathbf{F}$ é injetiva.

SOLUÇÃO:

A matriz associada é

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 0 & 1 \end{bmatrix}.$$

Se $\mathbf{F}\left(\begin{bmatrix} x_1 \\ y_1 \end{bmatrix}\right) = \mathbf{F}\left(\begin{bmatrix} x_2 \\ y_2 \end{bmatrix}\right)$, obtemos o seguinte sistema

Exemplo 2.45

$$\begin{cases} x_1 + y_1 = x_2 + y_2, \\ x_1 - y_1 = x_2 - y_2, \\ y_1 = y_2, \end{cases}$$

do qual segue $y_1 = y_2$ e, substituindo nas duas primeiras equações, também $x_1 = x_2$. Logo, $\mathbf{F}$ é injetiva. Novamente, as colunas de $\mathbf{A}$ são LI.

Exemplo 2.46

Considere $\mathbf{G} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ definida por

$$\mathbf{G}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 0 \\ x + y \\ 0 \end{bmatrix}$$

Verifique se G é injetiva.

SOLUÇÃO:

A matriz associada é

$$\mathbf{B} = \begin{bmatrix} 0 & 0 \\ 1 & 1 \\ 0 & 0 \end{bmatrix}.$$

Note que $\mathbf{G}\left(\begin{bmatrix} 1 \\ -1 \end{bmatrix}\right) = \mathbf{0}$ e $\mathbf{G}(\mathbf{0}) = \mathbf{0}$, embora $\begin{bmatrix} 1 \\ -1 \end{bmatrix} \neq \mathbf{0}$. Portanto, $\mathbf{G}$ não é injetiva.

Note que, nesse caso, as colunas de $\mathbf{B}$ são LD (uma é igual à outra), o que antecipa a conexão entre injetividade e independência das colunas da matriz associada.

2.10.2 Núcleo de uma transformação linear

Definição 2.26: Núcleo

Seja $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ uma transformação linear. O **núcleo** de $\mathbf{F}$, indicado por $\text{Ker}(\mathbf{F})$, é o conjunto

$$\text{Ker}(\mathbf{F}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{F}(\mathbf{x}) = \mathbf{0}\}.$$

Definição 2.26

Ou seja, $\text{Ker}(\mathbf{F})$ é o conjunto de todos os vetores do domínio que são “enviados para zero” pela transformação.

Observação 2.13

Se $\mathbf{F}(\mathbf{x}) = \mathbf{Ax}$, então

$$\text{Ker}(\mathbf{F}) = \{\mathbf{x} \in \mathbb{R}^p : \mathbf{Ax} = \mathbf{0}\},$$

ou seja, o núcleo de $\mathbf{F}$ coincide com o conjunto de soluções do sistema homogêneo $\mathbf{Ax} = \mathbf{0}$.

Exemplo 2.47

Determine o núcleo da transformação $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ dada por

$$\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} x + y \\ x - y \\ y \end{bmatrix},$$

SOLUÇÃO:

Temos $\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \mathbf{0}$ se, e somente se,

$$\begin{cases} x + y = 0, \\ x - y = 0, \\ y = 0, \end{cases}$$

o que implica $y = 0$ e $x = 0$. Logo,

$$\text{Ker}(\mathbf{F}) = \{\mathbf{0}\}.$$

Exemplo 2.48

Determine o núcleo da transformação $\mathbf{G} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ dada por

$$\mathbf{G}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 0 \\ x + y \\ 0 \end{bmatrix},$$

SOLUÇÃO:

Temos $\mathbf{G}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \mathbf{0}$ se, e somente se,

$$x + y = 0,$$

isto é, $x = -y$. Assim,

$$\text{Ker}(\mathbf{G}) = \left\{ \begin{bmatrix} t \\ -t \end{bmatrix} : t \in \mathbb{R} \right\} = \text{Span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\},$$

que é uma reta em $\mathbb{R}^2$.

A transformação $\mathbf{F}$ do Exemplo 1.47 é injetiva (ver Exemplo 1.45) e a transformação $\mathbf{G}$ do Exemplo 1.48 não é injetiva (ver Exemplo 1.46). No primeiro caso, apenas o vetor nulo pertence ao núcleo da transformação, enquanto, no segundo caso, um subespaço de dimensão menor é gerado. De fato, o núcleo de qualquer transformação injetiva possui dimensão zero, i.e., possui apenas o vetor nulo como elemento.

Resultado 2.11: Núcleo e injetividade

Uma transformação linear $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é injetiva se, e somente se,

$$\text{Ker}(\mathbf{F}) = \{\mathbf{0}\}.$$

DEMONSTRAÇÃO:

($\Rightarrow$) Suponha que $\mathbf{F}$ seja injetiva. Se $\mathbf{x} \in \text{Ker}(\mathbf{F})$, então $\mathbf{F}(\mathbf{x}) = \mathbf{0}$. Mas também $\mathbf{F}(\mathbf{0}) = \mathbf{0}$. Pela injetividade, $\mathbf{x} = \mathbf{0}$. Logo, $\text{Ker}(\mathbf{F}) = \{\mathbf{0}\}$.

($\Leftarrow$) Suponha agora que $\text{Ker}(\mathbf{F}) = \{\mathbf{0}\}$. Se $\mathbf{F}(\mathbf{u}) = \mathbf{F}(\mathbf{v})$, então

$$\mathbf{F}(\mathbf{u}) - \mathbf{F}(\mathbf{v}) = \mathbf{0} \Rightarrow \mathbf{F}(\mathbf{u} - \mathbf{v}) = \mathbf{0}.$$

Resultado 2.11

Logo, $\mathbf{u} - \mathbf{v} \in \text{Ker}(\mathbf{F})$. Como o núcleo é apenas $\{\mathbf{0}\}$, concluímos que $\mathbf{u} - \mathbf{v} = \mathbf{0}$, isto é, $\mathbf{u} = \mathbf{v}$. Portanto, $\mathbf{F}$ é injetiva.

□

Definição 2.27: Espaço coluna

Seja $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ uma matriz com colunas $\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_p \in \mathbb{R}^n$. O **espaço coluna** de $\mathbf{A}$, indicado por $\text{col}(\mathbf{A})$, é o subespaço vetorial de $\mathbb{R}^n$ gerado por essas colunas:

$$\text{col}(\mathbf{A}) = \text{Span}\{\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_p\} = \{\mathbf{y} \in \mathbb{R}^n : \mathbf{y} = \alpha_1 \mathbf{c}_1 + \dots + \alpha_p \mathbf{c}_p, \alpha_i \in \mathbb{R}\}.$$

Definição 2.28: Imagem

Seja $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ uma transformação linear. A **imagem** de $\mathbf{F}$, indicada por $\mathfrak{I}(\mathbf{F})$, é o conjunto

$$\mathfrak{I}(\mathbf{F}) = \{\mathbf{F}(\mathbf{u}) : \mathbf{u} \in \mathbb{R}^p\},$$

isto é, o conjunto de todos os vetores de $\mathbb{R}^n$ que de fato aparecem como imagem de algum vetor do domínio.

Resultado 2.12: Imagem e espaço coluna

Se $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é uma transformação linear com matriz associada $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ em relação às bases canônicas, então

$$\mathfrak{I}(\mathbf{F}) = \text{col}(\mathbf{A}).$$

DEMONSTRAÇÃO:

Seja $\mathbf{x} \in \mathbb{R}^p$. Escrevendo $\mathbf{x}$ em coordenadas em relação à base canônica, temos

$$\mathbf{F}(\mathbf{x}) = \mathbf{A}\mathbf{x} = x_1 \mathbf{c}_1 + \dots + x_p \mathbf{c}_p,$$

logo $\mathbf{F}(\mathbf{x}) \in \text{col}(\mathbf{A})$. Isso mostra que $\mathfrak{I}(\mathbf{F}) \subseteq \text{col}(\mathbf{A})$.

Resultado 2.12

Reciprocamente, seja $\mathbf{y} \in \text{col}(\mathbf{A})$. Então existem escalares $\alpha_1, \dots, \alpha_p \in \mathbb{R}$ tais que

$$\mathbf{y} = \alpha_1 \mathbf{c}_1 + \dots + \alpha_p \mathbf{c}_p.$$

Definindo $\mathbf{x} = (\alpha_1, \dots, \alpha_p)^\top$, obtemos

$$\mathbf{F}(\mathbf{x}) = \mathbf{A}\mathbf{x} = \mathbf{y},$$

o que mostra que $\mathbf{y} \in \mathfrak{S}(\mathbf{F})$. Logo, $\text{col}(\mathbf{A}) \subseteq \mathfrak{S}(\mathbf{F})$ e a igualdade está demonstrada. $\square$

Definição 2.29: Dimensão da imagem e do espaço coluna

A **dimensão da imagem** de $\mathbf{F}$ é definida como $\dim(\mathfrak{S}(\mathbf{F}))$. A **dimensão do espaço coluna** de $\mathbf{A}$ é

$$\dim(\text{col}(\mathbf{A})) = \text{número de colunas LI de } \mathbf{A}.$$

Pelo resultado anterior, temos sempre

$$\dim(\mathfrak{S}(\mathbf{F})) = \dim(\text{col}(\mathbf{A})).$$

2.10.3 Transformações lineares sobrejetivas

Definição 2.30: Transformação linear sobrejetiva

Seja $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ uma transformação linear. Dizemos que $\mathbf{F}$ é **sobrejetiva** quando

$$\mathfrak{S}(\mathbf{F}) = \mathbb{R}^n,$$

isto é, quando cada vetor de $\mathbb{R}^n$ é a imagem de algum vetor em $\mathbb{R}^p$.

Usando a identificação $\mathfrak{S}(\mathbf{F}) = \text{col}(\mathbf{A})$, vemos que a sobrejetividade de $\mathbf{F}$ está ligada ao fato de que as colunas de $\mathbf{A}$ geram todo $\mathbb{R}^n$.

Resultado 2.13: Sobrejetividade e espaço coluna

Se $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é linear com matriz associada $\mathbf{A} \in M_{n \times p}(\mathbb{R})$, então:

$$\mathbf{F} \text{ é sobrejetiva} \iff \Im(\mathbf{F}) = \mathbb{R}^n \iff \dim(\text{col}(\mathbf{A})) = n.$$

Exemplo 2.49

(a) A transformação $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dada por

$$\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 2x \\ -3y \end{bmatrix}$$

é sobrejetiva, pois qualquer vetor $(a, b)^\top \in \mathbb{R}^2$ pode ser escrito como

$$\begin{bmatrix} a \\ b \end{bmatrix} = \mathbf{F}\left(\begin{bmatrix} a/2 \\ -b/3 \end{bmatrix}\right).$$

Equivalentemente, as duas colunas de $\mathbf{A}$ são LI e geram $\mathbb{R}^2$.

(b) A transformação $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ dada por

$$\mathbf{F}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} x + y \\ x - y \\ y \end{bmatrix}$$

não é sobrejetiva, pois a imagem é um subespaço de dimensão 2 em $\mathbb{R}^3$ (um plano passando pela origem); logo, $\Im(\mathbf{F}) \neq \mathbb{R}^3$.

(c) A transformação $\mathbf{G} : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ dada por

$$\mathbf{G}\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} 0 \\ x + y \\ 0 \end{bmatrix}$$

também não é sobrejetiva, pois sua imagem é apenas uma reta em $\mathbb{R}^3$.

2.10.4 Transformações lineares bijetivas

Definição 2.31: Transformação linear bijetiva

Um operador linear $\mathbf{F} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ é dito **bijetor** quando é injetivo e sobrejetivo ao mesmo tempo.

Do ponto de vista geométrico, um operador bijetor é aquele que “reorganiza” os vetores de $\mathbb{R}^n$ sem perder informação (injetivo) e sem deixar nenhum vetor de fora (sobrejetivo). Do ponto de vista matricial, veremos que isso significa que a matriz associada $\mathbf{A} \in M_n(\mathbb{R})$ tem colunas que formam uma base de $\mathbb{R}^n$.

Resultado 2.14: Bijetividade e dimensão da imagem

Se $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é linear com matriz associada $\mathbf{A}$, então:

$$\mathbf{F} \text{ é bijetora} \iff p = n \text{ e } \dim(\Im(\mathbf{F})) = n \iff \dim(\text{col}(\mathbf{A})) = n.$$

Em particular, no caso bijetor, as colunas de $\mathbf{A}$ formam uma base de $\mathbb{R}^n$.

Exemplo 2.50

(a) A identidade $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dada por

$$\mathbf{F} \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} x \\ y \end{bmatrix}$$

é bijetora: é claramente injetiva e sobrejetiva. A matriz associada é $\mathbf{I}_2$, cujas colunas formam a base canônica de $\mathbb{R}^2$.

(b) A transformação $\mathbf{F} : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ dada por

$$\mathbf{F} \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} 2x \\ 2y \end{bmatrix}$$

também é bijetora: é injetiva (a única solução de $2x = 0$ e $2y = 0$ é $(0, 0)$) e sobrejetiva (basta tomar $(x, y) = (a/2, b/2)$ para obter (a, b) como imagem). As colunas da matriz

Exemplo 2.50

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 2 \end{bmatrix}$$

formam uma base de $\mathbb{R}^2$.

2.10.5 Posto de uma matriz

Definição 2.32: Posto de uma matriz

Seja $\mathbf{A} \in M_{n \times p}(\mathbb{R})$. O **posto** de $\mathbf{A}$, indicado por $r(\mathbf{A})$, é definido por

$$r(\mathbf{A}) = \dim(\text{col}(\mathbf{A})),$$

isto é, o número máximo de colunas LI de $\mathbf{A}$.

Com essa notação, podemos reescrever vários resultados desta seção de forma compacta, conectando diretamente a “matriz invisível” $\mathbf{A}$ às propriedades da transformação linear $\mathbf{F}(\mathbf{x}) = \mathbf{A}\mathbf{x}$.

Resultado 2.15: Posto, injetividade, sobrejetividade e bijetividade

Seja $\mathbf{F} : \mathbb{R}^p \rightarrow \mathbb{R}^n$ uma transformação linear com matriz associada $\mathbf{A} \in M_{n \times p}(\mathbb{R})$. Então:

- (a) $\mathbf{F}$ é injetiva $\iff r(\mathbf{A}) = p \implies n \geq p$.
- (b) $\mathbf{F}$ é sobrejetiva $\iff r(\mathbf{A}) = n \implies n \leq p$.
- (c) $\mathbf{F}$ é bijetora $\iff r(\mathbf{A}) = n = p$.
- (d) Sempre vale $r(\mathbf{A}) \leq \min\{n, p\}$.

Esses resultados mostram como, ao estudar o núcleo e a imagem de $\mathbf{F}$, estamos, na prática, investigando subespaços determinados pelas colunas da matriz associada $\mathbf{A}$. Mesmo quando a matriz não aparece explicitamente, ela está sempre “escondida” por trás da transformação, governando propriedades fundamentais como injetividade, sobrejetividade e bijetividade.

2.10.6 Matrizes inversíveis

Antes de formalizarmos a noção de matriz inversível, retomemos a ideia de transformação linear inversa estudada anteriormente. Dada uma transformação linear $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$, dizemos que F é inversível quando existe uma transformação linear $F^{-1} : \mathbb{R}^n \rightarrow \mathbb{R}^n$ tal que $F^{-1}(F(\mathbf{x})) = \mathbf{x}$ e $F(F^{-1}(\mathbf{x})) = \mathbf{x}$ para todo vetor $\mathbf{x} \in \mathbb{R}^n$. Fixada uma base de $\mathbb{R}^n$, a transformação linear F é representada por uma matriz quadrada $\mathbf{A}$ e, quando F é inversível, a transformação inversa F^{-1} é representada por uma matriz inversa $\mathbf{A}^{-1}$. Nesta seção, estudaremos diretamente a inversibilidade de matrizes, tendo em mente essa correspondência entre transformações lineares e matrizes.

Definição 2.33: Matriz inversível

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. Dizemos que $\mathbf{A}$ é uma **matriz inversível** quando existir uma matriz quadrada $\mathbf{B}$ de ordem $n \times n$ tal que

$$\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n,$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$. Quando a matriz $\mathbf{A}$ não é inversível, dizemos que a matriz $\mathbf{A}$ é uma **matriz singular**.

Resultado 2.16

Se $\mathbf{A}$ é uma matriz inversível de ordem $n \times n$, então é única a matriz $\mathbf{B}$ tal que $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$.

DEMONSTRAÇÃO:

Admitamos que exista, além da matriz $\mathbf{B}$, uma matriz $\mathbf{C}$ de ordem $n \times n$ tal que $\mathbf{AC} = \mathbf{CA} = \mathbf{I}_n$. Assim,

$$\mathbf{C} = \mathbf{I}_n \mathbf{C} = (\mathbf{BA})\mathbf{C} = \mathbf{B}(\mathbf{AC}) = \mathbf{BI}_n = \mathbf{B}.$$

Como $\mathbf{C} = \mathbf{B}$, é única a matriz $\mathbf{B}$.

□

Definição 2.34: Matriz inversa

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz inversível de ordem $n \times n$. Dizemos que a matriz $\mathbf{A}^{-1}$ é a **matriz inversa** da matriz $\mathbf{A}$ quando $\mathbf{A}\mathbf{A}^{-1} = \mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$.

Exemplo 2.51

(a) A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}$$

é inversível, pois tomando

$$\mathbf{B} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix},$$

segue que $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_2$, em que $\mathbf{I}_2$ é a matriz identidade de ordem 2×2 . Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1/2 & 0 \\ 0 & 1 \end{bmatrix}.$$

(b) A matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 3 \\ 2 & 7 \end{bmatrix}$$

é inversível, pois tomando

$$\mathbf{B} = \begin{bmatrix} 7 & -3 \\ -2 & 1 \end{bmatrix},$$

segue que $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_2$, em que $\mathbf{I}_2$ é a matriz identidade de ordem 2×2 . Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 7 & -3 \\ -2 & 1 \end{bmatrix}.$$

(c) A matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 7 \\ 0 & 3 & 1 \\ 0 & 5 & 2 \end{bmatrix}$$

é inversível, pois tomando

Exemplo 2.51

$$\mathbf{B} = \begin{bmatrix} 1 & 31 & -19 \\ 0 & 2 & -1 \\ 0 & -5 & 3 \end{bmatrix},$$

segue que $\mathbf{AB} = \mathbf{BA} = \mathbf{I}_3$, em que $\mathbf{I}_3$ é a matriz identidade de ordem 3×3 . Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} 1 & 31 & -19 \\ 0 & 2 & -1 \\ 0 & -5 & 3 \end{bmatrix}.$$

Exemplo 2.52

Qual é a matriz inversa da matriz

$$\mathbf{A} = \begin{bmatrix} 3 & 7 \\ 5 & 11 \end{bmatrix}?$$

SOLUÇÃO:

Fazendo

$$\mathbf{A}^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

em que a , b , c e d são números reais desconhecidos, segue que

$$\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_2 \Leftrightarrow \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} 3 & 7 \\ 5 & 11 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \Leftrightarrow \begin{cases} 3a + 5b = 1, \\ 7a + 11b = 0, \end{cases} \text{ e } \begin{cases} 3c + 5d = 0, \\ 7c + 11d = 1. \end{cases}$$

Logo, $a = -\frac{11}{2}$, $b = \frac{7}{2}$, $c = \frac{5}{2}$ e $d = -\frac{3}{2}$. Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} -\frac{11}{2} & \frac{7}{2} \\ \frac{5}{2} & -\frac{3}{2} \end{bmatrix},$$

uma vez que temos também $\mathbf{AA}^{-1} = \mathbf{I}_2$, em que $\mathbf{I}_2$ é a matriz identidade de ordem 2×2 .

Exemplo 2.53

A matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 4 & 8 \end{bmatrix}$$

é singular (não é inversível), pois se

$$\mathbf{A}^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix},$$

em que a , b , c e d são números reais desconhecidos, decorre que

$$\mathbf{A}\mathbf{A}^{-1} = \mathbf{I}_2 \Leftrightarrow \begin{bmatrix} 1 & 2 \\ 4 & 8 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \Leftrightarrow \begin{cases} a + 2c = 1, \\ 4a + 8c = 0, \end{cases} \text{ e } \begin{cases} b + 2d = 0, \\ 4b + 8d = 1. \end{cases}$$

Ambos os sistemas são impossíveis, portanto não existem números reais a , b , c e d satisfazendo a definição de matriz inversa.

Exemplo 2.54

Qual é a matriz inversa da matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 1 \\ 4 & 9 & 1 \end{bmatrix}?$$

SOLUÇÃO:

Fazendo

$$\mathbf{A}^{-1} = \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix},$$

em que todas as entradas dessa matriz são números reais desconhecidos, segue que

Exemplo 2.54

$$\begin{aligned}
\mathbf{A}^{-1}\mathbf{A} = \mathbf{I}_3 &\Leftrightarrow \begin{bmatrix} a & b & c \\ d & e & f \\ g & h & i \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 2 & 3 & 1 \\ 4 & 9 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \\
&\Leftrightarrow \begin{cases} a + 2b + 4c = 1, \\ a + 3b + 9c = 0, \\ a + b + c = 0, \end{cases} \quad \begin{cases} d + 2e + 4f = 0, \\ d + 3e + 9f = 1, \\ d + e + f = 0, \end{cases} \quad \text{e} \quad \begin{cases} g + 2h + 4i = 0, \\ g + 3h + 9i = 0, \\ g + h + i = 1. \end{cases}
\end{aligned}$$

Logo,

$$\begin{cases} a = -3, & b = 4, & c = -1, \\ d = 1, & e = -\frac{3}{2}, & f = \frac{1}{2}, \\ g = 3, & h = -\frac{5}{2}, & i = \frac{1}{2}. \end{cases}$$

Exemplo 2.55

Portanto,

$$\mathbf{A}^{-1} = \begin{bmatrix} -3 & 4 & -1 \\ 1 & -3/2 & 1/2 \\ 3 & -5/2 & 1/2 \end{bmatrix},$$

uma vez que temos também $\mathbf{A}\mathbf{A}^{-1} = \mathbf{I}_3$, em que $\mathbf{I}_3$ é a matriz identidade de ordem 3×3 .

Observação 2.14

Dos exemplos anteriores, observamos que dado um número natural não-nulo n , para determinar a matriz inversa de uma matriz quadrada de ordem $n \times n$, temos de obter n^2 incógnitas, resolvendo n sistemas de n equações e n incógnitas cada um. Esse método não é prático, por isso vamos estudar outros métodos para obtenção da matriz inversa, como, por exemplo, via determinantes e vamos aprender como calcular a matriz inversa de uma matriz dada com o auxílio do *software* estatístico R.

Resultado 2.17: Propriedades da matriz inversa

A matriz inversa de uma matriz quadrada dada apresenta as seguintes propriedades:

- (a) $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$, qualquer que seja a matriz inversível $\mathbf{A} \in M_n(\mathbb{R})$.
- (b) $(\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1}$, qualquer que seja a matriz inversível $\mathbf{A} \in M_n(\mathbb{R})$.
- (c) $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$, quaisquer que sejam as matrizes inversíveis $\mathbf{A}, \mathbf{B} \in M_n(\mathbb{R})$.
- (d) $(\alpha\mathbf{A})^{-1} = \frac{1}{\alpha}\mathbf{A}^{-1}$, qualquer que seja o número real $\alpha \neq 0$ e a matriz inversível $\mathbf{A} \in M_n(\mathbb{R})$.

DEMONSTRAÇÃO:

- (a) Fazendo $\mathbf{B} = \mathbf{A}^{-1}$ segue que

$$\mathbf{BB}^{-1} = \mathbf{I}_n \Leftrightarrow \mathbf{A}^{-1}(\mathbf{A}^{-1})^{-1} = \mathbf{I}_n,$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$. Como a matriz inversa é única, concluímos que

$$(\mathbf{A}^{-1})^{-1} = \mathbf{A}.$$

Analogamente, se tivéssemos partido de $\mathbf{B}^{-1}\mathbf{B} = \mathbf{I}_n$.

- (b) De fato,

$$(\mathbf{AA}^{-1})^\top = \mathbf{I}_n^\top = \mathbf{I}_n,$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$. Logo, pelo item (d) do Teorema 5, segue que

$$(\mathbf{A}^{-1})^\top \mathbf{A}^\top = \mathbf{I}_n.$$

Portanto, como a matriz inversa é única, concluímos que

$$(\mathbf{A}^{-1})^\top = (\mathbf{A}^\top)^{-1}.$$

- (c) De fato,

$$(\mathbf{AB})(\mathbf{B}^{-1}\mathbf{A}^{-1}) = \mathbf{A}(\mathbf{BB}^{-1})\mathbf{A}^{-1} = \mathbf{AI}_n\mathbf{A}^{-1} = \mathbf{AA}^{-1} = \mathbf{I}_n,$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$. Analogamente, mostramos que

Resultado 2.17

$$(B^{-1}A^{-1})(AB) = I_n.$$

Portanto,

$$(AB)^{-1} = B^{-1}A^{-1}.$$

(d) Fazendo $B = \alpha A$ segue que

$$BB^{-1} = I_n \Leftrightarrow \alpha A (\alpha A)^{-1} = I_n,$$

em que I_n é a matriz identidade de ordem $n \times n$. Como a matriz inversa é única, concluímos que

$$(\alpha A)^{-1} = \frac{1}{\alpha} A^{-1}.$$

Analogamente, se tivéssemos partido de $B^{-1}B = I_n$.

□

2.11 Determinantes

Definição 2.35: Determinante de matrizes quadradas ($n \leq 3$)

Sejam n um número natural não-nulo menor do que ou igual a 3 e $M_n(\mathbb{R})$ o conjunto das matrizes quadradas de ordem $n \times n$. Seja $A \in M_n(\mathbb{R})$. Chamamos de **determinante** da matriz A , que indicamos por $\det(A)$, o número real que podemos obter operando os elementos da matriz A da seguinte forma:

(a) Se $n = 1$, isto é, A é uma matriz quadrada de ordem 1×1 , então $\det(A)$ é igual ao único elemento de A . Em outras palavras,

$$A = [a_{11}] \Rightarrow \det(A) = a_{11}.$$

(b) Se $n = 2$, isto é, A é uma matriz quadrada de ordem 2×2 , então $\det(A)$ é igual ao produto dos elementos da diagonal principal menos o produto dos elementos

Definição 2.35

da diagonal secundária. Em outras palavras,

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix} \Rightarrow \det(\mathbf{A}) = a_{11}a_{22} - a_{12}a_{21}.$$

(c) Se $n = 3$, $\mathbf{A}$ é uma matriz quadrada de ordem 3×3 , isto é

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

então


$$\det(\mathbf{A}) = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}.$$

Observação 2.15

1. Podemos representar o determinante de uma matriz $\mathbf{A}$ colocando os elementos da matriz $\mathbf{A}$ entre duas **barras verticais**. Assim, podemos representar o determinante de uma matriz genérica de ordem 3×3 da seguinte forma

$$\begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix}.$$

2. Podemos memorizar a definição de determinante para matrizes de ordem 3×3 da seguinte forma:
 - Repetimos, ao lado da matriz, as duas primeiras colunas e efetuamos as seis multiplicações como indicado
 - Os produtos obtidos no sentido da diagonal principal permanecem com o mesmo sinal.
 - Os produtos obtidos no sentido da diagonal secundária mudam de sinal.
 - O determinante é a soma dos valores assim obtidos.

Observação 2.1

Pierre Frédéric Sarrus foi o matemático francês que descobriu essa regra prática para encontrar o determinante de matrizes quadradas de ordem 3×3 . Em sua homenagem, essa regra é chamada *regra de Sarrus*.

Exemplo 2.56

Calcule o determinante da matriz

$$\mathbf{A} = \begin{bmatrix} \sqrt{2} & -1 \\ 3 & 5\sqrt{2} \end{bmatrix}.$$

SOLUÇÃO:

$$\begin{vmatrix} \sqrt{2} & -1 \\ 3 & 5\sqrt{2} \end{vmatrix} = 10 + 3 = 13.$$

Exemplo 2.57

Determine o número real x tal que

$$\begin{vmatrix} 5 & 2 \\ x-1 & x+3 \end{vmatrix} = -1.$$

Exemplo 2.57SOLUÇÃO:

$$\begin{vmatrix} 5 & 2 \\ x-1 & x+3 \end{vmatrix} = -1 \Leftrightarrow 5(x+3) - 2(x-1) = -1 \Leftrightarrow 3x + 17 = -1 \Leftrightarrow x = 6.$$

Exemplo 2.58

Dadas as matrizes $\mathbf{A} = \begin{bmatrix} 3 & 1 \\ -1 & 2 \end{bmatrix}$ e $\mathbf{B} = \begin{bmatrix} -1 & 5 \\ 0 & -1 \end{bmatrix}$, calcule:

(a) $\det(\mathbf{A} + \mathbf{B})$.

(b) $\det(\mathbf{AB})$.

(c) $(\det(\mathbf{A}))\mathbf{B}$.

SOLUÇÃO:

(a) Temos

$$\mathbf{A} + \mathbf{B} = \begin{bmatrix} 2 & 6 \\ -1 & 1 \end{bmatrix}.$$

Logo,

$$\det(\mathbf{A} + \mathbf{B}) = 2 + 6 = 8.$$

(b) Temos

$$\mathbf{AB} = \begin{bmatrix} -3 & 14 \\ 1 & -7 \end{bmatrix}.$$

Logo,

$$\det(\mathbf{AB}) = 21 - 14 = 7.$$

(c) Temos

$$\det(\mathbf{A}) = 6 + 1 = 7.$$

Logo,

$$(\det(\mathbf{A}))\mathbf{B} = 7\mathbf{B} = \begin{bmatrix} -7 & 35 \\ 0 & -7 \end{bmatrix}.$$

Exemplo 2.59

Dadas as matrizes

$$\mathbf{A} = \begin{bmatrix} 2 & x \\ 3 & 9 \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} 1 & -1 & 0 \\ 2 & 3 & x \\ -1 & 2 & 1 \end{bmatrix}.$$

Determine o número real x tal que $\det(\mathbf{A}) = \det(\mathbf{B})$.

SOLUÇÃO: Temos

$$\det(\mathbf{A}) = 18 - 3x \text{ e } \det(\mathbf{B}) = 5 - x.$$

Logo,

$$\det(\mathbf{A}) = \det(\mathbf{B}) \Leftrightarrow 18 - 3x = 5 - x \Leftrightarrow 2x = 13 \Leftrightarrow x = \frac{13}{2}.$$

Definição 2.36: Menor complementar

Considere uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$, em que n é um número natural maior do que ou igual a 2. Seja a_{ij} o elemento genérico da matriz $\mathbf{A}$ que está na linha i e coluna j de forma que i e j são números naturais tais que $1 \leq i \leq n$ e $1 \leq j \leq n$. O **menor complementar** do elemento a_{ij} , que indicamos por D_{ij} , é o determinante da matriz que se obtém suprimindo a linha i e a coluna j da matriz $\mathbf{A}$.

Exemplo 2.60

Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 4 & 3 & 4 \\ 2 & 1 & 5 \\ 3 & 3 & 2 \end{bmatrix}.$$

- (a) Determine D_{11} o menor complementar do elemento a_{11} da matriz $\mathbf{A}$.
- (b) Determine D_{21} o menor complementar do elemento a_{21} da matriz $\mathbf{A}$.
- (c) Determine D_{31} o menor complementar do elemento a_{31} da matriz $\mathbf{A}$.

Exemplo 2.61SOLUÇÃO:

(a)

$$D_{11} = \begin{vmatrix} 1 & 5 \\ 3 & 2 \end{vmatrix} = -13.$$

(b)

$$D_{21} = \begin{vmatrix} 3 & 4 \\ 3 & 2 \end{vmatrix} = -6.$$

(c)

$$D_{31} = \begin{vmatrix} 3 & 4 \\ 1 & 5 \end{vmatrix} = 11.$$

Exemplo 2.60

Considere a matriz

$$\mathbf{B} = \begin{bmatrix} 5 & 6 \\ 7 & 8 \end{bmatrix}.$$

(a) Determine D_{12} o menor complementar do elemento b_{12} da matriz $\mathbf{B}$.(b) Determine D_{22} o menor complementar do elemento b_{22} da matriz $\mathbf{B}$.SOLUÇÃO:

$$(a) \quad D_{12} = |7| = 7.$$

$$(b) \quad D_{22} = |5| = 5.$$

Definição 2.37: Cofator

Considere uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$, em que n é um número natural maior do que ou igual a 2. Seja a_{ij} o elemento genérico de $\mathbf{A}$ que está na linha i e na coluna j de forma que i e j são números naturais tais que $1 \leq i \leq n$ e $1 \leq j \leq n$. O **cofator** do elemento a_{ij} , que indicamos por A_{ij} , é o número $(-1)^{i+j}D_{ij}$, em que D_{ij} é o menor complementar do elemento a_{ij} .

Exemplo 2.61

Considere a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 3 & -2 \\ 1 & 4 & 8 \\ 7 & 5 & 3 \end{bmatrix}.$$

- (a) Determine A_{11} o cofator do elemento a_{11} da matriz $\mathbf{A}$.
- (b) Determine A_{12} o cofator do elemento a_{12} da matriz $\mathbf{A}$.
- (c) Determine A_{13} o cofator do elemento a_{13} da matriz $\mathbf{A}$.

SOLUÇÃO:

$$(a) \quad A_{11} = (-1)^2 D_{11} = \begin{vmatrix} 4 & 8 \\ 5 & 3 \end{vmatrix} = -28.$$

$$(b) \quad A_{12} = (-1)^3 \begin{vmatrix} 1 & 8 \\ 7 & 3 \end{vmatrix} = 53.$$

$$(c) \quad A_{13} = (-1)^4 \begin{vmatrix} 1 & 4 \\ 7 & 5 \end{vmatrix} = -23.$$

Já vimos no início dessa seção a definição de determinante para matrizes quadradas de ordem 1, 2 e 3. Vamos agora, com o auxílio do conceito de cofator, apresentar definição de determinante, válida para matrizes de ordem $n \times n$ qualquer que seja o número natural não-nulo n .

Definição 2.38: Determinante (caso geral)

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. O **determinante** da matriz $\mathbf{A}$, que indicamos por $\det(\mathbf{A})$, é tal que

- (a) Se $n = 1$, isto é, $\mathbf{A}$ é uma matriz quadrada de ordem 1×1 , então $\mathbf{A} = [a_{11}]$ e $\det(\mathbf{A}) = a_{11}$.

Definição 2.39: Determinante (caso geral)

(b) Se $\mathbf{A}$ é uma matriz quadrada de ordem $n \times n$, em que n é um número natural maior do que 2, então

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

e definimos

$$\det(\mathbf{A}) = a_{11}A_{11} + a_{21}A_{21} + a_{31}A_{31} + \dots + a_{n1}A_{n1} = \sum_{i=1}^n a_{i1}A_{i1},$$

em que A_{i1} é o cofator do elemento a_{i1} da matriz $\mathbf{A}$ para todo número natural i tal que $1 \leq i \leq n$. Em outras palavras, o determinante de uma matriz quadrada de ordem $n \times n$, $n \geq 2$, é a soma dos produtos dos elementos da primeira coluna da matriz pelos respectivos cofatores,

Exemplo 2.62

Calcule o determinante das seguintes matrizes:

$$(a) \mathbf{A} = \begin{bmatrix} 3 & 1 & 2 & -2 \\ 0 & 2 & 0 & 4 \\ 0 & 4 & 1 & -2 \\ 0 & 1 & 3 & 3 \end{bmatrix}.$$

$$(b) \mathbf{B} = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 2 & 1 & 4 & 3 \\ 3 & 0 & 0 & 2 \\ 4 & 3 & 2 & -5 \end{bmatrix}.$$

Exemplo 2.62SOLUÇÃO:

(a)

$$\det(\mathbf{A}) = 3A_{11} + 0A_{21} + 0A_{31} + 0A_{41} = 3A_{11} = 3 \times (-1)^2 \times \begin{vmatrix} 2 & 0 & 4 \\ 4 & 1 & -2 \\ 1 & 3 & 3 \end{vmatrix} = 3 \times 62 = 186.$$

(b)

$$\begin{aligned} \det(\mathbf{B}) &= 1A_{11} + 2A_{21} + 3A_{31} + 4A_{41} \\ &= \begin{vmatrix} 1 & 4 & 3 \\ 0 & 0 & 2 \\ 3 & 2 & -5 \end{vmatrix} - 2 \begin{vmatrix} 2 & 1 & 1 \\ 0 & 0 & 2 \\ 3 & 2 & -5 \end{vmatrix} + 3 \begin{vmatrix} 2 & 1 & 1 \\ 1 & 4 & 3 \\ 3 & 2 & -5 \end{vmatrix} - 4 \begin{vmatrix} 2 & 1 & 1 \\ 1 & 4 & 3 \\ 0 & 0 & 2 \end{vmatrix} \\ &= -176. \end{aligned}$$

Observação 2.2

Note que quando a primeira coluna da matriz que desejamos calcular o determinante não possui zeros, o cálculo do determinante torna-se trabalhoso (ver Exemplo anterior). Portanto, vamos aprender, mais adiante, como calcular o determinante de uma matriz dada com o auxílio do *software* estatístico R.

Resultado 2.18: Propriedades de determinantes

- (a) (*Teorema fundamental de Laplace*) O determinante de uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$, em que n é um número natural maior do que ou igual a 2, é o produto dos elementos de uma fila qualquer (linha ou coluna) pelos respectivos cofatores.
- (b) (*Fila de zeros*) Se todos os elementos de uma linha ou coluna de uma matriz quadrada $\mathbf{A}$ forem iguais a zero, então seu determinante será igual a zero, isto é, $\det(\mathbf{A}) = 0$.

Resultado 2.18

- (c) (*Troca de filas paralelas*) Seja $\mathbf{A}$ uma matriz de ordem $n \times n$, em que n é um número natural maior do que ou igual a 2. Se trocarmos de posição duas filas paralelas (linhas ou colunas), então obteremos uma nova matriz $\mathbf{A}'$ tal que $\det(\mathbf{A}') = -\det(\mathbf{A})$.
- (d) (*Filas iguais*) Se os elementos correspondente de duas linhas (ou duas colunas) de uma matriz quadrada $\mathbf{A}$ forem iguais, então seu determinante será nulo, isto é, $\det(\mathbf{A}) = 0$.
- (e) (*Filas paralelas proporcionais*) Se uma matriz quadrada $\mathbf{A}$ possui duas linhas (ou duas colunas) proporcionais, seu determinante será nulo, isto é, $\det(\mathbf{A}) = 0$.
- (f) (*Multiplicação de uma fila por uma constante*) Se multiplicarmos uma fila qualquer (linha ou coluna) de uma matriz quadrada $\mathbf{A}$ por um número real α , então obteremos uma nova matriz $\mathbf{A}'$ tal que $\det(\mathbf{A}') = \alpha \det(\mathbf{A})$.
- (g) (*Multiplicação da matriz por uma constante*) $\det(\alpha \mathbf{A}) = \alpha^n \det(\mathbf{A})$, qualquer que sejam o número real α e a matriz quadrada $\mathbf{A}$ de ordem $n \times n$, em que n é um número natural não-nulo.
- (h) (*Determinante da transposta*) $\det(\mathbf{A}^\top) = \det(\mathbf{A})$, qualquer que seja a matriz quadrada $\mathbf{A}$ de ordem $n \times n$, em que n é um número natural não-nulo.
- (i) (*Determinante da matriz triangular*) O determinante de uma matriz triangular é igual ao produto dos elementos da diagonal principal.
- (j) (*Teorema de Binet*) $\det(\mathbf{AB}) = \det(\mathbf{A})\det(\mathbf{B})$, qualquer que sejam as matrizes quadradas $\mathbf{A}$ e $\mathbf{B}$ de ordem $n \times n$, em que n é um número natural não-nulo.
- (k) (*Determinante da inversa*) Se $\mathbf{A}$ é uma matriz inversível de ordem $n \times n$, então $\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}$.

A demonstração das propriedades de determinantes podem ser vistas da página 87 até a página 124 do livro de [Iezzi e Hassan \(1995\)](#).

Exemplo 2.63

Considere as seguintes matrizes quadradas:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 1 & 1 \\ 2 & 1 & 4 & 3 \\ 3 & 0 & 0 & 2 \\ 4 & 3 & 2 & 5 \end{bmatrix}, \mathbf{B} = \begin{bmatrix} 0 & 1 & 4 \\ 0 & 1 & 3 \\ 0 & 1 & 2 \end{bmatrix}, \mathbf{C} = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 3 & 6 & 3 \end{bmatrix}, \mathbf{D} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 2 & 0 \\ 3 & 4 & 3 \end{bmatrix} \text{ e } \mathbf{E} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 2 & 3 \\ 3 & 4 & 3 \end{bmatrix}.$$

Determine os seguintes determinantes:

(a) $\det(\mathbf{A})$.

(b) $\det(\mathbf{B})$.

(c) $\det(\mathbf{A}')$, em que

$$\mathbf{A}' = \begin{bmatrix} 2 & 1 & 4 & 3 \\ 1 & 2 & 1 & 1 \\ 3 & 0 & 0 & 2 \\ 4 & 3 & 2 & 5 \end{bmatrix}.$$

(d) $\det(\mathbf{C})$.

(e) $\det(\mathbf{A}'')$ em que

$$\mathbf{A}'' = \begin{bmatrix} 4 & 2 & 8 & 6 \\ 1 & 2 & 1 & 1 \\ 3 & 0 & 0 & 2 \\ 4 & 3 & 2 & 5 \end{bmatrix}.$$

(f) $\det(3\mathbf{A})$.

(g) $\det(\mathbf{A}^\top)$.

(h) $\det(\mathbf{D})$.

(i) $\det(\mathbf{DE})$.

(j) $\det(\mathbf{D}^{-1})$.

Exemplo 2.63SOLUÇÃO:

(a) Pelo teorema fundamental de Jacob,

$$\det(\mathbf{A}) = 3A_{31} + 0A_{32} + 0A_{33} + 2A_{34} = 3A_{31} + 2A_{34} = -176.$$

(b) Como os elementos da primeira coluna da matriz $\mathbf{B}$ são todos iguais a zero, segue que $\det(\mathbf{B}) = 0$.

(c) A matriz $\mathbf{A}'$ é consequência da troca da primeira com a segunda linha da matriz $\mathbf{A}$. Portanto, $\det(\mathbf{A}') = -\det(\mathbf{A}) = 176$.

(d) A primeira e a terceira coluna da matriz $\mathbf{C}$ são iguais, portanto $\det(\mathbf{C}) = 0$.

(e) A matriz $\mathbf{A}''$ é consequência da multiplicação da primeira linha da matriz $\mathbf{A}'$ por 2. Portanto, $\det(\mathbf{A}'') = 2\det(\mathbf{A}') = 252$.

(f) $\det(3\mathbf{A}) = 9\det(\mathbf{A}) = -1.584$.

(g) $\det(\mathbf{A}^\top) = \det(\mathbf{A}) = -176$.

(h) Como $\mathbf{D}$ é uma matriz triangular superior, então $\det(\mathbf{D}) = 1 \times 2 \times 3 = 6$.

(i) $\det(\mathbf{DE}) = \det(\mathbf{D})\det(\mathbf{E}) = 6 \times 6 = 36$.

(f) $\det(\mathbf{D}^{-1}) = \frac{1}{\det(\mathbf{D})} = \frac{1}{6}$.

Observação 2.3

Segue, como consequência da propriedade do determinante da inversa, que a matriz inversa $\mathbf{A}^{-1}$ de uma matriz quadrada $\mathbf{A}$ só existe se $\det(\mathbf{A}) \neq 0$.

Exemplo 2.64

Como o determinante da matriz $\mathbf{B} = \mathbf{O}_n$ é tal que $\det(\mathbf{B}) = 0$, concluímos que não existe a matriz inversa da matriz $\mathbf{B}$.

2.12 Traço

A soma dos elementos da diagonal principal de uma matriz quadrada assume um papel importante em muitas áreas da Estatística. Vamos explorar a sua importância mais adiante quando estudarmos vetores aleatórios e o método dos mínimos quadrados. Por enquanto, vamos focar na sua definição e algumas propriedades que julgamos importantes.

Definição 2.40: Traço

Sejam n um número natural não-nulo e $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$. O **traço** da matriz $\mathbf{A}$, que indicamos por $tr(\mathbf{A})$, é definido como sendo a soma dos elementos da diagonal principal da matriz $\mathbf{A}$. Em outras palavras,

$$tr(\mathbf{A}) := \sum_{i=1}^n a_{ii}.$$

Exemplo 2.65

Determine o traço de cada uma das matrizes quadradas definidas a seguir.

$$(a) \mathbf{A} = \begin{bmatrix} 1 & -9 \\ -7 & -5 \end{bmatrix}$$

$$(c) \mathbf{I}_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$(b) \mathbf{O} = \begin{bmatrix} 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

$$(d) \mathbf{B} = \begin{bmatrix} 2 & 0 & 0 \\ 3 & 4 & 0 \\ 1 & 5 & 0 \end{bmatrix}$$

SOLUÇÃO:

$$(a) \operatorname{tr}(\mathbf{A}) = 1 - 5 = -4.$$

$$(b) \operatorname{tr}(\mathbf{O}) = 0 + 0 + 0 + 0 = 0.$$

$$(c) \operatorname{tr}(\mathbf{I}_3) = 1 + 1 + 1 = 3.$$

$$(d) \operatorname{tr}(\mathbf{B}) = 2 + 4 + 0 = 6.$$

Resultado 2.19: Propriedades do traço

O traço de uma matriz quadrada dada apresenta as seguintes propriedades:

- (a) $tr(\mathbf{I}_n) = n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$.
- (b) $tr(\mathbf{A}^\top) = tr(\mathbf{A})$, qualquer que seja a matriz $\mathbf{A} \in M_n(\mathbb{R})$.
- (c) $tr(\mathbf{A} + \mathbf{B}) = tr(\mathbf{A}) + tr(\mathbf{B})$, quaisquer que sejam as matrizes $\mathbf{A}, \mathbf{B} \in M_n(\mathbb{R})$.
- (d) $tr(\alpha \mathbf{A}) = \alpha tr(\mathbf{A})$, qualquer que seja o número real α e a matriz $\mathbf{A} \in M_n(\mathbb{R})$.
- (e) $tr(\mathbf{AB}) = tr(\mathbf{BA})$, qualquer que sejam as matrizes $\mathbf{A}, \mathbf{B} \in M_n(\mathbb{R})$.

DEMONSTRAÇÃO:

- (a) Como existem n elementos na diagonal principal da matriz identidade $\mathbf{I}_n$ e eles são todos iguais a 1, segue que

$$tr(\mathbf{I}_n) = \sum_{i=1}^n a_{ii} = \sum_{i=1}^n 1 = n.$$

- (b) O elemento genérico a_{ij} que está na linha i e na coluna j da matriz $\mathbf{A}$, em que i e j são números naturais tais que $1 \leq i \leq n$ e $1 \leq j \leq n$, é tal que

$$a_{ij} = a'_{ji},$$

em que a'_{ji} é o elemento genérico que está na linha j e coluna i da matriz $\mathbf{A}^\top$. Logo, $a_{ij} = a'_{ij}$. Portanto,

$$tr(\mathbf{A}^\top) = \sum_{i=1}^n a'_{ii} = \sum_{i=1}^n a_{ii} = tr(\mathbf{A}).$$

- (c) De fato,

$$tr(\mathbf{A} + \mathbf{B}) = \sum_{i=1}^n (a_{ii} + b_{ii}) = \sum_{i=1}^n a_{ii} + \sum_{i=1}^n b_{ii} = tr(\mathbf{A}) + tr(\mathbf{B}).$$

- (d) De fato,

$$tr(\alpha \mathbf{A}) = \sum_{i=1}^n \alpha a_{ii} = \alpha \sum_{i=1}^n a_{ii} = \alpha tr(\mathbf{A}).$$

Resultado 2.19

- (e) Tome $\mathbf{C} = \mathbf{AB}$, então o elemento genérico c_{pq} que está na linha p e na coluna t da matriz $\mathbf{C}$, em que p e q são números naturais tais que $1 \leq p \leq n$ e $1 \leq q \leq n$, é tal que

$$c_{pt} = \sum_{j=1}^n a_{pj} b_{jq}.$$

Tome também $\mathbf{G} = \mathbf{BA}$, então o elemento genérico g_{rs} que está na linha r e coluna s da matriz $\mathbf{G}$, em que r e s são números naturais tais que $1 \leq r \leq n$ e $1 \leq s \leq n$, é tal que

$$g_{rs} = \sum_{i=1}^n b_{ri} a_{is}.$$

Todavia,

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{C}) = \sum_{p=1}^n c_{pp} = \sum_{p=1}^n \sum_{j=1}^n a_{pj} b_{jp}$$

e também

$$\text{tr}(\mathbf{BA}) = \text{tr}(\mathbf{G}) = \sum_{r=1}^n g_{rr} = \sum_{r=1}^n \sum_{i=1}^n b_{ri} a_{ir}.$$

Portanto,

$$\text{tr}(\mathbf{AB}) = \text{tr}(\mathbf{BA})$$

□

Exemplo 2.66

Sejam n um número natural não-nulo e $\mathbf{P}$ uma matriz quadrada de ordem $n \times n$. Dizemos que $\mathbf{P}$ é uma **matriz ortogonal** quando $\mathbf{P}$ é inversível e $\mathbf{P}^{-1} = \mathbf{P}^\top$.

- (a) Mostre que $\text{tr}(\mathbf{P}^{-1}) = \text{tr}(\mathbf{P})$.
- (b) Mostre que $\det(\mathbf{P}) = \pm 1$.
- (c) Mostre que $\text{tr}(\mathbf{P}^\top \mathbf{A} \mathbf{P}) = \text{tr}(\mathbf{A})$ qualquer que seja a matriz quadrada $\mathbf{A}$ de ordem $n \times n$.

SOLUÇÃO:

- (a) Como $\mathbf{P}$ é ortogonal, segue que $\mathbf{P}$ é inversível e $\mathbf{P}^{-1} = \mathbf{P}^\top$. Portanto,

Exemplo 2.66

$$\text{tr}(\mathbf{P}^{-1}) = \text{tr}(\mathbf{P}^\top) = \text{tr}(\mathbf{P}).$$

(b) Como $\mathbf{P}$ é ortogonal, segue que $\mathbf{P}$ é inversível e, então, $\det(\mathbf{P}) \neq 0$ e

$$\det(\mathbf{P}^{-1}) = \frac{1}{\det(\mathbf{P})}.$$

Além disso, pelo fato de $\mathbf{P}$ ser ortogonal, temos $\mathbf{P}^{-1} = \mathbf{P}^\top$. Portanto,

$$\begin{aligned} \det(\mathbf{P}^{-1}) = \frac{1}{\det(\mathbf{P})} &\Leftrightarrow \det(\mathbf{P}^\top) = \frac{1}{\det(\mathbf{P})} \\ &\Leftrightarrow \det(\mathbf{P}) = \frac{1}{\det(\mathbf{P})} \\ &\Leftrightarrow \det^2(\mathbf{P}) = 1 \\ &\Leftrightarrow \det(\mathbf{P}) = \pm 1. \end{aligned}$$

(c) De fato,

$$\begin{aligned} \text{tr}(\mathbf{P}^\top \mathbf{A} \mathbf{P}) &= \text{tr}(\mathbf{P}^{-1}(\mathbf{A} \mathbf{P})) \\ &= \text{tr}((\mathbf{A} \mathbf{P}) \mathbf{P}^{-1}) \\ &= \text{tr}(\mathbf{A} \mathbf{I}_n) \\ &= \text{tr}(\mathbf{A}). \end{aligned}$$

2.13 Aspectos geométricos de uma amostra por meio do conceito de matrizes

Quando trabalhamos com várias variáveis medidas simultaneamente nas mesmas unidades amostrais, o conjunto de dados ganha uma estrutura naturalmente matricial: cada linha representa uma unidade (indivíduo, empresa, município, paciente etc.) e cada coluna corresponde a uma variável observada. Essa forma de organizar os dados nos permite descrever a amostra usando instrumentos da álgebra linear, como vetores e matrizes, o que abre espaço para interpretações geométricas muito úteis. Nesta seção, vamos formalizar a ideia de *matriz de dados* e, a partir dela, introduzir as matrizes de variâncias e covariâncias amostrais e de correlações amostrais, que resumem, em forma

matricial, como as variáveis da amostra variam conjunta e linearmente.

Definição 2.41: Matriz de dados

Sejam n um número natural não-nulo e p um número natural não-nulo. Suponha que observamos p variáveis

$$X_1, X_2, \dots, X_p$$

em n unidades amostrais (indivíduos, objetos, localidades, etc.). Denotamos por x_{ij} a observação da variável X_j na i -ésima unidade amostral, para $i = 1, \dots, n$ e $j = 1, \dots, p$. A **matriz de dados** associada a esse conjunto de observações é a matriz

$$\mathbf{X} := \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix} \in M_{n \times p}(\mathbb{R}).$$

Assim, cada *linha* de $\mathbf{X}$ representa uma unidade amostral e cada *coluna* representa uma variável observada ao longo da amostra.

Definição 2.42: Matriz de variâncias e covariâncias amostrais

Seja $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ a matriz de dados definida acima, com elementos x_{ij} , em que $i = 1, \dots, n$ e $j = 1, \dots, p$. Para cada variável X_j , denotamos a média amostral por

$$\bar{x}_j := \frac{1}{n} \sum_{i=1}^n x_{ij}, \quad j = 1, \dots, p.$$

A **matriz de variâncias e covariâncias amostrais** associada à matriz de dados $\mathbf{X}$ é a matriz

$$\mathbf{S}_n := (s_{jk})_{p \times p},$$

em que, para $j, k = 1, \dots, p$,

$$s_{jk} := \frac{1}{n} \sum_{i=1}^n (x_{ij} - \bar{x}_j)(x_{ik} - \bar{x}_k).$$

O índice n em $\mathbf{S}_n$ destaca que estamos dividindo as variâncias e covariâncias pelo próprio tamanho amostral n , e não por $(n - 1)$.

Definição 2.43: Matriz de correlações amostrais

Nas condições da definição anterior, a **matriz de correlações amostrais** associada à matriz de dados $\mathbf{X}$ é a matriz

$$\mathbf{R} := (r_{jk})_{p \times p},$$

em que, para $j \neq k$,

$$r_{jk} := \frac{s_{jk}}{\sqrt{s_{jj}}\sqrt{s_{kk}}}$$

e, por convenção,

$$r_{jj} := 1, \quad j = 1, \dots, p.$$

Assim, r_{jk} representa a correlação linear amostral entre as variáveis X_j e X_k , enquanto $r_{jj} = 1$ indica a correlação perfeita de uma variável consigo mesma.

Observação 2.4

Das definições, segue que $s_{jk} = s_{kj}$ para todos $j, k = 1, \dots, p$, de modo que a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$ é uma **matriz simétrica**. De forma análoga, como $r_{jk} = r_{kj}$ para todos j, k , a matriz de correlações amostrais $\mathbf{R}$ também é **simétrica**. Em particular, $\mathbf{S}_n$ e $\mathbf{R}$ pertencem ao subconjunto das matrizes quadradas que já estudamos anteriormente sob o nome de matrizes simétricas.

Quando temos uma única variável, a variância amostral costuma ser usada para medir o quanto os dados observados variam em torno da média amostral. No entanto, quando p variáveis são observadas simultaneamente em uma mesma unidade amostral (ou seja, em um contexto multivariado), usamos a matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$ para descrever essa variação conjunta. Em certas situações, pode ser útil resumir toda essa variabilidade multivariada em um único número. Duas formas comuns de fazer isso envolvem o uso da *variância total amostral* e da *variância generalizada amostral*.

Definição 2.44: Variância total amostral

Seja p um número inteiro positivo e seja $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ uma matriz de dados, com matriz de variâncias e covariâncias amostrais $\mathbf{S}_n \in M_{p \times p}(\mathbb{R})$. A *variância total amostral* associada a $\mathbf{X}$ é a soma dos elementos da diagonal principal de $\mathbf{S}_n$, isto é, o

Definição 2.44

traço de $\mathbf{S}_n$:

$$tr(\mathbf{S}_n) = s_{11} + s_{22} + \cdots + s_{pp}.$$

Vale observar que a variância total amostral não leva em conta a estrutura de correlação linear entre as variáveis, ela considera apenas as variações individuais de cada uma, isto é, as variâncias amostrais $s_{11}, \dots, s_{pp}$. Apesar dessa limitação, a variância total amostral pode ser bastante útil em contextos nos quais desejamos obter uma medida geral da variabilidade do conjunto de variáveis, sem nos preocuparmos com as inter-relações entre elas. Por exemplo, ao comparar dois grupos de indivíduos em termos de variáveis como altura, peso e pressão arterial, a variância total amostral pode fornecer um resumo simples e informativo da variabilidade conjunta de cada grupo. Assim, ela é uma ferramenta prática quando o objetivo é apenas quantificar o “tamanho” da variabilidade total, e não entender em detalhe como as variáveis se relacionam entre si.

Exemplo 2.67

Considere dois grupos de pacientes, para os quais foram observadas duas variáveis: pressão sistólica (X_1 , em $mmHg$) e índice de massa corporal (X_2 , em kg/m^2). Suponha que as matrizes de variâncias e covariâncias amostrais obtidas para cada grupo sejam

$$\mathbf{S}_{(1)} = \begin{bmatrix} 100 & 10 \\ 10 & 25 \end{bmatrix} \quad \text{e} \quad \mathbf{S}_{(2)} = \begin{bmatrix} 120 & 5 \\ 5 & 30 \end{bmatrix}.$$

- (a) Determine a variância total amostral de cada grupo.
- (b) Qual grupo apresenta maior variabilidade total nas variáveis analisadas?

SOLUÇÃO:

- (a) A variância total amostral de cada grupo é dada pelo traço da respectiva matriz de variâncias e covariâncias amostrais:

$$tr(\mathbf{S}_{(1)}) = 100 + 25 = 125 \quad \text{e} \quad tr(\mathbf{S}_{(2)}) = 120 + 30 = 150.$$

- (b) Como $tr(\mathbf{S}_{(2)}) > tr(\mathbf{S}_{(1)})$, o **grupo 2 apresenta maior variabilidade total amostral** nas variáveis analisadas.

Exemplo 2.68

Considere dois grupos nos quais avaliamos duas variáveis: renda anual (X_1 , em milhares de reais) e satisfação com a qualidade de vida (X_2 , em uma escala de 1 a 10). Suponha que as matrizes de variâncias e covariâncias *amostrais* para os dois grupos sejam

$$\mathbf{S}_{(1)} = \begin{bmatrix} 400 & 12 \\ 12 & 4 \end{bmatrix} \quad \text{e} \quad \mathbf{S}_{(2)} = \begin{bmatrix} 1600 & 24 \\ 24 & 4 \end{bmatrix}.$$

- Determine a variância total amostral de cada grupo.
- Com base nos valores obtidos, qual grupo apresenta maior variabilidade total nas variáveis analisadas?
- Há alguma variável que domina a variância total amostral? Comente o impacto disso na interpretação dos resultados.

SOLUÇÃO:

- A variância total amostral de cada grupo é dada pelo traço da matriz de variâncias e covariâncias amostrais:

$$tr(\mathbf{S}_{(1)}) = 400 + 4 = 404 \quad \text{e} \quad tr(\mathbf{S}_{(2)}) = 1600 + 4 = 1604.$$

- Como $tr(\mathbf{S}_{(2)}) > tr(\mathbf{S}_{(1)})$, o **grupo 2 apresenta maior variabilidade total amostral** nas variáveis analisadas.
- Observe que a variável X_2 (satisfação) tem a mesma variância amostral nos dois grupos, mas a variável X_1 (renda) apresenta uma escala quatro vezes maior no grupo 2. Isso mostra que a **variância total amostral está sendo fortemente influenciada pela escala da renda**. Esse domínio de uma variável pode mascarar a contribuição da outra, especialmente quando usamos a variância total amostral para comparar variabilidade entre grupos. A variância total do grupo 2 é muito maior, mas isso ocorre principalmente porque a variável *renda* está em uma escala muito mais alta. Assim, a variância total tende a ser dominada pela variável de maior escala, mesmo que as variações relativas entre os grupos não sejam tão diferentes.

Quando as variáveis estão em escalas muito diferentes, como no exemplo anterior, a variância total amostral pode não representar adequadamente a variabilidade conjunta do sistema. Isso acontece porque essa medida soma as variâncias individuais, sem considerar as unidades de medida, as escalas ou as correlações entre as variáveis. Por ser simples de calcular e interpretar, a variância total amostral é útil como uma medida inicial de dispersão. No entanto, ela pode mascarar relações importantes entre os dados. Em situações que exigem uma visão mais completa da variabilidade multivariada, é preferível utilizar medidas alternativas, como a *variância generalizada amostral*, que incorpora toda a estrutura de covariância entre as variáveis.

Definição 2.45: Variância generalizada amostral

Seja p um número inteiro positivo e seja $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ uma matriz de dados, com matriz de variâncias e covariâncias amostrais $\mathbf{S}_n \in M_{p \times p}(\mathbb{R})$. A *variância generalizada amostral* associada a $\mathbf{X}$ é o determinante de $\mathbf{S}_n$, isto é,

$$|\mathbf{S}_n|.$$

Uma interpretação geométrica de $|\mathbf{S}_n|$ pode nos ajudar a apreciar seus pontos fortes e fracos como um resumo descritivo da variabilidade conjunta do sistema. Vamos construir essa intuição a partir do caso $p = 2$ e, em seguida, comentar sua extensão para o caso geral.

Sejam $\mathbf{x}_1 \in \mathbb{R}^n$ o vetor de n observações da variável X_1 e $\mathbf{x}_2 \in \mathbb{R}^n$ o vetor de n observações da variável X_2 . Considere os vetores $\mathbf{d}_1 \in \mathbb{R}^n$ e $\mathbf{d}_2 \in \mathbb{R}^n$ tais que

$$\mathbf{d}_1 := \begin{bmatrix} x_{11} - \bar{x}_1 \\ x_{21} - \bar{x}_1 \\ \vdots \\ x_{n1} - \bar{x}_1 \end{bmatrix} \quad \text{e} \quad \mathbf{d}_2 := \begin{bmatrix} x_{12} - \bar{x}_2 \\ x_{22} - \bar{x}_2 \\ \vdots \\ x_{n2} - \bar{x}_2 \end{bmatrix}.$$

O vetor $\mathbf{d}_1$ é conhecido como *vetor de desvios* da variável X_1 e $\mathbf{d}_2$ é conhecido como *vetor de desvios* da variável X_2 . Da álgebra linear em $\mathbb{R}^n$, sabemos que os tamanhos dos vetores $\mathbf{d}_1$ e $\mathbf{d}_2$ podem ser expressos pelas suas normas euclidianas, isto é,

$$\begin{aligned} \|\mathbf{d}_1\| &:= \sqrt{\sum_{j=1}^n d_{j1}^2} = \sqrt{\sum_{j=1}^n (x_{j1} - \bar{x}_1)^2}, \\ \|\mathbf{d}_2\| &:= \sqrt{\sum_{j=1}^n d_{j2}^2} = \sqrt{\sum_{j=1}^n (x_{j2} - \bar{x}_2)^2}. \end{aligned}$$

Nesse sentido, a geometria analítica nos permite construir o diagrama da Figura 2.2.




Figura 2.2. Paralelogramo formado a partir do ângulo entre os vetores de desvios $\mathbf{d}_1$ e $\mathbf{d}_2$.

Note que a área do paralelogramo é dada por

$$\begin{aligned} \text{área} &= \|\mathbf{d}_2\| h \\ &= \|\mathbf{d}_2\| \|\mathbf{d}_1\| \sin(\theta) \\ &= \|\mathbf{d}_1\| \|\mathbf{d}_2\| \sqrt{1 - \cos^2(\theta)}, \end{aligned}$$

em que a última igualdade decorre da identidade trigonométrica $\sin^2(\theta) + \cos^2(\theta) = 1$.

A correlação amostral entre X_1 e X_2 pode ser escrita da seguinte maneira:

$$\begin{aligned} r_{12} &:= \frac{s_{12}}{\sqrt{s_{11}} \sqrt{s_{22}}} \\ &= \frac{\sum_{j=1}^n (x_{j1} - \bar{x}_1)(x_{j2} - \bar{x}_2)}{\sqrt{\sum_{j=1}^n (x_{j1} - \bar{x}_1)^2} \sqrt{\sum_{j=1}^n (x_{j2} - \bar{x}_2)^2}} \\ &= \frac{\sum_{j=1}^n d_{j1} d_{j2}}{\sqrt{\sum_{j=1}^n d_{j1}^2} \sqrt{\sum_{j=1}^n d_{j2}^2}} \\ &\stackrel{(i)}{=} \frac{\mathbf{d}_1^\top \mathbf{d}_2}{\|\mathbf{d}_1\| \|\mathbf{d}_2\|} \\ &\stackrel{(ii)}{=} \frac{\langle \mathbf{d}_1, \mathbf{d}_2 \rangle}{\|\mathbf{d}_1\| \|\mathbf{d}_2\|} \\ &\stackrel{(iii)}{:=} \cos(\theta), \end{aligned}$$

em que (i) segue da definição da norma euclidiana, (ii) segue da definição do produto interno induzido pela norma euclidiana e (iii) da definição do cosseno do ângulo entre dois vetores. Dessa forma, podemos reescrever a covariância amostral em termos do produto interno dos desvios e as variâncias amostrais em termos das normas dos desvios:

$$\begin{aligned}
s_{12} &:= \frac{1}{n} \sum_{j=1}^n (x_{j1} - \bar{x}_1)(x_{j2} - \bar{x}_2) = \frac{1}{n} \sum_{j=1}^n d_{j1}d_{j2} = \frac{1}{n} \mathbf{d}_1^\top \mathbf{d}_2 = \frac{1}{n} \langle \mathbf{d}_1, \mathbf{d}_2 \rangle, \\
s_{11} &:= \frac{1}{n} \sum_{j=1}^n (x_{j1} - \bar{x}_1)^2 = \frac{1}{n} \sum_{j=1}^n d_{j1}^2 = \frac{1}{n} \|\mathbf{d}_1\|^2, \\
s_{22} &:= \frac{1}{n} \sum_{j=1}^n (x_{j2} - \bar{x}_2)^2 = \frac{1}{n} \sum_{j=1}^n d_{j2}^2 = \frac{1}{n} \|\mathbf{d}_2\|^2.
\end{aligned}$$

Portanto,

$$\begin{aligned}
\text{área} &= \|\mathbf{d}_1\| \|\mathbf{d}_2\| \sqrt{1 - r_{12}^2} \\
&= \sqrt{ns_{11}} \sqrt{ns_{22}} \sqrt{1 - r_{12}^2} \\
&= n \sqrt{s_{11}s_{22}(1 - r_{12}^2)}.
\end{aligned} \tag{2.1}$$

Por outro lado, o determinante $|\mathbf{S}_n|$ da matriz de variâncias e covariâncias amostrais, no caso $p = 2$, pode ser escrito como

$$\begin{aligned}
|\mathbf{S}_n| &= \begin{vmatrix} s_{11} & s_{12} \\ s_{21} & s_{22} \end{vmatrix} \\
&= s_{11}s_{22} - s_{12}s_{21} \\
&= s_{11}s_{22} - s_{12}^2. \\
&= s_{11}s_{22} - s_{11}s_{22} \frac{s_{12}^2}{s_{11}s_{22}} \\
&= s_{11}s_{22} - s_{11}s_{22}r_{12}^2 \\
&= s_{11}s_{22}(1 - r_{12}^2).
\end{aligned} \tag{2.2}$$

Da igualdade (2.1) combinada com a igualdade (2.2), concluímos que a variância generalizada amostral $|\mathbf{S}_n|$ pode ser escrita como

$$|\mathbf{S}_n| = \frac{\text{área}^2}{n^2}.$$

Essa interpretação geométrica pode ser generalizada para espaços de dimensão maior, com p variáveis e, conseqüentemente, p vetores de desvios (ver p. 63 de Johnson e Wichern, 2014). Nesse caso, a variância generalizada amostral está relacionada ao volume do para-

lelepípedo (ou hipercubo) gerado pelos vetores de desvios:

$$|\mathbf{S}_n| = \frac{\text{volume}^2}{n^{-(p+1)}}.$$




Figura 2.3. (a) Variância generalizada amostral “grande” para $p = 3$ e (b) Variância generalizada amostral “pequena” para $p = 3$.

Para um tamanho de amostra fixo, fica claro pela geometria que o volume, ou $|\mathbf{S}_n|$, aumentará quando o comprimento de qualquer vetor de desvios $\mathbf{d}_i$ (ou, equivalentemente, a variância amostral s_{ii}) for aumentado. Além disso, o volume aumentará se os vetores de desvio de comprimento fixo forem movidos até que fiquem ortogonais entre si, como na Figura 3.6 (a). Por outro lado, o volume, ou $|\mathbf{S}_n|$, será pequeno se apenas um dos vetores de desvios $\mathbf{d}_i$ (ou, equivalentemente, a variância amostral s_{ii}) for pequeno ou se um dos vetores de desvios estiver quase contido no hiperplano formado pelos outros vetores - ou ambos. Essa é a situação mostrada na Figura 3.6 (b), em que $\mathbf{d}_3$ está quase contido no plano formado por $\mathbf{d}_1$ e $\mathbf{d}_2$.

A variância generalizada amostral é uma medida de variabilidade que considera não só a dispersão individual de cada variável, mas também sua independência (ou falta de correlação) em relação às outras, penalizando a redundância entre variáveis; isto é, quanto mais correlacionadas as variáveis, menor tende a ser a variância generalizada amostral. Portanto, ela é especialmente útil para detectar se a variabilidade está de fato “espalhada” em várias direções do espaço multivariado, ou se está concentrada em um subespaço de menor dimensão.

Exemplo 2.69

Uma escola está avaliando o desempenho dos alunos em duas provas muito parecidas. Ambas medem habilidades similares e foram aplicadas na mesma semana. Após a aplicação, foi calculada a seguinte matriz de variâncias e covariâncias *amostrais*:

$$\mathbf{S}_n = \begin{bmatrix} 9 & 8,9 \\ 8,9 & 9 \end{bmatrix}.$$

- (a) Determine a variância total amostral.
- (b) Determine a variância generalizada amostral.
- (c) Compare os valores obtidos nos itens (a) e (b). O que essa comparação revela sobre as desvantagens do uso da variância total como medida para resumir a variabilidade conjunta do sistema e sobre como a variância generalizada amostral supera tais desvantagens?

SOLUÇÃO:

- (a) A variância total amostral é dada pelo traço da matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$, ou seja, pela soma das variâncias individuais: $tr(\mathbf{S}_n) = s_{11} + s_{22} = 9 + 9 = 18$.
- (b) A variância generalizada amostral é dada pelo determinante de $\mathbf{S}_n$, isto é,

$$|\mathbf{S}_n| = \begin{vmatrix} 9 & 8,9 \\ 8,9 & 9 \end{vmatrix} = (9 \times 9) - (8,9 \times 8,9) = 81 - 79,21 = 1,79.$$

- (c) A variância total amostral é maior do que a variância generalizada amostral ($tr(\mathbf{S}_n) = 18 > 1,79 = |\mathbf{S}_n|$). A variância total sugere que há bastante variação nas notas, mas não diz se essa variação é realmente ?diversa? em termos de direções no plano (prova 1, prova 2). A variância generalizada amostral mostra que, apesar disso, as duas variáveis praticamente carregam a mesma informação. De fato,

$$r_{12} = \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}} = \frac{8,9}{9} \approx 0,99,$$


uma correlação quase igual a 1. Os alunos que foram bem na primeira prova também foram bem na segunda prova, quase perfeitamente. Assim, a variância

Exemplo 2.69

total “infla” a percepção de variabilidade por somar duas variâncias muito parecidas, enquanto a variância generalizada amostral enxerga que o padrão é quase unidimensional.

Exemplo 2.70: (Johnson e Wichern, 2014, p. 64, tradução e grifo nosso)

Considere uma população finita particionada em três grupos, nos quais um vetor de observações bidimensional (X_1, X_2) foi registrado. Os gráficos de dispersão em cada um dos grupos foram construídos na figura



Em todos os grupos, o vetor de médias amostrais é

$$\bar{\mathbf{x}} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}$$

Exemplo 2.70

e as matrizes de variâncias e covariâncias *amostrais* são

$$\mathbf{S}_{(1)} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{S}_{(2)} = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix} \quad \text{e} \quad \mathbf{S}_{(3)} = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}.$$

- Determine a correlação amostral r_{12} entre as variáveis X_1 e X_2 em cada um dos grupos.
- Determine a variância generalizada amostral em cada um dos grupos.
- Compare os valores obtidos nos itens (a) e (b). O que essa comparação revela sobre as limitações do uso da variância generalizada amostral como medida para resumir a variabilidade conjunta do sistema?

SOLUÇÃO:

- A correlação amostral r_{12} entre as variáveis X_1 e X_2 é definida como

$$r_{12} := \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}}.$$

Assim, usando a matriz de variâncias e covariâncias amostrais de cada grupo, temos

- Grupo 1:** $r_{12} = \frac{4}{5} = 0,8$.
- Grupo 2:** $r_{12} = 0$.
- Grupo 3:** $r_{12} = -\frac{4}{5} = -0,8$.

- A variância generalizada amostral é o determinante da matriz de variâncias e covariâncias amostrais. Logo, para cada grupo, temos

- Grupo 1:** $|\mathbf{S}_{(1)}| = (5 \times 5) - (4 \times 4) = 25 - 16 = 9$.
- Grupo 2:** $|\mathbf{S}_{(2)}| = (3 \times 3) - (0 \times 0) = 9 - 0 = 9$.
- Grupo 3:** $|\mathbf{S}_{(3)}| = (5 \times 5) - [(-4) \times (-4)] = 25 - 16 = 9$.

- Aqui a variância generalizada amostral $|\mathbf{S}_{(g)}|$ fornece o mesmo valor, 9, para todos os três grupos. No entanto, os padrões de dispersão são claramente diferentes: um com correlação positiva forte, outro sem correlação e outro com correlação negativa forte.

Exemplo 2.70

Isso mostra que a variância generalizada amostral não contém informação sobre a *orientação* dos padrões; ela é mais fácil de interpretar quando as populações (ou grupos) que estão sendo comparadas possuem orientações aproximadamente iguais. Imagine duas variáveis X_1 e X_2 , em que todas as observações obedecem exatamente $X_2 = 2X_1$.

- (a) Se desejássemos construir um gráfico de dispersão, os pontos observacionais estariam espalhados pelo plano $\mathbb{R}^2$ ou haveria um padrão evidente? Comente.
- (b) Mostre que a variância generalizada amostral é igual a zero.
- (c) O valor obtido no item (b) é compatível com sua resposta no item (a)? Por quê?

SOLUÇÃO:

- (a) Nesse caso, os pontos estariam todos dispostos sobre a reta $y = 2x$ (construa esse gráfico por si só). Portanto, não há "nuvem" de pontos espalhada em duas direções independentes; todo o padrão é essencialmente unidimensional.
- (b) A variância generalizada amostral é o determinante da matriz de variâncias e covariâncias amostrais $\mathbf{S}_n$. Denotando por s_{11} a variância amostral de X_1 e por s_{22} a variância amostral de X_2 , temos, como $X_2 = 2X_1$ para todas as observações,

$$s_{22} = \text{Var}_n(X_2) = \text{Var}_n(2X_1) = 4 \text{Var}_n(X_1) = 4s_{11}.$$

As variáveis X_1 e X_2 possuem uma relação linear perfeita e, dessa forma, $r_{12} = 1$ ou $r_{12} = -1$; aqui, como a relação é $X_2 = 2X_1$, temos $r_{12} = 1$. Logo,

$$r_{12} = 1 \Rightarrow \frac{s_{12}}{\sqrt{s_{11}}\sqrt{s_{22}}} = 1 \Rightarrow s_{12} = \sqrt{s_{11}}\sqrt{4s_{11}} = 2s_{11}.$$

Portanto,

$$\mathbf{S}_n = \begin{bmatrix} s_{11} & 2s_{11} \\ 2s_{11} & 4s_{11} \end{bmatrix},$$

e, conseqüentemente,

$$|\mathbf{S}_n| = (s_{11})(4s_{11}) - (2s_{11})(2s_{11}) = 4s_{11}^2 - 4s_{11}^2 = 0.$$

Exemplo 2.70

- (c) Como $|\mathbf{S}_n| = 0$, o paralelogramo formado pelos vetores de desvio $\mathbf{d}_1$ e $\mathbf{d}_2$, associados respectivamente às variáveis X_1 e X_2 , tem área igual a zero. Isso só é possível quando o ângulo entre os vetores é 0° ou 180° , ou seja, quando estão perfeitamente alinhados. Nesses casos, o cosseno do ângulo, que corresponde à correlação entre as variáveis, é igual a 1 ou -1 . Em outras palavras, X_1 e X_2 apresentam uma relação linear perfeita, exatamente como no item (a), onde foi dado que $X_2 = 2X_1$. Assim, a variância generalizada amostral igual a zero é totalmente compatível com o fato de os pontos do diagrama de dispersão estarem todos sobre uma única reta.

A variância generalizada amostral será zero em certas situações. Uma variância generalizada igual a zero é indicativo de uma degeneração extrema. Em Estatística Multivariada (e em Álgebra Linear), degeneração refere-se a situações em que os dados perdem dimensionalidade efetiva, ou seja, “vivem” em um espaço de dimensão menor do que o esperado. Portanto, quando dizemos que há uma degeneração extrema e que a variância generalizada amostral é zero, isso quer dizer que os vetores de desvios (ou seja, os vetores que representam as diferenças entre as observações e a média amostral) estão todos alinhados em um subespaço de dimensão menor. Na prática, em vez de se espalharem em várias direções no espaço (por exemplo, plano ou espaço tridimensional), todos os vetores ficam contidos, por exemplo, numa linha reta ou num plano. Isso implica que uma ou mais variáveis são combinações lineares das outras, ou seja, há colinearidade perfeita.

A variância generalizada amostral também é excessivamente afetada pela variabilidade das medições em uma única variável. Por exemplo, suponha que alguma variância amostral s_{ii} seja muito grande ou muito pequena. Então, geometricamente, o vetor de desvios correspondente será muito longo ou muito curto e, portanto, será claramente um fator importante na determinação do volume. Consequentemente, às vezes é útil padronizar todos os vetores de desvio para que tenham o mesmo comprimento. Isso nos leva à *matriz de correlações amostrais* $\mathbf{R}$ e, consequentemente, à variância generalizada das variáveis padronizadas, isto é, ao determinante de $\mathbf{R}$.

Tabela 2.1. Comparação entre variância total amostral e variância generalizada amostral como medidas de variabilidade conjunta.

Aspecto	Variância Total Amostral	Variância Generalizada Amostral
Definição curta	Traço da matriz de variâncias e covariâncias amostrais	Determinante da matriz de variâncias e covariâncias amostrais
Desvantagens	Sensível à escala; não considera relações entre variáveis	Sensível à escala; pode ser zero com variâncias marginais positivas; não capta a orientação (sinal das associações)
Utilidade	Comparar variabilidade marginal média entre grupos (na mesma escala)	Comparar variabilidade conjunta total entre grupos, considerando dependências lineares
Interpretação	Soma das variâncias amostrais individuais; mede a variabilidade total marginal	Volume (ao quadrado, após normalização por n) do paralelepípedo formado pelos vetores de desvio
Situação ideal de uso	Quando se deseja comparar a variabilidade individual entre variáveis em mesma escala e com associações fracas	Quando se deseja comparar grupos em termos da variabilidade conjunta, levando em conta dependências entre variáveis e assumindo orientação aproximadamente semelhante dos padrões

2.14 Exercícios

1. Quais das seguintes aplicações de $\mathcal{L}(\mathbb{R}^3, \mathbb{R}^3)$ são operadores lineares? Apresente uma justificativa sem provar pela definição. Determine a matriz associada em relação às bases canônicas quando a aplicação for linear.

$$(a) \quad F \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} x - y \\ x + y \\ 0 \end{bmatrix}.$$

$$(c) \quad H \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} x \\ x \\ x \end{bmatrix}.$$

$$(b) \quad G \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} 2x - y + z \\ 0 \\ 0 \end{bmatrix}.$$

$$(d) \quad T \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} 2x^2 + 3y \\ x \\ z \end{bmatrix}.$$

2. Para cada matriz definida a seguir, especifique sua ordem, classifique-a e indique qual é a transformação linear associada em relação às bases canônicas.

$$(a) \quad \mathbf{A} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

$$(c) \quad \mathbf{C} = \begin{bmatrix} 2 & 1 & -1 & 3 \end{bmatrix}.$$

$$(b) \quad \mathbf{B} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \\ 1 & -1 \end{bmatrix}.$$

$$(d) \quad \mathbf{D} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

3. Uma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é dita ser **injetora** quando para qualquer $\mathbf{u} \in \mathbb{R}^p$ e qualquer $\mathbf{v} \in \mathbb{R}^p$

$$F(\mathbf{u}) = F(\mathbf{v}) \Rightarrow \mathbf{u} = \mathbf{v}.$$

- (a) Verifique que o operador linear $F : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ tal que

$$F \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} x \\ -y \end{bmatrix}$$

é injetor.

- (b) Determine a matriz $\mathbf{A}$ associada à transformação F definida no item (a) e verifique que suas colunas são linearmente independentes.
- (c) Verifique que a transformação linear $G : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ tal que

$$G \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} 0 \\ x + y \\ 0 \end{bmatrix}$$

não é injetora.

(d) Determine a matriz $\mathbf{B}$ associada à transformação G definida no item (c) e verifique que suas colunas são linearmente dependentes.

(e) A seguinte afirmação é verdadeira:

*“ $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é uma transformação linear **injetora** se, e somente se, as colunas da sua matriz $\mathbf{A}$ associada em relação às bases canônicas são **linearmente independentes**”.*

Dê dois exemplos que ilustrem essa afirmação. Um exemplo com F injetora (verifique que as colunas da matriz associada são L.I.) e outro com F não sendo injetora (verifique que as colunas da matriz associada são L.D.).

4. Uma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é dita ser **sobrejetora** quando $\text{Im}(F) = \mathbb{R}^n$, ou seja, para $\mathbf{v} \in \mathbb{R}^n$, existe $\mathbf{u} \in \mathbb{R}^p$ tal que $F(\mathbf{u}) = \mathbf{v}$.

(a) Verifique que a transformação linear $F : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ tal que

$$F \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} x \\ y \end{bmatrix}$$

é sobrejetora.

(b) Determine a matriz $\mathbf{A}$ associada à transformação F definida no item (a) e verifique que exatamente $n = 2$ colunas linearmente independentes.

(c) Verifique que **não** é sobrejetora a transformação linear $G \in \mathcal{L}(\mathbb{R}^3, \mathbb{R}^2)$ cuja matriz associada em relação às bases canônicas é uma matriz de uns.

(d) Quantas são as colunas linearmente independentes da matriz associada à transformação G definida no item (c)?

(e) A seguinte afirmação é verdadeira:

*“ $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ é uma transformação linear **sobrejetora** se, e somente se, a sua matriz $\mathbf{A}$ associada em relação às bases canônicas possui **exatamente** n colunas **linearmente independentes**”.*

Dê dois exemplos que ilustrem essa afirmação. Um exemplo com F sobrejetora (verifique que o número de colunas da matriz associada que são L.I. é n) e outro

com F não sendo sobrejetora (verifique que o número de colunas da matriz associada que são L.I. não é n).

- (f) De acordo com o resultado enunciado no item (e) é possível que exista alguma transformação linear $F : \mathbb{R}^p \rightarrow \mathbb{R}^n$ sobrejetora quando $p < n$? Por quê?
5. (a) Dê um exemplo de uma transformação linear F que seja **bijetora**, i.e., F é injetora e sobrejetora. Determine a matriz associada em relação às bases canônicas.
- (b) Mostre que para que F seja **bijetora** ela deve ser um **operador linear**. *Dica:* Use as propriedades das matrizes associadas descritas nos itens (e) dos Exercícios 3 e 4.
6. (a) Considere as transformações lineares $F : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ e $G : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ tais que

$$F \left(\begin{bmatrix} x \\ y \\ z \end{bmatrix} \right) = \begin{bmatrix} x+y \\ z \end{bmatrix} \text{ e } G \left(\begin{bmatrix} x \\ y \end{bmatrix} \right) = \begin{bmatrix} x \\ y \\ x+y \end{bmatrix}.$$

Verifique se $F \circ G$ e $G \circ F$ estão bem definidas. Quando estiver bem definida a transformação composta, determine seu domínio, contradomínio e lei. Para encontrar a lei da transformação composta, você deve utilizar o **produto das matrizes** $\mathbf{A}$ da transformação F e $\mathbf{B}$ da transformação G . Especifique as ordens das matrizes envolvidas.

- (b) Considere as matrizes

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & 1 \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} 1 & 0 & 1 \\ 0 & -1 & 0 \\ 1 & 0 & -1 \end{bmatrix}.$$

Verifique se $\mathbf{AB}$ e $\mathbf{BA}$ estão bem definidos. Quando estiver bem definida, determine a matriz resultante do produto. Em seguida, determine o domínio, o contradomínio e a lei da transformação composta associada a essa matriz resultante.

- (c) Por que o produto de uma matriz quadrada $\mathbf{A}$ de ordem p com uma matriz quadrada $\mathbf{B}$ de ordem p sempre está bem definido? Justifique utilizando argumentos relativos à composição da transformação linear F associada à matriz $\mathbf{A}$ com a transformação linear G associada à matriz $\mathbf{B}$.
- (d) Dê um exemplo de duas transformações lineares F e G tais que $F \circ G = G \circ F$.

7. Considere as matrizes abaixo e responda às questões para cada uma delas:

- (a) Determine a dimensão do espaço coluna da matriz.
- (b) Especifique o domínio, contradomínio e lei da transformação linear associada à matriz.
- (c) Determine a dimensão da imagem da transformação linear associada à matriz.
- (d) Determine a dimensão do núcleo da transformação linear associada à matriz.
- (e) Determine o posto da matriz.
- (f) Classifique a transformação linear associada à matriz como **injetora**, **sobrejetora**, **bijetora** ou **nem injetora nem sobrejetora**.

As matrizes são:

$$(i) \mathbf{A} = \begin{bmatrix} 1 & 2 \\ 0 & 1 \\ 0 & 0 \end{bmatrix},$$

$$(iii) \mathbf{C} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix},$$

$$(v) \mathbf{E} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix},$$

$$(ii) \mathbf{B} = \begin{bmatrix} 1 & 0 & 2 \\ 0 & 1 & 1 \end{bmatrix},$$

$$(iv) \mathbf{D} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 0 \end{bmatrix},$$

$$(vi) \mathbf{F} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \\ 5 & 6 \end{bmatrix}.$$

8. (a) Se $\mathbf{A} \in M_{n \times p}(\mathbb{R})$, qual a relação de ordem existente entre n e p quando a transformação linear associada à matriz $\mathbf{A}$ é **injetora**? Dê um exemplo.
- (b) Se $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ e a transformação linear associada à matriz $\mathbf{A}$ é **sobrejetora**, por que não podemos ter $n > p$?
- (c) Por que apenas matrizes quadradas podem estar associadas a transformações lineares **bijetoras**?

9. Considere os seguintes sistemas lineares $\mathbf{A}\mathbf{x} = \mathbf{b}$. Faça o que se pede:

- (a) Escalone o sistema linear.
- (b) Classifique o sistema linear em impossível, possível determinado e possível indeterminado.
- (c) Determine a matriz $\mathbf{A}'$ escalonada a partir de $\mathbf{A}$.
- (d) Determine o posto de $\mathbf{A}$ e de $\mathbf{A}'$.

Os sistemas lineares são:

$$\begin{array}{ll}
 (i) \begin{cases} 2x_1 + 4x_2 - x_3 = 5, \\ x_1 + 2x_2 + 3x_3 = 6, \\ 4x_1 + 8x_2 + 2x_3 = 11. \end{cases} & (iii) \begin{cases} x_1 + 2x_2 + 3x_3 = 6, \\ 2x_1 + 4x_2 + 5x_3 = 10, \\ 3x_1 + 6x_2 + 7x_3 = 14. \end{cases} \\
 (ii) \begin{cases} x_1 + x_2 + x_3 = 6, \\ 2x_1 + 3x_2 + 5x_3 = 10, \\ 3x_1 + 4x_2 + 6x_3 = 12. \end{cases} & (iv) \begin{cases} x_1 + x_2 + x_3 = 6, \\ 2x_1 + 2x_2 + 2x_3 = 8, \\ 3x_1 + 3x_2 + 3x_3 = 12. \end{cases}
 \end{array}$$

10. As seguintes afirmações são verdadeiras:

- **Afirmção 1:** Se $\mathbf{A} \in M_{n \times m}(\mathbb{R})$ e $\mathbf{B} \in M_{m \times p}(\mathbb{R})$, então $r(\mathbf{AB}) \leq \min\{r(\mathbf{A}), r(\mathbf{B})\}$.
- **Afirmção 2:** Se $\mathbf{A} \in M_{n \times m}(\mathbb{R})$ e $\mathbf{B} \in M_{m \times p}(\mathbb{R})$, então $r(\mathbf{AB}) \leq r(\mathbf{A}) + r(\mathbf{B})$.
- **Afirmção 3:** Se $\mathbf{A} \in M_{n \times m}(\mathbb{R})$ com $r(\mathbf{A}) = m$ e $\mathbf{B} \in M_{m \times p}(\mathbb{R})$ com $r(\mathbf{B}) = m$, então $r(\mathbf{AB}) = m$.

Em cada item a seguir verifique-as.

$$\begin{array}{ll}
 (a) \mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 0 & 1 \\ 2 & 1 & 0 \end{bmatrix}. \\
 (b) \mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 1 & 2 & 3 & 4 \\ 1 & 2 & 3 & 4 \end{bmatrix}. \\
 (c) \mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \\ 10 & 11 & 12 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 1 & 1 & 1 & 1 & 1 \\ 2 & 2 & 2 & 2 & 2 \\ 3 & 3 & 3 & 3 & 3 \end{bmatrix}.
 \end{array}$$

11. Mostre que

- (a) $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ com $r(\mathbf{A}) = 0$ se, e somente se, $\mathbf{A} = \mathbf{O}$.
- (b) $r(\mathbf{I}_n) = n$.
- (c) $r(\lambda \mathbf{A}) = r(\mathbf{A})$ qualquer que seja $\mathbf{A} \in M_{n \times p}(\mathbb{R})$ e $\lambda \in \mathbb{R}^*$.
- (d) O posto de uma matriz diagonal é igual ao número de elementos não-nulos que sua diagonal possui.
- (e) Se F é a transformação linear associada a uma matriz $\mathbf{A} \in M_{n \times m}(\mathbb{R})$, G é uma transformação linear associada a uma matriz $\mathbf{A} \in M_{m \times p}(\mathbb{R})$ e H é a transformação linear associada a matriz $\mathbf{AB}$, então $\text{Ker}(G) \subset \text{Ker}(H)$.

13. (a) Determine todas as matrizes $\mathbf{X} \in M_2(\mathbb{R})$ que comutam com a matriz $\mathbf{B} = \begin{bmatrix} 1 & 1 \\ 0 & 0 \end{bmatrix}$.
- (b) Determine todas as matrizes $\mathbf{X} \in M_3(\mathbb{R})$ que comutam com a matriz $\mathbf{C} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$.
- (c) Determine uma matriz $\mathbf{X} \in M_2(\mathbb{R})$ não-nula que satisfaz $\mathbf{X}^2 = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem 2×2 e $\mathbf{X}^2 = \mathbf{X}\mathbf{X}$, i.e., $\mathbf{X}^2$ é a matriz quadrada de ordem 2×2 obtida a partir do produto da matriz $\mathbf{X}$ por ela mesma.

Exemplo. As matrizes $\mathbf{X} \in M_2(\mathbb{R})$ que comutam com a matriz $\mathbf{A} = \begin{bmatrix} 1 & -1 \\ 3 & 0 \end{bmatrix}$ são aquelas tais que $\mathbf{X}\mathbf{A} = \mathbf{A}\mathbf{X}$. Escreva

$$\mathbf{X} = \begin{bmatrix} a & b \\ c & d \end{bmatrix}.$$

Logo,

$$\mathbf{X}\mathbf{A} = \mathbf{A}\mathbf{X} \Leftrightarrow \begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 3 & 0 \end{bmatrix} = \begin{bmatrix} 1 & -1 \\ 3 & 0 \end{bmatrix} \begin{bmatrix} a & b \\ c & d \end{bmatrix} \Leftrightarrow \begin{cases} c = -3b, \\ d = a + b. \end{cases}$$

Portanto, todas as matrizes $\mathbf{X}$ que comutam com $\mathbf{A}$ são da forma

$$\mathbf{X} = \begin{bmatrix} a & b \\ -3b & a + b \end{bmatrix},$$

em que $a, b \in \mathbb{R}$.

14. Diga quais das afirmações a seguir são verdadeiras e quais são falsas. Caso ela seja verdadeira, prove a veracidade da afirmação e, no caso em que a afirmação for falsa, exiba um contra-exemplo (um exemplo que conteste a afirmação).
- (a) O produto de duas matrizes simétricas de ordem $n \times n$ é também uma matriz simétrica.
- (b) O produto de duas matrizes anti-simétrica de ordem $n \times n$ é também uma matriz anti-simétrica.

- (c) Se $\mathbf{A}$ e $\mathbf{B}$ são matrizes quadradas de ordem $n \times n$ são tais que $\mathbf{AB} = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times n$, então $\mathbf{BA} = \mathbf{O}$.
- (d) Se todos os elementos de uma linha (ou coluna) de uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$ são iguais a zero, então a matriz $\mathbf{A}$ não é inversível.
- (e) Existe uma matriz quadrada $\mathbf{A}$ inversível de ordem $n \times n$ tal que $\mathbf{A}^2 = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem $n \times n$.
15. As matrizes definidas a seguir são inversíveis. Escreva um código em R, em que você cria cada uma destas matrizes e calcula a sua respectiva matriz inversa. Explícite a matriz inversa calculada.

$$(a) \mathbf{A} = \begin{bmatrix} 2 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$(b) \mathbf{B} = \begin{bmatrix} 1 & 2 & 1 \\ 0 & 1 & 2 \\ 1 & 3 & 4 \end{bmatrix}.$$

$$(c) \mathbf{C} = \begin{bmatrix} 1 & 1 & -1 \\ 2 & 1 & 1 \\ 3 & -1 & 1 \end{bmatrix}.$$

16. Determine algebricamente o posto das seguintes matrizes.

$$(a) \mathbf{A} = \begin{bmatrix} 1 & 1 & 0 & -1 \\ 1 & 0 & -1 & 1 \\ 0 & 1 & 1 & -1 \\ 1 & 1 & 0 & -2 \end{bmatrix}.$$

$$(b) \mathbf{B} = \begin{bmatrix} 1 & 3 & 2 \\ 3 & 8 & 9 \\ 1 & 2 & 5 \end{bmatrix}.$$

17. Sejam $\mathbf{A} \in M_n(\mathbb{R})$ e $\mathbf{B} \in M_n(\mathbb{R})$ matrizes simétricas e inversíveis. Mostre que a matriz $\mathbf{X} \in M_n(\mathbb{R})$ tal que

$$(\mathbf{AB})^\top \mathbf{X} (\mathbf{BA})^{-1} = \det(2\mathbf{I}_n) \mathbf{I}_n$$

é a matriz $\mathbf{X} = 2^n \mathbf{I}_n$.

18. Determine, se existir, o número real x tal que

$$(a) \begin{vmatrix} 1 & x & x \\ 2 & 2x & 1 \\ 3 & x+1 & 1 \end{vmatrix} = 0.$$

$$(b) \begin{vmatrix} 1 & x & 2 \\ -2 & x & -4 \\ 1 & -3 & -x \end{vmatrix} = 0.$$

$$(c) \begin{vmatrix} 1 & 1 & 1 & 1 \\ x & 1 & 2 & 3 \\ x^2 & 1 & 4 & 9 \\ x^3 & 1 & 8 & 27 \end{vmatrix} = 0.$$

19. Diga quais das afirmações a seguir são verdadeiras e quais são falsas. Caso ela seja verdadeira, prove a veracidade da afirmação e, no caso em que a afirmação for falsa, exiba um contra-exemplo (um exemplo que conteste a afirmação).

(a) Se $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$, então $\text{tr}(\alpha \mathbf{I}_n) = \alpha n$.

(b) Se $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{AB}$ são matrizes triangulares de ordem $n \times n$, então

$$\det(\mathbf{AB}) = \prod_{i=1}^n a_{ii}b_{ii},$$

em que a_{ii} e b_{ii} são, respectivamente, os elementos genéricos das matrizes $\mathbf{A}$ e $\mathbf{B}$ que estão na linha i e coluna i dessas matrizes, em que i é um número natural não-nulo tal que $1 \leq i \leq n$.

(c) Se $\mathbf{A}$ é uma matriz quadrada de ordem $n \times n$ tal que $\text{tr}(\mathbf{A}) = 0$, então existe $\alpha \in \mathbb{R}$ tal que $\mathbf{A}^2 = \alpha \mathbf{I}_n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$.

20. Considere a matriz $\mathbf{A}$ de ordem 4×4 tal que

$$\mathbf{A} = \begin{bmatrix} x & 1 & 2 & 0 \\ 0 & x & 1 & 1 \\ 0 & 0 & x & 1 \\ 0 & 0 & 0 & x \end{bmatrix},$$

em que x é um número real qualquer.

(a) Determine o menor complementar $\mathbf{D}_{31}$ e o cofator $\mathbf{A}_{31}$ do elemento genérico a_{31} da matriz $\mathbf{A}$.

(b) Determine o menor complementar $\mathbf{D}_{41}$ e o cofator $\mathbf{A}_{41}$ do elemento genérico a_{41} da matriz $\mathbf{A}$.

(c) Determine os valores reais de x para os quais $\det^2(\mathbf{A}) - 2\det(\mathbf{A}) + 1 = 0$.

21. (a) Calcule o determinante da matriz quadrada $\mathbf{A}$ de ordem 5×5 sabendo que $\det(\mathbf{A}) \neq 0$ e $3\mathbf{A}^2 - \mathbf{A} = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem 5×5 .

- (b) Sejam $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ matrizes quadradas de ordem 3×3 tais que $\mathbf{AB} = \mathbf{C}^{-1}$ e $\mathbf{B} = 2\mathbf{A}$. Se $\det(\mathbf{C}) = 32$, calcule o determinante da matriz $\mathbf{A}$. Explícite as saídas do R.
- (c) Calcule o determinante da matriz quadrada $\mathbf{A}$ de ordem 4×4 sabendo que $\det(\mathbf{A}) \neq 0$ e $\mathbf{A}^3 + 2\mathbf{A}^2 = \mathbf{O}$, em que $\mathbf{O}$ é a matriz nula de ordem 4×4 .
- (d) Sejam $\mathbf{A}$, $\mathbf{B}$ e $\mathbf{C}$ matrizes quadradas de ordem 2×2 tais que $\mathbf{AB}^{-1} = \mathbf{C}^{-1}$ e $\mathbf{B} = 3\mathbf{A}^2$. Se $\det(\mathbf{C}) = 9$, calcule o determinante da matriz $\mathbf{A}$.
22. Seja n um número inteiro positivo e $\mathbf{P}$ uma **matriz ortogonal** de ordem $n \times n$, isto é, uma matriz inversível tal que

$$\mathbf{P}^\top \mathbf{P} = \mathbf{I}_n \quad \text{ou, equivalentemente,} \quad \mathbf{P}^{-1} = \mathbf{P}^\top.$$

- (a) Mostre que

$$\mathbf{P}\mathbf{x} = \mathbf{0} \Rightarrow \mathbf{x} = \mathbf{0},$$

em que $\mathbf{0}$ é o vetor nulo de ordem $n \times 1$.

- (b) Mostre que se p_{ij} é o elemento genérico que está na linha i e na coluna j da matriz $\mathbf{P}$, $i, j = 1, 2, \dots, n$, então

$$-1 \leq p_{ij} \leq 1.$$

- (c) Use a definição de matriz ortogonal para mostrar que

$$|\mathbf{P}| = \pm 1.$$

- (d) Use a definição anterior e o resultado do item (c) para mostrar que, para qualquer matriz quadrada $\mathbf{A} \in M_n(\mathbb{R})$,

$$|\mathbf{P}^\top \mathbf{A} \mathbf{P}| = |\mathbf{A}|.$$

- (e) Mostre que toda matriz ortogonal é de posto completo, isto é,

$$r(\mathbf{P}) = n.$$

- (f) Mostre que, se $\mathbf{P}_1, \mathbf{P}_2, \dots, \mathbf{P}_k$ são matrizes ortogonais de ordem $n \times n$, então o produto

$$\mathbf{P}_1 \mathbf{P}_2 \cdots \mathbf{P}_k$$

também é uma matriz ortogonal de ordem $n \times n$.

(g) Considere a seguinte afirmação:

“Se $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ é um operador linear cuja matriz associada é a matriz ortogonal $\mathbf{P}$, então o único vetor $\mathbf{x}$ cuja imagem pela F é o vetor nulo $\mathbf{0}$ é o próprio vetor nulo $\mathbf{0}$.”

Você concorda com essa afirmação? Justifique sua resposta com base nas propriedades demonstradas anteriormente.

23. Considere as seguintes matrizes quadradas

$$\mathbf{A} = \begin{bmatrix} 1 & -2 \\ -2 & 1 \end{bmatrix}, \quad \mathbf{B} = \begin{bmatrix} 0 & 6 \\ 6 & 0 \end{bmatrix} \quad \text{e} \quad \mathbf{C} = \begin{bmatrix} 3 & 3 \\ 3 & 3 \end{bmatrix}.$$

(a) Determine a matriz quadrada

$$\mathbf{M} = \alpha^2 \mathbf{A} + \alpha \mathbf{B} + \mathbf{C}, \quad \alpha \in \mathbb{R}.$$

(b) A matriz $\mathbf{M}$ é simétrica? Justifique.

(c) Calcule o determinante $|\mathbf{M}|$ da matriz $\mathbf{M}$ em função de $\alpha \in \mathbb{R}$.

(d) Utilize o item (c) para determinar os valores de $\alpha \in \mathbb{R}$ para os quais a matriz $\mathbf{M}$ admite inversa.

(e) Utilize os itens (c) e (d) para determinar os valores de $\alpha \in \mathbb{R}$ para os quais a matriz $\mathbf{M}$ possui posto completo.

24. Quais as condições necessárias e suficientes para que um determinante se anule?

25. (a) Qual é a condição sobre a para que a matriz

$$\mathbf{M} = \begin{bmatrix} 1 & a & a \\ a & 1 & a \\ a & a & 1 \end{bmatrix}$$

seja inversível?

(b) Determine os valores de m para os quais a matriz $\mathbf{M} = \begin{bmatrix} 1 & m \\ m & 2 \end{bmatrix}$ seja inversível.

26. Mostre que

$$\begin{vmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & 1+a_1 & 1 & \dots & 1 \\ 1 & 1 & 1+a_2 & \dots & 1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1+a_n \end{vmatrix} = a_1 a_2 \cdots a_n.$$

27. Vetores e matrizes de um's são muito utilizados na teoria estatística. Por exemplo, o vetor de um's é definido por

$$\mathbf{1}_n = \begin{bmatrix} 1 & 1 & \dots & 1 \end{bmatrix}^\top.$$

- (a) Seguindo esta ideia, a **matriz de um's**, denotada por $\mathbf{J}_n$, é uma matriz $n \times n$ na qual todos os elementos são iguais a um. Como representar a matriz $\mathbf{J}_n$ em função do vetor $\mathbf{1}_n$?

- (b) Mostre que

$$\mathbf{J}_n^2 = n \cdot \mathbf{J}_n.$$

- (c) Como é a forma da matriz

$$\left(\mathbf{I} - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right)?$$

28. Mostre que a matriz $\mathbf{H}$ da transformação linear F que projeta ortogonalmente o vetor de observações $\mathbf{y} \in \mathbb{R}^n$ da variável Y sobre a reta suporte gerada pelo vetor de observações $\mathbf{x} \in \mathbb{R}^n$ da variável X é dada por

$$\mathbf{H} = \frac{\mathbf{x} \mathbf{x}^\top}{\mathbf{x}^\top \mathbf{x}}.$$

29. Uma matriz quadrada $\mathbf{A}$ é dita *idempotente* quando $\mathbf{A}^2 = \mathbf{A}$, em que $\mathbf{A}^2 = \mathbf{A}\mathbf{A}$; e é dita *simétrica* quando $\mathbf{A}^\top = \mathbf{A}$. Seja $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ e defina a matriz

$$\mathbf{H} := \mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top.$$

- (a) Especifique a ordem da matriz $\mathbf{H}$ e, em seguida, verifique se a matriz $\mathbf{H}$ é simétrica.
- (b) Verifique se a matriz $\mathbf{H}$ é idempotente.
- (c) Especifique a ordem da matriz $\mathbf{I}_n - \mathbf{H}$ e, em seguida, verifique se a matriz $\mathbf{I}_n - \mathbf{H}$ é uma matriz idempotente, em que $\mathbf{I}_n$ denota a matriz identidade de ordem n .

- (d) Mostre que $\mathbf{H}(\mathbf{I}_n - \mathbf{H}) = \mathbf{O}_n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem n e $\mathbf{O}_n$ é a matriz nula de ordem n .
- (e) Sejam $\mathbf{1}_n$ o vetor de uns de ordem n e σ^2 uma constante real positiva. Usando que $\mathbf{1}_n^\top \mathbf{H} = \mathbf{1}_n^\top$, verifique que

$$\frac{1}{\sigma^2} \left(\mathbf{H} - \frac{\mathbf{1}_n \mathbf{1}_n^\top}{n} \right) \mathbf{I}_n (\mathbf{I}_n - \mathbf{H}) = \mathbf{O}_n,$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem n e $\mathbf{O}_n$ é a matriz nula de ordem n .

30. Uma matriz $\mathbf{H} \in M_n(\mathbb{R})$ é dita de *Hadamard* quando todas as suas entradas consistem apenas de $+1$ ou -1 e $\mathbf{H}^\top \mathbf{H} = n\mathbf{I}_n$, em que $\mathbf{I}_n$ é a matriz identidade de ordem n .

- (a) Mostre que se $\mathbf{H}$ é uma matriz Hadamard, então $n^{-1/2}\mathbf{H}$ é não-singular.
- (b) Mostre que se $\mathbf{H}$ é uma matriz Hadamard, $n^{-1/2}\mathbf{H}$ é uma matriz ortogonal.
Dica: Uma matriz $\mathbf{P} \in M_n(\mathbb{R})$ é ortogonal quando $\mathbf{P}^\top = \mathbf{P}^{-1}$.
- (c) Mostre que se $\mathbf{H}$ é uma matriz Hadamard, então $\mathbf{H}$ é inversível. Determine sua inversa $\mathbf{H}^{-1}$ e verifique que $n\mathbf{H}^{-1}$ é uma matriz de Hadamard.
- (d) Mostre que se $\mathbf{H}$ é uma matriz Hadamard, então $|\mathbf{H}| = n^{n/2}$.

31. Usando determinantes verifique, em cada item, se os vetores são linearmente dependentes ou linearmente independentes.

- (a) $\mathbf{u} = [1 \ 0 \ 0]^\top$, $\mathbf{v} = [200 \ 2 \ 1]^\top$ e $\mathbf{w} = [300 \ 1 \ 2]^\top$.
- (b) $\mathbf{u} = [1 \ 2 \ 1]^\top$, $\mathbf{v} = [1 \ -1 \ -7]^\top$ e $\mathbf{w} = [4 \ 5 \ -4]^\top$.
- (c) $\mathbf{u} = [0 \ 1 \ 1]^\top$ e $\mathbf{v} = [0 \ 3 \ 1]^\top$.

32. Usando determinantes, encontre $m \in \mathbb{R}$ para que sejam linearmente dependentes.

- (a) $\mathbf{u} = [m \ 1 \ m]^\top$ e $\mathbf{v} = [1 \ m \ 1]^\top$.
- (b) $\mathbf{u} = [1 - m^2 \ 1 - m \ 0]^\top$ e $\mathbf{v} = [m \ m \ m]^\top$.
- (c) $\mathbf{u} = [m \ 1 \ m + 1]^\top$, $\mathbf{v} = [1 \ 2 \ m]^\top$ e $\mathbf{w} = [1 \ 1 \ 1]^\top$.
- (d) $\mathbf{u} = [m \ 1 \ m + 1]^\top$, $\mathbf{v} = [0 \ 1 \ m]^\top$ e $\mathbf{w} = [0 \ m \ 2m]^\top$.

33. Considere um estudo em que observamos uma amostra de tamanho n de um vetor aleatório p -dimensional

$$[X_1 \ X_2 \ \dots \ X_p]^\top.$$

Denote por $\mathbf{X} \in M_{n \times p}(\mathbb{R})$ a matriz de dados, $\bar{\mathbf{x}}$ o vetor de médias amostrais associado e por $\mathbf{S}_n$ a matriz de variâncias e covariâncias amostrais correspondente.

(a) Mostre que

$$\bar{\mathbf{x}} = \frac{1}{n} \mathbf{X}^\top \mathbf{1}_n,$$

em que $\mathbf{1}_n \in \mathbb{R}^n$ é o vetor de uns de ordem n .

(b) Mostre que

$$\mathbf{S}_n = \frac{1}{n} \mathbf{X}^\top \left(\mathbf{I}_n - \frac{1}{n} \mathbf{1}_n \mathbf{1}_n^\top \right) \mathbf{X},$$

em que $\mathbf{I}_n \in M_n(\mathbb{R})$ é a matriz identidade de ordem n .

(c) Denote por $\mathbf{D}^{1/2} \in M_p(\mathbb{R})$ a *matriz de desvios-padrões amostrais*, i.e.,

$$\mathbf{D}^{1/2} := \begin{bmatrix} \sqrt{s_{11}} & 0 & \cdots & 0 \\ 0 & \sqrt{s_{22}} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sqrt{s_{pp}} \end{bmatrix}.$$

Mostre que $\mathbf{D}$ é inversível e que

$$\mathbf{R} = \mathbf{D}^{-1/2} \mathbf{S} \mathbf{D}^{-1/2},$$

em que $\mathbf{R} \in M_p(\mathbb{R})$ é a matriz de correlações amostrais.

(d) Use o item (c) para mostrar que

$$\mathbf{S} = \mathbf{D}^{1/2} \mathbf{R} \mathbf{D}^{1/2}.$$

(e) Considere a seguinte variável aleatória

$$Y := b_1 X_1 + b_2 X_2 + \cdots + b_p X_p$$

em que $\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_p]^\top \in \mathbb{R}^p$ é um vetor de constantes. Mostre que a média amostral de Y é

$$\bar{y} = \mathbf{b}^\top \bar{\mathbf{x}}.$$

(f) Considere a seguinte variável aleatória

$$Y := b_1 X_1 + b_2 X_2 + \cdots + b_p X_p$$

em que $\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_p]^\top \in \mathbb{R}^p$ é um vetor de constantes. Mostre que a

variância amostral de Y é

$$s_Y = \mathbf{b}^\top \mathbf{S}_n \mathbf{b}.$$

(g) Considere as seguintes variáveis aleatórias

$$Y := b_1 X_1 + b_2 X_2 + \cdots + b_p X_p$$

e

$$Z := c_1 X_1 + c_2 X_2 + \cdots + c_p X_p$$

em que $\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_p]^\top \in \mathbb{R}^p$ e $\mathbf{c} = [c_1 \ c_2 \ \cdots \ c_p]^\top \in \mathbb{R}^p$ são vetores de constantes. Mostre que a covariância amostral entre Y e Z é

$$s_{YZ} = \mathbf{b}^\top \mathbf{S}_n \mathbf{c}.$$

(h) Mostre que

$$|\mathbf{S}| = (s_{11}s_{22} \cdots s_{pp})|\mathbf{R}|.$$

34. Dois métodos de treinamento foram aplicados em grupos diferentes de funcionários para melhorar o desempenho em três habilidades, todas avaliadas em uma escala de 0 a 100: Comunicação, Liderança e Gestão de Tempo. As matrizes de variâncias e covariâncias **amostrais** obtidas em cada uma das subpopulações foram:

$$\mathbf{S}_n^{(1)} = \begin{bmatrix} 12 & 3 & 4 \\ 3 & 10 & 5 \\ 4 & 5 & 11 \end{bmatrix} \quad (\text{Método 1}) \quad \text{e} \quad \mathbf{S}_n^{(2)} = \begin{bmatrix} 8 & 2 & 1 \\ 2 & 7 & 3 \\ 1 & 3 & 6 \end{bmatrix} \quad (\text{Método 2}).$$

- (a) Calcule a variância total **amostral** para cada método.
- (b) Compare os resultados e interprete: qual grupo apresentou maior dispersão geral nas habilidades avaliadas?
- (c) Que tipo de informação o cálculo da variância generalizada **amostral** agregaria?
35. Considere as seguintes matrizes de variâncias e covariâncias **amostrais**:

$$\mathbf{S}_n^{(1)} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}, \quad \mathbf{S}_n^{(2)} = \begin{bmatrix} 5 & -4 \\ -4 & 5 \end{bmatrix}, \quad \mathbf{S}_n^{(3)} = \begin{bmatrix} 3 & 0 \\ 0 & 3 \end{bmatrix}.$$

- (a) Esboce os paralelogramos associados a cada uma das matrizes de variâncias e covariâncias amostrais. Compare-os.
- (b) Determine as variâncias generalizadas associadas a cada uma das matrizes de variâncias e covariâncias amostrais.

(c) Suas respostas para os itens (a) e (b) são consistentes?

36. Dois métodos de ensino foram aplicados para treinar operadores de máquinas, avaliados em duas habilidades medidas em uma escala de 0 a 10: Precisão e Velocidade. As matrizes de variâncias e covariâncias **amostrais** obtidas para os dois grupos de operadores foram:

$$\mathbf{S}_n^{(1)} = \begin{bmatrix} 2 & 1,8 \\ 1,8 & 2 \end{bmatrix} \quad (\text{Método 1}) \quad \text{e} \quad \mathbf{S}_n^{(2)} = \begin{bmatrix} 1 & 0,8 \\ 0,8 & 1 \end{bmatrix} \quad (\text{Método 2}).$$

- (a) Calcule a variância total **amostral** para cada método.
- (b) Compare os resultados: qual grupo apresentou maior dispersão geral?
- (c) A variância total **amostral** é uma boa medida de resumo nessa situação? Por quê?
- (d) Comente o que o cálculo da variância generalizada **amostral** agregaria para a análise.
- (e) A variância generalizada **amostral** é uma boa medida de resumo nessa situação? Por quê?

3 Formas lineares e quadráticas

“Na matemática não conhecemos através de conceitos, mas pela construção na pura intuição.”

Immanuel Kant (1724 – 1804)

Neste capítulo estudaremos com mais cuidado as formas lineares, do tipo $\mathbf{a}^\top \mathbf{x}$, e as formas quadráticas, do tipo $\mathbf{x}^\top \mathbf{A} \mathbf{x}$, que aparecem de maneira central na formulação matricial de problemas em Estatística. Em particular, na regressão linear múltipla, o critério de mínimos quadrados pode ser escrito como uma forma quadrática em $\boldsymbol{\beta}$,

$$Q(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}),$$

cujas função objetivo é diferenciável; para encontrar o estimador de mínimos quadrados $\hat{\boldsymbol{\beta}}$ precisaremos justamente calcular derivadas de formas lineares e quadráticas. Ao mesmo tempo, veremos que a estrutura dessas formas está intimamente ligada ao conceito de matrizes definidas positivas, negativas, semidefinidas positivas e semidefinidas negativas, que desempenham papel fundamental tanto na convexidade dos problemas de otimização envolvidos quanto na interpretação estatística: a matriz de variâncias e covariâncias, por exemplo, é sempre simétrica e semidefinida positiva, e condições adicionais que a tornem definida positiva garantem unicidade de soluções e boa definição de diversas quantidades usadas em modelos estatísticos multivariados.

3.1 Definições e primeiros exemplos

Começemos como um exemplo

Exemplo 3.1: Transformação linear

Considere as seguintes transformações lineares

(a) $F : \mathbb{R}^2 \rightarrow \mathbb{R}^3$ tal que

$$F(x, y) = \begin{bmatrix} x \\ x + y \\ x - y \end{bmatrix}.$$

Exemplo 3.1

(b) $F : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ tal que

$$F(x, y) = \begin{bmatrix} x + 2y \\ 0 \end{bmatrix}.$$

(c) $F : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que

$$F(x, y, z) = x + 2y - z.$$

(d) $F : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que

$$F(x, y) = x.$$

Determine as matrizes associadas.

SOLUÇÃO:

(a) Para $F : \mathbb{R}^2 \rightarrow \mathbb{R}^3$,

$$F(e_1) = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \quad F(e_2) = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix}.$$

Logo a matriz associada é

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & -1 \end{bmatrix}, \quad \text{de modo que } F(\mathbf{x}) = A\mathbf{x}.$$

(b) Para $F : \mathbb{R}^2 \rightarrow \mathbb{R}^2$,

$$F(e_1) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad F(e_2) = \begin{bmatrix} 2 \\ 0 \end{bmatrix},$$

e a matriz associada é

$$A = \begin{bmatrix} 1 & 2 \\ 0 & 0 \end{bmatrix}, \quad \text{com } F(\mathbf{x}) = A\mathbf{x}.$$

(c) Para $F : \mathbb{R}^3 \rightarrow \mathbb{R}$,

Exemplo 3.1

$$F(e_1) = 1, \quad F(e_2) = 2, \quad F(e_3) = -1,$$

logo a matriz (linha) associada é

$$A = \begin{bmatrix} 1 & 2 & -1 \end{bmatrix}, \quad \text{e} \quad F(\mathbf{x}) = A\mathbf{x}.$$

(d) Para $F : \mathbb{R}^2 \rightarrow \mathbb{R}$,

$$F(e_1) = 1, \quad F(e_2) = 0,$$

de forma que a matriz associada é

$$A = \begin{bmatrix} 1 & 0 \end{bmatrix}, \quad \text{e} \quad F(\mathbf{x}) = A\mathbf{x}.$$

Definição 3.1: Forma linear

Seja $n \in \mathbb{N}$. Chamamos de *forma linear* em $\mathbb{R}^n$ qualquer transformação linear

$$L : \mathbb{R}^n \rightarrow \mathbb{R}$$

que pode ser escrita na forma

$$L(\mathbf{x}) = \mathbf{a}^\top \mathbf{x},$$

em que $\mathbf{a} \in \mathbb{R}^n$ e $\mathbf{x} \in \mathbb{R}^n$. O vetor $\mathbf{a}$ recebe o nome de *vetor associado* à forma linear L .

Exemplo 3.2: Formas lineares

Encontre o vetor associado às seguintes formas lineares:

(a) $L_1 : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que

$$L_1(x_1, x_2) = 3x_1 - 2x_2.$$

Exemplo 3.2

(b) $L_2 : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que

$$L_2(x_1, x_2, x_3) = x_1 + 4x_2 - 5x_3.$$

(c) $L_3 : \mathbb{R}^4 \rightarrow \mathbb{R}$ tal que

$$L_3(x_1, x_2, x_3, x_4) = 2x_1 - x_2 + x_3 + 7x_4.$$

SOLUÇÃO:

Basta identificar os coeficientes de cada coordenada de $\mathbf{x}$.

(a) Em $L_1(\mathbf{x}) = 3x_1 - 2x_2$, o vetor associado é $\mathbf{a}_1 = \begin{bmatrix} 3 & -2 \end{bmatrix}^\top$.

(b) Em $L_2(\mathbf{x}) = x_1 + 4x_2 - 5x_3$, o vetor associado é $\mathbf{a}_2 = \begin{bmatrix} 1 & 4 & -5 \end{bmatrix}^\top$.

(c) Em $L_3(\mathbf{x}) = 2x_1 - x_2 + x_3 + 7x_4$, o vetor associado é $\mathbf{a}_3 = \begin{bmatrix} 2 & -1 & 1 & 7 \end{bmatrix}^\top$.

Definição 3.2: Forma quadrática

Seja $n \in \mathbb{N}$ e seja $\mathbf{A} \in \mathbb{R}^{n \times n}$ uma matriz quadrada. Denominamos *forma quadrática* associada a $\mathbf{A}$ a aplicação $Q : \mathbb{R}^n \rightarrow \mathbb{R}$ dada por

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^n.$$

Quando for conveniente, consideraremos a matriz associada simétrica, isto é, $\mathbf{A} = \mathbf{A}^\top$, pois essa escolha leva a propriedades geométricas e algébricas mais agradáveis.

Exemplo 3.3: Formas quadráticas associadas a matrizes

Determine as formas quadráticas associadas às seguintes matrizes:

(a) $\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}.$

Exemplo 3.4

$$(b) \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

$$(c) \mathbf{A} = \begin{bmatrix} 1 & 3 & 0 \\ 3 & -1 & -2 \\ 0 & -2 & 2 \end{bmatrix}.$$

SOLUÇÃO:

Seja $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top$ ou $\mathbf{x} = \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix}^\top$, conforme o caso.

(a)

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + 2x_1x_2 + x_2^2.$$

(b)

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = x_1^2 + x_2^2.$$

(c)

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = \begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix} \begin{bmatrix} 1 & 3 & 0 \\ 3 & -1 & -2 \\ 0 & -2 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = x_1^2 + 6x_1x_2 - x_2^2 - 4x_2x_3 + 2x_3^2.$$

Resultado 3.1

Se $Q : \mathbb{R}^n \rightarrow \mathbb{R}$ é uma forma quadrática associada a uma matriz simétrica $\mathbf{A}$, então ela pode ser escrita da seguinte forma:

$$Q(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j,$$

em que $a_{ij} \in \mathbb{R}$ está na linha i e coluna j da matriz $\mathbf{A}$.

Resultado 3.1**DEMONSTRAÇÃO:**

Seja $\mathbf{x} = [x_1 \ \dots \ x_n]^\top$ e seja $\mathbf{A} = (a_{ij})_{1 \leq i, j \leq n}$ uma matriz simétrica. Então

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} = [x_1 \ \dots \ x_n] \begin{bmatrix} a_{11} & \dots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}.$$

Multiplicando a primeira matriz pela segunda, obtemos um vetor linha cuja i -ésima coordenada é

$$\sum_{j=1}^n a_{ij} x_j.$$

Multiplicando esse vetor linha pelo vetor coluna final, resulta

$$Q(\mathbf{x}) = \sum_{i=1}^n \left(x_i \sum_{j=1}^n a_{ij} x_j \right) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j,$$

como queríamos demonstrar. $\square$

Exemplo 3.5: Matrizes associadas a formas quadráticas

Determine, para cada uma das formas quadráticas abaixo, duas matrizes associadas: uma matriz simétrica e uma matriz não simétrica.

(a) $Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que

$$Q(\mathbf{x}) = 9x_1^2 + 12x_1x_2 + 5x_2^2.$$

(b) $Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que

$$Q(\mathbf{x}) = 2x_1x_2.$$

(c) $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que

$$Q(\mathbf{x}) = 4x_1^2 + 4x_1x_2 - 8x_1x_3 + 10x_2^2 + 8x_2x_3 + 9x_3^2.$$

Exemplo 3.5SOLUÇÃO:

Lembrando que, para uma matriz simétrica, cada termo cruzado $x_i x_j$ aparece duas vezes na soma $\sum_i \sum_j a_{ij} x_i x_j$, dividimos o coeficiente do termo cruzado por 2 para obter os elementos fora da diagonal da matriz simétrica.

(a) Para $Q(\mathbf{x}) = 9x_1^2 + 12x_1x_2 + 5x_2^2$, uma matriz simétrica associada é

$$\mathbf{A}_{\text{sim}} = \begin{bmatrix} 9 & 6 \\ 6 & 5 \end{bmatrix},$$

pois $\mathbf{x}^\top \mathbf{A}_{\text{sim}} \mathbf{x} = 9x_1^2 + 12x_1x_2 + 5x_2^2$. Uma matriz não simétrica associada pode ser, por exemplo,

$$\mathbf{A}_{\text{ns}} = \begin{bmatrix} 9 & 12 \\ 0 & 5 \end{bmatrix},$$

que também satisfaz $\mathbf{x}^\top \mathbf{A}_{\text{ns}} \mathbf{x} = 9x_1^2 + 12x_1x_2 + 5x_2^2$.

(b) Para $Q(\mathbf{x}) = 2x_1x_2$, uma matriz simétrica associada é

$$\mathbf{A}_{\text{sim}} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix},$$

enquanto que uma matriz não simétrica associada pode ser

$$\mathbf{A}_{\text{ns}} = \begin{bmatrix} 0 & 2 \\ 0 & 0 \end{bmatrix}.$$

(c) Para

$$Q(\mathbf{x}) = 4x_1^2 + 4x_1x_2 - 8x_1x_3 + 10x_2^2 + 8x_2x_3 + 9x_3^2,$$

a matriz simétrica associada é

$$\mathbf{A}_{\text{sim}} = \begin{bmatrix} 4 & 2 & -4 \\ 2 & 10 & 4 \\ -4 & 4 & 9 \end{bmatrix},$$

obtida dividindo os coeficientes dos termos cruzados por 2.

Exemplo 3.5

Uma matriz não simétrica associada à mesma forma quadrática pode ser

$$\mathbf{A}_{\text{ns}} = \begin{bmatrix} 4 & 4 & -8 \\ 0 & 10 & 8 \\ 0 & 0 & 9 \end{bmatrix}.$$

Qualquer matriz quadrada $\mathbf{A} \in \mathbb{R}^{n \times n}$ pode ser decomposta de forma única na soma de sua parte simétrica e de sua parte antissimétrica:

$$\mathbf{A} = \underbrace{\frac{\mathbf{A} + \mathbf{A}^\top}{2}}_{\text{parte simétrica}} + \underbrace{\frac{\mathbf{A} - \mathbf{A}^\top}{2}}_{\text{parte antissimétrica}}.$$

A primeira parcela é simétrica e a segunda é antissimétrica, e essa decomposição é a única com essa propriedade.

No estudo de formas quadráticas, vamos preferir sempre associar à forma a sua matriz *simétrica*, pois ela concentra toda a informação relevante da forma quadrática e apresenta propriedades geométricas e algébricas mais interessantes, em particular na classificação em matrizes definidas positivas, negativas, semidefinidas positivas e semidefinidas negativas.

3.2 Matrizes definidas positivas, definidas negativas, semidefinidas positivas e semidefinidas negativas

Definição 3.3: Matrizes definidas e semidefinidas

Seja $\mathbf{A} \in \mathbb{R}^{n \times n}$ uma matriz *simétrica* e seja

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}, \quad \mathbf{x} \in \mathbb{R}^n,$$

a forma quadrática associada a $\mathbf{A}$. Dizemos que:

- $\mathbf{A}$ é *definida positiva* se

$$Q(\mathbf{x}) > 0 \quad \text{para todo } \mathbf{x} \neq \mathbf{0}.$$

Definição 3.3

- A é *definida negativa* se

$$Q(\mathbf{x}) < 0 \quad \text{para todo } \mathbf{x} \neq \mathbf{0}.$$

- A é *semidefinida positiva* se

$$Q(\mathbf{x}) \geq 0 \quad \text{para todo } \mathbf{x} \in \mathbb{R}^n \quad \text{e existe } \mathbf{x}_0 \neq \mathbf{0} \text{ tal que } Q(\mathbf{x}_0) = 0.$$

- A é *semidefinida negativa* se

$$Q(\mathbf{x}) \leq 0 \quad \text{para todo } \mathbf{x} \in \mathbb{R}^n \quad \text{e existe } \mathbf{x}_0 \neq \mathbf{0} \text{ tal que } Q(\mathbf{x}_0) = 0.$$

- A é *indefinida* se existem vetores $\mathbf{x}_1, \mathbf{x}_2 \in \mathbb{R}^n$ tais que

$$Q(\mathbf{x}_1) > 0 \quad \text{e} \quad Q(\mathbf{x}_2) < 0.$$

Essas classificações são feitas sempre em termos do sinal assumido pela forma quadrática $\mathbf{x}^\top A \mathbf{x}$.

Exemplo 3.6: Classificando matrizes pela definição

Verifique, usando diretamente a definição acima, que as matrizes a seguir são:

- uma matriz definida positiva;
- uma matriz definida negativa;
- uma matriz semidefinida positiva;
- uma matriz semidefinida negativa;
- uma matriz indefinida.

Considere, para isso, as matrizes

$$A_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \end{bmatrix}, \quad A_2 = \begin{bmatrix} -2 & 0 \\ 0 & -1 \end{bmatrix}, \quad A_3 = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix},$$

Exemplo 3.6

$$\mathbf{A}_4 = \begin{bmatrix} -1 & -1 \\ -1 & -1 \end{bmatrix}, \quad \mathbf{A}_5 = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

SOLUÇÃO:

Seja $\mathbf{x} = \begin{bmatrix} x_1 & x_2 \end{bmatrix}^\top$.

(a) Para $\mathbf{A}_1$,

$$Q_1(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}_1 \mathbf{x} = 2x_1^2 + 2x_1x_2 + 2x_2^2 = (x_1 + x_2)^2 + x_1^2 + x_2^2.$$

A soma de quadrados só pode ser nula se $x_1 = x_2 = 0$. Logo $Q_1(\mathbf{x}) > 0$ para todo $\mathbf{x} \neq \mathbf{0}$ e $\mathbf{A}_1$ é definida positiva.

(b) Para $\mathbf{A}_2$,

$$Q_2(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}_2 \mathbf{x} = -2x_1^2 - x_2^2.$$

Para todo $\mathbf{x} \neq \mathbf{0}$ temos $-2x_1^2 - x_2^2 < 0$, logo $\mathbf{A}_2$ é definida negativa.

(c) Para $\mathbf{A}_3$,

$$Q_3(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}_3 \mathbf{x} = x_1^2 + 2x_1x_2 + x_2^2 = (x_1 + x_2)^2 \geq 0.$$

A igualdade vale, por exemplo, para $\mathbf{x} = (1, -1)^\top \neq \mathbf{0}$. Assim, $Q_3(\mathbf{x}) \geq 0$ para todo $\mathbf{x}$ e é nula para vetores não nulos, o que mostra que $\mathbf{A}_3$ é semidefinida positiva.

(d) Para $\mathbf{A}_4$,

$$Q_4(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}_4 \mathbf{x} = -(x_1 + x_2)^2 \leq 0,$$

com igualdade, por exemplo, em $\mathbf{x} = (1, -1)^\top \neq \mathbf{0}$. Logo $\mathbf{A}_4$ é semidefinida negativa.

(e) Para $\mathbf{A}_5$,

$$Q_5(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}_5 \mathbf{x} = x_1^2 - x_2^2.$$

Se tomarmos $\mathbf{x}_1 = (1, 0)^\top$, obtemos $Q_5(\mathbf{x}_1) = 1 > 0$. Já para $\mathbf{x}_2 = (0, 1)^\top$, temos $Q_5(\mathbf{x}_2) = -1 < 0$. Portanto a forma quadrática assume valores positivos e negativos, e $\mathbf{A}_5$ é indefinida.

Depois de alguns exemplos, fica claro que verificar essas propriedades *diretamente* a partir da expressão $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ pode se tornar trabalhoso em dimensões maiores. Gostaríamos de ter um *critério prático*, em termos dos elementos da matriz, que nos dissesse quando uma matriz é definida positiva ou negativa.

No caso $n = 2$, por exemplo, se $\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} \\ a_{12} & a_{22} \end{bmatrix}$, temos

$$Q(\mathbf{x}) = a_{11}x_1^2 + 2a_{12}x_1x_2 + a_{22}x_2^2.$$

Completando quadrados,

$$Q(\mathbf{x}) = a_{11} \left(x_1 + \frac{a_{12}}{a_{11}} x_2 \right)^2 + \left(a_{22} - \frac{a_{12}^2}{a_{11}} \right) x_2^2.$$

Para que $Q(\mathbf{x}) > 0$ para todo $\mathbf{x} \neq \mathbf{0}$, os coeficientes dos dois quadrados precisam ser positivos, o que nos leva a

$$a_{11} > 0 \quad \text{e} \quad a_{11}a_{22} - a_{12}^2 > 0.$$

Repare que essas quantidades são exatamente os determinantes dos *menores principais* 1×1 e 2×2 de $\mathbf{A}$. Em dimensões maiores, podemos repetir esse raciocínio (ou pensar em uma eliminação de Gauss adaptada a formas quadráticas) e obter um resultado geral, conhecido como *critério de Sylvester*.

Resultado 3.2: Critério de Sylvester

Seja $\mathbf{A} \in \mathbb{R}^{n \times n}$ uma matriz simétrica. Denote por Δ_k qualquer menor principal de ordem k de $\mathbf{A}$ (determinante de uma submatriz obtida escolhendo o mesmo conjunto de índices de linhas e colunas). Então:

- $\mathbf{A}$ é *definida positiva* se, e somente se, todos os menores principais de $\mathbf{A}$ são estritamente positivos, isto é,

$$\Delta_k > 0 \quad \text{para todo } k = 1, \dots, n.$$

- $\mathbf{A}$ é *definida negativa* se, e somente se, todos os menores principais de $-\mathbf{A}$ são estritamente positivos (equivalentemente, se $(-1)^k \Delta_k > 0$ para todo menor principal de ordem k).
- $\mathbf{A}$ é *indefinida* caso não seja nem definida e nem semidefinida.

Resultado 3.2

- $\mathbf{A}$ é *semidefinida positiva* se, e somente se, todos os menores principais de $\mathbf{A}$ são não negativos, isto é,

$$\Delta_k \geq 0 \quad \text{para todo } k = 1, \dots, n.$$

Em particular, se todos forem estritamente positivos, $\mathbf{A}$ é definida positiva; se pelo menos um deles for nulo, $\mathbf{A}$ é semidefinida positiva (mas não definida positiva).

- $\mathbf{A}$ é *semidefinida negativa* se, e somente se, todos os menores principais de $-\mathbf{A}$ são não negativos (equivalentemente, se $(-1)^k \Delta_k \geq 0$ para todo menor principal de ordem k). Em particular, se algum desses menores principais é nulo, $\mathbf{A}$ é semidefinida negativa (e não definida negativa).

Exemplo 3.7: Classificando matrizes pelo critério de Sylvester

Use o critério de Sylvester para classificar as matrizes abaixo como

- definida positiva;
- definida negativa;
- semidefinida positiva;
- semidefinida negativa;
- indefinida.

Considere

$$\mathbf{B}_1 = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{B}_2 = \begin{bmatrix} -2 & 0 & 0 \\ 0 & -3 & 0 \\ 0 & 0 & -1 \end{bmatrix}, \quad \mathbf{B}_3 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix},$$

$$\mathbf{B}_4 = \begin{bmatrix} -1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \quad \mathbf{B}_5 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & -1 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

Exemplo 3.7**SOLUÇÃO:**

Como as matrizes são diagonais, seus menores principais são produtos de entradas da diagonal.

- (a) Para $\mathbf{B}_1$, os menores principais de ordem 1 são $2, 3, 1 > 0$; os de ordem 2 são $2 \cdot 3 = 6$, $2 \cdot 1 = 2$ e $3 \cdot 1 = 3$, todos positivos; o menor principal de ordem 3 é $\det(\mathbf{B}_1) = 2 \cdot 3 \cdot 1 = 6 > 0$. Pelo critério de Sylvester, $\mathbf{B}_1$ é definida positiva.
- (b) Para $\mathbf{B}_2$, observamos que $-\mathbf{B}_2 = \text{diag}(2, 3, 1)$, cujos menores principais são exatamente os de $\mathbf{B}_1$ e, portanto, todos positivos. Assim, pelo critério de Sylvester, $\mathbf{B}_2$ é definida negativa.
- (c) Para $\mathbf{B}_3$, os menores principais são todos ≥ 0 : temos $1, 1, 0$ na ordem 1; $1, 0, 0$ na ordem 2; e $\det(\mathbf{B}_3) = 0$ na ordem 3. Logo a matriz não é definida positiva (pois o determinante é nulo), mas nenhum menor principal é negativo. Como a forma quadrática associada é $Q(\mathbf{x}) = x_1^2 + x_2^2 \geq 0$ para todo $\mathbf{x}$, concluímos que $\mathbf{B}_3$ é semidefinida positiva.
- (d) Para $\mathbf{B}_4$, temos $-\mathbf{B}_4 = \mathbf{B}_3$. Assim, todos os menores principais de $-\mathbf{B}_4$ são ≥ 0 , mas o determinante é nulo, de modo que $\mathbf{B}_4$ não é definida negativa. A forma quadrática correspondente é $Q(\mathbf{x}) = -x_1^2 - x_2^2 \leq 0$, com igualdade em vetores não nulos que tenham $x_1 = x_2 = 0$ e $x_3 \neq 0$. Assim, $\mathbf{B}_4$ é semidefinida negativa.
- (e) Em $\mathbf{B}_5$, já na ordem 1 aparecem menores principais de sinais diferentes (1 e -1). Além disso, o menor principal de ordem 2 dado pela submatriz das duas primeiras linhas e colunas é $\det(\text{diag}(1, -1)) = -1 < 0$. Esses sinais conflitantes mostram que a matriz não pode ser definida positiva nem definida negativa; e, como há menores principais negativos, ela também não é semidefinida positiva nem semidefinida negativa. Concluímos que $\mathbf{B}_5$ é indefinida.

Esses exemplos ilustram como o critério de Sylvester fornece um procedimento algébrico, baseado em determinantes de submatrizes, para estudar o sinal da forma quadrática $\mathbf{x}^\top \mathbf{A} \mathbf{x}$ sem precisar trabalhar diretamente com a expressão em termos das coordenadas de $\mathbf{x}$.

3.3 Derivadas de formas lineares e quadráticas

Nesta seção vamos estudar como calcular derivadas de formas lineares $\mathbf{a}^\top \mathbf{x}$ e de formas quadráticas $\mathbf{x}^\top \mathbf{A} \mathbf{x}$. Nosso objetivo é preparar o terreno para a aplicação desses resultados na regressão linear múltipla, onde a função objetivo de mínimos quadrados é, justamente, uma forma quadrática no vetor de parâmetros.

Definição 3.4: Derivada (gradiente) de funções escalares

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função diferenciável. Chamamos de *gradiente* de f no ponto $\mathbf{x} \in \mathbb{R}^n$ ao vetor

$$\nabla f(\mathbf{x}) = \begin{bmatrix} \frac{\partial f}{\partial x_1}(\mathbf{x}) \\ \vdots \\ \frac{\partial f}{\partial x_n}(\mathbf{x}) \end{bmatrix},$$

que representa a derivada de f em $\mathbf{x}$ vista como aplicação linear de $\mathbb{R}^n$ em $\mathbb{R}$. Em outras palavras, o gradiente é o vetor de derivadas parciais de f .

Resultado 3.3: Derivada de uma forma linear

Seja $\mathbf{a} \in \mathbb{R}^n$ um vetor fixo e considere a forma linear $L : \mathbb{R}^n \rightarrow \mathbb{R}$ dada por

$$L(\mathbf{x}) = \mathbf{a}^\top \mathbf{x}.$$

Então, para todo $\mathbf{x} \in \mathbb{R}^n$,

$$\nabla L(\mathbf{x}) = \mathbf{a}.$$

DEMONSTRAÇÃO:

Escrevendo $\mathbf{a} = [a_1 \ \dots \ a_n]^\top$ e $\mathbf{x} = [x_1 \ \dots \ x_n]^\top$, temos

$$L(\mathbf{x}) = \mathbf{a}^\top \mathbf{x} = a_1 x_1 + \dots + a_n x_n.$$

Assim,

$$\frac{\partial L}{\partial x_i}(\mathbf{x}) = a_i, \quad i = 1, \dots, n,$$

Resultado 3.3

e, portanto,

$$\nabla L(\mathbf{x}) = \begin{bmatrix} a_1 \\ \vdots \\ a_n \end{bmatrix} = \mathbf{a}. \quad \square$$

Exemplo 3.8: Derivada de uma forma linear

Considere a forma linear $L : \mathbb{R}^3 \rightarrow \mathbb{R}$ dada por

$$L(\mathbf{x}) = 2x_1 - 3x_2 + 5x_3.$$

Calcule $\nabla L(\mathbf{x})$.

SOLUÇÃO:

Escrevendo $L(\mathbf{x}) = \begin{bmatrix} 2 & -3 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$, temos, pelo Resultado 3.3,

$$\nabla L(\mathbf{x}) = \begin{bmatrix} 2 \\ -3 \\ 5 \end{bmatrix}.$$

Observe que o gradiente não depende de $\mathbf{x}$: no caso de formas lineares, a derivada é um vetor constante. $\square$

Agora passamos para formas quadráticas.

Resultado 3.4: Derivada de uma forma quadrática

Seja $\mathbf{A} \in \mathbb{R}^{n \times n}$ uma matriz quadrada e seja $Q : \mathbb{R}^n \rightarrow \mathbb{R}$ a forma quadrática associada,

$$Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}.$$

Então, para todo $\mathbf{x} \in \mathbb{R}^n$,

$$\nabla Q(\mathbf{x}) = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x}.$$

Resultado 3.4

Em particular, se $\mathbf{A}$ é simétrica, $\mathbf{A} = \mathbf{A}^\top$, obtemos

$$\nabla Q(\mathbf{x}) = 2\mathbf{A}\mathbf{x}.$$

DEMONSTRAÇÃO:

Escreva $\mathbf{A} = (a_{ij})_{1 \leq i, j \leq n}$ e $\mathbf{x} = [x_1 \ \dots \ x_n]^\top$. Pelo Resultado 3.1, temos

$$Q(\mathbf{x}) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} x_i x_j.$$

Fixando $k \in \{1, \dots, n\}$ e derivando em relação a x_k , obtemos

$$\frac{\partial Q}{\partial x_k}(\mathbf{x}) = \sum_{j=1}^n a_{kj} x_j + \sum_{i=1}^n a_{ik} x_i = (\mathbf{A}\mathbf{x})_k + (\mathbf{A}^\top \mathbf{x})_k.$$

Logo

$$\nabla Q(\mathbf{x}) = \mathbf{A}\mathbf{x} + \mathbf{A}^\top \mathbf{x} = (\mathbf{A} + \mathbf{A}^\top)\mathbf{x}.$$

Se $\mathbf{A}$ é simétrica, temos $\mathbf{A}^\top = \mathbf{A}$ e $\nabla Q(\mathbf{x}) = 2\mathbf{A}\mathbf{x}$. $\square$

Exemplo 3.9: Derivada de uma forma quadrática

Considere a matriz simétrica

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix}$$

e a forma quadrática associada $Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x}$, com $\mathbf{x} = [x_1 \ x_2]^\top$. Calcule $\nabla Q(\mathbf{x})$.

SOLUÇÃO:

Pelo Resultado 3.3, como $\mathbf{A}$ é simétrica, vale

$$\nabla Q(\mathbf{x}) = 2\mathbf{A}\mathbf{x}.$$

Assim,

$$\nabla Q(\mathbf{x}) = 2 \begin{bmatrix} 2 & 1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 2 \begin{bmatrix} 2x_1 + x_2 \\ x_1 + 3x_2 \end{bmatrix} = \begin{bmatrix} 4x_1 + 2x_2 \\ 2x_1 + 6x_2 \end{bmatrix}.$$

Exemplo 3.9

Se quisermos conferir, podemos escrever explicitamente

$$Q(\mathbf{x}) = 2x_1^2 + 2x_1x_2 + 3x_2^2$$

e calcular as derivadas parciais:

$$\frac{\partial Q}{\partial x_1} = 4x_1 + 2x_2, \quad \frac{\partial Q}{\partial x_2} = 2x_1 + 6x_2,$$

o que confirma o resultado anterior.

Um segundo objeto importante no estudo de formas quadráticas é a matriz de segundas derivadas, conhecida como *Hessiana*.

Definição 3.5: Hessiana

Seja $f : \mathbb{R}^n \rightarrow \mathbb{R}$ uma função duas vezes diferenciável. A *Hessiana* de f no ponto $\mathbf{x}$ é a matriz

$$\nabla^2 f(\mathbf{x}) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n}(\mathbf{x}) \\ \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1}(\mathbf{x}) & \cdots & \frac{\partial^2 f}{\partial x_n^2}(\mathbf{x}) \end{bmatrix}.$$

No caso de formas quadráticas, a Hessiana tem uma forma particularmente simples: se $Q(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x}$ com $\mathbf{A}$ simétrica, então $\nabla^2 Q(\mathbf{x}) = 2\mathbf{A}$, independente de $\mathbf{x}$. A relação entre a definitude de $\mathbf{A}$ e o tipo de ponto crítico de Q (mínimo, máximo ou sela) é um tópico importante em Otimização e se conecta diretamente com as classificações vistas anteriormente.

3.4 Aplicação das derivadas de formas lineares e quadráticas em regressão linear múltipla

Voltamos agora ao problema de regressão linear múltipla. Suponha que temos uma resposta y e p variáveis explicativas, observadas em n unidades amostrais. Em notação

matricial, podemos escrever o modelo como

$$\mathbf{y} = \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\varepsilon},$$

em que $\mathbf{y} \in \mathbb{R}^n$ é o vetor de respostas, $\mathbf{X} \in \mathbb{R}^{n \times p}$ é a matriz de projeto (contendo as covariáveis), $\boldsymbol{\beta} \in \mathbb{R}^p$ é o vetor de parâmetros e $\boldsymbol{\varepsilon} \in \mathbb{R}^n$ é o vetor de erros.

O método dos mínimos quadrados busca o vetor $\hat{\boldsymbol{\beta}}$ que minimiza a soma dos quadrados dos resíduos,

$$Q(\boldsymbol{\beta}) = \|\mathbf{y} - \mathbf{X}\boldsymbol{\beta}\|^2 = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}).$$

Observe que $Q(\boldsymbol{\beta})$ é uma forma quadrática em $\boldsymbol{\beta}$. Vamos usar os resultados da seção anterior para encontrar o ponto em que essa função atinge seu mínimo.

Resultado 3.5: Equações normais e estimador de mínimos quadrados

Considere a função

$$Q(\boldsymbol{\beta}) = (\mathbf{y} - \mathbf{X}\boldsymbol{\beta})^\top (\mathbf{y} - \mathbf{X}\boldsymbol{\beta}), \quad \boldsymbol{\beta} \in \mathbb{R}^p.$$

(a) O gradiente de Q é dado por

$$\nabla Q(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

(b) Qualquer ponto crítico $\hat{\boldsymbol{\beta}}$ de Q (isto é, que satisfaz $\nabla Q(\hat{\boldsymbol{\beta}}) = \mathbf{0}$) verifica as equações normais

$$\mathbf{X}^\top \mathbf{X}\hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y}.$$

(c) Se $\mathbf{X}^\top \mathbf{X}$ é definida positiva (ou seja, inversível), então o ponto crítico é único e dado por

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y},$$

que é o estimador de mínimos quadrados em regressão linear múltipla.

DEMONSTRAÇÃO:

Começamos expandindo $Q(\boldsymbol{\beta})$:

$$Q(\boldsymbol{\beta}) = \mathbf{y}^\top \mathbf{y} - 2\mathbf{y}^\top \mathbf{X}\boldsymbol{\beta} + \boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X}\boldsymbol{\beta}.$$

O primeiro termo $\mathbf{y}^\top \mathbf{y}$ não depende de $\boldsymbol{\beta}$, logo sua derivada é nula.

Resultado 3.5

No segundo termo, usando o Resultado 3.3 e a identidade $\mathbf{y}^\top \mathbf{X} \boldsymbol{\beta} = (\mathbf{X}^\top \mathbf{y})^\top \boldsymbol{\beta}$, obtemos

$$\nabla_{\boldsymbol{\beta}}(-2\mathbf{y}^\top \mathbf{X} \boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y}.$$

No terceiro termo, escrevemos $\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta} = \boldsymbol{\beta}^\top \mathbf{A} \boldsymbol{\beta}$ com $\mathbf{A} = \mathbf{X}^\top \mathbf{X}$, que é simétrica. Pelo Resultado 3.3,

$$\nabla_{\boldsymbol{\beta}}(\boldsymbol{\beta}^\top \mathbf{X}^\top \mathbf{X} \boldsymbol{\beta}) = 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta}.$$

Somando essas contribuições, obtemos

$$\nabla Q(\boldsymbol{\beta}) = -2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \boldsymbol{\beta},$$

o que prova o item (a).

Para encontrar os pontos críticos, igualamos o gradiente a zero:

$$-2\mathbf{X}^\top \mathbf{y} + 2\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{0},$$

ou, equivalentemente,

$$\mathbf{X}^\top \mathbf{X} \hat{\boldsymbol{\beta}} = \mathbf{X}^\top \mathbf{y},$$

que são as equações normais, provando o item (b).

Se $\mathbf{X}^\top \mathbf{X}$ é definida positiva, então é inversível. Nesse caso, as equações normais têm solução única,

$$\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}.$$

Além disso, como Q é uma forma quadrática associada a uma matriz definida positiva (a Hessiana de Q em relação a $\boldsymbol{\beta}$ é $2\mathbf{X}^\top \mathbf{X}$), esse ponto crítico é necessariamente um mínimo global. $\square$

Exemplo 3.10: Interpretação geométrica

Mostre que, quando $\mathbf{X}^\top \mathbf{X}$ é definida positiva, o vetor de predições $\hat{\mathbf{y}} = \mathbf{X} \hat{\boldsymbol{\beta}}$ pode ser interpretado como a *projeção ortogonal* de $\mathbf{y}$ sobre o subespaço gerado pelas colunas de $\mathbf{X}$.

Exemplo 3.10SOLUÇÃO:

Pelas equações normais,

$$\mathbf{X}^\top(\mathbf{y} - \mathbf{X}\hat{\boldsymbol{\beta}}) = \mathbf{0},$$

isto é,

$$\mathbf{X}^\top(\mathbf{y} - \hat{\mathbf{y}}) = \mathbf{0}.$$

Isso significa que o vetor de resíduos $\mathbf{e} = \mathbf{y} - \hat{\mathbf{y}}$ é ortogonal a todas as colunas de $\mathbf{X}$, logo é ortogonal ao subespaço coluna de $\mathbf{X}$. Portanto, $\hat{\mathbf{y}}$ é a projeção ortogonal de $\mathbf{y}$ nesse subespaço. Essa interpretação geométrica reforça a ideia de que o método dos mínimos quadrados escolhe, entre todos os vetores da forma $\mathbf{X}\boldsymbol{\beta}$, aquele que fica mais próximo de $\mathbf{y}$ em norma euclidiana.

Dessa forma, as derivadas de formas lineares e quadráticas fornecem uma ponte natural entre a teoria de matrizes e a regressão linear múltipla: de um lado, a forma da função objetivo de mínimos quadrados; de outro, as propriedades de definitude da matriz $\mathbf{X}^\top \mathbf{X}$ garantem a existência e unicidade da solução, além de permitir uma interpretação geométrica clara em termos de projeções em subespaços vetoriais.

3.5 Exercícios

1. Determine o domínio, contradomínio e a lei da **forma quadrática** associada às seguintes **matrizes simétricas**.

$$(a) \mathbf{A} = \begin{bmatrix} 9 & -2 \\ -2 & 6 \end{bmatrix}.$$

$$(b) \mathbf{A} = \begin{bmatrix} -2 & 2 \\ 2 & 0 \end{bmatrix}.$$

$$(c) \mathbf{A} = \begin{bmatrix} 0 & 2 & -4 \\ 2 & 0 & 10 \\ -4 & 10 & 0 \end{bmatrix}.$$

$$(d) \mathbf{A} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix}.$$

$$(e) \mathbf{A} = \begin{bmatrix} 3 & 0 & 2 & 2 \\ 0 & 1 & 1 & 0 \\ 2 & 1 & 9 & -2 \\ 2 & 0 & -2 & 4 \end{bmatrix}.$$

2. Determine as **matrizes simétricas** $\mathbf{A}$ associadas às seguintes **formas quadráticas**.

$$(a) Q: \mathbb{R}^3 \rightarrow \mathbb{R} \text{ tal que } Q(\mathbf{x}) = 2x_1^2 - 2x_1x_2 + x_2^2 + 4x_1x_3 + x_3^2.$$

$$(b) Q: \mathbb{R}^4 \rightarrow \mathbb{R} \text{ tal que } Q(\mathbf{x}) = 3(x_1^2 + x_2^2 + x_3^2 + x_4^2).$$

(c) $Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = -x_1x_2$.

(d) $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = 25x_1^2 - 4x_1x_2 + 8x_1x_3 + 4x_2^2 + 2x_2x_3 + 9x_3^2$.

3. Sem utilizar o **critério de Sylvester** mostre que as **matrizes simétricas** $\mathbf{A}$ definidas a seguir são **positiva definidas**.

$$(a) \mathbf{A} = \begin{bmatrix} 6 & 0 & 0 & 0 \\ 0 & 4 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 9 \end{bmatrix} \quad (b) \mathbf{A} = \begin{bmatrix} 2 & -1 \\ -1 & 1 \end{bmatrix} \quad (c) \mathbf{A} = \begin{bmatrix} 2 & 2 & 2 \\ 2 & 3 & 2 \\ 2 & 2 & 4 \end{bmatrix}.$$

4. Use o **critério de Sylvester** para verificar se as **matrizes simétricas** $\mathbf{A}$ associadas às seguintes **formas quadráticas** são **positivas definidas**.

(a) $Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = x_1^2 - 2x_1x_2 + x_2^2$.

(b) $Q : \mathbb{R}^2 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = x_1^2 - 2x_2^2$.

(c) $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = 12x_1^2 + 8x_1x_2 + 6x_1x_3 + 2x_2^2 - 2x_2x_3 + 7x_3^2$.

(d) $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = 20x_1^2 + 8x_1x_2 + 10x_1x_3 + 2x_2^2 + 6x_2x_3 + 5x_3^2$.

5. (a) Verifique que **todas** as **matrizes positivas definidas** obtidas nos Exercícios 3 e 4 possuem os elementos da diagonal principal **todos** positivos.

(b) Quais dentre as matrizes obtidas no Exercício 4 possuem os elementos da diagonal principal **todos** positivos, mas não é positiva definida?

(c) Verifique que **todas** as matrizes do Exercício 4 que não são positivas definidas possuem **algum** dos elementos da diagonal principal menores ou igual à zero.

6. Mostre que se $\mathbf{A}$ é uma **matriz positiva definida** de ordem $n \times n$, então os elementos da diagonal principal de $\mathbf{A}$ são **todos** positivos.

7. Determine a **derivada** das seguintes **formas lineares**.

(a) $F : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que $F(\mathbf{x}) = x + 2y - z$.

(b) $F : \mathbb{R}^5 \rightarrow \mathbb{R}$ tal que $F(\mathbf{x}) = \sum_{i=1}^5 2i^2 x_i$.

(c) $F : \mathbb{R}^{500} \rightarrow \mathbb{R}$ tal que $F(\mathbf{x}) = 0$.

(d) $F : \mathbb{R}^{900} \rightarrow \mathbb{R}$ tal que $F(\mathbf{x}) = \sum_{i=1}^{100} x_i$.

8. Determine a **derivada** das seguintes **formas quadráticas**.

(a) $Q : \mathbb{R}^3 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = 2xy + 4xz + 8yz$.

(b) $Q : \mathbb{R}^5 \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = x_1^2 - x_1x_3 + x_5^2$.

(c) $Q : \mathbb{R}^{500} \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = 0$.

(d) $Q : \mathbb{R}^{900} \rightarrow \mathbb{R}$ tal que $Q(\mathbf{x}) = \sum_{i=1}^{100} x_i^2$.

9. (a) Seja $g : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$g(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x} + \mathbf{b}^\top \mathbf{x},$$

em que $\mathbf{A} \in M_n(\mathbb{R})$ é uma **matriz simétrica** e $\mathbf{b} \in \mathbb{R}^n$. Determine $\frac{\partial g}{\partial \mathbf{x}}$.

(b) Seja $h : \mathbb{R}^n \rightarrow \mathbb{R}$ tal que

$$h(\mathbf{x}) = \mathbf{x}^\top \mathbf{A}\mathbf{x} + \mathbf{b}^\top \mathbf{x} + c,$$

em que $\mathbf{A} \in M_n(\mathbb{R})$ é uma **matriz simétrica**, $\mathbf{b} \in \mathbb{R}^n$ e $c \in \mathbb{R}$. Determine $\frac{\partial h}{\partial \mathbf{x}}$ e, em seguida, $\frac{\partial^2 h}{\partial \mathbf{x} \partial \mathbf{x}^\top}$.

10. Sejam $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ vetores do $\mathbb{R}^n$, $\boldsymbol{\mu}$ um vetor de $\mathbb{R}^p$ e $\boldsymbol{\Sigma}$ uma **matriz simétrica inversível** de $M_p(\mathbb{R})$. Determine o valor de $\boldsymbol{\mu} \in \mathbb{R}^p$ que **maximiza** a função $\ell : \mathbb{R}^p \rightarrow \mathbb{R}$ tal que

$$\ell(\boldsymbol{\mu}) = -\frac{np}{2} \log(2\pi) - \frac{n}{2} \log |\boldsymbol{\Sigma}| - \frac{1}{2} \sum_{i=1}^n (\mathbf{x}_i - \boldsymbol{\mu})^\top \boldsymbol{\Sigma}^{-1} (\mathbf{x}_i - \boldsymbol{\mu}),$$

em que $|\boldsymbol{\Sigma}|$ denota o determinante de $\boldsymbol{\Sigma}$.

4 Decomposição de matrizes

“A beleza da matemática só se mostra aos seguidores mais pacientes.”

Maryam Mirzakhani (1997 – 2017)

Ao longo destas notas vimos que as matrizes aparecem naturalmente sempre que representamos transformações lineares e organizamos conjuntos de dados em Estatística. De modo geral, decompor uma matriz significa escrevê-la como a combinação de outras matrizes mais simples, dotadas de propriedades que nos interessam; exemplos clássicos são as decomposições LU e de Choleskey, usadas para facilitar o cálculo de determinantes, o cálculo da matriz inversa e para melhorar a estabilidade numérica dos algoritmos. Na Estatística, tais decomposições surgem no cálculo de estimadores de mínimos quadrados, na fatoração de matrizes de variâncias e covariâncias (em geral, matrizes definidas positivas) e em métodos multivariados, como a Análise de Componentes Principais. Neste capítulo, aprofundaremos essa ideia estudando, em particular, a decomposição espectral de matrizes simétricas e a decomposição em valores singulares, que fornecem descrições geométricas muito claras de como uma transformação linear alonga, contrai ou distorce o espaço em diferentes direções.

4.1 Autovalores e autovetores

Vamos iniciar este capítulo, revisando algumas noções importantes sobre autovalores e autovetores.

Definição 4.1: Autovalores e autovetores de uma transformação linear

Seja $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ uma transformação linear. Dizemos que um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ é um *autovetor* de F se existir um escalar $\lambda \in \mathbb{R}$ tal que

$$F(\mathbf{x}) = \lambda \mathbf{x}.$$

Nesse caso, o escalar λ é denominado *autovalor* (associado ao autovetor $\mathbf{x}$) da transformação linear F .

Um autovetor é um vetor não nulo que, ao ser transformado por uma transformação linear F de um espaço em si mesmo, é apenas multiplicado por um escalar: seu tamanho é alterado (e, se o escalar for negativo, o sentido é invertido), mas a direção é preservada.

Quando o escalar é zero, o vetor é enviado para a origem, e dizemos que o autovalor correspondente é zero.

Exemplo 4.1

Verifique que os vetores

$$\mathbf{x}_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

são autovetores do operador linear $F : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ tal que

$$F\left(\begin{bmatrix} x \\ y \end{bmatrix}\right) = \begin{bmatrix} x \\ 2y \end{bmatrix}.$$

Em seguida, determine os autovalores associados.

SOLUÇÃO:

Para o vetor $\mathbf{x}_1$, temos

$$F(\mathbf{x}_1) = F\left(\begin{bmatrix} 0 \\ 1 \end{bmatrix}\right) = \begin{bmatrix} 0 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 2 \mathbf{x}_1.$$

Logo, $\mathbf{x}_1$ é autovetor de F com autovalor associado $\lambda_1 = 2$.

Para o vetor $\mathbf{x}_2$, obtemos

$$F(\mathbf{x}_2) = F\left(\begin{bmatrix} 1 \\ 0 \end{bmatrix}\right) = \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 1 \begin{bmatrix} 1 \\ 0 \end{bmatrix} = 1 \mathbf{x}_2.$$

Assim, $\mathbf{x}_2$ é autovetor de F com autovalor associado $\lambda_2 = 1$.

A partir da Definição 4.1, podemos descrever autovalores e autovetores em termos da matriz associada a uma transformação linear. De fato, seja $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$ uma transformação linear e seja $\mathbf{A}$ a matriz quadrada de ordem $n \times n$ associada a F na base canônica, isto é,

$$F(\mathbf{x}) = \mathbf{A}\mathbf{x} \quad \text{para todo } \mathbf{x} \in \mathbb{R}^n.$$

Pela Definição 4.1, um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ é um autovetor de F se existir $\lambda \in \mathbb{R}$ tal que $F(\mathbf{x}) = \lambda\mathbf{x}$. Substituindo $F(\mathbf{x})$ por $\mathbf{A}\mathbf{x}$, obtemos a equivalência

$$F(\mathbf{x}) = \lambda\mathbf{x} \iff \mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Isso mostra que a condição de ser autovetor de F pode ser escrita diretamente em termos da matriz $\mathbf{A}$. Essa observação motiva a definição a seguir.

Definição 4.2: Autovalores e autovetores de uma matriz

Seja $\mathbf{A}$ a matriz quadrada de ordem $n \times n$ associada à transformação linear $F : \mathbb{R}^n \rightarrow \mathbb{R}^n$. Um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ é dito um *autovetor* de $\mathbf{A}$ quando

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$$

para algum $\lambda \in \mathbb{R}$. Nesse caso, o escalar λ é dito um *autovalor* de $\mathbf{A}$ (associado ao autovetor $\mathbf{x}$).

Exemplo 4.2

Verifique que os vetores

$$\mathbf{x}_1 = \begin{bmatrix} -2 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

são autovetores da matriz quadrada $\mathbf{A}$ de ordem 2×2 ,

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix}.$$

Em seguida, determine os autovalores associados.

SOLUÇÃO:

Para o vetor $\mathbf{x}_1$, temos

$$\mathbf{A}\mathbf{x}_1 = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} -2 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \cdot (-2) + 0 \cdot 1 \\ 1 \cdot (-2) + 3 \cdot 1 \end{bmatrix} = \begin{bmatrix} -2 \\ 1 \end{bmatrix} = 1 \begin{bmatrix} -2 \\ 1 \end{bmatrix} = 1 \mathbf{x}_1.$$

Logo, $\mathbf{x}_1$ é autovetor de $\mathbf{A}$ com autovalor associado $\lambda_1 = 1$.

Para o vetor $\mathbf{x}_2$, obtemos

$$\mathbf{A}\mathbf{x}_2 = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix} = 3 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = 3 \mathbf{x}_2.$$

Assim, $\mathbf{x}_2$ é autovetor de $\mathbf{A}$ com autovalor associado $\lambda_2 = 3$.

Note que, no Exemplo 1.2, outros vetores também são autovetores associados aos mesmos autovalores. Por exemplo,

$$\mathbf{x}'_1 = \begin{bmatrix} -4 \\ 2 \end{bmatrix} = 2 \begin{bmatrix} -2 \\ 1 \end{bmatrix} = 2 \mathbf{x}_1 \quad \text{satisfaz} \quad \mathbf{A}\mathbf{x}'_1 = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} -4 \\ 2 \end{bmatrix} = \begin{bmatrix} -4 \\ 2 \end{bmatrix} = 1 \mathbf{x}'_1,$$

isto é, $\mathbf{x}'_1$ é também autovetor de $\mathbf{A}$ associado ao autovalor $\lambda_1 = 1$. De modo análogo,

$$\mathbf{x}'_2 = \begin{bmatrix} 0 \\ -5 \end{bmatrix} = -5 \begin{bmatrix} 0 \\ 1 \end{bmatrix} = -5 \mathbf{x}_2 \quad \text{satisfaz} \quad \mathbf{A}\mathbf{x}'_2 = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 0 \\ -5 \end{bmatrix} = \begin{bmatrix} 0 \\ -15 \end{bmatrix} = 3 \begin{bmatrix} 0 \\ -5 \end{bmatrix} = 3 \mathbf{x}'_2,$$

de forma que $\mathbf{x}'_2$ é autovetor associado ao autovalor $\lambda_2 = 3$.

Esse comportamento é geral: se $\mathbf{x}$ é um autovetor de uma matriz $\mathbf{A}$ associado ao autovalor λ , então todo múltiplo escalar não nulo $c\mathbf{x}$, com $c \neq 0$, também é autovetor associado ao mesmo autovalor, pois

$$\mathbf{A}(c\mathbf{x}) = c\mathbf{A}\mathbf{x} = c\lambda\mathbf{x} = \lambda(c\mathbf{x}).$$

O conjunto de todos os autovetores associados a λ , juntamente com o vetor nulo, forma um subespaço vetorial de $\mathbb{R}^n$, chamado de *autoespaço* de λ .

Pela definição de autovalor e autovetor, um escalar $\lambda \in \mathbb{R}$ é autovalor de uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$ se, e somente se, existir um vetor não nulo $\mathbf{x} \in \mathbb{R}^n$ tal que

$$\mathbf{A}\mathbf{x} = \lambda\mathbf{x}.$$

Essa igualdade pode ser reescrita como

$$(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0},$$

ou seja, $\mathbf{x}$ é solução não trivial do sistema homogêneo $(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$. Logo, para que λ seja um autovalor de $\mathbf{A}$, é necessário e suficiente que o sistema acima tenha soluções não nulas, o que ocorre exatamente quando a matriz $\mathbf{A} - \lambda\mathbf{I}_n$ não é inversível. Como vimos em capítulos anteriores, isso equivale a dizer que o determinante dessa matriz é nulo, i.e.,

$$\det(\mathbf{A} - \lambda\mathbf{I}_n) = 0.$$

Portanto, os autovalores de $\mathbf{A}$ são precisamente as raízes do polinômio $\det(\mathbf{A} - \lambda\mathbf{I}_n)$ em relação a λ .

Definição 4.3: Polinômio característico

Dada uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$, chama-se *polinômio característico* de $\mathbf{A}$ o seguinte polinômio de grau n

$$P_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_n),$$

em que $\mathbf{I}_n$ é a matriz identidade de ordem $n \times n$ e $\lambda \in \mathbb{R}$. As raízes de $P_{\mathbf{A}}(\lambda)$ são os autovalores da matriz $\mathbf{A}$.

Resultado 4.1: Caracterização de autovalores

Sejam n um número inteiro positivo, $\mathbf{A}$ uma matriz quadrada de ordem $n \times n$ e λ^* um número real. As seguintes afirmações são equivalentes:

1. λ^* é um *autovalor* de $\mathbf{A}$.
2. λ^* é solução da equação polinomial $P_{\mathbf{A}}(\lambda) = 0$, isto é,

$$P_{\mathbf{A}}(\lambda^*) = \det(\mathbf{A} - \lambda^* \mathbf{I}_n) = 0,$$

em que $\mathbf{I}_n$ denota a matriz identidade de ordem $n \times n$.

3. O sistema de equações lineares

$$(\mathbf{A} - \lambda^* \mathbf{I}_n) \mathbf{u} = \mathbf{0}_n$$

possui solução não trivial, em que $\mathbf{0}_n$ denota o vetor nulo de ordem $n \times 1$.

Observe que esse resultado já foi, essencialmente, demonstrado na discussão anterior: partindo da definição de autovetor $\mathbf{A}\mathbf{x} = \lambda\mathbf{x}$ com $\mathbf{x} \neq \mathbf{0}$, reescrevemos a igualdade como $(\mathbf{A} - \lambda\mathbf{I}_n)\mathbf{x} = \mathbf{0}$, concluindo que o sistema tem solução não trivial se, e somente se, $\det(\mathbf{A} - \lambda\mathbf{I}_n) = 0$. Assim, as raízes do polinômio característico $P_{\mathbf{A}}(\lambda)$ são exatamente os autovalores de $\mathbf{A}$.

Exemplo 4.3

Para cada uma das matrizes abaixo, determine:

- o polinômio característico;
- os autovalores;
- o autoespaço associado a cada autovalor;
- um autovetor *unitário* correspondente a cada autovalor.

$$(a) \mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix}.$$

$$(b) \mathbf{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix}.$$

$$(c) \mathbf{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix}.$$

SOLUÇÃO:

- (a) • **Polinômio característico:**

$$P_{\mathbf{A}}(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_n) = \begin{vmatrix} 1 - \lambda & 0 \\ 1 & 3 - \lambda \end{vmatrix} = (1 - \lambda)(3 - \lambda).$$

- **Autovalores:** Os autovalores são as raízes de $P_{\mathbf{A}}(\lambda)$, logo $\lambda_1 = 1$ e $\lambda_2 = 3$.
- **Autoespaço associado ao autovalor $\lambda_1 = 1$:** O autoespaço em questão é o conjunto

$$V(1) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_1 \mathbf{x} \right\}.$$

Como

Exemplo 4.3

$$\mathbf{A}\mathbf{x} = \lambda_1\mathbf{x} \Rightarrow \mathbf{A}\mathbf{x} = \mathbf{x}$$

$$\Rightarrow \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

$$\Rightarrow \begin{cases} x_1 & = x_1, \\ x_1 + 3x_2 & = x_2 \end{cases} \Rightarrow \begin{cases} x_1 & = t, \quad t \in \mathbb{R}, \\ x_2 & = -\frac{t}{2}, \quad t \in \mathbb{R}. \end{cases}$$

Portanto,

$$V(1) = \left\{ \begin{bmatrix} t \\ -t/2 \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ -1/2 \end{bmatrix} \right\}.$$

- **Autovetor unitário** $\lambda_1 = 1$: $\mathbf{e}_1 = \sqrt{\frac{4}{5}} \begin{bmatrix} 1 \\ -1/2 \end{bmatrix}$.
- **Autoespaço associado ao autovalor** $\lambda_2 = 3$: O autoespaço em questão é o conjunto

$$V(3) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_2\mathbf{x} \right\}.$$

$$\mathbf{A}\mathbf{x} = \lambda_2\mathbf{x} \Rightarrow \mathbf{A}\mathbf{x} = 3\mathbf{x}$$

$$\Rightarrow \begin{bmatrix} 1 & 0 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 3x_1 \\ 3x_2 \end{bmatrix}$$

$$\Rightarrow \begin{cases} x_1 & = 3x_1, \\ x_1 + 3x_2 & = 3x_2 \end{cases} \Rightarrow \begin{cases} x_1 & = 0, \\ x_2 & = t, \quad t \in \mathbb{R}. \end{cases}$$

Portanto,

$$V(3) = \left\{ \begin{bmatrix} 0 \\ t \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 0 \\ 1 \end{bmatrix} \right\}.$$

- **Autovetor unitário associado com** $\lambda_2 = 3$: $\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$.

Exemplo 4.3

- (b) • **Polinômio característico:**

$$P_A(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_3) = \begin{vmatrix} 2 - \lambda & 0 & 0 \\ 0 & 2 - \lambda & 0 \\ 0 & 0 & 6 - \lambda \end{vmatrix} = (2 - \lambda)^2(6 - \lambda).$$

- **Autovalores:** Os autovalores são as raízes de $P_A(\lambda)$, logo

$$\lambda_1 = 2 \text{ (com multiplicidade 2)} \quad \text{e} \quad \lambda_2 = 6.$$

- **Autoespaço associado ao autovalor $\lambda_1 = 2$:** O autoespaço em questão é o conjunto

$$V(2) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_1 \mathbf{x} \right\}.$$

Temos

$$\begin{aligned} \mathbf{A}\mathbf{x} = \lambda_1 \mathbf{x} &\Rightarrow \mathbf{A}\mathbf{x} = 2\mathbf{x} \\ &\Rightarrow \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2x_1 \\ 2x_2 \\ 2x_3 \end{bmatrix} \\ &\Rightarrow \begin{cases} 2x_1 = 2x_1, \\ 2x_2 = 2x_2, \\ 6x_3 = 2x_3, \end{cases} \Rightarrow \begin{cases} x_1 = s, & s \in \mathbb{R}, \\ x_2 = t, & t \in \mathbb{R}, \\ x_3 = 0, \end{cases} \end{aligned}$$

com s e t não sendo iguais a zero simultaneamente. Portanto,

$$V(2) = \left\{ \begin{bmatrix} s \\ t \\ 0 \end{bmatrix} : s, t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\}.$$

- **Autovetores unitários associados a $\lambda_1 = 2$:** podemos tomar

Exemplo 4.3

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix},$$

que já são ortogonais entre si e têm norma igual a 1.

- **Autoespaço associado ao autovalor $\lambda_2 = 6$:**

$$V(6) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_2 \mathbf{x} \right\}.$$

Temos

$$\mathbf{A}\mathbf{x} = \lambda_2 \mathbf{x} \Rightarrow \mathbf{A}\mathbf{x} = 6\mathbf{x}$$

$$\begin{aligned} \Rightarrow \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} &= \begin{bmatrix} 6x_1 \\ 6x_2 \\ 6x_3 \end{bmatrix} \\ \Rightarrow \begin{cases} 2x_1 = 6x_1, \\ 2x_2 = 6x_2, \\ 6x_3 = 6x_3, \end{cases} &\Rightarrow \begin{cases} x_1 = 0, \\ x_2 = 0, \\ x_3 = t, \end{cases} \quad t \in \mathbb{R}^*. \end{aligned}$$

Portanto,

$$V(6) = \left\{ \begin{bmatrix} 0 \\ 0 \\ t \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

- **Autovetor unitário associado a $\lambda_2 = 6$:**

$$\mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

- (c) • **Polinômio característico:**

Exemplo 4.3

(c)

$$P_A(\lambda) = \det(\mathbf{A} - \lambda \mathbf{I}_3) = \begin{vmatrix} 2 - \lambda & 0 & 0 \\ 0 & -4 - \lambda & 0 \\ 0 & 0 & 6 - \lambda \end{vmatrix} = (2 - \lambda)(-4 - \lambda)(6 - \lambda).$$

- **Autovalores:** Os autovalores são as raízes de $P_A(\lambda)$, logo

$$\lambda_1 = 2, \quad \lambda_2 = -4, \quad \lambda_3 = 6.$$

- **Autoespaço associado ao autovalor $\lambda_1 = 2$:**

$$V(2) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_1 \mathbf{x} \right\}.$$

Temos

$$\mathbf{A}\mathbf{x} = \lambda_1 \mathbf{x} \Rightarrow \mathbf{A}\mathbf{x} = 2\mathbf{x}$$

$$\begin{aligned} \Rightarrow \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} &= \begin{bmatrix} 2x_1 \\ 2x_2 \\ 2x_3 \end{bmatrix} \\ \Rightarrow \begin{cases} 2x_1 = 2x_1, \\ -4x_2 = 2x_2, \\ 6x_3 = 2x_3, \end{cases} &\Rightarrow \begin{cases} x_1 = t, & t \in \mathbb{R}^*, \\ x_2 = 0, \\ x_3 = 0. \end{cases} \end{aligned}$$

Portanto,

$$V(2) = \left\{ \begin{bmatrix} t \\ 0 \\ 0 \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \right\}.$$

- **Autovetor unitário associado a $\lambda_1 = 2$:**

$$\mathbf{e}_1 = \begin{bmatrix} 1 & 0 & 0 \end{bmatrix}^\top.$$

Exemplo 4.3

- Autoespaço associado ao autovalor $\lambda_2 = -4$:

$$V(-4) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_2 \mathbf{x} \right\}.$$

Temos

$$\begin{aligned} \mathbf{A}\mathbf{x} = \lambda_2 \mathbf{x} &\Rightarrow \mathbf{A}\mathbf{x} = -4\mathbf{x} \\ \Rightarrow \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} &= \begin{bmatrix} -4x_1 \\ -4x_2 \\ -4x_3 \end{bmatrix} \\ \Rightarrow \begin{cases} 2x_1 = -4x_1, \\ -4x_2 = -4x_2, \\ 6x_3 = -4x_3, \end{cases} &\Rightarrow \begin{cases} x_1 = 0, \\ x_2 = t, \\ x_3 = 0. \end{cases} \quad t \in \mathbb{R}^*, \end{aligned}$$

Portanto,

$$V(-4) = \left\{ \begin{bmatrix} 0 \\ t \\ 0 \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \right\}.$$

- Autovetor unitário associado a $\lambda_2 = -4$:

$$\mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

- Autoespaço associado ao autovalor $\lambda_3 = 6$:

$$V(6) = \left\{ \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} : \mathbf{A}\mathbf{x} = \lambda_3 \mathbf{x} \right\}.$$

Temos

$$\mathbf{A}\mathbf{x} = \lambda_3 \mathbf{x} \Rightarrow \mathbf{A}\mathbf{x} = 6\mathbf{x}$$

Exemplo 4.3

Temos

$$\Rightarrow \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 6x_1 \\ 6x_2 \\ 6x_3 \end{bmatrix}$$

$$\Rightarrow \begin{cases} 2x_1 = 6x_1, \\ -4x_2 = 6x_2, \\ 6x_3 = 6x_3, \end{cases} \Rightarrow \begin{cases} x_1 = 0, \\ x_2 = 0, \\ x_3 = t, \quad t \in \mathbb{R}^*. \end{cases}$$

Portanto,

$$V(6) = \left\{ \begin{bmatrix} 0 \\ 0 \\ t \end{bmatrix} : t \in \mathbb{R} \right\} = \text{span} \left\{ \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}.$$

- **Autovetor unitário associado a $\lambda_3 = 6$:**

$$\mathbf{e}_3 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Quando o autoespaço associado a um autovalor λ tem dimensão 1, os autovetores correspondentes são únicos a menos de múltiplos escalares; já quando a dimensão é maior que 1, o autoespaço contém infinitos autovetores associados ao mesmo autovalor (e, portanto, infinitas direções possíveis), mas qualquer conjunto de autovetores linearmente independentes desse autoespaço tem, no máximo, $\dim V(\lambda)$ vetores. Em termos de dimensão, o número de autovetores *geradores* (isto é, o número de vetores em uma base) do autoespaço de λ é igual à *multiplicidade geométrica* desse autovalor. Por definição, a multiplicidade geométrica de λ é precisamente a dimensão do autoespaço $V(\lambda)$. Em geral, a multiplicidade geométrica é menor ou igual à multiplicidade algébrica (a multiplicidade da raiz no polinômio característico); no caso particular de matrizes simétricas reais, essas duas multiplicidades coincidem, o que garante que sempre podemos escolher um número de autovetores linearmente independentes igual à multiplicidade algébrica de λ .

Exemplo 4.4: Autovalor nulo implica singularidade

Mostre que se uma matriz quadrada $\mathbf{A}$ de ordem $n \times n$ possui um autovalor nulo ($\lambda = 0$), então $\mathbf{A}$ é *singular* (não possui inversa).

SOLUÇÃO:

Se $\lambda = 0$ é um autovalor de $\mathbf{A}$, então existe um vetor não nulo $\mathbf{x} \neq \mathbf{0}$ tal que

$$\mathbf{A}\mathbf{x} = 0 \cdot \mathbf{x} \implies \mathbf{A}\mathbf{x} = \mathbf{0}.$$

Logo, o sistema homogêneo $\mathbf{A}\mathbf{x} = \mathbf{0}$ possui solução não trivial. Isso significa que as colunas de $\mathbf{A}$ formam um conjunto de vetores linearmente dependentes e, consequentemente, $\mathbf{A}$ não de posto completo, i.e., $r(\mathbf{A}) < n$. Portanto, $\det(\mathbf{A}) = 0$, da onde concluímos que $\mathbf{A}$ não é inversível, i.e., $\mathbf{A}$ é singular.

4.2 Decomposição espectral

Nesta seção, estudaremos a *decomposição espectral* de matrizes, mas nosso foco estará no caso mais importante para a Estatística: o das matrizes simétricas reais. Essa escolha não é por acaso. Em muitos problemas estatísticos, trabalhamos com matrizes de variâncias e covariâncias, correlações ou matrizes associadas a transformações lineares em espaços de dados multivariados, e todas essas matrizes são, em geral, simétricas. Por isso, entender como uma matriz simétrica pode ser decomposta em termos de seus autovalores e autovetores é fundamental para interpretar a estrutura de dependência entre as variáveis, construir novas combinações lineares (como em análise de componentes principais) e, de modo geral, explorar a geometria dos dados em dimensões mais altas.

Antes de apresentarmos a decomposição espectral, destacamos dois resultados fundamentais sobre matrizes simétricas reais, que aceitaremos sem demonstração. Primeiro, toda matriz simétrica real de ordem $n \times n$ possui exatamente n autovalores *contando multiplicidades algébricas*, isto é, se escrevermos o polinômio característico de $\mathbf{A}$, a soma das multiplicidades das suas raízes é sempre n . Assim, podemos associar n autovetores a esses n autovalores (com repetições), de modo que cada autovalor apareça tantas vezes quanto a sua multiplicidade algébrica. Além disso, autovalores distintos possuem autovetores ortogonais entre si e, quando um autovalor é repetido, os autovetores do autoespaço correspondente podem ser ortogonalizados por meio do procedimento de Gram–Schmidt. A união das bases ortonormais de cada autoespaço fornece, então, uma base ortonormal completa de $\mathbb{R}^n$ formada por autovetores de $\mathbf{A}$. Esses fatos tornam o caso das matrizes

simétricas particularmente simples e importante para nós, pois todos os autovalores são reais e conseguimos trabalhar sempre com autovetores ortogonais, o que será essencial para desenvolver a decomposição espectral.

Nesse contexto, suponha que $\mathbf{A}$ seja uma matriz simétrica real de ordem $n \times n$. Pela discussão anterior, existem autovalores reais $\lambda_1, \lambda_2, \dots, \lambda_n$ (com repetição, de acordo com a multiplicidade algébrica) e autovetores associados $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$, que podemos escolher como quisermos dos respectivos autoespaços associados.

Definimos então as matrizes

$$\mathbf{Q} := [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_n], \quad \mathbf{\Lambda} := \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}.$$

É comum (mas não obrigatório) ordenar os autovalores em ordem decrescente, i.e., $\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_n$. Essa será a convenção que adotaremos nessas notas.

Como cada $\mathbf{x}_i$ é autovetor de $\mathbf{A}$ com autovalor λ_i , temos, para $i = 1, 2, \dots, n$,

$$\mathbf{A}\mathbf{e}_i = \lambda_i\mathbf{e}_i.$$

Podemos reunir essas n equações em uma única igualdade matricial. De fato,

$$\begin{aligned} \mathbf{A}\mathbf{Q} &= \mathbf{A}[\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_n] \\ &= [\mathbf{A}\mathbf{x}_1 \quad \mathbf{A}\mathbf{x}_2 \quad \cdots \quad \mathbf{A}\mathbf{x}_n] \\ &= [\lambda_1\mathbf{e}_1 \quad \lambda_2\mathbf{e}_2 \quad \cdots \quad \lambda_n\mathbf{e}_n] \\ &= [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_n] \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} \\ &= \mathbf{Q}\mathbf{\Lambda}. \end{aligned}$$

Portanto,

$$\mathbf{A}\mathbf{Q} = \mathbf{Q}\mathbf{\Lambda}.$$

A igualdade $\mathbf{A}\mathbf{Q} = \mathbf{Q}\mathbf{\Lambda}$ mostra que, se a matriz $\mathbf{Q}$ for inversível, então podemos decompor a matriz $\mathbf{A}$ escrevendo $\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1}$. Assim, a possibilidade de obter uma decomposição espectral depende essencialmente de garantirmos que $\mathbf{Q}$ é de fato inversível.

Os resultados apresentados a seguir assegurarão exatamente isso. Veremos que, no caso das matrizes simétricas reais, os autovetores são ortogonais e sempre é possível escolher autovetores ortonormais, de modo que $\mathbf{Q}$ se torna uma matriz ortogonal e, portanto, automaticamente inversível.

Para construir a decomposição espectral de forma cuidadosa, começaremos pelo caso mais simples, em que todos os autovalores de $\mathbf{A}$ são distintos. Nessa situação, veremos que os autovetores associados formam automaticamente um conjunto de vetores ortogonais, o que facilita bastante a análise. Em seguida, trataremos do caso em que alguns autovalores possuem multiplicidade maior que 1. Nessa segunda etapa, será necessário olhar com mais atenção para os autoespaços correspondentes a autovalores repetidos e mostrar como podemos escolher, dentro de cada um deles, uma base ortonormal, de modo que, ao final, continuemos obtendo uma base ortonormal completa de autovetores de $\mathbf{A}$.

Resultado 4.2: Autovetores de autovalores distintos são ortogonais

Sejam n um número inteiro positivo e $\mathbf{A}$ uma matriz simétrica real de ordem $n \times n$. Se os autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$ são todos distintos entre si, então os autovetores associados $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ são dois a dois ortogonais.

DEMONSTRAÇÃO:

Considere dois autovalores distintos λ_i e λ_j de $\mathbf{A}$, com autovetores (não-nulos) associados $\mathbf{v}_i$ e $\mathbf{v}_j$, isto é,

$$\mathbf{A}\mathbf{x}_i = \lambda_i\mathbf{x}_i \quad \text{e} \quad \mathbf{A}\mathbf{x}_j = \lambda_j\mathbf{x}_j, \quad i \neq j.$$

Note que

$$\begin{aligned} \mathbf{A}\mathbf{x}_i = \lambda_i\mathbf{x}_i &\Rightarrow \mathbf{x}_j^\top \mathbf{A}\mathbf{x}_i = \mathbf{x}_j^\top \lambda_i\mathbf{x}_i \\ &\Rightarrow (\mathbf{A}^\top \mathbf{x}_j)^\top \mathbf{x}_i = \lambda_i \mathbf{x}_j^\top \mathbf{x}_i \\ &\stackrel{(i)}{\Rightarrow} (\mathbf{A}\mathbf{x}_j)^\top \mathbf{x}_i = \lambda_i \mathbf{x}_j^\top \mathbf{x}_i \\ &\stackrel{(ii)}{\Rightarrow} (\lambda_j \mathbf{x}_j)^\top \mathbf{x}_i = \lambda_i \mathbf{x}_j^\top \mathbf{x}_i \\ &\Rightarrow \lambda_j \mathbf{x}_j^\top \mathbf{x}_i = \lambda_i \mathbf{x}_j^\top \mathbf{x}_i \\ &\Rightarrow (\lambda_j - \lambda_i)(\mathbf{x}_j^\top \mathbf{x}_i) = 0, \end{aligned}$$

em que (i) segue do fato de $\mathbf{A}$ ser simétrica e (ii) segue da definição de autovalor e autovetor. Como $\lambda_i \neq \lambda_j$, segue que $\mathbf{v}_j^\top \mathbf{v}_i = 0$. Portanto, $\mathbf{v}_i$ e $\mathbf{v}_j$ são ortogonais sempre que $i \neq j$.

O resultado anterior mostra que, no caso em que todos os autovalores são distintos, os autovetores associados $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n$ são dois a dois ortogonais. Em particular, isso implica que eles são linearmente independentes e, portanto, formam uma base de $\mathbb{R}^n$. Se construirmos a matriz

$$\mathbf{Q} = [\mathbf{x}_1 \quad \mathbf{x}_2 \quad \cdots \quad \mathbf{x}_n],$$

segue que $\mathbf{Q}$ é inversível e a relação $\mathbf{A}\mathbf{Q} = \mathbf{Q}\mathbf{\Lambda}$ nos permite escrever

$$\mathbf{A} = \mathbf{Q}\mathbf{\Lambda}\mathbf{Q}^{-1}.$$

No entanto, como já vimos, podemos (e vamos) escolher os autovetores com norma igual a 1, isto é, podemos normalizá-los definindo

$$\mathbf{e}_i = \frac{\mathbf{x}_i}{\|\mathbf{x}_i\|}, \quad i = 1, \dots, n.$$

Dessa forma, o conjunto $\{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ passa a ser uma base ortonormal de $\mathbb{R}^n$. Se agora definirmos

$$\mathbf{P} = [\mathbf{e}_1 \quad \mathbf{e}_2 \quad \cdots \quad \mathbf{e}_n],$$

as colunas de $\mathbf{P}$ formam um conjunto ortonormal, o que implica $\mathbf{P}^\top \mathbf{P} = \mathbf{I}_n$; logo, $\mathbf{P}$ é uma matriz ortogonal, inversível de modo natural, com $\mathbf{P}^{-1} = \mathbf{P}^\top$. Nesse passo, será mais conveniente trabalhar com a matriz $\mathbf{P}$ (cujas colunas são os autovetores normalizados), e a decomposição espectral assume a forma

$$\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top.$$

Exemplo 4.5: Decomposição espectral de matrizes simétricas

Considere as seguintes matrizes simétricas reais

$$(a) \quad \mathbf{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix}, \quad (b) \quad \mathbf{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 6 \end{bmatrix}.$$

Para cada matriz, encontre a **decomposição espectral**, isto é, matrizes $\mathbf{P}$ (ortonormal) e $\mathbf{\Lambda}$ (diagonal) tais que $\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top$.

Exemplo 4.5SOLUÇÃO:

(a) Do Exemplo 1.3, já sabemos que a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 0 & 0 \\ 0 & -4 & 0 \\ 0 & 0 & 6 \end{bmatrix}$$

tem autovalores

$$\lambda_1 = 6, \quad \lambda_2 = 2, \quad \lambda_3 = -4,$$

com os seguintes autovetores unitários associados, respectivamente:

$$\mathbf{e}_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Construímos, então, a matriz ortogonal $\mathbf{P}$ colocando esses autovetores como colunas:

$$\mathbf{P} = [\mathbf{e}_1 \quad \mathbf{e}_2 \quad \mathbf{e}_3] = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}, \quad \mathbf{P}^\top \mathbf{P} = \mathbf{I}_3.$$

A matriz diagonal dos autovalores, na mesma ordem das colunas de $\mathbf{P}$, é

$$\mathbf{\Lambda} = \begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & -4 \end{bmatrix}.$$

Assim, obtemos a decomposição espectral de $\mathbf{A}$, i.e.,

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top,$$

em que $\mathbf{P}$ é ortogonal e $\mathbf{\Lambda}$ contém os autovalores de $\mathbf{A}$ na diagonal.

Exemplo 4.5

(b) Como vimos no Exemplo 1.3, os autovalores de $\mathbf{A}$, em ordem decrescente, são

$$\lambda_1 = 6, \quad \lambda_2 = 2, \quad \lambda_3 = 2,$$

e podemos escolher os seguintes autovetores unitários associados:

$$\mathbf{e}_1 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \quad \mathbf{e}_2 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{e}_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}.$$

Dessa forma, obtemos a matriz diagonal dos autovalores

$$\mathbf{\Lambda} = \begin{bmatrix} 6 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

e a matriz ortogonal

$$\mathbf{P} = [\mathbf{e}_1 \quad \mathbf{e}_2 \quad \mathbf{e}_3] = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}, \quad \mathbf{P}^\top \mathbf{P} = \mathbf{I}_3.$$

Assim, a decomposição espectral de $\mathbf{A}$ é dada por

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top.$$

Vale notar que, no item (b) do Exemplo 3.4, o autovalor de maior multiplicidade algébrica possui multiplicidade 2, e sua multiplicidade geométrica também é igual a 2. Nesse caso, mesmo sem aplicarmos qualquer procedimento de ortonormalização (veremos o método de Gram–Schmidt adiante), obtivemos *gratuitamente* uma base ortonormal de autovetores. Isso ocorre porque, para matrizes simétricas, autoespaços associados a autovalores distintos são automaticamente ortogonais entre si e, além disso, cada autoespaço admite uma base ortogonal. Assim, basta normalizar os autovetores encontrados: eles já formam uma base ortonormal dentro de cada autoespaço e também entre autoespaços distintos.

Resultado 4.3: Determinante, traço e potências de matrizes simétricas

Seja $\mathbf{A}$ uma matriz simétrica real de ordem $n \times n$. Denotemos por $\lambda_1, \lambda_2, \dots, \lambda_n$ os autovalores reais de $\mathbf{A}$. Então valem as seguintes afirmações:

(a) O determinante de $\mathbf{A}$ é o produto dos seus autovalores, i.e.,

$$\det(\mathbf{A}) = \lambda_1 \lambda_2 \cdots \lambda_n.$$

(b) O traço de $\mathbf{A}$ é a soma dos seus autovalores, i.e.,

$$\text{tr}(\mathbf{A}) = \lambda_1 + \lambda_2 + \cdots + \lambda_n.$$

(c) Para todo inteiro $k \geq 1$, vale

$$\mathbf{A}^k = \mathbf{P} \mathbf{\Lambda}^k \mathbf{P}^\top.$$

DEMONSTRAÇÃO: Como $\mathbf{A}$ é simétrica, $\mathbf{A}$ admite a decomposição espectral. Assim, denotando por $\mathbf{P}$ a matriz ortogonal cujas colunas são os autovetores de $\mathbf{A}$ associados com os autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$ de $\mathbf{A}$ e $\mathbf{\Lambda}$ a matriz diagonal cujos elementos da diagonal principal são os autovalores de $\mathbf{A}$ segue que

(a)

$$\begin{aligned} \mathbf{A} &= \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top \Rightarrow \det(\mathbf{A}) = \det(\mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top) \\ &\Rightarrow \det(\mathbf{A}) = \det(\mathbf{P}) \det(\mathbf{\Lambda}) \det(\mathbf{P}^\top) \\ &\Rightarrow \det(\mathbf{A}) = \det(\mathbf{P}) \det(\mathbf{\Lambda}) \det(\mathbf{P}^{-1}) \\ &\Rightarrow \det(\mathbf{A}) = \det(\mathbf{P}) \det(\mathbf{\Lambda}) \det(\mathbf{P}^{-1}) \\ &\Rightarrow \det(\mathbf{A}) = \det(\mathbf{P}) \det(\mathbf{\Lambda}) \frac{1}{\det(\mathbf{P})} \\ &\Rightarrow \det(\mathbf{A}) = \det(\mathbf{\Lambda}) \\ &\Rightarrow \det(\mathbf{A}) = \prod_{i=1}^n \lambda_i. \end{aligned}$$

Resultado 4.3

(b)

$$\begin{aligned}
\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top &\Rightarrow \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top) \\
&\Rightarrow \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{P}^\top\mathbf{P}\mathbf{\Lambda}) \\
&\Rightarrow \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{P}^{-1}\mathbf{P}\mathbf{\Lambda}) \\
&\Rightarrow \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{I}_n\mathbf{\Lambda}) \\
&\Rightarrow \text{tr}(\mathbf{A}) = \text{tr}(\mathbf{\Lambda}) \\
&\Rightarrow \det(\mathbf{A}) = \sum_{i=1}^n \lambda_i.
\end{aligned}$$

(c)

$$\begin{aligned}
\mathbf{A} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top &\Rightarrow \mathbf{A}^k = (\mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top)^k \\
&\Rightarrow \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top\mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top \dots \mathbf{P}\mathbf{\Lambda}\mathbf{P}^\top \\
&\Rightarrow \mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1}\mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1} \dots \mathbf{P}\mathbf{\Lambda}\mathbf{P}^{-1} \\
&\Rightarrow \mathbf{P}\mathbf{\Lambda}\mathbf{\Lambda} \dots \mathbf{\Lambda}\mathbf{P}^{-1} \\
&\Rightarrow \mathbf{P}\mathbf{\Lambda}^k\mathbf{P}^{-1} \\
&\Rightarrow \mathbf{P}\mathbf{\Lambda}^k\mathbf{P}^\top.
\end{aligned}$$

■

4.3 Decomposição em valores singulares

Após estudarmos a decomposição espectral para matrizes simétricas, avançamos agora para um resultado ainda mais geral, aplicável a qualquer matriz real, quadrada ou retangular. Trata-se da *decomposição em valores singulares* (SVD), uma ferramenta central em Estatística e em diversas áreas das ciências de dados.

As ideias que motivam a decomposição espectral podem ser estendidas para obter uma decomposição adequada também para matrizes retangulares, e não apenas para matrizes quadradas. Se $\mathbf{A}$ é uma matriz retangular, então os vetores que aparecem na expansão de $\mathbf{A}$ estão relacionados aos autovetores das matrizes quadradas $\mathbf{A}\mathbf{A}^\top$ e $\mathbf{A}^\top\mathbf{A}$.

Resultado 4.4: Decomposição em Valores Singulares

Seja $\mathbf{A}$ uma matriz real de ordem $n \times p$. Então existem uma matriz ortogonal $\mathbf{U}$ de ordem $n \times n$ e uma matriz ortogonal $\mathbf{V}$ de ordem $p \times p$ tais que

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top,$$

em que a matriz $\mathbf{\Sigma}$, de ordem $n \times p$, cujos *elementos diagonais*, i.e., que estão na i -ésima linha e i -ésima coluna de $\mathbf{\Sigma}$, são $\sigma_1, \sigma_2, \dots, \sigma_{\min(n,p)}$ satisfazendo $\sigma_i \geq 0$ para cada i , e os demais elementos são iguais a zero. As constantes positivas σ_i são chamadas de *valores singulares* da matriz $\mathbf{A}$.

Começamos observando que a matriz $\mathbf{A}^\top \mathbf{A}$ é sempre uma matriz simétrica de ordem $p \times p$. Dessa forma, pelo resultado estudado na seção anterior, sabemos que $\mathbf{A}^\top \mathbf{A}$ admite uma decomposição espectral. Em outras palavras, existe uma matriz ortogonal $\mathbf{P}$, de ordem $p \times p$, cujas colunas formam um conjunto de vetores ortonormais de $\mathbf{A}^\top \mathbf{A}$, e existe uma matriz diagonal $\mathbf{\Lambda}$, de ordem $p \times p$, cujos elementos da diagonal principal são exatamente os autovalores de $\mathbf{A}^\top \mathbf{A}$, tais que

$$\mathbf{A}^\top \mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^\top.$$

Além disso, sabemos que sempre existe uma decomposição em valores singulares para qualquer matriz $\mathbf{A}$ de ordem $n \times p$. Isto é, podemos escrevê-la como

$$\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top,$$

em que $\mathbf{U}$ e $\mathbf{V}$ são matrizes ortogonais de ordens $n \times n$ e $p \times p$, respectivamente, e $\mathbf{\Sigma}$ é uma matriz $n \times p$ cujos elementos diagonais são não negativos.

Aplicando essa fatoração à identidade anterior, obtemos

$$\mathbf{A}^\top \mathbf{A} = (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top)^\top (\mathbf{U} \mathbf{\Sigma} \mathbf{V}^\top) = \mathbf{V} \mathbf{\Sigma}^\top \mathbf{\Sigma} \mathbf{V}^\top.$$

Comparando essa expressão com a decomposição espectral de $\mathbf{A}^\top \mathbf{A}$, concluímos que

$$\mathbf{V}^\top = \mathbf{P}^\top \quad \text{e} \quad \mathbf{\Sigma}^\top \mathbf{\Sigma} = \mathbf{\Lambda}.$$

Ou seja, os *vetores singulares à direita* (colunas de $\mathbf{V}$) coincidem com os autovetores de $\mathbf{A}^\top \mathbf{A}$, e os *valores singulares* σ_i são as raízes quadradas dos autovalores correspondentes.

De forma análoga, a matriz $\mathbf{A}\mathbf{A}^\top$ é simétrica de ordem $n \times n$ e também admite decomposição espectral:

$$\mathbf{A}\mathbf{A}^\top = \mathbf{Q}\mathbf{\Lambda}^*\mathbf{Q}^\top,$$

em que $\mathbf{Q}$ é uma matriz ortogonal cujas colunas são vetores ortonormais de $\mathbf{A}\mathbf{A}^\top$, e $\mathbf{\Lambda}^*$ é uma matriz diagonal cujos elementos da diagonal são os autovalores de $\mathbf{A}\mathbf{A}^\top$.

Usando novamente a decomposição singular,

$$\mathbf{A}\mathbf{A}^\top = (\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top)(\mathbf{U}\mathbf{\Sigma}\mathbf{V}^\top)^\top = \mathbf{U}\mathbf{\Sigma}\mathbf{\Sigma}^\top\mathbf{U}^\top.$$

Comparando essa expressão com a decomposição espectral acima, obtemos

$$\mathbf{U} = \mathbf{Q} \quad \text{e} \quad \mathbf{\Sigma}\mathbf{\Sigma}^\top = \mathbf{\Lambda}^*.$$

Portanto, podemos interpretar a matriz $\mathbf{U}$ como contendo vetores associados aos autovalores de $\mathbf{A}\mathbf{A}^\top$, enquanto a matriz $\mathbf{V}$ reúne os vetores associados aos autovalores de $\mathbf{A}^\top\mathbf{A}$. As matrizes diagonais $\mathbf{\Lambda}$ e $\mathbf{\Lambda}^*$ possuem os mesmos autovalores, apenas organizados em ordens diferentes para se ajustarem às dimensões de $\mathbf{\Sigma}^\top\mathbf{\Sigma}$ e $\mathbf{\Sigma}\mathbf{\Sigma}^\top$. Dessa forma, os valores singulares σ_i de $\mathbf{A}$ são as raízes quadradas dos autovalores comuns às duas matrizes simétricas $\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$.

Resultado 4.5

Sejam n e p números inteiros positivos e seja $\mathbf{A}$ uma matriz real de ordem $n \times p$. Valem as afirmações:

- (a) $\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ são matrizes cujos autovalores são maiores ou iguais a zero.
- (b) Se $\mathbf{u} \in \mathbb{R}^p$ é um autovetor de $\mathbf{A}^\top\mathbf{A}$ associado a um autovalor não nulo λ , então $\mathbf{A}\mathbf{u}$ é um autovetor de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor λ .
- (c) As matrizes $\mathbf{A}^\top\mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ possuem os mesmos autovalores não nulos, contando multiplicidades.

DEMONSTRAÇÃO:

- (a) Seja $\mathbf{x} \in \mathbb{R}^p$. Então

$$\mathbf{x}^\top \mathbf{A}^\top \mathbf{A} \mathbf{x} = (\mathbf{A}\mathbf{x})^\top (\mathbf{A}\mathbf{x}) = \|\mathbf{A}\mathbf{x}\|^2 \geq 0.$$

Resultado 4.5

Logo, $\mathbf{A}^\top \mathbf{A}$ é simétrica definida não negativa, e todos seus autovalores são reais e maiores ou iguais a zero. De modo análogo, para $\mathbf{y} \in \mathbb{R}^n$,

$$\mathbf{y}^\top \mathbf{A} \mathbf{A}^\top \mathbf{y} = (\mathbf{A}^\top \mathbf{y})^\top (\mathbf{A}^\top \mathbf{y}) = \|\mathbf{A}^\top \mathbf{y}\|^2 \geq 0,$$

o que mostra que todos os autovalores de $\mathbf{A} \mathbf{A}^\top$ também são maiores ou iguais a zero.

- (b) Suponha que $\mathbf{u} \in \mathbb{R}^p$ seja um autovetor de $\mathbf{A}^\top \mathbf{A}$ associado a um autovalor não nulo λ , isto é,

$$\mathbf{A}^\top \mathbf{A} \mathbf{u} = \lambda \mathbf{u}, \quad \lambda \neq 0.$$

Multiplicando à esquerda por $\mathbf{A}$, obtemos

$$\mathbf{A} \mathbf{A}^\top \mathbf{A} \mathbf{u} = \mathbf{A} (\mathbf{A}^\top \mathbf{A} \mathbf{u}) = \mathbf{A} (\lambda \mathbf{u}) = \lambda \mathbf{A} \mathbf{u}.$$

Logo, $\mathbf{A} \mathbf{u}$ é um autovetor de $\mathbf{A} \mathbf{A}^\top$ associado ao autovalor λ . Resta verificar que $\mathbf{A} \mathbf{u} \neq \mathbf{0}$. Se tivéssemos $\mathbf{A} \mathbf{u} = \mathbf{0}$, então

$$\lambda \mathbf{u} = \mathbf{A}^\top \mathbf{A} \mathbf{u} = \mathbf{A}^\top \mathbf{0} = \mathbf{0},$$

o que implicaria $\mathbf{u} = \mathbf{0}$, contradição com o fato de $\mathbf{u}$ ser autovetor. Portanto, $\mathbf{A} \mathbf{u} \neq \mathbf{0}$ e a afirmação está demonstrada.

- (c) Vamos mostrar que $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A} \mathbf{A}^\top$ possuem os mesmos autovalores não nulos, contando multiplicidade. Se $\lambda \neq 0$ é autovalor de $\mathbf{A}^\top \mathbf{A}$, então existe $\mathbf{u} \neq \mathbf{0}$ tal que

$$\mathbf{A}^\top \mathbf{A} \mathbf{u} = \lambda \mathbf{u}.$$

Multiplicando à esquerda por $\mathbf{A}$,

$$\mathbf{A} \mathbf{A}^\top (\mathbf{A} \mathbf{u}) = \lambda (\mathbf{A} \mathbf{u}),$$

e, como no item (b), $\mathbf{A} \mathbf{u} \neq \mathbf{0}$. Logo, λ é autovalor de $\mathbf{A} \mathbf{A}^\top$. O mesmo argumento, começando por um autovalor não nulo de $\mathbf{A} \mathbf{A}^\top$, mostra que todo autovalor não nulo de $\mathbf{A} \mathbf{A}^\top$ também é autovalor de $\mathbf{A}^\top \mathbf{A}$. Portanto, as duas matrizes possuem exatamente os mesmos autovalores não nulos, com as mesmas multiplicidades. ■

Exemplo 4.6

Determine a decomposição em valores singulares da matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 0 & 0 \end{bmatrix}.$$

SOLUÇÃO:

- Cálculo de $\mathbf{A}^\top \mathbf{A}$:

$$\mathbf{A}^\top \mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix}.$$

- Polinômio característico de $\mathbf{A}^\top \mathbf{A}$:

$$P_\lambda(\mathbf{A}^\top \mathbf{A}) = \begin{vmatrix} 5 - \lambda & 4 \\ 4 & 5 - \lambda \end{vmatrix} = (5 - \lambda)^2 - 16 = \lambda^2 - 10\lambda + 9.$$

- Autovalores de $\mathbf{A}^\top \mathbf{A}$: Os autovalores desta matriz são obtidos de $P_\lambda(\mathbf{A}^\top \mathbf{A}) = 0$, cujas soluções são $\lambda_1 = 9$ e $\lambda_2 = 1$.
- Autovetor unitário associado com $\lambda_1 = 9$:

$$\begin{aligned} (\mathbf{A}^\top \mathbf{A}) \mathbf{x} &= \lambda_1 \mathbf{x} \Rightarrow \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 9 \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\ &\Rightarrow \begin{bmatrix} 5x_1 + 4x_2 \\ 4x_1 + 5x_2 \end{bmatrix} = \begin{bmatrix} 9x_1 \\ 9x_2 \end{bmatrix} \\ &\Rightarrow \begin{cases} 5x_1 + 4x_2 = 9x_1, \\ 4x_1 + 5x_2 = 9x_2 \end{cases} \\ &\Rightarrow x_1 = x_2 = t, \quad t \in \mathbb{R}^* \end{aligned}$$

Logo,

Exemplo 4.6

$$\begin{aligned}
 V(9) &= \left\{ \begin{bmatrix} t \\ t \end{bmatrix} : t \in \mathbb{R} \right\} \\
 &= \left\{ t \begin{bmatrix} 1 \\ 1 \end{bmatrix} : t \in \mathbb{R} \right\} \\
 &= \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \end{bmatrix} \right\}
 \end{aligned}$$

Portanto,

$$\mathbf{e}_1 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix}.$$

- Autovetor unitário associado com $\lambda_2 = 1$:

$$\begin{aligned}
 (\mathbf{A}^\top \mathbf{A}) \mathbf{x} &= \lambda_2 \mathbf{x} \Rightarrow \begin{bmatrix} 5 & 4 \\ 4 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 &\Rightarrow \begin{bmatrix} 5x_1 + 4x_2 \\ 4x_1 + 5x_2 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 &\Rightarrow \begin{cases} 5x_1 + 4x_2 = x_1, \\ 4x_1 + 5x_2 = x_2 \end{cases} \\
 &\Rightarrow x_2 = -x_1,
 \end{aligned}$$

Logo,

$$\begin{aligned}
 V(1) &= \left\{ \begin{bmatrix} t \\ -t \end{bmatrix} : t \in \mathbb{R} \right\} \\
 &= \left\{ t \begin{bmatrix} 1 \\ -1 \end{bmatrix} : t \in \mathbb{R} \right\} \\
 &= \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \end{bmatrix} \right\}
 \end{aligned}$$

Portanto,

$$\mathbf{e}_2 = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

Exemplo 4.6

- Decomposição espectral de $A^T A$:

$$A^T A = P \Lambda P^T,$$

em que

$$P = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix} \quad \text{e} \quad \Lambda = \begin{bmatrix} 9 & 0 \\ 0 & 1 \end{bmatrix}.$$

- Cálculo de AA^T :

$$AA^T = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 2 & 1 & 0 \\ 1 & 2 & 0 \end{bmatrix} = \begin{bmatrix} 5 & 5 & 0 \\ 5 & 5 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

- Autovalores de AA^T : Os autovalores não-nulos desta matriz são iguais aos da matriz $A^T A$. Logo, $\lambda_1^* = \lambda_1 = 9$, $\lambda_2^* = \lambda_2 = 1$ e $\lambda_3^* = 0$.
- Autovetor unitário associado com $\lambda_1^* = 9$:

$$Ae_1 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 3 \\ 3 \\ 0 \end{bmatrix}.$$

Logo,

$$e_1^* = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}.$$

- Autovetor unitário associado com $\lambda_2^* = 1$:

$$Ae_2 = \begin{bmatrix} 2 & 1 \\ 1 & 2 \\ 0 & 0 \end{bmatrix} \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix},$$

. Logo,

$$e_2^* = \frac{1}{\sqrt{2}} \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}.$$

Exemplo 4.6

- Autovetor unitário associado com $\lambda_3^* = 0$:

$$\begin{aligned}
 (\mathbf{A}\mathbf{A}^\top) \mathbf{x} = \lambda_3^* \mathbf{x} &\Rightarrow \begin{bmatrix} 5 & 5 & 0 \\ 5 & 5 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \\
 &\Rightarrow \begin{bmatrix} 5x_1 + 5x_2 \\ 5x_1 + 5x_2 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix} \\
 &\Rightarrow \begin{cases} 5x_1 + 5x_2 = 0, \\ 5x_1 + 5x_2 = 0 \\ 0 = 0 \end{cases} \\
 &\Rightarrow \begin{cases} x_1 = t, & t \in \mathbb{R}, \\ x_2 = -t, \\ x_3 = s, & s \in \mathbb{R}, \end{cases}
 \end{aligned}$$

em que s e t não são simultaneamente nulos. Logo,

$$\begin{aligned}
 V(0) &= \left\{ \begin{bmatrix} t \\ -t \\ s \end{bmatrix} : s, t \in \mathbb{R} \right\} \\
 &= \left\{ t \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + s \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} : t, s \in \mathbb{R} \right\} \\
 &= \text{span} \left\{ \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}.
 \end{aligned}$$

Portanto,

$$\mathbf{e}_3^* = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

Exemplo 4.6

- **Decomposição espectral de $AA^\top$:**

$$AA^\top = Q\Lambda^*Q^\top,$$

em que

$$Q = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad \text{e} \quad \Lambda^* = \begin{bmatrix} 9 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}.$$

- **Decomposição em valores singulares:** Portanto, a decomposição em valores singulares é

$$A = U\Sigma V^\top,$$

em que

$$U = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix} \quad \text{e} \quad V^\top = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}.$$

4.4 Exercícios

1. Considere as seguintes **matrizes quadradas**

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \quad \text{e} \quad B = \begin{bmatrix} 2 & 0 & 0 \\ 2 & 1 & 2 \\ 3 & 2 & 1 \end{bmatrix}.$$

- (a) Determine o domínio, contradomínio e a lei dos **operadores lineares** associados às matrizes definidas anteriormente.
- (b) Verifique que

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ \sqrt{2} - 1 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_2 = \begin{bmatrix} 1 \\ -(1 + \sqrt{2}) \end{bmatrix}$$

são **autovetores** de **A**. Quais são os **autovalores** associados a esses autovetores?

(c) Verifique que

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \quad \mathbf{x}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{x}_3 = \begin{bmatrix} 0 \\ -1 \\ 1 \end{bmatrix}$$

são **autovetores** de $\mathbf{B}$. Quais são os **autovalores** associados a esses autovetores?

2. Determine os **polinômios característicos** das seguintes **matrizes quadradas**.

$$(a) \mathbf{A} = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}. \quad (b) \mathbf{B} = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}. \quad (c) \mathbf{C} = \begin{bmatrix} 4 & 4 \\ 1 & 4 \end{bmatrix}. \quad (d) \begin{bmatrix} 0 & 7 & -6 \\ -1 & 4 & 0 \\ 0 & 2 & -2 \end{bmatrix}.$$

3. Determine os **autovalores** e **autovetores** das **matrizes quadradas** associadas aos seguintes **operadores lineares**.

$$(a) F: \mathbb{R}^2 \rightarrow \mathbb{R}^2 \text{ tal que } F\left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix}\right) = \begin{bmatrix} x_1 + 2x_2 \\ 2x_1 - 2x_2 \end{bmatrix}.$$

$$(b) F: \mathbb{R}^3 \rightarrow \mathbb{R}^3 \text{ tal que } F\left(\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}\right) = \begin{bmatrix} 4x_1 \\ 9x_2 \\ x_3 \end{bmatrix}.$$

$$(c) F: \mathbb{R}^3 \rightarrow \mathbb{R}^3 \text{ tal que } F\left(\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}\right) = \begin{bmatrix} x_1 + x_2 + x_3 \\ x_1 + x_2 + x_3 \\ x_1 + x_2 + x_3 \end{bmatrix}.$$

4. (a) Verifique que **todas** as matrizes obtidas no Exercício 9 que são **invertíveis** possuem **autovalores** diferentes de zero ($\lambda \neq 0$).

(b) Quais dentre as matrizes obtidas no Exercício 9 possuem **autovalor** nulo ($\lambda = 0$)? Essas matrizes admitem inversa? Por quê?

5. Mostre que se $\mathbf{A}$ é uma **matriz quadrada** de ordem $n \times n$ que apresenta algum **autovalor nulo** ($\lambda = 0$), então $\mathbf{A}$ é **singular**.

6. Verifique se as matrizes definidas a seguir são **ortogonais**.

$$(a) \mathbf{P} = \begin{bmatrix} \frac{5}{13} & \frac{12}{13} \\ -\frac{12}{13} & \frac{5}{13} \end{bmatrix}. \quad (b) \mathbf{P} = \begin{bmatrix} \cos(\theta) & -\sin(\theta) \\ \sin(\theta) & \cos(\theta) \end{bmatrix}. \quad (c) \mathbf{P} = \begin{bmatrix} \frac{2}{3} & -\frac{2}{3} & \frac{1}{3} \\ \frac{2}{3} & \frac{1}{3} & -\frac{2}{3} \\ \frac{1}{3} & \frac{2}{3} & \frac{2}{3} \end{bmatrix}.$$

7. Determine a **decomposição espectral** das seguintes matrizes de variâncias e covari-

$$\text{âncias.} \quad (a) \mathbf{\Sigma} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 9 & 0 \\ 0 & 0 & 1 \end{bmatrix} \quad (b) \mathbf{\Sigma} = \begin{bmatrix} 2\sigma^2 & 0 \\ 0 & \sigma^2 \end{bmatrix} \text{ com } \sigma^2 > 0. \quad (c) \mathbf{\Sigma} = \begin{bmatrix} 4 & 3 \\ 3 & 4 \end{bmatrix}.$$

8. Para cada uma das matrizes do Exercício 13, faça o que se pede.

- (a) Calcule o determinante.
- (b) Calcule Σ^{100} .
- (c) Determine Σ^{-1} , se existir.

9. Usando a matriz

$$\mathbf{A} = \begin{bmatrix} 1 & 1 \\ 2 & -2 \\ 2 & 2 \end{bmatrix}.$$

- (a) Calcule $\mathbf{A}^\top \mathbf{A}$ e obtenha os seus **autovalores** e **autovetores**.
- (b) Calcule $\mathbf{A}\mathbf{A}^\top$ e obtenha os seus **autovalores** e **autovetores**. Lembre-se que os autovalores não-nulos de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ são iguais.
- (c) Obtenha a **decomposição em valores singulares** da matriz $\mathbf{A}$.

10. Usando a matriz

$$\mathbf{A} = \begin{bmatrix} 4 & 8 & 8 \\ 3 & 6 & -9 \end{bmatrix}.$$

- (a) Calcule $\mathbf{A}^\top \mathbf{A}$ e obtenha os seus **autovalores** e **autovetores**.
- (b) Calcule $\mathbf{A}\mathbf{A}^\top$ e obtenha os seus **autovalores** e **autovetores**. Lembre-se que os autovalores não-nulos de $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ são iguais.
- (c) Obtenha a **decomposição em valores singulares** da matriz $\mathbf{A}$.

11. Sejam n e p números inteiros positivos e $\mathbf{A}$ uma matriz de ordem $n \times p$. Mostre que

- (a) $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ são matrizes cujos os **autovalores** são **maiores do que ou iguais a zero**.
- (b) Se $\mathbf{u} \in \mathbb{R}^p$ é **autovetores** de $\mathbf{A}^\top \mathbf{A}$ associado a um **autovalor** não-nulo λ , então $\mathbf{A}\mathbf{u}$ é um **autovetor** de $\mathbf{A}\mathbf{A}^\top$ associado ao mesmo autovalor.
- (c) $\mathbf{A}^\top \mathbf{A}$ e $\mathbf{A}\mathbf{A}^\top$ possuem os mesmos **autovalores não-nulos**, considerando a multiplicidade.

5 Considerações finais

“Eu gosto de estar perdida. É um bom lugar para começar.”

Maryam Mirzakhani (1997 – 2017)

Estas notas de aula tiveram como objetivo apresentar, de maneira gradual, os principais elementos da Teoria de Matrizes necessários à formação estatística. Ao longo do semestre, destacamos o papel central que as matrizes desempenham na formulação, interpretação e solução de problemas em Estatística, desde representações de dados e transformações lineares até decomposições fundamentais que sustentam diversos métodos clássicos e modernos.

Começamos revisando os conceitos básicos de vetores, operações matriciais e propriedades algébricas essenciais, enfatizando sempre a interpretação geométrica das transformações lineares. Em seguida, avançamos para resultados estruturais, como postos, núcleos, imagens, bases ortonormais e matrizes ortogonais, relacionando tais ideias a problemas de bijetividade, projeções e mudança de base. Discutimos também formas lineares e quadráticas, a importância das matrizes simétricas e critérios para determinar positividade, tópicos que aparecem recorrentemente em inferência estatística, otimização e aprendizagem de máquina.

Dedicamos atenção especial às decomposições espectral e em valores singulares, tanto pelo seu valor teórico quanto pela ampla gama de aplicações práticas. Buscamos mostrar que cada resultado matricial é, simultaneamente, um instrumento algébrico, uma construção geométrica e um alicerce metodológico para análises estatísticas mais sofisticadas. Em vários momentos, destacamos a necessidade de uma postura crítica: compreender não apenas como aplicar uma técnica, mas também em que condições ela é válida e quais limitações deve-se ter em mente ao utilizá-la.

Com isso, esperamos ter transmitido uma visão integrada do papel da Teoria de Matrizes no estudo da Estatística, que é uma área que se apoia fortemente em conceitos lineares e cujas ferramentas crescem em importância com o avanço dos métodos computacionais e de alta dimensão.

Portanto, acredito que este curso tenha oferecido uma boa introdução à Teoria de Matrizes para Estatística, buscando equilibrar a apresentação dos resultados fundamentais com a valorização de uma postura crítica diante de suas hipóteses e limitações. Espero que estas notas de aula tenham sido úteis em sua trajetória de aprendizado e que o conteúdo aqui discutido possa servir de ponto de partida para estudos mais aprofundados e aplicações práticas em diferentes áreas da Estatística.

